PSL
UNIVERSITÉ PARIS

THÈSE DE DOCTORAT
DE L'UNIVERSITÉ PSL

Préparée à École Normale Supérieure

Modéliser la littérature de genre :

Méthodes computationnelles et évolution des genres dans la fiction de langue française

Soutenue par

Jean Barré

Le 5 juin 2026

École doctorale n°540

LASHS (Lettres, Arts, Sciences humaines et sociales)

Spécialité

Langues et littératures

Préparée au

Laboratoire Lattice
(Langues, Textes, Traitements informatiques, Cognition)

Composition du jury :

Marie-Ève Thérenty Université de Montpellier III	*Présidente*
Evelyn Gius Université Technique de Darmstadt	*Rapporteure*
Matthieu Letourneux Université Paris-Nanterre	*Rapporteur*
Claire Barel-Moisan ENS de Lyon, CNRS	*Examinatrice*
Ted Underwood Université d'Illinois Urbana-Champaign	*Examinateur*
Thomas Conrad ENS-PSL	*Co-encadrant*
Thierry Poibeau ENS-PSL, CNRS	*Directeur*

ENS | PSL

À vous deux, Daniel et Dominique.

Remerciements

Je ne saurais assez remercier mes deux directeurs. Thierry, tu as cru en moi dès le début, quand je ne savais pas encore trop où je mettais les pieds. Thomas, beaucoup s'est joué dans ton bureau à l'ENS, autour des vieux grimoires de la bibliothèque, que je remercie en passant pour les trésors qu'elle couve et qu'elle rend accessibles. Si cette thèse a quelque pertinence, elle en doit beaucoup à vos encouragements quand il en fallait, et à vos mises en garde quand je m'égarais.

Ce travail doit aussi beaucoup à nombre de collègues, qui m'ont montré la voie dans un champ de recherche qui se constitue peu à peu. À Aude Leblond, Fotis Jannidis, David Bamman, Mike Kestemont, Jean-Baptiste Camps, Florian Cafiero, Simon Gabay, pour des échanges qui ont nourri la thèse à des moments décisifs.

Au quotidien, je remercie l'ensemble du Lattice, et plus particulièrement Virginie, sans qui pas grand-chose n'aurait tourné rond ; Frédérique, qui m'a montré une voie plus apaisée dans la recherche ; Olga, qui m'a beaucoup appris par son exigence ; Pascal et Mathieu, qui ont canalisé un enseignant en herbe ; Yoann pour ses fameux cookies du NLP-Lattice ; Sophie, qui veille au grain au laboratoire. Et enfin comment ne pas mentionner thésardland, mes compagnons de galère : Émile en capitaine de route, Mathilde, Milad, Jiayi, Noé, Antoine, Yasi, David, Esther, Mehran, Jeanne, Pedro, et tous les autres.

Spéciale dédicace à mes valeurs refuges de ces dernières années, à Pierre et Violette, pour les mercredis légendaires en CourO ; à Hugo, pour ces brunchs au marché des Lilas. J'ai aussi une grosse pensée pour le cercle des poètes disparus, Jules, Yanis et Giulia, qui auront vu les tout débuts.

Enfin, je ne pourrais finir sans une pensée pour mes parents, votre soutien sans faille a apporté bien plus que vous ne le pensez, et pour mes adelphes Juliette et Nathan, vous avez été des petites bulles de bonheur durant toutes ces années ; et enfin, de tout mon cœur, merci Marie, rien de tout cela n'aurait été possible sans toi.

Résumé

Cette thèse propose une approche computationnelle de la littérature de genre dans la fiction de langue française, en articulant la théorie de l'intertextualité, la modélisation statistique et une analyse des textes à grande échelle. Elle prend appui sur la prémisse structuraliste selon laquelle les œuvres n'existent pas comme unités closes mais comme nœuds d'un réseau de relations, et soutient que les méthodes computationnelles en constituent une opérationnalisation directe. Elles rendent observables, sur de grands corpus, des régularités et des transformations qui échappent à la lecture individuelle.

La première partie construit ce cadre théorique et méthodologique, autour de la notion d'intertextualité, et de sa pertinence pour la notion de genre. Cette dernière y est définie comme une dimension à la fois interne et externe aux textes. Les études littéraires computationnelles se révèlent être une discipline privilégiée pour traiter les conséquences formelles des dispositifs contextuels spécifiques à la littérature de genre. Il s'agit également de mener une présentation critique des principales méthodes computationnelles employées.

La deuxième partie met ce cadre théorique à l'épreuve sur le roman policier (1866–2020). Elle identifie la signature textuelle du roman policier à partir d'une modélisation supervisée et contrôle la robustesse des résultats en examinant les cas limites. Elle analyse ensuite l'archétype du détective, figure clé du genre par la construction d'un *détecteur de détectives*. Cela permet de suivre la stabilité et les transformations de l'enquêteur au cours de l'histoire du genre. Enfin, l'étude de la *naissance* du roman policier montre une sédimentation progressive de trois caractéristiques formelles indépendantes avant la stabilisation médiatique du genre dans les années 1930 : la persistance du thème criminel, la centralité du détective dans le récit et la structure prototypique de l'intrigue, tirée du crime vers sa résolution.

La troisième partie change d'échelle et compare le roman policier au roman d'aventures en proposant de prédire leur présence au sein du corpus romanesque des archives de la Bibliothèque nationale de France. Il s'agit ensuite de détecter la signature du genre au niveau de ses scènes stéréotypiques, entre mésaventure et dépaysement. Elle teste enfin l'hypothèse d'une normalisation formelle accompagnant l'avènement des collections spécialisées dans l'entre-deux-guerres, et montre, en mesurant la diversité discursive de ces deux genres avant et après leur cristallisation éditoriale, que cette reconnaissance s'accompagne d'une contraction de l'espace des possibles discursifs.

Mots clés : littérature de genre, études littéraires computationnelles, romans d'aventures, romans policiers, traitement automatique des langues, lecture distante

Abstract

This thesis proposes a computational approach to genre fiction in French-language literature, articulating intertextuality theory, statistical modelling, and large-scale text analysis. It builds on the structuralist premise that literary works do not exist as self-enclosed units but as nodes in a network of relations, and argues that computational methods constitute a direct operationalisation of this premise. They make it possible to observe, across large corpora, regularities and transformations that elude individual reading.

The first part constructs this theoretical and methodological framework around the notion of intertextuality and its relevance to the notion of genre. Genre is defined therein as a dimension that is both internal and external to texts. Computational literary studies prove to be a privileged discipline for addressing the formal consequences of the contextual apparatus specific to genre fiction. This part also offers a critical presentation of the main computational methods employed.

The second part puts this theoretical framework to the test on the detective novel (1866–2020). It identifies the textual signature of the detective novel through supervised modelling and checks the robustness of the results by examining borderline cases. It then analyses the archetype of the detective, a key figure of the genre, through the construction of a *detective detector*. This makes it possible to track the stability and transformations of the investigator over the history of the genre. Finally, the study of the *birth* of the detective novel reveals a gradual sedimentation of three independent formal characteristics prior to the media stabilisation of the genre in the 1930s : the persistence of the criminal theme, the centrality of the detective within the narrative, and the prototypical structure of the plot, drawn from the crime towards its resolution.

The third part shifts scale and compares the detective novel with the adventure novel by attempting to predict their presence within the novelistic corpus of the Bibliothèque nationale de France archives. It then seeks to detect the genre's signature at the level of its stereotypical scenes, between misadventure and estrangement. Finally, it tests the hypothesis of a formal normalisation accompanying the advent of specialised collections in the interwar period, and shows, by measuring the discursive diversity of these two genres before and after their editorial crystallisation, that this recognition is accompanied by a contraction of the space of discursive possibilities.

Keywords : genre literature, computational literary studies, adventure novels, detective novels, natural language processing, distant reading

Table des matières

Remerciements ii

Résumé iii

Abstract iv

Table des matières iv

Liste des figures xi

Liste des tableaux xiv

Introduction 1
1 La littérature de genre . . . 3
2 Intertextualité et système littéraire . . . 5
3 Les études littéraires computationnelles . . . 6
4 Structure de la thèse . . . 7

I Théorie : littérature de genre et intertextualité 9

1 Modélisation du texte 10
1 Intertextualité . . . 11
1.1 Introduction à la notion . . . 11
1.2 Le système intertextuel . . . 13
1.2.1 La littérature comme système . . . 13
1.2.2 Le système des genres . . . 14
1.3 L'évolution du système littéraire . . . 15
1.4 La textualité . . . 19
2 Les études littéraires computationnelles . . . 20
2.1 La mesure dans les études littéraires . . . 22
2.2 La modélisation en études littéraires . . . 24
3 Opérationnaliser l'intertextualité . . . 26
3.1 L'intertextualité computationnelle . . . 27
3.2 Le genre comme attracteur architextuel . . . 27
3.3 Objets d'étude et méthodologie . . . 28

2 Les genres littéraires 30
1 Définitions consensuelles . . . 31

2 Deux grands systèmes historiques des genres . . . 32
3 Système des genres et aspect dynamique de la généricité . . . 34
4 Approches textuelles des genres . . . 35
4.1 Brunetière . . . 35
4.2 Formalistes russes . . . 36
4.3 Bakhtine et le dialogisme générique . . . 37
4.4 Structuralistes . . . 38
5 Le genre au-delà du texte . . . 39
6 Le genre comme matrice prescriptive . . . 42
6.1 Du modèle générique au formatage éditorial . . . 42
6.2 Du feuilleton à la collection de genre . . . 44
7 Conclusion . . . 45

3 Approches computationnelles des genres littéraires 46
1 Le formalisme quantitatif . . . 48
2 La modélisation perspectiviste . . . 49
2.1 Principe . . . 49
2.2 Contraintes pratiques et choix méthodologiques . . . 50
3 Apports des approches quantitatives . . . 51
3.1 Classification . . . 51
3.1.1 Généalogie . . . 51
3.1.2 Études sur la fiction . . . 52
3.1.3 Déclinaisons . . . 52
3.2 Extraction de caractéristiques distinctives . . . 53
3.3 Clustering et approches non supervisées . . . 54
3.4 Échelle d'analyse et granularité du genre . . . 54
3.5 Synthèse . . . 55
4 Limites : le retour du contexte . . . 55
4.1 La critique de l'anachronisme . . . 55
4.2 L'approche « molle » des genres . . . 56
4.3 Deux dimensions complémentaires . . . 57
5 Risques d'un relativisme tautologique . . . 57
6 La ressemblance de famille . . . 58
6.1 Le modèle wittgensteinien . . . 58
6.2 Application aux genres littéraires . . . 59
6.3 Convergence méthodologique . . . 60
7 Vers une cartographie computationnelle des genres . . . 60

4 Procédés expérimentaux 62
1 Introduction . . . 64
2 Corpus . . . 65
2.1 Le corpus *Chapitres* : corpus de référence . . . 65
2.2 Le corpus *Fictions littéraires de Gallica* : corpus de projection . . . 67
3 Extraction des personnages dans la fiction . . . 69
3.1 Présentation de la chaîne de traitement Propp-fr . . . 69
3.2 Identification et regroupement des personnages . . . 71
3.3 Des attributs aux représentations vectorielles . . . 72
4 Apprentissage automatique : principes et classifieurs . . . 73
4.1 Principes généraux . . . 73
4.2 Machines à vecteurs de support (SVM) . . . 75

4.3 Grands modèles de langue et classification : apports et limites 76
4.4 Stratégies de validation croisée : contrôler les effets de structure 78
5 Opérationnaliser l'intertextualité 79
5.1 Du texte au vecteur 79
5.1.1 Le sac-de-mots 79
5.1.2 La modélisation thématique 80
5.1.3 Les embeddings de phrases 81
5.2 Choix du modèle et procédure d'affinage 82
5.3 Validation des représentations vectorielles 84
5.4 Analyses d'ablation 86
5.5 Ce que capturent les embeddings 88
5.6 Validation empirique 89
5.6.1 Similarité et distance temporelle 89
5.6.2 Profil temporel des œuvres individuelles 90
5.6.3 Cadres collectifs : canon et archive 91
6 Réseaux de similarité 92
6.1 Construction des graphes d'intertextualité 92
6.2 Agrégation des similarités : du passage au roman 92
6.3 Détection de communautés 94
6.4 Interprétation des structures communautaires 96
6.5 Contrôle qualitatif 96
6.6 Limites méthodologiques 97
7 Usage encadré des modèles de langue génératifs 97
8 Conclusion 98

II Mise en pratique : le roman policier (1866-2020) 99

5 Le roman policier, un architexte modèle ? 100
1 Affirmation du genre 101
2 Le roman policier, un architexte modèle ? une approche supervisée 104
2.1 Protocole expérimental 105
2.2 Tests de robustesse : auteurs prolifiques et déséquilibres chronologiques . . 106
2.3 Caractéristiques discriminantes : anatomie de la signature policière 107
2.4 Distribution des probabilités : continuité du signal policier 108
2.5 Lecture qualitative des cas-limites : régime d'enquête et empreinte textuelle 109
2.5.1 Faux positifs : enquête sans genre policier 110
2.5.2 Faux négatifs : canonisation rétroactive et faible signal textuel . 111
2.5.3 Cas canoniques : convergence entre machine et historiographie . 112
2.6 Autres déplacements du régime d'enquête au XXe siècle 113
2.6.1 Policiers déclarés, signaux faibles : Leroux, Boileau-Narcejac, Volodine 113
2.6.2 Enquêtes sans crime : Queneau, Modiano, Angot 114
2.7 Un degré d'appartenance au roman policier 115
3 Mutations du roman policier : problèmes de la périodisation du genre 116
3.1 Approche par spécification des trois périodes du genre 117
3.2 Approche par SVM roulant 118
4 Regroupements internes dans le roman policier : une approche non-supervisée . . 120
4.1 Réseaux de similarité à l'échelle du roman 120
4.2 Du roman au réseau intertextuel 122

4.3 Du cas d'étude à la cartographie du sous-genre . . . 125
4.4 Conclusion intermédiaire . . . 128

6 La figure du détective 130
1 Introduction . . . 132
1.1 L'archétype du détective : définition et origines . . . 132
1.2 Caractérisation et personnage . . . 134
1.3 Notre approche computationnelle des personnages . . . 136
2 Le détecteur de détectives . . . 137
2.1 Corpus et annotation des données . . . 137
2.2 Plongements de personnages . . . 138
2.3 Classification supervisée . . . 139
2.4 Évaluation quantitative . . . 139
2.5 Évaluation qualitative des attributs distinctifs de l'archétype du détective 141
2.6 Distribution des scores de détectivité à l'échelle des personnages . . . 143
2.7 Continuité de la discrimination *détective*, *non-détective* . . . 144
2.8 Analyse des faux négatifs : trois cas d'étude . . . 146
2.9 Analyse des faux positifs : trois cas d'étude . . . 147
3 L'émergence de la figure du détective . . . 148
4 La trajectoire sémantique de l'archétype du détective . . . 150
4.1 Les trois régimes du détective . . . 151
4.2 Cas-limites : décalages temporels et enquêtes non policières . . . 154
4.3 Synthèse : du faux positif au degré de détectivité . . . 156
4.4 Étude de contrôle : dérive linguistique générale ou évolution du genre ? . . . 156
4.4.1 Protocole . . . 156
4.4.2 Résultats : corrélations par période . . . 157
4.4.3 Période *proto* . . . 157
4.4.4 Période *classique* . . . 157
4.4.5 Période *contemporaine* . . . 158
4.4.6 Synthèse . . . 158
5 Discussion . . . 158
5.1 Interprétation des résultats . . . 158
5.2 Limites . . . 159

7 La naissance du roman policier 160
1 Origine et sédimentation des genres . . . 162
2 Origine et sédimentation du roman policier . . . 164
2.1 Problèmes de la naissance du roman policier . . . 164
2.2 Cadre théorique : formation et reconnaissance . . . 169
2.3 Hypothèses de travail . . . 170
3 Indices qualitatifs de la transformation générique . . . 170
3.1 Du roman-feuilleton au roman policier : transformation du support . . . 170
3.2 Du roman-feuilleton au roman policier : trois évolutions formelles . . . 171
4 Approches computationnelles de la naissance du roman policier . . . 173
4.1 Corpus . . . 173
4.2 Opérationnalisation de la persistance du thème criminel . . . 174
4.3 Opérationnalisation de la centralité croissante du détective . . . 174
4.3.1 L'archétype du détective comme figure fondatrice . . . 175
4.3.2 Détection automatique des détectives . . . 175
4.3.3 Mesure de la centralité narrative par réseaux de personnages . . . 176

4.4 Opérationnalisation de la prototypicalité de l'intrigue . . . 177
5 Résultats . . . 179
5.1 Persistance du thème criminel . . . 179
5.1.1 Évolution intra-textuelle du thème criminel . . . 179
5.2 Mesure quantitative de la persistance thématique . . . 180
5.3 Affirmation progressive du détective comme pivot narratif . . . 182
5.3.1 Exemples de réseaux . . . 182
5.3.2 Centralité croissante du détective . . . 183
5.4 Prototypicalité de l'intrigue . . . 184
6 Discussion . . . 186
6.1 Convergence des trois indicateurs . . . 186
6.2 Vérification des hypothèses . . . 186
6.3 Limites . . . 187

III Exploration : changements d'échelles 188

8 À la recherche de l'aventure 189
1 Introduction . . . 191
1.1 Du roman policier au roman d'aventures . . . 191
1.2 Le roman d'aventures selon Letourneux . . . 192
1.3 Des scénarios intertextuels aux scènes stéréotypiques . . . 193
1.4 Questions de recherche . . . 194
2 La scène comme unité d'analyse . . . 195
2.1 La notion de scène . . . 195
2.2 Notre approche . . . 196
3 Retrouver le roman d'aventures dans les fictions de Gallica . . . 196
3.1 Approche supervisée par SVM . . . 197
3.1.1 Données d'entraînement . . . 197
3.1.2 Représentation et classification . . . 198
3.1.3 Classification par SVM linéaire . . . 199
3.2 Correction par approche non supervisée . . . 201
3.2.1 Principe . . . 201
3.2.2 Protocole de correction . . . 202
3.2.3 Analyse qualitative des corrections . . . 203
3.2.4 Bilan quantitatif . . . 203
3.2.5 Auteurs représentatifs du corpus . . . 204
4 Du corpus aux scènes : détecter l'aventure dans le texte . . . 207
4.1 Annotation . . . 207
4.1.1 Exemples . . . 207
4.1.2 Annotation par modèle de langue . . . 209
4.1.3 Analyse exploratoire des annotations . . . 210
4.2 Diffusion par classification supervisée . . . 210
5 Analyse multiscalaire . . . 211
5.1 Échelle du roman : lecture proche . . . 211
5.1.1 Vingt mille lieues sous les mers : un cas prototypique . . . 211
5.1.2 L'Éducation sentimentale : un contre-exemple instructif . . . 213
5.1.3 Synthèse : persistance comme marqueur du genre . . . 215
5.2 Échelle des sous-genres : lecture distante . . . 215
5.3 Échelle du corpus : diachronie . . . 218

6 Discussion . . . 219
6.1 Complémentarité des approches . . . 219
6.2 Le genre entre regroupement et circulation . . . 220
6.3 Limites et perspectives . . . 220
Annexe . . . 221

9 Du feuilleton aux collections : la naissance de la littérature de genre 223
1 Introduction . . . 225
1.1 De la dominante générique à la normalisation des genres . . . 225
1.2 La collection éditoriale comme dispositif normalisateur . . . 227
1.3 Deux régimes de codification . . . 228
1.4 Poids des contextes sur le texte . . . 230
1.5 Enjeux de recherche . . . 231
2 Méthode . . . 231
2.1 Corpus . . . 231
2.2 Construction des modes discursifs . . . 232
2.2.1 Segmentation en passages . . . 233
2.2.2 Représentation vectorielle . . . 233
2.2.3 Réduction dimensionnelle . . . 233
2.2.4 Classification : les K-moyennes . . . 233
2.2.5 Aperçu lexical des modes (TF-IDF) : . . . 235
2.2.6 Les modes discursifs du roman d'aventures . . . 236
2.3 Métriques . . . 237
2.4 Protection contre les artefacts d'échantillonnage . . . 238
2.5 Inférence statistique . . . 239
3 Résultats : le roman policier . . . 239
3.1 Contraction de la diversité discursive . . . 239
3.2 Stabilité du centroïde . . . 240
3.3 Estimation en différences de différences . . . 241
3.4 Test de robustesse : l'effet Simenon . . . 241
3.5 Analyse qualitative : ce que le genre a perdu et gagné . . . 242
4 Résultats : le roman d'aventures . . . 246
4.1 Évolution de la diversité discursive . . . 246
4.2 Dérive du centroïde : le genre se déplace . . . 247
4.3 Estimation en différences de différences . . . 247
4.4 Analyse qualitative : ce que le genre perd et ce qui lui survit . . . 248
5 Discussion . . . 250
5.1 Deux logiques de normalisation . . . 250
5.2 La mort du feuilleton . . . 251
5.3 Limites . . . 252

Conclusion 253
6 Apports . . . 254
7 Perspectives . . . 257

Liste des publications 259

Bibliographie 262

Annexes 275

Liste des figures

4.1 Distribution du nombre de romans du corpus *Chapitres* dans le temps, avec des indicateurs de canonicité (échelle de l'auteur) en rouge. 65
4.2 Sous-genres littéraires dans le corpus *Chapitres*, avec des indicateurs de canonicité (échelle de l'auteur) en rouge. 66
4.3 Nombre de romans par décennie dans le corpus *Fictions littéraires de Gallica*. . . 68
4.4 Qualité de l'OCR dans le temps : proportion de mots corrects par œuvre. 68
4.5 Évolution de la fonction de perte au cours de l'entraînement du modèle *fr_literary_bge* 83
4.6 Test de cohérence interne : précision en fonction du nombre de passages agrégés (BGE-M3, fr_literary_bge, CamemBERT). 85
4.7 Expériences d'ablation : impact de différentes suppressions/transformations sur la similarité cosinus entre deux passages similaires. 87
4.8 Expériences d'ablation combinées : impact cumulatif des différentes transformations. 87
4.9 Similarité moyenne en fonction de la distance temporelle entre les œuvres (en années). 89
4.10 Profils temporels de similarité pour deux romans : Les Misérables présente un pic de similarité avec les œuvres naturalistes des années 1880–1900, postérieures à sa publication ; *Le Mystère de la chambre jaune* montre une similarité croissante avec les décennies suivantes, reflétant son rôle fondateur dans le genre policier. 90
4.11 Similarité textuelle avant et après publication : comparaison entre œuvres canoniques (bleu) et œuvres de l'archive (orange). Les courbes sont centrées sur la date de publication de chaque œuvre (année 0). L'erreur standard est affichée après 10 itérations d'échantillonnage stratifié. 91
4.12 Réseau de similarité entre romans policiers (Top-5 voisins) et communautés détectées (Louvain/Leiden). 95

5.1 Coefficients discriminants pour assigner le roman policier 107
5.2 Classification automatique du roman policier 108
5.3 Prédiction du genre policier tous les 25 ans 118
5.4 Réseau intertextuel dans *Le Mystère de la chambre jaune* (1907) de Leroux . . . 120
5.5 Réseau intertextuel commun pour *L'Affaire Lerouge* (1866) de Gaboriau et *Le Mystère de la chambre jaune* (1907) de Leroux 123
5.6 Réseau de similarité dans le roman Policier 126

6.1 Erreurs de prédiction du modèle sur le temps. 141
6.2 Caractère distinctif des attributs de la figure du détective, mesuré par un z-score normalisé. Une valeur de +1 indique l'attribut le plus fortement associé aux détectives, et −1 le moins. 143

6.3 Distribution des scores de détectivité des personnages en fonction de l'année de publication (1800–2020). Chaque point représente un personnage, positionné selon la probabilité prédite par le modèle (axe vertical) et l'année de publication du roman dont il est issu (axe horizontal). Les personnages disposant d'une annotation manuelle sont distingués par couleur : bleu pour les détectives, rouge pour les non-détectives, gris pour les personnages sans label. Les zones colorées délimitent les seuils de décision : zone basse (< 0,30) en rouge pâle, zone haute (> 0,70) en bleu pâle. 145
6.4 Ratio de personnage *Détective* prédit par le modèle au fil du temps 149
6.5 Établissement progressif du détective comme élément central du récit 149
6.6 Regroupements de détectives 150

7.1 Évolution des occurrences des termes « roman-feuilleton », « roman judiciaire », « roman d'aventures » et « roman policier » dans la presse française (Gallicagram), 1830–1950 167
7.2 Évolution du thème criminel en rouge dans *L'Affaire Lerouge* (1866) 179
7.3 Évolution du thème criminel en rose dans *Le Mystère de la chambre jaune* (1907) 180
7.4 Évolution du thème criminel en rose dans *120 rue de la Gare* (1943) 181
7.5 Persistance du thème criminel au fil du temps. La zone ombrée représente un intervalle de confiance à 95 % autour de la moyenne glissante des moyennes annuelles et de leur erreur standard. 181
7.6 Émile Gaboriau, *Dossier 113* (1867). 182
7.7 Georges Simenon, *Le fou de Bergerac* (1932) 183
7.8 Évolution de la centralité narrative du détective (1860-1945). Les points représentent les moyennes annuelles ; la courbe bleue représente des moyennes mobiles sur 10 ans. Le *PageRank* du détective augmente progressivement témoignant de l'affirmation du détective comme hub structurel du récit. 184
7.9 Évolution de la prototypicalité de l'intrigue policière (score *PPlot*) entre 1840 et 1945. Chaque point représente un roman ; la courbe indique la moyenne glissante sur 8 ans. 185

8.1 Distribution des probabilités de classification « aventure » assignées par le SVM aux romans du corpus Gallica. Les ¾ des textes sont classés avec une probabilité très élevée (>90%), indiquant un signal stylistique fort. 200
8.2 Répartition temporelle des romans classés « aventure » par le SVM. La distribution se concentre sur la période 1860–1910, en accord avec la périodisation de Letourneux. 200
8.3 Coefficients les plus élevés (en valeur absolue) du SVM linéaire. Les barres vertes (coefficients positifs) correspondent aux mots associés à la classe « aventure » ; les barres rouges (coefficients négatifs) aux mots associés à la classe « non-aventure ». 201
8.4 Visualisation du graphe de similarité k-NN mixte : romans « aventure » étiquetés par le SVM (orange) et des romans « non-aventure » tirés au hasard (vert). Même si les *layouts* par forces peuvent produire des lobes secondaires, la forte séparation des étiquettes motive une correction fondée sur le voisinage. 202
8.5 Auteurs les plus représentés dans le corpus corrigé : nombre de titres par auteur (top 25). 204
8.6 Temporalité des auteurs les plus représentatifs : chaque point correspond à un titre du corpus, positionné par année de publication dans Gallica (la taille des points est proportionnelle au nombre de titres pour une même année). La dispersion temporelle tient en partie aux rééditions présentes dans les fonds numérisés. . . . 205

8.7 Nombre de titres par auteur dans le corpus « aventures » de Gallica (barres triées par effectif). Pour des raisons de lisibilité, Plotly n'affiche qu'un sous-ensemble des étiquettes de l'axe des auteurs dans la version statique (PNG) ; toutes les barres correspondent néanmoins à l'ensemble des auteurs du corpus. 206
8.8 Probabilité d'appartenance à la classe « Exploration » pour chaque passage de *Vingt mille lieues sous les mers*. L'abscisse représente la progression dans le récit, l'ordonnée la probabilité assignée par le modèle. 212
8.9 Probabilité d'appartenance à la classe « Danger » pour chaque passage de *Vingt mille lieues sous les mers*. 213
8.10 Probabilité d'appartenance à la classe « Danger » dans *L'Éducation sentimentale*. 214
8.11 Pourcentage de scènes de « Danger » par sous-genre. 216
8.12 Pourcentage de scènes d'« Exploration » par sous-genre. 217
8.13 Proportion de scènes d'« Exploration » dans l'ensemble du corpus, agrégée par année. 218
8.14 Proportion de scènes de « Danger » dans l'ensemble du corpus, agrégée par année. 219
8.15 Exactitude équilibrée (*balanced accuracy*) du SVM en fonction du nombre de mots (MFW ou sélection aléatoire). Les MFW surpassent systématiquement la sélection aléatoire. L'optimum est atteint à 5 000 MFW (85.6%). 221
8.16 Sensibilité des métriques du graphe au paramètre k. À gauche : l'homophilie reste stable et bien supérieure à la baseline aléatoire (0.5) pour toutes les valeurs de k testées. À droite : la modularité décroît à mesure que le graphe se densifie, mais demeure élevée, confirmant la robustesse de la structure de clustering. 222

9.1 Fréquence des expressions « roman policier » (rouge) et « roman d'aventures » (bleu) dans la presse française, 1860–1940. Source des points de données : Gallicagram. 226
9.2 Variance expliquée cumulée en fonction du nombre de composantes principales. La ligne pointillée indique le seuil retenu (50 composantes). 234
9.3 Score de silhouette moyen en fonction du nombre de clusters K. La ligne pointillée indique la valeur retenue ($K = 50$). 235
9.4 Nombre de modes effectifs (K_{eff}), 1842-2013. Points : estimations par fenêtre de 5 ans (8 romans raréfiés par fenêtre). Ligne : lissage LOWESS. Ligne pointillée : seuil de 1930. 240
9.5 Dérive du centroïde (distance cosinus entre prototypes de fenêtres successives), 1842-2013. Ligne pointillée : seuil de 1930. 241
9.6 Nombre de modes effectifs (K_{eff}), 1832-1939. Points : estimations par fenêtre de 5 ans (16 romans raréfiés par fenêtre). Ligne : lissage LOWESS. Ligne pointillée : seuil de 1920. 246
9.7 Dérive du centroïde dans le corpus d'aventures et le témoin, 1832-1939. Ligne pointillée : seuil de 1920. 247

Liste des tableaux

5.1 Robustesse du classificateur selon différentes stratégies de validation. 106
5.2 Prédictions des modèles, en *GroupKFold* sur les 3 grandes périodes du roman policier 117

6.1 Performances détaillées des modèles : *balanced accuracy* (B. Acc.), précision (P), rappel (R) et score F1 par classe pour le *détecteur de détective*, en fonction des différentes représentations sémantiques et des algorithmes de classification. 140
6.2 Bornes temporelles des trois clusters de détectives, définies par quantiles robustes (p15–p85) de l'année de publication. 151
6.3 Attributs les plus distinctifs de chaque cluster de détectives. 155
6.4 Corrélations entre les *z-scores* de période dans le groupe contrôle et dans le groupe détective, par type d'attribut. 157

7.1 Matrice de corrélation (Pearson) entre les fréquences d'apparition des termes « roman-feuilleton », « roman judiciaire », « roman d'aventures » et « roman policier » dans la presse française (Gallicagram), 1860–1939. Les astérisques indiquent la significativité statistique ($^{***}p < .001$, $^{**}p < .01$, $^{*}p < .05$). Plus la valeur de (p) est faible, moins il est probable que l'effet observé soit dû au hasard ; trois astérisques signalent donc un résultat plus robuste qu'un seul. 168

8.1 Résultats de validation croisée sur le corpus Letourneux ($n = 320$) pour une base BoW (MFW) et pour des représentations par embeddings de paragraphes. 199
8.2 Effet de la correction par graphe sur le corpus aventure. 204
8.3 Distribution des labels dans le corpus annoté. 210
8.4 Évaluation du modèle SVM en validation croisée (k=5). 211

9.1 Mots les plus distinctifs (TF-IDF) de quatre modes discursifs du corpus policier. n : nombre total de passages dans le cluster. 235
9.2 Mots les plus distinctifs (TF-IDF) de quatre modes discursifs du corpus d'aventures. n : nombre total de passages dans le cluster. 236
9.3 Estimation en différences de différences (DiD), corpus policier vs témoin (seuil : 1930) 241
9.4 Comparaison des résultats avec et sans Simenon (seuil : 1930) 242
9.5 Modes discursifs en expansion et en contraction (corpus policier, seuil 1930) . . . 242
9.6 Estimation en différences de différences (DiD), corpus d'aventures vs témoin (seuil : 1920) 247
9.7 Modes discursifs en expansion et en contraction (corpus d'aventures, seuil 1920) . 248
10.8 Romans aberrants retirés du corpus initial (règle : $\geq$80% de voisins non-aventure ; $n = 113$). 275

10.9 Romans infiltrés ajoutés au corpus initial (règle : ≥80% de voisins aventures). . . 280
10.10Profils lexicaux indicatifs des 50 modes discursifs du corpus policier. Pour chaque cluster, les mots les plus distinctifs (TF-IDF) sont présentés après filtrage des artefacts d'OCR, du paratexte éditorial et des tokens en langue étrangère. Ces profils lexicaux sont fournis à titre illustratif pour faciliter l'identification du contenu de chaque mode ; ils ne correspondent pas à la représentation vectorielle effectivement utilisée pour le clustering et le calcul des métriques. n : nombre de passages dans le cluster. 285
10.11Profils lexicaux indicatifs des 50 modes discursifs du corpus d'aventures. Pour chaque cluster, les mots les plus distinctifs (TF-IDF) sont présentés après filtrage des artefacts d'OCR, du paratexte éditorial et des tokens en langue étrangère. Ces profils lexicaux sont fournis à titre illustratif pour faciliter l'identification du contenu de chaque mode ; ils ne correspondent pas à la représentation vectorielle (embeddings) effectivement utilisée pour le clustering et le calcul des métriques. n : nombre de passages dans le cluster. 288

Introduction

> Mass culture comes into being when mass society seizes upon cultural objects, and its danger is that the life process of society (which like all biological processes insatiably draws everything available into the cycle of its metabolism) will literally consume the cultural objects, eat them up and destroy them.
>
> *Hannah Arendt. « The Crisis in Culture : Its Social and Its Political Significance. Six Exercises in Political Thought ».* Between Past and Future. *Penguin Books, 1977 [1961], p. 197-226, p. 207*

> La culture de masse apparaît quand la société de masse se saisit des objets culturels, et son danger est que le processus vital de la société (qui, comme tout processus biologique, attire insatiablement tout ce qui est accessible dans le cycle de son métabolisme) consommera littéralement les objets culturels, les engloutira et les détruira.
>
> *Hannah Arendt.* La crise de la culture. *Paris : Gallimard, 2013 [1961], p. 265-266*

La littérature de genre occupe une place singulière dans la circulation et la consommation de fiction romanesque aux XIXe et XXe siècles. Les romans qui relèvent de cette catégorie constituent des objets culturels à part, participant à façonner la conscience collective de générations de lecteurs et de lectrices. Une grande partie de cette littérature forme aujourd'hui ce que Margaret Cohen appelle la littérature *hors d'usage*[1], c'est-à-dire la littérature qui n'est plus lue, plus étudiée par la recherche en littérature. Ce diagnostic ne renvoie pas à une absence de lecture historique : nombre de ces textes furent au contraire des succès éditoriaux, des lectures de masse, des références partagées. Il désigne plutôt un angle mort de l'histoire littéraire, qui a tendu à confondre ce qu'on appelle « littérature » avec une fraction étroite de la production, stabilisée par les mécanismes de consécration et de l'enseignement.

Dès 1895, Lanson posait la question : « comment se fait la sélection des œuvres et des noms destinés à l'immortalité ? »[2]. La réponse, on le sait aujourd'hui, n'est pas simplement affaire de qualité intrinsèque. Les processus de canonisation attribuant à un auteur ou à un roman une

1. Margaret Cohen. *The sentimental education of the novel.* Princeton : Princeton University press, 1999, p. 20.
2. Gustave Lanson. *Hommes et livres : études morales et littéraires.* Hachette livre-bnf, 1895, p. 303.

valeur esthétique sont le résultat de négociations impliquant un ensemble d'agents et d'institutions du champ littéraire : critiques, historiens, système éducatif, stratégies éditoriales, qui contribuent ensemble à constituer l'œuvre comme objet littéraire [3]. Le tamis esthétique de la production littéraire est façonné par ce que Pollock appelle une « tradition sélective » [4], traversée par des biais de genre, d'ethnicité ou de classe sociale. Le canon qui en résulte n'est pas un reflet neutre de la production : il incarne, selon la formule de Casanova, « la légitimité littéraire elle-même » [5], c'est-à-dire la référence à partir de laquelle toute autre production est évaluée. La littérature de genre n'en est pas totalement exclue, puisque des auteurs comme Alexandre Dumas ou Eugène Sue ont survécu à cette sélection. Mais l'immense majorité de la production sérielle a disparu du canon littéraire. L'objectif de cette thèse n'est pas de défendre la valeur esthétique de cette littérature, ni de revendiquer son entrée dans le canon. Il est plutôt de prendre acte qu'elle constitue, du roman-feuilleton de la monarchie de Juillet aux collections spécialisées du XXe siècle, le mode dominant de production et de consommation de la fiction romanesque. À ce titre, elle constitue un terrain d'observation privilégié pour étudier comment ont évolué les formes narratives des deux derniers siècles.

Franco Moretti a donné à ce décalage entre le canon et la réalité de la production une formulation radicale. Dans *The Slaughterhouse of Literature* [6], il montre que le canon fonctionne comme un *abattoir* : sur l'ensemble des romans publiés dans l'Angleterre victorienne, seule une poignée survit à la sélection opérée par la critique, l'université et le marché. Les milliers d'autres, pourtant lus et appréciés en leur temps, disparaissent de la mémoire disciplinaire. Le canon ne conserve pas le meilleur de la production ; il conserve ce que les institutions littéraires ont jugé digne de transmission, selon des critères qui ne recoupent pas forcément la réalité de la lecture. L'enjeu, dès lors, n'est pas simplement d'ajouter des œuvres oubliées à un corpus déjà constitué, mais de déplacer la focale : ouvrir l'enquête à la littérature *hors d'usage* de Cohen, et à ce que Moretti invite à penser comme l'*archive* massive de la production imprimée [7].

Cette opposition entre *canon* et *archive* fournit un cadre décisif pour les études sur la littérature populaire. La littérature de genre a été, pour une large part du XIXe et du XXe siècle, un produit culturel majeur : elle s'adosse à des supports périodiques, des collections, des logiques sérielles, et contribue à stabiliser des attentes de lecture collectives. Elle est, en ce sens, un observatoire privilégié pour comprendre comment se forment, se diffusent et se transforment les formes narratives. Cependant, ce déplacement vers l'archive soulève immédiatement un problème de méthode : comment produire de la connaissance sur des milliers de romans sans reconduire, sous une autre forme, la logique restrictive du canon ? Moretti [8], avec sa notion de *distant reading*, a proposé une tentative de réponse. Son idée est de substituer, au commentaire de quelques œuvres,

3. Pierre Bourdieu. *Les Règles de l'art : Genèse et structure du champ littéraire*. Paris : Éditions du Seuil, 1992.

4. Griselda Pollock. *Differencing the canon : feminist desire and the writing of art's histories*. London ; New York : Routledge, 1999, p. 10.

5. Pascale Casanova. *La république mondiale des lettres*. Paris : Éditions du Seuil, 2008.

6. Franco Moretti. « The Slaughterhouse of Literature ». *Modern Language Quarterly* 2000, p. 207-228. DOI : 10.1215/00267929-61-1-207.

7. Franco Moretti. « Conjectures on World Literature ». *New Left Review* 2000, p. 54-68.

8. Franco Moretti. *Graphs, maps, trees : abstract models for a literary history*. London ; New York : Verso, 2005.

la construction d'abstractions (cartes, graphes, arbres) capables de rendre visibles des régularités, des distributions, des trajectoires. L'histoire littéraire devient alors inséparable d'opérations de modélisation.

1 La littérature de genre

Si les méthodes computationnelles trouvent dans les genres littéraires un objet d'étude naturel, c'est que les genres sériels présentent des propriétés qui les rendent particulièrement accessibles à la modélisation.

Les travaux de Matthieu Letourneux ont montré combien les fictions de genre relèvent d'une « fiction à la chaîne » [9], des œuvres prises dans des dynamiques industrielles, médiatiques et sérielles où la signification et la valeur se construisent au niveau des ensembles (séries, collections) plutôt qu'au seul niveau de l'œuvre singulière. Le roman policier publié au Masque, le roman d'aventures paru chez Ferenczi ou Tallandier ne sont pas des unités autonomes : ils s'inscrivent dans des systèmes de conventions partagées entre auteurs, éditeurs et lecteurs.

Cette analyse s'inscrit dans une histoire plus longue, celle de l'entrée de la France dans ce que Dominique Kalifa a appelé « le premier âge de la "culture de masse" » [10]. Kalifa montre que les transformations décisives s'amorcent dès les années 1860, à la croisée de plusieurs éléments convergents : l'alphabétisation généralisée, l'essor du roman-feuilleton comme premier produit culturel de grande diffusion, puis l'invention de la collection bon marché. Le phénomène avait été perçu très tôt par les contemporains. Dès 1839, Sainte-Beuve avait forgé la notion polémique de « littérature industrielle » dans la *Revue des Deux Mondes*, dénonçant la marchandisation de la production littéraire [11]. Mollier le décrit matériellement, comme une transformation structurelle où l'écriture devient une industrie, le feuilletoniste un producteur soumis à des contraintes de rendement et de format, le livre une marchandise insérée dans les circuits du capitalisme éditorial. Mollier montre précisément comment « ces fabriques de best-sellers deviennent peu à peu de véritables entreprises, [où] l'artisanat et l'amateurisme cèdent souvent la place à la direction attentive et fine d'une grande affaire » [12]. Les fascicules à quatre sous, les collections Fayard ou Ferenczi, les personnages récurrents de Rocambole à Fantômas ne sont pas des accidents de l'histoire littéraire, ils sont les produits d'un régime de production qui impose ses logiques propres de sérialité et de standardisation. Les formes de la littérature de genre ne se comprennent pas sans les dispositifs éditoriaux qui les portent.

Cawelti [13] rend compte dans son ouvrage des dispositifs formels utilisés par la littérature populaire. Il propose la *formula* comme une synthèse entre des archétypes narratifs universels (l'aventure, le mystère, la romance) et des conventions culturelles spécifiques propres à une

9. Matthieu Letourneux. *Fictions à la chaîne : littératures sérielles et culture médiatique*. Paris : Éditions du Seuil, 2017.

10. Dominique Kalifa. *La culture de masse en France. 1 : 1860 - 1930*. Paris : Éditions La Découverte, 2001, p. 5.

11. Charles-Augustin Sainte-Beuve. *De la littérature industrielle*. Paris : Éditions Allia, 2013 [1839].

12. Jean-Yves Mollier. *L' argent et les lettres : histoire du capitalisme d'édition ; 1880 - 1920*. Paris : Fayard, 1988, p. 12.

13. John G. Cawelti. *Adventure, mystery, and romance : formula stories as art and popular culture*. Chicago, Ill. : The Univ. of Chicago Press, 1997 [1976].

époque et à un public. Le genre populaire repose sur des structures fortement prévisibles qui garantissent la satisfaction d'attentes conventionnelles. Eco [14] prolonge cette analyse en montrant que le plaisir sériel naît précisément de la répétition de schémas connus, où le lecteur de genre ne cherche pas la surprise mais la confirmation du familier. La notion de « scénario intertextuel » [15] désigne les schémas narratifs préfabriqués que le « lecteur modèle » [16] mobilise pour interpréter un texte en le rapportant à d'autres textes du même type. Ces schémas opèrent à des échelles très différentes : depuis les règles de genre qui prescrivent l'organisation d'ensemble du récit jusqu'aux scènes reconnaissables (le duel, la poursuite, le naufrage) qui en constituent la matière concrète.

Bourdieu, dans *Les Règles de l'art* [17], fournit un modèle proprement institutionnel de cette dynamique. Les formes littéraires ne se stabilisent pas seulement par imitation textuelle, mais par des médiations (éditeurs, collections, prescriptions, hiérarchies) qui exercent une pression normative sur ce qu'il est légitime d'écrire et de publier. La littérature de genre est, parmi l'ensemble de la production romanesque, celle qui est le plus directement soumise au marché, à l'horizon d'attente façonné par les éditeurs et les lecteurs. Chaque épisode de Fantômas se termine ainsi sur le même schéma : Juve et Fandor vont enfin mettre la main sur l'insaisissable criminel, qui par un coup de théâtre déjoue l'arrestation. Rouletabille doit parvenir à une conclusion rationnelle et triompher du criminel Larsan. Axel, dans *Voyage au centre de la Terre*, doit offrir par son voyage un dépaysement radical ponctué d'épisodes de mort imminente, tout en refermant la parenthèse fictionnelle par son retour dans sa vie quotidienne.

La question que nous posons est de savoir si ces règles laissent des traces mesurables dans les textes, si elles se stabilisent et se transforment de manière observable, et si l'apparition de catégories institutionnelles (le « roman policier », le « roman d'aventures ») a des effets quantifiables sur la production. Autrement dit : nous cherchons à observer la mise au point progressive de ce que Paige appelle des « technologies » [18], c'est-à-dire des arrangements formels spécifiques, et que nous appelons par extensions les *technologies formelles* des genres.

Cette thèse se propose de mesurer les empreintes formelles des conditions matérielles et institutionnelles de production de la littérature de genre, du roman feuilleton aux collections de genre. Les régularités discursives et narratives de la littérature de genre ne sont pas des propriétés intrinsèques des textes. Elles sont le produit sédimenté des contraintes éditoriales, des logiques sérielles et des attentes de lecture que l'on vient de décrire. Les méthodes computationnelles n'expliquent pas ces processus, elles permettent d'en observer les effets à l'échelle où ils se déploient réellement, c'est-à-dire à l'échelle de milliers de textes et de décennies de production. Reste à préciser par quelle voie ces conditions de production s'incorporent dans les textes. C'est ici que la notion d'intertextualité devient décisive.

14. Umberto Eco. « Innovation and Repetition : Between Modern and Post-Modern Aesthetics ». *Daedalus* 1985, p. 161-184.
15. Umberto Eco. *Lector in fabula*. Paris : Librairie Générale Française, 2018 [1979], p. 83-85.
16. Ibid., p. 48.
17. Bourdieu, op. cit., p. 193-203.
18. Nicholas D. Paige. *Technologies of the Novel : Quantitative Data and the Evolution of Literary Systems*. Cambridge University Press, 2020. doi : 10.1017/9781108890861, p. 5.

2 Intertextualité et système littéraire

Ce programme de modélisation rejoint, par une voie inattendue, l'un des acquis les plus importants de la théorie littéraire du XXe siècle : la notion d'intertextualité. Nous venons de décrire la littérature de genre comme un produit dépendant de conditions matérielles, mais celles-ci ne façonnent pas les textes de l'extérieur, par simple pression mécanique. Elles opèrent à travers un tissu de relations entre textes, un système de reprises et de variations qui constitue la matière même de la production sérielle. L'intertextualité fournit le cadre théorique pour penser cette articulation entre les conditions de production et les formes qui en résultent.

Le concept d'intertextualité est construit par Julia Kristeva et plus largement par le mouvement structuraliste. Il admet une propriété qui serait constitutive du texte lui-même : « tout texte est absorption et transformation d'un autre texte » [19], un « croisement de surfaces textuelles » [20] où résonnent les mots d'autres textes, d'autres discours.

Gérard Genette a proposé de systématiser ces relations dans *Palimpsestes* [21], en distinguant cinq types de « transtextualité » : l'intertextualité au sens strict (citation, plagiat, allusion), la paratextualité (titres, préfaces, notes), la métatextualité (le commentaire critique), l'hypertextualité (la transformation d'un texte par un autre) et l'architextualité, c'est-à-dire la relation du texte à l'ensemble des catégories génériques dont il relève. Cette dernière relation est celle qui nous intéresse le plus directement. Dans *Introduction à l'architexte* [22], Genette propose « d'inventer une discipline dont l'objet n'est pas le texte, mais l'architexte » : non pas l'œuvre isolée, mais l'ensemble des catégories, modes, genres et régimes de discursivité qui la rendent possible et l'inscrivent dans un système de relations.

Si l'on prend au sérieux cette perspective, le genre littéraire se construit à partir d'un ensemble de relations qui le travaillent de l'intérieur : les mots qu'un auteur de roman policier choisit, les scènes qu'il construit, les personnages qu'il met en jeu sont informés par la mémoire de tous les romans policiers qu'il a lus et que ses lecteurs ont lus. Le genre est, au sens fort, un phénomène intertextuel.

C'est précisément là que les approches computationnelles trouvent leur pertinence. Une représentation vectorielle qui rapproche deux romans dans un espace de haute dimension détecte, sans le savoir, une forme d'intertextualité diffuse. Les méthodes computationnelles fournissent un nouveau mode d'approche des objets que la théorie avait identifié mais que les moyens de la lecture individuelle ne permettaient pas d'observer à grande échelle. Ted Underwood, dans *Distant Horizons*, insiste sur ce point : « Une seule paire d'yeux au niveau du sol ne peut embrasser la courbe de l'horizon, et les raisonnements limités à la mémoire d'un seul lecteur ne peuvent révéler les grandes structures qui organisent l'histoire littéraire » [23]. Les méthodes computationnelles, si elles sont bien calibrées, peuvent nous permettre de voir ces transformations lentes, qui traversent

19. Julia Kristeva. *Sèmèiotikè : recherches pour une sémanalyse*. Paris : Éditions Point, 2017 [1969], p. 89.
20. Ibid., p. 87.
21. Gérard Genette. *Palimpsestes : la littérature au second degré*. Paris : Éditions du Seuil, 1982.
22. Gérard Genette. « Introduction à l'architexte ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986, p. 110-148.
23. Ted Underwood. *Distant horizons : digital evidence and literary change*. Chicago : The University of Chicago Press, 2019, Préface, p. x.

les dynamiques de production dans la longue durée.

3 Les études littéraires computationnelles

La discipline dans laquelle s'inscrit cette thèse est celle des études littéraires computationnelles (*Computational Literary Studies*, CLS). Il ne s'agit pas d'un simple appariement entre informatique et études littéraires. Les CLS se définissent par un geste interprétatif spécifique : la construction de modèles formels capables de capter des phénomènes littéraires, c'est-à-dire la traduction d'hypothèses interprétatives en opérations mesurables et reproductibles.

Cette définition implique une posture épistémologique particulière. Tout modèle computationnel est une abstraction : il sélectionne certaines dimensions du texte (le lexique, la syntaxe, la structure narrative, les personnages) et en ignore d'autres. Underwood [24] insiste sur le fait que cette sélection n'est pas un appauvrissement, mais une condition de l'observation : de même qu'un microscope ne donne pas une image appauvrie de la cellule mais en rend visibles des structures autrement invisibles, le modèle computationnel rend visibles des régularités textuelles que la lecture individuelle ne peut pas percevoir. Encore faut-il être lucide sur ce que le modèle voit et ce qu'il ne voit pas. La modélisation est, en ce sens, toujours *perspectiviste* : elle donne un point de vue sur les données, pas une vérité exhaustive. Changer de modèle, changer de représentation, c'est changer de perspective sur le même objet.

Grâce aux CLS, les chercheurs sont à même de mener une étude de l'évolution formelle de la production et de la consommation des objets culturels à l'échelle où ces phénomènes se déploient réellement. L'histoire des genres littéraires se joue dans des milliers de textes, publiés sur des décennies, lus par des millions de lecteurs, façonnés par des contraintes éditoriales, sérielles et marchandes. Pour observer ces processus, il faut des outils capables de traiter la masse et de mesurer des variations sur le temps long. C'est ce que font les méthodes de classification supervisée, de modélisation thématique, de *clustering*, de représentation vectorielle que nous mobilisons dans cette thèse.

Cependant, il faut aussi être conscient de ce que ces méthodes ne peuvent pas. Elles ne comprennent pas les textes au sens où un lecteur le fait, elles n'accèdent pas à l'ironie, au double sens, à la subversion des conventions. Elles ne saisissent pas la tonalité d'un auteur, l'intention d'un narrateur. Nous verrons par exemple que notre modèle de détection de scènes de danger repère correctement les marqueurs lexicaux du péril dans un duel de Flaubert, mais ne peut pas saisir l'ironie flaubertienne qui sous-tend le passage et le tourne en ridicule. Ce n'est pas une faiblesse des outils actuels que des modèles plus sophistiqués résoudraient, c'est une limite constitutive de toute approche qui opère sur les régularités de surface plutôt que sur le sens pragmatique.

Le parti pris méthodologique de cette thèse est de transformer cette limite en protocole. Chaque opérationnalisation est systématiquement confrontée à une analyse en lecture proche des cas qu'elle produit (les faux positifs, les faux négatifs, les cas-limites). C'est dans cet aller-retour entre la vue d'ensemble et le retour au texte que se construit, à notre sens, la validité des résultats

24. Ibid.

et les éclairages sur les concepts que nous convoquons. Cette exigence rejoint celle formulée par Gius et Jacke : les chercheurs en CLS doivent « rendre explicite la relation exacte entre les caractéristiques textuelles ciblées par les méthodes computationnelles et les concepts littéraires pertinents, et remettre en perspective les résultats si nécessaire » [25].

L'objectif méthodologique est de retomber systématiquement sur une analyse qualitative du phénomène formel que nous sommes en train de quantifier. De manière plus générale, l'ambition est de produire des résultats qui fassent sens pour des chercheurs en littérature. La tentation quantitative est certes grande, mais le parti pris est de participer à produire de la connaissance pour la discipline, ce qui est difficile sans le recours aux méthodes de lecture proche qui en constituent le cœur.

Dans cette thèse nous nous concentrons donc sur deux terrains particulièrement structurants pour la littérature de genre. Le roman policier et le roman d'aventures, en les abordant comme des ensembles de pratiques et d'attentes historiquement situées, plutôt que comme des catégories fixes. Nous fondons nos analyses sur des recherches menées par des spécialistes de ces genres qui ont édité des listes de textes et de critères à la fois internes et externes. L'objectif est moins d'interroger la validité de ces experts que de tester la robustesse des méthodes computationnelles que nous allons utiliser.

Les deux genres s'affirment comme genres sériels autonomes à des périodes voisines (la fin du XIXe siècle pour le roman d'aventures, le début du XXe pour le roman policier), dans le contexte d'une industrialisation de la production littéraire et d'une massification du lectorat. Pourtant ces deux architextes sont à de nombreux égards divergents, tant dans leur codification textuelle que dans leur architecture contextuelle.

Cette thèse restera dans le giron de la production francophone. La raison la plus évidente est de circonscrire le corpus, déjà massif (plusieurs milliers de romans couvrant près de deux siècles), afin de garder un ancrage important sur les textes. Elle s'appuie principalement sur deux archives numériques, les *Fictions Littéraires de Gallica* [26], qui rassemblent plus de 12 000 romans numérisés par la Bibliothèque nationale de France, et le corpus *Chapitres* [27] avec près de 3 000 romans rassemblé par des chercheurs en littérature.

4 Structure de la thèse

La thèse s'organise en trois parties, la première pose le cadre théorique général, la deuxième présente plusieurs études menées sur le roman policier, et la troisième élargit enfin la perspective en examinant les dynamiques génériques à différentes échelles.

La partie I (*Théorie : l'intertextualité et la littérature de genre*) établit le cadre conceptuel et méthodologique de la recherche. Le chapitre 1 articule la notion d'intertextualité avec celle de système littéraire, en revenant sur les travaux des structuralistes, afin de justifier la nécessité d'une modélisation à grande échelle des relations entre textes. Le chapitre 2 propose une synthèse

25. Evelyn Gius et Janina Jacke. « Are Computational Literary Studies Structuralist ? » *Journal of Cultural Analytics* 2022, p. 1289. DOI : 10.22148/001c.46662, p. 18.
26. Pierre-Carl Langlais. *Fictions littéraires de Gallica*. Version 1. 2021. DOI : 10.5281/zenodo.4751204.
27. Aude Leblond. *Corpus Chapitres*. Version v1.0.0. 2022. DOI : 10.5281/zenodo.7446728.

des théories du genre et montre comment les genres sériels de la fin du XIXe siècle constituent des matrices architextuelles, où contraintes éditoriales et attentes de lecture s'incorporent dans les formes narratives. Le chapitre 3 problématise les approches computationnelles du genre (classification, extraction de caractéristiques textuelles, *clustering*) et en discute les limites épistémologiques (anachronisme, biais d'étiquetage, limites des métadonnées), avant de proposer une démarche opérationnelle fondée sur la *ressemblance de famille* et une modélisation perspectiviste articulant textes, réseaux et temporalités. Enfin, le chapitre 4 explicite l'architecture expérimentale de la thèse : constitution des corpus, représentations vectorielles, protocoles d'apprentissage, extraction d'information narrative et modélisation en réseau.

La partie II (*Mise en pratique : le roman policier, 1866–2020*) met ce cadre à l'épreuve sur un genre fortement codifié. Le chapitre 5 dégage une signature textuelle du roman policier par apprentissage supervisé, en contrôle la robustesse (effets d'auteur, de période) et examine les cas-limites afin de préciser les frontières du genre. Le chapitre 6 se concentre sur la figure du détective comme archétype : à partir de chaînes de coréférence et d'extraction d'attributs, un détecteur de détectives est construit, permettant de suivre, à grande échelle, l'émergence de la figure et la trajectoire sémantique de ses profils linguistiques sur près de 150 ans de fiction française. Le chapitre 7 interroge la genèse formelle du roman policier en opérationnalisant trois dimensions structurelles (persistance du thème criminel, centralité du détective, structure tendue de l'intrigue) afin de tester l'hypothèse d'une sédimentation progressive de ces traits avant la stabilisation médiatique du terme dans les années 1930, et de départager deux modèles explicatifs de cette cristallisation, celui du génie fondateur et celui de l'accumulation collective.

La partie III (*Exploration : changements d'échelles*) élargit la perspective au roman d'aventures et à la dynamique comparée des genres. Le chapitre 8 propose une reconstruction du corpus d'aventures à partir des *Fictions Littéraires de Gallica*, en combinant classification supervisée et correction par graphe de similarité. Il descend ensuite à l'échelle du passage en détectant des scènes stéréotypiques de danger et d'exploration, qu'il diffuse sur l'ensemble de la production romanesque pour constater la circulation de ces scénarios intertextuels au-delà des frontières du genre et tester l'hypothèse de la persistance comme marqueur de la spécificité générique. Le chapitre 9 étudie les effets de la naissance des collections de genres spécialisées sur la forme. En mesurant la diversité discursive du roman policier et du roman d'aventures avant et après leur cristallisation éditoriale respective, il montre que l'avènement des collections spécialisées s'accompagne d'une contraction de l'espace des possibles discursifs, et que les registres sentimentaux et mélodramatiques hérités du roman-feuilleton disparaissent au profit de conventions resserrées dont la forme varie selon les genres.

En proposant des méthodes computationnelles pour l'étude de la littérature française, cette thèse entend contribuer conjointement aux études littéraires et aux humanités numériques. Elle vise à montrer que la modélisation quantitative, loin de réduire la richesse des textes, permet de décrire des structures et des dynamiques inaccessibles à la lecture individuelle, en particulier lorsqu'il s'agit de suivre des transformations sur de vastes corpus et de longues durées.

Partie I

Théorie : littérature de genre et intertextualité

Chapitre 1

Modélisation du texte dans les études littéraires computationnelles

Objectifs

Ce chapitre présente les fondements théoriques de l'approche computationnelle adoptée dans cette thèse pour étudier la littérature de genre. Il s'appuie sur les concepts d'intertextualité et de système littéraire pour justifier la nécessité d'une modélisation à grande échelle des relations entre les textes. Il s'agit d'expliquer comment les méthodes computationnelles permettent de rendre visibles des régularités et des dynamiques qui échappent à une lecture individuelle. L'objectif est de montrer que la modélisation du texte n'est pas un simple outil, mais une reformulation ontologique de l'objet littéraire, engageant une conception de la littérature comme réseau de relations intertextuelles en transformation.

Sommaire

1 Intertextualité **11**
1.1 Introduction à la notion 11
1.2 Le système intertextuel 13
1.3 L'évolution du système littéraire 15
1.4 La textualité 19
2 Les études littéraires computationnelles **20**
2.1 La mesure dans les études littéraires 22
2.2 La modélisation en études littéraires 24
3 Opérationnaliser l'intertextualité **26**
3.1 L'intertextualité computationnelle 27
3.2 Le genre comme attracteur architextuel 27
3.3 Objets d'étude et méthodologie 28

> Nous ne faisons que nous entregloser [...] Nos opinions s'entent les unes sur les autres. La premiere sert de tige à la seconde, la seconde à la tierce. Nous eschellons ainsi de degré en degré. Et advient de là que le plus haut monté a souvent plus d'honneur que de mérite ; car il n'est monté que d'un grain sur les espaules du penultime
>
> *Michel de* Montaigne. Les Essais. *Sous la dir. de P.* Villey *et V.-L.* Saulnier. *Online edition by P. Desan, University of Chicago, 1595, Livre troisième, XIII — « De l'expérience »*

1 Intertextualité

1.1 Introduction à la notion

« Le texte est donc une *productivité* » [1] écrit Kristeva en 1968. Cette expression peut être comprise comme la capacité d'un texte à générer du sens, des interprétations et des interactions. L'article dans lequel Kristeva développe cette thèse est intitulé *Le texte clos*. Ce titre apparaît ironique au vu des directions théoriques qui y sont développées. Kristeva y discute les limites de l'approche traditionnelle du texte, qui considère le texte comme *clos*, c'est-à-dire fermé sur lui-même et immuable dans le temps, et dont le seul matériel textuel permet la construction du sens.

En opposition à cette conception du texte, Kristeva et plus largement le mouvement structuraliste fait du texte un objet dynamique dont le sens évolue au fur et à mesure qu'il est lu et interprété. Le lecteur est ainsi réhabilité comme co-créateur du texte puisqu'il est responsable des significations qui vont advenir du texte. Chaque lecture apporte une nouvelle perspective et une nouvelle signification. À cela s'ajoute la notion d'intertextualité, que Kristeva définit en ces termes : « tout texte se construit comme mosaïque de citations, tout texte est absorption et transformation d'un autre texte » [2]. La structuraliste pose ainsi la vision d'un texte qui n'a plus sa dimension finie, et dont l'interprétation et la signification complètes doivent passer par la résolution du réseau des relations textuelles.

Quelques années plus tard, Barthes développe la définition :

> Tout texte est un intertexte ; d'autres textes sont présents en lui à des niveaux variables, sous des formes plus ou moins reconnaissables : les textes de la culture antérieure et ceux de la culture environnante ; tout texte est un tissu nouveau de citations révolues [3].

Cette métaphore du tissu, rappelant que l'étymologie du mot *texte* renvoie à l'idée de tissage, illustre que toute création littéraire est en réalité une trame de contributions collectives. Le

1. Julia Kristeva. « Le texte clos ». *Langages* 1968, p. 103-125. doi : 10.3406/lgge.1968.2356, p. 103.
2. Idem, *Sèméiotikè : recherches pour une sémanalyse*, Chapitre 4, p. 89.
3. Roland Barthes. *Texte (théorie du)*. 1974. url : https://www.universalis-edu.com/encyclopedie/theorie-du-texte/.

texte, conçu comme un réseau complexe de fils entrelacés, représente un lieu de convergence où s'entremêlent diverses influences, voix et traditions culturelles. Compagnon prolonge la phrase de Montaigne en épigraphe : « Toute écriture est glose et entreglose, toute énonciation répète. » [4]. Le constat va dans le même sens que Barthes : toute énonciation est une reprise, une appropriation, une répétition, le déplacement ou le filage d'une citation déjà existante.

Si l'on reprend la citation exacte en épigraphe, Montaigne constatait que le savoir se construisait par couches successives, et déplorait que le mérite ne revienne qu'au « plus haut monté » sur la pile du savoir. Quatre siècles plus tard, ce principe devient chez les structuralistes constitutif de la production littéraire dans son ensemble.

Le concept d'intertextualité cristallise donc les propositions structuralistes et constitue une remise en question de notions fondamentales pour les études littéraires. Il offre une nouvelle vision de la production de sens qui n'est plus restreinte à un texte mais à son réseau intertextuel. Il conteste l'auctorialité puisque la place de l'auteur n'est plus qu'un fil dans un tissu d'écritures, et enfin il proclame la toute puissance interprétative du lecteur. La citation célèbre de Barthes est à ce propos équivoque : « La naissance du lecteur doit se payer par la mort de l'auteur » [5]. Si l'on écarte l'aspect péremptoire de la proposition, l'idée est de replonger le sens du texte non plus dans la perspective de la volonté d'un auteur mais dans une compréhension plurielle des intertextes reconstruits inconsciemment par le lecteur. Le rôle du lecteur dans l'appréciation de ces intertextes est repris quelques années plus tard par Riffaterre [6], pour qui l'intertextualité désigne une opération de lecture nécessaire : elle est « la perception que notre lecture du texte ne peut être ni complète ni satisfaisante sans passer par l'intertexte ». Cette conception, centrée sur l'actualisation de l'intertexte dans la lecture, est éclairante, mais elle n'épuise pas tout à fait la perspective de Barthes :

> L'intertextuel dans lequel est pris tout texte, puisqu'il est lui même l'être-texte d'un autre texte, ne peut se confondre avec quelques origines du texte : Rechercher les « sources », les « influences » d'une œuvre, c'est satisfaire au mythe de la filiation ; les citations dont est fait un texte sont anonymes, irréparables et cependant déjà lue : ce sont des citations sans guillemets [7].

Barthes radicalise ici le concept, puisque l'intertexte n'est plus seulement explicite ou retrouvé par un lecteur actif. Il est nécessairement latent à tout texte. Cette conception aboutit à une disproportion entre l'ambition du concept qui se veut à la fois totalisant, capable de rendre compte des similarités textuelles sur le temps long et les limites inhérentes à l'approche en lecture proche. L'intertextualité est de fait impossible à saisir à la main, puisque la multiplication des potentiels intertextes n'est pas vraiment définie. Une réponse à cette limite, certes pas tout à fait satisfaisante, mais permettant quand même un changement de paradigme, est l'approche

4. Antoine Compagnon. *La seconde main ou Le travail de la citation*. Paris : Éditions Points, 2016 [1979], Avant Propos, p. 16.

5. Roland Barthes. « La mort de l'auteur ». *Le bruissement de la langue*. Paris : Éditions Points, 2015 [1968], p. 69.

6. Michael Riffaterre. « Intertextual Representation : On Mimesis as Interpretive Discourse ». *Critical Inquiry* 1984, p. 141-162. doi : 10.1086/448279, p. 142–143.

7. Roland Barthes. « De l'œuvre au texte ». *Le bruissement de la langue*. Paris : Éditions Points, 2015 [1971], p. 72.

computationnelle. L'outil informatique a été construit spécifiquement pour des tâches similaires à la nôtre : comparer d'immenses ensembles de données de manière automatique et systématique. Nous exposons en section 2 une réflexion sur les fondements de notre approche computationnelle.

Le constat théorique qui découle de toutes ces mises au point est celui de l'étude de l'intertextualité : comment envisager l'infinité des liens textuels, d'un texte à l'autre, d'un texte à un ensemble d'autres ? Il nous faut dès lors un objet théorique capable de décrire les interactions au sein de la littérature, en prenant en compte les éléments structurants les interrelations entre les textes. Autrement dit il nous faut représenter les textes romanesques dans un système littéraire.

1.2 Le système intertextuel

La notion d'intertextualité appelle un cadre de description plus vaste que la simple addition de renvois d'un texte à l'autre. Si l'on veut penser la multiplicité des liens possibles, il faut postuler un *système* où ces liens prennent sens et se transforment. La présente section propose d'abord de considérer la littérature comme un système au sens structural, puis d'identifier l'instance médiatrice qui relie ce système général au texte singulier : les *genres*. Les chapitres suivants prolongeront ce mouvement en traitant précisément des genres littéraires.

1.2.1 La littérature comme système

Dans l'héritage Saussurien, « la langue est un système dont toutes les parties peuvent et doivent être considérées dans leur solidarité synchronique » [8]. Transposée au domaine littéraire, cette intuition est approfondie par les formalistes russes : chez Tynianov, l'œuvre se définit comme un système, et chaque élément n'y prend sens qu'en vertu de sa place dans l'ensemble. Il appelle « fonction constructive » la « possibilité » pour un élément de l'œuvre littéraire « d'entrer en corrélation avec les autres éléments du même système et par conséquent avec le système entier » [9]. Sans fixer a priori la nature de ces facteurs, on peut entendre par là l'ensemble des éléments en jeu dans la narration, depuis les thèmes et motifs jusqu'à la distribution des voix, la construction des personnages et l'économie de l'intrigue. La sémantique de l'œuvre ne tient donc pas à un noyau isolable, mais à la cohérence globale des relations qui articulent ses composantes.

C'est lorsque nous élargissons la focale et que nous considérons l'échelle de la production romanesque dans son ensemble que nous apercevons un second niveau de systématicité. L'œuvre est un système de sens spécifique, mais l'intertextualité institue des relations de système à système, d'œuvre à œuvre, sous la forme de coprésences, de réécritures, d'allusions et de circulations. Les humanités numériques ont donné une visibilité particulière à ce plan relationnel en substituant aux étagères du livre l'hyperlien et la mise en réseau, ce qui fait affleurer une littérature connectée où « tout le système textuel qu'un texte active surgit à la surface » et se donne sur un même plan [10]. De ce point de vue, la modélisation en réseau apparaît moins comme un simple outil

8. Ferdinand de Saussure. *Cours de linguistique générale*. Sous la dir. de Charles Bally, Albert Sechehaye et Albert Riedlinger. Paris : Payot, 1971 [1916], p. 124.

9. Iouri Tynianov. « De l'évolution littéraire ». *Théorie de la littérature : textes des formalistes russes*. Sous la dir. de Tzvetan Todorov. Paris : Éditions du Seuil, 2001 [1927], p. 125.

10. Marine Riguet. « Le sacre d'une littérature palimpseste ? » *Des humanités numériques littéraires ?* Cerisy, France : Didier Alexandre, Marc Douguet et Milad Doueihi, 2017, p. 2.

que comme une reformulation ontologique de l'objet littéraire, une « mise à plat réticulaire » qui répond à la manière dont nos corpus se constituent et se lisent désormais.

Comment modéliser ce système littéraire élargi ? La première possibilité héritée des sciences de l'évolution consiste à recourir à des arbres généalogiques. L'analogie a une longue histoire dans les sciences de la culture : on dresse des arbres en linguistique historique pour figurer la divergence des langues [11], en folklore et en musicologie pour cartographier des familles de motifs [12], en philologie pour reconstruire des stemmata [13], et plus largement dans l'étude des formes narratives lorsqu'on raisonne en termes de descentes et de bifurcations. La modélisation par arborescence a l'avantage de rendre visible des parentés et des héritages, mais elle importe aussi ses présupposés : une origine, une hiérarchie, une filiation univoque.

Cependant, Deleuze et Guattari contestent cette conception dans leur critique de l'arborescence : « Nous sommes fatigués de l'arbre […] Toute la culture arborescente est fondée sur eux, de la biologie à la linguistique. […] La pensée n'est pas arborescente » [14], écrivent-ils, en opposant au modèle généalogique la logique du rhizome, faite de connexions latérales, de multiplicités et d'alliances, sans centre ni tronc. Appliquée au littéraire, cette position incite à déplacer l'attention de la filiation verticale vers les dynamiques de co-présence, d'hybridation et de circulation, autrement dit vers la carte des relations effectives plutôt que vers la reconstitution d'une origine.

Marine Riguet propose de traiter la littérature comme un tissu d'actualisations réciproques. Elle avance le concept de *nexus*, où un texte n'existe jamais seul mais comme nœud de passages, de reprises et de frictions. Le *nexus* n'installe ni origine ni centre et permet de décrire la propagation de formes par contact plutôt que par filiation. Dans un tel cadre, cartographier le littéraire revient moins à remonter une histoire verticale qu'à tracer des trajectoires et le sens d'une unité ne vaut que par la configuration de relations qui la porte.

1.2.2 Le système des genres

Cependant, modéliser toute la production romanesque en un seul système ne fait pas sens, car il négligerait la complexité des phénomènes culturels et serait finalement non producteur de connaissances pour la discipline. Dès lors, il nous faut un objet théorique intermédiaire entre le système de l'œuvre et le système littéraire. Ce sont les genres littéraires. On parle d'ailleurs plus de système des genres que de système littéraire. Les genres relèvent d'abord de l'activité très humaine de catégoriser des choses afin de mieux les appréhender. Les textes ayant des thèmes et des intrigues similaires peuvent être classifiés sous la même catégorie, afin de créer des repères pour l'auteur, le lecteur, le critique et tout le marché du livre.

Le système des genres littéraires n'a pas attendu le numérique pour être pensé et construit par les théoriciens. Cette intuition du système s'articule chez Jauss : « Les genres littéraires

11. Lyle Campbell. *Historical linguistics : an introduction*. Edinburgh : Edinburgh University Press, 2013.
12. Patrick E. Savage, Steven Brown et al. « Statistical universals reveal the structures and functions of human music ». *Proceedings of the National Academy of Sciences* 2015, p. 8987-8992. doi : 10.1073/pnas.1414495112.
13. Jean-Baptiste Camps et Julien Randon-Furling. « Lost Manuscripts and Extinct Texts : A Dynamic Model of Cultural Transmission ». *Proceedings of the Workshop on Computational Humanities Research (CHR 2022)*. CEUR Workshop Proceedings, 2022.
14. Gilles Deleuze et Félix Guattari. *Mille plateaux*. Paris : Éditions de Minuit, 2009 [1980], p. 24, cité dans Riguet, op. cit., p. 5

n'existent pas isolément, ils constituent les différentes fonctions du système littéraire de l'époque et mettent l'œuvre individuelle en relation avec ce système » [15]. Le système permet à Jauss de penser conjointement la synchronie du réseau de relations au sein d'un genre, et la diachronie de ce système, dans son rapport aux traditions antérieures.

Prolongeant cela, Genette déplace l'objet de la poétique vers l'architexte, c'est-à-dire l'ensemble des relations ou modèles génériques invoqués par le texte : « […] la poétique, dont l'objet, posons-le fermement, n'est pas le texte, mais l'architexte » [16]. Dans le même esprit, J.-M. Schaeffer parle de « relation générique hypertextuelle », soit « toute filiation plausible qu'on peut établir entre un texte et un ou plusieurs ensembles textuels antérieurs ou contemporains » [17]. Les genres ne sont donc pas de simples étiquettes : ils fonctionnent comme des dispositifs de contrainte et d'attente qui rendent possible et lisible la circulation intertextuelle.

Ce cadre rejoint une définition générale du système comme « unité organisée d'interrelations » [18] où œuvres, pratiques et genres occupent des positions relatives, structurées par des éléments dominants qui orientent l'ensemble. Genette en tire une conséquence décisive pour l'historien : « L'histoire littéraire ainsi comprise devient l'histoire d'un système : c'est l'évolution des fonctions qui est significative, et non celle des éléments, et la connaissance des relations synchroniques précède nécessairement celle des procès » [19]. Ainsi, l'intertextualité n'est pas un faisceau contingent de ressemblances, mais un champ de contraintes qui fait sens à la fois par rapport à un état du système en synchronie mais également à sa dynamique diachronique.

1.3 L'évolution du système littéraire

Cette dynamique du système littéraire est un des objets privilégiés de tout un champ disciplinaire, celui de l'évolution culturelle. Nous en proposons ici un état de l'art succinct.

Prolongeant le cadre systémique précédent, l'évolution ne se conçoit pas comme une suite d'écoles, mais comme la transformation de fonctions et de relations au sein d'un tout structuré. Dès 1927, Tynianov en donne l'armature : « l'étude de l'évolution littéraire n'est possible que si on la considère comme une série, un système mis en corrélation avec d'autres séries ou systèmes et conditionné par eux. » [20]. L'évolution littéraire est impliquée par sa *mise en corrélation* avec d'autres séries (juridiques, techniques, médiatiques, scientifiques, morales) et ce sont des variations externes au champ littéraire qui déplacent la dominante interne et redistribuent les fonctions au sein de la série. Cette perspective permet d'inclure les facteurs sociaux dans l'analyse des modifications du système littéraire, là où se redistribuent les dominantes et s'ajustent les fonctions.

Dans ce mouvement, la pression évolutive s'institutionnalise au niveau du marché du livre. Éditeurs, collections et supports cadrent l'offre et la lecture, stabilisent des genres monétisables

15. Hans Robert Jauss. « Littérature médiévale et théorie des genres ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986 [1970], p. 67.
16. Genette, op. cit., p. 159.
17. Jean-Marie Schaeffer. *Qu'est-ce qu'un genre littéraire ?* Paris : Éditions du Seuil, 1989, p. 192.
18. Edgar Morin. *La méthode. 1 : La nature de la nature*. Paris : Éditions du Seuil, 1977, p. 102.
19. Gérard Genette. *Figures. I*. Paris : Éditions du Seuil, 1966, p. 179.
20. Tynianov, op. cit., p. 139.

et répliquent ce qui rencontre un public, tandis que les formules non performantes s'éteignent. L'éditeur, instance médiatrice, produit ce que Letourneux appelle un « pacte de lecture éditorial ordonné suivant des principes génériques » [21] : formats, périodicité, maquettes et mots de genre standardisent les œuvres et les rendent comparables, au point d'opérer un « transfert d'autorité » [22] de l'auteur vers la marque éditoriale. En relayant des traits architextuels récurrents dans des présentations normées, les éditeurs créent un « effet d'objectivation des délimitations des genres » [23], au point de « convertir en modèle générique partagé par la plupart des acteurs du marché ce qui n'étaient à l'origine que les traits de l'une ou l'autre de leurs collections » [24]. C'est précisément ce processus de normalisation éditoriale et ses effets mesurables sur la production générique que nous examinerons au chapitre 9, en testant l'hypothèse selon laquelle la reconnaissance institutionnelle d'un genre s'accompagne d'une contraction quantifiable de l'espace des possibles discursifs.

Cette dynamique de consolidation trouve un cadre théorique explicite dans la théorie du polysystème d'Even-Zohar [25]. Plutôt que de concevoir la littérature comme un système unique et homogène, Even-Zohar la décrit comme un ensemble stratifié de sous-systèmes concurrents (canonisés et non-canonisés) dont les tensions réciproques constituent le moteur de l'évolution. Au sein de ce polysystème, les modèles littéraires *primaires* qui parviennent à occuper le centre subissent un processus inévitable de *secondarisation* : leur perpétuation s'accompagne d'une réduction structurelle par laquelle les modèles hétérogènes se transforment en modèles homogènes, le nombre de configurations incompatibles diminue, et les relations complexes cèdent la place à des relations simplifiées. Ce mécanisme rejoint directement la boucle éditoriale décrite par Letourneux, mais en précise la mécanique interne : la consolidation d'un genre n'est pas seulement la réplication de formules performantes par le marché, c'est aussi l'appauvrissement progressif du répertoire de possibles au sein du système canonisé. Nous verrons au chapitre 9 que cette secondarisation pourrait éclairer le cas du roman policier après 1927.

Cette approche trouve un relais chez Mukařovský [26], qui formule le principe d'interrelations structurelles entre évolution littéraire et évolution sociale. Chaque œuvre y apparaît comme un point d'équilibre instable entre la dynamique interne de sa forme et les pressions du contexte historique qui en orientent les transformations. Wellek en propose une formulation englobante : penser la littérature comme un système global d'œuvres qui, à mesure que de nouveaux textes s'y agrègent, reconfigure sans cesse ses relations internes, « un tout changeant qui grandit en changeant » [27]. Autrement dit, l'évolution nomme la dynamique par laquelle l'ajout d'œuvres modifie l'architecture relationnelle du champ.

Au-delà de ce constat, Sobchuk [28] propose un cadre opératoire minimal afin d'expliciter les

21. Letourneux, op. cit., p. 149.
22. Ibid., p. 144.
23. Ibid., p. 172.
24. Ibid., p. 172.
25. Itamar Even-Zohar. « Polysystem Theory ». *Poetics Today* 1990, p. 9-26. doi : 10.2307/1772666.
26. Jan Mukařovský. *Aesthetic Function, Norm and Value as Social Facts*. Trad. par Mark E. Suino. Ann Arbor, MI : University of Michigan Press, 1970 [1936], p. 102.
27. René Wellek et Austin Warren. *Theory of literature*. New York, Harcourt, Brace & World, 1956, p. 255.
28. Oleg Sobchuk. « Evolution of Modern Literature and Film ». *Oxford Handbook of Cultural Evolution*. Sous la dir. de Jamshid J. Tehrani, Jeremy Kendal et Rachel L. Kendal. Oxford University Press, 2023, p. 554-564.

mécanismes du changements. Toute évolution suppose selon lui (i) une source de variation, (ii) un mécanisme de sélection des variantes, (iii) un mode de transmission assurant leur circulation. Les récits n'évoluent pas comme des organismes ; ils se transforment cumulativement au niveau des formes narratives, déclinées en plusieurs plans : l'histoire (personnages, événements, lieux), l'intrigue (configuration, ordre, focalisation) et le style (présentation verbale ou visuelle).

Ce triptyque (variation, sélection, transmission) appelle toutefois une clarification épistémologique. Moretti [29] distingue deux modèles d'évolution culturelle, qui renvoient à l'opposition fondatrice entre Lamarck [30] et Darwin [31] en biologie. Le modèle lamarckien suppose que les variations sont orientées vers l'adaptation : l'organisme, ou par analogie la forme littéraire, se transformerait en réponse directe aux pressions du milieu, et ces transformations acquises se transmettraient aux générations suivantes. Dans l'histoire littéraire traditionnelle, cette logique sous-tend l'idée d'un progrès où chaque forme succède logiquement à la précédente, les innovations n'apparaissant que lorsque le contexte les appelle. Moretti qualifie cette vision de « rêve hégélien » [32].

Le modèle darwinien est au contraire dualiste et les variations sont générées indépendamment de leur utilité future, par le hasard des recombinaisons et des expérimentations, tandis que la sélection, gouvernée par la nécessité environnementale, trie a posteriori les variantes selon leur aptitude au contexte. Ces deux processus sont disjoints : le contexte peut sélectionner des formes, mais il ne les génère pas. Appliqué à la littérature, ce dualisme signifie que les formes dominantes ne sont pas celles de la classe dominante, mais celles qu'elle a sélectionnées parmi un répertoire qu'elle n'a pas produit [33]. Cette distinction éclaire la dynamique décrite par Letourneux : les boucles de rétroaction éditoriales (succès, imitation, consolidation) constituent précisément le mécanisme de sélection, tandis que la génération des variantes reste largement contingente. Elle permet aussi de comprendre pourquoi la majorité des innovations échouent : l'histoire littéraire, selon la formule de Moretti, est « presque entièrement une collection de demi-choses ennuyeuses, ou de francs échecs » [34].

Dans le prolongement de ce cadre, plusieurs travaux ont cherché à mesurer le changement. La divergence de Kullback-Leibler, issue de la théorie de l'information [35], a d'abord servi à quantifier des distributions en écologie, puis a été progressivement utilisée dans les SHS computationnelles. En évolution linguistique [36], en histoire avec par exemple Barron et al [37] qui l'emploient pour

DOI : 10.1093/oxfordhb/9780198869252.013.45.

29. Franco Moretti. « On Literary Evolution ». *Signs Taken for Wonders : Essays in the Sociology of Literary Forms*. London : Verso, 1997 [1983], p. 262-278.

30. Jean-Baptiste Pierre Antoine de Monet de Lamarck. *Philosophie zoologique*. Paris : Éditions Flammarion, 1996 [1809].

31. Charles Darwin. *L'origine des espèces au moyen de la sélection naturelle ou La préservation des races favorisées dans la lutte pour la vie*. Paris : Flammarion, 2008 [1859].

32. Moretti, op. cit., p. 263.

33. Ibid., p. 266.

34. Ibid., p. 267.

35. Voir à ce sujet la synthèse de Simon DeDeo. *Information Theory for Intelligent People*. 2018

36. Christian Bentz, Dimitrios Alikaniotis et al. « The Entropy of Words—Learnability and Expressivity across More than 1000 Languages ». *Entropy* 2017, p. 275. DOI : 10.3390/e19060275.

37. Alexander T. J. Barron, Jenny Huang et al. « Individuals, institutions, and innovation in the debates of the French Revolution ». *Proceedings of the National Academy of Sciences* 2018, p. 4607-4612. DOI : 10.1073/pnas.1717729115.

estimer la nouveauté d'un discours (relativement aux précédents) et sa transience (relativement aux suivants) à l'Assemblée constituante. En littérature, Algee-Hewitt et al [38] l'adaptent aux textes fictionnels avec des calculs de prévisibilité des transitions lexicales, Liddle [39] met en évidence des corrélations entre histoires nationales du roman et pressions informationnelles. À l'échelle diachronique, Seminck et al [40] montrent qu'un changement intra-auteur permet de prédire une date de publication, tandis qu'Underwood et al [41] et Sobchuk et al [42] soulignent que ces variations demeurent limitées au regard de l'effet de cohorte générationnelle. L'ensemble converge : une part substantielle du changement s'explique par le renouvellement générationnel plutôt que par l'adaptation progressive des auteurs à leur contexte.

Ce constat ramène la dynamique formelle aux temporalités sociales, mais il ne suffit pas d'invoquer les générations comme principe explicatif. Reste à comprendre ce qui médiatise le passage d'une génération d'auteurs à l'autre. C'est ici que le marché retrouve sa fonction : l'appareil éditorial, en sélectionnant ce qui reste disponible (rééditions, collections), détermine le corpus accessible aux nouvelles générations d'écrivains et donc le répertoire à partir duquel elles peuvent varier. Comme le montre Letourneux, la dynamique sérielle repose sur une logique de remplacement où « les éditeurs orientant, par le choix des publications, les pratiques d'écriture. […] La standardisation des formes et des contenus est le trait principal de la culture de masse » [43]. Cette boucle succès-imitation-consolidation ne se contente pas de répliquer les formules performantes, elle élimine aussi de la mémoire collective les expérimentations non retenues, orientant de fait les possibles. Le marché opère ainsi comme un filtre générationnel : il ne génère pas les variations (qui relèvent du hasard des recombinaisons individuelles), mais il sélectionne ce qui sera transmis et donc ce sur quoi la génération suivante pourra travailler. L'effet générationnel mesuré par Underwood et Sobchuk trouve ici son mécanisme : chaque génération hérite non pas de l'ensemble des formes produites, mais du sous-ensemble retenu par les instances éditoriales.

Béhar [44] définit la génération comme une communauté d'éducation, d'intérêts et d'idées, rythmée par des cycles d'environ trente ans. Quelques années plus tard, Moretti [45] observe également la régularité du remplacement des sous-genres (25-30 ans) et postule un « mécanisme générationnel » des cycles romanesques. Ces régularités appellent toutefois une réserve méthodologique : les sous-genres que Moretti mobilise (novel of manners, industrial novel, sensation novel) sont des étiquettes construites rétroactivement par l'histoire littéraire, souvent à partir de catégories critiques postérieures aux textes eux-mêmes. Or cette nomenclature savante ne coïncide

38. Mark Algee-Hewitt, Sarah Allison et al. « Canon/Archive. Large-scale Dynamics in the Literary Field ». *Pamphlets of the Stanford Literary Lab* 2016.

39. Dallas Liddle. « Could Fiction Have an Information History ? Statistical Probability and the Rise of the Novel ». *Journal of Cultural Analytics* 2019. DOI : 10.22148/16.033.

40. Olga Seminck, Philippe Gambette et al. « The Evolution of the Idiolect over the Lifetime : A Quantitative and Qualitative Study of French 19th Century Literature ». *Journal of Cultural Analytics* 2022. DOI : 10.22148/001c.37588.

41. Ted Underwood, Kevin Kiley et al. « Cohort Succession Explains Most Change in Literary Culture ». *Sociological Science* 2022, p. 184-205. DOI : 10.15195/v9.a8.

42. Oleg Sobchuk et Bret A. Beheim. « Does literature evolve one funeral at a time ? » *Proceedings of the Royal Society B : Biological Sciences* 2025, p. 20242033. DOI : 10.1098/rspb.2024.2033.

43. Letourneux, op. cit., p. 95.

44. Henri Béhar. *La littérature et son golem*. Paris : H. Champion, 1996.

45. Moretti, *Graphs, maps, trees*.

pas nécessairement avec les catégories opératoires du marché au moment de la publication : les mots de genre employés par les éditeurs, les découpages de collections, les attentes de lecture contemporaines constituent un tout autre système de classement, plus labile et plus directement lié aux mécanismes de sélection. Mesurer l'évolution à partir de catégories rétrospectives risque donc de projeter sur le passé une cohérence générique que le marché n'a jamais produite, et de manquer précisément la dynamique de variation et de sélection que le cadre darwinien entend saisir. Ces régularités ne sont pas pour autant de simples constantes démographiques : elles traduisent le temps nécessaire pour qu'une nouvelle cohorte, formée sur le corpus sélectionné par le marché, produise à son tour des variations qui entreront en concurrence pour la sélection suivante. La périodicité des cycles romanesques reflète ainsi l'articulation entre temporalité biologique (renouvellement des agents), temporalité éditoriale (rotation des catalogues, obsolescence des collections) et temporalité formelle (épuisement des archétypes, ouverture de nouveaux possibles), à condition de reconstituer les catégories génériques telles qu'elles fonctionnaient pour les acteurs du marché plutôt que telles que la critique les a fixées après coup.

Pour les études littéraires computationnelles, la pertinence de la notion d'évolution est théorique, parce qu'elle articule intertextualité, genres et contextes dans une dynamique relationnelle où le marché joue le rôle d'instance sélective. Elle est également méthodologique, parce qu'elle fournit des échelles de mesures afin de situer chaque texte dans le mouvement d'ensemble.

1.4 La textualité

Le système littéraire peut donc être considéré comme un flux permanent en transformation. C'est ce que nous nommons *textualité*, pour désigner ce nouvel objet d'étude, non plus l'œuvre isolée, mais le fil discontinu que tissent les textes entre eux au fil du temps. Chaque texte, par ses choix de formels, participe à la trame plus vaste de la textualité. Les contextes sont incorporés dès lors qu'ils laissent des marques repérables, qu'elles soient stylistiques, thématiques, ou modales, et que l'analyse manuelle ne peut décrire et ni comparer.

Dans cette perspective, des marqueurs sociologiques deviennent constitutifs de la textualité. La position de l'auteur, les régimes de réception critique, la structuration des communautés de lecteurs et des sous-genres informent, consciemment ou non, la manière dont les textes s'écrivent et se lisent. La *textualité* se sédimente par des habitudes d'écriture et des attentes de lecture, et les redistribue. Cet objet se prête particulièrement aux études littéraires computationnelles (CLS), parce que ses permanences sont détectables à l'échelle de corpus massifs. Les méthodes quantitatives permettent de mesurer ces récurrences, avant d'en éprouver la valeur interprétative par retour au texte.

La généricité, la canonicité et l'auctorialité constituent trois forces structurantes de la textualité. La généricité cadre les attentes de lecture et stabilise des formes. L'auctorialité oriente la variation singulière. La canonicité, enfin, institue un horizon d'attente rétrospectif : elle sélectionne, hiérarchise et transmet des manières d'écrire qui deviennent des points de référence. En ce sens, le canon fonctionne comme la mémoire institutionnelle de la *textualité*. Il conserve certains motifs et procédures, tout en oubliant d'autres.

En élargissant ainsi le domaine des études littéraires, la *textualité* n'abolit pas l'analyse

des œuvres singulières, elle l'inscrit dans une cartographie des formes et des usages, où l'on peut articuler intertextualité et dimensions matérielles des formes. Le programme est de décrire ces régularités qui composent la trame littéraire générale et ensuite de mesurer comment elles se transforment quand elles sont adoptées par des auteurs différents. Dans cette thèse, nous aborderons la *textualité* par le prisme de la littérature de genre, avec une attention particulière au roman policier et au roman d'aventures, deux genres sériels dont la sédimentation éditoriale au début du XXe siècle offre un terrain d'observation privilégié afin de mesurer comment les dynamiques éditoriales et les attentes de lecture reconfigurent concrètement leur trame formelle.

2 Les études littéraires computationnelles

Cette thèse s'inscrit dans le champ des études littéraires computationnelles, qui contribue en partie à répondre à ces attentes d'étude dynamique de la littérature. En effet, les méthodes computationnelles permettent aux chercheurs d'étendre leurs investigations au-delà de l'étude limitée du canon et de son nombre restreint de textes. Si l'affirmation du domaine est récente, celui de la statistique textuelle [46] (également appelé lexicométrie ou textométrie) a déjà une cinquantaine d'années avec les études de Benzécri [47], Muller [48], puis Brunet [49] ou Pincemin [50]. Ce champ a longtemps peiné à trouver sa légitimité disciplinaire : dès 1993, Mark Olsen [51] dressait un constat sévère de l'échec des études littéraires computationnelles à s'imposer auprès de la critique traditionnelle, qu'il imputait non à un manque de moyens mais à une erreur d'objet, avec l'application de l'ordinateur à des questions de lecture proche pour lesquelles il est mal adapté. Il appelait à réorienter la discipline vers l'étude des discours et systèmes de signes à grande échelle, préfigurant ainsi l'argument que formulera Moretti sept ans plus tard.

Le renouveau actuel du domaine peut finalement s'expliquer par deux éléments pratiques qui ont préparé son expansion. La disponibilité de grands corpus de textes littéraires en format numérique, on pense pour la langue française, à la collection « Fictions Littéraires de Gallica » [52], qui comprend 19 240 documents du domaine public provenant de la plateforme numérique de la Bibliothèque nationale de France, ou le corpus Chapitres [53] qui se compose de près de 3000 romans. À cela s'ajoute une augmentation de la puissance des ordinateurs personnels qui permet aujourd'hui de traiter ces milliers de documents en seulement quelques heures. Ces avancées techniques ont permis aux chercheurs de naviguer dans la grande diversité de la littérature avec une facilité sans précédent, et par la même occasion de construire les fondements de la discipline.

46. Ludovic Lebart et A. Salem. *Statistique textuelle*. Paris : Dunod, 1994.
47. Jean-Paul Benzécri. *L'Analyse des données*. Paris Bruxelles Montréal : Dunod, 1973.
48. Charles Muller. *Principes et méthodes de statistique lexicale*. Paris : Hachette, 1977.
49. Étienne Brunet. *Le vocabulaire de Proust*. Genéve : Slatkine, 1983.
50. Bénédicte Pincemin. « Sémantique interprétative et analyses automatiques de textes : que deviennent les sèmes ? » *Sémiotiques* 1999, p. 71-120. Pour une histoire plus complète du champ de la statistique textuelle, voir la synthèse de Valérie Beaudouin. « Retour aux origines de la statistique textuelle : Benzécri et l'école française d'analyse des données ». *JADT 2016*. Sous la dir. de Damon Mayaffre, Cédric Poudat, Ludovic Vanni et al. Nice, France, 2016, p. 17-27
51. Mark Olsen. « Signs, Symbols and Discourses : A New Direction for Computer-Aided Literature Studies ». *Computers and the Humanities* 1993, p. 309-314.
52. Langlais, op. cit.
53. Leblond, op. cit.

Ce nouveau paradigme technique ouvre la possibilité de mener des recherches en *lecture distante*[54], qui invite les chercheurs à élargir la focale sur le passé littéraire, facilitant ainsi une compréhension plus profonde des tendances et des schémas qui définissent l'évolution de la littérature. La lecture distante propose ainsi une approche diachronique de l'intertextualité, puisqu'elle implique de considérer l'œuvre romanesque comme un chaînon d'un ensemble plus vaste, essayant de comprendre un phénomène dans la *longue durée*[55], présent à l'échelle des romans, mais dont les significations générales peuvent être différentes.

Des recherches récentes se fondant sur ces concepts ont montré que malgré la succession des mouvements littéraires dans le temps, les mécanismes formels du prestige littéraire sont restés relativement stables au cours des deux siècles précédents, en poésie anglophone[56] ou dans le roman anglais[57], français[58], allemand[59] et danois[60]. Ces recherches concluaient que dans des genres et des aires culturelles différentes, les nouveaux volumes de poésie et ouvrages romanesques avaient une tendance constante à changer en exagérant légèrement certaines caractéristiques ayant été célébrées dans leur passé récent. Ainsi, la lecture distante met l'accent sur les unités de sens globales au détriment de la spécificité des œuvres. Pour le texte, c'est un changement fondamental, puisque c'est le processus intertextuel structurant l'œuvre qui est étudié et non le texte lui-même.

Le changement d'échelle nécessite donc le développement d'outils spécifiques, en particulier avec le traitement automatique des langues (TAL). Ces approches computationnelles peuvent mettre en évidence des informations textuelles, des tendances et des connexions qui seraient peu pratiques pour les humains de discerner dans la masse de données textuelles. Une discussion plus complète des différents outils utilisés dans la thèse est menée au chapitre 4.

Le deuxième élément clé qui découle de cette nécessité computationnelle est la notion d'opérationnalisation, développée par le *Literary Lab* à Stanford[61]. Cette dernière réside dans le passage de concepts tirés de la théorie littéraire vers une mise en pratique computationnelle. C'est ce passage qui permet de justifier le traitement automatique par un cadre théorique précis et avec des attentes particulières tirées de l'histoire littéraire. L'opérationnalisation représente le pont entre deux disciplines, permettant l'articulation entre théorie et pratique, entre lecture proche et distante. Précisons tout de même que cette modélisation formelle ne rend compte que

54. Moretti, « Conjectures on World Literature » ; Underwood, *Distant horizons*. On notera une synthèse des écrits autour de cette notion dans un ouvrage dédié : Franco Moretti. *Distant reading*. London : Verso, 2013

55. Fernand Braudel, éd. *La Méditerranée : l'espace et l'histoire*. Paris : Flammarion, 2001 [1949], p. 160.

56. Ted Underwood et Jordan Sellers. « The "Longue Durée" of Literary Prestige ». *Modern Language Quarterly* 2016, p. 321-344. DOI : 10.1215/00267929-3570634.

57. Algee-Hewitt, Allison et al., « Canon/Archive. Large-scale Dynamics in the Literary Field ».

58. Jean Barré, Jean-Baptiste Camps et Thierry Poibeau. « Operationalizing Canonicity : A Quantitative Study of French 19th and 20th Century Literature ». *Journal of Cultural Analytics* 2023. DOI : 10.22148/001c.88113.

59. Judith Brottrager, Annina Stahl et al. « Modeling and Predicting Literary Reception. A Data-Rich Approach to Literary Historical Reception ». *Journal of Computational Literary Studies* 2022. DOI : 10.48694/jcls.95.

60. Pascale Feldkamp, Alie Lassche et al. « Canonical Status and Literary Influence : A Comparative Study of Danish Novels from the Modern Breakthrough (1870–1900) ». *Proceedings of the 4th international conference on natural language processing for digital humanities*. Sous la dir. de Mika Hämäläinen, Emily Öhman et al. Miami, USA : Association for Computational Linguistics, 2024, p. 140-155.

61. Franco Moretti. « Operationalizing' : or, the function of measurement in modern literary theory ». *Pamphlets of the Stanford Literary Lab* 2013.

partiellement du phénomène à l'étude.

2.1 La mesure dans les études littéraires

Les études littéraires computationnelles[62] élargissent la focale en traitant la production littéraire comme une population de textes plutôt que comme une suite d'objets singuliers. Il devient alors possible de comparer, sur des bases empiriques, des ensembles issus de périodes et de contextes sociaux distincts, et de décrire des régularités ou des écarts de distribution que la lecture individuelle ne peut stabiliser. Dans cette perspective, Franco Moretti et le laboratoire littéraire de Stanford[63] ont joué un rôle structurant en proposant un programme explicitement fondé sur la mesure et sur la fabrication d'indicateurs reproductibles. Les pamphlets 1, « Quantitative Formalism : an Experiment »[64], 6, « "Operationalizing" : or, the function of measurement in modern literary theory »[65] et 12, « Literature, Measured »[66] ne se contentent pas de légitimer le recours au quantitatif : ils posent un cadre où la description littéraire passe par la construction d'objets mesurables, et où l'interprétation est inséparable des choix de formalisation.

Un des effets les plus visibles de ce déplacement est une redéfinition pratique de l'objet d'étude. Le roman n'est pas seulement abordé comme une unité matérielle isolée, mais comme un faisceau de propriétés observables que l'on peut extraire, comparer et situer dans un espace de variation. Autrement dit, chaque texte devient aussi un point parmi d'autres dans une cartographie, et son interprétation dépend en partie des voisinages et des contrastes qui se dessinent à l'échelle du corpus. Mark Algee-Hewitt résume l'enjeu de cette transformation, du texte à la donnée : « l'enjeu de cette transformation est donc notre compréhension du roman lui-même : ce qu'il est, l'information qu'il contient et ce qu'il peut faire en tant qu'objet littéraire et critique »[67]. Cette perspective n'abolit pas la singularité des œuvres, elle la recontextualise, en faisant de la différence un phénomène mesurable et historiquement interprétable.

Dans cette logique, Matthew L. Jockers propose de penser l'examen systématique des textes comme une *macroanalysis*[68] : il s'agit moins de remplacer la lecture par des chiffres que de disposer d'un point de vue macroscopique sur la manière dont les textes s'alignent, divergent ou se situent par rapport à des tendances culturelles. Comme il l'écrit, « Une approche macro-analytique nous aide non seulement à voir et à comprendre le fonctionnement d'une "économie littéraire" plus vaste, mais aussi, grâce au changement d'échelle, à mieux saisir dans quelle mesure la littérature et les auteurs individuels qui la produisent répondent aux tendances littéraires et

62. Une version antérieure de certains éléments de cadrage (mesure et modélisation en études littéraires computationnelles) a été développée dans mon mémoire de Master 2 (2022) ; la présente section en propose une réécriture et un élargissement, intégrés à l'argumentation propre de la thèse.

63. https://litlab.stanford.edu/

64. Sarah Allison, Mark Algee-Hewitt et al. « Quantitative Formalism : an Experiment ». *Pamphlets of the Stanford Literary Lab* 2011.

65. Moretti, op. cit.

66. Franco Moretti. « Literature, Measured ». *Pamphlets of the Stanford Literary Lab* 2016.

67. Mark Algee-Hewitt, Erik Fredner et Hannah Walser. « The Novel as Data ». *The Cambridge Companion to the Novel*. Sous la dir. d'Eric Bulson. Cambridge University Press, 2018, p. 189-216. doi : 10.1017/9781316659694.013, p. 211.

68. Matthew L. Jockers. *Macroanalysis : Digital Methods and Literary History*. University of Illinois Press, 2013. doi : 10.5406/illinois/9780252037528.001.0001.

culturelles ou réagissent contre elles » [69]. Cette perspective permet de comprendre la singularité des ouvrages comme un phénomène mesurable comme une différence de la tendance générale du champ littéraire.

Dans ces méthodes, les nombres ne valent pas comme une garantie d'objectivité, mais comme un dispositif de description des degrés. Ted Underwood le formule nettement :

> Les chiffres ne sont pas plus objectifs que les mots. Ils ne sont que des signes qui permettent aux observateurs humains de se débattre avec des questions de degré. Nous avons besoin de chiffres pour comprendre les longues chronologies littéraires. À mesure que nous prenons du recul pour observer de grands motifs historiques, nous avons besoin de nombres, non parce que nous chercherions à être plus objectifs qu'à l'ordinaire, mais parce que notre matériau devient plus varié et que les comparaisons deviennent plus difficiles [70].

Le quantitatif sert alors à stabiliser des comparaisons et à rendre manipulables des temporalités longues, à condition de ne pas confondre fréquence et signification. Dans le même esprit, Andrew Piper, dans *Énumérations* [71], invite à interroger ce que produit le changement d'échelle. Lorsque la littérature est traitée comme une masse, les opérations de comptage, d'agrégation et de sélection deviennent elles-mêmes des gestes critiques, qui exigent des protocoles explicites.

Les corpus littéraires étant de plus en plus volumineux, les études computationnelles se sont ouvertes à des approches exploitant cette échelle. Le projet *culturomics*, porté entre autres par l'équipe de Google Books [72], cherche à interroger des millions de livres numérisés, tente de vérifier des hypothèses historiques et culturelles à une échelle inaccessible à la lecture humaine (en l'occurrence, traquer la disparition d'un artiste juif dans les textes allemands des années 1930, mesurer le rythme de régularisation des verbes anglais, dater l'adoption d'une technologie par sa fréquence lexicale). L'approche n'est pas à proprement parler inductive puisque les questions restent guidées par des connaissances historiques préalables. Mais l'ampleur des corpus confère aux réponses une portée statistique qui dépasse l'anecdote et permet de détecter des évolutions graduelles imperceptibles à l'échelle d'un corpus réduit.

Toutefois, cette puissance heuristique s'accompagne de limites méthodologiques considérables. Les biais de corpus sont multiples et cumulatifs : erreurs d'OCR qui déforment le texte original, métadonnées lacunaires ou erronées qui faussent la périodisation, composition éditoriale déséquilibrée qui surreprésente certains genres ou éditeurs au détriment d'autres. Plus fondamentalement encore, l'approche *data-driven* entretient une illusion selon laquelle la fréquence d'apparition d'un terme ou d'un motif révélerait directement sa signification culturelle ou littéraire. Or un mot peut être omniprésent sans être sémantiquement central, et inversement, des phénomènes littéraires décisifs peuvent se manifester par des traces textuelles rares ou discrètes (par exemple

69. Ibid., p. 28.

70. Ted Underwood. « Why Literary Time is Measured in Minutes ». *ELH* 2018, p. 341-365. DOI : 10.1353/elh.2018.0013, p. 354.

71. Andrew Piper. *Enumerations : data and literary study*. Chicago ; London : The University of Chicago Press, 2018.

72. Jean-Baptiste Michel, Yuan Kui Shen et al. « Quantitative Analysis of Culture Using Millions of Digitized Books ». *Science* 2011, p. 176-182. DOI : 10.1126/science.1199644 ; Jean-Paul Delahaye et Nicolas Gauvrit. *Culturomics : le numérique et la culture*. Paris : Odile Jacob, 2013.

le *ptyx* de Mallarmé, hapax devenu emblématique, a reçu une attention critique sans commune mesure avec sa fréquence [73]).

La thèse adopte une posture principalement *theory-driven*. Nous partirons d'hypothèses formulées sur la base de savoirs historiques et d'analyses littéraires, puis construit des instruments capables d'en tester certaines conséquences observables dans les textes (comme au chapitre 7 sur la naissance du roman policier). L'exploration inductive n'est pas exclue, mais elle est subordonnée à un cadre de validation. Les calculs servent à répondre à des hypothèses, à mesurer des écarts et à objectiver des régularités, avant un retour interprétatif qui réinscrit ces résultats dans des contextes éditoriaux, sociaux et esthétiques.

Ces méthodes fonctionnent ainsi en tandem avec la théorie et l'histoire littéraires : ignorer les acquis de l'analyse traditionnelle serait contre-productif et appauvrirait l'interprétation en études computationnelles. La thèse privilégie donc un dialogue constant entre modèles théoriques établis et validation empirique sur corpus, plaçant l'expertise disciplinaire au cœur du processus computationnel plutôt qu'en aval de celui-ci.

2.2 La modélisation en études littéraires

Au cours de la dernière décennie, les humanités numériques ont bénéficié des progrès des méthodes quantitatives. Au-delà du simple relevé de variables ou de fréquences, la recherche requiert désormais des modèles statistiques pour appréhender des concepts littéraires : des méthodes descriptives, on est passé à des méthodes prédictives de modélisation.

Dans cette thèse, nous mettons en œuvre ces techniques et précisons leurs modalités d'emploi. L'introduction de l'apprentissage machine dans la réflexion en sciences humaines dépasse la mesure propre à la lecture distante. Selon Richard J. So, « La lecture à distance est innovante parce qu'elle a introduit non seulement des "données" ou des "algorithmes" dans les études littéraires, mais aussi, et surtout, la modélisation quantitative comme forme de raisonnement et d'analyse » [74]. La modélisation statistique transforme fondamentalement notre rapport aux phénomènes littéraires en instillant l'incertitude et la probabilité au cœur de la mesure. Là où une analyse traditionnelle affirme qu'un texte appartient ou non à un genre, qu'un auteur emploie ou non un procédé stylistique, la modélisation quantifie des degrés d'appartenance, des gradients de probabilité, des zones d'indétermination. Elle ne livre pas des résultats tranchés, mais un compte rendu de ce que le modèle a cherché à mesurer, de la manière dont il l'a opérationalisé, et des limites de sa capacité à produire un résultat. Cette transparence méthodologique contraint le chercheur à expliciter ses présupposés théoriques : quelles variables choisir pour représenter la *fictionnalité* ? Quels indicateurs textuels pour cerner le *fantastique* ? La modélisation n'objective en rien les études littéraires, elle cherche à rendre visible l'écart entre le concept littéraire et sa traduction en variables mesurables.

Pour cerner ce changement de paradigme, revenons à Franco Moretti et à son article « Style,

73. Dennis Duncan. « The Protean Ptyx : Nonsense, Non-Translation, and Word Magic in Mallarmé's 'Sonnet en yx' ». *Modernism and Non-Translation*. Oxford University PressOxford, 2019, 34-C3.P71. DOI : 10.1093/oso/9780198821441.003.0003.

74. Richard Jean So. « "All Models Are Wrong" ». *PMLA/Publications of the Modern Language Association of America* 2017, p. 668-673. DOI : 10.1632/pmla.2017.132.3.668, p. 669.

Inc : Reflections on Seven Thousand Titles (British Novels, 1740-1850) » [75]. Il y observe la baisse de la longueur des titres de romans dans le temps par de simples moyennes annuelles projetées sur un graphe : autant d'analyses descriptives qui constatent une tendance sans pouvoir évaluer sa robustesse statistique, sans distinguer signal et bruit, sans quantifier l'incertitude entourant cette observation. Ces mesures n'autorisent ni conclusions définitives ni garanties de significativité : impossible de savoir si la baisse observée résulte d'une évolution culturelle réelle ou d'un artefact lié à la composition du corpus. Andrew Piper avance que la modélisation introduit « une nouvelle manière de penser le passage entre les différentes échelles de l'analyse critique » [76] : les modèles, en quantifiant l'incertitude et en testant des hypothèses alternatives, permettent des lectures plus nuancées et des affirmations graduées plutôt que catégoriques.

Dans les études littéraires computationnelles, l'apprentissage automatique est mobilisé pour des tâches de classification, comme distinguer fiction et non-fiction. Le travail d'Andrew Piper [77] montre que des indices textuels modélisés identifient un texte fictionnel ou non-fictionnel avec plus de 94% d'efficacité. Si la tâche peut sembler attendue, Piper précise :

> L'intérêt du point de vue quantitatif est qu'il permet de mieux comprendre la manière dont un type d'écriture particulier signale aux lecteurs une orientation particulière, ce que l'on pourrait appeler sa position sociale. Cela n'exclut pas les innombrables façons dont les lecteurs peuvent trouver leur propre version de l'importance du roman. Mais cela permet de mieux comprendre le roman comme catégorie sociale [78].

L'algorithme agrège des caractéristiques textuelles, telles que les distributions de temps verbaux, les fréquences de pronoms, la densité lexicale ou encore la longueur de phrases et évalue dans quelle mesure elles distinguent statistiquement un texte comme appartenant à la catégorie assignée. Cette opération révèle les marqueurs conventionnels, les signaux tacites par lesquels un texte se fait reconnaître comme fiction ou essai, au-delà des intuitions critiques. Pour autant, Ted Underwood rappelle que « l'ordinateur ne sait rien de l'histoire littéraire : il ne modélise que les éléments que nous lui fournissons. Le modèle ne peut mesurer aucune dimension universelle du langage ; il indique simplement si un texte donné ressemble plus aux exemples du groupe A ou du groupe B » [79]. La modélisation ne découvre pas une essence ontologique de la fiction, elle reconstruit empiriquement les conventions textuelles qui permettent à une communauté de lecteurs de reconnaître un texte comme relevant de la fiction, ou non.

Des travaux analogues ont porté sur la notion de genre [80] et on le verra par la suite, le genre n'est pas une essence stable, ses frontières sont souvent poreuses. L'apprentissage machine ne vise pas une vérité absolue, il cartographie plutôt les contours de catégories forgées par des siècles

75. Franco Moretti. « Style, Inc. Reflections on Seven Thousand Titles (British Novels, 1740–1850) ». *Critical Inquiry* 2009, p. 134-158. doi : 10.1086/606125.

76. Andrew Piper. « Think Small : On Literary Modeling ». *PMLA/Publications of the Modern Language Association of America* 2017, p. 651-658. doi : 10.1632/pmla.2017.132.3.651, p. 651.

77. Andrew Piper. « Fictionality ». *Journal of Cultural Analytics* 2016. doi : 10.22148/16.011.

78. Ibid., p. 27.

79. Underwood, *Distant horizons*, p. 36.

80. Ted Underwood, Michael L. Black et al. « Mapping mutable genres in structurally complex volumes ». *2013 IEEE International Conference on Big Data*. 2013 IEEE International Conference on Big Data. Silicon Valley, CA, USA : IEEE, 2013, p. 95-103. doi : 10.1109/BigData.2013.6691676.

d'écritures et de lectures, en rendant visible leur flou constitutif. Certains textes se situent à la lisière de plusieurs genres, d'autres manifestent une appartenance ambiguë. La modélisation transforme ainsi des catégories critiques jugées évidentes en distributions probabilistes qui reflètent la complexité historique des pratiques littéraires.

Bien d'autres travaux modélisent des phénomènes littéraires à l'aide de méthodes computationnelles variées. Long et So défendent ainsi une forme de « reconnaissance de motifs littéraires » [81] qui fait dialoguer lecture rapprochée, histoire culturelle et apprentissage automatique. Le modèle n'y remplace pas l'interprétation, il la reconfigure en faisant apparaître, à une autre échelle, des régularités textuelles que la lecture critique peut ensuite historiciser. Cette exigence suppose toutefois que les mécanismes d'inférence restent lisibles. Comme le soulignent Ribeiro et al, la confiance dans un modèle dépend de la possibilité de produire des explications à la fois intelligibles et fidèles [82]. Examiner les variables qui pèsent dans une décision, identifier celles qui sont redondantes ou contre-intuitives, comprendre ce que révèlent les erreurs du modèle : autant d'opérations qui transforment l'outil computationnel en instrument critique plutôt qu'en simple machine à prédire.

Cette thèse s'inscrit dans cette perspective, en combinant grands nombres et retour à une lecture proche afin d'interpréter les inférences des modèles.

3 Opérationnaliser l'intertextualité

L'intertextualité constitue le cadre théorique de cette thèse en études littéraires computationnelles. L'objectif est d'inscrire ce travail dans la perspective des structuralistes qui ont élaboré cette notion, tout en complétant leur approche par des expérimentations empiriques sur un grand nombre de textes littéraires. Nous soutiendrons que les études littéraires computationnelles représentent, par définition, une opérationnalisation de l'intertextualité : une mise en relation quantitative des textes entre eux et avec les conditions de leur production. Elle peut porter sur différentes dimensions textuelles (qu'elles soient lexicales, sémantiques ou thématique) et aborder diverses questions (l'attribution d'auteur, l'identification du genre ou de la période), mais elle place toujours le texte dans un réseau plus vaste, que nous avons nommé *textualité*.

Cette mise en relation ne se limite pas uniquement au matériau textuel puisque les données contextuelles (dates de publication, étiquettes génériques, appartenances éditoriales) y entrent de plein droit, non comme des variables externes au texte, mais comme des marqueurs des contextes qui informent l'écriture et dont la textualité, telle que nous l'avons définie, porte la trace. En fonction des techniques mobilisées, la configuration de ce réseau varie, et les conclusions en dépendent. Le traitement computationnel demeure donc intimement lié à ses configurations et hypothèses de départ et les interprétations possibles sont nécessairement circonscrites au type d'opérationnalisation mené.

81. Hoyt Long et Richard Jean So. « Literary Pattern Recognition : Modernism between Close Reading and Machine Learning ». *Critical Inquiry* 2016, p. 235-267. DOI : 10.1086/684353.

82. Marco Tulio Ribeiro, Sameer Singh et Carlos Guestrin. « "Why Should I Trust You ?" : Explaining the Predictions of Any Classifier ». *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. KDD '16 : The 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco California USA : ACM, 2016, p. 1135-1144. DOI : 10.1145/2939672.2939778.

3.1 L'intertextualité computationnelle

L'intertextualité a été définie différemment par les chercheurs successifs et peut être abordée de multiples façons[83]. La définition traditionnelle se concentre sur la détection de citations explicites. Les études littéraires, qu'elles soient computationnelles ou non, se sont naturellement attachées à suivre ces citations d'un texte à l'autre pour comprendre les phénomènes d'influence ou de réécriture (voir Allen et al.[84], Büchler et al.[85], Ganascia et al.[86]).

Une approche large de l'intertextualité, par contraste, identifie de simples allusions ou des similitudes thématiques et linguistiques entre un texte et un ensemble d'autres textes. Les méthodes computationnelles ont permis de développer cette perspective, notamment avec les travaux de Ganascia[87] qui proposent une détection automatique de fragments textuels réutilisés par leur similarité en n-grammes. Cette approche permet d'identifier des relations intertextuelles qui échapperaient à l'analyse manuelle, révélant la structure du *nexus* littéraire dans lequel chaque texte n'existe jamais seul mais comme nœud de reprises, de circulations et de transformations.

Les études littéraires computationnelles se révèlent particulièrement utiles pour cartographier ce *nexus* dans de vastes corpus, permettant de repérer des motifs et des tendances dans l'usage de l'intertextualité à travers différents genres, périodes et contextes culturels. L'article fondateur de Manjavacas et al[88] propose ainsi une approche thématique et lexicale de l'intertextualité : en regroupant des auteurs et des textes partageant des similitudes, leur objectif était d'évaluer la possibilité de détecter des phénomènes intertextuels à partir d'une source donnée (la Bible) dans un corpus particulier.

Plus récemment, Xing et al[89] propose un modèle quantitatif d'intertextualité fondé sur les n-gram embeddings, combinant la précision locale des séquences lexicales et la richesse sémantique des représentations vectorielles. La méthode compare les similarités entre n-grammes de deux textes, filtre les résultats au-dessus d'un seuil et calcule un score global d'intertextualité.

3.2 Le genre comme attracteur architextuel

Dans cette thèse, nous abordons l'intertextualité par le prisme de la littérature de genre. Plutôt que de chercher des relations entre des textes isolés, nous partons du constat que les genres constituent des ensembles de textes suffisamment denses et suffisamment conventionnels pour que les relations intertextuelles y soient à la fois massives et observables. Le genre offre ainsi un

83. Pour une présentation générale du concept, voir l'ouvrage de Allen, (Graham Allen. *Intertextuality*. London, New York : Routledge, Taylor & Francis Group, 2022).

84. Timothy Allen, Charles Cooney et al. « Plundering Philosophers : Identifying Sources of the Encyclopédie ». *Journal of the Association for History and Computing* 2010.

85. Marco Büchler, Gregory Crane et al. « Increasing Recall for Text Re-use in Historical Documents to Support Research in the Humanities ». *Lecture Notes in Computer Science*. Springer Berlin Heidelberg, 2012, p. 95-100. doi : 10.1007/978-3-642-33290-6_11.

86. Jean-Gabriel Ganascia, Pierre Glaudes et Andrea Del Lungo. *Automatic Detection of Reuses and Citations in Literary Texts*. 2014. doi : 10.48550/ARXIV.1404.2997.

87. Jean-Gabriel Ganascia. « Détection automatique de phénomènes intertextuels ». *Genesis* 2020, p. 63-77. doi : 10.4000/genesis.5671.

88. Enrique Manjavacas, Folgert Karsdorp et Mike Kestemont. « A Statistical Foray into Contextual Aspects of Intertextuality ». *Proceedings of the Workshop on Computational Humanities Research (CHR 2020)*. CEUR Workshop Proceedings, 2020, p. 77-96.

89. Yi Xing. *Modelling Intertextuality with N-gram Embeddings*. 2025. arXiv : 2509.06637 [cs.CL].

niveau d'analyse intermédiaire entre le texte singulier et le système littéraire dans son ensemble, suffisamment circonscrit pour être modélisé, suffisamment vaste pour que des régularités s'y manifestent.

Les sous-genres romanesques de la fin du XIXe et du début du XXe siècle présentent un terrain particulièrement fertile pour opérationnaliser l'intertextualité. Durant cette période, l'industrialisation de la production littéraire accompagne un lectorat toujours plus important [90]. Le passage du roman-feuilleton à la publication en collections professionalise les genres et engendre une multiplication sans précédent de textes affiliés à des sous-genres identifiables : roman d'aventures, roman policier, roman sentimental, roman fantastique [91]. Ces catégories génériques fonctionnent comme des cadres architextuels : chaque texte dialogue avec les conventions du genre, reprend, transforme ou subvertit des motifs récurrents, et participe à l'évolution collective de la forme. L'intertextualité y est prépondérante précisément en raison du nombre considérable de textes associés à ces sous-genres, et autant de variations spécifiques autour d'un prototype créant un dense réseau de références, et d'emprunts. Les marqueurs sociologiques, comme la position de l'auteur, la réception critique, ou les communautés de lecteurs, s'incorporent dans la *textualité* même de ces productions, informant les choix d'écriture et les horizons d'attente.

En identifiant les marqueurs génériques (motifs thématiques, structures narratives, registres lexicaux), les méthodes computationnelles peuvent cartographier l'espace intertextuel du genre et révéler les processus d'évolution littéraire. Il ne s'agit plus de remonter une histoire verticale mais de tracer des trajectoires, de suivre des prises et des relais entre unités hétérogènes. L'intertexte n'est plus extérieur au texte : il constitue la mécanique interne de ces raccords, et le sens d'une unité ne vaut que par la configuration de relations qui la porte.

3.3 Objets d'étude et méthodologie

Cette recherche se concentre sur deux sous-genres majeurs de la période, le roman d'aventures et le roman policier. Ces genres disposent de corpus relativement bien délimités et abondants, facilitant la constitution d'ensembles textuels substantiels. Leur succès commercial et leur large circulation ont généré une importante production textuelle, créant les conditions d'une intertextualité dense et permettant d'observer comment la récurrence de certaines combinaisons stabilise des attentes spécifiques.

Notre approche méthodologique combine plusieurs techniques d'analyse computationnelle qui seront développées plus amplement au chapitre 4. Nous mobilisons d'abord des représentations en *sacs-de-mots* et en *plongements de mots* pour capturer différentes dimensions de la similarité textuelle. Ces représentations sont ensuite exploitées par des classifieurs (réseaux de neurones, SVM) afin de détecter les caractéristiques distinctives de ces genres.

L'annotation des données reposera sur une approche hybride, avec principalement une annotation humaine de référence afin d'entraîner et d'évaluer des modèles. Parallèlement, nous explorons l'utilisation de grands modèles de langage (LLMs) pour identifier automatiquement les scènes caractéristiques des genres. Des scènes de danger et d'exploration pour le roman

90. Kalifa, *La culture de masse en France. 1*, p. 26.
91. Ibid., p. 21.

d'aventures, des scènes de crime et de raisonnement pour le roman policier. Cette combinaison permet de traiter de vastes corpus tout en maintenant une exigence et un contrôle important sur la qualité de l'annotation.

En définitive, cette opérationnalisation de l'intertextualité par le genre romanesque nous permettra de mesurer empiriquement comment les textes se définissent mutuellement dans la textualité, comment les conventions génériques se stabilisent et se transforment sous l'effet des dynamiques éditoriales et de la reconnaissance institutionnelle, et comment les innovations individuelles s'inscrivent dans une dynamique collective de circulation et de sélection.

Chapitre 2

Les genres littéraires

Objectifs

Ce chapitre vise à synthétiser les approches théoriques de la notion de genre, sans visée exhaustive puisque la notion est le fruit de débats dans la critique littéraire depuis la *Poétique* d'Aristote. On se focalisera sur différentes approches, des pré-formalistes aux approches contemporaines. Le parcours théorique nous apprendra que le concept de genre comme matrice textuelle s'exemplifie dans les genres sérialisés de la fin du XIXe siècle, où les contraintes éditoriales et les attentes du public se sont incorporées dans les formes narratives elles-mêmes. Cette incorporation rend ces genres computationnellement saillants et légitimera dans les chapitres suivants de tester empiriquement la distinction entre genres à haute densité architextuelle (roman policier) et les genres à généricité plus diffuse (roman d'aventures).

Sommaire

1 Définitions consensuelles . . . **31**
2 Deux grands systèmes historiques des genres . . . **32**
3 Système des genres et aspect dynamique de la généricité . . . **34**
4 Approches textuelles des genres . . . **35**
4.1 Brunetière . . . 35
4.2 Formalistes russes . . . 36
4.3 Bakhtine et le dialogisme générique . . . 37
4.4 Structuralistes . . . 38
5 Le genre au-delà du texte . . . **39**
6 Le genre comme matrice prescriptive . . . **42**
6.1 Du modèle générique au formatage éditorial . . . 42
6.2 Du feuilleton à la collection de genre . . . 44
7 Conclusion . . . **45**

> Εἰσὶ δέ τινες οἳ πᾶσι χρῶνται τοῖς εἰρημένοις, λέγω δὲ οἷον ῥυθμῷ καὶ μέλει καὶ μέτρῳ, ὥσπερ ἥ τε τῶν διθυραμβικῶν ποίησις καὶ ἡ τῶν νόμων καὶ ἥ τε τραγῳδία καὶ ἡ κωμῳδία· διαφέρουσι δὲ ὅτι αἱ μὲν ἅμα πᾶσιν αἱ δὲ κατὰ μέρος.
>
> ARISTOTE. La poétique. *Trad. par Roselyne* DUPONT-ROC *et Jean* LALLOT. *Paris : Éditions du Seuil, 1980 [335 BCE], p. 34*
>
> Il est des auteurs qui utilisent tous les moyens que j'ai cités, je veux dire le rythme, le chant et le mètre, comme dans la poésie dithyrambique, le nome, la tragédie et la comédie. La différence alors vient de ce que les uns les prennent tous ensemble, les autres séparément.
>
> *ibid., p. 35*

1 Définitions consensuelles

Comme nous l'avons établi au chapitre précédent, la littérature peut être pensée comme un réseau où les textes se définissent mutuellement. Les genres participent pleinement de cette dynamique. Ils ne sont pas seulement des catégories que la critique impose après coup aux œuvres, ils orientent concrètement leur production et leur réception, structurent les attentes des lecteurs, guident les choix des auteurs et des éditeurs. En ce sens, les genres existent dans les œuvres autant que dans les discours sur les œuvres. Ce chapitre vise à fonder théoriquement cette conception en retraçant les débats critiques sur la notion de genre, de Brunetière aux approches contemporaines des cultures sérielles, pour aboutir à une définition opérationnelle compatible avec une analyse computationnelle.

Le concept de genre occupe une place centrale dans les études littéraires car il se situe à l'intersection de la poétique, qui s'intéresse aux formes et aux structures internes des textes, et de l'histoire littéraire, qui examine la succession des œuvres à travers le temps. La notion représente un niveau d'abstraction qui permet de faire le lien entre l'œuvre particulière et la littérature dans son ensemble, vue comme un vaste corpus organisé. Le problème réside dans le flou autour de ce lien, qui peut être défini de plusieurs manières, interne ou externe aux textes, en diachronie ou en synchronie, de manière modale, formelle ou thématique. Cette multiplicité de perspectives rend compte de la nature complexe des genres, à la fois configuration textuelle, institution de réception et matrice prescriptive de formes.

Notre parcours théorique visera à dégager les conditions sous lesquelles ces dimensions convergent et deviennent quantitativement saisissables. Nous nous focaliserons sur les efforts de redéfinition et de clarification de la notion depuis le début du XXe siècle, en portant une attention particulière aux cultures sérielles où l'architextualité générique atteint sa plus haute densité.

La réflexion de Jean-Marie Schaeffer sur la notion de genre pose un cadre particulièrement utile pour notre démarche. Dans un texte de 1986, Schaeffer [1] défend que la théorie générique

1. Jean-Marie SCHAEFFER. « Du texte au genre ». *Théorie des genres*. Sous la dir. de Gérard GENETTE et Tzvetan TODOROV. Paris : Éditions du Seuil, 1986.

doit rendre compte de ressemblances textuelles, formelles et thématiques entre les œuvres, sans postuler une essence cachée du genre. Ces ressemblances peuvent être saisies en définissant la généricité comme une composante textuelle, les relations génériques comme « un ensemble de réinvestissements (plus ou moins transformateurs) de cette même composante textuelle » [2], et le genre comme le produit d'« un jeu de répétitions, d'imitations, d'emprunts, etc., d'un texte par rapport à un autre, ou à d'autres » [3]. Schaeffer précise cependant que ces ressemblances n'épuisent pas à elles seules la généricité, qui engage aussi des cadres de production, de transmission et de réception.

Trois ans plus tard, dans *Qu'est-ce qu'un genre littéraire ?*, Schaeffer [4] affine cette position. Il montre que la logique des genres littéraires n'est pas celle des espèces naturelles : les textes ne se reproduisent pas, ne s'engendrent pas les uns les autres, et un texte n'existe que grâce à l'intervention d'une causalité non textuelle, celle de l'auteur qui le produit. La conséquence est que la relation entre la classe et l'individu est inversée : « Alors que la relation générique biologique va de la classe à l'individu, la relation générique artefactuelle va des individus à la classe » [5]. Si des textes forment un genre, ce n'est pas parce qu'une classe préexistante leur aurait conféré des propriétés communes, mais parce que des modes différents de constitution des classes (exemplification, application de règles, filiation hypertextuelle, simple ressemblance) permettent de les regrouper. Cette inversion a une conséquence évolutive décisive, formulée par Todorov à propos de la littérature fantastique, et reprise par Schaeffer : « toute œuvre modifie l'ensemble des possibles, chaque nouvel exemple change l'espèce » [6]. Cette vision d'un sous-genre romanesque en reconfiguration permanente rejoint la textualité vue comme un flux, où chaque texte, par ses choix de forme et de thème, reconfigure la trame d'ensemble.

Ce cadre a une conséquence directe pour notre travail. Si la généricité se manifeste notamment par des reprises, des transformations et des régularités observables d'un texte à l'autre, alors les méthodes computationnelles, conçues pour détecter de telles régularités à grande échelle, peuvent en proposer une saisie partielle et empiriquement contrôlable. Il va de soi que la généricité ne se réduit pas à sa dimension textuelle : les conditions éditoriales, les attentes de lecture et les cadres institutionnels participent pleinement à la constitution des genres. Mais c'est par les traces que ces dynamiques laissent dans les textes que nous pouvons les saisir. Avant de détailler cette opérationnalisation, il nous faut cependant un détour théorique plus large sur la notion de genre, de ses premières formulations systématiques à ses développements contemporains.

2 Deux grands systèmes historiques des genres

De nombreuses descriptions de la littérature sous la forme d'un système des genres ont été réalisées au cours de l'histoire littéraire. Ici, nous choisissons de résumer les systèmes classique et romantique en suivant l'*Introduction à l'architexte* de Gérard Genette [7], qui retrace précisément

2. Ibid., p. 186.
3. Ibid., p. 186.
4. Idem, *Qu'est-ce qu'un genre littéraire ?*
5. Ibid., p. 80.
6. Tzvetan Todorov. *Introduction à la littérature fantastique*. Paris : Éditions du Seuil, 1976, p. 10.
7. Genette, « Introduction à l'architexte ».

la généalogie menant du système classique (Aristote, Platon) à la triade romantique (épique, dramatique et lyrique) telle qu'elle a été établie notamment par Goethe[8] et Schlegel[9]. Cette triade structure encore largement le système des genres tel qu'il nous parvient aujourd'hui.

Genette explique que chacun de ces trois grands genres correspond, dans la théorie romantique, à une fonction discursive spécifique. Le lyrique est conçu comme l'expression de la subjectivité du poète, donnant voix à l'intériorité, aux émotions et à l'expérience personnelle. L'épique, à l'inverse, prend en charge les récits collectifs et les destinées communautaires, relatant les grandes gestes, les mythes fondateurs, les aventures qui dépassent l'individu. Enfin, le dramatique repose sur la représentation de l'action par le dialogue et la mise en scène, où les personnages s'affrontent directement, sans médiation narrative.

Dans une visée de légitimation de leur courant de pensée, les romantiques se revendiquent des classiques, avec notamment Aristote et Platon. Cependant, Genette souligne que cette projection des romantiques sur le modèle classique est comme une « erreur historique qui cautionne et valorise une confusion théorique »[10], une confusion entre les modes du discours et les genres.

Pour clarifier les notions, Genette définit plusieurs concepts distincts, qui viennent préciser la classification des œuvres : d'abord les *modes* comme des situations d'énonciations (narratif vs dramatique), ensuite les *types* comme une spécification des modes (par exemple au sein du narratif, la narration à la première personne), puis les *genres* comme des réalisations concrètes historiques (roman, nouvelle, épopée, …) et enfin les sous-genres associés (roman policier, picaresque, …). Toujours selon Genette, le système d'Aristote[11] distingue deux modes principaux, le narratif et le dramatique, et deux catégories d'objets, les héros supérieurs et inférieurs. Cette combinaison aboutit à quatre classes : dramatique supérieur (tragédie), dramatique inférieur (comédie), narratif supérieur (épopée) et narratif inférieur (parodie). Il est à noter que la poésie lyrique est absente de ce cadre. Genette clarifie ainsi les différences entre les systèmes des genres :

> La différence structurale entre le système d'Aristote et celui des théories romantiques et modernes, c'est que ces dernières se ramènent à un schéma d'inclusions univoques et hiérarchisées (les œuvres dans les espèces, les espèces dans les genres, les genres dans les « types »), tandis que le système aristotélicien — si rudimentaire soit-il par ailleurs — est implicitement un tableau à (au moins) double entrée, où chaque genre relève à la fois (au moins) d'une catégorie modale et d'une catégorie thématique[12].

Ainsi, la division romantique envisage le lyrique, l'épique et le dramatique non plus comme de simples modes d'énonciation, mais comme de véritables « *attitudes fondamentales* de mise en forme »[13], c'est-à-dire comme des genres. La transformation du système platonicien / aristotélicien

8. Genette cite deux textes : *Dichtarten* et *Naturformen der Dichtung*, republiés dans Johann Wolfgang von Goethe. *Divan d'Orient et d'Occident*. Paris : les Belles lettres, 2012, où Goethe parle de la triade epos (narration), lyrique et drame comme « trois authentiques formes naturelles »

9. Selon Schlegel, l'ordre générique est « épique, lyrique, dramatique : thèse, antithèse, synthèse » dans August Wilhelm Schlegel. *Vorlesungen über dramatische Kunst und Literatur (1809–1811) : Teilband 1 : Text*. Leiden, The Netherlands : Brill | Schöningh, 2018 [1809]. doi : 10.30965/9783657778546, cité dans Antoine Compagnon. *Théorie de la littérature : la notion de genre. Cours de M. Antoine Compagnon*. 2001

10. Genette, op. cit., p. 148.

11. Aristote, *La poétique*.

12. Genette, op. cit., p. 149.

13. Karl Viëtor. « L'histoire des genres littéraires ». *Théorie des genres*. Sous la dir. de Gérard Genette et

au nôtre relève donc du passage d'une catégorisation qui relève de la linguistique (type de discours), à une catégorisation proprement littéraire.

Il faut toutefois souligner que ces systèmes ont été conçus pour la poésie au sens large et ne prennent pas en compte le roman, genre tardif qui ne s'impose comme catégorie autonome qu'au XVIIIe siècle. Nous les exposons néanmoins car c'est à partir de leur relecture que Genette élabore la notion d'architextualité, que nous chercherons à opérationnaliser dans la suite de ce travail, et plus largement parce que les catégories qu'ils ont forgées restent pertinentes pour penser les sous-genres romanesques que nous étudions.

3 Système des genres et aspect dynamique de la généricité

À travers ces exemples, classique, romantique et moderne, nous voyons que la construction de systèmes est une constante dans l'histoire littéraire. Il y a là une volonté de stabilisation de la littérature sous la forme d'un système saisissable par les historiens, un pré-requis pour pouvoir étudier la littérature. Le seul consensus à ces approches théoriques réside dans la volonté de rendre compte de la nature mouvante des genres, en perpétuelle transformation. Il est évident que tout système ne peut être considéré comme stable seulement de manière synchronique, comme photographie d'un état historique précis qui s'insère dans une diachronie dynamique : un système de classification donné va être valide pour une époque littéraire donnée. Clément Moisan [14] prolonge cette perspective, lorsqu'il rappelle que toute étude sur l'évolution de la littérature nécessite l'« établissement de modèles synchroniques susceptibles de fixer, par leur comparaison, l'histoire d'un genre et, par confrontation de ces modèles aux autres modèles d'autres genres, l'évolution des genres ».

Établir un système des genres et son évolution, par exemple celui des sous-genres du roman, demande donc de multiplier les études du système à des instants précis, qui mis bout à bout pourraient permettre un aperçu de l'évolution du genre. L'explication de cet état de fait réside dans la nature discontinue de la littérature où chaque nouvelle publication modifie nécessairement le genre et son système. La généricité, c'est-à-dire l'état textuel du genre, est donc un état dynamique par nature. Schaeffer la synthétise ainsi :

> tout texte modifie « son » genre : la composante générique n'est jamais [...] la simple reduplication du modèle générique. constitué par la classe de textes (supposés antérieurs) dans la lignée desquels il se situe. Au contraire, pour tout texte en gestation le modèle générique est un « matériel » parmi d'autres sur lequel il « travaille » [15].

Et plus loin :

> Il y a généricité dès que la confrontation d'un texte à son contexte littéraire (au sens vaste) fait surgir en filigrane cette sorte de trame qui lie ensemble une classe textuelle et par rapport à laquelle le texte en question s'écrit : soit qu'il disparaisse à son tour

Tzvetan TODOROV. Paris : Éditions du Seuil, 1986, p. 10.

14. Clément MOISAN. « Les genres comme catégorie de l'histoire littéraire ». *L'Histoire littéraire aujourd'hui*. Sous la dir. d'Henri BÉHAR et Roger FAYOLLE. Paris : Armand Colin, 1990.

15. SCHAEFFER, « Du texte au genre », p. 197.

> dans la trame, soit qu'il la distorde ou la démonte, mais toujours soit s'y intégrant, soit se l'intégrant [16].

Chaque nouveau texte est une instance du genre, qui ne va jamais totalement correspondre à la norme de manière satisfaisante. La généricité est donc dynamique car elle construit le genre de proche en proche en modifiant nécessairement les usages de la textualité du genre.

4 Approches textuelles des genres

Les approches des genres que nous abordons ont un point de vue centré sur le genre comme ensemble de textes possédant des similarités textuelles. Cette approche est ancrée dans les théories des formalistes Russes, et nous en développons les grandes lignes ci-après. Nous la cadrons d'une part avec l'approche naturaliste de Brunetière, un théoricien français très cité par les formalistes, et d'autre part avec les structuralistes, en tant qu'ils constituent les héritiers des formalistes.

4.1 Brunetière

La discipline de l'histoire littéraire s'est construite à la fin du XIXe siècle avec comme modèle analogique une discipline en pleine affirmation à l'époque : les sciences naturelles. La synthèse de Marine Riguet [17] est à cet égard fort instructive. Elle y montre que les premiers historiens de la littérature [18] « entreprennent à leur tour de classer, ordonner, hiérarchiser, dans le sillage de l'histoire naturelle » afin de légitimer leur discipline. Nous allons nous attarder sur Brunetière qui porte une vision de l'histoire littéraire en rupture avec ses contemporains et surtout un mode d'évolution de la littérature et son système des genres.

Brunetière déplore la vision de l'histoire de la littérature comme une « collection […] de monographies ou d'études, mises bout, et reliées d'ordinaire par un fil assez lâche » [19]. Brunetière cherche à fonder une doctrine littéraire qui serait capable de retrouver les liens qui unissent une œuvre avec l'ensemble de la littérature. En somme, il veut sortir des dictionnaires d'œuvres ou d'auteurs, et trouver un moyen de mettre chaque texte dans un réseau de relations. Brunetière pose le fait que les formes littéraires ne se succèdent pas de manière fortuite. Selon lui, le travail de l'histoire littéraire est donc de comprendre quels sont les mécanismes relationnels (chronologiques, généalogiques ou esthétiques) des formes entre elles. Pour cela, il propose sur le modèle de la « méthode évolutive » un modèle d'évolution des genres littéraires avec cinq lois fondamentales :

1. De l'existence des genres - Les genres comme catégories arbitraires de la critique.
2. De la différenciation des genres - Ce qui caractérise et individualise les genres entre eux.
3. De la fixation des genres - Les conditions de stabilité qui leur assurent une existence.
4. Des modificateurs des genres - Les potentiels instables du genre.

16. Ibid., p. 204.
17. Marine Riguet. « Pour une histoire naturelle de la littérature ». *La Littérature et la Vie*. Paris : Classiques Garnier, 2018, p. 33-49. DOI : 10.15122/isbn.978-2-406-06743-6.p.0033.
18. Marine Riguet cite Sainte-Beuve, Renan, Taine, Brunetière, Hennequin et Lanson
19. Ferdinand Brunetière. *L'évolution des genres dans l'histoire de la littérature*. Paris : Hachette, 1914.

5. De la transformation des genres - Principe de concurrence des genres avec la persistance du plus apte (sélection naturelle).

En utilisant un modèle évolutif fondé sur des lois semblables à celles de la sélection naturelle, il postule que les genres sont des entités avec des propriétés propres, qui se fixent, puis subissent des modifications avant de se transformer sous la pression de genres concurrents.

Toutefois, on peut citer longuement Jean-Marie Schaeffer qui pose une contradiction importante faite à Brunetière :

> La classification biologique suppose une relation d'inclusion globale, l'individu comme tel, dans sa constitution organique, appartenant à une classe spécifique. […] Mais la logique des messages verbaux que sont les œuvres littéraires n'est pas celle des espèces naturelles. Nous avons vu pourquoi : les êtres naturels se reproduisent biologiquement, s'engendrent l'un l'autre, l'unité de l'espèce étant garantie par l'identité du stock génétique qui est transmis lors de la reproduction ; par contre, jusqu'à preuve du contraire, les textes ne se reproduisent pas, ne s'engendrent pas directement les uns les autres. Autrement dit, comme Aristote l'avait déjà vu, alors que la constitution d'une classe biologique repose sur la continuité d'un processus d'engendrement, donc sur une causalité interne, la constitution d'une classe textuelle est fondamentalement un processus discontinu lié à une causalité externe [20].

L'approche de Brunetière est donc assez critiquable aujourd'hui, puisque la nécessaire concurrence entre les formes internes des genres est loin de la recherche actuelle, nous le verrons en section 5, qui analyse la transformation des formes littéraires de manière contextuelle, avec des facteurs culturels et historiques.

Ainsi, bien que critiquable dans sa métaphore biologique, Brunetière est un des premiers à dire que la littérature dans son ensemble peut être appréhendée selon un modèle cohérent qui permettrait de mieux comprendre les relations entre les espèces (les genres) et les individus singuliers (les textes). De cette manière, Brunetière se place comme précurseur des approches formalistes, qui adviendront quelques décennies plus tard en Russie. Brunetière pose aussi une intuition fondamentale que reprendra le concept de nexus : la littérature ne se comprend pas comme collection d'œuvres isolées, mais comme réseau de relations où chaque forme se définit par rapport aux autres.

4.2 Formalistes russes

La conception du genre comme sous-division du champ littéraire en classe d'œuvres similaires textuellement est en partie héritée des formalistes russes et de leur approche particulière de la littérature. Tynianov se place dans la filiation des approches naturalistes de l'évolution de la littérature à la Brunetière. Il propose sa doctrine en 1927 dans son article intitulé *De l'évolution littéraire* :

20. Schaeffer, *Qu'est-ce qu'un genre littéraire ?*, p. 78-79.

> La théorie des valeurs dans la science littéraire nous conduit à l'étude périlleuse des phénomènes principaux mais isolés et elle réduit l'histoire littéraire à « l'histoire des généraux » [21].

Tynianov suggère que la valeur d'un phénomène littéraire donné devrait être comprise en terme de son « importance et qualités évolutives ». Selon lui et plus largement les formalistes russes, l'identité d'un fait littéraire dépend de sa qualité différentielle, c'est-à-dire de la nouveauté formelle ou narrative d'un ouvrage par rapport aux autres œuvres d'un même espace synchronique. Tynianov lie ces prérogatives sur l'évolution littéraire au système des genres, qu'il faut analyser dans une perspective dynamique. Chaque genre peut être considéré comme une séries de textes littéraires qui sont en corrélation les uns avec les autres.

Ce passage de la série au genre se joue autour de ce que Tomachevski [22] et Jakobson [23] appellent *la dominante* : « l'élément focal d'une œuvre d'art [… qui] gouverne, détermine, et transforme les autres éléments ». Cette dernière regroupe les procédés et les traits de genre (formels, stylistiques, thématiques) qui organisent la composition de l'œuvre. Si un ensemble de textes rassemble plusieurs dominantes qui dénotent dans le système littéraire, alors cela autorise la formation d'un genre.

Ainsi, les séries se rassemblent autour de traits de genres de diverses sortes (rythme, syntaxe, style, sujet, sémantique) puis font face à leur usure dans le temps. Selon les formalistes, cette usure est toujours à mettre en relation avec les séries voisines, culturelles et sociales qui impacte le rythme de l'usure et de la transformation des genres.

4.3 Bakhtine et le dialogisme générique

La conception formaliste de la dominante et de l'évolution littéraire trouve son prolongement théorique le plus fécond dans l'œuvre de Mikhaïl Bakhtine, qui déplace la question du genre du terrain de la forme vers celui de l'énonciation. Pour Bakhtine, tout énoncé, y compris et surtout le texte littéraire, est fondamentalement *dialogique* : il n'existe jamais en isolation, mais toujours en relation avec d'autres énoncés, dans une chaîne communicationnelle ininterrompue. Cette conception trouve sa formulation la plus claire dans son essai sur les genres du discours, où il affirme que « Tout énoncé, en plus de son propre thème, répond toujours (au sens large du terme) sous une forme ou sous une autre, aux énoncés d'autrui qui le précèdent. » [24].

Appliquée à la littérature, cette perspective dialogique implique que tout texte répond implicitement ou explicitement à d'autres textes qui l'ont précédé, tout en anticipant les réponses futures et les lectures possibles. Cette conception historique du langage fait de chaque énonciation un acte intrinsèquement intertextuel, même lorsqu'aucune citation explicite n'est présente.

Le genre littéraire, dans cette perspective, devient un phénomène essentiellement dialogique.

21. Tynianov, « Théorie de la littérature », p. 122.
22. Boris Tomachevski. « Thématique ». *Théorie de la littérature : textes des formalistes russes.* Sous la dir. de Tzvetan Todorov. Paris : Éditions du Seuil, 2001 [1925].
23. Roman Jakobson. *Questions de poétique.* Paris : Éditions du Seuil, 1973.
24. Mikhaïl Bakhtine. « The Problem of Speech Genres ». *Speech Genres and Other Late Essays.* Sous la dir. de Caryl Emerson et Michael Holquist. Trad. par Vern W. McGee. Austin : University of Texas Press, 1986 [1952-1953], p. 60-102, p. 94.

Bakhtine distingue les *genres premiers*, formes simples de la communication immédiate, et les *genres seconds*, formes complexes de la communication culturelle élaborée, parmi lesquelles figurent notamment le roman, le théâtre ou les genres scientifiques [25]. Ces derniers se constituent en absorbant et en transformant des genres premiers insérés dans des ensembles discursifs plus complexes. Dès lors, le roman n'apparaît plus comme une forme autonome ou purement formelle, mais comme une configuration discursive traversée par des usages antérieurs du langage. Lorsqu'un auteur écrit un roman d'aventures, il ne mobilise donc pas seulement des conventions abstraites : il réélabore des formes, des scènes et des schémas narratifs déjà socialement et littérairement disponibles. Les conventions du genre, la structure de la quête, les scènes de danger ou le dépaysement exotique peuvent ainsi être compris comme des sédimentations de pratiques textuelles répétées.

Cette approche dialogique du genre préfigure ce que nous avons appelé, à la suite de Marine Riguet, le *nexus* littéraire, un réseau où aucun texte n'existe seul mais toujours comme nœud de reprises et de transformations. Cette dimension est particulièrement sensible dans les genres populaires de la fin du XIXe siècle, où la production sérielle et les contraintes éditoriales créent une densité intertextuelle exceptionnelle, chaque nouveau feuilleton reprenant des personnages-types, des situations narratives et des formules langagières qui circulent d'un texte à l'autre.

4.4 Structuralistes

Gérard Genette et les structuralistes reprennent le projet formaliste et font du texte un système de relations dont la signification est mouvante et multiple. Par exemple, Barthes [26] et Genette [27] ont beaucoup travaillé sur la structure narrative, les niveaux de récit, les fonctions du narrateur, etc. Ils tendent à se démarquer des formalistes puisqu'ils considèrent la littérature comme une production de sens au sein d'un système plus large (social, culturel, linguistique) plutôt que comme un artefact autonome.

Genette pense le genre littéraire comme une catégorie d'un mode d'approche de la littérature dans son ensemble qu'il appelle la *Transtextualité*. Il la définit comme l'« ensemble des façons dont un texte peut transcender sa "clôture", ou immanence, et entrer en relation avec d'autres textes » [28]. L'objet même de la poétique se voit modifié :

> L'objet de la poétique, […] n'est pas le texte, considéré dans sa singularité (ceci est plutôt l'affaire de la critique), mais l'architexte, […] c'est-à-dire l'ensemble des catégories générales, ou transcendantes – type de discours, modes d'énonciation, genres littéraires, etc – dont relève chaque texte singulier [29].

La transtextualité est un projet très ambitieux de Genette qui témoigne d'un profond changement de la place du texte dans la littérature, considérée dès lors comme un nœud dont la

25. Ibid., p. 61-62.
26. Roland Barthes. *S/Z*. Paris : Éditions du Seuil, 1996 [1970].
27. Gérard Genette. *Métalepse. De la figure à la fiction*. Paris : Le Seuil, 2004 ; Gérard Genette. *Figures IV*. Paris : Éditions du Seuil, 1999.
28. Idem, *Figures IV*, p. 20.
29. Idem, *Palimpsestes*, p. 7.

signification dépend d'un vaste réseau de relations inter et extra-textuelles. Genette définit cinq types de relations transtextuelles :

1. La *Paratextualité* - Titre, appareil critique ou présentation éditoriale. Voir *Seuils*[30] où Genette discute spécifiquement de cette dimension transtextuelle.
2. La *Métatextualité* - Réception critique et discours médiatique autour de l'ouvrage.
3. L'*Intertextualité* - Citation explicite, allusion ou plagiat.
4. L'*Hypertextualité* - Dérivation, transformation explicite. Voir le travail de Genette sur la parodie comme forme d'hypertextualité dans *Palimpsestes*[31]
5. L'*Architextualité* - La perception générique, qui oriente et détermine la réception de l'œuvre.

Ces dimensions transtextuelles sont autant de facteurs nécessaires à la constitution de l'interprétation. La dimension qui va nous intéresser le plus est celle de l'*Architextualité*, puisqu'elle est synonyme des relations qui existent au sein d'un genre littéraire. Le concept de Genette rejoint également notre conception du genre comme élément attracteur du nexus. Le genre n'est pas une catégorie transcendante, mais un ensemble de relations qui placent chaque texte dans un réseau de passages, de reprises et d'échos. La perception générique est donc toujours une perception relationnelle : identifier un genre, c'est activer un ensemble de connexions intertextuelles qui orientent la lecture.

Ainsi, on a pu voir une des deux approches principales des genres littéraires. Brunetière, les formalistes et dans une moindre mesure les structuralistes considèrent les genres comme des catégories permettant de regrouper des œuvres en fonction de caractéristiques textuelles communes. Les formalistes fondent cette dimension textuelle dans l'utilisation spécifique de procédés stylistiques, thématiques ou de constructions prototypiques du récit pour la création de genres littéraires.

Cependant, les structuralistes sortent d'une conception des genres immanente au texte, avec notamment l'identification du genre dans les seuils du récit (la relation au genre transparaît dans le paratexte, les titres, sous-titres). La seconde approche que l'on va voir ci-après est portée par les post-structuralistes et la recherche contemporaine.

5 Le genre au-delà du texte

L'approche textuelle des genres littéraires proposée par les formalistes russes a permis de fonder un cadre théorique sur la notion de genre. La recherche actuelle tend plutôt à prendre en compte des facteurs de constitution des classifications en genres, qui sont par définition externes aux textes et relatifs à l'intention humaine (système des théoriciens, mais également classification des bibliothécaires, ou encore ligne éditoriale dans une logique de marché). Un des écueils de cette constitution externe réside dans la *catégorisation rétrospective* des textes dans les genres. Le problème est énoncé par Viëtor : « Est-il possible d'écrire l'histoire des genres, quand aucune norme du genre ne peut être fixée au préalable ? »[32].

30. Gérard Genette. *Seuils*. Paris : Éditions du Seuil, 1987.
31. Idem, *Palimpsestes*.
32. Viëtor, « L'histoire des genres littéraires », p. 29.

Ce problème de conception anachronique des genres est également soulevé par Schaeffer :

> La première question concerne la problématique de la classification rétrospective [...] La confusion résulte du fait qu'en général ces deux aspects se trouvent télescopés. Or, le texte en tant qu'il surgit à un moment t n'appartient évidemment pas au genre tel qu'il est constitué rétrospectivement [...] Pour n'importe quel texte situé temporellement avant t^{+n}, le modèle générique est constitué uniquement par les textes antérieurs, ce qui signifie que le modèle générique textuel n'est jamais [...] identique au modèle générique rétrospectif[33].

En effet, cette approche des genres littéraires soulève le risque d'une projection anachronique, où un genre défini rétrospectivement ou de manière transcendante sur de longues périodes ne correspond pas toujours aux réalités littéraires et culturelles du contexte dans lequel les œuvres ont été produites, avec les intentions ou les perceptions des auteurs et des lecteurs de l'époque.

Afin de remédier aux problèmes structurels des systèmes de genres, une nouvelle vision des genres littéraires s'est développée. Cette dernière redonne de l'importance aux *dehors* du texte, en examinant notamment les contextes de production, de réception et de la lecture dans la construction des genres. Émilie Pézard et Valérie Stiénon proposent ainsi de rendre compte de la dimension pragmatique des genres littéraires :

> Les genres, en effet, n'existent pas en eux-mêmes : en tant que classes d'œuvres réunies par des similarités, ils résultent d'un geste interprétatif, nécessairement situé historiquement. Si les similarités s'observent à partir d'indices textuels objectifs, qui interdisent de voir à l'inverse dans le genre une construction gratuite ou arbitraire, ceux-ci sont perçus dans une lecture qui a une histoire[34].

Cette conception du genre est poursuivie par Letourneux, qui souligne que l'appartenance à un genre n'est pas uniquement textuelle, et qu'elle serait plutôt :

> le résultat d'une négociation sur le long terme entre différents acteurs. Chaque œuvre correspond à une instanciation (puisqu'elle est seconde) de cette réalité interdiscursive, et en offre une définition implicite (puisque sa situation dans un réseau de séries intertextuelles et architextuelles tend à produire une telle définition implicite)[35].

Ainsi, les genres littéraires ne sont pas des catégories fixes ou naturelles, mais plutôt des catégories construites à travers un processus d'interprétation. Autrement dit, la définition et l'identification des genres littéraires dépendent de la manière dont les lecteurs, critiques, auteurs, et éditeurs interprètent les œuvres littéraires au fil du temps. Ce processus herméneutique implique que les genres ne sont pas simplement des étiquettes descriptives, mais sont en constante reconfiguration selon les contextes historiques, culturels et sociaux. Cependant, Todorov montre que cette vision des genres fondée sur la réception doit être complétée par une dimension

33. Schaeffer, « Du texte au genre », p. 198.
34. Émilie Pézard et Valérie Stiénon. « Introduction ». *Les genres du roman au XIXe siècle*. Classiques Garnier, 2022. doi : 10.48611/ISBN.978-2-406-12980-6.P.0007, p. 11.
35. Matthieu Letourneux. « Le genre comme pratique historique ». *Belphégor* 2016. doi : 10.4000/belphegor.732, p. 6.

institutionnelle, qui confère aux genres leur réalité en tant que catégories sociales et critiques partagées :

> […] on peut toujours trouver une propriété commune à deux textes, et donc les réunir en une classe. A-t-on intérêt à appeler le résultat d'une telle réunion « genre » ? Je pense qu'on resterait en accord avec l'usage courant du mot et qu'en même temps on disposerait d'une notion commode et opérante si l'on convenait d'appeler genres les seules classes de textes qui ont été perçues comme telles au cours de l'histoire[36].

Todorov résout ainsi le problème de la classification rétrospective, et limite le système des genres à ceux qui ont eu une réalité critique et sociale synchronique. L'approche contemporaine des genres considère chaque texte dans sa dimension communicationnelle, et chaque genre dans un espace culturel donné. Cette démarche d'étude des genres est héritière des post-structuralistes avec notamment Jauss qui a beaucoup travaillé sur le rôle de la réception comme élément participant activement à la construction du texte. C'est le dernier point que l'on va aborder dans cette synthèse sur les genres, et il est aujourd'hui un des plus importants lorsque l'on traite des genres littéraires dans la recherche actuelle.

Jauss propose la notion d'« horizon d'attente » qui permet de rendre compte des conditions historiques auxquelles le genre est soumis. Selon Jauss, l'horizon d'attente

> se constitue par une tradition ou une série d'œuvres déjà connues et par l'état d'esprit spécifique suscité, avec l'apparition de l'œuvre nouvelle, par son genre et ses règles de jeu[37].

Cette notion est d'une importance capitale, puisque chaque lecteur participe à la définition du genre. Ainsi, tout texte peut être rapproché d'un genre si celui-ci s'inscrit dans le cadre d'un usage et d'une attente spécifique institués et partagés par une communauté de lecteurs et les instances de réception. Jauss identifie « l'expérience préalable que le public a du genre dont elle [l'œuvre] relève »[38] comme fondamentale pour constituer cet horizon d'attente. Cet horizon d'attente pré-conditionne donc l'établissement d'un genre. La notion de genre est ainsi considérée comme une norme de lecture, où la perception générique oriente et détermine l'horizon d'attente du lecteur, et donc la réception de l'œuvre. John Frow va dans ce sens en affirmant que « la structure générique permet et restreint à la fois le sens »[39]. Ce dernier souligne le rôle fondamental du genre dans le processus de production de signification. Le genre fonctionne comme un cadre structurant : il établit des règles et des conventions qui guident l'interprétation des textes, tout en limitant les possibles interprétations en fonction des attentes et normes associées à ce genre.

Comme Todorov le disait, « C'est parce que les genres existent comme une institution qu'ils fonctionnent comme des "horizons d'attente" pour les lecteurs, des "modèles d'écriture" pour les auteurs »[40]. En tant que conventions collectivement reconnues, les genres structurent la manière

36. Tzvetan Todorov. *Les Genres du discours*. Paris : Éditions du Seuil, 1978, p. 57.
37. Jauss, « Littérature médiévale et théorie des genres », p. 41-42.
38. Hans Robert Jauss. *Pour une esthétique de la réception*. Paris : Gallimard, 2005 [1978], p. 54.
39. John Frow. *Genre*. London ; New York : Routledge, 2006, p. 10.
40. Tzvetan Todorov. « L'origine des genres ». *La notion de littérature et autres essais*. Paris : Éditions du Seuil, 1987, p. 27-46, p. 34.

dont les lecteurs anticipent et interprètent les œuvres, fournissant des repères sur les attentes narratives, tout en agissant comme des cadres créatifs pour les auteurs, qui peuvent s'en inspirer ou les subvertir.

6 Le genre comme matrice prescriptive

Les développements théoriques que nous avons retracés, du système textuel formaliste à l'horizon d'attente réceptionnel, du dialogisme bakhtinien à l'architextualité genettienne, prennent une acuité particulière lorsqu'on les applique aux genres populaires de la fin du XIXe et du début du XXe siècle[41]. Dans ce contexte historique spécifique, le genre devient une véritable *matrice prescriptive* qui formate la production littéraire elle-même. C'est précisément dans cet espace que notre opérationnalisation computationnelle de l'intertextualité trouve sa pertinence maximale, car les genres populaires offrent un terrain où les dimensions du genre (à la fois internes et externes) sont pleinement observables.

6.1 Du modèle générique au formatage éditorial

Dans la perspective schaefferienne, le genre n'est pas une simple classe taxinomique, mais un « modèle générique »[42] qui agrège des régularités formelles, thématiques et pragmatiques : un schème opératoire de reconnaissance et de production qui règle l'activité des lecteurs et des auteurs. Cette conception prend une dimension nouvelle lorsqu'on considère les conditions matérielles de production des genres populaires. Le genre devient alors un opérateur prescriptif qui stabilise des attentes collectives et prescrit des formes, des motifs et même des découpages d'intrigue qui orientent concrètement la fabrique du récit.

Le roman-feuilleton de la presse quotidienne illustre cette logique médiatique et sérielle. Publié au *rez-de-chaussée*[43] du journal, découpé en tranches quotidiennes, il doit affronter un problème fondamental : comment maintenir l'attention du lecteur d'un jour à l'autre, alors que celui-ci ne possède pas encore la totalité du texte ? La réponse tient dans les seuils du récit et dans leur mise en scène. Letourneux[44] montre que le texte s'entoure de signaux génériques : titres typés (*Les Mystères de Paris*, *Les Mystères de Londres*, …), sous-titres explicites (« roman dramatique et d'aventures »), annonces publicitaires multipliant les promesses d'émotion (« poignant », « sensationnel »), et gravures stéréotypées fixant visuellement l'horizon d'attente.

La trajectoire éditoriale des *Mystères de Paris* en exemplifie la dynamique. Grâce au succès de la parution en feuilleton dans le *Journal des Débats* entre juin 1842 et octobre 1843, le roman de Sue inaugure une véritable « Mysterymania »[45]. Repris, traduit, adapté dans toute l'Europe,

41. Voir à ce propos l'introduction de l'ouvrage collectif sur le sujet (Pézard et Stiénon, op. cit.)
42. Schaeffer, *Qu'est-ce qu'un genre littéraire ?*, p. 76.
43. « Emplacement situé au bas de la première page d'un journal et occupant toute sa largeur. Cette chronique paraît au rez-de-chaussée. Par métonymie. Article figurant à cet emplacement. » https://www.dictionnaire-academie.fr/article/A9R2471
44. Matthieu Letourneux. « Le genre comme pratique historique et médiatique (1860-1940) ». *Les Genres du roman au xixe siècle*. Classiques Garnier, 2022. DOI : 10.48611/ISBN.978-2-406-12980-6.P.0339, p. 346.
45. Matthieu Letourneux. « Les "mystères urbains", expression d'une modernité énigmatique ». *Alla ricerca delle radici popolari della cultura europea, Looking for the Roots of European Popular Culture*. Bologne, Italy,

il donne naissance à un genre transnational, celui des mystères urbains, qui transforme la ville en miroir de la société moderne. Partout se reproduit la même structure : une métropole inquiétante, des bas-fonds criminels dont Kalifa [46] a retracé l'imaginaire tenace, des frontières brouillées entre misère et vice, compassion et terreur.

Dans les cultures sérielles de la fin du XIXe siècle, cette institutionnalisation passe par des dispositifs matériels concrets qui formatent littéralement la matière narrative. Comme l'a démontré Matthieu Letourneux dans ses travaux sur le genre comme pratique historique [47], les modalités de publication ne sont pas de simples supports neutres. Elles déterminent la structure même du récit : la cadence des épisodes impose des relances par *cliffhanger* en fin de livraison, la longueur prédéfinie des fascicules contraint l'économie narrative, la périodicité régulière favorise la typification des figures et la récurrence de situations obligées. Pour illustrer cela de manière plus concrète, nous citons Kalifa plus longuement :

> Les pratiques de ces romanciers procèdent très largement des contraintes du support (quotidien, collections à bon marché, fascicules, etc.) et de la nécessité financière qu'ils avaient de publier simultanément plusieurs textes. Industrielle, cette littérature l'est par le recours constant à la standardisation et à la division du travail. Les auteurs les plus célèbres ont des secrétaires, des ateliers, des « nègres ». […] À ces pratiques s'ajoutent celles de l'éditeur, auquel les romanciers abandonnent tout droit esthétique : les textes qui circulent sont amputés, remaniés, réécrits, adaptés, réadaptés, jusqu'à la disparition possible du nom de l'auteur. Seule prévaut à cet égard la logique commerciale. On perçoit évidemment combien ces usages rejaillissent sur le texte même, produit d'une littérature usinée : bourdes et stéréotypes, bavardage et dialogues sans fin (qui permettent de « tirer à la ligne »), schémas narratifs standard et rétrécis autour de quelques motifs obligatoires (générateurs d'émotions), univers du ressassement et de la répétition. Impulsée par les auteurs dramatiques du milieu du XIXe (Scribe) pour répondre à la demande croissante des théâtres, cette industrialisation de l'écriture atteint avec les journaux et l'édition à grand tirage du XXe une ampleur exceptionnelle. Si elle permet de démocratiser en profondeur les pratiques de l'écriture comme celle de la lecture, l'industrialisation de la littérature se double cependant de l'instauration de nouvelles hiérarchies, fondées sur la disqualification esthétique des textes publiés [48]

Le roman feuilleton est ainsi pris dans des contraintes matérielles, qui loin de n'être que des cadres extérieurs, produisent une manière de structurer un contenu en imposant un régime d'événements et de signes immédiatement lisibles.

À cela s'ajoute une hypersignalisation du genre dans les paratextes des feuilletons spécialisées, où les stratégies de vente cherchent à individualiser chaque œuvre en multipliant les « attelages génériques » [49] (« roman d'amour et d'aventures », « drame historique et judiciaire »). Le genre

2009 ; Marie-Ève Thérenty. « Mysterymania. Essor et limites de la globalisation culturelle au XIXe siècle ». *Romantisme* 2013, p. 53-64. DOI : 10.3917/rom.160.0053.

46. Dominique Kalifa. *Les bas-fonds histoire d'un imaginaire*. Paris : Éditions du Seuil, 2013.
47. Letourneux, « Le genre comme pratique historique et médiatique (1860-1940) ».
48. Kalifa, *La culture de masse en France. 1*, p. 96.
49. Letourneux, op. cit., p. 351.

accompagne l'œuvre mais ne l'englobe pas encore sous une catégorie éditoriale standardisée.

6.2 Du feuilleton à la collection de genre

La situation connaît un changement avec l'émergence des collections populaires bon marché au début du XIXe et surtout dans l'entre-deux-guerres. Comme le montre Letourneux, le basculement du journal vers les collections de livres transforme profondément la fonction de la généricité [50]. Le lecteur ne choisit plus une œuvre individualisée par ses promesses génériques multiples. Il choisit d'abord un *genre*, incarné dans une collection éditoriale standardisée, puis sélectionne au sein de cette collection une variante particulière. Le pacte de lecture se déplace de l'auteur vers l'éditeur, de l'œuvre vers la série.

Cette mutation s'accompagne d'une forte délimitation des périmètres génériques. Les collections de l'entre-deux-guerres (90% d'entre elles affichent explicitement leur appartenance générique par le titre, la couverture, ou un code couleur) [51] fonctionnent comme des « marques » au sens commercial : chaque titre exemplifie le genre-collection, et le lecteur évalue chaque roman comme une variante au sein d'un dispositif architextuel premier. Comme le souligne encore Letourneux, chaque genre se spécialise autour d'un public cible :

> Chaque roman est une variation autour d'un pacte de lecture éditorial à valeur générique qui s'explique par la standardisation de pratiques commerciales : les romans de même format coûtent le même prix, se vendent dans des réseaux spécifiques et s'adressent à des lecteurs types : enfants et adolescents pour les romans d'aventures géographiques (d'où l'absence d'intrigue amoureuse), femmes pour les drames d'amour, hommes pour les romans policiers [52].

Cette standardisation des périmètres génériques correspond donc à une standardisation plus large des pratiques commerciales. Le genre littéraire devient marqueur esthétique d'une logique de marque commerciale. Il ne s'agit plus, comme au XIXe siècle, de décrire par avance un texte unique, mais de garantir la conformité de chaque titre à une promesse éditoriale standardisée.

Ces constats menés par Letourneux sur les paratextes et les conditions matérielles de production des genres populaires amènent nécessairement à reconsidérer la dimension textuelle des œuvres elles-mêmes. Cette thèse vise donc à investiguer les conséquences textuelles de la formation de ces genres populaires, qui deviennent de véritables matrices prescriptives qui formatent la production narrative elle-même. Comme le proposait Todorov, « le chef-d'œuvre de la littérature de masse est précisément le livre qui s'inscrit le mieux dans son genre. » [53]. Les traits intertextuels ne sont pas de simples occurrences fortuites, mais des éléments constitutifs de leur architextualité générique. Nous reviendrons sur les effets textuels que peut avoir cette nouvelle donne dans le chapitre 9.

50. Ibid., p. 341.
51. Ibid., p. 342.
52. Ibid., p. 350.
53. Tzvetan Todorov. « Typologie du roman policier ». *Poétique de la prose*. Paris : Éditions du Seuil, 1980 [1966], p. 10.

7 Conclusion

Ainsi, les méthodes formalistes et plus tard structuralistes sont complétées par la notion d'horizon d'attente et l'importance de la réception dans la construction des catégories génériques. Cette approche cherche à réconcilier les perspectives historiques et textuelles, permettant d'appréhender les genres littéraires non seulement comme des structures fixes de manière synchronique, mais aussi comme des entités dynamiques influencées par leur contexte historique.

Les débats théoriques que nous avons retracés révèlent que le genre est un objet complexe. À la fois une configuration textuelle définie par des dominantes formelles, thématiques et stylistiques, une institution réceptionnelle fondée sur un horizon d'attente partagé et une reconnaissance collective, et une matrice éditoriale prescriptive qui formate la production dans la littérature de genre. Ces dimentions multiples posent un défi à l'opérationnalisation computationnelle : les méthodes quantitatives peuvent-elles identifier les régularités formelles et thématiques, et si oui, comment prendre en compte la dimension contextuelle des genres ?

La littérature de genre, et en particulier le roman policier et le roman d'aventures qui constituent notre corpus, offre ainsi un terrain où les dimensions du genre que nous avons retracées dans ce chapitre ne sont pas simplement superposées mais incorporées les unes dans les autres. Les contraintes éditoriales, les attentes du public et les impératifs de production se sont sédimentés dans les formes narratives elles-mêmes, dans les motifs récurrents et les structures d'intrigue.

Chapitre 3

Approches computationnelles des genres littéraires

Objectifs

Jusqu'à présent, nous avons rendu compte des différentes approches théoriques sur le statut ontologique des genres littéraires, et des tensions entre les définitions internes héritées des formalistes et les définitions contextuelles de la recherche contemporaine. Ce chapitre vise à cadrer et à problématiser les approches computationnelles des genres littéraires. Il présente d'abord l'héritage formaliste et l'émergence du formalisme quantitatif, puis expose la modélisation perspectiviste comme dispositif permettant d'articuler textes et contextes historiques. Il décrit et compare les méthodes centrales (classification supervisée, extraction de caractéristiques, *clustering*), en évaluant leurs apports et leurs limites épistémologiques (anachronisme, biais d'étiquetage, manque de métadonnées). À partir de ces constats, il propose une méthode opérationnelle fondée sur la notion de ressemblance de famille : granularité textuelle, réseaux intertextuels et dimension temporelle pour suivre la formation et la transformation des genres sur le long terme. L'objectif final est d'offrir un cadre théorique et méthodologique robuste qui concilie exploration empirique et rigueur critique pour l'étude dynamique des genres.

Sommaire

1 Le formalisme quantitatif **48**
2 La modélisation perspectiviste **49**
2.1 Principe 49
2.2 Contraintes pratiques et choix méthodologiques 50
3 Apports des approches quantitatives **51**
3.1 Classification 51
3.2 Extraction de caractéristiques distinctives 53
3.3 Clustering et approches non supervisées 54
3.4 Échelle d'analyse et granularité du genre 54
3.5 Synthèse 55
4 Limites : le retour du contexte **55**
4.1 La critique de l'anachronisme 55

4.2 L'approche « molle » des genres 56
4.3 Deux dimensions complémentaires 57
5 Risques d'un relativisme tautologique **57**
6 La ressemblance de famille **58**
6.1 Le modèle wittgensteinien 58
6.2 Application aux genres littéraires 59
6.3 Convergence méthodologique 60
7 Vers une cartographie computationnelle des genres **60**

> Toutes ces « disciplines », donc, et quelques autres qui restent à inventer et à casser à leur tour – le tout formant et réformant sans cesse la poétique, dont l'objet, posons-le fermement, n'est pas le texte, mais l'architexte –, peuvent servir, faute de mieux, à explorer cette transcendance architextuelle, ou architexturale. Ou plus modestement à y naviguer. Ou, plus modestement encore, à y flotter, quelque part au-delà du texte.
>
> GENETTE, *« Introduction à l'architexte », p. 159*

1 Le formalisme quantitatif

Les études littéraires computationnelles (ci-après ELC) se placent dans l'héritage des formalistes russes, premiers à entreprendre des approches quantitatives sur les textes littéraires. Tomachevski [1] applique la théorie des chaînes de Markov à l'étude de la prosodie. Boris Iarkho [2], quant à lui, analyse statistiquement la distribution de la parole dans les tragédies en cinq actes [3]. Comme le montre Lvoff [4], ce précédent historique n'est pas fortuit : formalisme russe et *distant reading* partagent une même ambition, comprendre la littérature à travers des structures et des régularités mesurables.

Les ELC actuelles, dont les travaux du Stanford Literary Lab ont largement contribué à la popularisation, se sont construites autour des notions de lecture distante et d'opérationnalisation : adapter des concepts de la théorie littéraire pour les rendre exploitables par des outils computationnels et interrogeables sur la longue durée. Les pamphlets 1 (« Quantitative Formalism : an Experiment » [5]), 6 (« "Operationalizing" : or, the function of measurement in modern literary theory » [6]) et 12 (« Literature, Measured » [7]) de Franco Moretti et le laboratoire littéraire de Stanford [8] conceptualisent le rôle de la mesure pour appréhender des objets culturels. Il n'est pas anodin que l'une des premières questions abordées concerne le genre littéraire. Le titre du pamphlet 1 [9] est explicite, l'ouverture l'est encore davantage :

> Formalisme, parce que nous sommes tous, d'une manière ou d'une autre, intéressés par les conventions formelles du genre ; et quantitatif, parce que nous cherchons des moyens plus précis – idéalement, mesurables – d'établir des différences génériques.

1. Boris TOMACHEVSKI. *O stikhe : stat'i.* Leningrad : Priboj, 1929, cité dans Tzvetan TODOROV. « L'héritage méthodologique du formalisme ». *Poétique de la prose.* Paris : Éditions du Seuil, 1971
2. Boris I. YARKHO. « Speech Distribution in Five-Act Tragedies (A Question of Classicism and Romanticism) ». *Journal of Literary Theory* 2019, p. 13-76. DOI : 10.1515/jlt-2019-0002.
3. Pour une synthèse des travaux de Boris Iarkho en tant que formalisme « appliqué », voir le panorama dans Mikhail GASPAROV. « Boris Yarkho's works on literary theory ». *Studia Metrica et Poetica* 2017, p. 130-150. DOI : 10.12697/smp.2016.3.2.05
4. Basil LVOFF. « Distant Reading in Russian Formalism and Russian Formalism in Distant Reading ». *Russian Literature* 2021, p. 29-65. DOI : 10.1016/j.ruslit.2021.07.003.
5. ALLISON, ALGEE-HEWITT et al., « Quantitative Formalism : an Experiment ».
6. MORETTI, « Operationalizing' : or, the function of measurement in modern literary theory ».
7. Idem, « Literature, Measured ».
8. https://litlab.stanford.edu/
9. ALLISON, ALGEE-HEWITT et al., « Quantitative Formalism : an Experiment ».

Les approches quantitatives adoptent de fait une position formaliste puisqu'elles permettent une interrogation systématique des textes entre eux. Dans le contexte des genres littéraires, chaque genre peut être considéré comme une série de textes en corrélation.

Cependant, ce retour formaliste pose un problème plus général, celui del' articulation de régularités textuelles mesurables (dimension interne) avec la reconnaissance de l'importance des contextes de production et de réception (dimension externe). Le formalisme quantitatif risque de réduire le genre à ses seules caractéristiques formelles, négligeant les processus socio-historiques de catégorisation. Cette tension a fait émerger des approches cherchant à recontextualiser les mesures textuelles.

2 La modélisation perspectiviste

Ted Underwood, figure influente des ELC, a proposé dès 2016 une approche théorique articulant explicitement dimensions textuelles et contextuelles du genre. Il la nomme *modélisation perspectiviste* :

> Mais la véritable valeur des méthodes quantitatives pourrait être qu'elles permettent aux chercheurs de coordonner des approches textuelles et sociales du genre. Cet essai [...] aborde le genre initialement comme une question sur l'histoire de la réception - en réunissant des listes de titres groupés par des lecteurs ou institutions particuliers à des moments historiques particuliers. Mais il regarde aussi au-delà de ces titres pour examiner les textes eux-mêmes. Les pratiques contemporaines de modélisation statistique nous permettent de mettre en dialogue différents groupes de textes entre eux. [...] Concernant le genre, cela signifie que notre objectif n'est plus de définir un genre, mais de trouver un modèle capable de reproduire les jugements faits par des observateurs historiques particuliers. [10]

2.1 Principe

L'apport conceptuel central d'Underwood réside dans le renversement du rapport entre définition et corpus. Plutôt que de partir d'une définition a priori du genre (« le roman policier est… ») pour ensuite sélectionner des textes, la modélisation perspectiviste part de listes historiquement situées, que ce soit des listes de chercheurs, des catalogues de bibliothèques, des collections éditoriales, qui incarnent une *perspective* particulière sur le genre. Le modèle statistique entraîné sur ces listes cherche ensuite quels traits textuels et stylistiques corrèlent avec cette catégorisation contextuelle.

Cette démarche permet une historicisation de la catégorie générique. En ancrant l'analyse sur des pratiques de classification documentées, on évite de projeter rétrospectivement des taxonomies contemporaines sur des corpus anciens, chaque liste reflétant son époque. Comme le souligne Underwood, l'objectif n'est plus de définir un genre de manière univoque, mais de modéliser la cohérence interne d'un corpus tel qu'il a été constitué historiquement. Les caractéristiques

10. Ted Underwood. « The Life Cycles of Genres ». *Journal of Cultural Analytics* 2016. DOI : 10.22148/16.005, p. 2.

identifiées par le modèle ne sont pas présentées comme l'essence du genre, mais comme des traces statistiques d'une pratique classificatoire située.

Si la modélisation perspectiviste ouvre une voie prometteuse, elle n'échappe pas à plusieurs tensions méthodologiques. La plus fondamentale concerne le statut des étiquettes de genre elles-mêmes. Underwood assume explicitement que ses modèles reproduisent des jugements institutionnels. Or ces jugements sont eux-mêmes le produit de processus historiques complexes, souvent opaques : quels critères ont présidé à l'inclusion d'un roman dans telle section d'une bibliothèque ? Comment les étiquettes ont-elles évolué au fil des recatalogages successifs ? Quels biais sociaux, ethniques ou genrés structurent ces corpus officiels ?

La modélisation perspectiviste ne résout pas ces questions, elle les déplace. Au lieu de définir le genre par des traits intrinsèques, elle le définit par une pratique institutionnelle de labellisation, dont les logiques restent en partie inexplorées. Comme le note Underwood, cette approche « nous dispense de définitions fixes » [11], sans pour autant rendre inutile une réflexion critique sur la validité, la représentativité et les biais éventuels des étiquettes mobilisées.

Un exemple concret : si l'on entraîne un modèle sur le corpus *detective fiction* de HathiTrust (1850-2000), ce corpus reflète-t-il la production effective de romans policiers de l'époque, ou seulement ceux que les bibliothèques américaines du XXe siècle ont rétrospectivement étiquetés comme tels ? La distinction est importante, puisque dans le second cas, le modèle ne capture pas la généricité telle qu'elle était perçue en 1900, mais telle qu'elle a été reconstruite par des institutions ultérieures.

2.2 Contraintes pratiques et choix méthodologiques

Au-delà de ces enjeux épistémologiques, la mise en œuvre de la modélisation perspectiviste se heurte à des contraintes pratiques, par exemple celle la disponibilité des métadonnées : les listes historiquement situées idéales sont rares et inégalement documentées. En pratique, les chercheurs s'appuient souvent sur des corpus contemporains rétrospectifs, dont la représentativité historique reste incertaine. Ensuite vient la granularité des labels : doit-on modéliser *le roman policier* comme catégorie unique, ou distinguer ses sous-genres (*detective novel*, *hard-boiled*, *thriller*) ? Le niveau de généralité adopté influence fortement les régularités statistiques détectées. Or ce niveau est souvent déterminé par les catégories disponibles dans les métadonnées, plutôt que par une réflexion théorique préalable. Enfin, se pose la question du choix des caractéristiques textuelles. Underwood le rappelle, « le choix n'est en réalité pas crucial » [12], dans un modèle prédictif, puisque celui-ci ne vise pas à identifier des relations causales. Cette flexibilité est un atout pour l'exploration, mais elle peut aussi conduire à une prolifération de caractéristiques hétérogènes dont la pertinence littéraire reste à évaluer.

Ces contraintes ne sont pas propres à l'approche d'Underwood, puisque toute analyse quantitative y est confrontée. Mais elles rappellent que la modélisation perspectiviste, malgré son ambition théorique, reste tributaire des corpus et de métadonnées imparfaites.

Underwood assume d'ailleurs explicitement le caractère exploratoire de sa démarche :

11. Idem, *Distant horizons*, p. 42.
12. Ibid., p. 20.

> Pour le dire plus précisément : les méthodes computationnelles rendent la théorie contemporaine des genres utile. Nous pouvons nous dispenser de définitions fixes et fonder l'étude des genres uniquement sur les pratiques changeantes des acteurs historiques particuliers – tout en produisant des modèles de genre suffisamment substantiels pour être comparés et contrastés. [13]

Ainsi, la méthode perspectiviste des genres fondée sur la modélisation prédictive ouvre la voie à une exploration approfondie des structures textuelles tout en mettant en lumière leurs relations avec les conventions sociales et historiques qui les façonnent. Cependant, ce type d'analyse exige une grande rigueur méthodologique et des définitions précises à chaque étape, qu'il s'agisse du choix des corpus, de l'attribution des étiquettes de genre ou de la conception et de l'interprétation des modèles statistiques employés.

3 Apports des approches quantitatives

Les méthodes computationnelles ont produit, au cours des trois dernières décennies, un ensemble de résultats empiriques sur les genres littéraires. Ces travaux mobilisent principalement trois types d'approches : la classification supervisée, l'extraction de traits distinctifs, et le *clustering* ou regroupement qui permet des travaux plus exploratoires sur les genres. Avant de détailler leurs apports respectifs, il convient de situer ces méthodes dans leur généalogie propre, distincte de la modélisation perspectiviste présentée précédemment.

3.1 Classification

3.1.1 Généalogie

La classification automatique de textes par genre est bien antérieure aux travaux d'Underwood. Dès les années 1980, des recherches en linguistique de corpus ont démontré qu'il était possible de discriminer des genres textuels à partir de traits linguistiques quantifiables.

Les travaux pionniers de Douglas Biber posent les fondements méthodologiques de cette approche en affirmant qu'« aucune dimension unique n'est en elle-même adéquate pour rendre compte de l'étendue de la variation linguistique dans une langue ; au contraire, une analyse multidimensionnelle est nécessaire » [14]. Il montre ensuite que différents genres se distinguent par des « ensembles de traits syntaxiques et lexicaux qui coapparaissent fréquemment dans les textes » [15]. Dans le champ du traitement automatique des langues, Kessler et al. [16] ont adapté ces intuitions à des modèles prédictifs, posant les bases de la détection automatique de genre en combinant traits linguistiques et apprentissage supervisé, et ouvrant ainsi la voie aux approches computationnelles à grande échelle.

13. Idem, « The Life Cycles of Genres », p. 6.
14. Douglas Biber. *Variation across Speech and Writing*. Cambridge : Cambridge University Press, 1988, p. 24.
15. Douglas Biber. « A Typology of English Texts ». *Linguistics* 1989, p. 3-43. DOI : 10.1515/ling.1989.27.1.3, p. 5.
16. Brett Kessler, Geoffrey Nunberg et Hinrich Schuetze. *Automatic Detection of Text Genre*. 1997. DOI : 10.48550/arXiv.cmp-lg/9707002.

3.1.2 Études sur la fiction

Les apports des études d'Underwood [17] résident dans l'articulation explicite entre classification textuelle et histoire de la réception. En entraînant ses modèles sur des corpus labellisés par des institutions historiquement situées, il ne cherche pas à définir le genre en soi, mais à reproduire les jugements de catégorisation portés par des acteurs historiques particuliers.

Cette approche permet d'étudier l'évolution diachronique des genres sur le temps long. Par exemple, Underwood [18] montre qu'un modèle entraîné sur le corpus *detective fiction* détecte des cohérences textuelles persistantes de 1850 à 2000, d'Edgar Allan Poe à Dennis Lehane [19]. Le résultat suggère que certains traits lexicaux du roman policier traversent plus d'un siècle de production, malgré les mutations éditoriales du genre au cours du temps. De façon plus générale, les résultats d'Underwood permettent d'interroger cette notion de changement littéraire, que les manuels d'histoire littéraire découpent sûrement un peu trop généreusement en grandes périodes exclusives.

3.1.3 Déclinaisons

Cette méthodologie, combinant classification supervisée et ancrage historique, a depuis été adaptée à d'autres aires linguistiques, avec des objectifs et des corpus variés :

— **Contexte hispanophone** : Calvo Tello [20] et Henny-Krahmer [21] ont appliqué des modèles de classification à des corpus de romans espagnols et hispano-américains (XIXe et XXe siècles), explorant notamment les hybridations génériques et les multi-assignations (romans appartenant simultanément à plusieurs sous-genres).

— **Contexte français** : Pierre-Carl Langlais [22] a mené des expérimentations sur le corpus numérisé de Gallica (BnF) afin de reconstituer les genres romanesques du XIXe siècle à partir de traits lexicaux et stylistiques. Ses travaux soulignent les difficultés spécifiques liées à la qualité variable de l'OCR et à la granularité des métadonnées disponibles.

— **Contexte germanique** : Hettinger et al. [23] ont souligné la nécessité de protocoles d'évaluation rigoureux pour la classification des sous-genres, en recourant à des validations croisées répétées, à l'équilibrage des classes par sous-échantillonnage et à un contrôle explicite du signal d'auteur.

— **Contexte anglo-saxon** : Van Cranenburgh et al. [24] proposent une analyse sur plus de 9

17. Underwood, « The Life Cycles of Genres » ; idem, *Distant horizons*.
18. Idem, « The Life Cycles of Genres ».
19. Romancier américain né en 1965, auteur de roman noir, connu notamment pour *Mystic River* (2001) et la série Kenzie-Gennaro.
20. José Calvo Tello. *The Novel in the Spanish Silver Age : A Digital Analysis of Genre Using Machine Learning*. Bielefeld University Press, 2021. DOI : 10.1515/9783839459256.
21. Ulrike Henny-Krahmer. *Genre Analysis and Corpus Design : Nineteenth-Century Spanish-American Novels (1830–1910)*. IDE, 2023.
22. Pierre-Carl Langlais. *Reconstituer les genres romanesque sur Gallica : essai de classification automatisée de 1500 romans (1815-1850)*. Billet. 2019.
23. Lena Hettinger, Fotis Jannidis et al. « Classification of Literary Subgenres ». *DHd 2016 : Modellierung – Vernetzung – Visualisierung*. Leipzig, 2016.
24. Andreas van Cranenburgh, Laura Allen et al. « Computational methods for the analysis of fiction genres ». *Multidisciplinary Views on Discourse Genre*. Routledge, 2024.

800 romans anglais combinant modélisation thématique et traits linguistiques de Biber. Leur étude montre que les sous-genres peuvent être prédits avec une efficacité encourageante d'environ 70%, que la structure thématique constitue un indicateur fort de la catégorisation générique, et que les oppositions stylistiques entre narration et argumentation permettent de caractériser finement les variations internes aux genres.

Il faut tout de même noter que ces travaux partagent avec Underwood l'usage de classifieurs supervisés, mais ne mobilisent pas nécessairement sa démarche perspectiviste au sens strict.

3.2 Extraction de caractéristiques distinctives

Au-delà de la classification globale des textes, une autre approche consiste à identifier les traits spécifiques qui caractérisent un genre. Les chercheurs veulent dans ce cas récupérer les mots ou les motifs narratifs qui sont sur-représentés dans un corpus générique spécifique.

Les mesures de distinctivité lexicale se sont révélées particulièrement efficaces pour cette tâche. Contrairement aux simples fréquences lexicales, qui peuvent être biaisées par quelques textes ou auteurs très productifs, elles tiennent compte de la régularité avec laquelle un mot apparaît à travers les textes ou segments d'un corpus. La mesure Zeta, proposée par John Burrows [25] puis développée pour l'analyse contrastive des corpus littéraires par Christof Schöch [26], calcule pour chaque mot la différence entre la proportion de segments où il apparaît dans le corpus cible et celle observée dans le corpus de comparaison : un score élevé signale donc un mot régulièrement présent dans le genre étudié et plus rare dans les autres corpus. La mesure Eta [27] repose sur un principe voisin, mais mobilise un autre indice de dispersion, la *déviation des proportions*. L'évaluation systématique de ces mesures [28] a montré leur robustesse pour identifier des vocabulaires caractéristiques stables, en particulier lorsque l'analyse repose sur un nombre limité de traits distinctifs.

En France, Legallois et al. [29] ont proposé une approche complémentaire fondée sur la détection de motifs (des séquences récurrentes de structures syntaxique) dans les romans sentimentaux. Leur méthode permet de repérer les « clichés » stylistiques propres au genre, offrant une formalisation des traits distinctifs à un niveau plus fin que le simple lexique.

Ces approches d'extraction de traits distinctifs fournissent des descriptions interprétables des spécificités génériques, contrairement aux classifieurs *boîte noire* qui prédisent efficacement mais sans toujours expliciter les traits discriminants. De plus, elles permettent de comparer les

25. J. Burrows. « All the Way Through : Testing for Authorship in Different Frequency Strata ». *Literary and Linguistic Computing* 2007. doi : 10.1093/llc/fqi067.

26. Christof Schöch. « Zeta für die kontrastive Analyse literarischer Texte. Theorie, Implementierung, Fallstudie ». *Quantitative Ansätze in den Literatur- und Geisteswissenschaften. Systematische und historische Perspektiven*. Sous la dir. de Toni Bernhart, Sandra Richter et al. De Gruyter, 2018, p. 77-94. doi : 10.1515/9783110523300-004.

27. Keli Du, Julia Dudar et al. « Zeta & Eta : An Exploration and Evaluation of Two Dispersion-based Measures of Distinctiveness ». *CEUR Workshop Proceedings*. 2021.

28. Idem, « Zeta & Eta : An Exploration and Evaluation of Two Dispersion-based Measures of Distinctiveness » ; Keli Du, Julia Dudar et Christof Schöch. « Evaluation of measures of distinctiveness : Classification of literary texts on the basis of distinctive words » 2022. doi : 10.48694/JCLS.102.

29. Dominique Legallois, Thierry Charnois et Thierry Poibeau. « Repérer les clichés dans les romans sentimentaux grâce à la méthode des "motifs" ». *Lidil. Revue de linguistique et de didactique des langues* 2016, p. 95-117. doi : 10.4000/lidil.3950.

signatures stylistiques de différents genres ou sous-genres, révélant des proximités que la critique ne soupçonnait pas nécessairement.

3.3 Clustering et approches non supervisées

Les méthodes de classification supervisée, qu'elles soient perspectivistes ou non, partagent le fait de dépendendre d'étiquettes préexistantes, héritées des pratiques de classification. Or ces étiquettes peuvent être incomplètes ou anachroniques. Afin de contourner cette dépendance, les approches non supervisées par regroupement (*clustering*) partent des textes eux-mêmes, sans étiquette préalable. En calculant des similarités intrinsèques aux textes, ces méthodes détectent des groupements qui partagent des traits communs, sans présupposer l'existence de genres prédéfinis.

Sobchuk et Šeļa [30] ont récemment comparé plusieurs algorithmes de *clustering* thématique appliqués à des corpus de fiction narrative, montrant que ces méthodes peuvent identifier des groupements cohérents (romans de guerre, romans domestiques, romans d'aventures) sans recourir à des labels externes. Leurs résultats suggèrent que certaines régularités génériques sont suffisamment fortes pour émerger spontanément de l'analyse statistique des textes.

Ces approches de *clustering* présentent également un intérêt pour l'étude des hybridations génériques, c'est-à-dire pour identifier les textes qui sont traversés par plusieurs genres. Contrairement aux classifications binaires, le *clustering* permet de repérer des textes intermédiaires, partageant des traits de plusieurs familles génériques. Calvo Tello [31] et Henny-Krahmer [32] ont exploité cette propriété pour analyser les multi-assignations dans les romans hispanophones, révélant des zones de porosité entre genres.

3.4 Échelle d'analyse et granularité du genre

Une question méthodologique transversale émerge de ces travaux : à quelle échelle textuelle le genre se manifeste-t-il ? Est-ce au niveau du roman entier, du chapitre, du paragraphe, voire de la page ?

Les approches traditionnelles de classification traitent généralement chaque texte comme une unité indivisible, où un roman est un seul vecteur de traits. Or cette hypothèse peut être problématique pour des œuvres longues et hétérogènes : un roman peut alterner passages descriptifs, dialogues, scènes d'action, réflexions intérieures, chacun relevant de régimes discursifs différents. De même, certains romans policiers comportent des passages sentimentaux, certains romans historiques des séquences d'aventure, etc.

Des recherches récentes ont commencé à explorer des approches à granularité variable, analysant les textes comme des assemblages, non plus comme des totalités homogènes. Calvo

30. Oleg Sobchuk et Artjoms Šeļa. « Computational thematics : comparing algorithms for clustering the genres of literary fiction ». *Humanities and Social Sciences Communications* 2024, p. 1-12. DOI : 10.1057/s41599-024-02933-6.

31. Calvo Tello, *The Novel in the Spanish Silver Age*.

32. Henny-Krahmer, *Genre Analysis and Corpus Design : Nineteenth-Century Spanish-American Novels (1830–1910)*.

Tello[33] et Henny-Krahmer[34] ont appliqué leur classification multi-étiquettes à des segments textuels, produisant des réseaux de textes où les liens reflètent les proximités génériques à différentes échelles.

3.5 Synthèse

L'ensemble de ces approches (classification, extraction de caractéristiques, *clustering*) converge vers un résultat empirique inattendu, qui n'avait pas nécessairement été anticipé par la critique littéraire traditionnelle : la persistance de certaines signatures génériques sur de très longues périodes.

Ces résultats tendent à valider, du moins partiellement, les approches formalistes et transcendantes des genres, postulant l'existence de structures relativement stables. Cependant, cette vision en longue durée et transhistorique du genre n'est pas exempte de critiques. Comme nous allons le voir, elle se heurte à des objections fondamentales concernant l'anachronisme, la négligence des dimensions sociales et médiatiques du genre, et les risques d'une réification essentialiste.

4 Limites : le retour du contexte

4.1 La critique de l'anachronisme

Les résultats empiriques présentés précédemment, notamment la capacité des modèles statistiques à identifier des cohérences génériques sur plus d'un siècle, soulèvent une question théorique : cette persistance textuelle valide-t-elle une conception transcendante des genres, ou masque-t-elle un biais méthodologique ?

Matthieu Letourneux formule à ce sujet une réserve sur les approches computationnelles. S'appuyant sur les travaux de l'historien Paul Veyne[35], il souligne que l'histoire des genres, lorsqu'elle est construite à partir de corpus contemporains, court le risque de refléter davantage les périodes de réception que celles de création.

> En réalité, cette approche ne permet pas de rendre compte de la dimension interdiscursive des genres, communicationnelle et médiatique, qui suppose de les saisir dans l'espace culturel historique[36].

L'argument pointé ici concerne le risque d'une *reconstruction rétrospective* : en identifiant des régularités textuelles à partir de catalogues contemporains (bibliothèques du XXe siècle, bases de données académiques actuelles), on projette potentiellement des catégories génériques qui n'existaient à l'époque de production des textes.

Toutefois, cette objection ne tient que partiellement face aux résultats empiriques. Comme le souligne Fotis Jannidis[37], dès qu'un nouveau genre émerge, ses textes sont immédiatement lus,

33. Calvo Tello, op. cit.
34. Henny-Krahmer, op. cit.
35. Paul Veyne. *Comment on écrit l'histoire*. Paris : Éditions du Seuil, 1989.
36. Matthieu Letourneux et Pierre-Carl Langlais. *Fictions Policières*. YouTube video. 2019.
37. Échanges de vive voix autour d'une version antérieure de ce chapitre lors d'un séjour de recherche dans son laboratoire

copiés, imités et transformés par les auteurs suivants. Les conventions génériques se diffusent donc dès la période de création, non pas seulement lors de reconstructions patrimoniales ultérieures. L'argument de Letourneux pourrait s'appliquer aux tout premiers textes d'un genre naissant (avant que les conventions ne soient stabilisées), mais ne peut expliquer la persistance de traits textuels sur plus d'un siècle.

Plus fondamentalement, les résultats d'Underwood constituent une réfutation empirique de la thèse relativiste forte. Si un modèle entraîné sur des romans policiers du XXe siècle peut identifier avec succès des romans de détective de la fin du XIXe siècle, alors cela démontre l'existence de régularités textuelles transhistoriques (vocabulaire de l'enquête, structures narratives de révélation progressive, types de personnages) qui ne peuvent être réduites à des reconstructions anachroniques. Les chapitres 5, 6 et 7 vont mettre à l'épreuve ces discussions dans le contexte du roman policier francophone.

4.2 L'approche « molle » des genres

Letourneux propose une perspective complémentaire, celle d'une approche « molle » des genres, attentive à leurs dimensions interdiscursives et médiatiques. Dans un article consacré à la définition de la science-fiction, il défend l'idée que le genre n'est rien d'autre que le résultat de « définitions fragmentaires sédimentées, et évoluant au fil des nouvelles actualisations » [38], et qu'il fonctionne comme un « système prototypique, avec des traits caractérisants plutôt centraux, d'autres plus périphériques » [39]. Selon cette perspective, les genres ne se réduisent pas à des structures textuelles stables, mais émergent de l'interaction entre différents acteurs du champ littéraire (auteurs, éditeurs, lecteurs, critiques) dans des situations spécifiques. C'est ce qu'il formulait déjà dans un article antérieur :

> les séries architextuelles gagnent à être pensées à partir de leurs situations socio-culturelles d'énonciation. Cela signifie que le genre se construit toujours à partir d'une œuvre ou d'un discours, et qu'il n'en existe pas d'unité qui transcenderait ses actualisations. Dès lors, chaque auteur, chaque œuvre propose une définition qui ne recoupe que partiellement les autres. De même en est-il pour chaque lecteur, dont les attentes sont déterminées par sa relation au genre, pour chaque commentateur, critique, journaliste, enfin pour chaque éditeur ou publicitaire. Tous offrent des interprétations du genre et, dans un même mouvement, renforcent les séries qui coïncident avec leur interprétation. [40]

Cette vision met en lumière un aspect important de la dynamique des genres : leur dépendance contextuelle. L'exemple du *roman de cape et d'épée* illustre cette variabilité : sa définition peut différer selon l'époque, le support de diffusion (feuilleton de presse, livre de poche), le milieu social (littérature pour enfants ou romans populaires pour adultes).

38. Matthieu Letourneux. « Le genre comme fait de discours : pour une définition molle de la science-fiction ». *ReS Futurae* 2022. DOI : 10.4000/resf.11405, p. 10.
39. Ibid., p. 9.
40. Idem, « Le genre comme pratique historique », p. 15.

Nous pensons que l'approche computationnelles, avec notamment les graphes de proximités textuelles (avec ses zones denses, ses marges et ses ponts entre communautés), produit le type de représentation que Letourneux décrit théoriquement : non pas des frontières catégorielles nettes séparant des territoires homogènes, mais des chevauchements entre familles génériques. Certains romans occupent le centre d'une communauté, cristallisant un faisceau de traits largement partagés, quand d'autres se situent aux marges, partageant quelques propriétés avec plusieurs familles sans appartenir pleinement à aucune.

4.3 Deux dimensions complémentaires

L'opposition apparente entre approches computationnelles et contextualistes repose en réalité sur une confusion entre deux questions distinctes. La première porte sur ce qui constitue le genre, c'est-à-dire sur le rôle respectif des traits internes au texte (structures narratives, lexique, conventions formelles) et des facteurs externes (pratiques institutionnelles, discours critiques, horizons d'attente). La seconde porte sur la permanence de ces traits, et notamment sur la mesure dans laquelle ils sont suffisamment stables pour être repérés à travers les époques et les contextes, ou au contraire dépendants d'un milieu, d'une période, d'une perspective particulière. Ces deux questions sont liées mais ne se confondent pas, et les confondre revient à opposer des approches qui opèrent en réalité à des niveaux complémentaires.

On peut parfaitement reconnaître que les genres comportent des régularités textuelles observables, ce que démontrent les modèles de classification, tout en admettant que ces régularités sont produites et maintenues par des pratiques situées. L'existence de continuités textuelles détectables par les ordinateurs n'implique donc pas une vision essentialiste du genre, mais simplement que certaines conventions narratives et stylistiques se transmettent avec une relative stabilité au fil des générations d'auteurs et de lecteurs.

Le véritable enjeu n'est donc pas de choisir entre texte et contexte, mais de comprendre comment les pratiques contextuelles façonnent les régularités textuelles observables, et inversement, comment ces régularités contraignent et structurent les pratiques de catégorisation.

5 Risques d'un relativisme tautologique

Si l'approche contextualiste de Letourneux éclaire utilement les dimensions sociales et médiatiques du genre, elle risque, poussée à l'extrême, de conduire à une impasse théorique. Comme l'a souligné John Rieder dans un article sur la définition de la science-fiction, les théories qui assimilent le genre uniquement aux pratiques historiques de catégorisation peuvent conduire à :

> une sorte de tautologie, une affirmation selon laquelle le genre est ce que les divers agents discursifs impliqués dans sa production, sa distribution et sa réception disent qu'il est [41].

Ce risque tautologique se manifeste lorsque l'on affirme que le genre n'existe que par les discours qui le nomment, sans reconnaître l'existence de régularités textuelles. Ce relativisme

41. John Rieder. « De l'avantage (ou non) de définir la science-fiction : théorie des genres, science-fiction et Histoire ». *ReS Futurae* 2013. DOI : 10.4000/resf.489, p. 2.

se heurte à plusieurs difficultés, notamment si le genre n'était qu'une construction discursive arbitraire, comment expliquer qu'un modèle statistique, entraîné sans aucune connaissance des contextes de production et de réception, puisse identifier avec succès des romans policiers sur le temps long ? Cette performance n'est possible que parce qu'il existe des régularités textuelles récurrentes qui transcendent (partiellement, nous le verrons par la suite) les variations contextuelles. De plus, les lecteurs reconnaissent intuitivement des familles de textes, des affinités génériques qui traversent les époques. Cette reconnaissance collective, qui fonde d'ailleurs les pratiques de classification institutionnelles, suppose l'existence de traits partagés suffisamment stables pour être identifiables malgré les transformations historiques.

6 La ressemblance de famille

6.1 Le modèle wittgensteinien

Le concept de *ressemblance de famille*, développé par Wittgenstein et publié dans ses *Investigations philosophiques*, offre un cadre conceptuel permettant d'articuler ces tensions.

Wittgenstein mobilise ce concept dans un contexte précis, celui de critiquer l'idée qu'un terme général (comme *jeu*) renvoie nécessairement à une essence unique partagée par tous ses référents. Il n'existe pas de trait unique, nécessaire et suffisant qui définirait tous les jeux. Wittgenstein écrit :

> Prenez[42], par exemple, les activités que nous appelons « jeux ». Je veux dire les jeux de société, les jeux de cartes, les jeux de balle, les jeux athlétiques, et ainsi de suite. Qu'ont-ils tous en commun ? – Ne dites pas : « Ils doivent avoir quelque chose en commun, sinon ils ne seraient pas appelés "jeux" » – mais regardez et voyez s'il y a quelque chose de commun à tous. Car si vous les regardez, vous ne verrez pas quelque chose qui soit commun à tous, mais des ressemblances, des affinités, et toute une série de celles-ci […]. Et le résultat de ces considérations est : nous voyons un réseau complexe de ressemblances qui se chevauchent et se croisent […]. Je ne peux penser à une meilleure expression pour caractériser ces ressemblances que celle de « ressemblance familiale » ; car les diverses ressemblances entre les membres d'une famille – la constitution, les traits, la couleur des yeux, la démarche, le tempérament, et ainsi de suite – se chevauchent et se croisent de la même manière. […] – Et je dirai : les « jeux » forment une famille[43].

Ce modèle rejette l'essentialisme logique : il n'existe pas de définition spécifique qui s'appliquerait à tous les jeux. Certains sont compétitifs, requièrent de l'adresse, d'autres du hasard, se jouent en équipe, ou en solitaire. Il maintient néanmoins une cohérence reconnaissable, car les jeux forment une famille identifiable, constituée par un réseau de similitudes partielles et

42. La traduction est tirée de l'édition française (Ludwig Wittgenstein. *Tractatus logico-philosophicus suivi de Investigations philosophiques*. Sous la dir. de Pierre Klossowski et Bertrand Russell. Paris : Gallimard, 1989 [1953])

43. Ludwig Wittgenstein. *Philosophical Investigations*. Trad. par G. E. M. Anscombe. Oxford : Basil Blackwell, 1958 [1953], §§ 66–67, pp. 32-33.

chevauchantes. Dans les années 1970, Rosch et Mervis[44] ont donné une assise empirique à cette intuition en montrant que la structure interne des catégories naturelles repose moins sur des définitions strictes que sur des ressemblances de famille au sens wittgensteinien, et qu'elle s'organise autour de membres plus prototypiques que d'autres.

6.2 Application aux genres littéraires

Dans la théorie des genres, le modèle semble pertinent, comme le discute Jauss dès 1970 :

> Il s'agit de saisir les genres littéraires non comme genera (classes) dans un sens logique, mais comme groupes ou familles historiques.[45]

Alastair Fowler précise l'intérêt de cette approche :

> Cette analogie se révèle extraordinairement suggestive. Elle promet de s'appliquer non seulement aux liens étroits à l'intérieur des sous-genres [...], mais aussi aux ressemblances lointaines entre des œuvres très divergentes [...]. Les genres paraissent bien plus semblables à des familles qu'à des classes[46].

Le modèle de la ressemblance de famille permet de concevoir les genres comme des réseaux de relations graduelles qui peuvent se chevaucher entre des œuvres. Un roman peut être « typiquement » policier lorsqu'il réunit une enquête, un détective, des indices et une révélation finale, « partiellement » policier lorsqu'il construit une intrigue de mystère sans détective professionnel, ou « marginalement » policier lorsque quelques éléments d'énigme affleurent dans un récit principalement sentimental.

Cette conception présente plusieurs avantages méthodologiques. Elle est d'abord compatible avec l'évolution historique des genres, puisque les traits pertinents pour identifier un genre peuvent varier au fil du temps sans rompre sa continuité. Le roman policier de Leroux des années 1910, avec son énigme aristocratique et son détective amateur, et celui de Manchette des années 1970, porté par une enquête urbaine et une critique sociale, partagent des ressemblances partielles suffisantes pour appartenir à la même famille, sans être identiques. La ressemblance de famille est ensuite ouverte à l'hybridation, dans la mesure où un texte peut appartenir simultanément à plusieurs familles génériques. Un roman policier-sentimental ou un thriller psychologique relèvent de deux catégories à la fois, ce qui est difficile à modéliser dans une logique de classes exclusives. Elle justifie enfin l'approche quantitative que nous adoptons dans cette thèse, car la puissance computationnelle permet de comparer un ensemble potentiellement très large de caractéristiques textuelles sans postuler a priori lesquelles sont essentielles. Nous le verrons dans les chapitres 5 et 6, les modèles statistiques peuvent cartographier des ressemblances partielles entre des milliers de textes, révélant des proximités graduelles plutôt que des frontières catégorielles nettes.

44. Eleanor Rosch et Carolyn B Mervis. « Family resemblances : Studies in the internal structure of categories ». *Cognitive Psychology* 1975, p. 573-605. DOI : 10.1016/0010-0285(75)90024-9.

45. Jauss, « Littérature médiévale et théorie des genres », p. 42-43.

46. Alastair Fowler. *Kinds of Literature - An Introduction to the Theory of Genres and Modes*. Oxford : Oxford University Press, 2002 [1982], p. 41.

6.3 Convergence méthodologique

Les approches contextualiste et computationnelle mobilisent toutes deux le concept de ressemblance de famille. Letourneux s'appuie sur Wittgenstein pour souligner la variabilité contextuelle des définitions génériques :

> On voit qu'une telle perspective s'inscrit dans cette logique de « ressemblance de famille » […]. Ainsi, Wittgenstein souligne qu'il n'y a pas nécessairement de traits unitaires généraux liant les différents objets rassemblés dans une catégorie transcendante, mais plutôt un ensemble de liens conceptuels dont la pertinence n'est toujours que partielle et variable. [47]

Underwood mobilise le même concept pour justifier sa méthodologie de modélisation prédictive, qui détecte empiriquement des réseaux de similitudes sans imposer de structure causale a priori :

> Les théoriciens des genres soupçonnent de plus en plus que les genres sont des « ressemblances de famille » […] Un problème de ce type nécessite une méthodologie prudente vis-à-vis des hypothèses ontologiques et attentive aux détails. La modélisation prédictive s'avère adaptée à cette tâche. Leo Breiman [48] a souligné que les modèles prédictifs s'écartent des méthodes statistiques familières […] en mettant entre parenthèses la recherche de l'identification des facteurs sous-jacents qui causent et expliquent réellement le phénomène étudié. [49]

Cette convergence conceptuelle suggère que l'opposition entre approches computationnelles et contextualistes est moins radicale qu'il n'y paraît. Les deux reconnaissent l'absence de traits nécessaires et suffisants définissant universellement un genre, l'existence de réseaux de ressemblances graduelles entre les textes, la nécessité d'une méthodologie qui n'impose pas de structure essentialiste a priori.

La différence réside dans l'accent mis sur certaines dimensions : Letourneux insiste sur la contingence historique des actualisations génériques, Underwood sur la persistance empirique de certaines régularités textuelles. Ces deux dimensions ne sont pas forcément contradictoires.

7 Vers une cartographie computationnelle des genres

La ressemblance de famille suggère que les genres littéraires peuvent être modélisés comme des réseaux dynamiques de similarités textuelles, où chaque œuvre occupe une position particulière dans l'espace des ressemblances, plus ou moins proche du centre du genre, plus ou moins hybride. Cette approche s'inscrit pleinement dans la *textualité* que nous avons défini au chapitre précédent, et l'on voit bien que les connexions entre œuvres varient en intensité, certaines partageant des similitudes fortes, d'autres ne se rejoignant que par quelques traits périphériques. Surtout, le réseau évolue au fil du temps, et chaque nouvelle publication ajoutant des nœuds et des liens qui modifient la structure globale du genre.

47. Letourneux, op. cit., p. 15.
48. Leo Breiman. « Statistical Modeling : The Two Cultures ». *Statistical Science* 2001, p. 199-215.
49. Underwood, « The Life Cycles of Genres », p. 5.

L'opérationnalisation de ce cadre suppose d'articuler les deux dimensions du genre identifiées au fil de ce chapitre. Sur le plan textuel, il s'agit de représenter chaque œuvre non pas comme une unité monolithique mais comme un ensemble hétérogène de passages, chacun pouvant activer différents registres stylistiques ou motifs thématiques, la généricité émergeant de la récurrence et de l'agencement de ces signaux à l'échelle du récit. Sur le plan contextuel, il s'agit d'ancrer l'analyse sur des corpus historiquement situés, constitués à partir de sources documentées, et d'interpréter les régularités détectées non comme des essences du genre mais comme des traces corrélées à des pratiques de catégorisation historiques. Le chapitre suivant décrit les procédés expérimentaux que nous mettons en œuvre pour réaliser cette cartographie.

Chapitre 4

Procédés expérimentaux

Objectifs

Le chapitre 4 présente les choix méthodologiques et les protocoles expérimentaux qui sous-tendent l'ensemble des analyses quantitatives de cette thèse. Il détaille les corpus mobilisés, les procédures de représentation vectorielle, les modèles d'apprentissage automatique, les méthodes d'extraction d'information narrative et les dispositifs de modélisation en réseau qui constituent l'architecture expérimentale de ce travail. L'objectif est de rendre explicites les choix méthodologiques qui structurent l'ensemble des analyses empiriques de la thèse, et de montrer comment ces choix engagent une certaine conception de la littérature, de ses objets et de ses modes d'approche.

Sommaire

1 Introduction . . . **64**
2 Corpus . . . **65**
2.1 Le corpus *Chapitres* : corpus de référence . . . 65
2.2 Le corpus *Fictions littéraires de Gallica* : corpus de projection . . . 67
3 Extraction des personnages dans la fiction . . . **69**
3.1 Présentation de la chaîne de traitement Propp-fr . . . 69
3.2 Identification et regroupement des personnages . . . 71
3.3 Des attributs aux représentations vectorielles . . . 72
4 Apprentissage automatique : principes et classifieurs . . . **73**
4.1 Principes généraux . . . 73
4.2 Machines à vecteurs de support (SVM) . . . 75
4.3 Grands modèles de langue et classification : apports et limites . . . 76
4.4 Stratégies de validation croisée : contrôler les effets de structure . . . 78
5 Opérationnaliser l'intertextualité . . . **79**
5.1 Du texte au vecteur . . . 79
5.2 Choix du modèle et procédure d'affinage . . . 82
5.3 Validation des représentations vectorielles . . . 84
5.4 Analyses d'ablation . . . 86
5.5 Ce que capturent les embeddings . . . 88
5.6 Validation empirique . . . 89
6 Réseaux de similarité . . . **92**
6.1 Construction des graphes d'intertextualité . . . 92

6.2 Agrégation des similarités : du passage au roman 92
6.3 Détection de communautés 94
6.4 Interprétation des structures communautaires 96
6.5 Contrôle qualitatif 96
6.6 Limites méthodologiques 97
7 Usage encadré des modèles de langue génératifs **97**
8 Conclusion **98**

> When you can measure what you are speaking about, and express it in numbers, you know something about it ; but when you cannot measure it, when you cannot express it in numbers, your knowledge is of a meagre and unsatisfactory kind : it may be the beginning of knowledge, but you have scarcely, in your thoughts, advanced to the stage of science, whatever the matter may be.
>
> *Lord Kelvin. « Electrical Units of Measurement ».* Popular Lectures and Addresses. *London : Macmillan, 1889, p. 73-136, p. 73*
>
> Lorsque vous pouvez mesurer ce dont vous parlez et l'exprimer en nombres, vous en savez quelque chose ; mais lorsque vous ne pouvez pas le mesurer, lorsque vous ne pouvez pas l'exprimer en nombres, votre connaissance est pauvre et insatisfaisante : ce n'est peut-être que le début du savoir, mais, dans vos pensées, vous avez à peine atteint le stade de la science, quel que soit le sujet.
>
> *ibid., p. 73*

1 Introduction

Ce chapitre rassemble et explicite les protocoles expérimentaux qui sous-tendent l'ensemble des analyses quantitatives de cette thèse. Chaque choix d'encodage, de représentation ou de modélisation implique une prise de position sur ce que l'on considère comme pertinent dans les textes et sur le type d'arguments que l'on juge recevables dans une histoire littéraire fondée sur des traces computationnelles. Les modèles quantitatifs sont ici conçus comme des instruments de mesure et de mise en relation, dont la raison d'être est de produire de nouveaux observables fondés sur des régularités formelles et de tester la robustesse d'hypothèses interprétatives à travers de grands corpus.

Ces méthodes rendent visibles des signaux faibles, des chevauchements ou des cas atypiques à grande échelle, et elles mettent à l'épreuve les frontières des concepts littéraires. C'est par l'étude des marges que nous cherchons à produire de la connaissance, en articulant mesures quantitatives et interprétation critique.

L'architecture des protocoles retenus suit une logique en plusieurs étapes. La première est celui des corpus et de leur mise en forme (section 2). La deuxième mobilise l'extraction d'information structurée au moyen d'un logiciel développé au Lattice, Propp-fr [1], qui fournit une représentation des personnages du roman (section 3). La troisième est celui de l'apprentissage automatique, où les modèles supervisés servent de capteurs de régularités plutôt que de moteurs d'explication (section 4). La quatrième concerne l'opérationnalisation de l'intertextualité au moyen de représentations vectorielles, grâce à un modèle d'encodage adapté au français littéraire (section 5). La dernière construit des réseaux de similarité où les romans deviennent des nœuds reliés par leur proximité vectorielle (section 6).

1. https://lattice-8094.github.io/propp/

2 Corpus

2.1 Le corpus *Chapitres* : corpus de référence

Le premier socle empirique de cette thèse est le corpus constitué par le projet de l'ANR *Chapitres*[2], l'un des corpus de fiction en français les plus importants et avec la plus grande qualité d'OCR actuellement disponibles[3]. Il rassemble 2 960 romans français, majoritairement des XIXe et XXe siècles, pour un total d'environ 15 millions de phrases et 234 millions de tokens. Les textes sont encodés en XML selon les recommandations de la TEI[4], ce qui permet d'articuler le texte lui-même à un ensemble de métadonnées homogènes (auteur, date de publication, collection, édition, dates des auteurs, genre littéraires) et à une structuration explicite en chapitres.

Le processus de constitution du corpus par l'équipe de l'ANR *Chapitres* a reposé sur la réutilisation de textes numérisés et mis en ligne par différentes institutions. Ce choix a introduit un biais structurel : le corpus *Chapitres* ne représente pas la totalité de la production romanesque, mais la partie qui a été sélectionnée, éditée, puis conservée et numérisée. Cette sélection tend à sur-représenter des œuvres dotées d'une certaine visibilité éditoriale ou patrimoniale. Néanmoins, le corpus ne se réduit pas à un simple canon : les œuvres non canoniques y sont largement majoritaires, ce qui en fait un observatoire intéressant de la zone intermédiaire entre canon et archives[5].

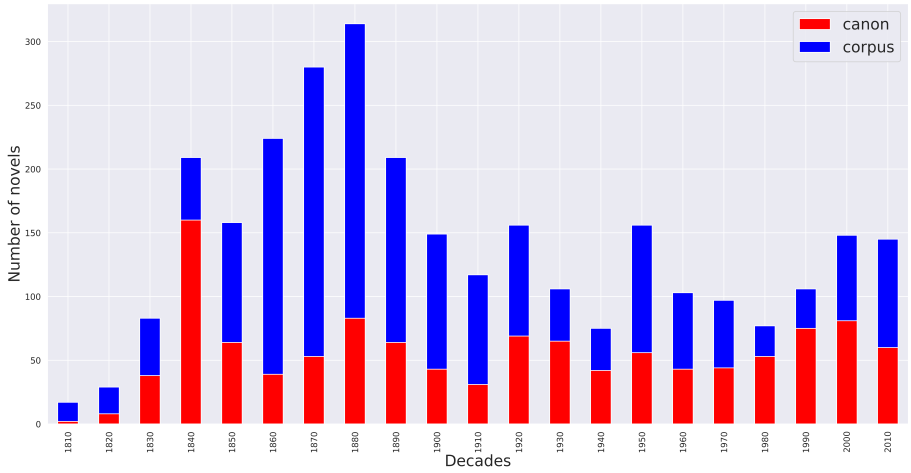


FIGURE 4.1 : Distribution du nombre de romans du corpus *Chapitres* dans le temps, avec des indicateurs de canonicité (échelle de l'auteur) en rouge.

La distribution temporelle des romans couvre deux siècles de production, de la première moitié du XIXe siècle au début du XXIe siècle (figure 4.1). Elle présente une concentration notable dans la seconde moitié du XIXe siècle, et en particulier dans les années 1880, qui comptent à

2. https://chapitres.hypotheses.org/
3. LEBLOND, *Corpus Chapitres*.
4. TEI Consortium, eds. TEI P5 : Guidelines for Electronic Text Encoding and Interchange. http://www.tei-c.org/Guidelines/P5/.
5. Les concepteurs du corpus ont défini la notion de canonicité au niveau des auteurs, en prenant en compte le nombre de réponses obtenues de requêtes sur la revue de recherche en ligne *fabula* : https://www.fabula.org/. Nous avons raffiné cette information dans un article sur le sujet dans BARRÉ, CAMPS et POIBEAU, « Operationalizing Canonicity »

elles seules près de 10 % des titres. Cela rend compte d'une production romanesque qui explose à cette période, mais la baisse qui suit ne correspond pas à une baisse de la production, mais plutôt au fait que le copyright rend plus difficile la constitution de corpus dès le début du XXe siècle. Ainsi, cette asymétrie doit être prise en compte dans l'interprétation des résultats, dans la mesure où elle peut amplifier le poids statistique de cette période.

Un des intérêts majeurs du corpus *Chapitres* pour cette thèse est la richesse de ses métadonnées. D'une part, le corpus est assorti d'indicateurs de canonicité de l'auteur, élaborés à partir de travaux antérieurs sur la réception contemporaine de la littérature française. Ces indicateurs permettent de situer chaque roman dans un continuum allant de l'archive peu visible aux œuvres fortement consacrées. La distribution des romans canoniques à l'échelle de l'auteur apparaît relativement constante sur l'ensemble du corpus, minimisant le risque de biais temporel. On compte environ 50 romans canoniques par décennie, à l'exception des années 1840 où l'on observe un pic notable de plus de 150 romans canoniques, anomalie attribuable en partie à Balzac, dont les 85 romans présents dans le corpus sont majoritairement issus d'éditions de cette décennie (ce qui constitue un problème, dans la mesure où une part importante de sa production commence dès 1829).

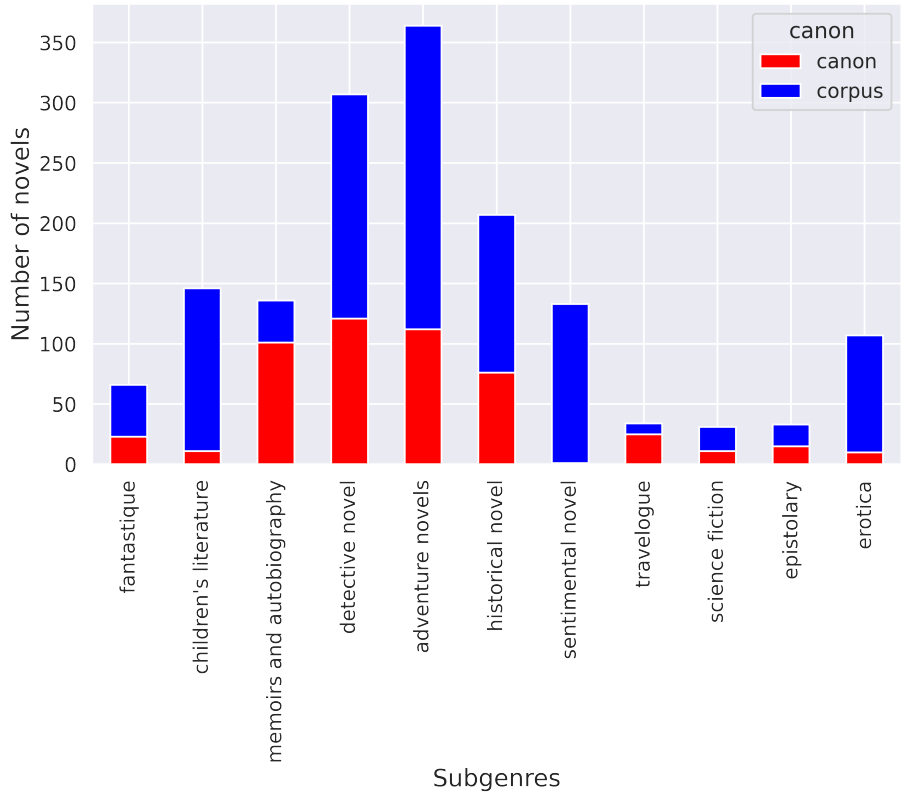


FIGURE 4.2 : Sous-genres littéraires dans le corpus *Chapitres*, avec des indicateurs de canonicité (échelle de l'auteur) en rouge.

D'autre part, environ deux tiers des textes disposent d'étiquettes de sous-genre, largement dérivées des pratiques de catalogage de la Bibliothèque nationale de France. Ces classements doivent toutefois être abordés avec prudence. Ils ne constituent ni un système générique homogène

ni des catégories toujours endogènes à l'histoire littéraire des œuvres. Certaines étiquettes correspondent à des désignations génériques historiquement attestées, d'autres relèvent davantage de regroupements documentaires ou rétrospectifs. Elles ne sont donc pas mobilisées ici comme des vérités de terrain, mais comme des hypothèses de travail servant de point de départ à des modèles supervisés dont l'un des objectifs est précisément d'en tester la robustesse textuelle. La figure 4.2 montre la distribution du canon à travers ces catégories. On n'y observe pas de surreprésentation du canon dans un sous-genre particulier, mais une absence partielle ou complète d'œuvres canoniques dans les sous-genres du roman sentimental et de la littérature de jeunesse, observation qui semble confirmer l'idée que ces deux sous-genres ne bénéficient pas de la reconnaissance littéraire associée, par exemple, au roman d'aventures.

Dans le cadre de cette thèse, le corpus *Chapitres* joue le rôle de corpus de référence (dit corpus *gold*). C'est sur lui que sont calibrées et évaluées la plupart des procédures, avec par exemple l'entraînement de modèles supervisés pour détecter le roman policier, ou encore les modèles d'embeddings que nous allons décrire en section 5. Les modèles ainsi appris seront ensuite projetés sur un corpus plus vaste et moins contrôlé, décrit dans la section suivante.

2.2 Le corpus *Fictions littéraires de Gallica* : corpus de projection

Le second corpus mobilisé dans cette thèse est la collection *Fictions littéraires de Gallica*[6], qui regroupe 19 240 textes de fiction issus de la bibliothèque numérique de la BnF. Ce corpus a été constitué à partir des notices catalographiques de Gallica : il rassemble des œuvres initialement cataloguées comme fictions en prose, publiées entre 1600 et 1950. Langlais[7] décrit ce corpus comme représentant près de 40% de tout ce qui a été publié en France au XIXe siècle.

Sa constitution repose sur le dispositif du dépôt légal français, qui oblige les éditeurs à déposer à la BnF un exemplaire de chaque ouvrage publié. Le corpus offre donc un échantillon massif et relativement représentatif de la production de fiction, incluant les nombreuses œuvres de la littérature *hors d'usage* de la littérature de genre.

La distribution temporelle des œuvres confirme la montée en puissance de la production romanesque au XIXe siècle, avec un pic très marqué dans les années 1890 (près de 3 000 titres pour cette seule décennie), comme l'illustre la figure 4.3. À l'autre extrémité de la période, l'approche de 1950 s'accompagne d'une chute brutale du nombre de textes disponibles : la plupart des œuvres publiées après cette date restent soumises au droit d'auteur et ne peuvent donc être intégrées au corpus en plein texte. En France, les textes entrent dans le domaine public 70 ans après la mort de leurs auteurs. Cette contrainte juridique limite la couverture de la littérature la plus récente, mais n'affecte pas l'objectif principal de cette thèse, centré sur le XIXe siècle et la première moitié du XXe siècle.

Le corpus brut présente plusieurs difficultés techniques qui doivent être prises en compte avant toute analyse computationnelle : qualité inégale de l'OCR[8], présence d'œuvres complètes,

6. Langlais, *Fictions littéraires de Gallica*.
7. Idem, *Reconstituer les genres romanesque sur Gallica*.
8. L'OCR (*Optical Character Recognition*) désigne les techniques de reconnaissance optique de caractères permettant de convertir des images de textes imprimés en fichiers texte exploitables. Les corpus issus de numérisations patrimoniales (Gallica, Google Books) présentent fréquemment des erreurs résiduelles : confusions de caractères

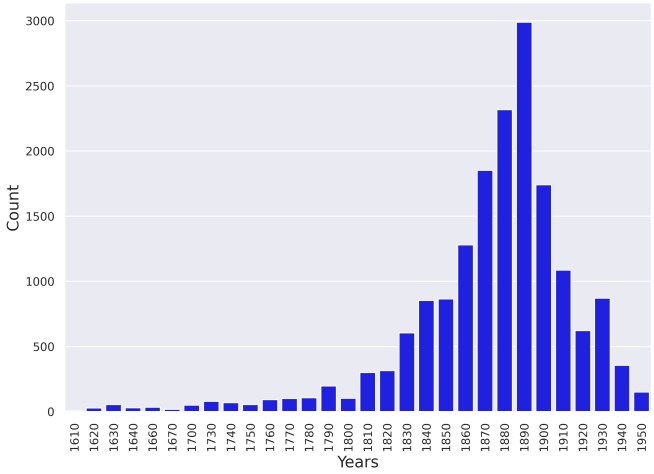


FIGURE 4.3 : Nombre de romans par décennie dans le corpus *Fictions littéraires de Gallica*.

multiplications d'éditions d'un même texte, hétérogénéité des pratiques orthographiques. Afin d'y remédier, plusieurs étapes de filtrage ont été mises en œuvre : exclusion systématique des éditions d'œuvres complètes, sélection de la première édition lorsqu'un roman est présent sous plusieurs formes (par exemple les 6 éditions des Travailleurs de la mer de Victor Hugo, de 1866 à 1894), et estimation de la qualité de l'OCR par comparaison avec un lexique de référence dérivé du corpus *Chapitres*.

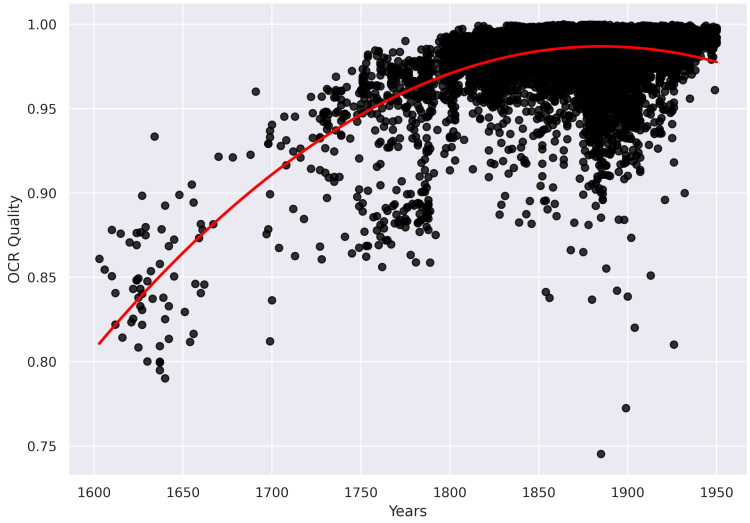


FIGURE 4.4 : Qualité de l'OCR dans le temps : proportion de mots corrects par œuvre.

Cette dernière étape permet de calculer, pour chaque texte, une approximation du taux d'erreur OCR et d'écarter les documents les plus bruités. Comme le montre la figure 4.4, les textes antérieurs au début du XIXe siècle obtiennent des scores plus faibles, ce qui s'explique notamment par des graphies moins stabilisées et par des caractéristiques matérielles qui rendent

($rn \rightarrow m$, $cl \rightarrow d$), segmentations erronées, ou caractères parasites.

la reconnaissance automatique plus difficile. La baisse observée en fin de période s'explique, quant à elle, par le déclin de la qualité du papier utilisé pour certaines œuvres, qui affecte négativement le processus d'OCR. Après filtrage, on obtient un sous-ensemble de 12 ,176 romans, qui constitue la base de travail utilisée dans cette thèse.

Les métadonnées littéraires disponibles pour le corpus *Fictions littéraires de Gallica* sont relativement pauvres : les notices fournissent des informations sur l'auteur, la date et parfois le genre ou la collection, mais sans système homogène d'étiquettes génériques ni indicateurs de réception. La stratégie adoptée consiste donc à projeter sur ce corpus massif les modèles et les approximations élaborées à partir du corpus *Chapitres*. Les classifieurs supervisés entraînés sur le corpus de référence (notamment l'identification de la littérature de genre au chapitre 8) sont appliqués aux 12 176 romans de Gallica filtrés. Le corpus *Fictions littéraires de Gallica* joue ainsi le rôle de corpus de projection : il permet de replacer les résultats obtenus sur un noyau relativement canonique dans l'horizon beaucoup plus large de la production romanesque.

Le corpus gallica filtré et enrichi en métadonnées dans la thèse est mis à disposition en ligne est publié sur Zenodo [9], avec tous les romans disponibles directement au téléchargement, accompagné d'un grand fichier de métadonnées. À cette échelle des erreurs de métadonnées peuvent encore exister, nous prévoyons de versionner sur Zenodo les ajouts de métadonnées et les différentes corrections. Le tout est explicité dans un data paper [10].

3 Extraction des personnages dans la fiction

3.1 Présentation de la chaîne de traitement Propp-fr

Au [11] cours de la dernière décennie, une part importante de la recherche en narratologie computationnelle s'est concentrée sur l'extraction automatique d'informations sur les personnages. Bamman et al. [12] proposent un modèle probabiliste permettant d'inférer des *personas*, c'est-à-dire des types de personnages, à partir d'un vaste corpus de romans anglais. Leur étude montre que des méthodes computationnelles peuvent identifier ces types en analysant les régularités linguistiques associées aux actions, descriptions et possessions des personnages. Cette approche a conduit au développement d'outils spécialisés : BookNLP pour l'anglais [13], ainsi que ses adaptations pour

9. Voir le lien vers le corpus.

10. Jean Barré. « Hors d'usage : Curated French Fiction from Gallica, 1800–1950 ». *Journal of Open Humanities Data* 2026. DOI : 10.5334/johd.597.

11. Cette section se fonde en partie sur mes contributions à deux articles publiés en collaboration avec l'équipe du lattice en 2023 et 2024. Jean Barré, Pedro Cabrera Ramírez et al. « Pour une détection automatique de l'espace personnage dans les romans ». *Humanistica 2023*. Genève, Suisse, 2023 et Frédérique Mélanie-Becquet, Jean Barré et al. « BookNLP-fr, the French Versant of BookNLP. A Tailored Pipeline for 19th and 20th Century French Literature ». *Journal of Computational Literary Studies* 2024, p. 1-34. DOI : 10.48694/jcls.3924

12. David Bamman, Ted Underwood et Noah A. Smith. « A Bayesian Mixed Effects Model of Literary Character ». *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*. Baltimore, Maryland : Association for Computational Linguistics, 2014, p. 370-379. DOI : 10.3115/v1/P14-1035.

13. David Bamman, Olivia Lewke et Anya Mansoor. « An Annotated Dataset of Coreference in English Literature ». *Proceedings of the Twelfth Language Resources and Evaluation Conference*. Sous la dir. de Nicoletta Calzolari, Frédéric Béchet et al. Marseille, France : European Language Resources Association, 2020, p. 44-54.

l'allemand [14], le néerlandais [15] et le français [16].

La chaîne de traitement comprend les étapes suivantes : une correction des artefacts d'OCR, une segmentation en phrases et tokens, une analyse morpho-syntaxique et un *parsing* en dépendances grâce au modèle de langue CamemBERT [17], détection des entités nommées par un modèle BiLSTM-CRF [18], et enfin résolution de coréférence par le module Propp-fr entraîné sur le corpus *Long-LitBank-fr* [19].

Les entités détectées relèvent de six catégories, adaptées des lignes directrices du projet LitBank [20] :

— **PER** (personnages) : mentions désignant des individus ou groupes d'individus, qu'il s'agisse de noms propres (*Jean Valjean*), de syntagmes nominaux (*le commissaire*, *la jeune fille*) ou de pronoms (*il*, *elle*) ;

— **LOC** (lieux) : entités géographiques sans organisation politique — *la mer*, *la forêt*, *la vallée* ;

— **GPE** (entités géopolitiques) : unités territoriales dotées d'une population, une structure de gouvernance — *la France*, *Paris*, *le Mexique* ;

— **FAC** (infrastructures) : constructions fonctionnelles destinées à l'habitation, au stockage ou au transport — *la maison*, *le bureau*, *la gare* ;

— **VEH** (véhicules) : dispositifs conçus pour le déplacement — *la voiture*, *le train*, *le navire* ;

— **TIME** (temps) : expressions temporelles, durées et moments de la journée — *le soir*, *sous le règne de Louis XIII*, *trois jours plus tard*.

Le résultat est une annotation riche où chaque mention de personnage est typée, reliée à une chaîne de coréférence et liée dans une structure syntaxique exploitable [21]. Cette granularité permet non seulement d'identifier qui agit dans le récit, mais aussi où et quand, autant d'informations cruciales pour caractériser les univers fictionnels propres à chaque sous-genre.

14. Anton Ehrmanntraut, Leonard Konle et Fotis Jannidis. « LLpro : A Literary Language Processing Pipeline for German Narrative Texts ». *Proceedings of the 19th Conference on Natural Language Processing (KONVENS 2023)*. Sous la dir. de Munir Georges, Aaricia Herygers et al. Ingolstadt, Germany : Association for Computational Linguistics, 2023, p. 28-39.

15. Joris van Zundert, Andreas van Cranenburgh et Roel Smeets. « Putting Dutchcoref to the Test : Character Detection and Gender Dynamics in Contemporary Dutch Novels ». *Computational Humanities Research Conference*. CEUR Workshop Proceedings. 2023, p. 757-771.

16. Mélanie-Becquet, Barré et al., op. cit.

17. Louis Martin, Benjamin Muller et al. « CamemBERT : a Tasty French Language Model ». *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Sous la dir. de Dan Jurafsky, Joyce Chai et al. Online : Association for Computational Linguistics, 2020, p. 7203-7219. doi : 10.18653/v1/2020.acl-main.645.

18. Meizhi Ju, Makoto Miwa et Sophia Ananiadou. « A Neural Layered Model for Nested Named Entity Recognition ». *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1 (Long Papers)*. Association for Computational Linguistics, 2018, p. 1446-1459.

19. Antoine Bourgois et Thierry Poibeau. *The Elephant in the Coreference Room : Resolving Coreference in Full-Length French Fiction Works*. 2025. arXiv : 2510.15594 [cs.CL].

20. David Bamman, Sejal Popat et Sheng Shen. « An annotated dataset of literary entities ». *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1 (Long and Short Papers)*. Minneapolis, Minnesota : Association for Computational Linguistics, 2019, p. 2138-2144. doi : 10.18653/v1/N19-1220.

21. Voir le dossier github du projet avec les annotations des romans en open-source https://github.com/lattice-8094/fr-litbank

Dans cette thèse, nous mobilisons l'adaptation française de ce *pipeline*, développée au laboratoire Lattice sous la direction de T. Poibeau. Le projet, initialement nommé BookNLP-fr, a évolué au cours de la thèse pour devenir Propp-fr [22], notamment avec l'ajout d'un module de coréférence à longue portée. Dans ce qui suit, nous utilisons l'appellation *Propp-fr* pour désigner la chaîne de traitement dans son ensemble, indépendamment de la version utilisée. Les différentes applications que l'on verra dans la suite de cette thèse vont se focaliser sur la notion de personnage et les éléments extraits par Propp-fr.

3.2 Identification et regroupement des personnages

L'identification des personnages repose sur une définition volontairement large de la catégorie PER, selon les instructions du manuel d'annotation de LitBank : sont considérés comme personnages non seulement les noms propres (PROP) comme Jean Valjean ou Madame François, mais aussi les syntagmes nominaux définis ou indéfinis (la jeune fille, les villageois) et les pronoms personnels ou démonstratifs qui les reprennent (il, elle, ce dernier, etc.). Propp-fr annote donc toutes les mentions de personnages, en distinguant systématiquement ces trois sous-types (PROP/NOM/PRON). Dans nos évaluations sur LitBank-fr et Long-LitBank-fr, la détection de mentions atteint un F1 score supérieur à 92% [23].

Le regroupement des mentions en personnages uniques s'appuie ensuite sur le *pipeline* de coréférence. Celui-ci adopte une approche par paire de mentions : pour chaque mention candidate, on considère un ensemble restreint d'antécédents possibles (fenêtre de 30 mentions pour les pronoms, 300 pour les noms propres et communs) et l'on encode chaque paire mention-antécédent par la concaténation de leurs embeddings contextuels et d'un vecteur de caractéristiques textuelles. Un réseau de neurones prédit alors la probabilité de coréférence, et un algorithme de *ranking* sélectionne l'antécédent le plus probable.

Pour les romans longs, une étape de post-traitement global sur les noms propres permet de corriger une partie des limites liées à la fenêtre locale : les décisions de coréférence de haute confiance sur des paires de noms propres (par exemple Monsieur de Rênal / M. de Rênal dans *Le rouge et le noir*) sont propagées à l'échelle de tout le document, ce qui permet de reconstituer des chaînes étendues malgré la longueur du texte. Inversement, des prédictions de non-coréférence très sûres (par exemple Ralph et Monsieur Delmare d'*Indiana*, qui ne sont pas les mêmes personnes) sont utilisées pour empêcher des fusions de chaînes erronées.

Dans nos analyses, nous filtrons ensuite ces chaînes pour définir l'ensemble des personnages au sens opérationnel. Nous excluons les chaînes très courtes, les entités manifestement non humaines et, selon les besoins, les chaînes purement plurielles lorsque l'unité d'analyse doit rester l'individu. Les personnages ainsi définis constituent les nœuds d'un espace de caractérisation : chacun est associé à un ensemble de mentions ordonnées dans le temps narratif, qui serviront de base au calcul des vecteurs de personnages.

22. Bourgois et Poibeau, *The Elephant in the Coreference Room : Resolving Coreference in Full-Length French Fiction Works*.
23. Ibid., p. 4.

3.3 Des attributs aux représentations vectorielles

Les étapes précédentes récupèrent pour chaque personnage un ensemble d'attributs lexicaux. Ces attributs constituent la matière première de notre représentation vectorielle qui va ensuite nous permettre de comparer les personnages à grande échelle.

Trois types d'attributs. Parmi les informations extraites par Propp-fr, nous retenons principalement :

— Les **verbes agentifs** : lemmes verbaux dont le personnage est le sujet grammatical (« interroger », « observer », « découvrir », « aimer », « fuir », etc.).

— Les **modifieurs** : adjectifs associés au personnage, encodant sa caractérisation explicite (« jeune », « pauvre », « policier », « rusé », etc.).

— Les **possessifs** : noms apparaissant après un déterminant possessif renvoyant au personnage, révélant son univers matériel et relationnel (« maison », « revolver », « enfant », « enquête », etc.).

Deux stratégies de vectorisation. Afin de transformer ces attributs en représentations numériques exploitables par un classifieur, nous comparons deux approches complémentaires :

1. **Sac-de-mots (représentation interprétable)** : pour chaque personnage, nous calculons les fréquences relatives des n attributs les plus fréquents dans le corpus (typiquement $n = 1\,000$). Cette représentation de haute dimension présente l'avantage d'une interprétabilité directe : lorsqu'un classifieur linéaire est entraîné sur ces vecteurs, ses coefficients associent explicitement chaque attribut à une contribution positive ou négative pour chaque classe. On peut ainsi identifier les verbes, adjectifs ou possessions les plus fortement associés à un type de personnage.
2. **Embeddings contextuels (représentation dense)** : pour chaque attribut associé au personnage, nous extrayons son embedding contextuel grâce à $CamemBERT_{LARGE}$[24], un modèle de langue neuronal de type Transformer entraîné sur de grands corpus de français. Le vecteur final du personnage est obtenu par moyenne des embeddings de tous ses attributs, produisant une représentation dense de 1 024 dimensions. Cette approche capture des régularités sémantiques au-delà de la surface lexicale (deux personnages décrits par des vocabulaires distincts mais sémantiquement proches seront représentés par des vecteurs voisins), au prix d'une moindre interprétabilité directe.

Dans les chapitres suivants, nous utilisons les embeddings CamemBERT pour maximiser la performance des modèles et construire des espaces de similarité entre personnages, puis nous récupérons l'interprétabilité *a posteriori* par des analyses de distinctivité lexicale. Cette complémentarité permet de combiner puissance prédictive et lisibilité des résultats.

24. Martin, Muller et al., op. cit.

4 Apprentissage automatique : principes et classifieurs

4.1 Principes généraux

Les méthodes d'apprentissage machine que nous mobilisons dans cette thèse peuvent être décrites, dans leur formulation la plus simple, comme des procédures qui apprennent une fonction à partir de données. On suppose l'existence d'une fonction inconnue h qui associe à chaque objet x appartenant à un espace d'instances $\mathcal{X}$ (ici, des passages de romans, des romans entiers, des personnages représentés par des vecteurs) une sortie y dans un ensemble de valeurs possibles $\mathcal{Y}$ (par exemple, une étiquette de genre ou une catégorie de personnage). L'apprentissage machine consiste à construire une approximation $\hat{h}$ de cette fonction à partir d'exemples observés, de manière à pouvoir prédire correctement la sortie pour de nouveaux objets.

On distingue classiquement deux grands cadres : l'apprentissage supervisé, où l'on dispose d'exemples annotés sous forme de paires (x, y) (texte, étiquette), et l'apprentissage non supervisé, où aucune étiquette n'est disponible. Dans le premier cas, l'objectif est de retrouver une règle de décision qui reproduise au mieux les annotations existantes. Dans le second, il s'agit plutôt de mettre au jour des structures latentes dans les données sans indication préalable.

Ces deux approches ne s'opposent pas mais se complètent, et c'est leur articulation qui structure notre démarche. L'apprentissage supervisé permet de tester ces catégories préexistantes (roman policier / non-policier, détective / non-détective) et d'en évaluer la robustesse à travers les erreurs de classification et l'analyse des marges. Or, les étiquettes de genre sont souvent des reconstructions a posteriori forgées par l'histoire littéraire, et nous cherchons dans cette thèse à interroger le geste interprétatif des chercheurs. C'est précisément l'apprentissage non supervisé qui peut venir valider ou infirmer la pertinence de ces découpages : en faisant émerger des regroupements que les catégories établies n'anticipaient pas, en révélant des proximités inattendues, il interroge les frontières que le supervisé prenait pour acquises. Les deux modes constituent ainsi des angles de vue complémentaires sur les mêmes objets littéraires. Le premier vérifie si nos étiquettes tiennent face aux données, le second explore ce que les données suggèrent au-delà de nos étiquettes.

Au sein de l'apprentissage supervisé, on distingue encore classification et régression. Dans un problème de classification, l'espace de sortie $\mathcal{Y}$ est fini et discret. Il s'agit alors d'assigner à chaque texte l'étiquette la plus plausible. Dans un problème de régression, à l'inverse, la sortie est une variable continue (par exemple une date de publication estimée ou un score de canonicité). Les tâches abordées dans cette thèse sont principalement des tâches de classification binaires, mais nous pouvons en récupérer des indices continus afin d'en tirer une interprétation plus solide. Nous le verrons notamment au chapitre 5 et au chapitre 6, nous pouvons retrouver une probabilité prédite d'appartenir à une classe donnée. Cela nous sera très utile afin d'interroger les résultats comme des mesures de proximité au prototype du roman policier.

L'enjeu central de l'apprentissage machine n'est pas seulement d'ajuster un modèle aux données disponibles, mais de lui permettre de généraliser à de nouveaux cas. Un modèle peut, en effet, se comporter de deux manières extrêmes : il peut être sous-entraîné lorsqu'il est trop simple pour capturer les régularités présentes dans les données, ce qui se traduit par de

mauvaises performances à la fois sur l'échantillon d'entraînement et sur l'échantillon de test. Il peut être surentraîné lorsqu'il est trop complexe et s'adapte trop finement aux exemples vus, au point de mémoriser le bruit et les individualités de l'échantillon d'entraînement, au détriment des performances sur les nouvelles données de l'échantillon de test. La régularisation regroupe l'ensemble des techniques visant à contrôler cette complexité pour trouver un compromis satisfaisant entre fidélité aux données d'entraînement et capacité de généralisation.

Ces considérations se traduisent dans la pratique par des protocoles de validation rigoureux. On considère que les données disponibles constituent un échantillon fini de l'espace des textes possibles ; cet échantillon est usuellement partitionné en trois sous-ensembles : un ensemble d'entraînement, utilisé pour ajuster les paramètres du modèle ; un ensemble de validation (dit de « développement »), utilisé pour choisir entre plusieurs modèles et régler leurs hyperparamètres ; et enfin un ensemble de test, conservé à l'écart jusqu'à la fin de l'analyse et qui fournit une estimation honnête des performances du modèle sur des données nouvelles. Dans nos expériences, cette partition est parfois remplacée ou complétée par des procédures de validation croisée, qui permettent d'estimer la variabilité des performances lorsque l'on modifie légèrement la composition des ensembles d'entraînement et de test.

L'évaluation des modèles de classification s'appuie sur un ensemble de mesures standard issues de la matrice de confusion : l'exactitude globale (*accuracy*), qui exprime la proportion d'exemples correctement classés, mais aussi la précision et le rappel par classe, qui permettent de distinguer la fiabilité des prédictions positives (précision) et la capacité à récupérer la totalité des cas pertinents (rappel). La moyenne harmonique de ces deux mesures, le F1-score, fournit un compromis synthétique lorsque l'on souhaite optimiser simultanément précision et rappel. Dans des contextes où les classes sont déséquilibrées, ces mesures par classe sont plus informatives que la seule exactitude globale. Enfin, les performances des modèles sont systématiquement comparées à des modèles de référence simples (*baseline*), comme une prédiction assignant systématiquement la classe majoritaire, afin de s'assurer que les gains obtenus ne résultent pas d'artefacts triviaux.

Dans le cadre de l'apprentissage supervisé, la tâche de classification peut être formalisée de la manière suivante : on cherche une fonction de décision

$$\hat{h} : \mathcal{X} \to \mathcal{Y}$$

qui associe à chaque vecteur de caractéristiques $x \in \mathcal{X}$ (par exemple l'embedding d'un chapitre ou le vecteur décrivant un personnage) une étiquette $y \in \mathcal{Y}$ (par exemple {policier, non policier}). La fonction idéale h, qui encode la décision que prendrait un lecteur idéalement informé, demeure inobservable ; on ne dispose que d'un échantillon de paires $\langle x_i, y_i \rangle$ annotées manuellement ou dérivées de métadonnées existantes. L'apprentissage consiste à choisir, au sein d'une famille de modèles possible (une classe d'hypothèses), la fonction $\hat{h}$ qui reproduit le mieux ces annotations sur l'ensemble d'entraînement tout en conservant une bonne capacité de généralisation.

Au-delà de cette définition technique, la classification joue un rôle central dans les humanités numériques comme pratique de construction de sens. Comme le soulignent Bamman et al. [25],

25. David Bamman, Kent K. Chang et al. « On Classification with Large Language Models in Cultural Analytics ». *Proceedings of the Computational Humanities Research Conference*. Sous la dir. de Wouter Haverals,

l'acte de classer des textes en catégories dont les frontières ont été établies par de longues traditions théoriques (comme les genres littéraires) ou nouvellement circonscrites au cours de la recherche répond à plusieurs objectifs distincts : tester l'association de traits avec des catégories pour mieux comprendre ces catégories elles-mêmes ; reproduire le jugement humain à une échelle inaccessible à l'annotation manuelle ; et problématiser les frontières catégorielles initiales en exploitant les machines pour interroger notre compréhension actuelle de ces frontières.

4.2 Machines à vecteurs de support (SVM)

Parmi la diversité des algorithmes d'apprentissage supervisé disponibles, les machines à vecteurs de support (Support Vector Machines, dit SVM) s'imposent comme un choix méthodologique éprouvé en études littéraires computationnelles. Des travaux pionniers dès les années 2000 ont montré l'efficacité des SVM pour la classification de textes littéraires [26]. Une évaluation systématique menée par Hettinger, Jannidis et al. [27] sur des tâches de classification de sous-genres romanesques a comparé plusieurs algorithmes (k plus proches voisins, Naïve Bayes, arbres de décision, réseaux de neurones, SVM) sur un corpus de près de 1700 romans allemands. Leurs résultats montrent que les SVM linéaires, combinés à des caractéristiques thématiques issus de topic models (LDA), atteignaient les meilleures performances parmi tous les classifieurs testés, avec une efficacité de 0,83 sur les romans prototypiques et 0,81 sur le corpus élargi, scores que les auteurs de l'étude jugent satisfaisants. Plus récemment, un article de synthèse de Hatzel et al. [28] portant sur 40 publications en études littéraires computationnelles, confirme que les SVM restent, aux côtés des modèles neuronaux, l'une des méthodes les plus fréquemment employées. Les auteurs avancent plusieurs raisons pour expliquer cette persistance : la première étant que les données d'entraînement disponibles pour les tâches propres aux CLS sont souvent limitées, et dans ce cadre, les SVM, moins exigeants en volume de données, demeurent compétitifs face aux approches neuronales. Surtout, ils s'appuient sur des traits descriptifs explicites, qui rendent leurs décisions plus directement interprétables, ce qui constitue un avantage important pour l'analyse littéraire.

Afin de préciser le fonctionnement de ces modèles et les raisons de leur adéquation aux données textuelles, nous en rappelons brièvement l'intuition géométrique : dans le cas binaire le plus simple, on suppose que les exemples de deux classes (par exemple romans policiers vs non policiers) sont représentés par des points dans un espace vectoriel. Un SVM linéaire cherche un hyperplan de séparation, c'est-à-dire une frontière de décision qui divise l'espace en deux sous-espaces correspondant chacun à une classe. Parmi l'infinité d'hyperplans qui peuvent potentiellement séparer les données, le SVM choisit celui qui maximise la marge, c'est-à-dire la distance entre l'hyperplan et les points de chaque classe les plus proches de cette frontière. Ces

Marijn Koolen et Laure Thompson. 2024, p. 494-527.

26. B. Yu. « An evaluation of text classification methods for literary study ». *Literary and Linguistic Computing* 2008, p. 327-343. doi : 10.1093/llc/fqn015.

27. Lena Hettinger, Martin Becker et al. « Genre Classification on German Novels ». *Proceedings of the 26th International Workshop on Database and Expert Systems Applications (DEXA)*. Valencia, Spain : IEEE, 2015, p. 249-253. doi : 10.1109/DEXA.2015.62 ; Hettinger, Jannidis et al., « Classification of Literary Subgenres ».

28. Hans Ole Hatzel, Haimo Stiemer et al. « Machine Learning in Computational Literary Studies ». *it – Information Technology* 2023, p. 200-217. doi : 10.1515/itit-2023-0041.

points particuliers sont appelés vecteurs de support ; ce sont eux qui déterminent la position et l'orientation de l'hyperplan. Intuitivement, maximiser la marge revient à chercher une séparation la plus prudente possible, de manière à améliorer la capacité de généralisation du modèle.

Dans de nombreux cas, les classes ne sont pas parfaitement séparables par un hyperplan linéaire. Les SVM autorise alors certains points à se trouver du mauvais côté de la frontière, moyennant une pénalisation contrôlée par un hyperparamètre C : des valeurs de C faibles favorisent une marge large et tolèrent davantage d'erreurs, tandis que des valeurs élevées contraignent le modèle à corriger un maximum de points, au risque de surajuster. D'autre part, la technique du noyau permet de traiter des cas non linéaires en projetant implicitement les données dans un espace de dimension supérieure, où elles deviennent plus facilement séparables. Différents noyaux (linéaire, polynomial, *RBF*) peuvent être utilisés en fonction de la structure supposée des données.

Dans le contexte de cette thèse, nous privilégions les SVM linéaires pour plusieurs raisons. D'une part, ils sont plus rapides à entraîner que leurs variantes à noyau sur des corpus de taille moyenne et nécessitent moins d'hyperparamètres à ajuster. D'autre part, ils fournissent une représentation plus directement interprétable des décisions du modèle. En effet, dans le cas linéaire, l'hyperplan est défini par un vecteur de poids $\mathbf{w}$ dont chaque composante correspond à une dimension du vecteur d'entrée : lorsqu'on utilise des caractéristiques explicites, il est possible d'identifier les traits les plus fortement associés à chaque classe et d'en proposer une interprétation littéraire (lexique d'enquête, etc.). Hatzel et al. identifient cette possibilité d'introspection comme l'un des atouts majeurs des approches à base de traits par rapport aux modèles neuronaux de type « boîte noire » [29]. Dans notre approche, nous avons retenu la famille de SVM implémentée dans la bibliothèque scikit-learn [30], facilement implémentable dans le langage de programmation *Python*.

4.3 Grands modèles de langue et classification : apports et limites

L'émergence des grands modèles de langue (LLM) a suscité un intérêt croissant pour leur emploi dans des tâches de classification en humanités numériques. Capables de produire des classements en emploi direct sans adaptation (dit *zero-shot*) à partir d'instructions en langage naturel, ces modèles semblent offrir une alternative aux *pipelines* supervisés classiques, notamment en fournissant des pseudo-labels à faible coût et en accélérant certaines étapes de constitution de données. Toutefois, ces usages relèvent moins d'un remplacement de l'annotation que d'une augmentation de celle-ci : les performances restent hétérogènes selon les tâches et requièrent validation humaine et protocoles d'évaluation adaptés [31].

Une évaluation systématique menée par Bamman et al. [32] sur dix tâches issues des études littéraires computationnelles suggère, à première vue, que certaines tâches établies (parmi lesquelles figure la classification de genres populaires) peuvent être traitées de manière compétitive

29. Ibid.
30. F. Pedregosa, G. Varoquaux et al. « Scikit-learn : Machine Learning in Python ». *Journal of Machine Learning Research* 2011, p. 2825-2830.
31. Caleb Ziems, William Held et al. « Can Large Language Models Transform Computational Social Science ? » *Computational Linguistics* 2024, p. 237-291. DOI : 10.1162/coli_a_00502.
32. Bamman, Chang et al., « On Classification with Large Language Models in Cultural Analytics ».

par *prompting* avec des LLMs. Ce résultat a parfois été interprété comme l'indice que la classification générique serait, en tant que telle, résolue par les LLM. Or, dans la pratique, cette conclusion dépend fortement de la manière dont la tâche est opérationnalisée.

Dans l'analyse de Bamman et al., une tâche porte sur une classification de genres littéraire, dites *Genre*, et ne porte pas sur des romans entiers, mais sur des passages relativement courts : chaque livre est représenté par des extraits d'environ quelques centaines de mots, échantillonnés dans des œuvres du domaine public, et les étiquettes de genre proviennent de métadonnées (Library of Congress Subject Classification). L'évaluation privilégie ainsi des catégories relativement stabilisées, des cas prototypiques, et une reconnaissance fondée sur des indices locaux. Ce cadre est idéal pour tester la capacité d'un LLM à mobiliser des associations culturelles déjà présentes dans ses données de pré-entraînement. Il ne constitue pas, en revanche, une solution générale au problème de la classification générique à l'échelle d'objets longs, hétérogènes et historiquement situés comme les romans.

Cette différence d'échelle n'est pas seulement conceptuelle : elle est aussi technique. Les architectures utilisées en classification neuronale reposent aujourd'hui majoritairement sur les transformers, introduits par Vaswani et al. [33]. Le mécanisme central de ces modèles est l'attention : plutôt que de traiter le texte séquentiellement comme les réseaux récurrents, un transformer calcule pour chaque token une pondération de tous les autres tokens de la séquence, permettant ainsi de capturer des dépendances à longue distance. Cependant, cette opération a un coût computationnel quadratique par rapport à la longueur de la séquence, ce qui impose en pratique des fenêtres de contexte limitées. Le modèle BERT [34], qui a popularisé l'usage des transformers pour les tâches de classification textuelle, est ainsi limité à 512 tokens, soit environ 300 à 400 mots (2 pages de livres) selon la langue et le tokenizer utilisés. Dès lors, utiliser un transformer pour classer un roman revient souvent, en pratique, à classer une collection d'extraits plutôt qu'une œuvre comme totalité, ce qui favorise les signaux les plus saillants et les plus localement disponibles. Or, dans notre travail, le genre constitue un objet à la fois distribué dans le texte et historiquement structuré : il engage des conventions de composition, des configurations actantielles, qui sont difficilement capturables par des extraits. Dans cette thèse nous verrons que l'on peut quand même récupérer des éléments intéressants grâce à ce type de modèles.

Enfin, les modèles linéaires (régression logistique, SVM), lorsqu'ils opèrent sur des représentations explicites comme les fréquences de mots, permettent de relier une décision de classification à des dimensions identifiables : mots discriminants, motifs récurrents, attributs de personnages, etc. Cette possibilité d'introspection est centrale pour comprendre ce qui fait qu'un texte est classé comme policier et analyser les cas limites. Les LLM, en revanche, produisent des décisions difficiles à rapporter à des caractéristiques textuelles stables et contrôlables, ce qui limite leur usage lorsque l'objectif n'est pas seulement de prédire, mais de comprendre et d'argumenter.

Pour ces raisons, nous ne mobilisons pas les LLM comme modélisation principale dans

33. Ashish Vaswani, Noam Shazeer et al. « Attention Is All You Need ». *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2017.

34. Jacob Devlin, Ming-Wei Chang et al. « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding ». *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota : Association for Computational Linguistics, 2019, p. 4171-4186. doi : 10.18653/v1/N19-1423.

cette thèse. Ils peuvent intervenir ponctuellement comme outils exploratoires ou comme aides à l'annotation, mais nos résultats reposent sur des protocoles supervisés (notamment des SVM) et sur des représentations dont nous pouvons tester la robustesse et documenter l'interprétabilité.

4.4 Stratégies de validation croisée : contrôler les effets de structure

La validation croisée en k plis (k-fold cross-validation) constitue le protocole standard pour estimer la capacité de généralisation d'un modèle. Le corpus est partitionné en k sous-ensembles de taille approximativement égale ; le modèle est entraîné k fois, chaque fois sur $k-1$ plis et évalué sur le pli restant. La performance finale est la moyenne des k évaluations, ce qui fournit une estimation plus robuste qu'une simple partition train/test et permet de quantifier la variance des résultats.

Cependant, la validation croisée standard repose sur une hypothèse d'indépendance entre les exemples qui est rarement satisfaite dans les corpus littéraires. Deux sources de dépendance sont particulièrement problématiques pour les tâches de classification générique.

Effet auteur. Un auteur prolifique présent à la fois dans l'ensemble d'entraînement et dans l'ensemble de test peut artificiellement gonfler les performances du modèle. En effet, le modèle risque d'apprendre à reconnaître l'idiolecte de l'auteur (préférences lexicales, constructions syntaxiques récurrentes, tics stylistiques) plutôt que les traits propres au genre. Ce phénomène est particulièrement aigu dans notre sous-corpus policier de *Chapitres*, où Georges Simenon représente à lui seul plus de 80 romans.

Effet période. De même, si le modèle est entraîné sur des textes d'une certaine période et testé sur des textes de la même période, il peut exploiter des régularités chronologiques (évolution de la langue, conventions narratives d'une époque) plutôt que des invariants génériques. L'asymétrie temporelle du corpus *Chapitres*, avec une forte concentration dans la deuxième moitié du XIXe siècle, amplifie ce risque.

Afin de contrôler ces effets, nous recourons à des variantes de validation croisée qui imposent des contraintes sur la partition des données.

Validation croisée par groupe. Cette stratégie dites *GroupKFold* garantit que tous les exemples appartenant à un même groupe (par exemple, tous les romans d'un même auteur) se trouvent entièrement dans l'ensemble d'entraînement ou entièrement dans l'ensemble de test, mais jamais répartis entre les deux. Cette contrainte empêche le modèle de mémoriser des signatures auctoriales et force l'apprentissage de régularités transversales aux auteurs.

Contrôle temporel par échantillonnage. Une approche complémentaire consiste à limiter le nombre de textes par période (par exemple, 10 romans par décennie) avant d'effectuer la validation croisée. Cette stratégie d'échantillonnage, moins formalisée que *GroupKFold*, permet de réduire la surreprésentation de certaines périodes sans imposer une partition stricte.

Interprétation des écarts de performance. La comparaison des performances obtenues sous différentes contraintes de validation est en elle-même informative. Un modèle qui maintient une performance élevée en *GroupKFold* par auteur démontre qu'il a appris des régularités génériques indépendantes des idiolectes individuels. À l'inverse, une chute importante de performance signale que le pouvoir prédictif reposait en partie sur des effets de structure (auteur, période) plutôt que sur des traits proprement génériques. Cette dégradation contrôlée permet de quantifier la part respective des différentes sources de signal dans la classification.

Dans les expériences présentées aux chapitres suivants, nous systématisons cette approche en rapportant les performances sous plusieurs régimes de validation : validation standard, *GroupKFold* par auteur, et combinaison des contraintes. Cette triangulation permet d'évaluer la robustesse du signal générique détecté et de distinguer les invariants textuels transversaux des artefacts liés à la structure du corpus.

5 Opérationnaliser l'intertextualité

5.1 Du texte au vecteur

5.1.1 Le sac-de-mots

La[35] représentation en sac-de-mots (*bag-of-words*) constitue la forme la plus élémentaire de vectorisation textuelle. Le principe en est simple : un texte est représenté par un vecteur dont chaque dimension correspond à un mot du vocabulaire, et dont la valeur indique la fréquence relative de ce mot dans le texte. L'ordre des mots est entièrement ignoré, d'où la métaphore du « sac », de même que la structure syntaxique et la progression narrative. Le texte devient une distribution de termes, comparable à d'autres distributions par des mesures de distance standard.

Malgré cette simplification radicale, le sac-de-mots s'est révélé remarquablement efficace pour de nombreuses tâches de classification textuelle, y compris en études littéraires. Si Burrows[36] a donné à cette approche sa forme canonique en stylométrie moderne en montrant que ces distributions suffisent à distinguer les styles auctoriaux avec une précision élevée, l'idée d'une mesure quantitative du style remonte au moins à Lutoslawski[37], dont les travaux pionniers sur Platon constituent un jalon majeur de la préhistoire de la discipline. Plus récemment, Underwood[38] a montré que des modèles linéaires entraînés sur des sacs-de-mots permettent de retracer l'évolution historique des genres littéraires en anglais, du roman gothique à la science-fiction.

Dans le contexte francophone, nous adoptons une procédure comparable. Les textes sont d'abord nettoyés, puis vectorisés en comptant les occurrences des n mots les plus fréquents du

35. Cette section se fonde en partie sur un article publié en anglais : Jean Barré. « Latent Structures of Intertextuality in French Fiction ». *Proceedings of the Computational Humanities Research Conference 2024*. CHR 2024. Aarhus, 2024, p. 21-26

36. J. Burrows. « 'Delta' : a Measure of Stylistic Difference and a Guide to Likely Authorship ». *Literary and Linguistic Computing* 2002, p. 267-287. doi : 10.1093/llc/17.3.267.

37. W. Lutoslawski. « Principes de stylométrie appliqués à la chronologie des œuvres de Platon ». *Revue des Études Grecques* 1898, p. 61-81. doi : 10.3406/reg.1898.5847.

38. Underwood, *Distant horizons*.

corpus. Chaque roman est ainsi représenté par un vecteur de dimension n, où la i-ème composante encode la fréquence relative du i-ème mot le plus fréquent. Cette représentation peut être affinée de plusieurs manières : pondération TF-IDF pour atténuer l'influence des mots très courants mais peu discriminants, suppression des mots-outils (*stopwords*) pour se concentrer sur le vocabulaire de contenu, ou au contraire conservation de ces mots pour capturer des régularités stylistiques. Le maintien de ces mots-outils peut en effet se justifier par l'hypothèse qu'ils dépendent davantage de mécanismes d'écriture routiniers et peu conscients [39], tandis que les mots plus rares renvoient plus directement aux thèmes des textes.

L'intérêt majeur du sac-de-mots réside dans son interprétabilité directe. Lorsqu'un modèle linéaire est entraîné sur cette représentation, les coefficients appris associent explicitement chaque mot à une contribution positive ou négative pour chaque classe. Comme le montrera le chapitre 5, on peut ainsi identifier les termes les plus fortement associés au roman policier, à l'inverse, ceux qui en éloignent. Cette transparence permet une lecture littéraire des décisions du modèle.

Cette interprétabilité a toutefois un coût. En ignorant l'ordre des mots et la structure syntaxique, le sac-de-mots ne distingue pas entre *« le détective interroge le suspect »* et *« le suspect interroge le détective »*. Il ne capture pas non plus les régularités de niveau supérieur au mot, ni les phénomènes de cohérence textuelle qui se déploient sur plusieurs phrases ou paragraphes. Ces limitations expliquent pourquoi le sac-de-mots, s'il reste une *baseline* robuste et interprétable, est souvent complété ou remplacé par des représentations plus riches lorsque la tâche l'exige.

Dans les chapitres empiriques qui suivent, nous mobilisons le sac-de-mots pour les tâches où l'interprétabilité des traits discriminants est centrale, notamment pour la classification du genre policier, où l'identification du lexique caractéristique constitue un résultat en soi. Pour les tâches requérant une sensibilité aux régularités contextuelles et à la cohérence textuelle (réseaux de similarité entre romans, trajectoires sémantiques de personnages), nous recourons aux embeddings décrits dans la sous-sous-section 5.1.3.

5.1.2 La modélisation thématique

La modélisation thématique, ou modélisation de sujets (*topic modeling*), regroupe un ensemble de méthodes visant à identifier automatiquement des thèmes récurrents dans un corpus. Entre la représentation lexicale brute du sac-de-mots de la sous-sous-section 5.1.1 et les espaces vectoriels denses des plongements de passage de la prochaine sous-sous-section 5.1.3, la modélisation thématique occupe une position intermédiaire. Le principe fondamental, formalisé par Blei et al [40] avec le modèle *Latent Dirichlet Allocation* (LDA), consiste à postuler l'existence de thèmes latents dans un corpus : chaque document est conçu comme un mélange de thèmes, et chaque thème comme une distribution de probabilité sur les mots du vocabulaire. L'algorithme infère simultanément ces deux niveaux de distribution à partir des co-occurrences lexicales observées dans le corpus.

39. James W. Pennebaker. *The secret life of pronouns : what our words say about us*. New York : Bloomsbury Press, 2011.

40. David M. Blei, Andrew Y. Ng et Michael I. Jordan. « Latent Dirichlet Allocation ». *Journal of Machine Learning Research* 2003, p. 993-1022.

Concrètement, un modèle LDA entraîné sur un corpus de romans produit k thèmes (où k est un hyperparamètre fixé à l'avance), chacun caractérisé par une liste de mots ordonnés par leur probabilité d'appartenance. Idéalement, on obtient ainsi des thèmes interprétables : un thème « criminel » pourrait regrouper des termes comme *crime*, *assassin*, *police*, *enquête*, *victime* ; un thème « domestique » rassemblerait *maison*, *famille*, *mère*, *père*, *enfant*, *repas*. Pour chaque document (ou segment de document), le modèle fournit une distribution sur les k thèmes, permettant de quantifier la proportion de chaque thème dans le texte.

Cette approche a été largement utilisée dans les humanités numériques pour étudier l'évolution thématique de la fiction à grande échelle. Par exemple, une étude récente de Sobchuk et Beheim [41] utilise ce modèle pour tester des hypothèses sur le changement littéraire, montrant que les transformations thématiques de la fiction sont davantage portées par l'arrivée de nouveaux auteurs que par l'évolution interne des auteurs établis.

Dans cette thèse, nous recourons au LDA pour des tâches spécifiques où l'interprétabilité thématique est centrale (voir le chapitre 7). Afin d'extraire des thèmes pertinents pour l'analyse littéraire, nous appliquons plusieurs prétraitements : lemmatisation, filtrage par catégories grammaticales, élimination des noms propres, des mots rares et des mots outils. Les romans sont segmentés en morceaux de taille fixe (5000 mots), permettant de mesurer la proportion de chaque thème au fil du récit.

L'avantage principal du LDA réside dans le fait que les thèmes peuvent être inspectés, nommés, et leur présence dans un texte est directement quantifiable. Cette transparence permet de formuler des hypothèses précises et de les tester empiriquement. Par exemple, nous mesurerons au chapitre 7 si le thème criminel devient plus persistant au cours du XIXe siècle dans les romans qui préfigurent le policier. Toutefois, la modélisation thématique est fondée sur une logique de sac-de-mots et donc souffre de la même façon d'une insensibilité à l'ordre des mots et à la structure syntaxique. Deux phrases utilisant les mêmes termes dans des configurations opposées produiront des distributions thématiques identiques.

Ces limitations expliquent pourquoi la modélisation LDA est utilisée dans cette thèse comme un outil complémentaire, particulièrement adapté aux questions de persistance thématique et d'évolution diachronique, mais insuffisant pour les tâches requérant une sensibilité aux régularités contextuelles fines. Pour ces dernières, nous recourons aux embeddings de phrases décrits dans la section suivante.

5.1.3 Les embeddings de phrases

Les techniques que l'on a vu dans les deux sections précédentes présentent l'avantage d'être relativement interprétables (on peut inspecter les mots caractéristiques d'un genre ou d'un thème), mais elles tendent à négliger certaines dimensions importantes de la textualité, comme l'ordre des mots, la progression narrative ou les régularités stylistiques fines.

L'essor des modèles d'embeddings de documents, avec notamment les *Paragraph Vectors* de *Doc2Vec* [42], puis des modèles neuronaux de plus en plus performants, a ouvert la possibilité de

41. Sobchuk et Beheim, « Does literature evolve one funeral at a time ? »
42. Quoc V. Le et Tomas Mikolov. *Distributed Representations of Sentences and Documents*. 2014. arXiv :

représenter des passages de textes par des vecteurs denses, dans lesquels sont encodées de manière latente des informations mixtes, qu'elles soient lexicales, syntaxiques et sémantiques. Ces modèles ont montré leur efficacité pour des tâches traditionnelles en étude littéraires computationnelles, en stylométrie avec l'attribution d'auteurs [43], d'autres études sur le prestige littéraire [44] ou sur la dimension générique des textes [45], mais leur caractère de « boîte noire » suscite aussi des réticences.

Dans cette thèse, nous faisons le choix d'assumer ce caractère partiellement opaque en l'encadrant par deux précautions méthodologiques. La première consiste en un affinage (*fine-tuning*), c'est-à-dire en un entraînement supplémentaire visant à adapter le modèle à un corpus spécialisé de littérature française. Plutôt que d'utiliser un modèle pré-entraîné sur des corpus généralistes, nous spécialisons notre encodeur sur les textes mêmes que nous analysons, de sorte que l'espace vectoriel produit reflète les régularités propres à la prose romanesque française du XIXe et du XXe siècle. La seconde précaution repose sur des contrôles systématiques du comportement du modèle. Nous menons des analyses d'ablation pour identifier quelles dimensions textuelles contribuent effectivement aux similarités calculées, le tout accompagné d'évaluations sur des tâches annexes pour vérifier que les représentations capturent des distinctions littérairement pertinentes.

Plutôt que de supposer à l'avance quelles caractéristiques textuelles seraient pertinentes pour l'intertextualité, nous considérons que les embeddings de texte fournissent un espace latent susceptible de capturer conjointement plusieurs de ces dimensions. Nos expériences visent alors à tester dans quelle mesure cet espace reflète effectivement les distinctions génériques et les proximités intertextuelles qui nous intéressent.

5.2 Choix du modèle et procédure d'affinage

Techniquement, nous nous appuyons sur un modèle d'encodage de type *Sentence Transformer*, dérivé du modèle dense M3-Embedding [46]. Ce choix repose d'abord sur l'état de l'art disponible au moment de la mise en place des protocoles expérimentaux de la thèse, entre mai et juillet 2024. Ce type de modèle figurait alors parmi les plus performants sur le *benchmark MTEB* (Massive Multilingual Text Embedding Benchmark) [47] pour des tâches variées de similarité et de recherche sémantique [48]. Ce choix est motivé par sa dimension multilingue, qui couvre le français, et surtout la possibilité de l'adapter par affinage à la langue littéraire française.

L'objectif de cet affinage est de spécialiser le modèle afin de produire un espace vectoriel où les distances reflètent davantage les dimensions qui structurent notre corpus. Ce modèle

1405.4053 [cs.CL].

43. Maciej Eder. « Boosting word frequencies in authorship attribution ». *Proceedings of the Computational Humanities Research Conference (CHR 2022)*. CEUR Workshop Proceedings, 2022, p. 387-397.

44. Andreas van Cranenburgh, Karina van Dalen-Oskam et Joris van Zundert. « Vector space explorations of literary language ». *Language Resources and Evaluation* 2019, p. 625-650. DOI : 10.1007/s10579-018-09442-4.

45. Sobchuk et Šeļa, « Computational thematics ».

46. Jianlv Chen, Shitao Xiao et al. *BGE M3-Embedding : Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. 2024. arXiv : 2402.03216[cs].

47. https://huggingface.co/spaces/mteb/leaderboard

48. *MMTEB : Massive Multilingual Text Embedding Benchmark*. 2025. arXiv : 2502.13595 [cs.CL] ; Niklas Muennighoff, Nouamane Tazi et al. *MTEB : Massive Text Embedding Benchmark*. 2022.

affiné pourra ensuite être mobilisé pour l'ensemble des tâches de la thèse, que ce soit pour la classification de genre, la construction de réseaux de similarité entre romans, ou encore l'analyse des trajectoires de personnages.

Nous procédons donc à un affinage contrastif[49] du modèle sur un corpus de passages extraits de nos romans, en utilisant une fonction de perte de type *Multiple Negatives Ranking Loss*, à l'état de l'art pour des tâches de similarité à l'époque. Le principe retenu est celui d'une tâche de similarité de passages : pour chaque roman, nous sélectionnons aléatoirement des séquences de dix phrases qui servent de requêtes, et nous constituons pour chacune un passage positif (les dix phrases suivantes) et un passage négatif (dix phrases tirées aléatoirement dans l'ensemble du corpus). L'hypothèse est qu'à cette échelle de granularité, les passages contigus d'un même roman partagent une forte cohérence thématique et stylistique, tandis que des passages choisis aléatoirement dans des œuvres différentes ont, en moyenne, des profils plus éloignés. Le modèle est entraîné à rapprocher dans l'espace vectoriel les paires positives et à éloigner les paires négatives.

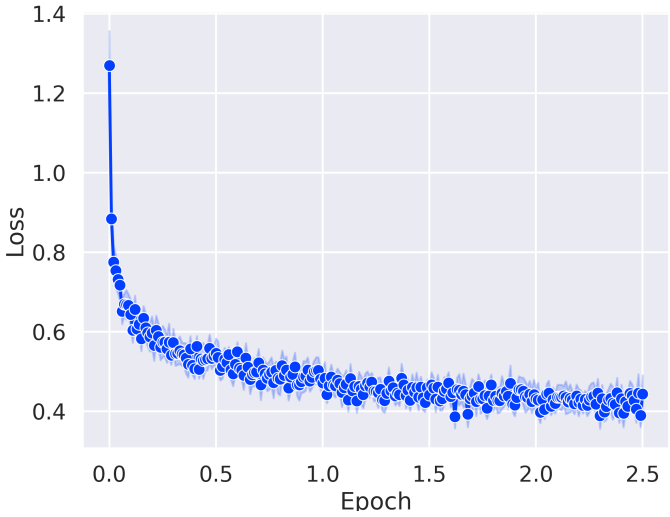


FIGURE 4.5 : Évolution de la fonction de perte au cours de l'entraînement du modèle *fr_literary_bge*

La figure 4.5 présente l'évolution de la fonction de perte au cours de l'entraînement. On observe une convergence rapide dès la première demi-époque, suivie d'une stabilisation progressive. Ce comportement indique que le modèle apprend efficacement à distinguer les passages contigus des passages aléatoires, sans signe de surapprentissage sur les itérations où le modèle voit son corpus d'entraînement.

Afin d'éviter que le modèle ne se contente d'exploiter des signaux triviaux (par exemple la présence de noms propres de personnages), nous anonymisons systématiquement les entités nommées de type personne en les remplaçant par un jeton spécial [PROPN]. L'extraction des

49. Nils REIMERS et Iryna GUREVYCH. « Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks ». *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Sous la dir. de Kentaro INUI, Jing JIANG et al. Hong Kong, China : Association for Computational Linguistics, 2019, p. 3982-3992. DOI : 10.18653/v1/D19-1410.

noms propres s'appuie sur Propp-fr (présenté en section 3), qui est une *pipeline* de référence pour la reconnaissance et la normalisation d'entités littéraires en français. Cette anonymisation force le modèle à se reposer davantage sur des indices formels et lexicaux plus diffus plutôt que sur l'identification directe de personnages.

Une fois ce modèle adapté, toute unité textuelle (chapitre, scène, roman, personnage agrégé par ses contextes d'apparition) peut être encodée en un vecteur dense de dimension fixe. La principale contrainte pratique tient à la fenêtre de contexte maximale du modèle (512 tokens), alors que les romans excèdent largement cette taille (environ 100,000 mots en moyenne). Pour représenter un roman, nous adoptons donc une stratégie d'échantillonnage–agrégation : pour chaque texte, nous tirons aléatoirement un certain nombre de fenêtres, nous encodons chacune d'elles, puis nous calculons la moyenne des vecteurs obtenus. Cette moyenne fournit une représentation unique du roman, interprétable comme une estimation de sa position moyenne dans l'espace latent du modèle. Le recours au *mean pooling* pour agréger des représentations contextuelles s'est imposé comme une pratique standard en TAL, surpassant généralement d'autres stratégies d'agrégation (*token [CLS]*, *max pooling*) pour les tâches de similarité sémantique[50].

La distance entre deux unités textuelles est mesurée par la similarité cosinus entre leurs vecteurs, mesure classique en TAL et en études computationnelles de la littérature, qui a montré une bonne corrélation avec des jugements humains de similarité sémantique[51]. Dans le cas de modèles contextualisés de grande taille, on sait toutefois que quelques dimensions peuvent dominer le calcul de similarité et introduire des effets parasites[52]. Pour limiter ce phénomène, nous appliquons avant le calcul une standardisation des vecteurs, qui revient à neutraliser les dimensions les plus globalement dominantes.

5.3 Validation des représentations vectorielles

La procédure retenue pour représenter un roman consiste à tirer aléatoirement un certain nombre de passages, à les encoder séparément, puis à calculer la moyenne de leurs vecteurs. Cette stratégie d'agrégation soulève une interrogation légitime : la représentation obtenue est-elle suffisamment stable pour capturer l'identité du roman, malgré la variabilité introduite par le tirage aléatoire ?

Afin de répondre à cette question, nous avons mis en place un test de cohérence interne sur un sous-ensemble de mille romans du corpus. Pour chaque œuvre, nous générons cinq représentations distinctes en répétant indépendamment la procédure complète : tirage aléatoire de passages, encodage par le modèle affiné, et calcul de la moyenne des embeddings. Cela produit un total de

50. Tianyu Gao, Xingcheng Yao et Danqi Chen. *SimCSE : Simple Contrastive Learning of Sentence Embeddings*. 2022. arXiv : 2104.08821 [cs.CL] ; Reimers et Gurevych, « Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks ».

51. Bin Wang, Angela Wang et al. « Evaluating word embedding models : methods and experimental results ». *APSIPA Transactions on Signal and Information Processing* 2019. DOI : 10.1017/ATSIP.2019.12.

52. Jiaqi Mu et Pramod Viswanath. *All-but-the-Top : Simple and Effective Postprocessing for Word Representations*. 2018 ; William Timkey et Marten van Schijndel. « All Bark and No Bite : Rogue Dimensions in Transformer Language Models Obscure Representational Quality ». *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Sous la dir. de Marie-Francine Moens, Xuanjing Huang et al. Online et Punta Cana, Dominican Republic : Association for Computational Linguistics, 2021, p. 4527-4546. DOI : 10.18653/v1/2021.emnlp-main.372.

5 000 vecteurs (5 moyennes des tirages × 1 000 romans).

L'évaluation consiste alors à vérifier, pour chaque représentation d'un roman, que ses quatre plus proches voisins dans l'espace vectoriel correspondent bien aux quatre autres versions du même roman. Si le modèle et la procédure d'agrégation sont robustes, chaque tirage devrait reconnaître ses « jumeaux » comme plus semblables que n'importe quel autre roman du corpus. Tout échec de cette reconnaissance entraîne une pénalité dans le score de précision.

Cette validation présente l'avantage de ne reposer sur aucune annotation externe. Elle teste directement la cohérence interne des représentations produites par le modèle. Un score de précision élevé indique que les embeddings capturent des régularités propres à chaque roman, insensibles à la variabilité du sous-échantillonnage.

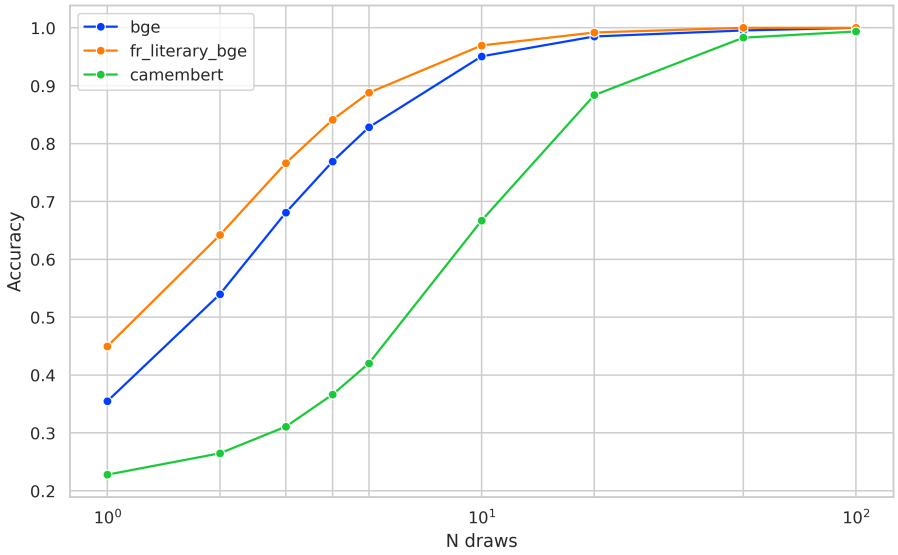


FIGURE 4.6 : Test de cohérence interne : précision en fonction du nombre de passages agrégés (BGE-M3, fr_literary_bge, CamemBERT).

La figure 4.6 présente les résultats de ce test de cohérence pour trois modèles : le modèle de base *BGE-M3*, sa version affinée sur notre corpus littéraire français (*fr_literary_bge*[53]), et un modèle de référence pour le français (CamemBERT, introduit plus haut). L'axe horizontal indique le nombre de tirages utilisés pour construire chaque représentation de roman, tandis que l'axe vertical mesure la précision du test (la proportion de cas où les quatre plus proches voisins sont bien les autres versions du même roman).

La première observation est que le modèle *fr_literary_bge* affiné sur notre corpus surpasse nettement le modèle de base *BGE-M3* et, plus encore, CamemBERT à tous les niveaux de tirage. Cette amélioration valide l'hypothèse selon laquelle l'adaptation à la langue littéraire française renforce la capacité du modèle à discriminer les œuvres. Ensuite, le modèle affiné atteint une précision de 100% dès 50 tirages, alors que le modèle de base nécessite 100 tirages pour des performances comparables. Cette réduction de moitié du nombre de passages requis a des implications pratiques cruciales : elle diminue considérablement le coût computationnel

53. Le modèle et le corpus d'affinage est disponible sur la plateforme *huggingface*, https://huggingface.co/crazyjeannot/fr_literary_bge_base

lors de l'inférence sur l'ensemble des 12 000 romans du corpus. Troisièmement, même avec seulement 10 tirages, le modèle affiné maintient une précision supérieure à 90%, suggérant que les représentations capturent des traits distinctifs stables, présents dans la plupart des passages d'un roman.

Ces résultats suggèrent que la procédure d'échantillonnage-agrégation produit des représentations à la fois robustes (insensibles au hasard du tirage) et discriminantes (spécifiques à chaque œuvre). Le modèle affiné parvient à extraire, dès quelques dizaines de passages, une signature vectorielle caractéristique de chaque roman, qui persiste malgré la diversité interne de l'œuvre.

5.4 Analyses d'ablation

Si le test de cohérence interne valide la stabilité des représentations, il ne nous enseigne pas encore sur la nature des caractéristiques capturées : s'agit-il du style, du vocabulaire thématique, des structures narratives ? Pour éviter de projeter nos propres intuitions littéraires sur les mesures computationnelles, nous avons mené une série d'expériences d'ablation, c'est-à-dire de manipulations contrôlées visant à retirer ou modifier certains éléments d'un texte pour mesurer leur effet sur la sortie du modèle. À partir d'une paire de passages jugés similaires, nous supprimons ou altérons systématiquement certaines composantes, puis nous observons l'impact de ces transformations sur la similarité calculée.

Le principe de l'ablation est simple : si la suppression d'un type d'information entraîne une forte baisse de similarité, cela indique que le modèle s'appuie fortement sur cette information pour établir sa mesure. À l'inverse, une ablation sans effet suggère que la dimension supprimée ne joue qu'un rôle marginal dans le calcul de similarité.

Nous avons sélectionné comme cas d'étude une paire de passages extraits de deux romans partageant un motif narratif commun : l'examen des traces de pas laissées par un criminel. Ces deux passages, bien que provenant d'œuvres différentes, présentent une forte similarité selon le modèle (cosinus $> 0{,}8$). Nous appliquons ensuite les transformations suivantes :

1. Suppression des noms propres : remplacement de tous les noms de personnages par un token générique [PROPN], pour neutraliser l'effet des entités nommées.
2. Suppression de la ponctuation : élimination de tous les signes de ponctuation, testant ainsi le rôle de la segmentation syntaxique.
3. Suppression des mots thématiques saillants.
4. Suppression des mots-outils : retrait des mots-outils afin d'isoler le vocabulaire porteur de contenu.
5. Suppression combinée : cumul de plusieurs ablations (mots-outils + mots thématiques, par exemple).
6. Permutation de l'ordre des mots : mélange aléatoire de tous les mots du passage, détruisant ainsi la structure syntaxique tout en conservant le vocabulaire.

Pour chaque transformation, nous calculons la similarité cosinus entre les différentes suppressions des deux passages et la comparons à la similarité de base.

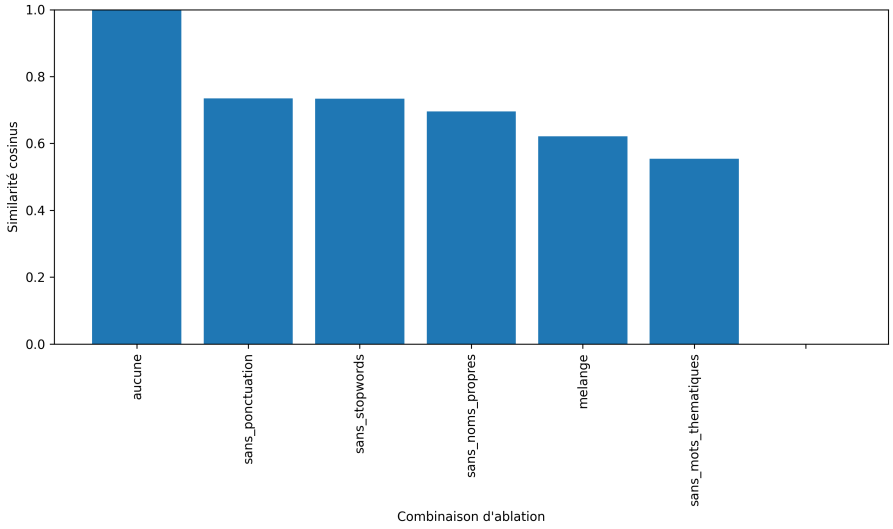


FIGURE 4.7 : Expériences d'ablation : impact de différentes suppressions/transformations sur la similarité cosinus entre deux passages similaires.

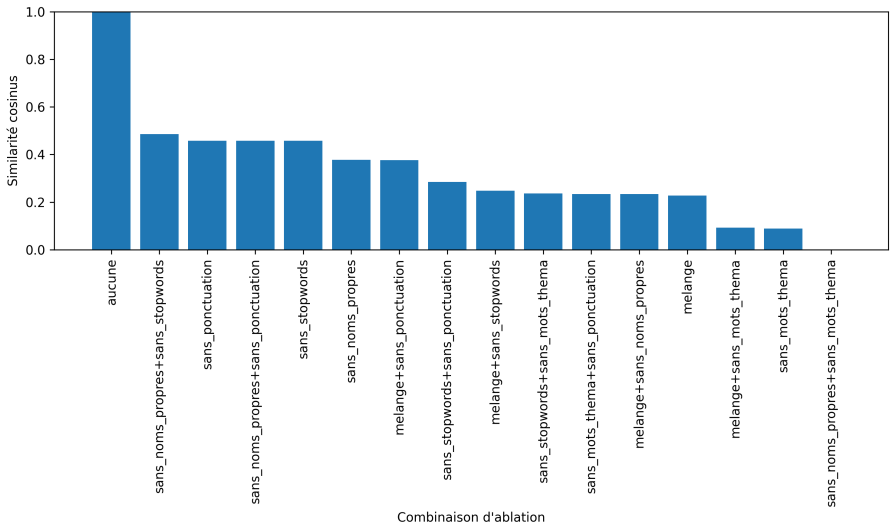


FIGURE 4.8 : Expériences d'ablation combinées : impact cumulatif des différentes transformations.

Les figures 4.7 et 4.8 présentent les résultats de ces expériences d'ablation, la première pour les manipulations isolées, la seconde pour leurs combinaisons.

La suppression des noms propres ou de la ponctuation n'affecte que modérément la similarité (baisse d'environ 25-30%). Le modèle continue à reconnaître les deux passages comme proches, suggérant qu'il ne s'appuie pas principalement sur l'identité des personnages ou sur les marqueurs de segmentation syntaxique pour établir la proximité entre textes.

En revanche, la suppression des mots thématiques saillants provoque une chute drastique de la similarité (baisse d'environ 45%). Ce résultat indique que le modèle fonde largement son jugement de proximité sur le champ lexical partagé, c'est-à-dire sur la co-occurrence de termes appartenant au même registre sémantique.

Le mélange aléatoire de l'ordre des mots entraîne une baisse notable de la similarité (environ 38%), moins marquée toutefois que la suppression du vocabulaire thématique. Le modèle est donc sensible à l'organisation syntaxique, mais cette dimension pèse moins lourd que la dimension lexicale dans le calcul de proximité.

Les résultats des ablations combinées (figure 4.8) révèlent un effet cumulatif : la suppression conjointe de plusieurs dimensions textuelles produit des chutes de similarité plus importantes que la somme de leurs effets isolés. La combinaison la plus destructrice associe le mélange de l'ordre des mots à la suppression des mots thématiques, confirmant que ces deux dimensions constituent les principaux supports de la représentation sémantique encodée par le modèle.

5.5 Ce que capturent les embeddings

Ces analyses d'ablation convergent vers une conclusion importante pour l'interprétation de nos résultats. Les embeddings capturent prioritairement des régularités de contenu thématique et lexical, davantage que des structures syntaxiques fines. Cette observation invite à interpréter les réseaux de similarité que nous construirons non comme des cartographies de styles au sens traditionnel, mais comme des cartographies de proximités thématiques et discursives. Les romans qui en partagent des caractéristiques tendent à être rapprochés dans l'espace vectoriel, indépendamment de leurs particularités stylistiques au sens strict.

Cette limite de notre opérationnalisation n'invalide pas la démarche, puisque l'on a vu que l'intertextualité ne se réduisait pas à la citation littérale ou à l'imitation stylistique. Elle inclut aussi, de manière centrale, la circulation de topoï, de configurations narratives, de réseaux sémantiques. En révélant quels textes activent des ressources lexicales et thématiques comparables, notre méthode donne accès à ce que l'on pourrait appeler, en empruntant à l'analyse du discours, une forme d'interdiscours[54] : non pas l'intertextualité des citations explicites ou des allusions conscientes, mais celle, plus diffuse, des formations discursives partagées, des répertoires sémantiques communs qui traversent les textes indépendamment de la volonté des auteurs. Précisément parce qu'elle échappe souvent à la conscience des auteurs et des lecteurs contemporains, cette dimension interdiscursive se prête particulièrement bien à une objectivation computationnelle à grande échelle.

Cette observation a des conséquences directes sur l'interprétation des résultats qui suivent. Au chapitre 8, nous verrons que notre modèle de détection des scènes d'aventures repère la matière thématique du genre mais ne saisit pas la modalisation de cette matière : une scène de duel chez Flaubert est détectée comme scène de danger alors même qu'elle est traitée sur un mode ironique. Au chapitre 5, certains romans policiers canoniques présentent un score de classification faible précisément parce que leur profil lexical est partagé avec d'autres registres (sentimental, feuilletonesque). Au chapitre 9, la contraction de la diversité discursive que nous mesurons après l'avènement contextuel du genre policier doit elle aussi s'entendre comme une réduction de l'espace thématique et lexical, non comme une homogénéisation stylistique au sens strict.

54. Dominique Maingueneau. *Genèses du discours*. Bruxelles : Mardaga, 1989.

5.6 Validation empirique

Les tests de cohérence interne et les analyses d'ablation présentés dans les sections précédentes valident la robustesse technique du modèle et précisent la nature des traits qu'il encode. Il reste cependant à démontrer que ces représentations vectorielles capturent des phénomènes littéraires réels, observables à l'échelle du corpus. Cette section présente une série d'expériences qui testent la capacité du modèle à retrouver des structures connues de l'histoire littéraire, en particulier la relation entre similarité textuelle et distance temporelle[55].

5.6.1 Similarité et distance temporelle

Une première validation consiste à vérifier que nos représentations vectorielles sont sensibles à l'évolution historique de la langue et des pratiques littéraires. L'intuition est simple : un roman de 1860 devrait ressembler davantage à un roman de 1870 qu'à un roman de 1990, parce que la langue, les conventions narratives et les préoccupations thématiques changent au fil du temps. Si nos embeddings ne capturaient pas cette dérive, ils seraient de mauvais capteurs des propriétés textuelles.

La figure 4.9 confirme cette attente. La similarité moyenne entre deux romans décroît avec la distance temporelle, passant de 0,520 pour des paires quasi contemporaines (moins de 10 ans d'écart) à 0,455 pour des paires séparés de deux siècles. Rapporté à l'échelle d'un siècle, l'effet est d'environ $\approx -0{,}037$, soit un glissement lent mais cumulatif. Pour donner un ordre de grandeur, cet effet temporel est du même ordre que la différence de similarité que nous observerons entre romans policiers et romans non-policiers dans nos expériences de classification (chapitre 5), ce qui signifie que la dérive diachronique constitue un facteur qu'il sera nécessaire de contrôler dans nos analyses.

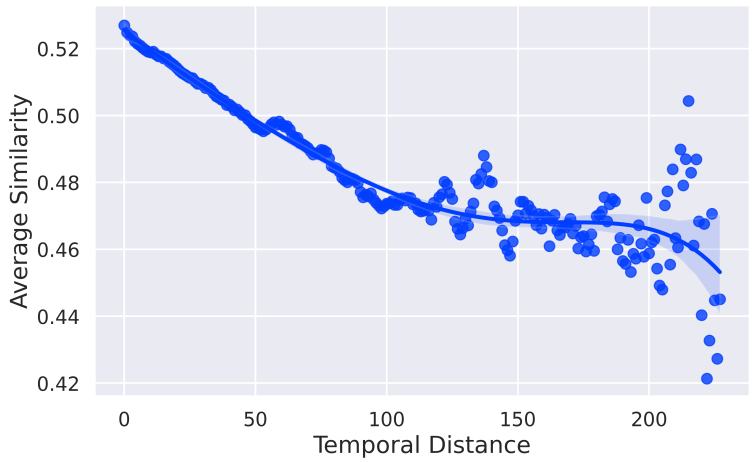


FIGURE 4.9 : Similarité moyenne en fonction de la distance temporelle entre les œuvres (en années).

La tendance est très nette en moyenne (corrélation de Pearson $r = -0{,}917$, $p \approx 1{,}7 \times 10^{-81}$ sur la courbe agrégée), mais la distance temporelle ne suffit pas à prédire la similarité d'une paire

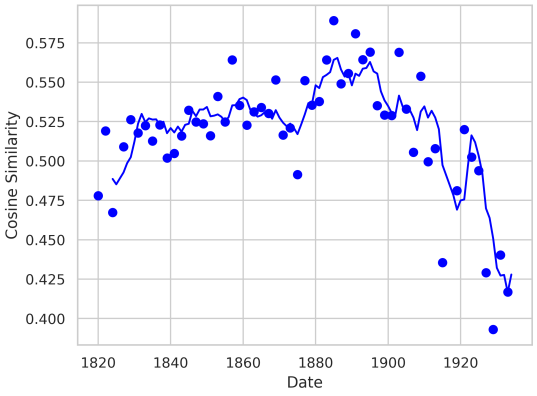
55. BARRÉ, « Latent Structures of Intertextuality in French Fiction ».

prise isolément (Pearson $r = -0{,}099$ sur les paires individuelles). C'est attendu : deux romans publiés la même année mais appartenant à des sous-genres différents (un roman sentimental et un roman policier, par exemple) peuvent être très éloignés dans l'espace vectoriel, tandis que deux romans policiers séparés de cinquante ans peuvent rester proches s'ils partagent les mêmes conventions. La distance temporelle structure la similarité en tendance, mais le genre, l'auteur et le registre narratif restent des facteurs au moins aussi puissants.

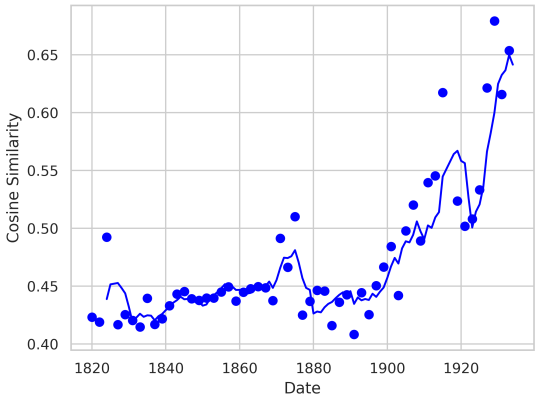
Nos embeddings encodent donc bien ce que Hughes et al.[56] appellent un « style d'époque », c'est-à-dire une configuration linguistique et thématique propre à chaque moment de l'histoire littéraire. Cette sensibilité diachronique est à la fois une validation, puisque nos représentations captent des propriétés réelles des textes, mais également un avertissement puisque toute comparaison entre des textes d'époques différentes devra tenir compte de cette dérive de fond.

5.6.2 Profil temporel des œuvres individuelles

Au-delà de cette tendance globale, le modèle permet d'explorer le profil temporel de chaque œuvre : comment sa similarité avec le reste du corpus évolue-t-elle selon les périodes ? Pour chaque roman, nous calculons sa similarité moyenne avec les textes publiés chaque année, en excluant les œuvres du même auteur pour neutraliser l'effet de l'idiolecte. Ce profil révèle la position de l'œuvre dans le réseau intertextuel diachronique.



(a) Victor Hugo, *Les Misérables (1862)*



(b) Gaston Leroux, *Le Mystère de la chambre jaune (1907)*

FIGURE 4.10 : Profils temporels de similarité pour deux romans : Les Misérables présente un pic de similarité avec les œuvres naturalistes des années 1880–1900, postérieures à sa publication ; *Le Mystère de la chambre jaune* montre une similarité croissante avec les décennies suivantes, reflétant son rôle fondateur dans le genre policier.

La figure 4.10 illustre deux profils contrastés. *Les Misérables* de Victor Hugo (1862) présente un pic de similarité non pas à sa date de publication, mais avec les œuvres des années 1880–1900. Plutôt qu'une anticipation au sens strict, ce décalage suggère que le vocabulaire et les thématiques du roman (misère sociale, bas-fonds parisiens, condition ouvrière) se retrouvent avec une densité

56. James M. HUGHES, Nicholas J. FOTI et al. « Quantitative patterns of stylistic influence in the evolution of literature ». *Proceedings of the National Academy of Sciences* 2012, p. 7682-7686. DOI : 10.1073/pnas.1115407109.

particulière dans la production naturaliste ultérieure, sans que la mesure de similarité permette à elle seule de trancher entre plusieurs explications possibles qui peuvent autant relever d'influences plus ou moins directes, ou une convergence thématique autour des mêmes réalités sociales.

Le Mystère de la chambre jaune de Gaston Leroux (1907) présente un profil différent. La similarité du roman avec le corpus croît de manière marquée après sa publication, passant d'environ 0,45 au XIXe siècle à plus de 0,65 dans les années 1920–1930. Ce profil est cohérent avec le rôle que l'historiographie attribue à Leroux dans l'avènement du genre policier, mais il reflète aussi plus largement la montée en puissance des conventions policières dans la production romanesque de l'entre-deux-guerres. L'interprétation de ces profils individuels dépasse le cadre de cette validation technique et sera reprise dans le chapitre 5 et le chapitre 6, où nous disposerons des outils nécessaires pour en préciser la portée.

5.6.3 Cadres collectifs : canon et archive

Les profils temporels individuels suggèrent que la position d'une œuvre dans le réseau intertextuel varie selon son statut. Pour tester cette hypothèse à l'échelle du corpus, nous comparons les profils de similarité des œuvres canoniques et des œuvres de l'archive, en utilisant les indicateurs de canonicité construits par Barré et al[57] et décrits dans la sous-section 2.1.

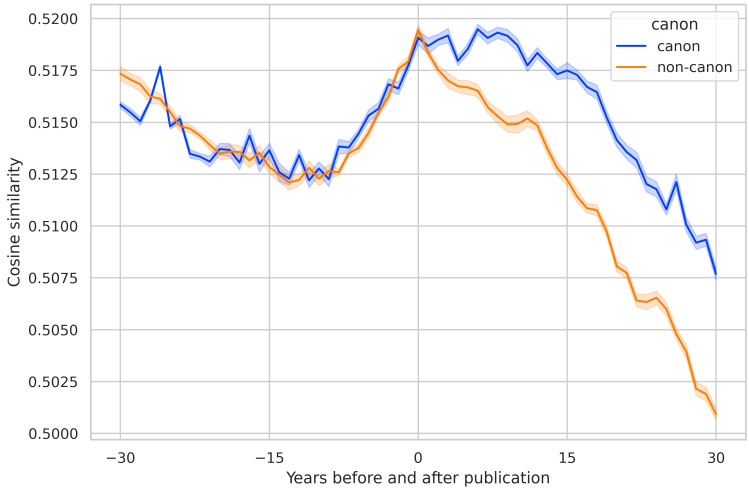


FIGURE 4.11 : Similarité textuelle avant et après publication : comparaison entre œuvres canoniques (bleu) et œuvres de l'archive (orange). Les courbes sont centrées sur la date de publication de chaque œuvre (année 0). L'erreur standard est affichée après 10 itérations d'échantillonnage stratifié.

La figure 4.11 révèle un profil particuler. Avant la publication (années −30 à 0), les deux courbes suivent une trajectoire similaire : les œuvres canoniques et non canoniques présentent le même profil de similarité avec leur contexte antérieur. En revanche, après la publication, les courbes divergent nettement. Les œuvres canoniques maintiennent une similarité élevée avec les textes postérieurs, tandis que les œuvres de l'archive voient leur similarité décroître plus rapidement.

57. BARRÉ, CAMPS et POIBEAU, « Operationalizing Canonicity ».

Cette divergence post-publication admet une interprétation en termes d'influence littéraire. Les œuvres qui deviendront canoniques exercent une influence durable sur la production ultérieure. Elles sont potentiellement imitées et leurs motifs narratifs ou thématiques se diffusent dans le réseau intertextuel. Les œuvres de l'archive, en revanche, n'ont qu'un impact limité et transitoire. Elles reflètent le style de leur époque sans le transformer durablement. Cette asymétrie suggère que la canonisation n'est pas seulement une question de réception critique ou institutionnelle, mais qu'elle laisse une trace mesurable dans les textes.

Ces expériences de validation empirique confirment que le modèle d'encodage capture des phénomènes littéraires réels et interprétables. La corrélation entre similarité et distance temporelle valide la sensibilité du modèle aux évolutions linguistiques et thématiques. Les profils temporels individuels révèlent des positions différenciées dans le réseau intertextuel. La divergence entre canon et archive suggère que les représentations vectorielles encodent des propriétés liées à l'influence littéraire.

6 Réseaux de similarité

6.1 Construction des graphes d'intertextualité

Le dernier niveau de notre architecture méthodologique utilise les représentations vectorielles décrites précédemment dans des réseaux de similarité. Les romans deviennent des nœuds reliés par des arêtes pondérées par leur proximité dans l'espace vectoriel. Ces graphes permettent de passer de la représentation vectorielle à une cartographie plus globale : familles de textes, communautés génériques, trajectoires historiques du roman policier, etc.

Le corpus d'entrée se compose d'un ensemble de fichiers au format *JSONL*, chaque fichier correspondant à un roman particulier. À l'intérieur de chaque fichier, le texte est sous la forme d'une séquence de fenêtres textuelles ou chunks, identifiées par un identifiant unique. Pour chaque fenêtre, on dispose d'un vecteur embedding de haute dimension (1024), ainsi que du texte original correspondant.

Cette granularité fine permet d'obtenir une mesure de proximité plus nuancée qu'une simple comparaison roman-contre-roman en bloc. De cette manière nous pouvons détecter des zones d'affinité localisées entre deux textes qui, globalement, pourraient sembler très différents. Elle rend aussi possible une forme d'explicabilité a posteriori, puisqu'on peut remonter, après avoir identifié une forte similarité entre deux romans, aux passages précis qui portent cette ressemblance, permettant ainsi une lecture proche et une validation qualitative des résultats quantitatifs.

6.2 Agrégation des similarités : du passage au roman

Il s'agit de transformer un ensemble potentiellement très large de similarités élémentaires entre segments textuels (tous les passages du roman A comparés à tous les passages du roman B) en une mesure synthétique unique représentant la proximité globale entre A et B ? Cette question d'agrégation n'est pas triviale car différentes stratégies capturent différents aspects de la relation intertextuelle. Nous avons donc implémenté plusieurs fonctions d'agrégation complémentaires,

chacune avec sa propre logique interprétative.

La première mesure proposée est la similarité moyenne sur l'ensemble des couples de passages possibles. Considérons deux romans A et B, segmentés respectivement en n et m passages, encodés comme des vecteurs $\mathbf{a}_i$ (pour $i = 1, \ldots, n$) et $\mathbf{b}_j$ (pour $j = 1, \ldots, m$). On commence par calculer la matrice complète des similarités cosinus entre tous les couples de passages, notée $\mathbf{C} \in \mathbb{R}^{n \times m}$, où chaque élément est défini par :

$$C_{ij} = \cos(\mathbf{a}_i, \mathbf{b}_j) = \frac{\mathbf{a}_i \cdot \mathbf{b}_j}{\|\mathbf{a}_i\| \|\mathbf{b}_j\|}$$

Cette matrice capture l'intégralité des proximités locales entre les deux textes. On définit ensuite la similarité globale comme la moyenne arithmétique de tous ces scores :

$$S_{\text{mean}}(A, B) = \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} C_{ij}$$

L'intuition derrière S_{mean} est qu'elle mesure une proximité diffuse à l'échelle des deux textes dans leur ensemble, reflétant la formalisation moyennée du texte par notre encodeur spécialisé. Toutefois, cette moyenne peut être tirée vers le bas si la majorité des passages sont peu comparables, ce qui arrive fréquemment dans des romans qui ne partagent qu'une poignée de scènes ou de motifs narratifs similaires. Autrement dit, S_{mean} favorise les textes dont la ressemblance est homogène sur toute leur longueur, mais pénalise les cas où quelques passages très proches coexistent avec une majorité de passages hétérogènes.

Pour remédier à cette limitation et mieux capter l'existence de zones d'accrochage localisées, nous introduisons une deuxième mesure fondée sur un seuillage. L'idée est de ne compter que les couples de passages dont la similarité dépasse un seuil τ relativement élevé (0.9 ou plus), reflétant des proximités vraiment fortes. Formellement, on définit :

$$S_\tau(A, B) = \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} \mathbf{1}[C_{ij} > \tau]$$

où $\mathbf{1}[\cdot]$ est la fonction indicatrice valant 1 si la condition est vraie et 0 sinon. Cette mesure compte essentiellement la proportion de couples de passages qui exhibent une similarité au-dessus du seuil. Son interprétation est différente de S_{mean} : elle favorise les cas où quelques passages très proches existent, sans exiger une homogénéité globale. Ainsi, deux romans qui partagent un motif narratif récurrent, un registre lexical spécifique ou un ensemble de formules phraséologiques peuvent obtenir un score S_τ élevé même si le reste de leurs contenus diverge. Cette mesure est particulièrement pertinente dans le cadre du genre policier, où certains topoï narratifs (la découverte du cadavre, la révélation finale, l'interrogatoire du suspect) sont susceptibles de se répéter d'un roman à l'autre avec des variations stylistiques mais une structure profonde similaire. Elle s'avère également adaptée à l'analyse des romans-feuilletons, qui, comme nous le verrons au chapitre 6, tendent à se défocaliser de l'intrigue criminelle durant de longs épisodes digressifs (par des intrigues sentimentales, descriptions de milieux sociaux, ou péripéties secondaires) avant d'y revenir ponctuellement : S_τ permet de capturer ces moments de convergence thématique sans

être pénalisée par les passages où le texte s'éloigne du noyau policier.

6.3 Détection de communautés

Pour des raisons de coût computationnel et de lisibilité, nous adoptons une stratégie de compression au niveau des romans : chaque texte est résumé par un unique vecteur obtenu en moyennant les embeddings de tous ses passages. Formellement, le vecteur représentant le roman A est défini par :

$$\bar{\mathbf{x}}_A = \frac{1}{n} \sum_{i=1}^{n} \mathbf{a}_i$$

Cette moyenne centrée capture une sorte de profil moyen du texte dans l'espace vectoriel. Si cette compression entraîne nécessairement une perte d'information fine (on ne sait plus, à ce stade, quels passages particuliers sont responsables de telle ou telle proximité), elle s'avère particulièrement efficace pour produire une vue d'ensemble cohérente du corpus et faciliter les calculs de similarité à grande échelle. La validité de cette moyenne repose sur l'hypothèse que les passages d'un même roman, bien que diversifiés, partagent suffisamment de propriétés communes pour que leur moyenne vectorielle soit représentative.

Une fois ces vecteurs moyens calculés pour l'ensemble des romans, on construit la matrice complète des similarités cosinus entre tous les couples de textes. Plutôt que de conserver toutes ces arêtes potentielles, ce qui produirait un graphe saturé, on applique une stratégie de parcimonisation fondée sur le principe des k plus proches voisins (k-nearest neighbors, ou kNN). Concrètement, chaque nœud du réseau (représentant un roman) est relié uniquement à ses k voisins les plus similaires selon la mesure de cosinus. Dans les visualisations présentées ici, nous avons fixé $k = 5$, valeur qui assure un bon compromis : suffisamment élevée pour que le graphe soit connexe ou peu fragmenté, suffisamment basse pour que la structure reste lisible et que les arêtes retenues soient réellement informatives. Le poids de chaque arête est défini par la similarité cosinus entre les deux nœuds concernés ; si une arête apparaît dans les choix réciproques des deux nœuds (c'est-à-dire si B fait partie des 5 plus proches voisins de A et réciproquement), on additionne les poids pour renforcer cette connexion bidirectionnelle.

Sur ce graphe pondéré et parcimonieux, on applique ensuite un algorithme de détection de communautés. Deux familles d'algorithmes sont particulièrement adaptées à cette tâche : Louvain [58] et Leiden [59]. L'algorithme de Louvain, très populaire pour sa rapidité et son efficacité, optimise itérativement une mesure de modularité en regroupant les nœuds de manière à maximiser la densité des connexions internes aux communautés par rapport aux connexions inter-communautés. L'algorithme de Leiden, variante plus récente, corrige certains défauts de Louvain (notamment les problèmes de communautés mal connectées) et offre généralement une meilleure stabilité sur les graphes pondérés. Le résultat de cette détection est une partition $\pi : V \to \{1, \ldots, K\}$ de l'ensemble des nœuds en K communautés disjointes. Chaque communauté

58. Vincent D Blondel, Jean-Loup Guillaume et al. « Fast unfolding of communities in large networks ». *Journal of Statistical Mechanics : Theory and Experiment* 2008, P10008. doi : 10.1088/1742-5468/2008/10/P10008.

59. V. A. Traag, L. Waltman et N. J. van Eck. « From Louvain to Leiden : guaranteeing well-connected communities ». *Scientific Reports* 2019, p. 5233. doi : 10.1038/s41598-019-41695-z.

regroupe des textes qui sont fortement inter-reliés et relativement isolés du reste du réseau, suggérant une cohésion interne forte selon les critères de similarité retenus.

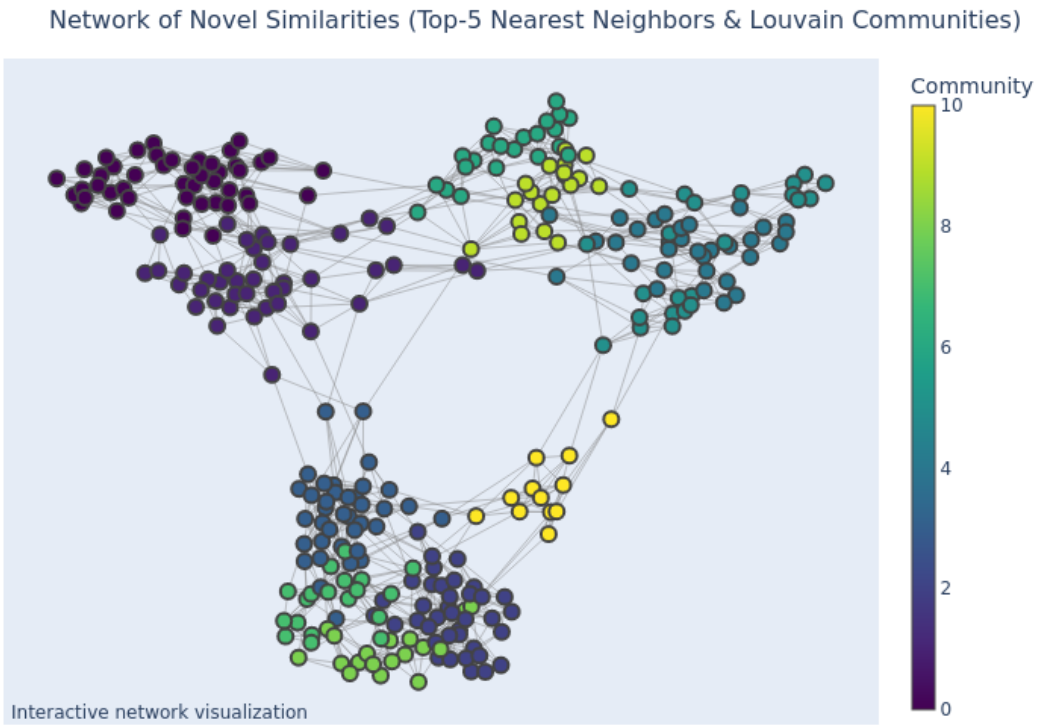


FIGURE 4.12 : Réseau de similarité entre romans policiers (Top-5 voisins) et communautés détectées (Louvain/Leiden).

La visualisation du réseau repose sur l'algorithme de Fruchterman et Reingold [60], une méthode de projection par forces (*force-directed layout*). Cet algorithme s'appuie sur deux principes : les sommets connectés par une arête doivent être proches les uns des autres, tandis que tous les sommets doivent éviter de se superposer. En pratique, des forces attractives s'exercent uniquement entre sommets voisins (reliés par une arête), tandis que des forces répulsives s'appliquent entre toutes les paires de sommets. Le déplacement de chaque sommet est limité par un paramètre de « température » qui décroît progressivement au fil des itérations : initialement élevée pour permettre des réorganisations importantes, cette température diminue jusqu'à ce que le système converge vers un état d'équilibre stable. Ce processus d'optimisation fait naturellement émerger des amas correspondant aux zones de forte densité relationnelle. Les romans d'une même communauté se retrouvent proches les uns des autres dans le plan de visualisation, tandis que les communautés distinctes forment des îlots séparés. La couleur des nœuds encode l'appartenance communautaire, permettant de distinguer visuellement les différentes familles détectées.

La figure 4.12 illustre cette cartographie pour le corpus policier. L'analyse détaillée de ces structures communautaires du genre et de ces nœuds-pivots sera développée au chapitre 5. Mais nous pouvons d'ores et déjà remarquer que sans aucune information de date ni d'étiquette externe,

60. Thomas M. J. FRUCHTERMAN et Edward M. REINGOLD. « Graph drawing by force-directed placement ». *Software : Practice and Experience* 1991, p. 1129-1164. DOI : 10.1002/spe.4380211102.

le graphe se structure spontanément en plusieurs amas densément connectés, reliés par des ponts plus clairsemés. Cette structuration émergente constitue un premier indice de la pertinence de la méthode : l'annotation a posteriori des communautés détectées montre qu'elles recoupent en grande partie des ensembles déjà repérés par l'histoire littéraire (proto-policier du XIXe siècle, roman d'enquête classique, polar contemporain).

Au-delà de cette partition grossière en trois macro-clusters, l'algorithme de Leiden permet d'identifier des sous-communautés plus fines, correspondant à des familles thématiques spécifiques au sein du genre. Le réseau révèle également des zones-charnières où certains romans jouent un rôle de pont entre regroupements, suggérant des hybridations ou des positions intermédiaires dans l'espace générique.

6.4 Interprétation des structures communautaires

Le résultat central de cette expérimentation est l'apparition de plusieurs amas relativement bien séparés dans l'espace de projection, correspondant aux communautés détectées algorithmiquement. Ces structures présentent trois types de configurations remarquables.

On observe des régions très denses où les romans sont fortement inter-connectés, formant ce qu'on peut appeler des familles fortement cohésives. Ces zones suggèrent l'existence de sous-ensembles textuels partageant un ensemble riche de propriétés communes, qu'il s'agisse de changements temporels stricts (un roman policier de 1870 et un de 2010 ne partagent pas les mêmes pratiques du genre), de conventions narratives (enquête à énigme versus roman noir), de cadres référentiels (milieu policier, univers criminel, bourgeoisie provinciale) ou de traits stylistiques (focalisation, régime dialogique). On commentera les principaux résultats de ce graphique de manière plus approfondie dans le chapitre 5.

Il convient toutefois de souligner que ces communautés n'ont pas valeur de genres naturels au sens où elles révéleraient des catégories ontologiques préexistantes dans le corpus. Elles matérialisent plutôt des zones de ressemblance dans l'espace vectoriel produit par le modèle de langue, zones qui émergent de la distribution des propriétés textuelles telles que captées par l'architecture neuronale. Cette conception est cohérente avec notre approche par ressemblance de famille (cf chapitre 3), où l'appartenance à un groupe n'est pas définie par un ensemble de caractéristiques nécessaires et suffisantes mais par un réseau de ressemblances partielles et de chevauchements. Deux romans d'une même communauté peuvent partager des propriétés A et B sans partager C, tandis qu'un troisième partage B et C sans A : c'est la structure relationnelle globale, plutôt qu'un prototype fixe, qui définit la cohésion du groupe. Cette perspective impose de compléter l'analyse algorithmique par une interprétation qualitative mobilisant les métadonnées et par des lectures proches permettant de caractériser précisément ce qui unit les membres d'une communauté (cf chapitre 5).

6.5 Contrôle qualitatif

Un complément méthodologique essentiel consiste à remonter des scores de similarité globaux aux segments textuels concrets qui les portent. Lorsque deux romans sont jugés très proches par

nos mesures d'agrégation, on peut identifier les passages précis responsables de cette proximité. Pour chaque fenêtre d'un roman cible A, on repère le passage le plus similaire dans un autre roman B, et on conserve le score obtenu ainsi que l'identifiant du passage correspondant. En triant ces correspondances par score décroissant, le chercheur peut consulter côte à côte les extraits appariés et vérifier qualitativement ce que la mesure quantitative a détecté.

Ces contrôles sont importants parce qu'un amas dans le réseau peut refléter des types de cohésion très différents. Deux romans peuvent être rapprochés parce qu'ils partagent un milieu social, un type de crime, un univers géographique, mais aussi parce qu'ils adoptent un même régime discursif ou parce qu'ils reprennent des patrons narratifs comparables. Seule la combinaison de l'analyse quantitative, des tests d'ablation et de la lecture qualitative des passages appariés permet de démêler ces différentes sources de similarité. Un travail de ce type sera mené au chapitre 5.

6.6 Limites méthodologiques

Plusieurs choix de paramètres affectent significativement les résultats, à commencer par la taille des fenêtres textuelles qui détermine l'échelle à laquelle la similarité est captée. Des fenêtres courtes permettent de détecter des échos ponctuels ou des formules récurrentes, tandis que des fenêtres longues capturent davantage des propriétés thématiques à plus large échelle.

Le choix de la fonction d'agrégation, ensuite, privilégie un type de relation entre romans plutôt qu'un autre. La moyenne sur tous les couples de passages (S_{mean}) favorise les similarités diffuses et homogènes, tandis que la mesure au seuil (S_τ) met en avant les zones d'accrochage ponctuel. Un couple de romans proche selon S_τ (partageant une scène-type) peut être éloigné selon S_{mean} (différents dans l'ensemble), et inversement. Le choix de la mesure doit donc être guidé par la question de recherche.

Enfin, il faut souligner qu'une arête dans ce réseau ne constitue pas une preuve d'influence intertextuelle au sens philologique du terme. La similarité vectorielle est un indice de proximité textuelle qui doit être croisé avec d'autres informations pour être interprété. L'analyse des passages appariés permet de distinguer entre ressemblances fortuites et véritables réemplois. Le réseau de similarité est un point de départ heuristique pour l'enquête littéraire et attire l'attention sur des configurations relationnelles. C'est ensuite au chercheur de transformer ces proximités en interprétations sur le phénomène étudié.

7 Usage encadré des modèles de langue génératifs

Dans cette thèse, nous avons ponctuellement recouru à des modèles de langue génératifs pour certains passages d'analyse qualitative, principalement dans les chapitre 5 et chapitre 6. Ce choix est lié à une orientation épistémologique centrale de notre travail, à savoir l'attention portée aux cas-limites. Dans le cadre de la classification automatique policier/non-policier, nous avons concentré l'analyse qualitative sur des ouvrages situés dans une zone intermédiaire (entre 0.45 et 0.55 de probabilité d'assignation), parce que ces textes génériquement instables permettent de mieux comprendre les conditions de reconnaissance du genre et ses tensions internes. Or ces

textes, précisément parce qu'ils sont marginaux, ne disposent pas toujours d'un appareil critique ou documentaire immédiatement accessible, et n'ont pas nécessairement fait l'objet d'une lecture préalable de notre part. Le recours à un modèle de langue a donc été destiné à faire émerger des hypothèses de lecture sur ces objets, non à déléguer l'interprétation littéraire.

L'usage a été encadré par le protocole suivant. Nous choisissons d'abord les points qui nous semblent les plus cruciaux pour éclairer le phénomène étudié. Lorsqu'un ouvrage particulier nécessite une première approche, nous soumettons le roman à un modèle de langue en lui demandant d'en produire un résumé. Une seconde requête est ensuite formulée en fonction du score obtenu dans la classification. Si l'ouvrage est classé au-dessus de 0.5, nous demandons pourquoi il ne correspond pas pleinement au canon du roman policier. S'il est classé en dessous, nous demandons au contraire pourquoi il s'en rapproche sans jamais tout à fait en relever. Les réponses produites ne sont jamais considérées comme des analyses achevées, mais comme des propositions interprétatives faibles destinées à orienter l'enquête critique.

Ces productions ne constituent en aucun cas des preuves. Aucune analyse issue de ces outils n'est mobilisée comme argument autonome dans la démonstration. Chaque hypothèse formulée de cette manière fait l'objet d'une double vérification. Nous revenons d'abord au texte afin de vérifier la présence effective des configurations invoqués. Nous confrontons ensuite ces propositions à la littérature critique existante lorsqu'elle est disponible, que ce soit pour confirmer, nuancer ou infirmer les suggestions produites par le modèle. L'autorité interprétative demeure humaine, et la preuve repose exclusivement sur le retour au texte et sur l'appui théorique. En ce sens, cet usage ponctuel déplace partiellement le régime de production des hypothèses, mais pas le régime de validation. Il s'inscrit dans la logique générale de cette thèse, qui cherche à articuler méthodes computationnelles et lecture proche.

Au cours de la préparation de ce manuscrit, nous avons également utilisé un modèle de langue génératif[61] dans le seul but d'améliorer ponctuellement la clarté rédactionnelle de certains passages. Les formulations ainsi proposées ont été systématiquement relues, vérifiées et, le cas échéant, révisées par l'auteur. L'entière responsabilité du contenu scientifique, analytique et rédactionnel de la thèse demeure celle de l'auteur.

8 Conclusion

Ce chapitre a explicité les choix qui organisaient la chaîne allant des fichiers océrisés de Gallica aux mesures de distance intertextuelle et aux graphes interconnectés de genres. Il ne cherche pas à proposer une théorie générale et abstraite des méthodes computationnelles, mais à rendre ces choix transparents et justifiés. En ce sens, ce chapitre propose de considérer les modèles statistiques comme producteurs d'arguments interprétatifs à part entière, dont la pertinence ne se mesure pas à la seule performance prédictive, mais à leur capacité à articuler et parfois déplacer nos questions de théorie littéraire à l'échelle de plusieurs milliers de romans. Les chapitres suivants mobiliseront ces différentes briques méthodologiques.

61. En l'occurrence, GPT-5 (Aaditya Singh, Adam Fry et al. *OpenAI GPT-5 System Card*. 2025. arXiv : 2601.03267 [cs.CL]) et Claude 4 (Anthropic. *Claude Opus 4 & Claude Sonnet 4 System Card*. 2025)

Partie II

Mise en pratique : le roman policier (1866-2020)

Chapitre 5

Le roman policier, un architexte modèle ?

Objectifs

Ce chapitre s'intéresse au roman policier, un genre littéraire majeur du XXe siècle. Après une présentation historique du genre, on discutera de ses caractéristiques architextuelles et de son intérêt pour une analyse computationnelle des genres littéraires. L'objectif est d'abord de déterminer une signature textuelle du roman policier à partir d'une modélisation supervisée fondée sur le lexique, en définissant les limites de cette signature à travers des tests de robustesse contrôlant les effets d'auteur et de période. L'analyse des traits discriminants et de la distribution des probabilités attribuées par le modèle permet d'évaluer la continuité du signal policier et d'éclairer les frontières du genre par une étude des cas limites. Enfin, une cartographie non supervisée par réseaux de similarité confirme une structuration temporelle sans recours aux étiquettes, tout en révélant des zones de transition et des romans-pivots qui objectivent les filiations souterraines au sein du genre policier.

Sommaire

1 Affirmation du genre **101**
2 Le roman policier, un architexte modèle ? une approche supervisée **104**
2.1 Protocole expérimental 105
2.2 Tests de robustesse : auteurs prolifiques et déséquilibres chronologiques 106
2.3 Caractéristiques discriminantes : anatomie de la signature policière 107
2.4 Distribution des probabilités : continuité du signal policier 108
2.5 Lecture qualitative des cas-limites : régime d'enquête et empreinte textuelle 109
2.6 Autres déplacements du régime d'enquête au XXe siècle 113
2.7 Un degré d'appartenance au roman policier 115
3 Mutations du roman policier : problèmes de la périodisation du genre **116**
3.1 Approche par spécification des trois périodes du genre 117
3.2 Approche par SVM roulant 118
4 Regroupements internes dans le roman policier : une approche non-supervisée **120**
4.1 Réseaux de similarité à l'échelle du roman 120
4.2 Du roman au réseau intertextuel 122
4.3 Du cas d'étude à la cartographie du sous-genre 125
4.4 Conclusion intermédiaire 128

> La littérature policière, depuis toujours, n'est pas considérée comme de la Littérature, mais bien comme un sous-genre destiné à de sous-lecteurs.
>
> *Anne* Martinetti. Le Masque : histoire d'une collection. *Amiens : Encrage, 1997, p. 7-8*

1 Affirmation du genre

Le roman policier s'est progressivement imposé comme un genre littéraire majeur dès la fin du XIXe siècle, pour devenir dans les années 1930 une référence incontournable dans l'imaginaire collectif. Régis Messac, un des premiers chercheurs à avoir étudié le roman policier, le décrit comme « un récit consacré avant tout à la découverte méthodique et graduelle, par des moyens rationnels, des circonstances exactes d'un crime mystérieux » [1]. La spécificité du genre repose avant tout sur une structure narrative spécifique (du crime ou du mystère vers sa reconstitution) impliquant une tension dramatique qui offre la promesse d'une lecture haletante.

Longtemps considéré comme de la littérature de second ordre, le genre s'est progressivement canonisé. Nous en retrouvons un premier signe en 1939 lorsqu'André Gide, écrivain déjà établi, déclare que « Simenon est un romancier de génie et le plus vraiment romancier que nous ayons dans notre littérature d'aujourd'hui » [2]. Cette déclaration a eu un fort retentissement car elle validait Simenon aux yeux d'une partie de la critique qui le considérait encore comme un simple artisan du roman de genre. Elle marque aussi une évolution plus large dans la perception du roman policier et du roman populaire comme espaces possibles d'innovation littéraire et d'exploration psychologique, anticipant ainsi la reconnaissance dont Simenon bénéficiera pleinement à partir des années 1960-1970, et qui se poursuivra jusqu'à la parution en 2003 aux éditions de *La Pléiade* d'un ensemble de romans choisis.

Le roman policier s'est affirmé dans un contexte de diffusion spécifique, celui de la littérature de masse et d'un marché du livre à flux tendu. Comme l'ont montré Artiaga et Letourneux [3], l'édition populaire française de l'après-guerre repose sur un modèle industriel où les collections spécialisées (le « Masque », la « Série noire », « Un mystère » aux Presses de la Cité, « Spécial Police » au Fleuve Noir) se livrent une concurrence pour occuper les points de vente, avec des cadences de publication de plusieurs titres par mois et des premiers tirages de plusieurs dizaines de milliers d'exemplaires. Ce modèle éditorial a des antécédents directs dans l'entre-deux-guerres. La collection du « Masque », lancée en 1927 par Albert Pigasse, d'abord poussive, est portée par les succès d'Agatha Christie et d'autres auteurs anglophones (Williams, Vance, Doyle) [4]. Son succès commercial inaugure un dispositif qui sera massivement reproduit par la suite, dans lequel la collection elle-même devient une marque générique, garantissant au lecteur la conformité de

1. Régis Messac. *Le "Detective Novel" et l'influence de la pensée scientifique*. Genève : Slatkine Reprints, 1975 [1929], p. 9.
2. Pierre Assouline. *Simenon : biographie*. Paris : Julliard, 1992.
3. Loïc Artiaga et Matthieu Letourneux. *Aux origines de la pop culture : le Fleuve noir et les Presses de la Cité au cœur du transmédia à la française, 1945-1990*. Paris : la Découverte, 2022.
4. Martinetti, *Le Masque*.

chaque titre à un ensemble de conventions narratives identifiables.

C'est ce dispositif éditorial, bien plus qu'un mouvement littéraire au sens classique, qui contribue à façonner l'âge d'or du roman policier en stabilisant un horizon d'attente partagé entre auteurs, éditeurs et lecteurs. Cet âge d'or se fonde sur la popularité du *whodunit*[5], formule narrative dans laquelle un crime (le plus souvent un meurtre) est commis au début du récit et où l'identité du coupable n'est révélée qu'au terme d'une enquête menée par un détective, le lecteur étant invité à résoudre l'énigme en même temps que lui. Le *whodunit* ne désigne pas seulement un sous-genre parmi d'autres, il incarne pendant plusieurs décennies l'essence même de ce que le public identifie comme « un roman policier ».

Ces motifs sont présents sur toute la longueur du XXe siècle dans le roman policier, mais la spécificité du *whodunit* réside dans la structuration de l'intrigue en puzzle, et la dissémination d'indices pour que le lecteur puisse deviner l'auteur du crime en même temps que le détective, généralement à partir d'un cercle restreint de suspects. Todorov[6], dans son essai *Typologie du roman policier* (1966), analyse la spécificité du *whodunit* en soulignant une double structure narrative : l'histoire cachée du crime et celle, visible, de l'enquête. Selon lui, ces deux récits ne s'entrecroisent pas directement, car l'enquête reconstitue seulement les événements passés sans pouvoir les modifier. Cette structure distingue le *whodunit* d'autres fictions policières, engageant le lecteur dans une démarche active de reconstruction du crime, semblable à celle du détective.

Il y a cependant un ensemble de textes publiés bien avant cette période que l'on peut rapprocher de l'esthétique de ce genre. Nous le verrons dans ce chapitre et dans le suivant, mais pour que le genre se constitue pleinement, il a fallu s'extirper des codes du roman-feuilleton, mode de publication majeur à la fin du XIXe siècle et qui a vu paraître les premiers romans considérés comme policiers, notamment les écrits d'Émile Gaboriau.

Le genre s'inscrit pleinement dans une logique architextuelle, telle que définie par Genette et introduite aux chapitres précédents. Le genre se caractérise par une signature générique forte, où la mise en scène de l'enquête, la progression de l'intrigue et la récurrence de certains archétypes constituent autant de repères architextuels pour le lecteur. L'archétype du personnage de détective, qui sera l'objet du chapitre 6, est la figure tutélaire du genre et un des vecteurs privilégiés de l'intertextualité. Cette dernière se manifeste pleinement dans la récurrence de figures emblématiques, à l'échelle d'une série spécifique (prenons par exemple le personnage de Lupin et ses apparitions dans 56 romans ou nouvelles par exemple), mais également dans la reconfiguration de l'image de l'enquêteur au fil du XXe siècle, de Rouletabille à Adamsberg, en passant par Maigret. Chaque nouvelle œuvre, tout en renouvelant certains éléments, se réfère aux modèles établis, créant un réseau de références partagées entre auteurs et lecteurs.

Cependant, ce n'est pas une œuvre isolée, ni même un auteur, qui va définir le roman policier, mais bien un réseau de textes interconnectés partageant des conventions communes. Si aucun exemplaire publié dans la collection du *Masque* ne satisfait pleinement à lui seul toutes les attentes du lecteur du genre, c'est précisément parce que le roman policier ne peut se réduire

5. Le terme, contraction familière de *who done it ?* (« qui l'a fait ? »), apparaît pour la première fois en 1930 sous la plume de Donald Gordon, critique littéraire au *News of Books*, qui qualifie le roman *Half-Mast Murder* de « whodunit satisfaisant ». Voir https://www.merriam-webster.com/dictionary/whodunit.

6. Todorov, « Typologie du roman policier ».

à une seule œuvre ou à un modèle unique. Il y a plutôt une pluralité de formes qui s'articule autour d'une même structure architextuelle : Edgar Allan Poe jette les bases de l'énigme dans ses nouvelles, Émile Gaboriau développe l'enquête méthodique à l'échelle du roman, Gaston Leroux l'institutionnalise, et Agatha Christie popularise le *whodunit*. Simenon, enfin, affine la veine psychologique et la tension latente de l'atmosphère générale du récit. Chacun apporte sa pierre à l'édifice, sans pour autant fixer définitivement l'essence du policier : la véritable unité vient de la logique d'enquête et des attentes du lecteur, qui se renouvellent avec le temps. C'est précisément cette variation autour du prototype qui produit le plaisir de la lecture de genre permettant ainsi de conserver toute l'attention du lecteur.

Cette stabilité de la cohérence architextuelle du roman policier s'explique en partie par la popularité de ce genre et par des règles éditoriales qui visent à répondre aux attentes de lecteurs d'une littérature de masse. Cette codification est si forte que les auteurs en viennent même à énoncer explicitement les règles du genre[7]. En 1928, le romancier et critique américain S. S. Van Dine publie ses *Twenty Rules for Writing Detective Stories*[8], un ensemble de prescriptions détaillant ce qu'un roman policier doit et ne doit pas contenir (un seul coupable, pas d'histoire d'amour, pas de surnaturel, etc.). L'année suivante, le théologien et auteur britannique Ronald Knox propose un *Detective Story Decalogue*[9], c'est-à-dire un ensemble de dix commandements du roman policier, calqué sur la forme du décalogue biblique, qui édicte des interdits similaires.

Ces codifications accompagnent les premières années de ce que l'historiographie appelle l'*Âge d'Or* du roman policier, période qui s'étend approximativement de la fin des années 1920 aux années 1950 et qui est dominée par les figures d'Agatha Christie ou de Dorothy L. Sayers. Elles témoignent d'un moment où le genre est suffisamment reconnu pour que ses praticiens puissent en formuler les lois, et où ces lois sont suffisamment partagées pour faire l'objet d'un consensus au sein d'une communauté.

Cette structuration architextuelle est également renforcée par des stratégies éditoriales :

> Les éditeurs de littérature populaire ont longtemps moins cherché à valoriser l'originalité de l'œuvre qu'à la rapporter à un modèle sériel la présentant comme une variante d'un ensemble plus large dont l'unité architextuelle était exhibée par la présentation du livre : titre de collection, extrait du catalogue, illustration de couverture toujours confiée au même artiste, etc[10].

Ce cadre éditorial a contribué à consolider une image cohérente du genre et à familiariser les lecteurs avec un ensemble de codes narratifs récurrents. Le roman policier s'appuie ainsi sur une communauté de lecteurs avertis qui savent reconnaître les motifs récurrents et anticiper les jeux d'attente qui structurent l'intrigue. Or c'est précisément cette familiarité qui rend possible, et même appelle, l'écriture sérielle. Un lecteur qui connaît les conventions du genre peut apprécier les variations qu'un auteur y apporte d'un roman à l'autre, chaque nouvel opus se lisant à la

7. Camille Fort. « Détectives et décalogues : pour une éthique de l'enquête ? » *Études anglaises* 2003, p. 285-297. doi : 10.3917/etan.563.0285.

8. S. S. Van Dine. « Twenty Rules for Writing Detective Stories ». *American Magazine* 1928, p. 129-131.

9. Ronald Knox. « Introduction ». *The Best Detective Stories of 1928–29*. Sous la dir. de Dorothy L. Sayers. London : Faber & Faber, 1929, p. 9-15.

10. Letourneux, *Fictions à la chaîne*, p. 149.

lumière des précédents. Simenon illustre parfaitement cette mécanique avec plus d'une centaine de romans et nouvelles consacrés au commissaire Maigret, où chaque œuvre propose une variation sur des motifs établis (la patience empathique de l'enquêteur, les intérieurs clos (notamment les cafés, hôtels et commissariats), la présence rassurante de Madame Maigret) tout en renouvelant l'intérêt narratif. Cette multiplicité crée un réseau de références internes où chaque texte devient un point d'entrée potentiel dans un univers familier, dont la cohérence repose sur la répétition reconnaissable de ces motifs.

Le roman policier constitue, de fait, un objet privilégié pour toute tentative d'analyse computationnelle des genres littéraires. En premier lieu, il se caractérise par une forte dimension architextuelle : chaque nouveau roman, que ce soit ceux de Leroux au début du XXe siècle, ceux de Simenon au milieu du XXe, ou encore ceux de Fred Vargas à l'époque contemporaine, reprend et modifie des motifs qui lui préexistent, tout en contribuant à façonner des attentes de lecture qui influencent, à leur tour, les récits suivants. C'est justement cette intrication réciproque entre textes passés et textes nouveaux, cette logique de références croisées, qui rend le policier idéal pour une cartographie computationnelle des structures relationnelles.

Ensuite, le policier francophone couvre plus d'un siècle de production, depuis le passage du roman-feuilleton à l'enquête moderne. Il s'agit d'un genre populaire où l'offre éditoriale est multiple, comme l'illustre le corpus *Chapitres*, qui comprend 371 romans policiers étiquetés manuellement. Cette abondance de données offre un terrain empirique particulièrement riche pour toute analyse statistique ou algorithmique : plus il y a de textes, plus il est possible de quantifier et de visualiser les récurrences, les divergences ou encore l'émergence de sous-tendances au sein du genre.

Enfin, le roman policier illustre parfaitement l'idée de *ressemblance de famille* : nul ne saurait définir le genre par un unique critère. On y observe plutôt un ensemble de caractéristiques partagées qui varient d'une œuvre à l'autre. Le but de l'approche computationnelle est alors d'évaluer quantitativement jusqu'à quel point ces traits se recouvrent entre les romans, et comment ils évoluent dans le temps, pour mieux comprendre ce qui fait du roman policier un genre à part entière.

2 Le roman policier, un architexte modèle ? une approche supervisée

Une première expérience quantitative nous permet d'illustrer la tension entre définition contextuelle et formaliste des genres littéraires que nous évoquions au chapitre précédent. Nous reproduisons dans le contexte francophone les expériences d'Underwood [11] sur les genres littéraires, que nous avons discutées au chapitre 3. Il s'agit d'entraîner un modèle statistique à prédire le genre d'un texte à partir de données textuelles, ainsi qu'un ensemble d'étiquettes fondées sur des listes constituées par des chercheurs. Dans ce cas, nous regardons les textes étiquetés *policier* par l'ANR *Chapitres* [12].

11. Underwood, *Distant horizons*, Chapitre 2, « The life spans of genres », p. 34–67.
12. Leblond, *Corpus Chapitres*.

2.1 Protocole expérimental

Pour tester empiriquement l'hypothèse d'une signature textuelle stable du roman policier, nous avons mis en place une série d'expérimentations de classification supervisée à partir du corpus *Chapitres*. Celui-ci comprend 371 romans étiquetés comme *policier* sur la base d'un travail d'étiquetage manuel, auxquels s'ajoutent plusieurs milliers de textes appartenant à d'autres sous-genres (roman sentimental, roman d'aventures, roman historique, etc.). Nous renvoyons au chapitre 4 pour plus de détails sur les choix méthodologiques.

L'objectif est de vérifier dans quelle mesure il est possible de prédire l'étiquette *policier* à partir des seuls indices lexicaux du texte intégral, sans recourir à des métadonnées. La tâche est formulée comme une classification binaire, la classe positive regroupe les romans policiers, celle négative un échantillon aléatoire des autres textes.

Sur le plan des représentations, nous partons d'un modèle de sac-de-mots très simple, afin de rester aussi proche que possible des protocoles d'Underwood (qu'il adopte pour leur simplicité et leur interprétabilité lorsqu'il sont associés à certaines techniques de modélisation) pour l'anglais tout en les adaptant au français. Les romans sont tokenisés, normalisés et vectorisés avec un sac-de-mots[13]. Pour limiter le nombre de dimensions, nous retenons les 1 000 mots les plus fréquents dans un échantillon aléatoire de 20 % du corpus, ce qui permet de constituer un vocabulaire des mots les plus fréquents. Deux versions du vocabulaire sont construites : l'une incluant l'ensemble des formes, l'autre supprimant une liste de mots-outils français nettoyée et normalisée, afin de tester l'impact de ces marqueurs plutôt structurels et inconscients[14] que thématiques.

Chaque roman est alors représenté par un vecteur de fréquences relatives sur ces 1 000 mots, ce qui donne une matrice *documents* × *caractéristiques* sur laquelle nous venons greffer l'annotation de référence *policier* ou *non policier* issue du fichier de métadonnées. Un premier pré-traitement consiste à équilibrer la distribution des classes. Le corpus brut est en effet très déséquilibré : le policier y reste minoritaire. Pour éviter que le modèle n'apprenne surtout la classe majoritaire, nous procédons à un échantillonnage par le bas systématique de la classe *non policier* : à chaque répétition, nous tirons au hasard autant de romans *non policiers* que de *policiers*, puis nous mélangeons l'ensemble. Le modèle est donc toujours appris et testé sur un corpus parfaitement équilibré entre les deux classes.

Le cœur du *pipeline* de classification repose sur une machine à vecteurs de support (SVM) linéaire. Nous avons explicité ce choix au chapitre 4, il s'agit d'un modèle robuste sur des représentations de type sac-de-mots de grande dimension. De plus, le noyau linéaire permet d'interpréter directement les poids appris comme des coefficients attribués à chaque mot.

L'évaluation adopte un protocole de validation croisée en K plis ($K = 5$). Pour chaque expérience, le corpus équilibré est divisé en cinq sous-ensembles ; le modèle est entraîné sur quatre plis et testé sur le cinquième, puis l'opération est répétée en permutant les rôles des plis. Afin de réduire l'effet des choix aléatoires, ce protocole est répété N = 100 fois avec des *seed* aléatoires différentes. Pour chaque répétition, nous calculons :

13. réalisé avec le *CountVectorizer* de la librairie Python Scikit-learn
14. Pennebaker, *The secret life of pronouns*.

1. la *balanced accuracy* (moyenne des rappels par classe), plus adaptée à un contexte où l'on équilibre artificiellement les classes ;
2. la matrice de confusion 2 × 2 (vrai policier / faux policier × vrai *non policier* / faux non policier).

Les matrices de confusion sont ensuite sommées pour obtenir une matrice agrégée qui donne, sur l'ensemble des répétitions, le nombre moyen de bonnes et de mauvaises classifications. Les coefficients linéaires du SVM sont eux aussi moyennés, ce qui permet d'identifier un ensemble stable de mots fortement associés à la classe *policier* ou, au contraire, à la classe *non policier*. Les prédictions de chaque jeu de test sont exportées dans un tableau qui indique pour chaque roman sa classe réelle, la classe prédite, la probabilité associée et un indicateur d'accord ou de désaccord. Ce tableau sert de base à une analyse qualitative des erreurs.

2.2 Tests de robustesse : auteurs prolifiques et déséquilibres chronologiques

La performance du modèle statistique pourrait être surestimée par deux effets parasites : (i) la présence d'auteur · rices très prolifiques, dont l'idiolecte peut *fuiter* entre entraînement et test, et (ii) une forte inégalité de couverture chronologique, susceptible d'amener le modèle à distinguer des périodes plutôt que le roman policier en tant que tel. Pour tester la robustesse du signal, quatre configurations de validation ont donc été comparées (Tableau 5.1).

Méthode de validation	**Balanced Accuracy**
5-fold standard	0,890
5-fold avec limitation temporelle (10 romans/décennie)	0,868
GroupKFold par auteur	0,832
StratifiedGroupKFold (auteur et période)	0,809

Table 5.1 : Robustesse du classificateur selon différentes stratégies de validation.

La validation croisée standard (5-fold) sert de référence (0,890). Un échantillonnage contrôlé par décennies (10 romans maximum par décennie) permet de limiter la surreprésentation de certaines périodes : la performance reste élevée (0,868), ce qui signifie que le découpage temporel n'est pas un facteur déterminant. Une validation *GroupKFold* par auteur, qui impose qu'aucun auteur ne soit présent à la fois dans l'entraînement et dans le test, réduit davantage la performance (0,832). Enfin, la combinaison des deux contraintes (*StratifiedGroupKFold*) produit la baisse la plus marquée (0,809). Cette dégradation progressive suggère qu'une partie du pouvoir prédictif provient de régularités auctoriales, particulièrement chez les auteurs prolifiques (80 romans rien que pour Simenon, 33 pour Leblanc, 22 pour Leroux), sans pour autant faire disparaître le signal générique : même sous contraintes maximales, la performance reste nettement supérieure au hasard (0,5). Le modèle capture donc des invariants lexicaux transversaux associés au policier, tout en révélant que l'évaluation peut être partiellement amplifiée par des effets d'auteur lorsque ceux-ci ne sont pas explicitement contrôlés.

2.3 Caractéristiques discriminantes : anatomie de la signature policière

L'examen des coefficients du modèle SVM permet de préciser la nature de la signature lexicale du roman policier. La figure 5.1 ci-dessous présente les vingts mots les plus discriminants dans chaque direction.

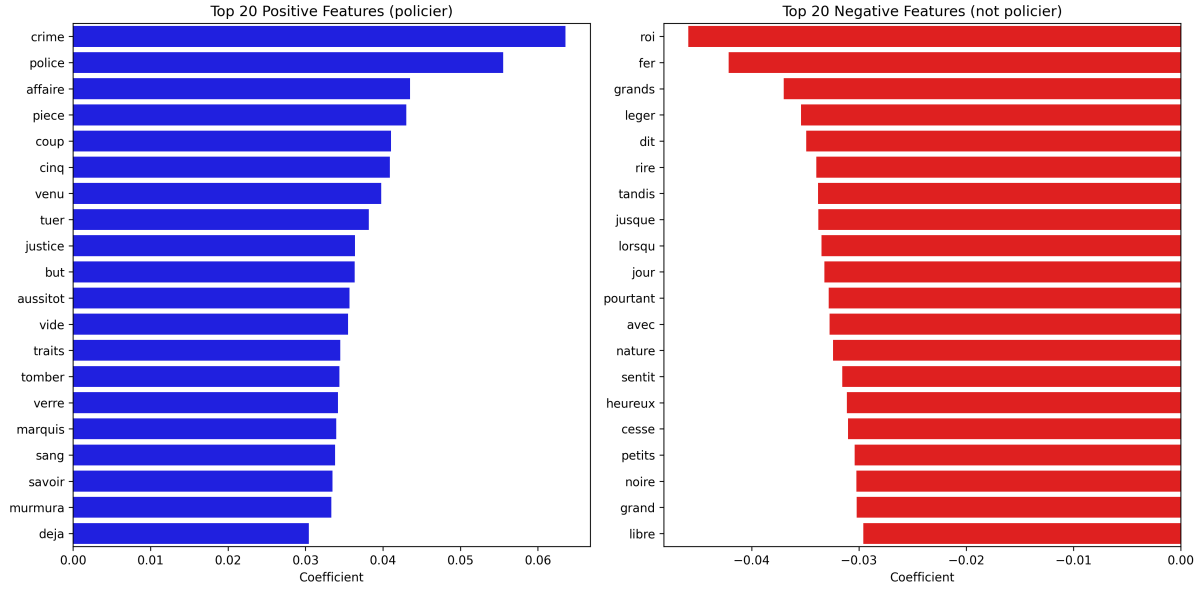


FIGURE 5.1 : Coefficients discriminants pour assigner le roman policier

L'analyse computationnelle fait apparaître une forte stabilité de certains motifs ou traits textuels sur le temps long, ce qui corrobore l'idée que certains genres, dont le policier, présentent une persistance voire une forme de cohérence historique [15].

Caractéristiques à coefficient positif (augmentent la probabilité *policier*). Du côté des poids positifs (Figure 5.1), le modèle met en avant un noyau lexical explicitement associé au crime et à l'institution judiciaire : « crime », « police », « justice », « tuer », « sang », ainsi que « affaire ». Autour de ce noyau apparaissent aussi des marqueurs plus « narratifs » ou situationnels (« venu », « aussitot », « déjà », « but ») et des éléments concrets (« pièce », « verre »), qui suggèrent que la décision du modèle n'est pas seulement thématique, mais s'appuie également sur des routines discursives de l'action et de la scène. La présence de formes comme « murmura » et « savoir » indique que des verbes de parole et de cognition peuvent contribuer au signal, au moins dans cette agrégation des coefficients.

Caractéristiques à coefficient négatif (diminuent la probabilité *policier*). Les poids négatifs sont dominés par des connecteurs et des mots de structuration du récit (« tandis », « jusque », « lorsqu », « pourtant », « avec »), ainsi que par des adjectifs généraux (« grands »/« grand », « petits », « noire », « léger », « libre ») et quelques items thématiques (« roi », « fer »). On note aussi « sentit » et « heureux », qui pointent plutôt vers un régime affectif. Autrement dit, dans

15. UNDERWOOD, « The Life Cycles of Genres ».

cette figure, l'opposition captée par le modèle n'oppose pas directement « crime et amour », mais plutôt un noyau institutionnel et violent (« crime/police/justice/tuer/sang ») à des formes plus générales de description narrative.

On pourrait multiplier l'analyse des lemmes spécifiques, mais on se heurte assez rapidement au problème interprétatif des sac-de-mots. Sans contexte il est en effet assez difficile de tirer des conclusions sur la nature de l'intrigue ou la méthode de l'enquêteur. Malgré tout cela reste un résultat encourageant : le modèle se base sur les indices attendus, et obtient une bonne performance.

2.4 Distribution des probabilités : continuité du signal policier

La figure 5.2 [16] montre deux ensembles, des points bleus qui sont les textes annotés à la main comme *policier* et des points oranges, un échantillon de romans qui ne sont pas *policier* dans le corpus *Chapitres* [17]. L'axe des abscisses qui correspond à la période considérée, 1811–2020. L'axe des ordonnées correspond à la probabilité d'appartenance au genre policier attribuée selon notre modèle.

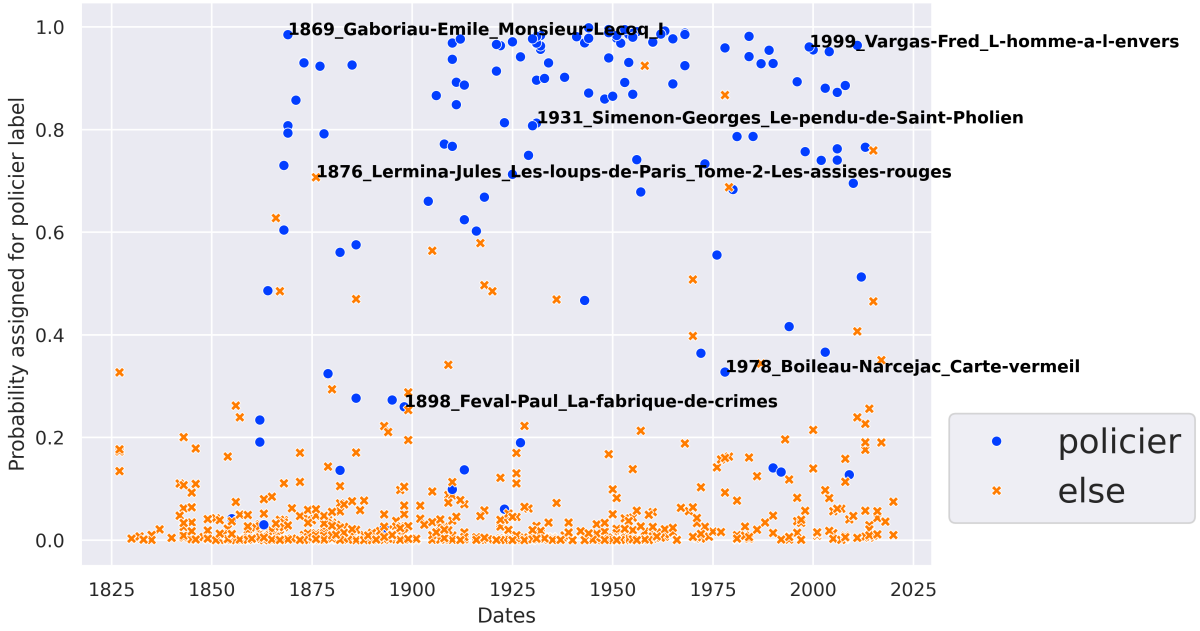


FIGURE 5.2 : Classification automatique du roman policier

L'examen de la distribution des probabilités attribuées par le modèle révèle une structure bimodale très nette. Sur un corpus équilibré de 594 romans (297 *policiers* / 297 *non policiers*), la plupart des romans annotés comme *policier* se situent dans la zone supérieure, marquée par des scores élevés : 242 textes, soit 81,48 % des policiers, obtiennent une probabilité supérieure à 0,70. Inversement, les romans annotés comme *non policiers* se concentrent massivement dans la zone de faible scores : 236 textes, soit 79,46 % des *non policiers*, obtiennent une probabilité

16. Voir le lien ci-après pour un aperçu interactif - Version HTML
17. LEBLOND, *Corpus Chapitres*.

inférieure à 0,30. Cette polarisation se lit aussi dans la partition globale du corpus : 257 textes sont dans la zone basse (<0,30), 258 dans la zone haute (>0,70), et seulement 79 dans l'intervalle intermédiaire, ce qui confirme que le modèle produit des décisions majoritairement tranchées plutôt qu'un continuum uniforme.

La zone intermédiaire (0.30/0.70) regroupe toutefois 79 romans (13.30 % du corpus), et elle contient 45 *non policiers* (soit 15.15 % des *non policiers*) contre 34 *policiers* (11.45 % des policiers). Autrement dit, l'ambiguïté du modèle ne correspond pas seulement à des *policiers* atypiques : elle est aussi portée, et même légèrement davantage, par des textes *non policiers* qui partagent avec le policier une partie de ses routines narratives (enquête, indices, révélation progressive, conflit judiciaire ou criminel). À l'autre extrémité, les erreurs franches restent minoritaires : seuls 16 *non policiers* (5.39 %) basculent dans la zone haute (>0.70), tandis que 21 *policiers* (7.07 %) tombent dans la zone basse (<0.30). Nous obtenons ainsi une lecture simple : le modèle repère un cœur générique très stable (zones basse et haute), tout en isolant une marge structurée (zone intermédiaire) qui matérialise précisément les zones de contact, d'hybridation et de transition où la notion de « roman policier » devient moins binaire et plus graduelle.

2.5 Lecture qualitative des cas-limites : régime d'enquête et empreinte textuelle

L'analyse qualitative des points les plus surprenants permet de préciser ce que le modèle reconnaît comme empreinte textuelle du roman policier. Nous distinguons trois configurations : les faux positifs (textes étiquetés manuellement comme *non policier* mais reconnus comme *policier* par le modèle), les faux négatifs (textes étiquetés manuellement comme *policiers* mais reconnu comme *non policier*), et les cas de convergence (textes où annotation et prédiction s'accordent). Nous signalons que la plupart des citations n'ont pas de page exacte, puisque nous disposons de fichiers *.txt* n'ayant plus cette information.

Le choix des romans commentés ici n'est pas aléatoire. Parmi l'ensemble des textes situés dans la zone intermédiaire de classification (entre 0.4 et 0.6 de probabilité d'assignation), nous avons retenu les cas qui nous semblaient les plus éclairants pour comprendre ce que le modèle capte et ce qui lui échappe. Certains ont été retenus parce qu'ils sont bien connus de l'histoire littéraire (Gaboriau, Féval), ce qui permet de confronter le jugement du modèle à un savoir critique établi. D'autres ont été retenus précisément parce qu'ils sont peu étudiés et que leur position dans l'espace de classification soulevait une question intéressante sur les frontières du genre. Pour ces derniers, qui ne disposent pas toujours d'un appareil critique immédiatement accessible, nous avons ponctuellement recouru à des modèles de langue génératifs afin de faire émerger des hypothèses de lecture, selon le protocole décrit en section 7. Ces hypothèses ont ensuite été vérifiées par un retour au texte et, lorsque c'était possible, par la confrontation à la littérature critique existante.

2.5.1 Faux positifs : enquête sans genre policier

Vidocq, *Mémoires* (tomes III et IV). Les *Mémoires* de Vidocq, publiés en quatre tomes entre 1828 et 1829, constituent l'autobiographie professionnelle de l'ancien bagnard devenu chef de la brigade de Sûreté sous la Restauration. L'ouvrage ne relève pas du roman policier au sens strict, mais il est régulièrement cité par l'historiographie comme l'un de ses précurseurs, en raison du rôle fondateur de la figure de Vidocq dans l'imaginaire de l'enquête criminelle. Dans le corpus *Chapitres*, les mémoires de Vidocq sont disponibles par tome, et les tomes III et IV ont retenu notre attention parce qu'ils présentent des scores de classification très contrastés alors que les tomes I et II, plus centrés sur la jeunesse de Vidocq et ses années de bagne, obtiennent des scores plus bas et posent des questions moins éclairantes pour notre propos.

Le tome III obtient un score élevé ($p = 0{,}76$). On constate qu'il est saturé du vocabulaire de l'action policière : les mots de la surveillance, de la ruse, du piège, de l'arrestation y sont fréquents. À l'inverse, le tome IV ($p = 0{,}22$) est traversé par un vocabulaire sensiblement différent. Vidocq y développe une critique du système pénitentiaire, propose des typologies de criminels, des classements, des considérations générales sur la pénalité. Le lexique dominant y est celui de l'essai et de la classification (catégories, types, systèmes, réformes) plutôt que celui de l'enquête.

Rappelons que notre modèle, fondé sur les fréquences des mots les plus courants, ne perçoit ni la structure narrative ni l'intention de l'auteur : il enregistre simplement que certains mots caractéristiques du corpus policier apparaissent plus ou moins souvent. Vidocq apparaît ainsi comme un auteur pré-générique, chez qui le vocabulaire de l'enquête est déjà très présent mais reste mêlé à des registres (mémorialiste, essayiste, doctrinal) que le genre policier ultérieur éliminera progressivement de son répertoire.

Zaccone, *Une vengeance anglaise* (1860). Pierre Zaccone (1818–1895) est un feuilletoniste prolifique du Second Empire, auteur de nombreux romans-feuilletons dont plusieurs relèvent du récit criminel. Son roman *Une vengeance anglaise* est annoté comme *non policier* dans notre corpus, mais le modèle lui attribue une probabilité élevée ($p = 0{,}86$). Ce score élevé peut s'expliquer dans le vocabulaire, puisque le texte est saturé de termes renvoyant au crime, au secret et à la dissimulation (« mystère », « déguisement », « soupçon »), au dévoilement progressif de la vérité, et aux bas-fonds urbains dont Kalifa [18] a montré qu'ils constituaient un topos central de la culture criminelle du XIXe siècle. On y trouve également un vocabulaire de la surveillance et de la machination qui, dans notre modèle, est fortement corrélé au corpus policier.

Une vengeance anglaise se distingue toutefois du roman policier tel qu'il se stabilisera plus tard, parce que ce lexique n'est pas organisé autour d'une figure d'enquêteur. Le moteur du récit est une vengeance longuement préparée et non une investigation. Mais du point de vue strictement lexical, la différence est peu perceptible par un modèle fondé sur les fréquences de mots les plus courants, qui ne distingue pas entre un personnage qui enquête et un personnage qui manœuvre dans l'ombre. *Une vengeance anglaise* illustre ainsi une zone que l'on pourrait qualifier de proto-policière, au sens où Kalifa parle de « récits du crime » [19] antérieurs à la constitution du

18. Kalifa, *Les bas-fonds histoire d'un imaginaire*.
19. Dominique Kalifa. *Crime et culture au XIXe siècle*. Paris : Perrin, 2005, p. 60.

genre policier comme catégorie éditoriale autonome. Le roman partage avec le policier ultérieur un répertoire lexical commun, sans en partager encore les conventions narratives spécifiques, que notre modèle, fondé sur les seules fréquences lexicales, n'est de toute façon pas en mesure de capter.

Verne, *Hector Servadac* (1877). Roman d'aventures scientifiques sans intrigue criminelle, *Hector Servadac* obtient pourtant une probabilité très élevée ($p = 0{,}96$). Ce score surprenant invite à examiner le profil lexical du texte.

Une première piste tient au vocabulaire de l'investigation scientifique qui irrigue le roman. Après le cataclysme initial, les personnages accumulent des observations : une inversion apparente du lever du soleil, des modifications atmosphériques, des variations de pesanteur. Ils confrontent des explications possibles et procèdent par élimination. Le texte mobilise massivement un lexique de l'élucidation (hypothèses, déductions, calculs, observations, précision) qui recoupe celui que notre modèle, fondé sur les fréquences de mots les plus courants, associe au corpus policier. Une seconde piste concerne les premières pages du roman, où une scène de duel mobilise un vocabulaire de type procédural fréquent dans les scènes d'instruction du corpus policier.

Le cas de Servadac n'est pas un phénomène isolé dans l'œuvre de Verne. Daniel Compère [20] a identifié un genre mixte qu'il appelle le *roman d'aventures policières*, où l'enquête existe mais reste subordonnée à l'aventure, et où la distribution des rôles diffère du policier canonique (le personnage central n'est pas l'enquêteur mais l'innocent accusé). Compère rattache explicitement certains romans de Verne à ce genre, notamment *Un drame en Livonie* et *La Jangada, huit-cent lieues sur l'Amazone*, où « l'enquête policière ne déboucherait pas sur la vérité sans un élément extérieur qui vient innocenter un accusé et dénoncer le vrai coupable » [21]. Notre modèle conforte cette analyse, puisqu'*Un drame en Livonie* obtient une probabilité élevée ($p = 0{,}82$). *Hector Servadac* ne relève pas du *roman d'aventures policières* au sens de Compère, car il n'y a ni crime ni accusé. Le vocabulaire du crime est d'ailleurs quasi absent du texte : les rares occurrences de « voleur » ou « cadavre » renvoient à des ressorts comiques (le marchand Hakhabut accusé de faux poids) ou à des métaphores scientifiques, non à une intrigue criminelle. Si le modèle lui attribue néanmoins un score aussi élevé, c'est vraisemblablement parce que le lexique dominant du roman est celui de l'élucidation rationnelle, que notre modèle ne distingue pas du vocabulaire de l'enquête policière. Servadac constituerait ainsi un cas-limite plus extrême que ceux identifiés par Compère, où la parenté lexicale avec le policier subsiste alors même que toute dimension criminelle a disparu.

2.5.2 Faux négatifs : canonisation rétroactive et faible signal textuel

Féval, *Les Mystères de Londres* (1843). Les trois tomes des *Mystères de Londres* sont annotés comme policiers, mais le modèle reste hésitant (respectivement $p = 0{,}21$, $0{,}47$ et $0{,}11$). Ce score faible pourrait s'expliquer par le profil lexical du texte. La vogue des « mystères urbains »

20. Daniel Compère. « Le roman d'aventures policières au XIXe siècle ». *Poétiques du roman d'aventures*. Sous la dir. d'Alain-Michel Boyer et Daniel Couégnas. Nantes : Université de Nantes, 2004.
21. Ibid., p. 118.

tel que l'a décrit Kalifa [22] se caractérise par la multiplication des milieux, des lieux et des fils narratifs. On peut faire l'hypothèse que le vocabulaire dominant du texte est celui du tableau social et du mélodrame plutôt que celui de l'investigation méthodique que le modèle a appris à associer au corpus policier. La dissonance entre le label assigné par les chercheurs et la probabilité du modèle matérialise une tension classique de la classification rétrospective, où l'on fait des *Mystères* un ancêtre du genre parce qu'ils mettent en scène crimes et bas-fonds, alors que leur empreinte lexicale reste celle du feuilleton criminel.

Balzac, *Une ténébreuse affaire* (1841). Souvent située par la critique dans une « préhistoire » du roman policier, *Une ténébreuse affaire* reçoit pourtant une probabilité très faible ($p = 0{,}12$). L'écart s'explique moins par l'absence d'enquête que par sa *forme*. Le texte met en scène une véritable machine policière et judiciaire : perquisitions au château, collecte des premiers éléments de l'instruction, recherche « des indices et des preuves », et surtout intervention d'agents de police (Corentin, Peyrade) décrits comme des « limiers » menant une chasse à l'homme, donnant des ordres, organisant la surveillance et le resserrement d'un dispositif de gendarmerie. Mais cette dynamique est constamment enchâssée dans un régime narratif d'histoire politique et de commentaire : le narrateur adopte explicitement une posture d'historien (« le devoir d'un historien est de le décrire »), recontextualise longuement l'affaire dans les institutions, et transforme l'énigme en problème de raison d'État. Ainsi, du point de vue d'un modèle calibré sur un prototype ultérieur du roman d'enquête. Le roman de Balzac ressemble davantage ici à un roman politico-judiciaire : l'enquête existe, mais elle prise dans de longues médiations institutionnelles et historiques, plutôt que configurée comme un dispositif central d'élucidation. D'ailleurs comme le note Bonniot citant Messac, Balzac néglige un des préceptes fondamentaux qui régie le roman policier : « C'est toutefois avec *une Ténébreuse affaire* estime Régis Messac, que Balzac s'est le plus rapproché du genre policier, sans qu'on puisse cependant lui attribuer la paternité, car il a prématurément informé le lecteur des secrets recherchés par les enquêteurs, secrets qu'ils ne découvriront complètement que trente ans plus tard » [23]. La résolution progressive de l'intrigue n'est donc pas exactement respectée par Balzac. Nous ne pouvons pas dire ici que le modèle entraîné sur une perspective lexicale détecte ce manquement aux règles de l'intrigue du policier, mais cela reste suffisant pour capter une distance importante au genre.

2.5.3 Cas canoniques : convergence entre machine et historiographie

Gaboriau, *L'Affaire Lerouge* (1866) et *Le Crime d'Orcival* (1867). À l'inverse des cas-limites, les romans de Gaboriau, souvent décrits comme un moment de stabilisation du policier français, sont bien reconnus par le modèle : *L'Affaire Lerouge* obtient p = 0,73 et *Le Crime d'Orcival* p = 0,72. Cette bonne classification s'explique par une convergence de marqueurs : des enquêteurs identifiables (père Tabaret, M. Lecoq), une mise en scène procédurale des premières constatations, et une narration structurée par la production et l'évaluation d'indices.

Dans *L'Affaire Lerouge*, l'ouverture installe immédiatement la chaîne institutionnelle de

22. Kalifa, *Les bas-fonds histoire d'un imaginaire*, p. 27–28.
23. Roger Bonniot. *Émile Gaboriau ou La naissance du roman policier*. Paris : Vrin, 1985, p. 164.

l'enquête : signalement d'une disparition, entrée forcée, constat du cadavre, puis « enquête provisoire » et « information préalable », avec interrogatoires successifs, tri de témoignages contradictoires, et arrivée d'acteurs spécialisés comme un juge d'instruction, un chef de la Sûreté, ou encore des agents de police.

Le texte explicite le programme lexical attendu de l'enquêteur (démêler « l'écheveau », saisir « le fil conducteur », déduire « du connu à l'inconnu », constituer un « faisceau de preuves »). *Le Crime d'Orcival* met en place un dispositif comparable dès les premières pages, avec la découverte d'un cadavre et le réflexe de préservation de la scène (« on ne doit jamais toucher au corps d'une personne assassinée, sans la justice »), alerte au maire, convocation du juge de paix, contrôle des accès et interdictions (« que nul surtout ne pénètre »), puis constatations matérielles (traces de sang, désordre, objets-repères) et enfin perquisition méthodique avec prise de notes. L'enquête est moins centrée sur un génie unique que sur une administration locale qui transforme immédiatement le fait divers en procédure d'élucidation. Ces « bons cas » indiquent que le modèle capte bien un noyau dur du policier, et permettent ensuite de lire les écarts comme des positions périphériques.

2.6 Autres déplacements du régime d'enquête au XXe siècle

Les mêmes phénomènes de discordance entre étiquette générique et probabilité prédite par le modèle se retrouvent au XXe siècle. Ils permettent de préciser ce que le modèle identifie, ou n'identifie pas, comme signature textuelle du roman policier. Sur l'ensemble du corpus (N = 847 romans), ces discordances concernent 12,3% des textes : 47 romans annotés « policier » reçoivent une probabilité inférieure à 0,30, tandis que 57 romans *non policiers* dépassent le seuil de 0,70. L'examen de cas représentatifs, sélectionnés selon le protocole décrit en section 7, permet de formuler des hypothèses sur les profils lexicaux en jeu.

2.6.1 Policiers déclarés, signaux faibles : Leroux, Boileau-Narcejac, Volodine

Boileau-Narcejac, *Carte vermeil* (1978, $p = 0{,}13$). Ce roman tardif de Boileau-Narcejac, annoté policier, reçoit un score très faible. On peut faire l'hypothèse que cela tient à la dominante lexicale du texte. *Carte vermeil* se présente comme un récit à focalisation interne, où le vocabulaire dominant relèverait du suspense psychologique et du drame relationnel plutôt que de la procédure d'enquête. L'enquête institutionnelle existe (un commissaire intervient), mais elle semble rester périphérique dans l'économie lexicale globale du texte. Le modèle, calibré sur les fréquences de mots les plus courants du corpus policier, pénalise probablement un texte dont les mots les plus fréquents appartiennent au registre de l'intériorité plutôt qu'à celui de l'investigation.

Gaston Leroux, au-delà de Rouletabille détective. Les romans de Leroux offrent un cas particulièrement éclairant de variabilité interne au sein de la production d'un même auteur. D'un côté, les deux titres les plus canoniques de la série Rouletabille sont très bien reconnus par le modèle : *Le Mystère de la chambre jaune* (1907) atteint $p = 0{,}98$ et *Le Parfum de la dame en noir* (1910) $p = 0{,}75$. Ces textes concentrent en effet tous les traits saillants du roman-enquête :

crime énigmatique (chambre close), détective raisonneur, alternance entre collecte d'indices et scènes de reconstitution, lexique abondant de la preuve, du raisonnement, de l'observation.

À l'inverse, plusieurs autres romans de Leroux, pourtant annotés policiers, reçoivent des probabilités très faibles : *L'Épouse du soleil* (1913, $p = 0{,}11$), *Rouletabille chez le tsar* (1913, $p = 0{,}14$), *Un homme dans la nuit* (1911, $p = 0{,}24$), *Le Château noir* (1916, $p = 0{,}26$), *Le Mystère Flow* (1927, $p = 0{,}26$). Dans ces romans, Leroux déplace largement son écriture vers l'aventure exotique ou le complot politique. L'enquête subsiste parfois comme fil directeur (notamment dans *Rouletabille chez le tsar* ou *Le Château noir*), mais elle n'organise plus la totalité du récit ni son lexique comme dans *Le mystère de la Chambre jaune* ou *Le Parfum de la dame en noir*. Rouletabille lui-même tend parfois à se muer en héros d'action, au détriment de la figure de détective raisonneur, ce qui se traduit probablement par un déplacement des fréquences lexicales vers des registres que le modèle n'associe pas au policier.

Antoine Volodine, *Lisbonne, dernière marge* (1990). Annoté comme *policier* par l'équipe de *Chapitres*, le roman obtient une probabilité faible ($p = 0{,}30$). Le livre met bien en place l'horizon d'un roman à suspense (Lisbonne comme décor, le duo entre une figure de policier et une figure de « terroriste », avec un lexique explicite de traque et de déchiffrement) : Kurt, le « flic » est tombé amoureux d'Ingrid, une « terroriste » recherchée par la police allemande. Dans la pratique narrative, la police n'est pas le moteur d'une élucidation progressive, elle est surtout un appareil de contrôle et de violence, intégré à une dystopie où la mémoire est falsifiée et où les textes (archives, libelles, dossiers) fonctionnent comme un montage. Le texte thématise bien l'enquête, mais souvent sur un mode déplacé, ce qui brouille les marqueurs prototypiques du *policier* appris par le modèle.

2.6.2 Enquêtes sans crime : Queneau, Modiano, Angot

À l'inverse, plusieurs textes manuellement annotés comme *non policiers* sont attribués par le modèle au genre avec des probabilités élevées. Ils partagent tous une même caractéristique : la présence d'un régime d'enquête déplacé, appliqué non à un crime mais à l'existence quotidienne, à l'identité ou au destin historique.

Queneau, *Le Dimanche de la vie* (1952, $p = 0{,}78$). Ce roman n'est pas un policier : on n'y trouve ni crime à élucider, ni enquête constituée, ni détective identifié. Le score élevé pourrait s'expliquer par la présence, dans le texte, d'un vocabulaire récurrent de l'observation, du soupçon et de la piste. Dans un épisode central, la narration s'organise autour d'une voyante que les personnages viennent consulter pour interpréter les signes du quotidien. Le texte recycle ainsi un lexique du dévoilement compatible avec celui que le modèle associe au policier. Le comique de Queneau repose souvent sur le détournement de codes littéraires établis (qu'il soit auto ou hétéro-parodique)[24], il est donc possible que le modèle capte ici les traces lexicales d'un jeu parodique avec les conventions du roman d'enquête.

24. Emmanuël Souchier. *Raymond Queneau*. Paris : Éditions du Seuil, 1991, p. 161.

Modiano, *Rue des boutiques obscures* (1978, $p = 0{,}87$). Bruno Blanckeman range *Rue des boutiques obscures* parmi les « romans d'investigation » de Modiano [25]. Le roman mobilise en effet un vocabulaire caractéristique de l'enquête. Le narrateur est un ancien employé d'agence de détectives, il manipule annuaires et bottins, et le texte emploie fréquemment les termes « piste », « traces », « indices ». On y trouve également un vocabulaire de la matérialité documentaire (journaux, faire-part, photographies, boîtes d'archives). Le modèle capte probablement cette densité lexicale de l'investigation.

Le décalage avec la lecture critique ne porte donc pas sur le lexique, qui est bien celui de l'enquête, mais sur sa finalité. *Rue des boutiques obscures* met en scène une investigation qui ne débouche pas sur une identification stable : les témoignages, les objets archivés et les traces documentaires n'y produisent aucune vérité pleinement assurée, mais entretiennent au contraire un régime d'incertitude, de « suspense identitaire » [26]. Or cette différence de finalité n'est pas accessible à un modèle fondé sur les fréquences de mots.

Angot, *Les Désaxés* (2004, $p = 0{,}75$). Ce roman illustre un cas où le modèle rapproche du policier un texte dont le vocabulaire dominant est celui d'une investigation intime au sein du couple. Comme le note Katerine Gagnon, *Les Désaxés* met en scène un « couple de scénaristes en débâcle » dans une écriture qui tient « beaucoup du procès-verbal » [27]. La narration est fortement marquée par des termes renvoyant à la confrontation argumentative ainsi que par des structures dialogiques proches de l'interrogatoire. Le modèle capte probablement ces régularités lexicales, compatibles avec celles du corpus policier, sans pouvoir distinguer une investigation criminelle d'une investigation conjugale. La logique centrale du texte n'est pas l'élucidation d'un crime, mais la mise à l'épreuve d'un récit adverse, distinction que les seules fréquences de mots ne permettent pas d'opérer.

2.7 Un degré d'appartenance au roman policier

Pris ensemble, ces résultats indiquent que le modèle reconnaît un profil lexical associé à l'enquête et à l'élucidation. Certains textes non policiers au sens strict peuvent ainsi recevoir des probabilités élevées dès lors qu'ils mobilisent ce vocabulaire (Vidocq, Verne, Modiano), tandis que des textes rattachés à une préhistoire du policier (Balzac, Féval) ou à ses marges contemporaines obtiennent des scores faibles lorsque leur lexique dominant relève d'autres registres.

La forte performance globale suggère qu'il existe bien une signature textuelle robuste associée au roman policier. Un noyau lexical suffisamment stable pour être repéré par un modèle simple. Cependant, les erreurs et les cas-limites dessinent des zones de transition, avec par exemple les romans *policiers* qui basculent vers le suspense psychologique ou l'aventure, et les ouvrages *non policiers* qui obtiennent un score élevé lorsqu'ils mettent en scène une logique d'enquête.

Dans cette perspective, la classification supervisée ne doit pas être comprise comme un arbitrage binaire, mais comme une mesure continue de proximité lexicale au cœur du sous-genre.

25. Bruno Blanckeman. *Lire Patrick Modiano*. Paris : Armand Colin, 2014, p. 52.
26. Ibid., p. 52.
27. Katerine Gagnon. « Coup de théâtre angotien ». *Spirale* 2005, p. 48-49.

La suite du travail dans le chapitre 6 prolonge cette logique à une autre échelle (celle des personnages) avec le détecteur de détectives : il ne s'agira plus de décider si un roman est policier, mais d'estimer à quel point un personnage se rapproche d'un prototype de « détective » construit à partir de cas canoniques.

3 Mutations du roman policier : problèmes de la périodisation du genre

Les résultats de l'approche supervisée montrent que le roman policier conserve un noyau de régularités textuelles sur une longue durée. Ils vont donc dans le sens d'une conception du genre comme forme relativement stable, qui transcenderait sa propre actualisation au fil du temps.

Cependant, l'histoire littéraire et la critique nuancent cette vision : on sait que le roman policier a évolué au fil du temps. Les éditeurs, auteurs et lecteurs n'ont pas toujours considéré tel ou tel texte comme *policier*. Prenons l'exemple de Simenon, lors de ses débuts chez Fayard, ses premiers tapuscrits de Maigret n'étaient pas encore reconnus comme des vrais romans policiers. Dans *Le Romancier* une conférence au ton autobiographique (prononcée à l'Institut français de New York le 20 novembre 1945), Simenon rapporte un échange avec son éditeur Fayard expliquant pourquoi ces écrits ne satisfont pas les canons du roman policier :

> – Je vous édite !
> Puis il ajoutait :
> – Seulement nous allons à la catastrophe.
> – Pourquoi ?
> – Parce que : 1° Vos romans *policiers* ne sont pas de vrais romans policiers. Ils ne sont pas scientifiques. Ils ne jouent pas la règle du jeu.
> – Ensuite ?
> – 2° Il n'y a pas d'amour, tout au moins d'amour comme on le conçoit dans le roman policier.
> – Encore ?
> – 3° Il n'y a pas de personnages franchement sympathiques ou de personnages franchement antipathiques. Vos romans ne finissent ni bien ni mal. C'est désastreux [28].

Cette réaction de l'éditeur révèle, d'une part, la conscience aiguë des règles du genre et, d'autre part, la dimension éminemment contextuelle des conventions génériques soumises à l'appréciation du marché et des attentes supposées du lectorat. Simenon s'est pourtant imposé, par la suite, comme l'un des auteurs majeurs du roman policier, prouvant que les genres évoluent et que certaines stratégies éditoriales plus traditionnelles peuvent se révéler caduques.

28. Georges Simenon. « Le Romancier ». *Le Roman de l'Homme*. Lausanne : Éditions de l'Aire, 1980, p. 73-103, p. 93-94.

3.1 Approche par spécification des trois périodes du genre

Afin de modéliser les changements qui ont lieu à l'intérieur d'un genre, Underwood [29] propose deux expérimentations. La première est de séparer l'histoire du genre en plusieurs parties, afin de voir comment se comportent des modèles entraînés et testés sur des périodes spécifiques du genre. Dans le contexte francophone du corpus *Chapitres*, nous pouvons distinguer trois périodes majeures de ce genre. Tout d'abord, la période d'émergence du genre, que Vareille décrit comme « archaïque » [30]. Nous identifions cette période dans le corpus de Gaboriau à Leroux et Leblanc. Puis celle de l'âge d'or du roman policier qui commence symboliquement en 1927 en France avec la collection du Masque, qui publie majoritairement des œuvres traduites, que nous n'avons donc ici. Cette période correspond notamment à celle de Simenon dans notre corpus. Enfin la période moderne, qui correspond aux modifications majeures du genre en France a lieu dans les années qui suivent la fin de la seconde guerre mondiale, lorsque le *hardboiled* est importé en France comme l'a montré Anne Cadin [31]. C'est le moment américain de la littérature française, le roman noir et le néo-polar vont modifier considérablement le genre policier. Nous faisons commencer cette période en 1950, afin de laisser le temps de l'appropriation de l'importation américaine par les auteurs francophones. La question posée est assez simple : un modèle entraîné sur les romans feuilletons policiers d'*Émile Gaboriau* ou de *Fortuné du Boisgobey* peut-il reconnaître le roman policier classique ou celui d'après guerre ? Et inversement, un modèle entraîné sur des romans policiers d'après guerre reconnaît-il les romans feuilletons policiers ?

Les résultats, présentés dans le tableau ci-dessous, témoignent de la capacité variable des modèles à généraliser au-delà de leur période d'entraînement :

Modèle entraîné sur	émergente	canonique	moderne
émergente (1866-1927)	id	0.675	0.550
canonique (1927-1950)	0.929	id	0.832
moderne (1950-Aujourd'hui)	0.689	0.710	id

TABLE 5.2 : Prédictions des modèles, en *GroupKFold* sur les 3 grandes périodes du roman policier

Le modèle entraîné sur la période *canonique* affiche une robustesse remarquable, atteignant une précision équilibrée de 0,929 lorsqu'il est évalué sur les œuvres de la période *émergente*. Cette performance élevée se maintient également à 0,832 sur les textes de la période *moderne*. Ce résultat suggère que les marqueurs lexicaux de la période canonique constituent un socle stable et durable permettant de reconnaître le genre policier, même en dehors de leur contexte historique initial.

À l'inverse, le modèle entraîné sur les œuvres de la période *émergente* peine à généraliser, avec une précision relativement modeste de 0,675 sur les œuvres canoniques, et une baisse notable à 0,550 sur les textes modernes.

29. UNDERWOOD, *Distant horizons*, p. 50.
30. Jean-Paul COLIN. *Le roman policier français archaïque : un essai de lecture groupée*. Berne : Lang, 1984.
31. Anne CADIN. « Le moment américain du roman français : 1945-1950 ». Thèse de doct. Paris : Classiques Garnier, 2018.

Ensuite, le modèle *moderne* présente une performance intermédiaire (0,689 et 0,710 respectivement sur les périodes *émergente* et *canonique*), révélant une difficulté relativement plus grande à prédire les textes de la période plus lointaine temporellement parlant. Les résultats restent néanmoins supérieurs si on les compare à la période *émergente*, ce qui souligne encore une fois la spécificité de cette période. Autrement dit, le roman policier des origines (1860–1927) semble différent à bien des égards : il n'est pas encore totalement figé, et les codes de l'enquête méthodique sont alors en cours de constitution.

3.2 Approche par SVM roulant

La seconde expérience proposée par Underwood [32] consiste à entraîner plusieurs modèles de manière roulante sur des périodes temporelles spécifiques. L'idée est de rendre compte des évolutions dans la standardisation du genre. Quelles périodes sont textuellement plus cohérentes et peut-on dater la période de cristallisation du genre ?

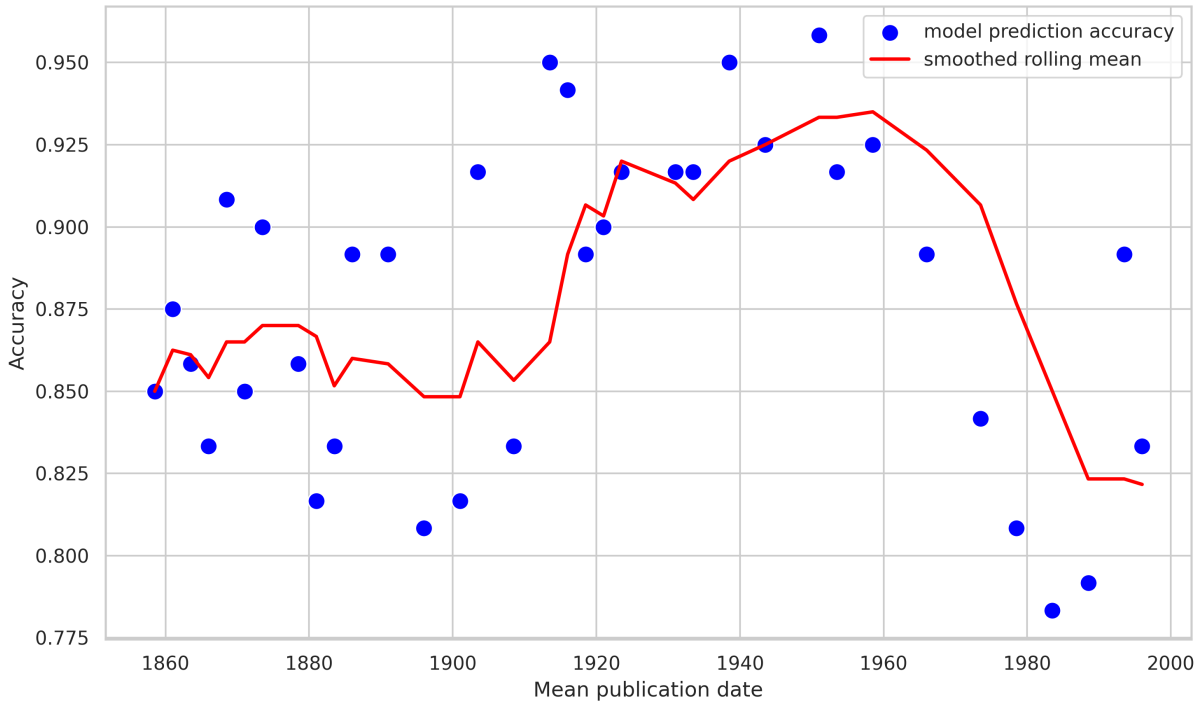


FIGURE 5.3 : Prédiction du genre policier tous les 25 ans

En figure 5.3, nous montrons les résultats de notre analyse. Chaque point représente un modèle unique entraîné sur un échantillon aléatoire de textes d'une certaine période. Chaque modèle couvre 60 textes échantillonnés sur une fenêtre de 25 ans ; les points sont tracés à la date moyenne de publication de ces textes. La courbe rouge est une moyenne roulante qui permet de donner une meilleure idée de l'évolution de l'efficacité des différentes modèles. Il est intéressant de noter qu'après une relative stabilité dans les débuts du genre, nous voyons une augmentation (de 0.86 à 0.92) qui commence au niveau de la fin de la première guerre mondiale et qui correspond

32. Ted UNDERWOOD. « Machine Learning and Human Perspective ». *PMLA* 2020, p. 92-109. DOI : 10.1632/pmla.2020.135.1.92.

aux années où Maurice Leblanc et Gustave Leroux sont prolifiques et contribuent à l'avènement du genre dans le contexte francophone. S'ensuit un plateau qui dure des années 20 aux années 60 correspondant aux années de Georges Simenon et de Léo Malet. Si l'on prend en compte l'effet de la fenêtre roulante qui agrandit quelque peu le phénomène, nous avons ce plateau qui se superpose à l'âge d'or du roman policier francophone, du début des années 30 aux années 50. On observe ensuite une baisse notoire jusqu'à nos jours, d'autant plus importante que le niveau de prédiction est plus bas qu'au début du genre, signalant une explosion des potentialités formelles du roman policier (*hardboiled*, néo-polar, procédure police, espionnage), et donc une moins grande stabilité du genre.

Il faut préciser qu'ici nous contrôlons l'impact de l'idiolecte des auteurs sur la prédiction, car nous avons quelques cas problématiques dans le corpus, avec notamment le prolifique George Simenon, auteur de 80 textes de 1931 à 1972. Nous retirons donc de nos caractéristiques textuelles les mots-outils, autant de signaux possible de l'idiolecte, mais surtout nous entraînons nos modèles en conservant l'information de l'auteur. L'entraînement se fait tel que l'on ne peut pas retrouver le même auteur à la fois dans le corpus d'entraînement et le corpus de test.

Il y a bien sûr une explication contextuelle à cela. Une fois le genre doté de collections spécifiques et d'auteurs prolifiques, alors le dispositif formel peut se stabiliser. Avec ce point de vue, le contexte est un pré-requis au texte, et c'est la position que nous avons présentée dans le chapitre 2 et chapitre 3 de cette thèse. Pourtant, nous pourrions aussi soutenir l'inverse : c'est un dispositif formel, arrivé progressivement à maturation, qui a permis l'explosion du genre et sa définition contextuelle. Cette interrogation sera prolongée dans le chapitre 7 et le chapitre 9.

Le premier constat que l'on peut tirer de cette figure est que le roman policier n'est pas stable dans le temps, et on observe sans surprise une convergence lexicale vers l'âge d'or du genre, des années 20 aux années 60. Le second est qu'il y a une asymétrie de prédiction entre les différentes grandes périodes du genre. La période émergente est particulièrement intéressante de ce point de vue puisqu'elle ne permet pas d'anticiper la forme que prendra le genre plus tard, alors que le modèle entraîné sur la période canonique parvient complètement à rembobiner l'histoire du genre et retrouver les formes émergentes.

Le chapitre 7 se focalisera sur ces questions, afin d'essayer de comprendre comment le genre policier est apparu et comment il s'est progressivement démarqué du roman-feuilleton. Nous reviendrons aux premières décennies de l'émergence du genre (1860–1927) afin d'identifier, dans un corpus plus resserré, les signaux formels qui permettent de caractériser ce moment fondateur du genre.

Ces constats soulignent par ailleurs un autre problème : la classification que l'on a vue au début du chapitre s'appuie sur des listes de romans policiers établies depuis notre vision contemporaine, et non sur des catégories historiquement situées. Cela crée un biais anachronique, car un roman que nous jugeons aujourd'hui comme « policier » n'était pas forcément étiqueté de la sorte à sa parution. Cet anachronisme relève donc d'une vision « anhistorique » du genre. L'une des pistes pour mieux intégrer le contexte est alors de recourir à des définitions éditoriales : pour la période après 1945, il devient possible d'exploiter les archives de maisons d'édition ou de collections spécialisées (par exemple la Série Noire ou les données de l'ANR Polarisation), et de

repérer comment ces étiquettes ont structuré la production et la réception des textes.

En définitive, si l'approche formelle et transcendante montre que l'on peut dégager des invariants du genre policier (au prix d'un certain anachronisme), une démarche plus historique et contextuelle éclairerait la dimension dynamique de ce genre : ses frontières se sont déplacées au fil des décennies, sous l'impulsion conjointe des auteurs, des éditeurs et des lecteurs.

4 Regroupements internes dans le roman policier : une approche non-supervisée

Dans la continuité de cette première approche supervisée, nous pouvons revenir à la question de la périodisation du genre en nous affranchissant, autant que possible, des étiquettes génériques préalables. L'idée est de laisser les textes « parler entre eux » : plutôt que de demander à un modèle de décider si un roman est *policier* ou non, nous encodons chaque passage sous forme de vecteur, puis nous observons comment ces vecteurs se regroupent, à différentes échelles, en fonction de leurs proximités dans l'espace des similarités. Cette démarche met en œuvre, dans un cas d'étude limité, la méthodologie des réseaux de similarité présentée à la section 6 du chapitre précédent.

4.1 Réseaux de similarité à l'échelle du roman

Concrètement, chaque roman est segmenté en fenêtres textuelles de longueur homogène (512 tokens, environ deux pages). Chaque fenêtre est encodée par un modèle d'« embeddings » textuels affiné sur un corpus littéraire francophone, puis reliée à ses cinq plus proches voisines en termes de similarité cosinus. Nous obtenons ainsi, pour un texte donné, un graphe de type k-plus-proches-voisins, où chaque nœud correspond à un passage du roman et où chaque arête indique une forte parenté textuelle.

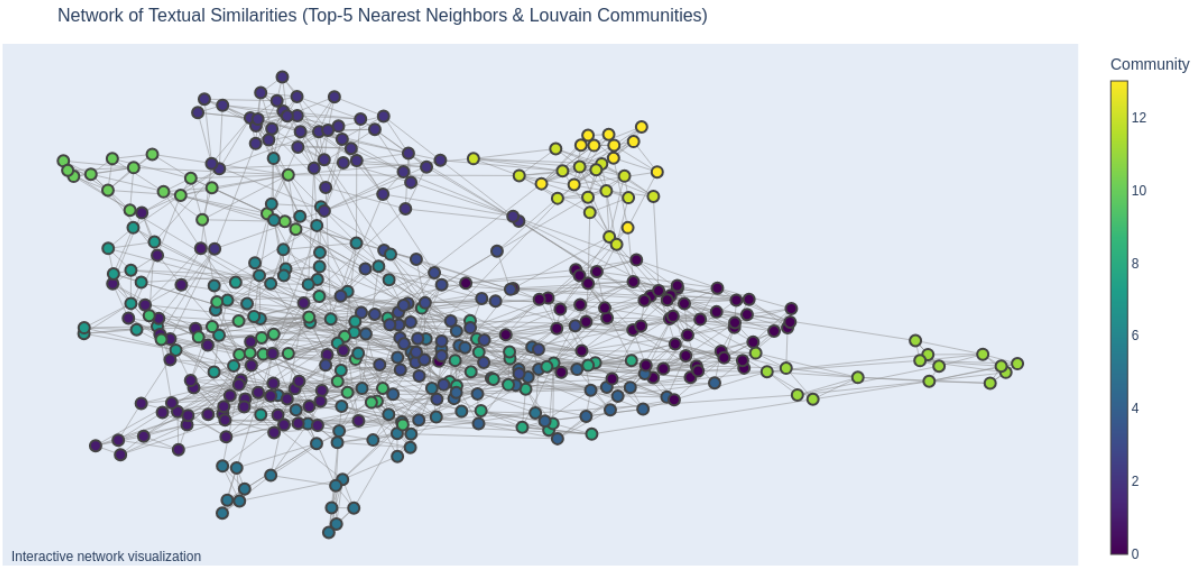


FIGURE 5.4 : Réseau intertextuel dans *Le Mystère de la chambre jaune* (1907) de Leroux

Appliqué au *Mystère de la chambre jaune* de Gaston Leroux [33], ce procédé produit un réseau dense où l'on distingue nettement plusieurs communautés de passages, bien reliés entre eux (figure 5.4). Certaines zones correspondent à des épisodes narratifs bien identifiables, par exemple la scène du crime, la reconstitution finale ou encore les confrontations judiciaires. D'autres regroupent des séquences dispersées mais thématiquement homogènes (discussions scientifiques, descriptions des lieux, scènes de surveillance, etc.). Le roman apparaît alors non plus comme une simple succession linéaire de texte, mais comme une topologie de motifs qui se réactivent tout au long du texte : une cartographie concrète de la « ressemblance de famille » interne au roman policier.

L'intrigue du roman se joue autour d'une femme, Mathilde Stangerson, qui est agressée dans une chambre fermée de l'intérieur au château du Glandier. Le jeune reporter Rouletabille mène l'enquête en parallèle du policier officiel Frédéric Larsan, et finit par découvrir que Larsan lui-même est le coupable. Le dénouement a lieu au tribunal, où Rouletabille révèle la vérité au moment du procès de Robert Darzac, injustement accusé.

Dans un premier couple de similarité, le modèle rapproche deux passages situés à quelques pages d'intervalle dans la scène du tribunal (passages 366 et 404). Dans le premier, Rouletabille accuse Larsan en s'appuyant sur sa fuite :

> « Expliquez-vous… quelle preuve ? demanda le président. — Ma preuve irréfutable, fit le jeune reporter, ne voyez-vous pas que c'est la fuite de Larsan. Je vous jure qu'il ne reviendra pas, allez !… Vous ne reverrez plus Frédéric Larsan… » Rumeurs au fond de la salle. « Si vous ne vous moquez pas de la justice, pourquoi, monsieur, n'avez-vous pas profité de ce que Larsan était avec vous, à cette barre, pour l'accuser en face ? Au moins, il aurait pu vous répondre !… — Quelle réponse eût été plus complète que celle-ci, monsieur le président ?… Il ne me répond pas ! Il ne me répondra jamais ! » [34]

Dans le second, quelques pages plus loin, Rouletabille répond à une nouvelle question du président en expliquant la stratégie de Larsan :

> « Encore une question, monsieur, fit le président. Nous comprenons, toujours en admettant votre thèse, que Larsan ait voulu détourner les soupçons sur M. Robert Darzac, mais quel intérêt avait-il à les détourner aussi sur le père Jacques ?… — L'intérêt du policier ! m'sieur ! L'intérêt de se montrer débrouillard en annihilant lui-même ces preuves qu'il avait accumulées. C'est très fort, ça ! » [35]

Le rapprochement par le modèle s'explique probablement par un profil lexical et discursif très similaire entre les deux passages : même situation d'énonciation (échange entre le président et le témoin), même vocabulaire juridique, même registre dialogique. Ce que le modèle capte concrètement, c'est la récurrence d'un ensemble de mots et d'une configuration discursive que l'on peut interpréter comme le motif de la révélation judiciaire, configuration récurrente du roman d'énigme où le tribunal fonctionne comme théâtre du dévoilement.

33. Gaston Leroux. *Le mystère de la chambre jaune : Rouletabille*. Paris : Le Livre de Poche, 2001 [1907].
34. Ibid., p. 244.
35. Ibid., p. 267.

Un second couple rapproche deux scènes où Rouletabille, marchant entre la gare et le château en compagnie du narrateur, livre des réflexions cryptiques. Dans la première (passage 41), en début de roman, le détective commente le caractère de la victime après avoir rencontré le juge d'instruction :

> « C'est une veine d'avoir rencontré ce juge d'instruction et son greffier… hein ! Que vous avais-je dit pour le revolver ?… » Il avait le front penché vers la route, les mains dans les poches, et il sifflotait. Au bout d'un instant, je l'entendis murmurer : « Pauvre femme !… — C'est Mlle Stangerson que vous plaignez ?… — Oui, c'est une très noble femme, […] Parce qu'elle a su tenir tête à l'assassin, parce qu'elle s'est défendue avec courage, et surtout, surtout, à cause de la balle dans le plafond ! » Je regardai Rouletabille, me demandant in petto s'il ne se moquait pas tout à fait de moi ou s'il n'était pas devenu subitement fou [36].

Dans la seconde (passage 176), c'est un objet anodin, une canne (qui aura une place importante dans le raisonnement final de Rouletabille) qui garde l'attention du reporter :

> « Avez-vous remarqué la canne de Frédéric Larsan ? me demanda le reporter quand nous fûmes seuls. C'est une canne toute neuve… que je ne lui ai jamais vue… Il a l'air d'y tenir beaucoup ; il ne la quitte pas… On dirait qu'il a peur qu'elle ne soit tombée dans des mains étrangères… Avant ce jour, je n'ai jamais vu de canne à Frédéric Larsan… Où a-t-il trouvé cette canne-là ? *Ça n'est pas naturel qu'un homme qui ne porte jamais de canne ne fasse plus un pas sans canne, au lendemain du crime du Glandier.* » [37]

Ici, la proximité vectorielle tient vraisemblablement à un cadre discursif partagé : dans les deux cas, un dialogue entre deux personnages en mouvement, un vocabulaire de l'observation et du soupçon, et surtout cette structure où le détective isole un détail dont le sens reste opaque pour le narrateur et pour le lecteur. On peut interpréter ce rapprochement comme la détection du motif de l'indice différé, technique de suspens herméneutique propre au roman d'énigme, où l'on voit le détective percevoir quelque chose sans comprendre encore ce qu'il perçoit.

4.2 Du roman au réseau intertextuel

La même procédure peut être étendue à plusieurs œuvres simultanément. En figure 5.5 nous construisons un réseau commun pour *L'Affaire Lerouge* (1866) de Gaboriau et *Le Mystère de la chambre jaune* (1907) de Leroux, en gardant là encore, pour chaque fenêtre, ses cinq plus proches voisines, nous obtenons un graphe bicolore où les nœuds rouges (Gaboriau) et jaunes (Leroux) occupent deux nappes bien séparées, mais reliées par de nombreuses arêtes.

La séparation globale traduit la cohérence propre à chaque auteur : les passages de Gaboriau se ressemblent davantage entre eux qu'avec ceux de Leroux, et inversement. Nos tests d'ablation (section 5.4) ont montré que les embeddings captent prioritairement des régularités thématiques et lexicales, mais ils encodent également des configurations discursives qui contribuent à la

36. Ibid., p. 35-36.
37. Ibid., p. 122-123.

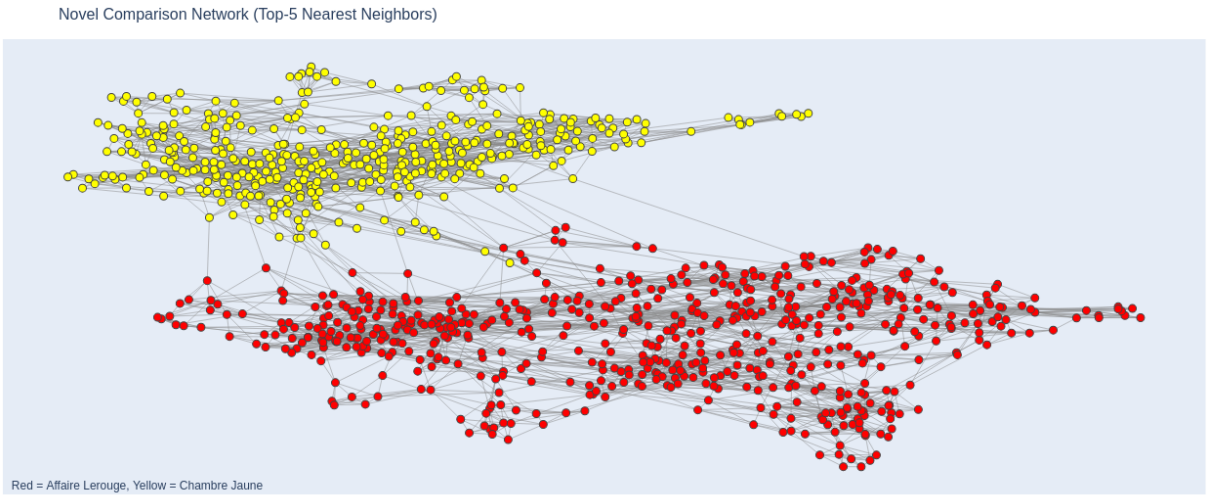


FIGURE 5.5 : Réseau intertextuel commun pour *L'Affaire Lerouge* (1866) de Gaboriau et *Le Mystère de la chambre jaune* (1907) de Leroux

proximité entre passages. La séparation entre les deux auteurs tient donc probablement à la conjonction de plusieurs facteurs : des univers référentiels distincts (Paris du Second Empire chez Gaboriau, Belle Époque chez Leroux), des registres différents (milieu judiciaire et procédural chez Gaboriau, monde scientifique et journalistique chez Leroux), et des modes narratifs propres à chacun. Les arêtes qui traversent la frontière entre les deux auteurs signalent en revanche les passages où ces différences s'effacent, là où les deux textes partagent ponctuellement un même registre discursif ou un même type de scène.

Afin d'illustrer cela, nous commentons deux couples de passages reliés par une arête dans le graphe, c'est-à-dire présentant une forte similarité cosinus entre leurs embeddings respectifs. Dans un premier couple de similarité, le modèle associe un passage de *L'Affaire Lerouge* où le détective exhibe les moulages des talons de l'assassin et commente longuement la forme de la chaussure :

> « Ah ! c'est trop fort ! dites-vous. Eh bien ! daignez jeter un regard sur ces morceaux de plâtre humide. Ils vous représentent les talons des bottes de l'assassin dont j'ai trouvé le moule d'une netteté magnifique près du fossé où on a aperçu la clé. Sur ces feuilles de papier j'ai calqué l'empreinte entière du pied que je ne pouvais relever ; car elle se trouve sur du sable. Regardez : talon haut, cambrure prononcée, semelle petite et étroite, chaussure d'élégant à pied soigné, bien évidemment. Cherchez-la, cette empreinte, tout le long du chemin, vous la rencontrerez deux fois encores.... » [38]

et un passage du *Mystère de la chambre jaune* où l'inspecteur confronte le père Jacques, gardien du château, à une paire de souliers compromettants :

> « Voilà, dit-il, les souliers que chaussait l'assassin ! Les reconnaissez-vous, père Jacques ? Le père Jacques se pencha sur ce cuir infect et, tout stupéfait, reconnut de vieilles chaussures à lui qu'il avait jetées il y avait déjà un certain temps au rebut, dans un

38. Émile GABORIAU. *L'affaire Lerouge*. Paris : Éditions du Masque, 2013 [1866], p. 47-48.

> coin du grenier ; il était tellement troublé qu'il dut se moucher pour dissimuler son émotion. » [39]

La proximité vectorielle entre ces deux passages tient probablement à plusieurs facteurs que les embeddings captent simultanément : un champ sémantique partagé (chaussure, empreinte, assassin, reconnaître), une situation d'énonciation comparable (un enquêteur présente un objet matériel à un interlocuteur pour le confondre ou l'interroger), et un même registre discursif (dialogue de confrontation ponctué d'impératifs et de réactions émotionnelles). On peut interpréter ce rapprochement comme la détection d'un motif policier récurrent, celui de l'indice matériel exhibé, où un objet trivial (empreinte de talon, soulier usé) est transformé en preuve accablante par le geste de l'enquêteur.

Un second couple de similarité rapproche un interrogatoire de Gaboriau, où l'accusé nie obstinément malgré l'accumulation de preuves :

> « — Que voulez-vous dire ? interrompit le juge.
> — Rien d'autre que ce que je dis, monsieur.
> — Ainsi vous persistez à nier ?
> — Je suis innocent.
> — Mais c'est de la folie…
> — Je suis innocent.
> — C'est bien, fit M. Daburon, pour aujourd'hui en voilà assez. Vous allez entendre la lecture du procès-verbal et on vous reconduira au secret. Je vous exhorte à réfléchir. La nuit vous inspirera peut-être un bon mouvement ; si le désir de me parler vous venait, quelle que soit l'heure, envoyez-moi chercher, je viendrai. » [40]

et une scène analogue chez Leroux, où Robert Darzac, le fiancé de la victime injustement soupçonné, reconnaît ne pas avoir d'alibi face au juge d'instruction :

> M. de Marquet dit, montrant à M. Darzac le jeune employé à la barbiche blonde :
> « Vous reconnaissez monsieur ?
> – Je le reconnais, fit Robert Darzac d'une voix qu'il essayait en vain de rendre ferme. C'est un employé de l'Orléans à la station d'Épinay-sur-Orge.
> – Ce jeune homme, continua M. de Marquet, affirme qu'il vous a vu descendre de chemin de fer, à Épinay…
> – Cette nuit, termina M. Darzac, à dix heures et demie… c'est vrai ! … » [41]

Ici encore, la proximité vectorielle repose vraisemblablement moins sur un vocabulaire partagé (les mots diffèrent sensiblement) que sur une configuration discursive commune : un dialogue serré entre un magistrat et un suspect, une alternance rapide de questions et de réponses brèves, un registre judiciaire formel. Les embeddings, parce qu'ils encodent les relations sémantiques entre mots et pas seulement leurs fréquences, sont capables de rapprocher deux scènes d'interrogatoire même lorsque le lexique de surface n'est pas identique. On peut interpréter ce rapprochement

39. Leroux, op. cit., p. 115.
40. Gaboriau, op. cit., p. 340.
41. Leroux, op. cit., p. 219.

comme la détection d'une configuration discursive typique du genre, celle de la confrontation judiciaire, sans qu'il soit nécessaire de fournir au modèle une liste préalable de motifs policiers.

Ces rapprochements ne prouvent pas l'existence d'une influence directe de Gaboriau sur Leroux, mais ils objectivent la présence de schémas discursifs communs qui participent à la construction progressive de l'architexte policier.

4.3 Du cas d'étude à la cartographie du sous-genre

Enfin, la même logique peut être montée en généralité à l'échelle du sous-genre tout entier. La figure 5.6 synthétise la démarche méthodologique détaillée au chapitre 4 en section 6. En moyennant les embeddings de toutes les fenêtres d'un roman, nous obtenons un vecteur représentant globalement l'œuvre. En reliant chaque roman policier du corpus *Chapitres* à ses voisins les plus proches, nous parvenons à construire le réseau de similarité entre romans.

Sans aucune information de date ni d'étiquette externe, le graphe se structure en trois amas densément connectés, reliés par des ponts. Nous avons d'un côté les grands cycles de roman-feuilleton de la fin du XIXe siècle (Vareille appelle cette période la *pré-histoire*[42] du roman policier, et nous reviendrons dessus au chapitre 7), de l'autre les *whodunits* du premier XXe siècle, plus loin encore les polars et romans noirs d'après-guerre.

Le cluster A (en bas) regroupe les textes proto-policiers allant approximativement de 1866 à 1930, dominés par les figures fondatrices de Maurice Leblanc, Gaston Leroux, Émile Gaboriau, Paul Féval et leurs contemporains. Le cluster B (en haut à gauche) concentre massivement la production de Georges Simenon et l'univers de Maigret, représentant le roman policier francophone « classique » de 1931 à 1970, avec quelques exceptions notables (Bernanos, Boileau-Narcejac). Le cluster C (en haut à droite) rassemble la production contemporaine de 1965 à 2020, avec des auteurs comme Didier Daeninckx, Fred Vargas, ADG, Albert Simonin, Léo Malet et Boris Vian. Cette structuration temporelle dominante suggère que le modèle capte moins des invariants génériques stables que des évolutions diachroniques du genre, que ce soit par ses transformations lexicales et narratives, ou encore son renouvellement des univers référentiels.

Au-delà de la structuration temporelle dominante du réseau, sa configuration fait apparaître des zones de transition : certains romans occupent des positions intermédiaires entre les trois clusters et jouent un rôle de pont entre des ensembles autrement disjoints. Dans ce graphe, chaque roman est représenté par la moyenne des embeddings de ses passages et relié à ses cinq plus proches voisins dans l'espace vectoriel. Une arête signale ainsi une proximité de profils thématiques et discursifs moyens, mesurée par similarité cosinus. L'interprétation de ces rapprochements repose dès lors sur plusieurs niveaux d'analyse complémentaires : la connaissance des textes, l'examen des passages les plus similaires entre romans appariés, l'étude de leurs mots les plus fréquents, ainsi que des hypothèses de lecture formulées à l'aide de modèles de langue génératifs selon le protocole décrit en section 7, puis systématiquement vérifiées par retour au texte.

42. Jean-Claude VAREILLE. « Préhistoire du roman policier ». *Romantisme* 1986, p. 23-36. DOI : 10.3406/roman.1986.4922.

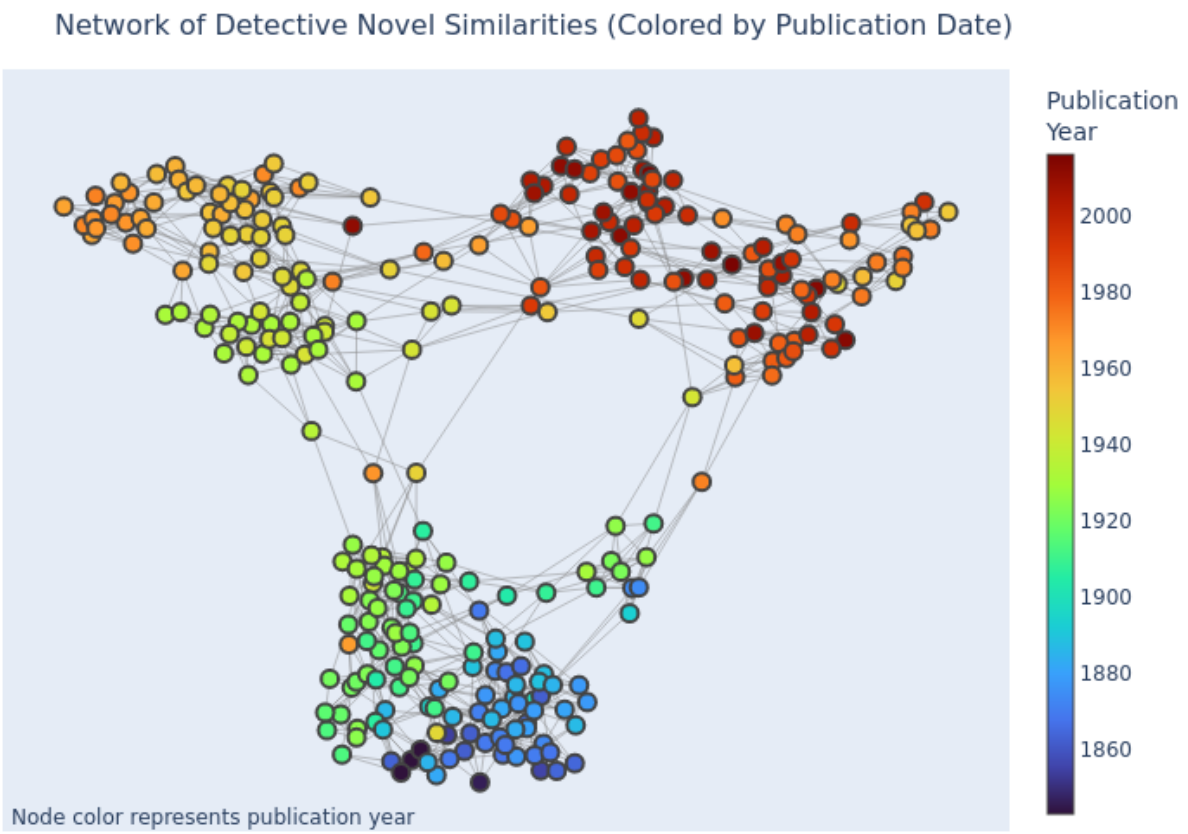


FIGURE 5.6 : Réseau de similarité dans le roman Policier

Connexions entre les clusters A et B. *Un crime* de Bernanos (1935) est relié à Rosny aîné (*La Femme disparue*, 1927, cluster A) et à trois Maigret (*Monsieur Gallet décédé* 1931, *L'affaire Saint-Fiacre* 1932, *L'inspecteur cadavre* 1944). Le texte de Bernanos est saturé d'un vocabulaire clérical qui lui est propre (le mot « curé » y apparaît plus de 200 fois, « prêtre » 90 fois), et ne se retrouve chez aucun de ses voisins dans le graphe. Malgré cette singularité, le modèle le relie à deux registres distincts. Avec les Maigret, et en particulier *L'affaire Saint-Fiacre*, la proximité vectorielle s'explique vraisemblablement par un vocabulaire partagé de l'espace provincial et de ses institutions : maire, gendarme, village, château, notaire sont présents avec des fréquences comparables dans les deux textes. Bernanos et Simenon situent tous deux un crime dans un milieu de notabilités rurales, ce qui produit un répertoire lexical commun indépendamment de leurs projets littéraires très différents. Avec Rosny, la connexion tient probablement à un autre registre, celui de l'atmosphère gothique et du suspense : les deux textes partagent un vocabulaire marqué de la nuit, de l'ombre, du silence, de la terreur et du mystère, ainsi que le lexique de la violence physique (revolver, sang, coup, cri).

Un mauvais rêve de Bernanos (1950) occupe une position remarquable dans le graphe. Ses plus proches voisins se répartissent entre quatre romans tardifs de Leblanc (cluster A), *Cherokee* d'Echenoz (1983, cluster C) et *Un crime* du même Bernanos (cluster B). C'est le seul texte du corpus connecté simultanément aux trois communautés. L'examen du vocabulaire des trois textes fait apparaître deux registres de convergence distincts. Avec Leblanc, la proximité passe par le

lexique de l'intrigue criminelle et de l'enquête : « crime », « meurtre », « assassin », « mort », « police », « secret », « complice » sont présents à des fréquences comparables dans les deux textes. Avec Echenoz, la connexion repose sur un tout autre registre : celui de la perception et de l'atmosphère nocturne. Les deux romans partagent un vocabulaire massif du regard et du corps et de l'obscurité. Dans les deux cas, des personnages naviguent dans des environnements opaques et menaçants où la surveillance et l'opacité sont centrales. La position intermédiaire d'*Un mauvais rêve* dans le graphe reflèterait l'appartenance à un répertoire de l'intrigue à secret partagé avec le roman d'aventures criminelles de Leblanc, mais égélement à un répertoire de l'atmosphère noire, partagé lui par-delà un demi-siècle d'écart, avec le polar d'Echenoz.

Connexions entre les clusters A et C. *Les récits de la demi-brigade* de Giono (1972) est quant à lui relié à Pierre Siniac (*Reflets changeants sur mare de sang* 1980, *L'unijambiste de la côte 284* 1980), et à Paul Féval (*Le dernier vivant* 1874). La proximité vectorielle entre des textes séparés de plus d'un siècle est a priori surprenante. L'examen des textes révèle cependant un faisceau de traits communs qui l'explique. Les trois textes sont des récits de crime à la première personne, un mode narratif relativement rare dans le corpus, où un narrateur-acteur raconte son implication dans une affaire violente. Le vocabulaire de l'action criminelle (« coup », « mort », « arme », « sang », « assassin ») apparaît à des fréquences remarquablement proches dans les trois romans, accompagné d'un registre oral très marqué et d'une forte densité de dialogue. La connexion avec Siniac passe plus spécifiquement par le lexique des armes à feu et du banditisme armé, deux récits de braquage en milieu rural. Celle avec Féval passe davantage par le dispositif du récit d'investigation rétrospectif, où un narrateur raconte comment il a démêlé une affaire (« savoir », « voir », « dire », « affaire » à des fréquences convergentes). Le modèle semble capter ici une configuration narrative précise : la voix d'un narrateur-aventurier racontant à la première personne une affaire de crime, configuration qui traverse les époques du roman policier, du feuilleton de Féval au néo-polar de Siniac en passant par le pastiche de Giono.

120, rue de la Gare de Léo Malet (1943) est un des textes fondateurs du roman noir français. Il est relié à Daeninckx (*Meurtres pour mémoire* 1984) et Siniac (*Reflets changeants sur mare de sang* 1980), mais aussi à Paul d'Ivoi (*L'espion X323* 1911). Le modèle relie ainsi directement des textes de la Belle Époque à des polars des années 1980, en passant par Malet. Cette position de pont s'explique par la superposition de deux registres lexicaux distincts. Avec les néo-polars, Malet partage le vocabulaire et la topographie urbaine du Paris populaire : argot, bistrots, figures de commissaires et d'inspecteurs. Avec les romans d'aventures de la Belle Époque, la connexion passe par le récit d'action à la première personne articulé autour de l'investigation et de l'arme à feu. L'examen du texte d'Ivoi, un roman d'espionnage situé en Égypte, sans aucun ancrage parisien, montre que les deux textes partagent un vocabulaire de la quête à des fréquences comparables (« chercher », « trouver », « suivre », « interroger »). Ce que le modèle capte ici n'est donc pas un milieu social commun, mais une configuration narrative partagée : le récit d'un narrateur-acteur armé d'un revolver, qui se déplace dans des espaces menaçants et tente de démêler une affaire. Cette configuration, indépendante du cadre géographique, fait le lien entre le roman d'aventures de la Belle Époque et le roman noir du XXe siècle.

Connexions entre les clusters B et C. *Les Gommes* de Robbe-Grillet (1953) se relie à Boileau-Narcejac (*La main passe*, 1991), à trois Simenon des années 1940 (*Les dossiers de l'agence O*, *Félicie est là*, *Signé Picpus*) et à Pierre Lemaitre (*Alex*, 2011). Ce rapprochement entre un texte canonique du Nouveau Roman et des policiers classiques n'est en réalité pas surprenant : l'examen du vocabulaire montre que *Les Gommes* est, au niveau lexical, un roman policier de plein droit. Les termes « commissaire », « assassin », « revolver », « police », « crime », « victime » y apparaissent à des fréquences égales ou supérieures à celles de Simenon. La convergence avec les Simenon des années 1940 repose sur le vocabulaire de l'investigation et celui du déplacement urbain. Les innovations formelles du Nouveau Roman ne modifient donc pas entièrement ce répertoire lexical de base. Comme le note Sjef Houppermans, « le policier moderne imite et pervertit les clés de la tradition du genre » [43]. C'est ce que le modèle capte : sous le travail formel de Robbe-Grillet, *Les Gommes* conserve une forte proximité lexicale avec le policier classique. La connexion avec Lemaitre, dont le profil lexical est sensiblement différent, pourrait en revanche passer par des appariements locaux de passages plutôt que par une convergence globale de vocabulaire.

Enfin, *L'âge bête* de Boileau-Narcejac (1978) est relié à leur propre production antérieure (*Les magiciennes* 1957, *La vie en miettes* 1972), à Thierry Jonquet (*Mygale* 1984), à Fred Vargas (*Sans feu ni lieu* 1997) et à deux Simenon de 1947 (*Maigret à New York*, *La pipe de Maigret*). On observe que ce texte, malgré sa date tardive, appartient au cluster B (celui de Simenon) plutôt qu'au cluster C (polar contemporain). La proximité avec Simenon repose sur les verbes de déplacement (« monter », « tourner », « marcher » à des fréquences quasi identiques dans les deux textes), et un registre psychologique partagé (« penser », « impression », « peur »). Le cadre de *L'âge bête*, une intrigue située dans un lycée, centré sur les relations entre un adolescent et son père, relève du roman à suspense psychologique des années 1950–1960 par son répertoire lexical, indépendamment de sa date de publication. La connexion avec Jonquet, dont *Mygale* a un profil lexical très différent, passe vraisemblablement par la narration centrée sur un personnage féminin et un vocabulaire de l'enfermement.

Cette approche non-supervisée n'a pas vocation à se substituer aux classifications éditoriales ou historiennes, elle montre comment les textes se regroupent spontanément en familles de ressemblance, indépendamment des catégories génériques explicites, et permet de repérer les zones de transition ou de tension au sein du roman policier.

4.4 Conclusion intermédiaire

Ce chapitre a envisagé le roman policier comme un architexte « modèle », au double sens du terme. Modèle d'abord parce que le policier se présente a priori dans le système littéraire français, comme un genre fortement institué, doté d'attentes stabilisées. Modèle ensuite parce que cette forte architextualité en fait un terrain d'essai privilégié pour les méthodes de classification automatique. En suivant la démarche proposée par Underwood, nous avons montré qu'un simple modèle supervisé, fondé sur des métadonnées attribuées par des chercheurs contemporains,

43. Sjef Houppermans. « Les Gommes : un roman policier poli et scié ». *Roman 20-50* 2010, p. 97-110. DOI : 10.3917/r2050.hs6.0097, p. 99.

parvenait à distinguer les romans policiers des autres fictions du corpus.

L'exploration diachronique nuance cependant cette image rassurante d'un genre homogène et intemporel. En segmentant l'histoire du policier en trois périodes (émergente, canonique et moderne) et en testant la transférabilité des modèles d'une période à l'autre, nous avons mis en évidence le rôle central de la phase canonique comme moment de stabilisation formelle du genre. Un modèle entraîné sur cette période « classique » reconnaît aussi bien les formes antérieures que les prolongements ultérieurs du policier, tandis qu'un modèle émergent généralise mal et qu'un modèle moderne peine à restituer la cohérence de l'ensemble. La courbe de performance sur les fenêtres glissantes confirme ce diagnostic, avec une montée progressive puis un plateau autour de l'entre-deux-guerres jusque dans les années 1960. Ensuite, la capacité de la lexicométrie à saisir le policier décroît nettement, au moment où le genre se diversifie et se recompose.

L'analyse en réseau non supervisée confirme et enrichit ce diagnostic d'une structuration temporelle du genre. Sans aucune information de date ni d'étiquette externe, le graphe se structure spontanément en trois clusters densément connectés qui correspondent aux trois périodes historiques identifiées par l'analyse supervisée. Le cluster A regroupe les textes de la préhistoire du roman policier de 1866 à 1930 (Gaboriau, Leblanc, Leroux, Féval), le cluster B concentre la production « classique » de Simenon et l'univers Maigret de 1931 à 1970, et le cluster C rassemble la production contemporaine de 1965 à 2020 (Malet, Daeninckx, Vargas). Cette partition spontanée suggère que le modèle vectoriel capte les mutations des conventions narratives du genre plus qu'un invariant générique stable. Au-delà de cette structuration dominante, le réseau révèle des zones de transition, avec certains romans qui occupent des positions intermédiaires entre les clusters, jouant un rôle de « ponts » qui relient des ensembles autrement disjoints. Ces passerelles suggèrent des filiations souterraines qui échappent aux découpages éditoriaux, rappelant que l'architexte policier ne se transmet pas par blocs homogènes mais par circulation de configurations narratives qui peuvent traverser les époques.

Chapitre 6

La figure du détective

Objectifs

Ce chapitre s'intéresse à la figure du détective en tant qu'archétype littéraire, en examinant comment elle a été construite et représentée dans la fiction policière. Nous utiliserons des méthodes computationnelles pour analyser les traits linguistiques associés à cette figure à travers un large corpus de romans policiers, afin de comprendre comment elle a évolué au fil du temps et comment elle se manifeste dans différents sous-genres. L'objectif est de tester si des profils linguistiques extraits automatiquement peuvent suivre à la fois la stabilité et les transformations d'un archétype aussi structurant que celui du détective. Nous nous appuierons sur les outils de la narratologie pour définir la caractérisation et le personnage, et nous utiliserons des techniques d'apprentissage supervisé pour construire un détecteur de détectives capable d'identifier cette figure à grande échelle. Enfin, nous analyserons les résultats pour comprendre les invariants discursifs qui sous-tendent la posture de l'enquêteur dans la fiction policière.

Sommaire

1 Introduction **132**
1.1 L'archétype du détective : définition et origines 132
1.2 Caractérisation et personnage 134
1.3 Notre approche computationnelle des personnages 136
2 Le détecteur de détectives **137**
2.1 Corpus et annotation des données 137
2.2 Plongements de personnages 138
2.3 Classification supervisée 139
2.4 Évaluation quantitative 139
2.5 Évaluation qualitative des attributs distinctifs de l'archétype du détective 141
2.6 Distribution des scores de détectivité à l'échelle des personnages 143
2.7 Continuité de la discrimination *détective*, *non-détective* 144
2.8 Analyse des faux négatifs : trois cas d'étude 146
2.9 Analyse des faux positifs : trois cas d'étude 147
3 L'émergence de la figure du détective **148**
4 La trajectoire sémantique de l'archétype du détective **150**

4.1 Les trois régimes du détective . . . 151
4.2 Cas-limites : décalages temporels et enquêtes non policières . . . 154
4.3 Synthèse : du faux positif au degré de détectivité . . . 156
4.4 Étude de contrôle : dérive linguistique générale ou évolution du genre ? . . . 156
5 Discussion . . . **158**
5.1 Interprétation des résultats . . . 158
5.2 Limites . . . 159

> Utilisant des méthodes connues de lui seul, notre enquêteur nous a rapporté de fort intéressantes statistiques.
>
> *René Goscinny et Gotlib.* Les Dingodossiers. *Paris : Dargaud, 1967. 91 p.*

1 Introduction

De[1] toutes les figures que la fiction a stabilisées, celle du détective présente un avantage rare pour l'analyse computationnelle des personnages : un archétype fortement reconnaissable, historiquement situé, théoriquement documenté, et qui traverse des sous-genres suffisamment distincts, du *whodunit* au *roman noir*, pour rendre visibles des inflexions de posture et d'implication narrative. L'enjeu de ce chapitre est de tester, sur ce cas particulièrement structurant, dans quelle mesure des profils linguistiques extraits automatiquement permettent de suivre à la fois la stabilité et les transformations d'un archétype.

Cette question s'inscrit dans un problème plus large, puisque les personnages occupent une position charnière entre le texte et le lecteur. Ils organisent l'investissement interprétatif et demeurent souvent l'un des principaux supports de la mémoire littéraire. Mais comment rendre cette centralité saisissable par des méthodes computationnelles, de façon à comparer des figures à grande échelle, tout en conservant un lien avec leur caractérisation ? La narratologie débat depuis longtemps pour savoir si ces figures ne sont que des « êtres de papier »[2] ou l'illusion de personnes bien réelles[3]. Ce qui reste clair, c'est leur importance à la lecture des romans, et la difficulté à la formaliser quantitativement.

1.1 L'archétype du détective : définition et origines

L'archétype du détective constitue une figure fondamentale du récit d'enquête, dont l'évolution le fait passer d'un simple résolveur d'énigmes périphérique à un personnage central incarnant la rationalité et le raisonnement méthodique. Comme le souligne Dubois, les détectives classiques tels que Dupin, Holmes ou Rouletabille privilégient un travail purement intellectuel, en se tenant à distance de l'action directe. Le détective est une *machine à raisonner*[4], qui met entre parenthèses les mobiles humains ou la psychologie pour ne considérer que l'exactitude des déductions portant

1. Ce chapitre se fonde en partie sur mes contributions à deux articles publiés en anglais en collaboration avec l'équipe du lattice 2025 et 2026. Jean Barré, Olga Seminck et al. « Modeling the Construction of a Literary Archetype : The Case of the Detective Figure in French Literature ». *Computational Humanities Research 2025*. Sous la dir. de Taylor Arnold, Margherita Fantoli et Ruben Ros. Anthology of Computers et the Humanities, 2025, p. 983-999. doi : 10.63744/smbyiwchzj87 et Antoine Bourgois, Jean Barré et al. « Toward an Ontological Representation of Fictional Characters ». *Journal of Computational Humanities Research* 2026, p. 1-15. doi : 10.1017/chr.2026.10025

2. Roland Barthes. « Introduction à l'analyse structurale des récits ». *Communications* 1966, p. 1-27. doi : 10.3406/comm.1966.1113, p. 19.

3. Vincent Jouve. « Pour une analyse de l'effet personnages ». *Littérature* 1992, p. 103-111.

4. Julian Symons. *Bloody Murder : From the Detective Story to the Crime Novel : A History*. London : Faber et Faber, 1972, p. 39.

sur les actes. Dès lors, le détective devient un symbole extrême de rationalité, dont les méthodes reposent systématiquement sur l'interprétation d'indices et de signes afin de résoudre un mystère.

Cette conception trouve une illustration exemplaire dans l'œuvre de Gaboriau, qui s'inspire directement d'Auguste Dupin, héros des nouvelles de Poe, pour créer ses propres figures d'enquêteurs. Dans *L'Affaire Lerouge* (1866), il imagine un policier amateur, le père Tabaret dit Tirauclair, qui possède, comme le personnage de Poe, l'art de raisonner juste. La méthode exposée par Tirauclair illustre parfaitement ce fonctionnement mécanique et déductif : « un crime étant donné, avec ses circonstances et ses détails, je construis pièce par pièce un plan d'accusation que je ne livre qu'entier et parfait. S'il rencontre un homme à qui ce plan s'applique exactement dans toutes ses parties, l'auteur du crime est trouvé. Sinon, on a mis la main sur un innocent » [5]. Cette démarche repose entièrement sur un principe d'induction logique, ainsi que le précise Tirauclair lui-même : « Comment suis-je arrivé au coupable ? En procédant par induction du connu à l'inconnu » [6]. Le détective gaboriausien apparaît ainsi comme un héritier direct de Dupin, appliquant une méthode systématique où l'enchaînement rigoureux des déductions permet de reconstituer la vérité à partir des seuls faits observables.

Cette définition est intimement liée au *whodunit*, sous-genre qui se distingue par une intrigue conçue comme un puzzle, où indices et fausses pistes sont soigneusement distribués pour inviter le lecteur à rivaliser avec le détective. Todorov analyse cette spécificité en mettant en évidence une double structure narrative : « Ce roman ne contient pas une mais deux histoires : l'histoire du crime et l'histoire de l'enquête » [7]. L'identité et la fonction du détective sont indissociables de cette structure : il devient à la fois le guide du lecteur et son double, reconstruisant logiquement un crime qui a déjà eu lieu.

L'archétype agrège un ensemble complexe de personnages qui se transforment dans le temps et selon les sous-genres. Il peut être incarné par une grande diversité de figures, allant du détective amateur au journaliste trop curieux jusqu'au criminel lui-même. En France, cette diversité se matérialise notamment à travers des figures ambiguës, comme Arsène Lupin, à la fois détective et criminel, poursuivi par de véritables détectives tels que le commissaire Ganimard ou l'enquêteur amateur Isidore Beautrelet. Ces incarnations multiples illustrent la manière dont la fiction d'enquête explore différentes perspectives et modalités d'investigation.

Nous ne reviendrons pas ici sur la généalogie sociale et culturelle des figures de l'enquête au XIXe siècle, déjà étudiée par Dominique Kalifa [8], qui montre que le détective moderne se constitue à l'intersection de transformations policières, médiatiques et culturelles. Dans la fiction, l'archétype du détective émerge ainsi à partir des développements littéraires du milieu du XIXe siècle, sous l'influence de figures proto-détectives telles qu'Edmond Dantès (*Le Comte de Monte-Cristo*), Rodolphe (*Les Mystères de Paris*) et Rocambole (Ponson du Terrail) [9]. Ses origines sont

5. Gaboriau, op. cit., p. 345.
6. Ibid., p. 345.
7. Todorov, op. cit., p. 11.
8. Dominique Kalifa. « Policier, détective, reporter : Trois figures de l'enquêteur dans la France de 1900 ». *Mil neuf cent* 2004, p. 15. DOI : 10.3917/mnc.022.0015.
9. Elsa de Lavergne. *La naissance du roman policier français : du Second Empire à la Première Guerre mondiale*. Paris : Classiques Garnier, 2009.

également façonnées par des figures comme Eugène François Vidocq[10], ancien criminel devenu en 1811 le premier chef de la *Sûreté* et fondateur de la première agence de détectives moderne, *Le Bureau de Renseignements*. Vidocq inspire directement le Vautrin de Balzac, ainsi que le Dupin de Poe, deux figures proto-détectives.

Les fondations du roman policier sont posées par Edgar Allan Poe, à travers trois nouvelles mettant en scène Auguste Dupin, enquêteur non professionnel qui résout les crimes en combinant raisonnement intuitif et outils scientifiques : une méthode que Poe nomme *ratiocination*[11]. Si Poe formule d'abord la « recette » policière dans le cadre de la nouvelle[12], Émile Gaboriau (1832–1873) est le premier à l'adapter, dans la tradition française, au format romanesque.

La fiction policière s'impose progressivement comme un genre littéraire majeur à la fin du XIXe siècle et, dans les années 1920–1930, devient une référence centrale de l'imaginaire collectif. Nous l'avons vu au chapitre 5, Régis Messac est un des premiers chercheurs à l'étudier de manière systématique dans sa thèse de doctorat, et il la définit comme « un récit consacré avant tout à la découverte méthodique et graduelle, par des moyens rationnels, des circonstances exactes d'un événement mystérieux »[13]. Sa spécificité tient à une structure narrative qui va d'un crime initial (ou d'un mystère) à sa reconstruction, en produisant une tension dramatique par la multiplication des suspects et par la mise en place d'attentes de lecture propices au suspense. Au-delà du suspense, la figure du détective est décisive : son raisonnement fait pivoter le récit vers sa résolution[14]. C'est par sa logique, son intuition et ses capacités d'analyse que l'intrigue progresse.

1.2 Caractérisation et personnage

Pour saisir ce qui fait l'unité et les variations de cet archétype, il faut s'appuyer sur les outils de la narratologie. En narratologie, la *caractérisation* renvoie à un processus complexe d'attribution de propriétés (actions, discours, perceptions, relations) à des agents dans un monde fictionnel[15].

Le débat sur la centralité du personnage est ancien. Dans le chapitre 6 de la *Poétique*, Aristote subordonne le personnage à l'intrigue :

> Ainsi, le principe et si l'on peut dire l'âme de la tragédie, c'est l'histoire ; les caractères viennent en second […] c'est qu'il s'agit avant tout d'une représentation d'action et, par là seulement, d'hommes qui agissent[16].

La narratologie contemporaine inverse cette hiérarchie : « Ce que veut le lecteur, ce sont des

10. Noel B. Gerson. *The Vidocq dossier : the story of the world's first detective*. Boston : Houghton Mifflin, 1977.
11. Voir à ce sujet la thèse de Murray S Ellison. « Edgar Allan Poe and Science : Unraveling the Plot of the Universe ». Master's thesis. Virginia Commonwealth University, 2015, p. 35-47
12. Cawelti, *Adventure, mystery, and romance*, p. 81.
13. Messac, op. cit., p. 9.
14. Willard Huntington Wright. « The Great Detective Stories ». *The Art of the Mystery Story*. New York : Grosset & Dunlap, 1947, p. 33-70.
15. Uri Margolin. « Characterization in narrative : Some theoretical prolegomena ». *Neophilologus* 1983, p. 1-14. DOI : 10.1007/BF01956983.
16. Aristote, *La poétique*, p. 57.

personnages fascinants et complexes »[17]. Une proposition durable est l'opposition proposée par Forster[18] entre personnages « plat » et « rond » (construits autour d'une idée unique ou capables de surprendre de manière convaincante).

Les perspectives formalistes et structuralistes traitent la figure comme une unité fonctionnelle : un « être de papier »[19] ou un rôle dans une grammaire de l'action, des « dramatis personae » de Propp[20] au schéma actantiel de Greimas[21]. Le *S/Z*[22] de Barthes radicalise cette approche en remplaçant la personne par un réseau de sèmes arrimés à un nom propre. La poétique de la description chez Hamon[23] permet d'en formuler le fonctionnement textuel : les indices descriptifs, répartis dans le récit, construisent le « personnel » du roman en rendant les personnages à la fois identifiables et distincts les uns des autres.

Les approches cognitives déplacent l'accent vers la manière dont les lecteurs perçoivent le personnage. Pour Jouve[24], le personnage est un « effet-personnage » : une construction émergente à l'intersection d'indices textuels et d'une activité de lecture. Margolin décrit précisément le processus inférentiel : la caractérisation s'accumule jusqu'au « character-building »[25] et aboutit sur la stabilisation d'une « constellation »[26] de caractéristiques propres à un personnage. La narratologie des mondes possibles prolonge cette perspective en situant le personnage au sein d'un univers fictionnel doté d'une cohérence propre. Comme l'écrit Ryan, « Contemplé de l'intérieur, l'univers textuel est peuplé d'êtres humains ontologiquement complets qui auraient existé et vécu certains événements même si personne n'avait entrepris la tâche de raconter leur histoire »[27]. Le personnage n'est donc plus seulement un effet de lecture ou une constellation de traits, mais un individu complet dont l'existence déborde le texte qui le manifeste.

Les synthèses de Jannidis[28] définissent la caractérisation comme un processus d'attribution, directe ou indirecte, de propriétés à des référents fictionnels, et soulignent le rôle des connaissances mobilisées par le lecteur dans l'interprétation des personnages. Jannidis distingue à ce titre trois sources principales d'inférence :

> (a) le type de base, qui fournit une structure très fondamentale pour ces entités qui sont vues comme des êtres sensibles ; (b) des modèles ou types de personnages tels que la femme fatale ou le détective hard-boiled ; (c) des connaissances encyclopédiques

17. Robert McKee. *Story : Substance, Structure, Style, and the Principles of Screenwriting*. New York : ReganBooks, 1997, p. 100.
18. Edward Morgan Forster. *Aspects of the novel*. London : Penguin Books, 1988 [1927].
19. Barthes, op. cit., p. 19.
20. Vladimir Iakovlevitch Propp. *Morphologie du conte*. Trad. par Marguerite Derrida, Tzvetan Todorov et Claude Kahn. Paris : Éditions Points, 2015 [1928].
21. Algirdas Julien Greimas. *Sémantique structurale : recherche de méthode*. Paris : Presses Universitaires de France, 2015 [1966].
22. Barthes, *S/Z*.
23. Philippe Hamon. *Le personnel du roman : le système des personnages dans les Rougon-Macquart d'Emile Zola*. Genève : Droz, 1998 [1983] ; Philippe Hamon. *Du descriptif*. Hachette Éducation, 2014.
24. Jouve, « Pour une analyse de l'effet personnages ».
25. Margolin, « Characterization in narrative », p. 4.
26. Ibid., p. 4.
27. Marie-Laure Ryan. *Possible worlds, artificial intelligence and narrative theory*. Bloomington, Ind. : Indiana Univ. Press, 1991, p. 23–24.
28. Fotis Jannidis. *Figur und Person : Beitrag zu einer historischen Narratologie*. De Gruyter, 2008. doi : 10.1515/9783110201697 ; Fotis Jannidis. « Character ». *the living handbook of narratology*. Hamburg : Hamburg University, 2013.

> sur les êtres humains qui sous-tendent les inférences contribuant au processus de caractérisation, c'est-à-dire un stock d'informations allant du savoir quotidien à la compétence spécifique au genre [29].

Les textes attribuent ainsi des propriétés psychologiques, sociales, physiologiques ou spatio-temporelles aux personnages, et c'est au lecteur de travailler leur interprétation. Cette caractérisation peut être explicite ou implicite et demeure contrainte par le régime narratif ainsi que par les indices mis à la disposition du lecteur.

Cette partition est directement pertinente pour notre approche : le détective relève clairement de la catégorie (b), mais les traits qui le caractérisent (verbes d'action, possessions, attributs) sont précisément ceux que les chaînes de traitement automatique peuvent extraire. L'enjeu est de vérifier si ces traces discursives suffisent à reconstituer l'archétype.

1.3 Notre approche computationnelle des personnages

Notre [30] approche assume une réduction méthodologique. Contrairement à la « complétude ontologique » des personnages que postule Ryan, elle traite le personnage comme un faisceau de traces discursives que l'on peut extraire automatiquement, ce qui la rapproche de la caractérisation par attribution de propriétés décrite par Jannidis.

Au cours de la dernière décennie, une part importante de la recherche en narratologie computationnelle s'est concentrée sur la question des personnages. Bamman et al. [31] proposent un *Bayesian mixed-effects model* afin d'inférer, à partir d'un vaste corpus de romans anglais, des types latents de personnages, c'est-à-dire des profils récurrents non définis a priori mais reconstruits statistiquement à partir du texte. Leur étude montre que des méthodes computationnelles peuvent faire émerger des *personas*, autrement dit des configurations typiques de personnages, en analysant les régularités linguistiques associées à leurs actions, à leurs descriptions ou à leurs possessions. Dans le prolongement de cette contribution, la communauté des études littéraires computationnelles a développé des outils spécialisés pour automatiser l'extraction d'informations sur les personnages : BookNLP pour l'anglais [32], ainsi que ses équivalents pour le français [33], l'allemand [34] et le néerlandais [35].

Ces chaînes de traitement permettent une identification plus fiable des mentions de personnages, proposent une résolution de coréférence mieux adaptée aux textes littéraires longs et permettent d'extraire diverses caractéristiques linguistiques associées aux personnages. Les

29. Idem, « Character », Section 2.

30. Nous mentionnons dans cette section des éléments plus amplement développés au chapitre 4 en sous-section 3.1.

31. Bamman, Underwood et Smith, « A Bayesian Mixed Effects Model of Literary Character ».

32. Bamman, Lewke et Mansoor, « An Annotated Dataset of Coreference in English Literature » ; David Bamman. *BookNLP*. 2021.

33. Mélanie-Becquet, Barré et al., « BookNLP-fr, the French Versant of BookNLP. A Tailored Pipeline for 19th and 20th Century French Literature ».

34. Ehrmanntraut, Konle et Jannidis, « LLpro : A Literary Language Processing Pipeline for German Narrative Texts ».

35. Zundert, Cranenburgh et Smeets, « Putting Dutchcoref to the Test : Character Detection and Gender Dynamics in Contemporary Dutch Novels ».

méthodes d'extraction sont le plus souvent fondées sur la syntaxe[36], reposant sur des règles appliquées aux étiquettes morpho-syntaxiques et aux arbres d'analyse pour identifier des traits comme les verbes dont un personnage est le sujet, les dépendants possessifs ou les prédicatifs.

Ainsi, nous proposons de récupérer les informations de nos détectives en trois temps : (i) identification des personnages à l'échelle romanesque avec des chaînes de coréférence et extraction d'attributs (verbes agentifs, modifieurs, possessifs) ; (ii) composition de représentations vectorielles de personnages et apprentissage supervisé d'un *détecteur de détective* ; (iii) inférence à grande échelle pour analyser l'émergence du détective, sa centralité narrative, puis sa trajectoire sémantique diachronique.

2 Le détecteur de détectives

En nous appuyant sur ce riche panorama, notre objectif est d'extraire l'archétype du détective comme une matrice commune à l'ensemble de ces figures, du *Père Tabaret* (première apparition en 1866) au *commissaire Adamsberg* (dernière apparition en 2017), et, paradoxalement, comme une entité qui ne coïncide pleinement avec aucune d'entre elles. Nous visons à mettre en œuvre une approche quantitative[37] capable d'identifier, dans chaque texte, les invariants comportementaux, narratifs et linguistiques qui sous-tendent la posture de l'enquêteur, malgré la diversité des époques, des styles et des rôles (méthodique, intuitif, empathique, cynique, …).

2.1 Corpus et annotation des données

Cette étude s'appuie sur un large corpus de fiction française, le corpus *Chapitres*[38], qui comprend près de 3 000 textes, dont de très nombreux romans policiers.

Détecter l'archétype du détective sur 150 ans d'histoire du genre n'a rien d'évident. Cela requiert deux choses : d'abord, la capacité à identifier de manière fiable les personnages à l'échelle du roman[39]. Nous utilisons pour cela la chaîne de traitement Propp-fr[40], une extension de BookNLP-fr[41] qui facilite la reconnaissance automatique des chaînes de coréférence à l'échelle de romans entiers (plus de 100 000 mots). Ensuite, il faut être capable de distinguer, parmi ces personnages, ceux qui sont des détectives et ceux qui ne le sont pas.

Notre annotation vise à représenter l'archétype du détective à travers différents sous-genres, du *whodunit* français aux thrillers de *série noire*. Nous nous sommes concentrés sur des figures paradigmatiques, dont l'influence est forte en raison de leur récurrence : journalistes amateurs

36. Michael Yoder, Sopan Khosla et al. « FanfictionNLP : A Text Processing Pipeline for Fanfiction ». *Proceedings of the Third Workshop on Narrative Understanding*. Sous la dir. de Nader Akoury, Faeze Brahman et al. Virtual : Association for Computational Linguistics, 2021, p. 13-23. doi : 10.18653/v1/2021.nuse-1.2.

37. Données et code de cette expérience disponibles à l'adresse : https://github.com/lattice-8094/DETECTIVES

38. Leblond, *Corpus Chapitres*.

39. Barré, Cabrera Ramírez et al., « Pour une détection automatique de l'espace personnage dans les romans » ; Bourgois et Poibeau, *The Elephant in the Coreference Room : Resolving Coreference in Full-Length French Fiction Works*.

40. https://github.com/lattice-8094/propp

41. Mélanie-Becquet, Barré et al., « BookNLP-fr, the French Versant of BookNLP. A Tailored Pipeline for 19th and 20th Century French Literature ».

(*Rouletabille*, Gaston Leroux, 1907), hors-la-loi justiciers (*Arsène Lupin*, Maurice Leblanc, 1908), détectives-criminels (*Larsan*, dans le même roman que *Rouletabille*), professionnels intègres (*Lecoq*, Émile Gaboriau ; *Maigret*, Georges Simenon) et adaptations françaises du *hard-boiled* (*Nestor Burma*, Léo Malet, 1942 ; *Gabriel Lecouvreur*, Didier Daeninckx, 1981 ; *Adamsberg*, Fred Vargas, 1991).

Au total, 185 personnages issus de 156 romans ont été annotés comme *Détectives*, représentant 47 figures distinctes (certaines apparaissent dans plusieurs œuvres). Nous avons également annoté 419 personnages comme *Non-Détectives*. Comme notre objectif est une classification binaire (*détective* vs. *non détective*), nous avons veillé à constituer un ensemble négatif diversifié afin que le modèle apprenne aussi ce qui ne définit pas l'archétype. Pour cela, nous avons sélectionné aléatoirement 419 personnages non détectives dans le corpus *Chapitres*, en échantillonant par période de manière à couvrir une variété de rôles et de fonctions narratives.

2.2 Plongements de personnages

Une fois les personnages annotés comme *Détective* ou *Non-Détective*, nous avons construit des représentations vectorielles que nous appellerons des *plongements de personnages* (*character embeddings*), comme les modèles de langue sont fondés sur des plongements de mots. Ces représentations sémantiques s'appuient sur le vocabulaire extrait, conjointement aux chaînes de coréférence, par l'outil Propp-fr. Pour chaque personnage, nous extrayons plusieurs types d'indices textuels : les verbes dont il est le sujet ou l'objet (autrement dit, les actions qu'il accomplit ou qu'il subit), les adjectifs ou attributs qui lui sont associés, ainsi que les noms apparaissant dans des groupes possessifs qui lui sont rattachés. On recueillera ainsi, par exemple, des verbes comme « observer » ou « interroger » des caractérisations comme « méthodique » ou « lucide », et des éléments possessifs comme « son carnet » ou « sa pipe ». Nous faisons l'hypothèse que l'archétype du détective implique une caractérisation textuelle spécifique, susceptible d'être capturée quantitativement.

Ces éléments servent de base à la représentation sémantique. Pour représenter chaque personnage dans un espace vectoriel, nous avons mis en œuvre deux approches distinctes.

Représentation *Sac-de-mots* : La première est une base de comparaison fondée sur un *Sac-de-mots* les plus fréquents. L'idée est de contrôler les dimensions de l'espace vectoriel en sélectionnant simplement les 1 000 mots les plus fréquents parmi les attributs de personnages extraits par BookNLP-fr. Pour chaque personnage de notre jeu de données annoté, nous calculons ensuite la fréquence relative de chacun de ces MFW dans les attributs associés au personnage.

Plongements contextualisés avec CamemBERT : La seconde méthode repose sur des plongements lexicaux contextualisés générés par $\text{CamemBERT}_{\text{LARGE}}$ [42], un modèle de langue de type *encoder-only*, c'est-à-dire un modèle qui produit pour chaque mot une représentation vectorielle dépendant de son contexte dans la phrase, sans chercher à générer lui-même du texte. Pour chaque attribut associé à un personnage, nous extrayons les représentations contextualisées

42. Martin, Muller et al., « CamemBERT : a Tasty French Language Model ».

correspondantes. Le vecteur final de plongement du personnage est obtenu en moyennant les plongements contextualisés de l'ensemble des attributs qui lui sont associés. Cette moyenne élément par élément produit une représentation sémantique dense (1 024 dimensions) qui capture le contexte descriptif du personnage au-delà de la seule fréquence lexicale en surface. Les occurrences où le personnage apparaît comme objet d'un verbe ont été exclues de ce processus, car des expériences préliminaires ont montré qu'elles apportaient un pouvoir discriminant limité pour la tâche de classification, notamment en raison de leur rareté.

2.3 Classification supervisée

Pour prédire si un personnage est un détective, nous utilisons les étiquettes de référence attribuées à la main (dites *gold standard* en anglais) et nous injectons les *plongements de personnages* pré-calculés dans des modèles de classification. Nous comparons deux classifieurs de Scikit-learn [43] : les *Support Vector Machines* (SVM) et la régression logistique [44].

Afin de gérer le déséquilibre des classes, nous recourons à une validation croisée stratifiée en 5 plis (*StratifiedKFold*), qui maintient le ratio détective/non-détective dans chaque découpage. Les performances sont évaluées au moyen de la *balanced accuracy* (*balanced_accuracy_score*).

Afin d'éviter toute fuite d'information (par exemple, un personnage comme le commissaire Maigret apparaissant à la fois dans les ensembles d'entraînement et de test), nous appliquons une stratégie *Leave-One-Group-Out* (LOGO), avec un regroupement par auteur, pour que tous les livres d'un même auteur soient placés intégralement soit uniquement dans l'ensemble d'entraînement, soit uniquement dans l'ensemble de test. Nous définissons trois schémas de regroupement :

1. *Personnage :* toutes les occurrences d'un même personnage sont mises à l'écart ensemble.
2. *Auteur :* tous les personnages associés au même auteur sont placés dans un seul groupe.
3. *Période :* tous les personnages issus d'une même époque historique forment un groupe.

En excluant tour à tour chaque groupe comme ensemble de validation (de sorte qu'aucun personnage, auteur ou période n'apparaisse à la fois dans l'entraînement et le test), nous évaluons de manière rigoureuse la capacité du détecteur à généraliser à des entités entièrement inédites. Cette procédure garantit qu'une surreprésentation de certaines figures de détectives, de certains auteurs ou de certaines périodes ne puisse pas artificiellement gonfler les performances du *Détecteur de détective*.

2.4 Évaluation quantitative

Le tableau 6.1 présente la *balanced accuracy* ainsi que la précision, le rappel et les scores F1 pour les deux classes, pour nos principales configurations, y compris sous les schémas de validation LOGO les plus stricts. La comparaison suit une progression du plus simple au plus complexe. Nous faisons d'abord varier la représentation textuelle : d'un côté, une représentation *Bag-of-Words*,

43. Pedregosa, Varoquaux et al., « Scikit-learn : Machine Learning in Python ».
44. Le lecteur peu familier de ces termes techniques (et de ceux qui suivront) pourra se reporter aux éléments méthodologiques présentés au chapitre 4, en particulier à la section 4.

qui code les textes à partir de la fréquence des mots ; de l'autre, des *embeddings* contextuels produits par CamemBERT, qui représentent les mots en tenant compte de leur environnement linguistique. Nous faisons ensuite varier l'algorithme de classification lui-même, en comparant régression logistique et SVM. L'objectif est donc d'évaluer séparément, puis conjointement, l'effet du type de représentation et celui du classifieur.

En partant de la base *Bag-of-Words*, la régression logistique atteint une *balanced accuracy* de 0,836, mais elle peine en particulier sur la classe *détective* (F1 = 0,75). Le remplacement du classifieur par un SVM produit un gain substantiel (B. Acc. = 0,895), avec une amélioration de la précision et du rappel dans les deux classes. Cela témoigne de la capacité du SVM à tracer des frontières de décision plus nettes, même sur des vecteurs clairsemés et de grande dimension.

En passant aux *embeddings* contextuels, CamemBERT associé à une régression logistique surpasse déjà les deux variantes en sac-de-mots (B. Acc. = 0,906), ce qui suggère que cette représentation capture mieux les régularités sémantiques et permet de mieux généraliser au-delà des seuls mots de surface ; le gain est particulièrement marqué en rappel pour les détectives (0,919). Enfin, lorsque l'on combine les *embeddings* CamemBERT avec un SVM, on obtient les meilleurs résultats : une *balanced accuracy* de 0,923, des précisions et des scores F1 proches de 0,94 (ou au-delà) pour les non-détectives, et un F1 de 0,887 pour les détectives. Cette configuration maintient une précision et un rappel élevés sur la classe détective, pourtant sous-représentée, en minimisant à la fois les faux positifs et les faux négatifs.

Au vu de ces résultats, nous adoptons le modèle CamemBERT + SVM pour l'ensemble des expériences suivantes.

Model	**B. Acc.**	**Non-détective**			**Détective**		
		P	**R**	**F1-score**	**P**	**R**	**F1-score**
BoW + LogReg	0.836	0.94	0.78	0.85	0.64	0.89	0.75
BoW + SVM	0.895	0.95	0.91	0.93	0.81	0.88	0.84
CamemBERT + LogReg	0.906	**0.961**	0.893	0.926	0.791	**0.919**	0.850
CamemBERT + SVM	**0.923**	0.959	**0.938**	**0.948**	**0.866**	0.908	**0.887**
LOGO (Character)	0.901	0.940	0.938	0.939	0.860	0.865	0.863
LOGO (Author)	0.908	0.943	0.945	0.944	0.875	0.870	0.873
LOGO (10 years)	0.915	0.950	0.943	0.946	0.872	0.886	0.879
LOGO (20 years)	0.904	0.940	0.943	0.942	0.870	0.865	0.867
LOGO (50 years)	0.892	0.928	0.952	0.940	0.885	0.832	0.858

TABLE 6.1 : Performances détaillées des modèles : *balanced accuracy* (B. Acc.), précision (P), rappel (R) et score F1 par classe pour le *détecteur de détective*, en fonction des différentes représentations sémantiques et des algorithmes de classification.

Comme on peut le voir dans le Tableau 6.1, les résultats en LOGO diffèrent très peu de ceux du meilleur modèle évalué sans LOGO, ce qui conduit à conclure que, malgré un corpus d'entraînement déséquilibré du point de vue des détectives et des auteurs représentés, le *détecteur de détective* est robuste et peu sensible à la sur-représentation de certaines figures de détectives.

Nous avons en outre examiné avec soin la stabilité temporelle du *détecteur de détective*, afin de

vérifier que les scores élevés n'étaient pas portés par une période particulière et que les détectives étaient identifiés de façon cohérente sur 150 ans. Pour cela, nous avons mené des analyses LOGO sur des intervalles de 10, 20 et 50 ans. Comme l'indique le Tableau 6.1, les résultats ne montrent pas de dégradation significative, ce qui suggère que le modèle n'est biaisé en faveur d'aucune époque spécifique. Cette conclusion est renforcée par l'évolution de l'erreur de prédiction dans le temps (Figure 6.1), qui demeure stable malgré de légères fluctuations. Une telle robustesse diachronique suggère qu'au-delà des variations stylistiques ou éditoriales, la figure de l'enquêteur conserve un ensemble relativement constant de traits linguistiques et narratifs, formant une empreinte discursive reconnaissable qui traverse le temps et unifie 150 ans de fiction d'enquête.

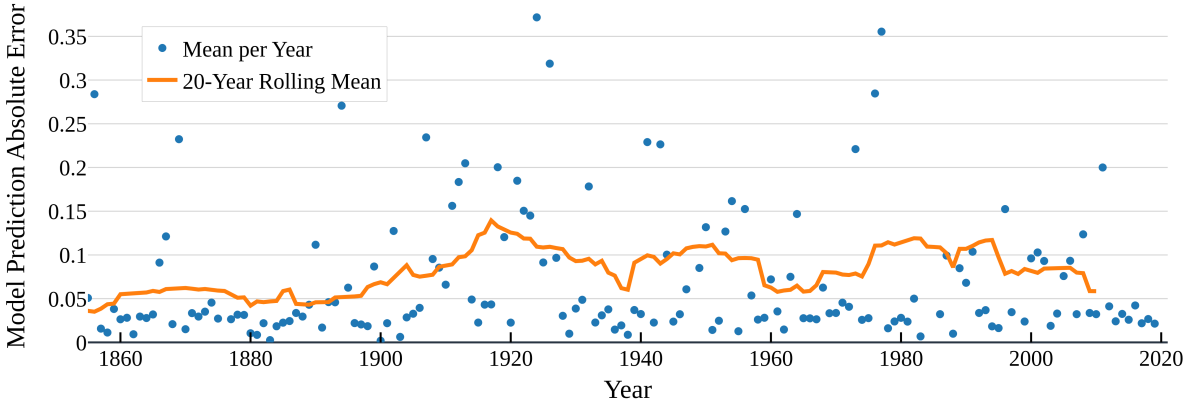


FIGURE 6.1 : Erreurs de prédiction du modèle sur le temps.

2.5 Évaluation qualitative des attributs distinctifs de l'archétype du détective

Si nous avons établi que le *détecteur de détective* atteint une précision élevée, nous avons également voulu comprendre ce qui distingue les personnages *Détective* des *Non-Détectives*. Pour cela, nous examinons les attributs associés aux deux types de personnages dans l'ensemble du corpus *Chapitres*, au sein duquel nous détectons 713 *Détectives* et 29 152 *Non-Détectives*. Afin de comparer ces attributs, nous utilisons une mesure de spécificité fondée sur des *z-scores*, ensuite normalisés dans l'intervalle [-1, 1] pour en faciliter la lecture : une valeur proche de +1 indique un attribut particulièrement distinctif des détectives, une valeur proche de -1 un attribut davantage associé aux non-détectives.

Un z-score est ici un score standardisé : il mesure l'écart entre les deux catégories en le rapportant à la variabilité attendue. Cette méthode évite ainsi de donner trop d'importance à des écarts fondés sur des effectifs très faibles. Concrètement, le numérateur mesure à quel point un attribut est plus associé à une catégorie qu'à l'autre, tout en évitant de surévaluer les mots très rares. Nous suivons ici l'approche de Monroe et al. [45], particulièrement adaptée à l'extraction de caractéristiques lexicales informatives.

45. Burt L. MONROE, Michael P. COLARESI et Kevin M. QUINN. « Fightin' Words : Lexical Feature Selection and Evaluation for Identifying the Content of Political Conflict ». *Political Analysis* 2017, p. 372-403. DOI : 10.1093/pan/mpn018.

$$z_{\text{attr}} = \frac{\log\left(\frac{c_1+\frac{p}{n}}{n_1+1} \Big/ \frac{c_2+\frac{p}{n}}{n_2+1}\right)}{\sqrt{\frac{1}{c_1+\frac{p}{n}} + \frac{1}{c_2+\frac{p}{n}}}}$$

$z_{\textbf{attr}}$ **:** Score de spécificité de l'attribut *(positif = davantage associé au groupe 1)*

c_1 **:** Nombre d'occurrences de l'attribut dans le groupe 1 (détectives)

c_2 **:** Nombre d'occurrences de l'attribut dans le groupe 2 (non–détectives)

p **:** Nombre total d'occurrences de l'attribut dans le corpus ($p = c_1 + c_2$)

n_1 **:** Somme de tous les attributs dans le groupe 1 ($n_1 = \sum c_1$)

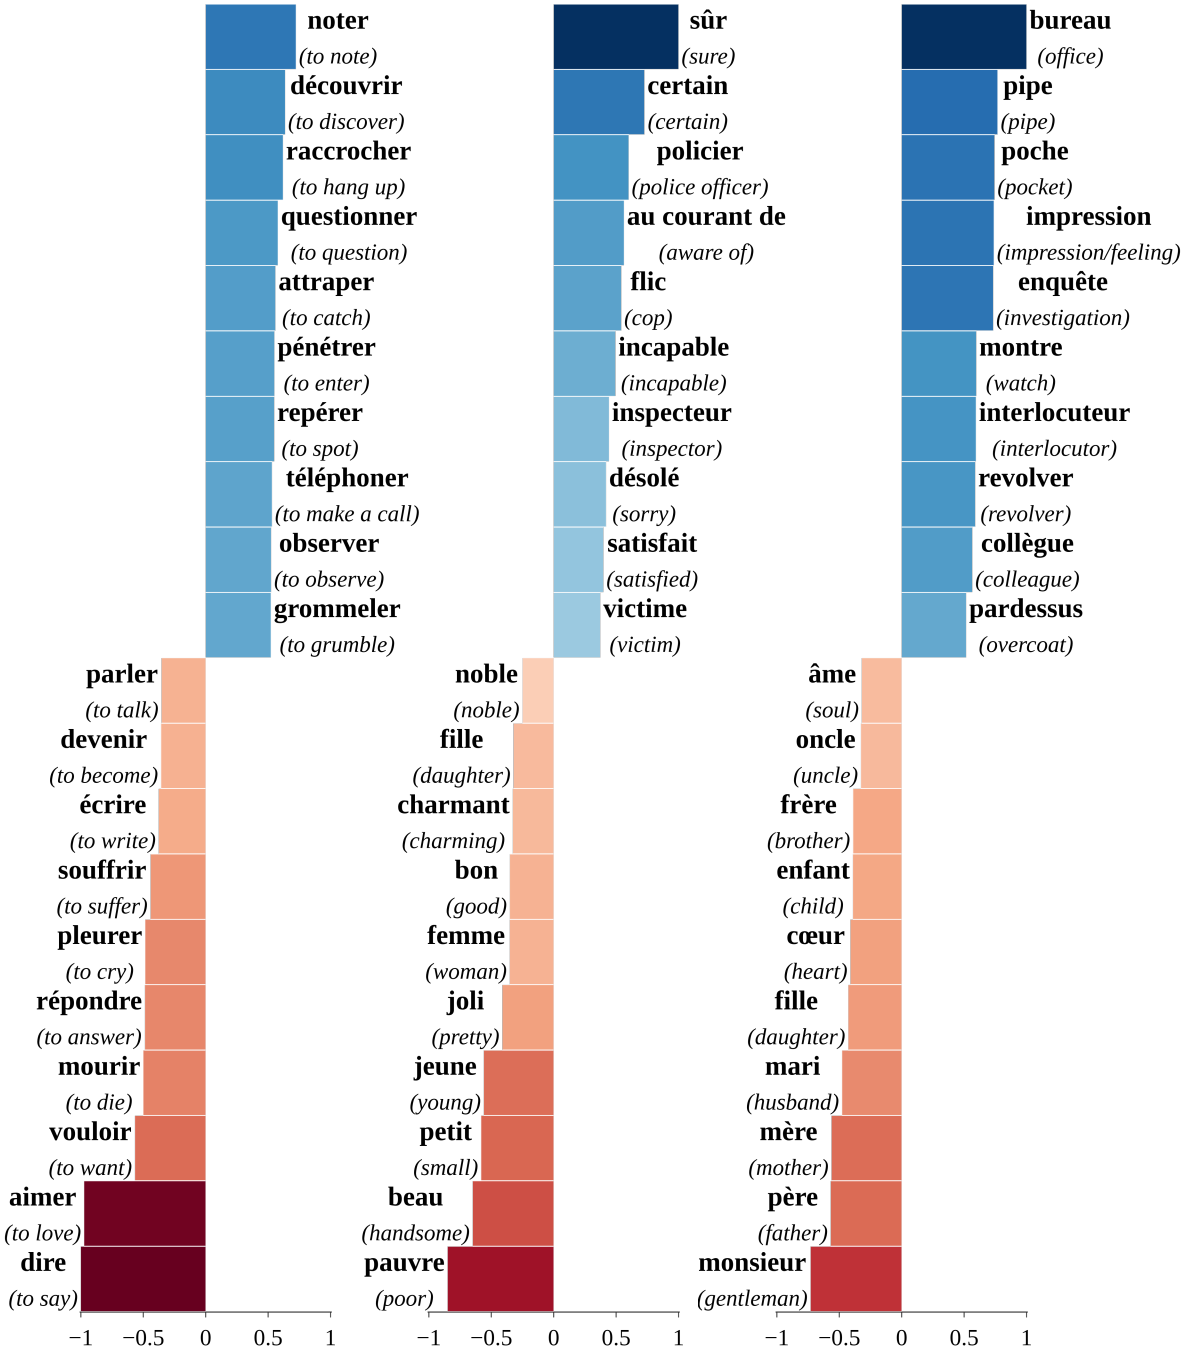
n_2 **:** Somme de tous les attributs dans le groupe 2 ($n_2 = \sum c_2$)

n **:** Somme totale de tous les attributs ($n = n_1 + n_2$)

Pour les trois types d'attributs retenus (verbes agentifs, modifieurs et possessifs), la figure 6.2 présente le vocabulaire le plus typique de l'archétype du détective (en bleu) et le moins typique (en rouge). Les *z-scores* des verbes agentifs se concentrent autour de termes tels que *noter*, *découvrir*, *questionner*, *détecter* et *observer*, ce qui souligne l'identité fondamentale du détective comme penseur méthodique. Ces verbes traduisent une attention incessante portée à la collecte d'indices et à l'inférence, dessinant l'enquêteur comme un appareil de raisonnement quasi mécanique. Tout aussi révélatrice est la forte sous-représentation de verbes comme *aimer*, *pleurer*, *souffrir* ou *désirer*, qui signale une réserve affective distinguant les détectives des autres personnages : leur présence narrative n'est pas définie par la passion ou le trouble, mais par un détachement inébranlable, presque clinique.

Du côté des possessions, les détectives évoquent rarement des liens familiaux ou des relations intimes. Les références à des possessions comme *mère*, *père* ou *fille* sont quasiment absentes, tandis que *manteau*, *poche*, *revolver* et *montre* sont, à l'inverse, surreprésentés : autant d'emblèmes d'une vocation qui privilégie les instruments d'observation plutôt que les attaches de la parenté. Ce motif lexical convoque l'image iconique de l'enquêteur solitaire : manteau boutonné haut, poches gonflées des outils du métier, revolver au côté et montre toujours présente, signalant à la fois la rigueur professionnelle et la solitude personnelle.

Enfin, les modifieurs mettent au jour le codage culturel du détective comme une figure ni féminine ni ornementale. Des scores très négatifs pour des descripteurs comme *femme*, *fille*, *beau* ou *joli* renforcent l'idée que le détective est rarement décrit comme beau ou féminin. L'archétype se cristallise plutôt en une figure solitaire, intellectuellement implacable, avec une posture affectivement neutre. Au final, ces signatures lexicales confirment et nuancent la longue tradition critique qui décrit le détective comme un agent isolé et cérébral, dont l'univers est structuré par l'observation et la déduction.



(a) Verbes agentifs (b) Modifieurs (c) Possessions

FIGURE 6.2 : Caractère distinctif des attributs de la figure du détective, mesuré par un z-score normalisé. Une valeur de +1 indique l'attribut le plus fortement associé aux détectives, et −1 le moins.

2.6 Distribution des scores de détectivité à l'échelle des personnages

L'application du classificateur à l'ensemble des personnages extraits du corpus permet d'observer la distribution des probabilités prédites à une granularité plus fine que l'échelle romanesque. Sur les 29 865 personnages identifiés dans les 3 000 romans du corpus, la très grande

majorité se concentre dans la zone de faibles scores : 28 719 personnages (96,16 %) obtiennent une probabilité inférieure à 0,30, tandis que seuls 452 (1,51 %) dépassent le seuil de 0,70. La zone intermédiaire, comprise entre 0,30 et 0,70, ne regroupe que 694 personnages (2,32 %).

Cette asymétrie reflète une réalité narratologique bien documentée : le personnage-détective, même au sein du roman policier, demeure une figure numériquement marginale. Un récit policier met typiquement en scène une constellation de personnages (des victimes, des suspects, des témoins, des adjuvants) parmi lesquels l'enquêteur n'occupe qu'une position singulière. La rareté des scores élevés traduit donc le fait que la fonction d'investigation qui organise le récit n'est incarnée que par un nombre restreint de figures.

L'examen des 604 personnages disposant d'une annotation manuelle (185 détectives, 419 non-détectives) révèle une polarisation comparable à celle observée au niveau des œuvres. Parmi les détectives annotés, 145 personnages (78,38 %) obtiennent une probabilité supérieure à 0,70, ce qui indique que le modèle parvient à capturer les marqueurs textuels associés à la fonction d'enquêteur (qu'il s'agisse de patrons syntaxiques récurrents, de champs lexicaux spécifiques ou de configurations actantielles caractéristiques). Symétriquement, 388 non-détectives (92,60 %) se situent dans la zone basse, en deçà de 0,30.

Les faux positifs/négatifs représentent seulement 12 détectives (6,49 %), qui obtiennent un score inférieur à 0,30, et 12 non-détectives (2,86 %) qui basculent au-delà de 0,70. Ces cas limites désignent des configurations narratives atypiques : des détectives dont la fonction investigatrice reste implicite ou diffuse, des non-détectives assumant ponctuellement un rôle d'enquête sans en porter les attributs canoniques.

2.7 Continuité de la discrimination *détective*, *non-détective*

Le score de détectivité constitue donc un indice continu qui situe chaque personnage sur un spectre. Cette propriété ouvre des perspectives analytiques que la classification catégorielle ne permettait pas : identifier les figures canoniques du genre, certes, mais aussi repérer les enquêteurs périphériques et les personnages qui, sans être des détectives au sens strict, participent de la logique investigatrice du récit.

La figure 6.3 [46] offre une vue de la distribution des scores de détectivité sur l'ensemble du corpus. Plusieurs phénomènes méritent d'être relevés.

Un découpage vertical. La distribution des points confirme visuellement la polarisation observée dans les statistiques descriptives. La zone basse ($< 0{,}30$) forme un socle dense et continu, rassemblant la quasi-totalité des personnages du corpus. Cette masse grise, qui s'étend sur toute la période étudiée, correspond aux milliers de personnages dépourvues de fonction investigatrice. À l'inverse, la zone haute ($> 0{,}70$) ne contient qu'une population clairsemée, mais nettement distincte. La zone intermédiaire, quant à elle, apparaît comme un espace de transition faiblement peuplé, ce qui confirme que le modèle produit des décisions majoritairement tranchées.

46. Voir le lien ci-après pour un aperçu interactif - Version HTML

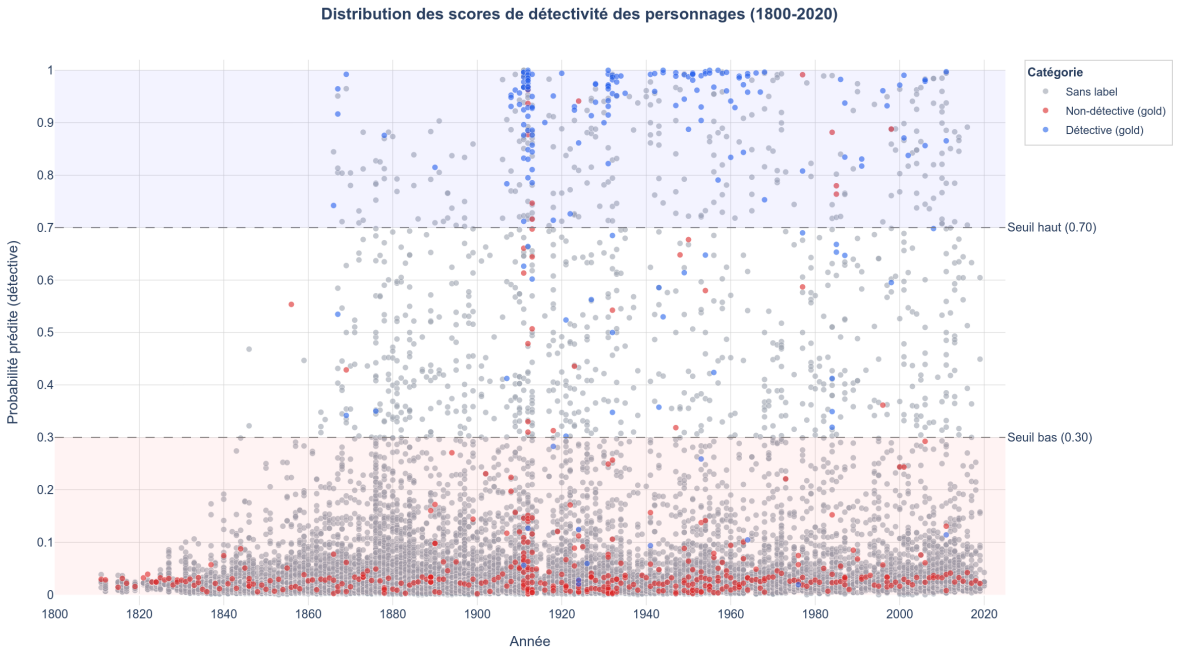


FIGURE 6.3 : Distribution des scores de détectivité des personnages en fonction de l'année de publication (1800–2020). Chaque point représente un personnage, positionné selon la probabilité prédite par le modèle (axe vertical) et l'année de publication du roman dont il est issu (axe horizontal). Les personnages disposant d'une annotation manuelle sont distingués par couleur : bleu pour les détectives, rouge pour les non-détectives, gris pour les personnages sans label. Les zones colorées délimitent les seuils de décision : zone basse ($< 0{,}30$) en rouge pâle, zone haute ($> 0{,}70$) en bleu pâle.

Une émergence historique du score de détective. Avant 1850, la zone haute demeure presque vide. Les premiers personnages à scores élevés apparaissent dans les années 1860–1880, période qui coïncide avec l'apparition progressive du roman policier en France. Cette émergence s'intensifie à partir de 1900, avec une densification notable entre 1900 et 1940. Ces décennies correspondent à l'âge d'or du genre, marqué par la diffusion massive des feuilletons policiers et la canonisation de figures telles que Rouletabille ou Maigret. La seconde moitié du XXe siècle présente une distribution plus régulière, suggérant une stabilisation du genre et de ses conventions.

Validation visuelle du classificateur. La superposition des annotations manuelles permet une évaluation qualitative immédiate. Les points bleus (détectives annotés) se concentrent massivement dans la zone haute, tandis que les points rouges (non-détectives) occupent presque exclusivement la zone basse. Les rares incursions de points rouges au-delà du seuil de 0,70, ou de points bleus en deçà de 0,30, correspondent aux cas d'erreur identifiés dans l'analyse quantitative. Cette séparation visuelle atteste de la robustesse du modèle et de sa capacité à discriminer les fonctions narratives sur la base des seuls attributs textuels.

Un réservoir de détectives potentiels. L'un des apports heuristiques de cette visualisation réside dans les points gris situés dans la zone haute. Ces personnages, dépourvus d'annotation manuelle mais obtenant des scores élevés, constituent des candidats probables à la fonction de détective. Leur distribution temporelle (concentrée sur la période 1880–1960) suggère qu'il s'agit pour l'essentiel de figures issues de romans policiers non inclus dans l'échantillon annoté. Cette population offre un terrain d'exploration pour des analyses ultérieures, qu'il s'agisse de valider manuellement leur statut ou d'étudier les formes périphériques de la fonction de détection.

2.8 Analyse des faux négatifs : trois cas d'étude

L'examen attentif des personnages mal classifiés par le modèle révèle des configurations narratives qui s'écartent significativement du prototype du détective canonique. Ces cas, loin de constituer de simples erreurs, mettent en lumière les limites du modèle face à certaines stratégies d'écriture. Nous avons dans cette section ponctuellement recouru à des modèles de langue génératifs afin de faire émerger des hypothèses de lecture, selon le protocole décrit en section 7.

Maigret dans *Le Fou de Bergerac* (score : 0.35). Le roman de Simenon s'ouvre sur un Maigret en vacances, voyageur ordinaire confronté aux désagréments d'un trajet nocturne en train. Les premières pages accumulent un lexique étranger à l'enquête : chaleur étouffante, insomnie, agacement, somnolence, « demi-bouteille de bordeaux », « chapeau melon posé en travers sur sa tête ». Le commissaire n'est pas en mission, il répond à l'invitation d'un collègue retraité et s'apprête à pêcher le saumon en Dordogne. L'investigation ne débute que par accident, lorsque Maigret saute d'un train en marche pour suivre un inconnu suspect. Cette entrée en matière dilue considérablement les marqueurs textuels associés à la fonction d'enquêteur : le personnage est d'abord un corps fatigué, un voyageur passif, avant d'être un policier. Le titre de « commissaire » apparaît certes, mais noyé dans un contexte sensoriel et domestique qui brouille le signal du détective.

Juve dans *La Mort de Juve* (score : 0.13). Le cas de Juve illustre une difficulté structurelle plus radicale. Le roman d'Allain et Souvestre s'ouvre sur un tout autre personnage : Hervé Martel, courtier maritime parisien dont on suit longuement le réveil, les démêlés avec son cocher, les considérations sur son automobile en commande. Juve n'apparaît pas dans les premiers chapitres ; lorsqu'il est enfin mentionné, c'est comme *victime présumée* : le titre même du roman annonce sa mort, et le récit est saturé par le deuil de ses proches et les spéculations sur sa disparition. Le détective devient ainsi l'objet de l'enquête plutôt que son sujet. Cette inversion des rôles narratifs (le chasseur devenu proie) produit un profil textuel radicalement différent de celui d'un enquêteur actif. Le lexique associé à Juve dans ce roman est celui de la mort, du souvenir, de l'absence : « paralytique », « infirme », « funérailles nationales », « Panthéon ». La révélation finale (Juve est vivant, déguisé parmi la foule) ne suffit pas à compenser l'absence de marqueurs de l'investigation tout au long du texte.

Patricia dans *Les Milliards d'Arsène Lupin* (score : 0.09). Patricia Johnston est la secrétaire du directeur du journal *Allô-Police*, qui devient au fil du roman une véritable journaliste d'investigation : elle file un suspect de New York à Paris, entre dans sa chambre armée d'un revolver pour récupérer des documents volés, utilise sa carte de reporter pour se joindre à une enquête de police, et publie un article à retentissement mondial dans lequel elle démontre le lien entre quatre crimes. Le texte salue sa « clarté magistrale dans les déductions » et les antagonistes la désignent comme « La journaliste qui nous a démasqués ». Le score de 0.09 constitue donc un authentique faux négatif. L'explication la plus directe tient à la composition du corpus d'entraînement : notre classifieur a été entraîné quasi exclusivement sur des détectives masculins, et Patricia est une femme. Le vocabulaire genré qui l'entoure (descriptions physiques, prénoms féminins, pronoms, termes d'adresse) la place d'emblée hors de l'espace vectoriel appris par le modèle comme *détective*. À cette cause première s'ajoute un facteur aggravant propre à la représentation des personnages féminins dans le roman populaire du début du siècle : la fonction d'investigation de Patricia coexiste avec un registre amoureux et victimaire. L'embedding intègre ces deux registres, et le second achève de noyer le signal d'investigation que la composition exclusivement masculine du corpus d'entraînement rendait déjà difficile à capter.

2.9 Analyse des faux positifs : trois cas d'étude

L'examen des personnages annotés comme non-détectives mais ayant obtenu des scores élevés révèle des configurations textuelles qui empruntent massivement au répertoire narratif de l'enquête, sans que les personnages n'occupent la fonction canonique d'enquêteur. Ces cas illustrent la capacité du modèle à détecter des *signatures textuelles* investigatrices indépendamment du statut diégétique des personnages.

Rouxval dans la nouvelle *La Dent d'Hercule Petitgris* (score : 0.94). Le score élevé de Rouxval s'explique par une configuration narrative où le personnage assume temporairement l'ensemble des fonctions de l'enquêteur. Rouxval est ministre, mais le récit le présente dans une posture typiquement détective : il « mesurait d'un pas rapide son vaste cabinet », reçoit des convocations mystérieuses, prépare une « confrontation », interroge des témoins, examine un « dossier » et cherche à résoudre un « scandale effroyable ». Le lexique qui l'entoure est saturé de marqueurs investigatifs : « affaire », « certitudes », « vérification », « solution », « réussir ». Le véritable détective du récit, Hercule Petitgris, n'apparaît qu'en second plan, observant silencieusement tandis que Rouxval conduit l'interrogatoire. Le ministre cumule ainsi les attributs textuels de l'enquêteur (questionnement, confrontation, recherche de la vérité) sans en détenir le titre professionnel.

Bouzille dans *La Guêpe rouge* (score : 0.94). Bouzille est un cheminot alcoolique, figure récurrente et comique de la série Fantômas, qui n'exerce aucune fonction policière. Son score élevé s'explique par son rôle d'*informateur* et d'*auxiliaire d'enquête*. Il transmet des informations cruciales sur les déplacements d'Hélène, reçoit des missions de surveillance (« Si vous revoyez la fille de Fantômas, il faudrait lui remettre ceci »), et observe clandestinement des conversations

suspectes (« Bouzille était curieux comme une commère […] se plaça près de la porte du salon avec l'intention bien nette de regarder par le trou de la serrure »). Le personnage est ainsi immergé dans un bain lexical d'investigation : filature, renseignement, écoute, transmission d'indices. Le modèle détecte cette proximité avec les routines narratives de l'enquête, même si Bouzille en est l'instrument plutôt que le sujet.

Mathieu dans *Charge d'âme* (score : 0.99). Le cas de Mathieu, physicien génial traqué par les services secrets dans le roman de science-fiction de Romain Gary, illustre une configuration plus complexe : celle du *savant-enquêteur* poursuivi. Le personnage cumule plusieurs signatures textuelles associées au détective : il « résout » des problèmes, « observait attentivement », « reconnaissait immédiatement les signes ». Surtout, il est l'objet d'une surveillance permanente par la CIA, le KGB et les RG français : « deux gardes du corps le suivaient discrètement », « La Puissance ne l'avait jamais perdu de vue, l'avait suivi à la trace ». Cette configuration narrative, un personnage central qui détient un secret, est traqué, interrogé, et dont les moindres faits et gestes sont analysés, produit un profil textuel remarquablement proche de celui du détective, bien que Mathieu soit en position de cible plutôt que de chasseur.

3 L'émergence de la figure du détective

Afin d'étendre notre caractérisation de l'archétype du détective au-delà de l'ensemble annoté manuellement, nous avons appliqué le modèle CamemBERT+SVM, notre détecteur le plus performant, à l'ensemble des personnages du corpus *Chapitres*. Pour chaque roman, nous avons retenu les dix personnages les plus saillants (mesurés par leur fréquence de mention), ce qui aboutit à un échantillon de 29 865 personnages. L'objectif est de calculer le pourcentage de détective par rapport à l'ensemble des personnages au fil du temps. Parmi eux, 713 sont classés comme *Détectives*. Cette inférence à grande échelle nous permet de retracer à la fois l'essor quantitatif de la figure du détective et sa saillance narrative sur plus d'un siècle de fiction française.

La figure 6.4 montre que les premiers détectives littéraires émergent autour de 1860, puis que leur proportion augmente fortement à partir de 1900 pour atteindre près de 6 % de l'ensemble des personnages à la fin des années 1930. Après 1940, la fréquence relative des détectives diminue autour de 4 %, avant de connaître un léger regain dans les années 1980.

Lavergne[47] identifie la figure de l'enquêteur comme un élément clé dans l'émergence du genre du roman policier. Longtemps relégué à un rôle secondaire, l'enquêteur devient le personnage central qui pilote la reconstruction progressive du drame. Nous avons également mesuré l'importance narrative du détective à l'aide du *mention-ratio* (la longueur de la chaîne de coréférence d'un personnage rapportée à la moyenne des autres personnages du livre). La figure 6.5 met en évidence une trajectoire ascendante continue, du milieu du XIXe siècle jusqu'à la fin de notre corpus, avec une première inflexion autour de 1900. La courbe souligne qu'à mesure que la fiction policière se constitue et se stabilise, l'enquêteur ancre de plus en plus la narration, même lorsque

47. Lavergne, *La naissance du roman policier français*.

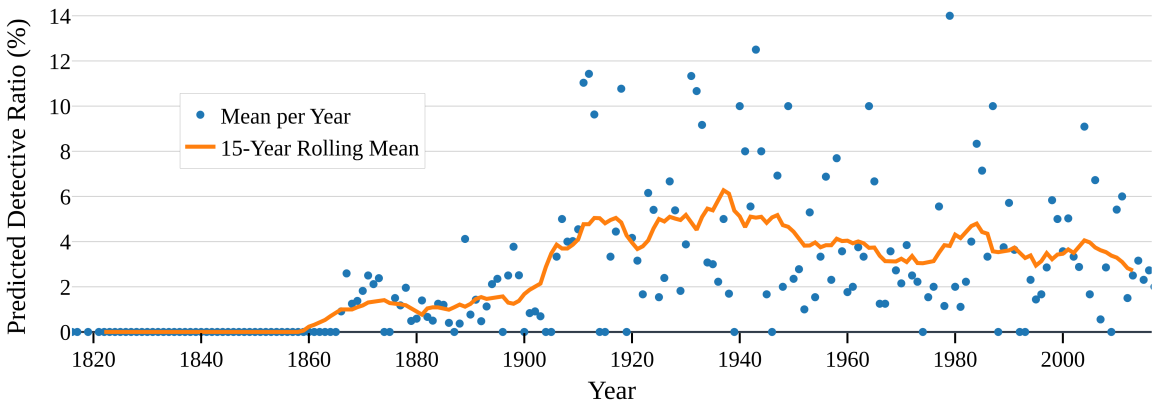


FIGURE 6.4 : Ratio de personnage *Détective* prédit par le modèle au fil du temps

les sous-genres se diversifient entre 1950 et 2000 (*hard-boiled, série noire, néo-polar, espionnage*) : cette diversification élargit le spectre des représentations du détective tout en préservant sa forte visibilité.

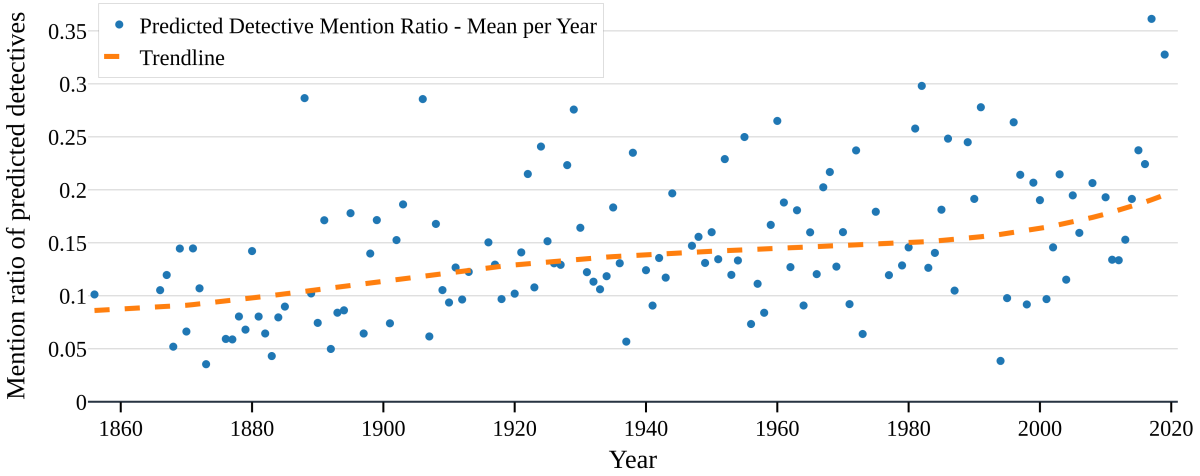


FIGURE 6.5 : Établissement progressif du détective comme élément central du récit

L'association de ces deux constats, à savoir l'augmentation du nombre de figures de détectives et leur centralité croissante, suggère un mouvement double. D'une part, l'archétype se cristallise suffisamment tôt pour rester reconnaissable, même lorsque la fiction policière expérimente de nouvelles formes. D'autre part, la dépendance croissante de la narration vis-à-vis de la figure de l'enquêteur indique que la résolution du mystère dépend de plus en plus de la voix et de la subjectivité du détective ; celui-ci n'est plus un simple auxiliaire du récit, mais le pivot autour duquel la tension narrative s'organise.

Cela soulève une question centrale pour la suite de notre étude : dans quelle mesure l'identité discursive de l'archétype du détective reste-t-elle constante au cours de 150 ans d'histoire du genre ? Au-delà de la persistance d'un ensemble central de marqueurs textuels, l'empreinte sémantique de l'archétype (ses façons caractéristiques de parler, de percevoir et d'enquêter) est-elle réellement stable, ou subit-elle des changements subtils au fil des contextes génériques

et historiques successifs ? Pour répondre à cette question, nous nous tournons vers une analyse diachronique et fine de la trajectoire sémantique de l'archétype.

4 La trajectoire sémantique de l'archétype du détective

Dans cette section, nous examinons la manière dont l'archétype du détective évolue au fil du temps, en mettant au jour des glissements sémantiques subtils au-delà de ses marqueurs textuels centraux. Pour retracer cette trajectoire à grain fin, nous partons des *embeddings* contextuels CamemBERT des 713 personnages que notre modèle a identifiés comme *Détectives* dans le corpus *Chapitres* et nous menons une expérience de *clustering* : nous réduisons d'abord ces représentations de grande dimension à deux dimensions à l'aide de l'algorithme UMAP (*uniform manifold approximation and projection*) [48] (*n_neighbors=10*). Visuellement, trois grands amas se distinguent nettement dans l'espace. Nous avons donc choisi de poursuivre avec un *clustering* fondé sur l'algorithme des K-means, en imposant trois clusters, ce qui a confirmé notre intuition initiale quant aux frontières entre groupes. Les résultats sont présentés dans la figure 6.6. On observe clairement l'influence de l'année de publication sur ce regroupement : les détectives issus de périodes proches tendent à se retrouver dans les mêmes clusters.

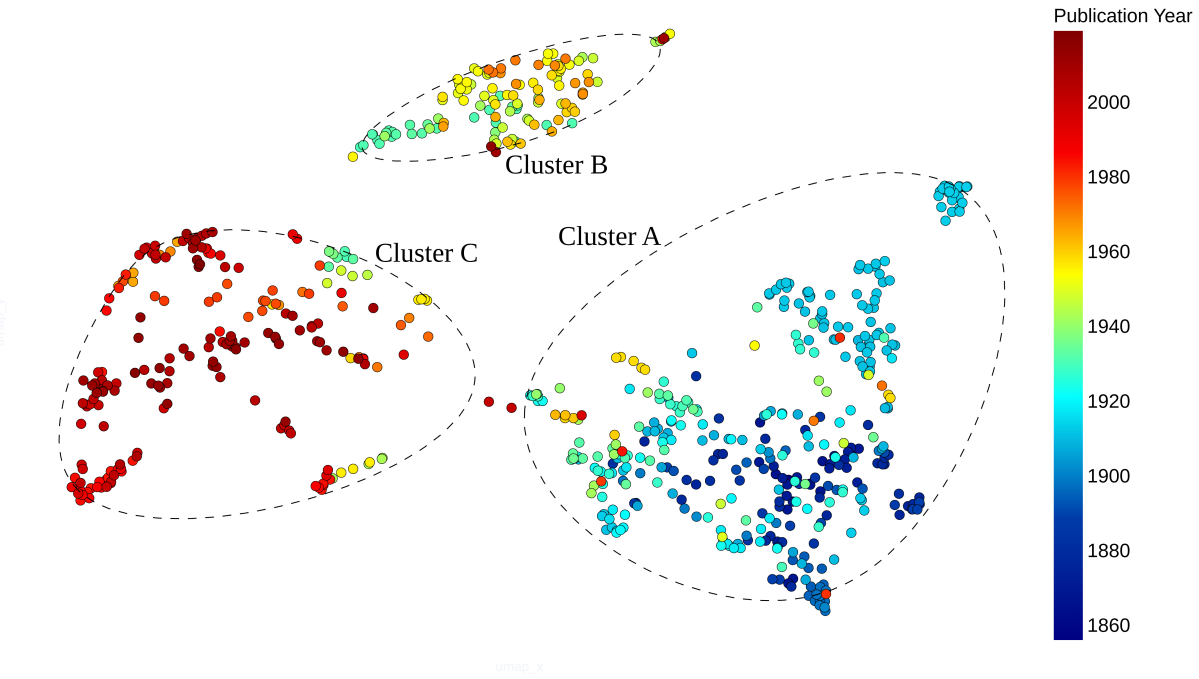


FIGURE 6.6 : Regroupements de détectives

Afin de déterminer si ces trois clusters correspondent à des phases distinctes dans la trajectoire sémantique des sous-genres policiers, nous avons appliqué la méthode par *z-scores* de la sous-section 2.5 afin d'extraire, pour chaque cluster, les attributs lexicaux les plus distinctifs. Cette fois, nous n'avons pris en compte que les attributs à score positif (z-score > 0), puisque l'on

48. Leland McInnes, John Healy et James Melville. *UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction*. 2020. arXiv : 1802.03426 [stat.ML].

veut comparer ce qui fait la spécificité de chaque cluster, pas leur vocabulaire commun. Ce vocabulaire est présenté dans le Tableau 6.3. Nous interprétons les traits spécifiques de chacun des trois clusters en examinant de plus près ce vocabulaire et en le replaçant dans ses contextes d'occurrence au sein du corpus *Chapitres*.

Cluster	Borne basse (p15)	Borne haute (p85)
A	1881	1931
B	1932	1964
C	1965	2011

TABLE 6.2 : Bornes temporelles des trois clusters de détectives, définies par quantiles robustes (p15–p85) de l'année de publication.

Les trois clusters mis au jour par l'analyse UMAP + K-means ne se laissent pas seulement décrire comme des paquets statistiques : ils correspondent à des régimes relativement cohérents de caractérisation du détective, qui s'organisent aussi dans le temps. Pour objectiver cette dimension diachronique, nous avons calculé, pour chaque cluster, une fenêtre temporelle robuste fondée sur les quantiles (p15–p85) des années de publication. Ce choix permet de décrire des bornes typiques en minimisant l'effet de quelques erreurs de datation ou de valeurs aberrantes (p. ex. métadonnées bruitées). On obtient ainsi des intervalles nettement séparés (Cluster A : 1881–1931 ; Cluster B : 1932–1964 ; Cluster C : 1965–2011). Ces seuils ne doivent pas être compris comme une périodisation étanche du genre, mais comme des zones de forte densité où se stabilisent des signatures linguistiques distinctes de la figure de l'enquêteur.

4.1 Les trois régimes du détective

Avant d'examiner les clusters et leur vocabulaire distinctif, il convient de resituer brièvement les trois périodes dans l'histoire du roman policier français.

La période du cluster A (1881–1931) couvre l'installation du genre policier en France. C'est l'époque de Gaboriau, puis de Leroux et Leblanc au début du XXe siècle. Les détectives de cette période sont déjà des figures sérielles (Lecoq, Rouletabille, Lupin), mais leur identité reste plus labile que celle des grandes figures du milieu du siècle : Lupin oscille entre criminel et enquêteur, Lecoq n'est pas toujours le protagoniste. Surtout, le détective est davantage défini par ses opérations (déduction, interrogatoire, filature) que par un éthos ou des routines reconnaissables. L'enquête se construit par accumulation de traces et circule entre différents espaces sociaux (police, presse, aristocratie, bas-fonds).

La période du cluster B (1932–1964) correspond à l'âge d'or du roman policier en France. Simenon commence à publier les Maigret en 1931, et la figure du commissaire s'impose rapidement comme l'incarnation du détective français. Contrairement aux héros de la période précédente, Maigret est institutionnalisé, professionnel, ancré dans une routine. Les romans à énigme britanniques (Christie, Sayers) sont largement traduits et influencent la production française. Le détective devient un rôle social reconnaissable, avec ses gestes, ses méthodes, son éthos. Cette période voit aussi l'émergence du roman noir américain traduit en Série Noire (créée en 1945),

mais le corpus français reste dominé par la figure du policier professionnel.

La période du cluster C (1965–2011) est celle de la diversification. Le néo-polar des années 1965–1980 (Manchette, Daeninckx) politise l'enquête et critique l'institution policière. Fred Vargas crée Adamsberg, policier professionnel entouré d'une équipe en se plaçant dans l'héritage de Simenon, mais en amenant un détective plus dilettante, plus fondé sur son intuition, ce qui pose d'ailleurs problème à son adjoint Danglard. Léo Malet, bien qu'ayant créé Nestor Burma dans les années 1940, connaît une seconde vie éditoriale dans les années 1965–1980. L'enquête se distribue davantage entre plusieurs personnages (binômes, équipes, réseaux d'informateurs). Le détective devient un opérateur flexible, susceptible d'incarner des postures très différentes.

Cluster A (1881–1931) Les personnages les plus prototypique du cluster sont Juve et Fandor (Allain et Souvestre), le père Tabaret et Lecoq (Gaboriau), et le couple Lupin/Ganimard (Leblanc). Ces figures partagent moins l'absence d'ancrage institutionnel qu'une relative hétérogénéité des statuts : Tabaret est un amateur, Fandor un journaliste, Lupin un criminel-enquêteur, tandis que Lecoq, Juve et Ganimard sont bien des policiers, mais souvent définis moins par leur fonction administrative que par leur singularité narrative. On peut faire l'hypothèse que ce qui les regroupe est un régime d'enquête antérieur à la professionnalisation du genre. Cette lecture rejoint l'analyse de Jean-Claude Vareille, pour qui le roman policier de la Belle Époque « fait de l'*enquête* d'abord une *quête* » [49] et conserve une forte parenté avec le roman d'aventures. Cette hypothèse reste néanmoins interprétative : le modèle ne capture que des proximités vectorielles entre les représentations de ces personnages.

Le vocabulaire distinctif du cluster confirme cette lecture, et la signature tient à une abondance de marqueurs de dialogue : « dire », « répondre », « déclarer », « s'écrier », « murmurer », « interroger ». Le détective de cette période est d'abord un interlocuteur dont la puissance d'enquête s'actualise dans et par le dialogue. Les possessifs (« ami », « compagnon », « revolver », « complice », « ennemi ») dessinent un univers relationnel où le détective navigue entre alliés et adversaires. Les modifieurs (« mystérieux », « faux », « honnête ») renvoient à un monde d'identités incertaines. Le cluster A correspond ainsi à un premier régime de l'enquête, où l'élucidation passe largement par la parole, l'interrogatoire et la déduction.

La présence de Lupin dans ce cluster appelle une précaution, puisqu'il n'est pas un détective au sens strict : c'est un cambrioleur, un maître du déguisement. Si le modèle l'agrège au pôle détective, c'est vraisemblablement parce que les récits de Lupin mobilisent intensément les mécanismes de l'énigme et du dévoilement, et que dans le binôme Lupin/Ganimard, les deux personnages partagent les opérations cognitives de l'enquête, même si leurs positions institutionnelles sont opposées.

Cluster B (1932–1964) La période du cluster B correspond à l'âge d'or du roman policier français, symboliquement inauguré en 1927 par la collection *Le Masque*. Maigret occupe la position centrale du cluster. Cette centralité n'est pas seulement quantitative (plus de 70 romans

49. Jean-Claude Vareille. « Roman policier archaïque et aventure archaïque ». *L'Aventure dans la littérature populaire au xixe siècle*. Sous la dir. de Roger Bellet. Lyon : Presses universitaires de Lyon, 1985, p. 185-196. doi : 10.4000/books.pul.1232, p. 186.

entre 1931 et 1972) : les personnages qui l'entourent dessinent un régime de caractérisation plus homogène que celui du cluster A. On observe une stabilisation de la figure du détective autour d'un rôle professionnel récurrent : les personnages de ce cluster sont majoritairement des fonctionnaires de police ou des enquêteurs de métier, là où le cluster A mêlait amateurs, journalistes et criminels. Cette observation est cohérente avec l'institutionnalisation du genre dans l'entre-deux-guerres.

Les verbes se déplacent de la parole vers la perception et l'intériorité : « regarder », « supposer », « se souvenir », « soupirer ». Comme le note Cawelti, « Les compétences de Maigret comme détective […] ne reposent pas sur la déduction rationnelle, mais sur une énergie infatigable et une intuition irrationnelle. » [50]. Les possessifs (« pipe », « bureau », « pardessus », « chapeau », « inspecteur », « collègue ») ancrent le détective dans un mobilier professionnel et dans une routine. Les modifieurs (« commissaire », « police », « fatigué », « maussade », « marié ») dessinent un personnage incarné, doté d'un corps fatigué, d'une vie conjugale, d'une position institutionnelle. L'enquête n'est plus un pur exercice de déduction : « le mystère ne porte ni sur l'identité du meurtrier ni sur la manière dont le crime a été commis ; il réside dans la question de savoir si le détective parviendra à l'élucider » [51]. Le lecteur est « placé dans la confidence d'une grande partie des inférences et des déductions qu'il tire des indices. » [52] : l'intériorité du détective devient le lieu du récit.

Cluster C (1965–2011) Le cluster C présente une hétérogénéité plus forte que les deux précédents, ce qui est cohérent avec la diversification du genre dans la seconde moitié du XXe siècle. Les personnages les plus prototypiques (Adamsberg et Danglard chez Vargas, Nestor Burma chez Malet, Gabriel Lecouvreur chez Daeninckx) illustrent des postures très différentes : intuition et rêverie chez Adamsberg, érudition chez Danglard, marginalité urbaine chez Burma, enquête à dimension politique chez Daeninckx. La diversité même de ces figures suggère que le cluster C ne se définit pas par un prototype unique, mais par opposition aux régimes plus homogènes des clusters A et B.

Les verbes marquent un rapport plus physique au monde : « sentir », « attraper », « enfiler », « avaler », « croiser ». Les possessifs se déplacent vers le corps et les objets matériels : « corps », « ventre », « dos », « doigt », « peau », « téléphone », « voiture », « sac ». Les modifieurs (« flic », « type », « nu », « seul », « désolé ») signalent une oralité plus crue et une solitude du détective. Le terme « foutre », vulgaire et polysémique, est emblématique de cette modernisation du registre. Cette période est marquée par ce que Cadin [53] appelle le « moment américain de la littérature française » : la *Série Noire* puis le néo-polar reconfigurent la fiction policière française. Mais le cluster C accueille aussi des figures plus introspectives.

Avec Adamsberg (première apparition en 1991 dans *L'Homme aux cercles bleus*), Vargas prolonge à sa manière une lignée du détective intuitif et empathique. Becker situe déjà Maigret dans le tournant du roman policier de l'après-Première Guerre mondiale, marqué par des méthodes

50. Cawelti, *Adventure, mystery, and romance*, p. 126.
51. Ibid., p. 126.
52. Ibid., p. 127.
53. Cadin, « Le moment américain du roman français ».

d'investigation fondées sur « l'instinct, l'intuition et l'empathie » [54] plutôt que sur la déduction rationnelle. Maigret, écrit-elle, « à la différence de celui de Holmes, n'est pas de raisonner, mais de comprendre intuitivement » [55]. Boisvert montre quant à elle qu'Adamsberg s'inscrit lui aussi dans cette filiation, en le décrivant comme un enquêteur relevant, malgré sa contemporanéité, de cette même ère « post-Première Guerre mondiale » [56].

Le cas de Nestor Burma mérite d'être signalé : bien que créé dans les années 1940, il est placé dans le cluster C plutôt que dans le cluster B. Ce décalage est doublement interprétable. D'une part, Burma incarne un détective privé urbain, marginal et désabusé, dont le style l'apparente davantage à « une veine noire du roman français » [57] qu'au policier d'énigme. D'autre part, Malet connaît une seconde vie éditoriale dans les années 1965–1980, si bien que la réception et la circulation de Burma coïncident avec la fenêtre du cluster C. Le modèle semble capter cette proximité stylistique avec le néo-polar tardif plutôt que la seule date de création du personnage.

Synthèse des trois régimes. L'articulation temporelle A/B/C peut être reformulée comme une trajectoire interprétable : un premier régime où l'enquêteur est surtout défini par la déduction mise en scène et la parole (A), un second où il se définit par une présence plus incarnée, un rapport au social et une intériorisation relative (B), puis un troisième où dominent une modernité du registre, une matérialité plus forte (corps/objets/mobilité) et une tension accrue avec la violence du monde représenté (C). Ces bornes ne prétendent pas « dater » le genre au sens strict, elles montrent plutôt que, dans les traces linguistiques de caractérisation captées par nos attributs, l'archétype du détective s'organise en régimes successifs qui correspondent à des transformations bien connues de l'histoire du policier français, tout en laissant place à des figures de transition et à des chevauchements, que nous examinerons dans la section suivante.

4.2 Cas-limites : décalages temporels et enquêtes non policières

L'examen des personnages qui ne se trouvent pas dans le cluster correspondant à leur période permet de préciser ce que le modèle capte au-delà de la simple chronologie.

Persistances formelles dans le cluster A. Le cluster A accueille quelques cas postérieurs à 1931, notamment le personnage de Simon dans *Djinn* de Robbe-Grillet (1981). Ce placement est cohérent avec ce que l'on observe par ailleurs pour *Les Gommes* dans l'analyse des réseaux de similarité (sous-section 4.3) : Robbe-Grillet reprend et déplace plusieurs codes du roman d'enquête. Comme l'écrit Houppermans, « le policier moderne imite et pervertit les clés de la tradition du genre » [58]. Le modèle rapproche vraisemblablement ces textes du cluster A parce qu'ils partagent avec les récits fondateurs un même répertoire de motifs, indépendamment de l'intention subversive de l'auteur.

54. Lucille F. Becker. *Georges Simenon*. Boston, Mass : Twayne, 1977, p. 36.
55. Ibid., p. 37.
56. Jayne R. Boisvert. « Introducing Fred Vargas : Commissioner Adamsberg, the Anti-flic as Interpreter of Signs ». *The French Review* 2012, p. 826-836. doi : 10.1353/tfr.2012.0228, p. 829.
57. Natacha Levet. *Le roman noir, une histoire française*. Paris : Presses Universitaires de France / Humensis, 2024, pp. 15.
58. Houppermans, « Les Gommes », p. 99.

	Cluster A	Cluster B	Cluster C
Agent Verbs	dire (to say)	questionner (to question)	sentir (to feel)
	s'écrier (to exclaim)	téléphoner (to make a call)	attraper (to catch)
	répondre (to answer)	supposer (to suppose)	poser (to put down)
	déclarer (to declare)	regarder (to look)	foutre (to not care / to make fun of)
	murmurer (to murmur)	bourrer (to stuff)	repérer (to spot)
	répliquer (to reply)	préférer (to prefer)	tenter (to attempt)
	interrompre (to interrupt)	fumer (to smoke)	lever (to get up)
	venir (to come)	connaître (to know)	croiser (to run into)
	demeurer (to remain)	boire (to drink)	acquiescer (to nod / to agree)
	reprendre (to resume)	avoir (to have)	se souvenir (to remember)
	ajouter (to add)	se souvenir (to remember)	sortir (to go out)
	interroger (to question)	savoir (to know)	enfiler (to put on (clothes))
	affirmer (to assert)	permettre (to allow)	vérifier (to check)
	crier (to shout)	soupirer (to sigh)	avaler (to swallow)
Modifiers	cher (dear)	sûr (sure / confident)	désolé (sorry)
	jeune (young)	lourd (heavy)	petit (small)
	brave (brave)	roux (red-haired)	flic (cop)
	malheureux (unhappy)	peine (sorrow / grief)	nu (naked)
	vieux (old)	commissaire (commissioner)	responsable (responsible)
	pauvre (poor)	maussade (gloomy / sullen)	certain (certain)
	excellent (excellent)	police (police)	seul (alone)
	faux (false / fake)	spécial (special)	censé (supposed)
	digne (worthy)	ivre (drunk)	conscient (aware)
	mystérieux (mysterious)	marié (married)	incapable (incapable)
	général (general)	incapable (incapable)	type (guy / dude)
	bon (good)	fatigué (tired)	proche (close / nearby)
	honnête (honest)	gros (fat)	enquêteur (investigator)
	misérable (miserable)	large (broad / wide)	au courant de (aware of)
Possessives	ami (friend)	pipe (pipe)	veste (jacket)
	parole (word / promise)	bureau (office / desk)	corps (body)
	compagnon (companion)	femme (wife)	téléphone (phone)
	dieu (god)	pardessus (overcoat)	sac (bag)
	maître (master)	chapeau (hat)	mal (pain / suffering)
	monsieur (gentleman)	inspecteur (inspector)	lunette (glasses)
	revolver (revolver)	impression (impression / feeling)	voiture (car)
	ordre (order)	envie (desire)	dos (back)
	foi (faith)	interlocuteur (interlocutor)	père (father)
	cabinet (office / cabinet)	collègue (colleague)	visage (face)
	ennemi (enemy)	veston (jacket)	ventre (belly / stomach)
	devoir (duty)	collaborateur (collaborator)	doigt (finger)
	complice (accomplice)	poche (pocket)	peau (skin)
	cheval (horse)	client (client)	mère (mother)

TABLE 6.3 : Attributs les plus distinctifs de chaque cluster de détectives.

Réinvestissements dans le cluster B. Le cluster B accueille des cas tardifs, notamment Camille Verhœven chez Pierre Lemaitre (2011). Le placement d'un commissaire de la Brigade criminelle dans le cluster de Maigret peut s'expliquer par le réinvestissement, chez Lemaitre, de routines d'enquête stabilisées dans l'entre-deux-guerres : interrogatoires de témoins, reconstitutions méthodiques, scènes de confrontation, travail d'équipe au sein de l'institution policière. L'hypothèse est que le cluster B ne désigne pas seulement une période historique, mais un régime narratif : celui de l'enquête institutionnalisée, organisée autour de gestes reconnaissables, qui peut être réinvesti dans des récits postérieurs.

Enquêtes non policières dans le cluster C. Le cluster C accueille des personnages issus de romans qui ne relèvent pas du genre policier, notamment chez Malraux (*La Condition humaine*, 1933 ; *L'Espoir*, 1937). Les personnages de Malraux ne sont pas des détectives, mais ils

évoluent dans des contextes de clandestinité et de décision sous incertitude : secret, soupçon, recoupement d'informations, vérification de sources, confrontation de versions concurrentes. Le modèle semble capter cette économie informationnelle partagée entre le roman d'enquête et le roman révolutionnaire. Ce rapprochement suggère que la notion de détective telle que le modèle la construit repose sur une fonction épistémique : produire un savoir à partir d'indices dispersés et de témoignages contradictoires, dans un contexte de dissimulation.

4.3 Synthèse : du faux positif au degré de détectivité

Plutôt que de traiter les occurrences problématiques comme de simples erreurs, on peut les lire comme des indices d'un phénomène plus intéressant : le modèle repère une fonction narrative. Un personnage qui participe à des interrogatoires, qui collecte des témoignages, qui confronte des versions contradictoires ou qui reconstitue des événements passés produit des signaux textuels similaires à ceux du détective, indépendamment de son statut social. C'est cette fonction que le modèle capte sous le terme de détectivité, et c'est elle qui explique la présence, dans les zones frontalières des clusters, de personnages issus du roman d'espionnage, du roman politique ou du roman familial. Ces cas-limites montrent que la figure du détective, telle que le modèle la construit, déborde le genre policier au sens strict pour désigner une position épistémique partagée par plusieurs traditions narratives.

4.4 Étude de contrôle : dérive linguistique générale ou évolution du genre ?

L'interprétation des trois clusters temporels repose sur l'hypothèse que les différences lexicales observées reflètent une évolution propre à la figure du détective. Or, une objection méthodologique s'impose : ces différences pourraient n'être qu'un artefact de la dérive diachronique du français littéraire dans son ensemble, indépendantes du seul genre policier. Les différences observées renverraient alors à un mouvement de fond discursif plus large.

Afin de démêler l'évolution interne au genre de la dérive linguistique générale, nous avons construit une expérience de contrôle comparant les profils diachroniques des personnages détectives à ceux d'un ensemble de personnages non-détectives issus des mêmes périodes.

4.4.1 Protocole

Nous avons réutilisé les trois bornes temporelles inférées à partir des clusters de détectives (moyennes : 1910, 1950, 1989), en calculant les points médians entre clusters successifs pour définir deux seuils : $b_1 \approx 1931$ et $b_2 \approx 1965$. Ces seuils délimitent trois périodes, *proto*, *classique*, *contemporain* auxquelles nous avons affecté l'ensemble des personnages du corpus, qu'ils soient détectives ou non.

Le groupe contrôle comprend 29 136 personnages non-détectives (5 464 en période *proto*, 4 074 en période *classique*, 5 598 en période *contemporain*), contre 713 détectives (325, 195 et 193 respectivement). Pour chaque période et chaque type d'attribut (verbes agentifs, modifieurs, possessifs), nous avons calculé les mêmes *z-scores* qu'en sous-section 2.5, afin de comparer les

personnages de la période cible à ceux des deux autres périodes, d'abord dans le groupe contrôle, puis dans le groupe détective.

Cette procédure produit, pour chaque attribut, deux *z-scores* : l'un mesurant son association avec la période dans le groupe contrôle (z_{control}), l'autre dans le groupe détective ($z_{\text{detective}}$). La corrélation entre ces deux vecteurs de scores permet d'estimer dans quelle mesure l'évolution lexicale des détectives suit celle de la prose narrative générale.

4.4.2 Résultats : corrélations par période

Le tableau 6.4 présente les corrélations de Pearson entre les *z-scores* des contrôles et des détectives pour chaque période et type d'attribut.

Période	Verbes agentifs	Modifieurs	Possessifs
proto (avant 1931)	0.679	0.627	0.650
classique (1931–1965)	0.337	0.307	0.367
contemporain (après 1965)	0.700	0.615	0.675

TABLE 6.4 : Corrélations entre les *z-scores* de période dans le groupe contrôle et dans le groupe détective, par type d'attribut.

Pour les périodes *proto* et *contemporain*, les corrélations sont relativement élevées ($r \approx 0.6$–0.7), indiquant que l'évolution lexicale des détectives accompagne en grande partie les transformations générales de la prose narrative française. En revanche, la période *classique* présente des corrélations nettement plus faibles ($r \approx 0.3$), suggérant que les détectives de l'entre-deux-guerres et de l'après-guerre développent un profil lexical plus autonome par rapport au reste de la fiction.

4.4.3 Période *proto*

L'examen des verbes agentifs de la période *proto* révèle que les marqueurs les plus distinctifs (« répondre », « s'écrier », « reprendre », « dire », « répliquer », « murmurer », « interrompre ») affichent des « z-scores » très élevés dans le groupe contrôle (30–80) et modérément positifs chez les détectives (8–24). Ce sont des verbes dialogiques et affectifs, caractéristiques d'une narration conversationnelle où les personnages parlent, répondent, s'exclament et murmurent.

Les détectives de la période 1881–1931 participent donc au même répertoire narratif que l'ensemble de la fiction de leur époque. La différence est de degré, puisque les *z-scores* sont systématiquement plus élevés dans le groupe contrôle, ce qui suggère que la fiction policière hérite du style dominant de l'époque sans introduire un profil d'action radicalement distinct. Les attributs possessifs confirment cette inscription dans le régime sentimental du XIXe siècle : « ami », « monsieur », « cœur », « âme », « maître » sont fortement associés à la période *proto* dans les deux groupes.

4.4.4 Période *classique*

La période *classique* (1931–1965) se distingue par des corrélations nettement plus faibles entre contrôles et détectives. Plusieurs marqueurs apparaissent fortement associés à cette période

dans le groupe contrôle mais faiblement chez les détectives, et inversement.

Ainsi, « questionner » et « supposer » sont des marqueurs forts chez les détectives ($z_{\text{det}} > 14$) mais plus modestes dans le groupe contrôle, signalant l'émergence d'un vocabulaire proprement policier. À l'inverse, des verbes comme « piger », « foncer » ou « sursauter », caractéristiques de la modernité narrative de l'entre-deux-guerres dans le groupe contrôle, ne marquent pas particulièrement les détectives de cette période.

4.4.5 Période *contemporaine*

La période *contemporaine* (après 1965) présente à nouveau des corrélations élevées entre contrôles et détectives. Les verbes les plus distinctifs (« foutre », « se souvenir », « imaginer », « croiser », « attraper », « repérer », « enfiler ») marquent fortement les deux groupes, témoignant d'une évolution partagée vers un registre plus corporel, familier et orienté vers l'action physique. Les possessions des détectives confirment cela en montrant qu'ils ont un « corps », un « ventre », un « sac », un « dos ».

Cependant, même au sein de cette convergence globale, certains verbes présentent un effet de période fort chez les détectives mais faible dans le groupe contrôle. C'est le cas de « lever » ($z_{\text{det}} = 12.3$, $z_{\text{ctl}} = 0.8$) et « fermer » ($z_{\text{det}} = 10.3$, $z_{\text{ctl}} = 2.4$). Ces micro-actions (lever les yeux, fermer un dossier, ouvrir une porte) relèvent d'une gestuelle procédurale propre aux scènes d'enquête, qui n'a pas d'équivalent aussi marqué dans la prose narrative générale.

4.4.6 Synthèse

L'étude de contrôle permet de nuancer l'interprétation des clusters temporels. Une partie de l'évolution lexicale des détectives reflète effectivement les grandes transformations du français littéraire : passage d'un registre dialogique et sentimental à un registre corporel et familier. Cette dimension partagée est particulièrement visible dans les périodes *proto* et *contemporaine*, où les corrélations entre contrôles et détectives atteignent 0.6–0.7.

Cependant, dans la période *classique*, le profil diachronique des détectives n'est pas réductible à cette dérive générale. On peut expliquer cette résistance au drift général par le fait que la période *classique* corresponde à l'âge d'or du roman policier français, inauguré symboliquement par la création de la collection *Le Masque* en 1927 et incarné par l'émergence du commissaire Maigret dans les années 1930. Après cette phase de consolidation dans la période *proto*, le genre a eu le temps de développer ses propres conventions lexicales et ne coïncident plus avec la prose narrative générale.

5 Discussion

5.1 Interprétation des résultats

L'analyse diachronique conduite sur près de 150 ans de fiction policière francophone met en évidence deux résultats principaux. Le premier est la stabilité remarquable de la signature textuelle du détective : un lexique central de l'investigation persiste à travers les trois clusters

identifiés par le modèle. Le second est la structuration de l'espace des personnages en trois pôles chronologiquement ordonnés, qui émergent de manière non supervisée et correspondent à de grandes phases historiques du genre. Cette tripartition ne relève pas d'un simple artefact chronologique : les cas de décalage temporel analysés dans la section précédente montrent que le modèle capte des proximités de régime narratif qui ne se réduisent pas à la date de publication. L'étude de contrôle permet de préciser la nature de cette évolution. Les périodes initiale et tardive présentent des corrélations élevées (r ≈0.6-0.7) entre détectives et personnages non-détectives, indiquant que l'évolution lexicale de la figure du détective accompagne en partie les transformations générales du français littéraire. La période médiane (1931–1965) présente en revanche des corrélations nettement plus faibles (r ≈0.3), ce qui suggère une autonomisation lexicale : le détective développe alors un vocabulaire propre qui diverge des tendances de la prose narrative. Cette divergence doit toutefois être nuancée par la composition du corpus : la période médiane est fortement dominée par Simenon, dont l'idiolecte pourrait à lui seul expliquer une partie de l'écart. La faible corrélation reflète donc autant la singularité stylistique d'un auteur que l'autonomisation du genre.

5.2 Limites

Notre étude présente deux limites principales. La première tient à la chaîne de traitement BookNLP-fr, utilisée pour l'identification des personnages et la résolution de coréférence. Le système peut fusionner à tort des personnages distincts ou scinder un même personnage en plusieurs chaînes, ce qui ajoute du bruit aux représentations. L'échelle du corpus empêche une validation manuelle exhaustive. La seconde limite concerne la méthode d'extraction des attributs, fondée sur des unigrammes lemmatisés : cette approche ne tient pas compte de la négation (« intelligent » et « pas intelligent » sont traités comme équivalents), de la gradation, ni de la polysémie. Des traitements linguistiques plus avancés (prise en compte de la négation, *embeddings* contextuels, désambiguïsation) amélioreraient la précision de notre compte rendu discursif.

Chapitre 7

La naissance du roman policier (1866-1945)

Objectifs

Ce chapitre s'intéresse à l'origine du roman policier, un genre littéraire majeur du XXe siècle. Après une présentation historique du genre, on discutera de ses caractéristiques architextuelles et de son intérêt pour une analyse computationnelle des genres littéraires. L'objectif est de comprendre comment le roman policier s'est constitué progressivement à travers une sédimentation de traits caractéristiques, avant même que le terme lui-même ne soit stabilisé dans le discours médiatique. Nous testerons l'hypothèse selon laquelle les éléments formels du genre (enquête, détective, énigme) se sont cristallisés graduellement entre 1866 et 1930, avant la consécration du terme « roman policier » dans les années 1930. Nous verrons également comment cette évolution s'inscrit dans une dynamique plus large de spécialisation et de différenciation des genres populaires au sein du système littéraire français.

Sommaire

1 Origine et sédimentation des genres . . . **162**
2 Origine et sédimentation du roman policier . . . **164**
2.1 Problèmes de la naissance du roman policier . . . 164
2.2 Cadre théorique : formation et reconnaissance . . . 169
2.3 Hypothèses de travail . . . 170
3 Indices qualitatifs de la transformation générique . . . **170**
3.1 Du roman-feuilleton au roman policier : transformation du support . . . 170
3.2 Du roman-feuilleton au roman policier : trois évolutions formelles . . . 171
4 Approches computationnelles de la naissance du roman policier . . . **173**
4.1 Corpus . . . 173
4.2 Opérationnalisation de la persistance du thème criminel . . . 174
4.3 Opérationnalisation de la centralité croissante du détective . . . 174
4.4 Opérationnalisation de la prototypicalité de l'intrigue . . . 177
5 Résultats . . . **179**
5.1 Persistance du thème criminel . . . 179
5.2 Mesure quantitative de la persistance thématique . . . 180
5.3 Affirmation progressive du détective comme pivot narratif . . . 182
5.4 Prototypicalité de l'intrigue . . . 184
6 Discussion . . . **186**

6.1 Convergence des trois indicateurs 186
6.2 Vérification des hypothèses 186
6.3 Limites 187

> Ce que Poe et Conan Doyle ont créé, c'est la « forme » du roman policier. Mais ils n'ont pas clairement compris quel devait en être le fond, c'est-à-dire la matière. Ils n'ont pas vu, notamment, que cette matière devait être *rebelle* et *résister* à l'investigation. […] Poe n'a pas songé à opposer à Dupin un meurtrier habile. […] Mais alors, comment en viendra-t-on au roman policier ? […] Un crime intelligent, un criminel adroit, voilà l'obstacle extérieur ; une pensée connaissant mieux ses limites, humble devant une réalité révélant peu à peu son foisonnement, voilà l'obstacle intérieur. Le roman policier apparaît avec l'incertitude.
>
> *Thomas* Narcejac. Une machine à lire, le roman policier. *Paris : Denoël/Gonthier, 1975, p. 43-45*

1 Origine et sédimentation des genres

Les chapitres théoriques et pratiques précédents ont montré que l'existence des genres était historiquement située. Un sous-genre du roman existe pendant une certaine période, parce qu'un certain nombre d'acteurs (lecteurs, éditeurs, journalistes, chercheurs, critiques) le décrivent comme un ensemble cohérent. Les approches computationnelles ont apporté des nuances, montrant le caractère persistant de certains traits caractéristiques du roman policier, mais ces résultats restent compatibles avec une existence historique. Si l'on admet cette dimension historique, alors on peut s'interroger sur l'origine du genre en question, qui vient forcément de l'état du système littéraire préexistant.

Schématiquement, la critique a exploré cette question en insistant tantôt sur le rôle de l'individu créateur, tantôt sur le processus cumulatif dans l'émergence d'un genre. L'hypothèse « individualiste » repose sur l'idée qu'un acte créatif singulier peut transgresser les normes littéraires établies et inaugurer, à lui seul, une nouvelle voie. Todorov formule cette intuition de manière particulièrement nette lorsqu'il prend l'exemple de Stendhal : à propos de *La Chartreuse de Parme*, il écrit que « c'est le genre "roman stendhalien" qui est créé par cette œuvre précisément », avant d'ajouter que « tout grand livre établit l'existence de deux genres : la réalité de deux normes : celle du genre qu'il transgresse, qui dominait la littérature précédente ; et celle du genre qu'il crée » [1]. Cette conception est reprise par Jauss, pour qui « un chef-d'œuvre se définit par une modification aussi inattendue qu'enrichissante de l'horizon d'un genre » [2], et par Scholes en 1974 : « L'artiste de génie, pour sa part, enrichit la tradition d'une contribution nouvelle parce qu'il prend conscience de possibilités qu'elle contenait mais qui étaient restées jusque-là inaperçues » [3]. Dans cette perspective, *La Chartreuse de Parme* illustre bien une dynamique où la singularité d'une œuvre reconfigure un horizon d'attente et impose rétrospectivement une norme nouvelle.

1. Todorov, « Typologie du roman policier », p. 10.
2. Jauss, « Littérature médiévale et théorie des genres », p. 58.
3. Robert Scholes. « Les modes de la fiction ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986 [1974], p. 78.

Cependant, la notion même de *naissance* d'un genre pose un problème conceptuel. Appliquée aux formes littéraires, la métaphore biologique suggère un instant inaugural, un texte-source, alors que les traits qui définiront plus tard un genre circulent d'abord de manière diffuse dans le système littéraire. Parler de naissance n'est donc tenable qu'au prix d'un déplacement, où il ne s'agit plus d'identifier un premier texte, mais de repérer le moment où une configuration de caractéristiques devient suffisamment stable, reconnaissable et réitérable pour constituer une forme autonome. La naissance se comprend alors comme un phénomène de sédimentation : un faisceau de conventions franchit des seuils d'intelligibilité pour les lecteurs et les médiateurs, devient imitable, puis se trouve éventuellement consacré par des dispositifs institutionnels (collections, étiquettes, discours critiques). Dans cette perspective, la question centrale n'est donc pas seulement qui crée, mais quand et comment des traits dispersés deviennent-ils une norme partageable ?

Par ailleurs, cette conception d'une origine des genres qui serait individuelle ne fait pas consensus. La critique considère aujourd'hui l'approche cumulative. Elle est résumée par John Rieder :

> la notion de genre est fondée sur la répétition et est strictement opposée à la notion d'originalité. Dans la théorie de Jauss, il ne peut y avoir un premier exemplaire d'un genre, parce que le caractère générique d'un texte est précisément ce qui est répété et conventionnel. Un texte peut violer les attentes génériques établies, mais on ne peut dire qu'il a établi de nouvelles attentes que lorsque de nouveaux textes, imitant ses stratégies, les solidifient en traits caractéristiques d'un genre [4].

Les caractéristiques spécifiques d'une forme littéraire nouvelle, une fois répétées et consolidées au fil du temps, forment un agrégat cohérent de textes suffisamment similaires entre eux et suffisamment dissemblables des autres genres pour former un genre à part entière. Pour ce qui est de l'origine textuelle de cette sédimentation, Todorov répond simplement : « Un nouveau genre est toujours la transformation d'un ou de plusieurs genres anciens » [5]. Il n'y a donc pas de « point de départ » aux genres, comme le souligne Kincaid [6] à propos de la SF, mais plutôt une hybridation et une accumulation d'un ensemble de traits spécifiques. Ainsi, Rieder poursuit en ce sens :

> Étudier les débuts du genre ne consiste pas du tout en une recherche de points d'origine mais plutôt en l'observation d'une accrétion de répétition, échos, imitations, identifications et distinctions qui témoigne d'une conscience émergente d'un réseau conventionnel de ressemblances [7].

Vareille, théoricien du roman policier, s'inscrit également dans la même logique :

> Le roman policier naît sans à-coup ni solution de continuité de genres ou de mentalités qui lui préexistent. Il n'y a pas rupture, mais glissement et métamorphoses [8].

4. Rieder, « De l'avantage (ou non) de définir la science-fiction : théorie des genres, science-fiction et Histoire », p. 6.
5. Todorov, « L'origine des genres », p. 30.
6. Paul Kincaid. « On the Origins of Genre ». *Extrapolation* 2003, p. 409-419. doi : 10.3828/extr.2003.44.4.04, p. 409.
7. Rieder, op. cit., p. 7.
8. Jean-Claude Vareille. *L'Homme masqué, le justicier et le détective*. Presses universitaires de Lyon, 1989,

Cette hypothèse cumulative a été reformulée dans le cadre de l'évolution culturelle par Oleg Sobchuk, qui reconstruit l'histoire du roman policier, de Godwin à Christie, comme une longue chaîne de procédés empruntés et recombinés, au point de faire du genre « une invention sans inventeur » [9].

Ainsi, c'est la sédimentation du roman policier que nous souhaitons détecter automatiquement, une démarche qui ne peut s'opérer qu'à travers une approche dynamique et graduelle de l'évolution de la littérature. Les études littéraires computationnelles offrent ici un point d'intérêt majeur en permettant une analyse systématique et progressive des textes, ce qui facilite l'exploration de questionnements autour de l'émergence, la solidification et la stabilisation progressive de traits caractéristiques d'un genre.

Cette perspective cumulative trouve une application particulièrement fertile dans l'étude du roman policier français. Contrairement à des genres aux contours flous, le roman policier présente des traits formels saillants qui en font un cas d'école pour observer la sédimentation progressive. Son histoire présente un décalage temporel important entre l'émergence de textes considérés rétrospectivement comme « policiers » et la consécration médiatique du terme lui-même. Cette disjonction entre formation textuelle et reconnaissance institutionnelle nous permet de tester empiriquement l'hypothèse cumulative : le genre se forme-t-il progressivement dans les textes avant d'être nommé, ou bien est-ce la désignation elle-même qui fixe et homogénéise des formes jusque-là dispersées ?

Notre approche computationnelle s'accorde particulièrement avec cette perspective cumulative, parce qu'elle permet précisément de systématiser l'observation de cette « accrétion » en la traitant comme un signal mesurable à grande échelle. Reste à savoir quelles caractéristiques du roman policier sont importantes dans la construction du genre, et comment les opérationnaliser de manière pertinente.

2 Origine et sédimentation du roman policier

2.1 Problèmes de la naissance du roman policier

L'histoire du roman policier est jalonnée de déclarations contradictoires sur ses origines. « Balzac, pionnier en tout, a écrit *Une ténébreuse affaire*, le premier roman policier » affirme Fortassier [10] ; « Poe est l'inventeur du roman policier » écrit Borges [11] [12] ; Gaboriau a « donné des modèles de roman policier » déclare Messac [13].

Cette multiplication de paternités rivales témoigne moins d'une incertitude factuelle que d'un

p. 43-44.

9. Oleg Sobchuk. « Charting Artistic Evolution : An Essay in Theory ». PhD thesis. Tartu : University of Tartu, 2018, p. 57.

10. Rose Fortassier. *Le roman français du XIXe siècle*. Paris : Pr. Univ. de France, 1995 [1982].

11. Jorge Luis Borges. *Borges, a reader : a selection from the writings of Jorge Luis Borges*. New York : Dutton, 1981 [1936].

12. Il est le plus souvent question des nouvelles *Double assassinat dans la rue Morgue*, *Le mystère de Marie Roget* et *La lettre volée* dans Edgar Allan Poe. *Histoires extraordinaires*. Trad. par Charles Baudelaire. Paris : Michel Lévy Frères, 1856, traduites par Baudelaire en 1856.

13. Messac, *Le "Detective Novel" et l'influence de la pensée scientifique*, p. 521.

problème théorique : comment apparaît un genre littéraire et comment se structure-t-il au fil du temps ?

Bonniot [14] remonte même au livre II de l'*Histoire* d'Hérodote (Ve siècle av. J.-C.) et à l'histoire des trésors du pharaon Rhampsinite. Mais comme l'a montré Gonon [15], cette vulgate participe d'une « mythologie » du policier qui enchaîne volontiers Œdipe, Zadig, Poe, puis Doyle, Leroux et Christie, et qui identifie le cœur du genre au *roman à énigme* (le *whodunit*) [16]. Dans ce modèle, la dynamique est d'abord celle de la curiosité (qui l'a fait ?), davantage que du suspense [17] [18]. Les protagonistes récurrents sont réputés « immunisés » pour pouvoir assurer l'enquête suivante [19], et le détective est souvent réduit à la seule puissance déductive et ses « petites cellules grises », quand le lecteur, « bricoleur », est invité à résoudre un *puzzle* en mode « do it yourself » [20]. Les figures canoniques elles-mêmes se mythifient : Dupin cristallise « la raison contre les faits », Holmes le « policier de laboratoire » [21], qui résout l'énigme sans rentrer dans l'action violente.

C'est précisément sous cet angle que la place de Poe devient intelligible : sa poétique compositionnelle met en forme l'économie rationnelle du *whodunit*. Dans *Genèse d'un poème*, Poe expose une méthode d'écriture où le dénouement commande le plan du récit :

> S'il est une chose évidente, c'est qu'un plan quelconque, digne du nom de plan, doit avoir été soigneusement élaboré en vue du dénouement, avant que la plume n'attaque le papier. Ce n'est qu'en ayant sans cesse la pensée du dénouement devant les yeux que nous pouvons donner à un plan son indispensable physionomie de logique et de causalité […] en faisant que tous les incidents tendent vers le développement de l'intention [22].

Poe ne discute pas de l'esthétique du roman policier, il développe ici sa manière d'écrire *Le Corbeau*, un poème fantastique, et l'on voit poindre l'idée de construction rétrospective de l'intrigue (concevoir d'abord le dénouement, puis élaborer le plan du récit par rapport à lui) ainsi que la dimension rationnelle et causale qui s'affirmera dans *Double Assassinat dans la rue Morgue* (1841) et *La Lettre volée* (1844). Autrement dit, la « mythologie » du policier décrite par Gonon [23] trouve chez Poe une matrice poétique : un dispositif où la trame de l'enquête et la lecture se confondent en jeu déductif, orienté par la fin et structuré par la rationnalité.

Ainsi, Poe apparaît comme un précurseur rétrospectif : s'il n'avait pas conscience d'écrire du roman policier à son époque, ce sont précisément ses choix narratifs qui, en exerçant une influence ultérieure, ont permis aux auteurs tels que Conan Doyle ou Gaston Leroux de le désigner a posteriori comme un fondateur du genre. C'est cette reconnaissance tardive, guidée par une

14. Bonniot, *Émile Gaboriau ou La naissance du roman policier*, p. 158.
15. Laetitia Gonon. « Mythes et démystification dans le roman policier de Fred Vargas ». *Recherches & Travaux* 2010, p. 119-135. DOI : 10.4000/recherchestravaux.434.
16. Sur cette typologie, voir Todorov, « Typologie du roman policier », p. 11.
17. Ibid., p. 14.
18. Raphaël Baroni. *La tension narrative : suspense, curiosité et surprise*. Paris : Éditions du Seuil, 2007, p. 114.
19. Todorov, op. cit., p. 14.
20. Jacques Dubois. *Le roman policier ou La modernité*. Paris : Nathan, 1992, p. 27.
21. Francis Lacassin. *Mythologie du roman policier*. Paris : Christian Bourgois, 1993 [1974], p. 38.
22. Edgar Allan Poe. *Eureka : la genèse d'un poëme ; Le corbeau ; Méthode de composition*. Trad. par Charles Baudelaire. Avec des annot. de Jacques Crépet. Paris : L. Conard, 1936 [1848], p. 160–161.
23. Gonon, op. cit.

réinterprétation des œuvres passées, qui nous permet aujourd'hui de le considérer comme l'un des inventeurs du roman policier. Le genre ne naît donc pas d'un acte de création ex nihilo, mais se constitue par sédimentation progressive et réappropriation rétrospective : c'est parce que le roman policier existe en 1900 qu'il peut englober des textes de 1850 qui, à leur époque, n'appartenaient pas encore à cette catégorie générique.

Cependant, cette vision est à nuancer. Comme le précise Lee :

> Si les œuvres de fiction détective sont animées par le désir de découvrir un coupable, le roman policier, en tant que genre, n'a pas de cerveau unique. Puisant ses racines dans la littérature classique, le roman gothique et les récits criminels populaires, il ne peut, même dans ses formes les plus anciennes, être réduit à une seule lignée ni à un seul ensemble de conventions. Cela dit, si quelqu'un peut être tenu pour l'inventeur du roman policier, c'est Poe[24].

Lee souligne que la naissance du roman policier s'inscrit dans un processus cumulatif d'influences multiples et d'évolutions littéraires successives, qui, ensemble, ont façonné le genre tel que nous le connaissons aujourd'hui. Il note toutefois que Poe reste néanmoins une matrice formelle importante, ce qui renforce l'intérêt de ce chapitre pour démêler tout cela.

Pour mieux comprendre les enjeux autour de l'apparition de la dénomination du genre policier dans le discours médiatique, nous représentons en figure 7.1 l'évolution des occurrences de plusieurs étiquettes génériques de la littérature populaire dans la presse française (1830–1950), à partir de Gallicagram[25]. Le graphique donne des fréquences relatives dans un vaste corpus de presse : il mesure donc moins la production littéraire elle-même que la manière dont celle-ci est nommée, catégorisée et rendue visible dans l'espace journalistique et éditorial[26].

Au XIXe siècle, la dénomination *roman-feuilleton* domine nettement l'espace médiatique. À partir du début du XXe siècle, on observe une montée des termes *roman d'aventures* puis *roman policier*, qui deviennent des catégories de plus en plus saillantes. Cette transition peut être interprétée comme une reconfiguration du langage médiatique. Le discours se déplace progressivement du format de publication du feuilleton vers celui de la collection et une spécialisation des étiquettes de genres, correspondant à une granularité générique plus fine. Il faut toutefois rappeler que ces catégories se recouvrent partiellement dans les pratiques, puisque beaucoup de romans d'aventures ou d'enquête paraissent eux-mêmes sous forme de feuilletons. Nous reviendrons sur les trajectoires distinctes de ces deux termes et leurs conséquences sur la production générique dans le chapitre 9.

Le cas de *roman judiciaire* est instructif. Si le terme demeure faible en fréquence globale (et disparaît presque après 1910), il présente au XIXe siècle une trajectoire propre, avec une visibilité structurée dans les décennies 1860–1890 : il fonctionne comme un label concurrent, avant d'être progressivement supplanté par d'autres désignations. Ce terme renvoie spécifiquement à la

24. Maurice S. Lee. « Edgar Allan Poe (1809–1849) ». *A Companion to Crime Fiction*. Sous la dir. de Charles J. Rzepka et Lee Horsley. Wiley, 2010, p. 369-380. DOI : 10.1002/9781444317916.ch29, p. 369.

25. Benoît de Courson et Benjamin Azoulay. « Gallicagram : un outil de lexicométrie pour la recherche » 2021. DOI : 10.31235/osf.io/84bf3.

26. Comme tout indicateur fondé sur des archives numérisées, ces séries sont sensibles aux variations de couverture du corpus ainsi qu'aux aléas de l'OCR ; l'interprétation doit porter prioritairement sur les tendances longues plutôt que sur des pics isolés.

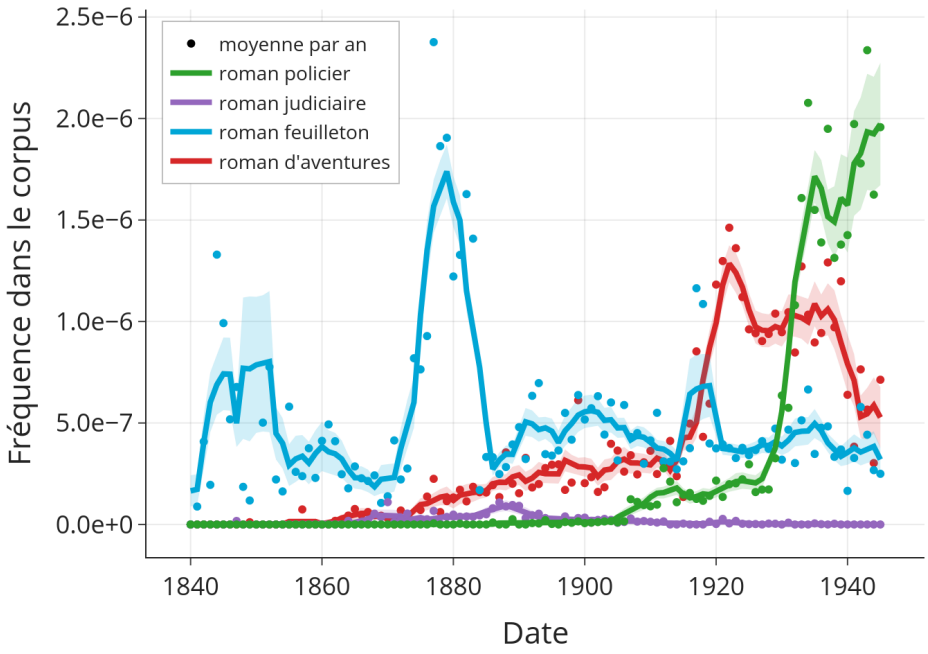


FIGURE 7.1 : Évolution des occurrences des termes « roman-feuilleton », « roman judiciaire », « roman d'aventures » et « roman policier » dans la presse française (Gallicagram), 1830–1950

tradition inaugurée par Émile Gaboriau avec *L'Affaire Lerouge* (1866), dont Roger Bonniot [27] a montré qu'il constituait le véritable acte de naissance du roman policier français. La disparition du terme « judiciaire » après 1910 marque l'effacement de cette filiation française au profit du modèle anglo-saxon, de Conan Doyle aux auteurs du *Masque*. À l'inverse, le terme *roman criminel* est quasiment absent de la presse sur la période considérée.

Ces observations sont confirmées par une analyse fournie par Gallicagram de co-variation entre nos séries temporelles. La tableau 7.1 donne la matrice de corrélation (1860–1939) entre les fréquences d'apparition des quatre expressions. Deux résultats dominent. D'abord, *roman policier* est corrélé positivement à *roman d'aventures* ($r = 0.537$, $p < .001$), ce qui suggère une montée conjointe de ces deux labels dans l'entre-deux-guerres. Loin d'émerger en opposition frontale au roman d'aventures, le policier monte dans le discours de presse en même temps que lui, porté par le même mouvement de spécialisation éditoriale des genres populaires. Ensuite, les corrélations négatives entre *roman judiciaire* et *roman policier* ($r = -0.162$, $p < .001$), ainsi qu'entre *roman judiciaire* et *roman d'aventures* ($r = -0.142$, $p < .001$), indiquent un phénomène de substitution terminologique : à mesure que de nouvelles étiquettes se stabilisent, l'ancienne catégorie du *judiciaire* décroît dans le discours de presse. Enfin, les corrélations modestement négatives de *roman-feuilleton* avec *roman policier* ($r = -0.065$, $p < .05$) et avec *roman d'aventures* ($r = -0.093$, $p < .01$) vont dans le même sens : elles marquent le déclin d'un label de format généraliste au profit de catégories génériques plus différenciées. La corrélation quasi nulle entre *roman judiciaire* et *roman-feuilleton* ($r = 0.040$) suggère enfin que ces deux

27. BONNIOT, *Émile Gaboriau ou La naissance du roman policier*.

désignations ne relèvent pas du même principe de catégorisation (format médiatique d'un côté, cadrage thématique de l'autre).

On notera également que le pic de *roman-feuilleton* observable dans les années 1875–1885 coïncide avec l'intensification des débats critiques sur la « littérature industrielle ». Dès 1839, Sainte-Beuve avait forgé cette notion polémique dans la *Revue des Deux Mondes*, dénonçant la marchandisation de la production littéraire et les « descriptions oiseuses » [28] du feuilleton. Comme l'a montré Lise Dumasy, la décennie qui suit voit se cristalliser une véritable « querelle du roman-feuilleton » [29], dont les prolongements se font sentir jusqu'à la fin du siècle. La fréquence élevée du terme dans la presse reflète donc autant sa diffusion comme pratique que sa présence comme objet de controverse.

	roman-feuilleton	*roman policier*	*roman d'aventures*
roman judiciaire	0.040	-0.162^{***}	-0.142^{***}
roman-feuilleton		-0.065^{*}	-0.093^{**}
roman policier			0.537^{***}

TABLE 7.1 : Matrice de corrélation (Pearson) entre les fréquences d'apparition des termes « roman-feuilleton », « roman judiciaire », « roman d'aventures » et « roman policier » dans la presse française (Gallicagram), 1860–1939. Les astérisques indiquent la significativité statistique ($^{***}p < .001$, $^{**}p < .01$, $^{*}p < .05$). Plus la valeur de (p) est faible, moins il est probable que l'effet observé soit dû au hasard ; trois astérisques signalent donc un résultat plus robuste qu'un seul.

En théorie, le roman policier devrait s'affirmer bien plus tôt, dès la traduction par Baudelaire des *Histoires extraordinaires* de Poe en 1856. Or, la figure montre que *roman policier* ne connaît un essor massif qu'à partir de la fin des années 1920. Comment interpréter cet intervalle entre des œuvres souvent considérées comme fondatrices et la stabilisation tardive de l'étiquette ? Plutôt que d'y voir une contradiction, on peut y lire un décalage entre l'existence de motifs formels et la consolidation d'une catégorie explicite dans le discours médiatique. Autrement dit, l'enquête comme régime narratif peut précéder de plusieurs décennies l'institution d'un nom générique stabilisé. De plus, les *Histoires extraordinaires* ne sont pas présentées ni reçues d'emblée comme du « policier ». Le recueil rassemble des textes hétérogènes, majoritairement fantastiques, dans lesquels les nouvelles dédiées à Dupin sont incluses au sein d'un horizon d'attente différent.

Cette disjonction chronologique entre reconnaissance contextuelle et constitution formelle du genre soulève plusieurs questions critiques. D'une part, dans quelle mesure la consécration tardive du terme « roman policier » et sa stabilisation dans le discours médiatique et éditorial dans les années 1930 exerce-t-elle un effet rétroactif sur les pratiques d'écriture ? Assiste-t-on alors à une normalisation des potentialités fictionnelles une fois que le genre est reconnu et que la logique commerciale du roman populaire s'impose ? D'autre part, l'apparition formelle du genre, c'est-à-dire la cristallisation d'un ensemble de traits narratifs, actantiels et discursifs reconnaissables, précède-t-elle ou suit-elle cette reconnaissance contextuelle ? Autrement dit, le

28. SAINTE-BEUVE, *De la littérature industrielle*.
29. Lise DUMASY. *La querelle du roman-feuilleton : littérature, presse et politique, un débat précurseur (1836-1848)*. Grenoble : ELLUG-Université Stendhal, 1999.

genre est-il déjà structurellement ancré dans les pratiques textuelles avant que les agents du champ littéraire ne le nomment et ne le consacrent, ou bien est-ce la désignation elle-même qui contribue à fixer et à homogénéiser des formes jusque-là dispersées ?

Enfin, que faire des textes considérés rétrospectivement comme des romans policiers, à commencer par *L'Affaire Lerouge* de Gaboriau (1866), souvent désigné comme le « premier » roman policier français ? Relèvent-ils d'une appartenance générique authentique, ou sont-ils des précurseurs rétrospectifs englobés a posteriori dans une catégorie qui n'existait pas encore à leur époque ? L'apparition formelle du genre est-elle aussi soudaine que son explosion contextuelle, ou bien résulte-t-elle d'un lent processus de sédimentation où les structures narratives se stabilisent progressivement avant d'être reconnues et étiquetées ? Ces questions nous invitent à distinguer deux temporalités du genre : celle de sa *formation* textuelle, qui peut être lente et diffuse, et celle de sa *légitimation* sociale, qui peut être plus brutale et concentrée. Ce chapitre se propose de répondre à toutes ces questions.

2.2 Cadre théorique : formation et reconnaissance

Dubois [30] a montré que l'institutionnalisation d'un genre passe par plusieurs étapes : l'émergence de pratiques textuelles communes, la reconnaissance par les producteurs, la création de labels éditoriaux, et enfin la consécration critique. Pour Dubois, le produit littéraire « se constitue dans l'interaction de plusieurs instances », chaque instance étant « un rouage institutionnel remplissant une fonction spécifique dans l'élaboration, la définition ou la légitimation d'une œuvre » [31]. Le cas du roman policier permet d'observer ce processus sur près d'un siècle, avec une particularité notable : l'existence d'une longue période où le genre semble se constituer formellement sans pour autant bénéficier d'une reconnaissance institutionnelle stabilisée.

L'explosion contextuelle du terme dans les années 1930 correspond d'ailleurs à la création de collections spécialisées. La collection *Le Masque*, fondée en 1927, est rapidement suivie par des collections concurrentes, notamment *L'Empreinte* (1932) à La Nouvelle Revue Critique et *Police et Mystère* (1932) chez Ferenczi, qui confirment la structuration éditoriale du genre. La *Série noire*, créée chez Gallimard en 1945, prolonge ensuite ce mouvement dans un autre contexte. Ces collections produisent le genre en lui donnant une identité visuelle, un paratexte normatif et une communauté de lecteurs fidèles. Elles instituent ainsi des frontières génériques plus nettes et contribuent à homogénéiser les pratiques d'écriture.

Cette temporalité française contraste d'ailleurs avec d'autres espaces nationaux. En Angleterre, le terme *detective novel* se stabilise dès les années 1890 avec Conan Doyle, tandis qu'aux États-Unis, le *hardboiled* (sous-genre du roman policier caractérisé par un détective cynique, une violence explicite et un ancrage dans les milieux urbains) émerge dans les *pulp magazines*, ces revues bon marché imprimées sur papier de mauvaise qualité qui constituent alors le principal vecteur de la fiction populaire américaine, dès les années 1920.

30. Jacques Dubois. *L'institution de la littérature*. Loverval : Éditions Labor, 2005 [1978].
31. Ibid., p. 122.

2.3 Hypothèses de travail

Notre démarche repose sur deux hypothèses complémentaires, et la première postule une sédimentation progressive. Des traits formels caractéristiques du roman policier, que l'on définira par la suite, se cristalliseraient graduellement entre 1866 et 1930, *avant* la reconnaissance médiatique massive du terme. Si cette hypothèse est correcte, nous devrions observer une évolution continue de ces traits plutôt qu'une rupture brusque autour de 1930. La seconde porte sur le mécanisme de cette sédimentation : le roman policier ne naîtrait pas *ex nihilo*, mais résulterait d'une spécialisation progressive du roman judiciaire populaire et du feuilleton à énigme, qui concentrent et systématisent des motifs déjà présents de manière diffuse dans la production antérieure. Les textes considérés rétrospectivement comme précurseurs, par exemple ceux de Gaboriau ou de Leroux, devraient donc présenter certains traits génériques, mais de manière moins systématique et moins stable que les romans postérieurs à 1930.

3 Indices qualitatifs de la transformation générique

Avant de procéder à l'analyse computationnelle à grande échelle, il convient d'examiner qualitativement les transformations narratives qui distinguent progressivement le roman policier du roman-feuilleton judiciaire dont il est issu. Ces observations, issues de la critique littéraire, guideront ensuite l'opérationnalisation de nos indicateurs computationnels et permettront d'interpréter les résultats quantitatifs dans leur contexte littéraire et historique.

3.1 Du roman-feuilleton au roman policier : transformation du support

Le roman policier français émerge au cœur du roman feuilleton, support privilégié pour la publication romanesque dans la seconde moitié du XIXe siècle. Le roman feuilleton constitue en effet la littérature populaire par excellence, touchant un vaste lectorat suivant assidûment les épisodes publiés quotidiennement ou hebdomadairement dans la presse.

Dans un journal quotidien, il s'agit de trouver chaque jour un nouveau motif d'intérêt, ce qui conduit à un récit fragmenté et à des rythmes saccadés, façonnés par des contraintes éditoriales et économiques strictes [32]. Comme le souligne Messac, « Au lieu d'une esthétique convergente, à la Poe, le feuilleton aura donc une esthétique divergente ; au lieu de rechercher l'unité d'intérêt, on y recherchera la multiplicité d'intérêt » [33]. La publication en feuilleton impose inévitablement des contraintes formelles de découpage, nécessaires pour répondre aux exigences économiques des journaux. Chaque épisode doit respecter une longueur déterminée afin de soutenir l'économie du support, ce qui se traduit par une intrigue qui se déploie à un rythme saccadé. Le support du journal a donc un impact important sur le récit [34].

32. Lise Queffélec. *Le roman-feuilleton français au XIXe siècle*. Paris : Presses Univ. de France, 1989.
33. Messac, op. cit., p. 388.
34. Sur ce sujet, voir Marie-Ève Thérenty. « Pour une poétique historique du support ». *Romantisme* 2009, p. 109-115. DOI : 10.3917/rom.143.0109. La chercheuse insiste sur l'impact des formes matérielles (journaux, feuilletons, livres) qui conditionnent la production littéraire. Roger Chartier rappelle également que « il n'est pas de texte hors le support qui le donne à lire, pas de compréhension d'un écrit qui ne dépende des formes dans lesquelles il atteint son lecteur », dans Roger Chartier. « Textes, imprimés, lectures ». *Pour une sociologie de la*

La tension entre formes courtes et formes longues, essentielle dans l'évolution du genre policier, est déjà manifeste chez Poe, dont la préférence marquée pour la nouvelle se fonde sur sa capacité à concentrer les effets narratifs. Dans *La genèse d'un poème*, Poe rejette implicitement le long poème épique précisément en raison de sa dispersion esthétique Poe soutient que « Ce que nous appelons un long poème n'est, en réalité, qu'une succession de poèmes courts » [35] et qu'il se trouve privé, du fait même de sa longueur, de cette « totalité ou unité d'effet » qui définit l'expérience poétique. Le genre policier ne s'établit véritablement comme genre romanesque qu'au moment où il parvient à s'acclimater à la forme longue du roman. Comme l'observe Cawelti :

> Avec l'émergence du format long, le problème devient celui de l'équilibre entre le foyer central de l'enquête et d'autres sources d'intérêt narratif [36].

Ainsi, pour que le roman policier puisse s'affirmer pleinement comme genre autonome, il doit se détacher du mode de diffusion spécifique au roman-feuilleton. Lavergne montre comment, tout au long de la période qu'elle étudie (du Second Empire à la Première Guerre mondiale), le récit policier reste tributaire des « entraves formelles » du feuilleton, notamment la publication par tranches et la longueur imposée par les logiques d'abonnement [37]. L'émancipation définitive ne viendra qu'au siècle suivant, avec l'apparition de collections éditoriales spécialisées (au premier rang desquelles *Le Masque* (1927)) qui offrent au genre un support autonome et contribuent à la consolidation médiatique du terme « roman policier », comme l'illustre l'évolution représentée en figure 7.1. Le chapitre 9 de cette thèse est dédié à ce changement de support de publication et à ses potentiels impacts formels.

3.2 Du roman-feuilleton au roman policier : trois évolutions formelles

Du point de vue du récit, la spécificité du roman policier ne surgit pas spontanément, mais émerge progressivement du roman judiciaire, lui-même branche spécialisée du roman populaire. Les romans d'Émile Gaboriau sont souvent caractérisés comme des romans judiciaires, où sont dépeints les mécanismes des procès, les débats devant la justice, ainsi que les tensions sociales qui traversent ces situations. Comme le note Lavergne, ces romans sont « imprégnés du mélange des genres et des tons de la période romantique, les romans judiciaires font donc bien souvent figures de textes archaïques [38] ou imparfaits par rapport aux standards des romans à énigme des années 1920-30, qui coïncident avec la théorisation du genre » [39].

Le roman policier se démarque progressivement du modèle feuilleton en proposant un récit plus resserré et centré sur l'investigation, c'est-à-dire en produisant ses propres règles du genre. Lavergne [40] identifie trois évolutions majeures qui marquent cette transformation :

lecture : lecture et lecteurs dans la France contemporaine. Paris : Éditions du Cercle de la librairie, 1988.

35. Poe, op. cit., p. 163-164.
36. Cawelti, op. cit., p. 109.
37. Lavergne, op. cit., p. 32–33.
38. Voir les travaux de Jean-Paul Colin pour la construction du terme : Colin, *Le roman policier français archaïque* ; Jean-Paul Colin. *La belle époque du roman policier français. Aux origines d'un genre romanesque*. Paris : Delachaux et Niestlé, 1999. DOI : 10.3917/deni.colin.1999.01, cités dans Lavergne, *La naissance du roman policier français*, p. 64.
39. Ibid., p. 64.
40. Ibid.

La première évolution concerne la persistance du thème criminel. Dans le roman-feuilleton, l'intrigue criminelle peut être interrompue par des digressions sentimentales, des descriptions de mœurs ou des épisodes secondaires. Le crime n'est qu'un moteur parmi d'autres, et le récit peut s'en éloigner temporairement pour suivre d'autres fils narratifs. Nous l'avons vu à l'instant l'importance du changement de support en sous-section 3.1, et le roman policier qui s'extirpe du roman feuilleton tend selon Lavergne vers une « une thématique criminelle persistante, l'une des conditions nécessaires à l'éclosion du roman policier. » [41]. Il y aurait donc une concentration thématique où le crime et son investigation traversent l'ensemble du récit, structurant toutes les péripéties et maintenant une cohérence de bout en bout.

La deuxième évolution porte sur la centralité croissante de l'enquêteur. Dans le roman judiciaire ou le feuilleton à énigme, le personnage chargé de l'investigation est souvent relégué à un rôle secondaire, voire épisodique. L'intrigue peut suivre tour à tour le criminel, la victime, les témoins ou d'autres personnages, sans privilégier systématiquement le point de vue de l'enquêteur. Lavergne le formule en ces termes :

> Le roman policier opère deux changements principaux par rapport au mode de récit habituel du roman populaire. En premier lieu, il met en vedette l'enquêteur, un personnage jusqu'alors absent du roman ou bien relégué au rang de personnage secondaire sans relief. Celui-ci se défait de ses attributs négatifs et éclipse désormais les acteurs directs du drame, les victimes, qui passent à l'arrière-plan, et le coupable, qu'il lui incombe de démasquer [42].

C'est donc à travers le parcours de l'enquêteur que le lecteur accède progressivement à l'énigme et à sa résolution. Le détective devient le pivot narratif autour duquel s'organise l'ensemble du récit.

La troisième évolution concerne la structure de l'intrigue, et elle est intimement liée à la persistance thématique. Lavergne ajoute aussitôt après avoir introduit cette première dimension, que :

> Cependant, le plus gros du travail reste à exécuter pour que naisse le genre : la mise au point d'un nouveau modèle formel, le fil du récit tendu du mystère vers sa résolution, et le renouvellement partiel des motifs du roman populaire, pour épurer le récit et faire glisser insensiblement le roman à thème criminel de l'aventure pure vers l'aventure de l'enquête [43].

La persistance du thème criminel est donc une condition nécessaire mais non suffisante : elle ne devient un trait proprement policier que lorsqu'elle s'accompagne d'une restructuration formelle du récit. Certes, le roman-feuilleton multiplie les intrigues parallèles, les digressions et les récits enchâssés qui diluent le suspense, mais le roman policier n'est pas seulement persistant, il organise son récit autour d'un fil directeur spécifique, celui du cheminement du crime jusqu'à à sa résolution. Toujours selon Lavergne, « les premiers romanciers judiciaires mettent en place une nouvelle structure de récit, inversée et tendue vers le dénouement et la résolution de l'énigme,

41. Ibid., p. 31-32.
42. Ibid., p. 55.
43. Ibid., p. 32.

inspirée des nouvelles policières d'Edgar Poe »[44]. Le récit policier se déploie ainsi selon une séquence reconnaissable : la mise en scène du crime, le travail de raisonnement et d'interprétation des indices, puis la révélation finale de la solution. Cette reconstruction progressive est semée de fausses pistes, de rebondissements et d'hésitations, mais elle reste orientée vers un dénouement qui ne consiste pas simplement en la fin chronologique de l'histoire, mais en la résolution d'une énigme posée dès l'ouverture. Lavergne insiste sur le fait que cette structure ne s'impose pas d'un coup. Les premiers récits policiers restent tributaires des habitudes du feuilleton, notamment du long « récit du passé » que l'on retrouve chez Gaboriau par exemple, qui interrompt brutalement l'enquête pour dérouler les origines familiales du drame[45]. C'est précisément l'élimination progressive de ces ruptures, et la consolidation de l'enchaînement *crime–raisonnement–résolution* comme armature du récit, qui marquent la maturation du genre.

Ces trois évolutions ne sont pas indépendantes : elles forment un faisceau cohérent où la concentration thématique, l'affirmation dela figure de l'enquêteur et la restructuration de l'intrigue se renforcent mutuellement. Notre démarche computationnelle s'appuie sur chacune d'elles et nous proposons dans les prochaines sections de rendre compte de notre démarche. La persistance du thème criminel est opérationnalisée par une analyse thématique diachronique en sous-section 4.2 ; la centralité du détective, par une mesure de sa position structurelle dans les réseaux de personnages en sous-section 4.3 ; et la prototypicalité de l'intrigue en sous-section 4.4, par une annotation automatique des scènes-clés du récit (crime, raisonnement, résolution) et par une mesure de la conformité de leur agencement au schéma canonique du genre.

4 Approches computationnelles de la naissance du roman policier

Ces trois évolutions analysées par Lavergne[46] peuvent être tenues pour des descriptions critiques robustes des transformations qui mènent au policier. L'enjeu n'est donc pas d'en discuter la validité sur le plan qualitatif, mais de relever un défi proprement computationnel : les rendre observables, c'est-à-dire les opérationnaliser sous forme d'indicateurs mesurables, comparables d'un texte à l'autre, et suffisamment stables pour être suivis à grande échelle. L'approche computationnelle permet alors de passer d'un constat critique à une mesure : dater l'affirmation de chacune de ces dimensions, estimer leur gradualité, et vérifier si elles convergent effectivement dans le temps. Comme on le verra dans la section suivante, chacune peut être traduite en métriques adaptées, permettant de suivre la sédimentation du policier sur un large corpus.

4.1 Corpus

Notre analyse s'appuie sur le corpus introduit au chapitre 4, le corpus *Chapitres*[47], comprenant 2961 romans, dont le sous-corpus policiers correspond à 372 romans.

44. Ibid., p. 93.
45. Ibid., p. 35.
46. Ibid.
47. Leblond, *Corpus Chapitres*.

4.2 Opérationnalisation de la persistance du thème criminel

La première évolution identifiée par Lavergne[48], la persistance du thème criminel tout au long de l'intrigue, nécessite une méthode capable d'identifier automatiquement le thème criminel dans les textes, de mesurer sa proportion au fil du récit, et de quantifier sa stabilité (c'est-à-dire l'absence d'épisodes isolés suivis de longues digressions). Pour ce faire, nous recourons à la modélisation de sujets par *Latent Dirichlet Allocation*[49] (LDA), une méthode probabiliste permettant d'extraire des thèmes latents dans un corpus.

La méthode Latent Dirichlet Allocation (LDA) est la méthode probabiliste retenue pour extraire des thèmes dans le corpus. Chaque document (segment de roman) est considéré comme une distribution de thèmes, eux-mêmes des distributions de mots. Afin de mieux isoler le thème criminel, nous avons appliqué plusieurs prétraitements : lemmatisation, filtrage par catégories grammaticales (noms, verbes, adjectifs, adverbes), élimination des noms propres, des mots rares et des mots outils (stopwords), puis segmentation des romans en morceaux de 5000 mots afin d'en étudier l'évolution intra-textuelle. Nous avons finalement extrait 100 thèmes dans le corpus *Chapitres* et mesuré leur proportion dans chaque segment.

La persistance du thème criminel se définit comme sa stabilité au fil des sections d'un même roman. Une faible variation signifie une présence continue, non-épisodique. Pour quantifier cette stabilité, nous recourons au *coefficient de variation* (CV), une mesure statistique classique de dispersion relative. Plus il est faible, plus la distribution du thème est homogène d'une section à l'autre. Il se définit mathématiquement comme suit :

$$CV = \frac{\sigma}{\mu} = \frac{\sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2}}{\mu} \tag{7.1}$$

où x_i est la proportion du thème criminel dans le segment i, μ la moyenne des proportions sur l'ensemble des segments, et σ l'écart-type. L'idée est ainsi de disposer d'une mesure entre 0 et 1 de l'homogénéité de la répartition du thème criminel dans chacun de nos textes.

4.3 Opérationnalisation de la centralité croissante du détective

La deuxième évolution identifiée par Lavergne[50] est l'affirmation du détective comme personnage central. Cela nécessite une approche permettant de mesurer objectivement la position du détective dans l'économie narrative du récit. Cette dimension constitue le cœur de notre hypothèse sur la sédimentation du genre : si le roman policier émerge progressivement comme forme autonome, nous devrions observer une croissance diachronique de l'importance structurelle du détective dans les romans.

Le chapitre 6 est dédié à cette figure clé du genre. Nous rappelons dans les prochaines sections les grands enjeux de l'archétype et nous construisons une manière plus robuste de calculer sa centralité narrative à l'aide de réseaux de personnages.

48. Lavergne, op. cit.
49. Blei, Ng et Jordan, « Latent Dirichlet Allocation ».
50. Lavergne, op. cit.

4.3.1 L'archétype du détective comme figure fondatrice

L'archétype du détective constitue une figure fondatrice au sein du roman policier, passant progressivement du simple résolveur d'énigmes en périphérie à une véritable *machine à raisonner*[51], incarnant la rationalité et le raisonnement méthodique. Comme le souligne Dubois, le détective classique se distingue du justicier feuilletonesque par sa plusieurs points : il est un « spécialiste qualifié par la technique », il est « extérieur au drame » et oriente l'enquête vers un procès de « détection et déduction » [52]. Cette approche rejoint étroitement la notion de *machine à raisonner*, qui exclut les motivations ou la psychologie humaines au profit de la seule justesse des déductions concernant les actes.

Maurice Leblanc, dans *Les confidences d'Arsène Lupin*, note d'ailleurs à propos de l'inspecteur Ganimard : « Jamais au cours de sa vie déjà longue, il [Ganimard] n'avait rencontré une telle clairvoyance, un esprit aussi aigu et aussi prompt » [53]. Ainsi, le détective évolue en un symbole de rationalité extrême, dont les méthodes reposent systématiquement sur l'interprétation rigoureuse d'indices.

4.3.2 Détection automatique des détectives

Pour mesurer l'affirmation progressive de cette figure centrale, nous devons d'abord être capables d'identifier automatiquement les détectives dans notre corpus à grande échelle. Cette identification repose sur le modèle de classification développé et détaillé dans le chapitre 6 [54].

En résumé, ce modèle supervisé, entraîné sur 185 personnages annotés manuellement (représentant 47 détectives uniques), exploite les sorties de Propp-fr pour caractériser chaque personnage par l'ensemble des verbes d'action qui lui sont associés, des adjectifs qui le qualifient, et des possessions qui lui sont attribuées. Ces attributs sont ensuite encodés soit par des représentations en sac-de-mots, soit par des embeddings contextuels, avant d'être utilisés pour entraîner un classificateur binaire. Le meilleur modèle atteint 92% d'efficacité, avec des performances stables sur des tests par auteur et par période, attestant de la robustesse diachronique de l'archétype détecté.

Ce modèle nous permet d'inférer automatiquement, pour chaque roman du corpus *Chapitres*, quels personnages jouent le rôle de détective, indépendamment de leur statut professionnel ou de leur style narratif. L'approche montre que le modèle capture un noyau formel commun à des figures aussi diverses que Tabaret, Lecoq, Rouletabille, Lupin (dans ses rôles d'enquêteur), Maigret, Burma ou Adamsberg.

51. Symons, *Bloody Murder : From the Detective Story to the Crime Novel : A History*, p. 39.
52. Jacques Dubois. « Naissance du récit policier ». *Actes de la Recherche en Sciences Sociales* 1985, p. 47-55. doi : 10.3406/arss.1985.2287, p. 49, 54.
53. Maurice Leblanc. *Les confidences d'Arsène Lupin*. Bibebook, 2013 [1913], p. 93.
54. Voir le chapitre précédent pour une présentation exhaustive de la méthode de détection de l'archétype du détective, incluant l'annotation du corpus d'entraînement, les représentations utilisées (BoW et CamemBERT), l'architecture du classificateur (SVM) et les résultats de validation.

4.3.3 Mesure de la centralité narrative par réseaux de personnages

Une fois les détectives identifiés dans chaque roman, nous mesurons leur importance structurelle en construisant le réseau des personnages du récit. Cette approche, désormais établie dans les humanités computationnelles[55], modélise chaque roman comme un graphe $G = (V, E)$ où les nœuds V représentent les personnages et les arêtes E leurs co-occurrences textuelles.

Concrètement, nous utilisons les chaînes de coréférence extraites par Propp-fr pour identifier les personnages, puis nous calculons leurs co-occurrences au niveau de la phrase : deux personnages sont reliés par une arête pondérée dont le poids correspond au nombre de phrases où ils apparaissent ensemble. Nous restreignons ensuite le réseau aux $N = 10$ personnages les plus mentionnés dans chaque roman, afin d'obtenir une représentation à la fois compacte et interprétable de la structure relationnelle principale du récit.

Pour quantifier la centralité d'un personnage dans ce réseau, nous recourons à l'algorithme *PageRank*[56], particulièrement adapté à notre objectif car il récompense non seulement la fréquence des interactions, mais surtout la position de hub connectant d'autres personnages importants. Formellement, le *PageRank* d'un personnage i est défini par la relation de récurrence :

$$PR(i) = \frac{1-d}{|V|} + d \sum_{j \in V} PR(j) \frac{w_{ji}}{s_j} \tag{7.2}$$

où w_{ji} est le poids de l'arête reliant j à i (nombre de co-occurrences), $s_j = \sum_k w_{jk}$ est la force sortante du nœud j, $|V|$ est le nombre total de personnages, et $d = 0.85$ est le facteur d'amortissement standard. Intuitivement, un personnage obtient un *PageRank* élevé s'il a des co-occurrences fréquentes avec d'autres personnages eux-mêmes centraux, ce qui devrait capturer le rôle du détective dans nos romans policiers.

Pour chaque roman, nous calculons le *PageRank* du personnage détecté comme détective. L'agrégation de ces valeurs par année de publication, lissée par une moyenne mobile sur 10 ans, permet de tracer l'évolution temporelle de la centralité du détective dans les réseaux de personnages. Si notre hypothèse de sédimentation progressive est correcte, nous devrions observer une croissance graduelle de cette centralité.

Cette approche présente plusieurs avantages méthodologiques. D'une part, elle ne repose pas sur des annotations manuelles à grande échelle (seul le modèle de détection des détectives a nécessité un corpus d'entraînement). D'autre part, elle fournit une mesure quantitative, reproductible et comparable entre romans, qui capture une dimension structurelle de la narration plutôt qu'une simple fréquence de mention.

55. David Elson, Nicholas Dames et Kathleen McKeown. « Extracting Social Networks from Literary Fiction ». *Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics*. Sous la dir. de Jan Hajič, Sandra Carberry et al. Uppsala, Sweden : Association for Computational Linguistics, 2010, p. 138-147 ; Markus Krug, Fotis Jannidis et al. « Comparison of Methods for the Identification of Main Characters in German Novels ». *Digital Humanities (DH2016)*. ADHO. Kraków, Poland, 2016 ; Vincent Labatut et Xavier Bost. « Extraction and Analysis of Fictional Character Networks : A Survey ». *ACM Computing Surveys* 2019. doi : 10.1145/3344548 ; Newman Chen, Frédérique Mélanie-Becquet et al. « Network Analysis, Plot Theory : Revisiting French Literature through Character Networks ». *Digital Humanities (DH2024)*. ADHO. Washington DC, United States, 2024.

56. Lawrence Page, Sergey Brin et al. *The PageRank Citation Ranking : Bringing Order to the Web*. Techreport. 1999.

4.4 Opérationnalisation de la prototypicalité de l'intrigue

Enfin, le dernier élément formel que nous voulons récupérer de nos textes est sans doute le plus complexe à extraire. La notion d'intrigue est un des talons d'Achille de la discipline computationnelle, puisque c'est une information pour le moment trop complexe à extraire automatiquement. Il s'agit de récupérer une information au niveau du récit entier, et les outils du TAL sont loin d'être à ce niveau. Malgré tout, on peut citer des travaux en Allemagne qui sont assez prometteurs à ce sujet. Nous renvoyons au chapitre 8 et à la sous-section 2.1 où un état de l'art succint sur la tâche est réalisé. Pour résumer, les progrès sont encourageants, mais ils confirment que la tâche reste loin d'être résolue, et sa transposition à d'autres langues demeure encore à accomplir.

Dans ce cadre, les modèles de langue génératifs (LLM) offrent une voie de travail particulièrement prometteuse. Nous nous appuyons ici sur eux pour proposer une méthode exploratoire de mesure de la prototypicalité de l'intrigue policière, depuis la mise en scène initiale du crime jusqu'à la résolution de l'énigme, que Lavergne identifie comme l'un des motifs formels majeurs dans la naissance du roman policier. Cette méthode repose sur l'annotation par un LLM d'un ensemble de scènes spécifiques, dont nous cherchons à mesurer la spécificité de l'agencement dans les récits policiers. Les trois scènes stéréotypiques retenues sont les suivantes :

— La scène de crime décrite par le récit, ou au moins sa découverte immédiate. Cette scène est un passage obligé du roman policier, et c'est tout le mécanisme de l'enquête qui va se mettre en place à partir de cet événement disrupteur.

— Ensuite vient la scène la plus importante du roman policier classique, celle du *raisonnement*. Elle peut prendre de multiples formes, Sherlock Holmes sur son fauteuil à bascule, Maigret fumant sa pipe, ou tout simplement un dialogue entre le détective et son associé (Rouletabille et le narrateur) ou entre le détective et les suspects. Cette scène prend en compte les hypothèses, les différents indices, c'est-à-dire le déroulé rationnel des tentatives de résolution.

— Enfin, la scène de résolution finale, où le détective donne la solution du crime, le choix d'un suspect et l'explication rationnelle du déroulé des évènements.

Voici le prompt, en anglais puisque ces modèles sont un peu meilleurs vu leur entraînement dominé par cette langue :

> You are classifying passages from French detective novels into one of four narrative categories.
>
> — **CRIME SCENE** : The crime or its immediate discovery is described. Use this label only when the passage truly depicts the act or finding of the crime.
> — **REASONING ATTEMPT** : A character analyzes evidence, forms hypotheses, interviews suspects, or reconstructs the sequence of events.
> — **CRIME FINAL RESOLUTION** : The definitive solution is revealed—who committed the crime, how, and why (not necessarily a trial).
> — **ELSE** : Anything that does not fit the above (e.g., setting, unrelated dialogue, character backstory).

For each passage :

1. Give two short sentences explaining your choice.
2. On a new line, output exactly one label in UPPERCASE.

L'annotation par modèle de langue a nécessité une phase de sélection et d'optimisation de l'instruction (*prompt*). Nous avons constitué un jeu de test de 100 passages annotés manuellement, sur lequel nous avons comparé trois modèles. Deux modèles à poids ouverts, exécutés localement sur les *GPU* du laboratoire, *Llama 3.1 8B-Instruct*[57] de Meta, (66% d'accord avec l'annotation humaine) et *DeepSeek-R1-Distill-Qwen-32B*[58] (74%), ont produit des résultats insuffisants pour notre tâche. Le modèle *Claude Sonnet 4* d'Anthropic[59], accessible par API, a atteint un taux d'accord de 86%, ce qui nous a conduit à le retenir pour l'ensemble de cette expérience. L'annotation des romans policiers antérieurs à 1945 du corpus *Chapitres*, soit environ une centaine de textes, a représenté un coût d'environ soixante euros en appels API.

L'intrigue prototypique d'un roman policier classique serait l'enchaînement de ces trois éléments : la scène de crime (SC), celle du raisonnement (R), puis celle de la résolution finale (RF). Dans un roman policier idéal, l'agencement de ces scènes suivrait le fil narratif le plus simple possible : d'une scène de crime initiale s'ensuit un enchaînement de scènes de raisonnement, puis vient la scène finale de résolution. Bien sûr, cette structure n'existe pas vraiment dans nos romans policiers, puisque l'intrigue est bien plus complexe que cela, avec de multiples crimes, des résolutions intermédiaires qui se révèlent être des fausses pistes, ou encore une résolution qui ne vient finalement jamais. Notre objectif est de mesurer à quel point nos textes se rapprochent de cette structure canonique, et nous voulons avec cela récupérer une mesure de la prototypicalité de l'intrigue entre 0 (très peu prototypique) et 1 (prototypique).

Pour ce faire, nous employons une mesure proche de la *distance d'édition* utilisée dans la discipline[60]. Nous comptons combien de permutations nous devons réaliser entre l'enchaînement de l'intrigue observée et l'intrigue prototypique. Prenons par exemple la séquence SC – R – SC – RF : la deuxième SC est en retard par rapport à la première R, ce qui nécessite une seule permutation pour retrouver l'ordre prototypique SC – SC – R – RF. Divisé par le nombre maximum de permutations possibles pour une séquence de quatre scènes, on obtient un score de 1/6. On ajoute dans le calcul le nombre de scènes *Else* (E) afin de pénaliser les intrigues qui se détournent de nos trois scènes-clés par des digressions sans rapport avec l'enquête.

$$\text{PPlot} = \frac{\#\text{permutations} + \#\text{E}}{\frac{n(n-1)}{2} + \#\text{E}} \quad \in [0, 1]$$

où n est le nombre de scènes différentes de *Else*.

57. Aaron Grattafiori, Abhimanyu Dubey et al. *The Llama 3 Herd of Models*. 2024. arXiv : 2407.21783 [cs.AI].

58. Daya Guo, Dejian Yang et al. « DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning ». *Nature* 2025, p. 633-638. doi : 10.1038/s41586-025-09422-z.

59. Anthropic, *Claude Opus 4 & Claude Sonnet 4 System Card*.

60. Cette mesure inédite est issue de discussions ménées notamment avec Valentin Thouzeau à Paris en avril 2025 et David Bamman à Würzburg en juin de la même année

Cette mesure exploratoire ne prétend pas capturer la double temporalité du récit policier (la superposition de l'histoire du crime et de l'histoire de l'enquête) décrite par Todorov ou Vareille. Ce qu'elle saisit, c'est la conformité de l'agencement séquentiel des scènes au schéma canonique du genre. Ce faisant, elle opérationnalise deux aspects complémentaires de la transformation décrite par Lavergne : d'une part, le resserrement de l'intrigue autour du fil crime–raisonnement–résolution ; d'autre part, l'élimination progressive des digressions feuilletonesques qui interrompaient l'enquête, puisque celles-ci sont précisément captées et pénalisées par la catégorie *Else* dans notre calcul.

5 Résultats

5.1 Persistance du thème criminel

5.1.1 Évolution intra-textuelle du thème criminel

La figure 7.2 propose l'évolution des thèmes dans *L'Affaire Lerouge* d'Émile Gaboriau. L'analyse LDA met en évidence l'instabilité du thème criminel sur l'ensemble du texte, et l'on observe ponctuellement quelques pans narratifs où ce thème demeure absent. Cette absence s'explique notamment par la publication initiale en feuilleton, qui amenait l'auteur à introduire des chapitres entiers consacrés à l'histoire personnelle de certains protagonistes, en dehors du ressort strictement criminel.

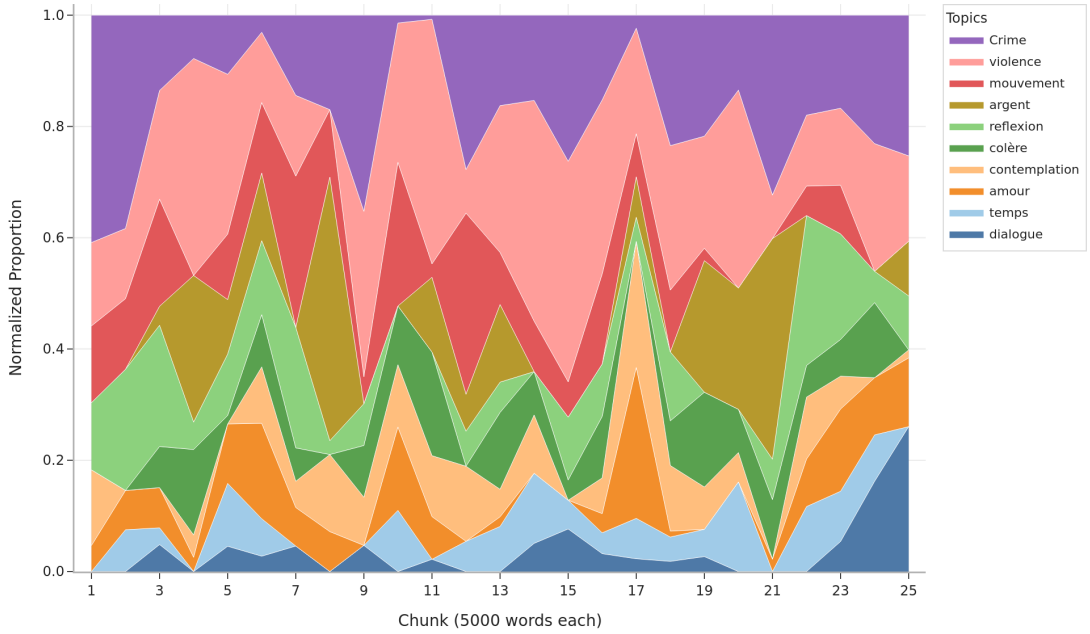


FIGURE 7.2 : Évolution du thème criminel en violet dans *L'Affaire Lerouge* (1866)

L'Affaire Lerouge porte précisément les marques du roman feuilleton : tout en développant le ressort de l'investigation, Gaboriau conserve certains chapitres dédiés à la biographie des personnages secondaires, sans lien direct avec le thème criminel. Nous avons par exemple le

juge Daburon qui durant un chapitre entier tombe amoureux de Claire d'Arlange, une jeune noble. Ce n'est que plus tard que l'on comprendra le lien avec l'histoire, puisqu'elle est elle-même liée d'amour avec Albert, prince de Commarin, principal suspect du crime que doit juger ce même Daburon. Cette intrigue amoureuse n'aborde dans sa longue construction aucun lien avec l'intrigue criminelle principale.

Dans la figure 7.3 *Le Mystère de la chambre jaune* de Gaston Leroux, nous relevons une meilleure stabilité du thème criminel à mesure que l'enquête progresse.

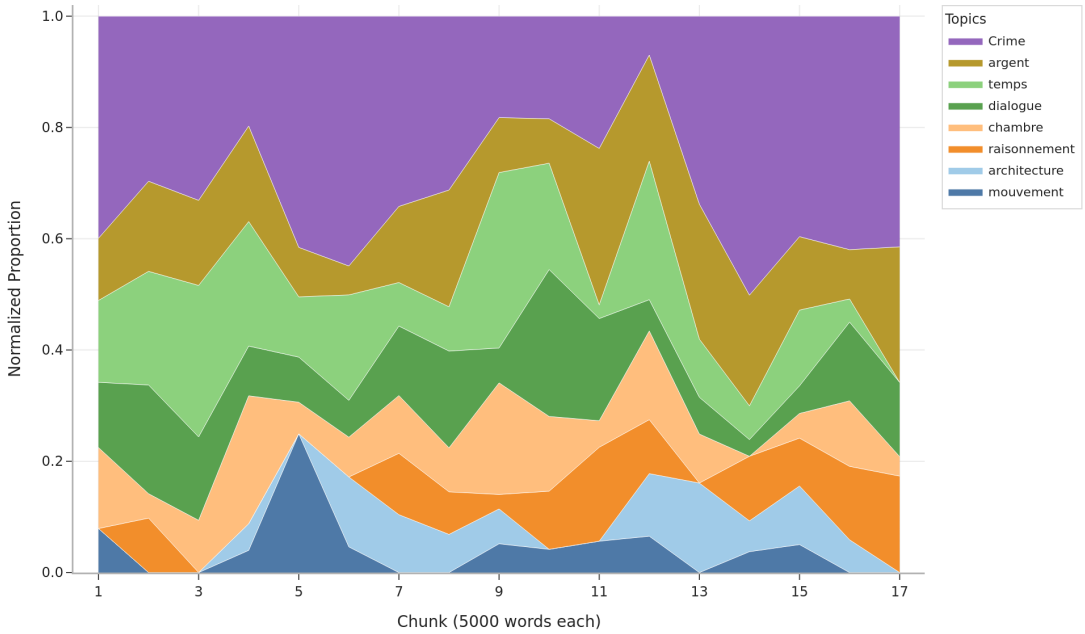


FIGURE 7.3 : Évolution du thème criminel en violet dans *Le Mystère de la chambre jaune* (1907)

Il y a encore cependant des périodes d'absence, par exemple avant le procès et le dénouement final, de longs passages sur la préparation du procès, la description de l'effervescence médiatique autour du mystère de la chambre jaune et l'attente de Rouletabille marquent une relative période d'absence du thème criminel.

La figure 7.4 présente le roman *120 rue de la Gare* de Léo Malet. La figure confirme cette tendance, tout en laissant davantage d'espace à d'autres thèmes (déplacements, bureaucratie) symptomatiques de la période de l'entre-deux-guerres.

Malet y développe la figure d'un enquêteur (Nestor Burma) qui s'affirme comme le pivot de la narration, et le roman maintient une immersion constante dans le thème criminel.

5.2 Mesure quantitative de la persistance thématique

La figure 7.5 met en évidence l'augmentation graduelle du score du coefficient de variation, suggérant qu'au fil du temps, le récit se recentre de plus en plus sur l'omniprésence du thème criminel. Dans les textes les plus anciens, on détecte encore une forte dispersion de la proportion du thème entre les différents segments, laquelle découle de l'hybridation feuilletonesque mentionnée

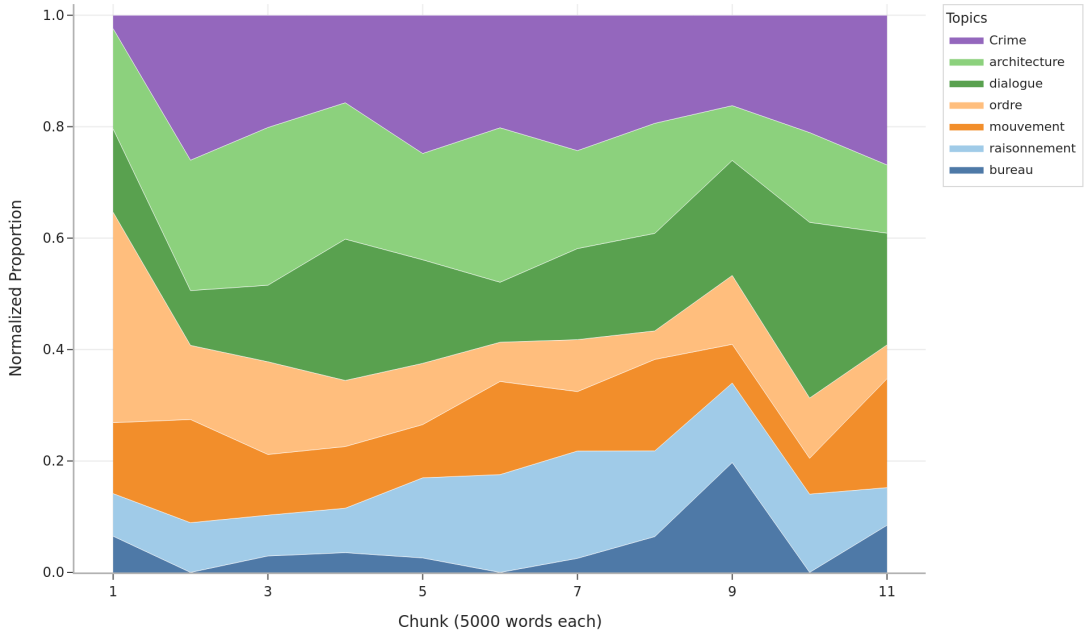


FIGURE 7.4 : Évolution du thème criminel en violet dans *120 rue de la Gare* (1943)

ci-dessus. Les romans plus tardifs, en revanche, offrent une intrigue sensiblement plus homogène.

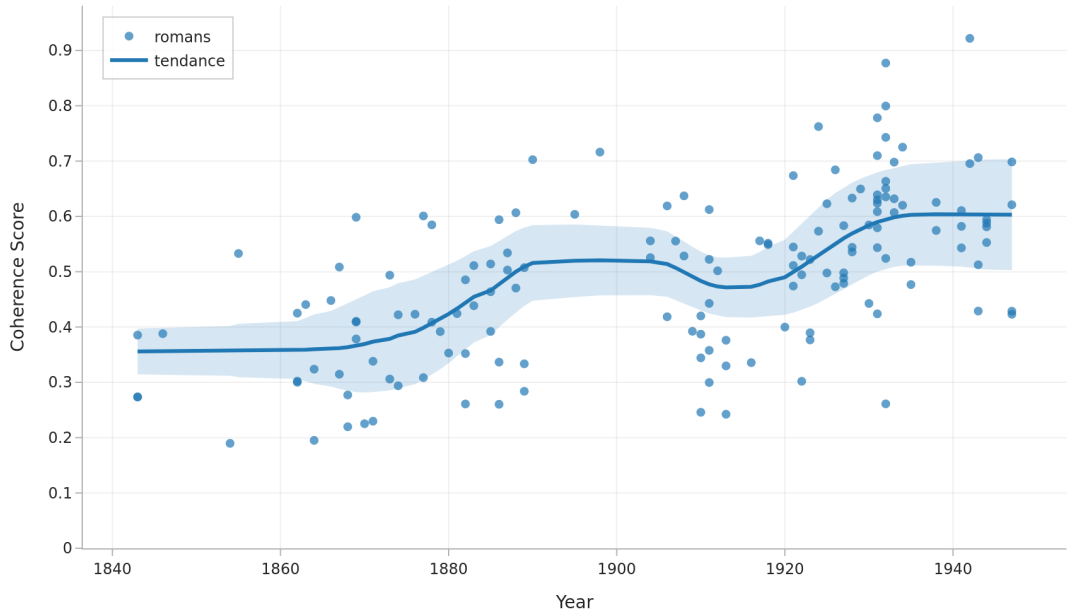


FIGURE 7.5 : Persistance du thème criminel au fil du temps. La zone ombrée représente un intervalle de confiance à 95 % autour de la moyenne glissante des moyennes annuelles et de leur erreur standard.

Dans les récits postérieurs à la Première Guerre mondiale, le thème criminel se retrouve réparti

de manière plus homogène, même s'il reste des fluctuations d'intensité au fil des romans. Cette uniformisation thématique correspond à l'émergence d'un véritable canon du roman policier, privilégiant l'enquête centrée sur le crime comme ressort narratif central. Cela confirme les intuitions de Lavergne et le suspense issu du roman-feuilleton s'intègre peu à peu dans un cadre plus strictement criminel.

5.3 Affirmation progressive du détective comme pivot narratif

5.3.1 Exemples de réseaux

Pour illustrer concrètement la transformation du texte en réseaux de personnages, la figure 7.6 présente le graphe de personnages de *Dossier 113* (Gaboriau, 1867), tandis que la figure 7.7 présente le réseau du *Fou de Bergerac* (Simenon, 1932).

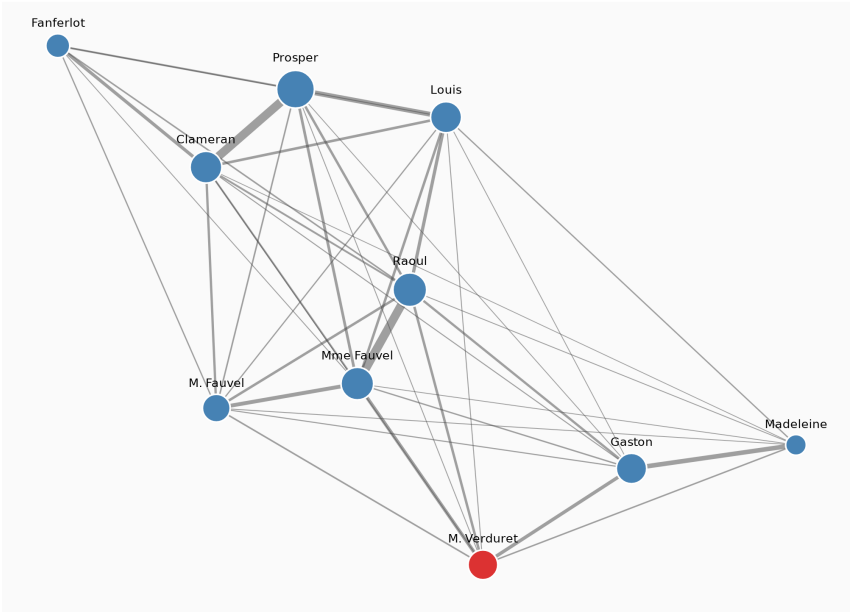


FIGURE 7.6 : Émile Gaboriau, *Dossier 113* (1867).

Dans *Dossier 113*, le détective Verduret (Lecoq) est bien repérable, mais sa position reste secondaire : avec un *PageRank* de 0,079, il apparaît davantage comme un relai du récit que comme un centre. Le réseau est porté par des personnages qui concentrent les interactions ordinaires du récit tandis que l'enquêteur intervient souvent à distance.

À l'inverse, dans *Le fou de Bergerac*, Maigret occupe une position nettement hégémonique : *PageRank* élevé (0,23), degré très important, et convergence des arêtes les plus épaisses vers son nœud. Cela colle à sa fonction : c'est lui qui interroge, recoupe, fait circuler l'information. Visuellement, son nœud rouge est placé au cœur du graphe, avec des arêtes épaisses vers plusieurs personnages-clés (on voit notamment Mme Maigret, mais aussi des figures locales comme Rivaud, Leduc, Françoise, Rosalie, etc.). Autrement dit, l'enquête est bien organisée autour de lui,

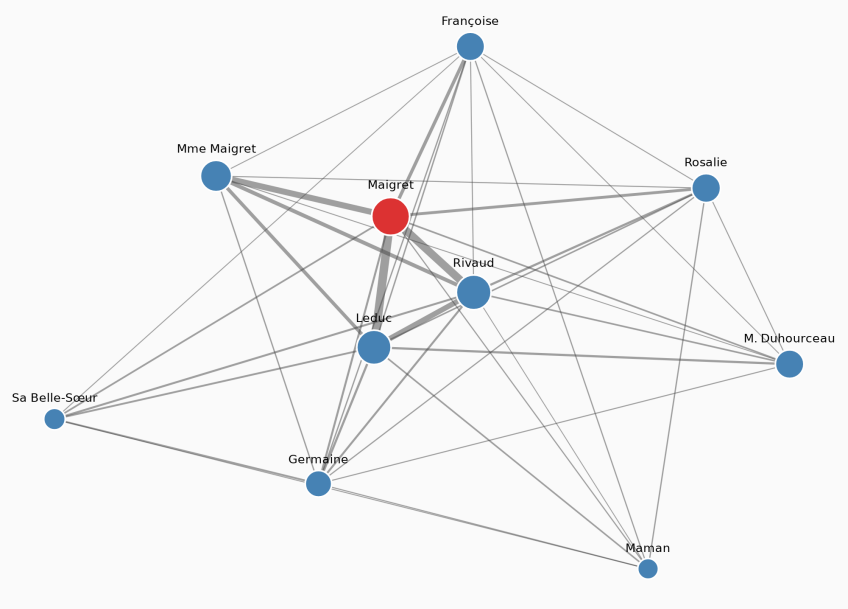


FIGURE 7.7 : Georges Simenon, *Le fou de Bergerac* (1932)

5.3.2 Centralité croissante du détective

L'application du détecteur de détective nous permet ensuite de mesurer, pour chaque roman, la centralité du détective principal dans le réseau des personnages de chaque roman. La figure 7.8 présente l'évolution temporelle du *PageRank* moyen du détective, agrégée par année de publication et lissée par une moyenne mobile sur 10 ans.

Le graphique révèle trois phases distinctes dans l'évolution de la centralité du détective :

1. **Phase pré-historique (1850-1880)** : Le *PageRank* du détective est aux alentours de 0,15. Dans les romans de cette période le détective n'est pas encore le centre organisateur du récit.
2. **Phase de convergence (1880-1925)** : On observe une croissance marquée et continue du *PageRank* du détective. Cette période correspond précisément à la cristallisation du genre policier en France : œuvres de Leroux (*Le Mystère de la chambre jaune*, 1907), cycles de Lupin (Leblanc). Le détective devient structurellement central et ne se contente plus d'apparaître épisodiquement.
3. **Phase de stabilisation (1925-1945)** : Après 1925, la courbe se stabilise dans une forme de plateau avec des hauts et des bas. Le détective est désormais, dans la grande majorité des cas, le personnage principal du récit.

Cette évolution quantitative confirme l'hypothèse qualitative de Lavergne[61]. Le roman policier se distingue du roman-feuilleton judiciaire par un recentrage progressif autour de l'enquêteur. Nos mesures ajoutent une caractérisation structurelle de ce processus, puisque l'on constate que la transition n'est pas brutale, mais progressive, s'étalant sur près de cinquante ans.

61. LAVERGNE, *La naissance du roman policier français*.

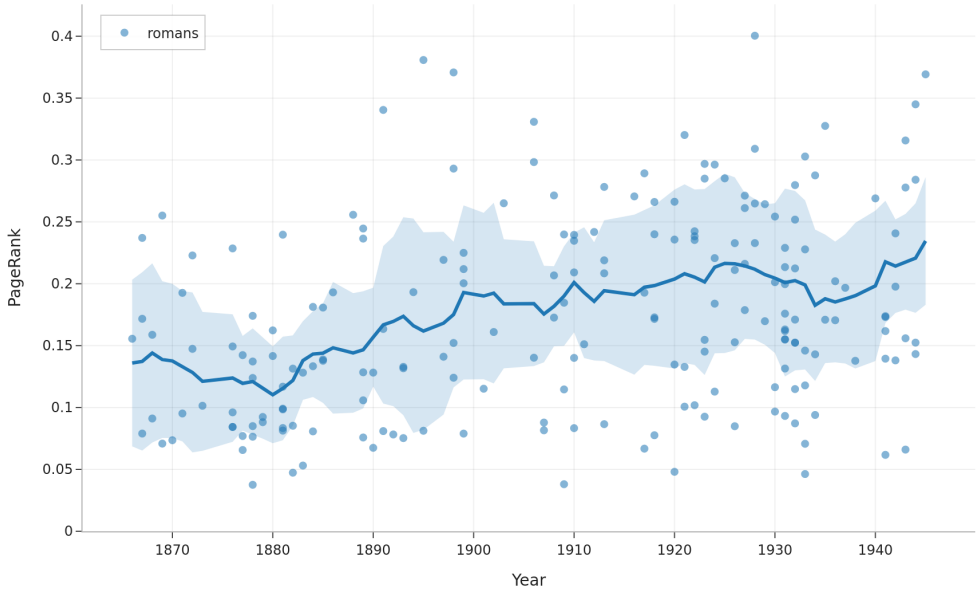


FIGURE 7.8 : Évolution de la centralité narrative du détective (1860-1945). Les points représentent les moyennes annuelles ; la courbe bleue représente des moyennes mobiles sur 10 ans. Le *PageRank* du détective augmente progressivement témoignant de l'affirmation du détective comme hub structurel du récit.

5.4 Prototypicalité de l'intrigue

Afin d'illustrer concrètement cette mesure, comparons deux romans aux scores contrastés. *Chez les Flamands* de Simenon (1932) obtient un score de 0.862, reflétant une structure narrative proche du schéma canonique. Sur 9 passages, un seul relève du contexte (E) : le premier, qui pose le décor de Givet et présente Anna Peeters. Les 8 passages restants s'enchaînent de manière quasi prototypique : trois passages de raisonnement (R) où Maigret interroge les différents protagonistes et recueille des témoignages, puis la découverte des preuves matérielles du crime (SC) (le rapport d'autopsie confirmant le meurtre et la découverte du marteau sur l'*Étoile-Polaire*), suivie de deux nouveaux passages de raisonnement, puis des aveux d'Anna dans les deux derniers passages (RF). La seule source d'inversions tient au fait que les trois premiers passages de raisonnement précèdent la scène de crime : Maigret enquête avant même que le meurtre soit formellement établi. Mais cette structure reste très proche du modèle canonique.

À l'inverse, *Les Esclaves de Paris* (Tome II) de Gaboriau (1868) n'atteint qu'un score de 0.566. L'examen de ses 39 passages révèle d'abord un trait caractéristique du roman-feuilleton : 28 passages sur 39 (72%) relèvent de la catégorie « Autre ». Il s'agit pour l'essentiel du long « Secret des Champdoce », ce « récit du passé » typique du feuilleton que Lavergne décrit comme une entrave à la forme policière [62]. Les crimes qui s'y déroulent (empoisonnement du duc, disparition de Croisenois) sont narrés chronologiquement comme du mélodrame, non découverts par un enquêteur : ils tombent donc dans la catégorie E. Parmi les 11 passages proprement policiers, on observe une inversion structurelle significative : une scène de résolution (l'explication de

62. Ibid., p. 34–35.

la disparition de Croisenois par Catenac) apparaît *avant* les 8 passages de raisonnement où André mène son enquête dans l'intrigue contemporaine. Le score est ainsi tiré vers le bas par la combinaison de deux facteurs : l'abondance de digressions feuilletonesques et le désordre dans l'agencement des scènes-clés.

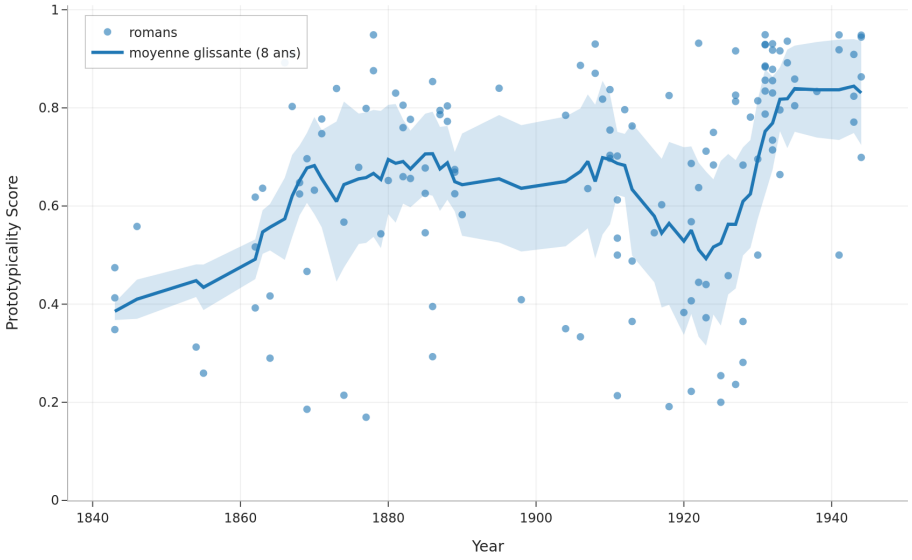


FIGURE 7.9 : Évolution de la prototypicalité de l'intrigue policière (score *PPlot*) entre 1840 et 1945. Chaque point représente un roman ; la courbe indique la moyenne glissante sur 8 ans.

La figure 7.9 présente l'évolution du score de prototypicalité de l'intrigue dans notre corpus policier entre 1840 et 1945. Trois phases se dessinent. Durant la période proto-policière (1840–1860), le score moyen reste bas, autour de 0.40 : les intrigues des premiers romans judiciaires, encore tributaires du modèle feuilletonesque, s'écartent sensiblement du schéma canonique crime–raisonnement–résolution. À partir des années 1870, avec Gaboriau et les premiers romanciers judiciaires, le score moyen s'élève progressivement pour atteindre un plateau autour de 0.65 qui se maintient jusqu'aux années 1910. Cette phase correspond à la période de maturation décrite par Lavergne, où les conventions du genre se mettent en place sans être encore pleinement stabilisées : la variabilité entre les romans reste importante, certains textes atteignant des scores élevés tandis que d'autres restent proches du modèle feuilletonesque.

La baisse de prototypicalité visible entre 1915 et 1927 s'explique par la domination, dans cette période, de romans policiers qui relèvent davantage du roman d'aventures que du *whodunit*. Les cycles tardifs de Leblanc en sont un exemple typique : *La Comtesse de Cagliostro* (1924), qui obtient un score de 0.32, est structuré comme un roman de cape et d'épée où Lupin affronte Joséphine Balsamo autour d'un trésor. Sur 20 passages, 15 relèvent de la catégorie « Autre » (aventure, romance, poursuites), et le seul passage de raisonnement est noyé parmi des scènes d'action sans lien avec une enquête méthodique. *La Demoiselle aux yeux verts* (1927, score de 0.50) présente un profil similaire : l'intrigue est une course-poursuite où les scènes de crime se multiplient sans être reliées par un fil d'investigation cohérent. Ces romans héritent encore des conventions du feuilleton d'aventures et n'adoptent pas la mécanique resserrée du roman policier.

La rupture la plus nette intervient à partir de la fin des années 1920. Le score moyen connaît une hausse marquée pour se stabiliser autour de 0.85 dans les années 1930–1940. Cette accélération coïncide avec l'entrée de Maigret dans le corpus (1931) : les romans de Simenon, par leur structure resserrée autour de l'enquête et leur élimination systématique des digressions, incarnent précisément le type d'intrigue que notre mesure capte comme prototypique. Plus largement, cette phase correspond à la consolidation institutionnelle du genre autour des collections spécialisées comme *Le Masque*, qui favorisent un format court et une structure narrative standardisée.

6 Discussion

6.1 Convergence des trois indicateurs

Les trois mesures proposées dans ce chapitre opérationnalisent chacune une dimension distincte de la naissance du roman policier décrite par Lavergne [63], et leurs trajectoires respectives méritent d'être confrontées. Le thème criminel gagne en persistance de manière graduelle tout au long de la période étudiée, avec une homogénéisation nette après la Première Guerre mondiale (sous-section 5.1). La centralité du détective dans les réseaux de personnages suit une courbe ascendante remarquablement régulière entre 1880 et 1925, avant de se stabiliser en plateau (sous-sous-section 5.3.2). Enfin, la prototypicalité de l'intrigue connaît une trajectoire plus heurtée, avec une phase de maturation (1870–1910), un creux correspondant à la domination du roman d'aventures (1915–1925), puis un bond brutal avec l'arrivée de Simenon et la consolidation éditoriale du genre (sous-section 5.4).

Ces trois dimensions convergent dans la même direction mais ne se sédimentent pas au même rythme. La persistance thématique et la centralité du détective évoluent de manière continue et progressive, ce qui correspond à l'intuition d'une sédimentation lente, par accumulation de traits d'un roman à l'autre. La prototypicalité de l'intrigue, en revanche, est plus sensible aux inflexions du champ littéraire : elle reflète la coexistence, dans le corpus, de modèles narratifs concurrents (roman d'aventures, roman judiciaire, roman à énigme) dont les proportions relatives varient selon les périodes.

6.2 Vérification des hypothèses

Ces résultats permettent de revenir sur les deux hypothèses formulées en début de chapitre. L'hypothèse de la sédimentation progressive est largement confirmée : les trois indicateurs montrent une évolution graduelle et continue des traits policiers entre 1866 et 1930, bien avant la reconnaissance médiatique massive du terme. Aucune de ces courbes ne présente de rupture brusque autour de 1927 ou 1930, et en d'autres termes, la formation textuelle du genre précède nettement sa consécration institutionnelle.

L'hypothèse de la transformation du roman-feuilleton est elle aussi corroborée, notamment par les exemples détaillés. Les scores de prototypicalité de Gaboriau (*Les Esclaves de Paris*, 0.566) illustrent précisément ce que Lavergne décrit : un roman qui possède déjà des traits

63. Ibid.

policiers (passages de raisonnement, résolution) mais où ceux-ci restent noyés dans une structure feuilletonesque dominée par les digressions. La comparaison avec Simenon (*Chez les Flamands*, 0.862) montre le chemin parcouru : l'élimination des « récits du passé », le resserrement autour de l'enquête, la concentration thématique. Les textes considérés rétrospectivement comme précurseurs présentent donc bien certains traits génériques, mais de manière moins systématique et moins stable que les romans postérieurs à 1930, conformément à notre prédiction.

Le creux de prototypicalité observé entre 1915 et 1927 ne correspond pas à un recul du genre, mais à une période où le corpus policier est dominé par des romans qui relèvent davantage de l'aventure policière que de l'énigme avec en particulier les cycles tardifs de Leblanc. Ce phénomène invite à nuancer le récit d'une progression linéaire qui serait linéaire. La sédimentation du genre n'est pas un mouvement uniforme, mais un processus traversé par des tensions entre modèles narratifs concurrents. Ce sont précisément les contraintes contextuelles, avec notamment les collections spécialisées, qui favorisent à partir des années 1930 la sélection et la stabilisation d'un modèle d'enquête plus homogène. Celui-ci ne se réduit pas au seul *whodunit* classique, mais correspond plus largement à une forme d'un roman policier procédural et intuitif comme celui qu'incarne Simenon. Nous prolongerons cette perspective dans le chapitre 9.

6.3 Limites

La mesure de prototypicalité de l'intrigue (*PPlot*) repose sur une annotation par LLM dont la fiabilité n'a pas été systématiquement évaluée contre une annotation humaine à grande échelle. Si les exemples détaillés (Simenon, Gaboriau, Leblanc) montrent que les annotations produites sont interprétables et cohérentes avec une lecture critique, une évaluation formelle de la précision et du rappel par catégorie serait nécessaire pour consolider ces résultats. Par ailleurs, la mesure ne distingue pas à l'intérieur de la catégorie *Reasonning* les véritables avancées de l'enquête des fausses pistes.

La centralité du détective dépend en amont de la qualité de la chaîne de traitement (coréférence, détection de l'archétype). Si le modèle de détection atteint 92% d'efficacité sur le corpus d'entraînement, des erreurs de coréférence dans les textes les plus longs peuvent affecter la construction des représentations des personnages puis des réseaux qui en découlent. La persistance thématique mesurée par LDA est tributaire du nombre de thèmes choisi (100) et de la granularité de la segmentation (5000 mots). Des choix différents pourraient produire des courbes légèrement décalées, même si la tendance générale devrait rester stable.

Malgré ces réserves, la convergence de trois indicateurs indépendants, construits par des méthodes différentes (modélisation de sujets, réseaux de personnages, annotation par LLM), sur un même corpus et une même période, constitue un argument fort en faveur de la robustesse du signal observé. La sédimentation du roman policier français est un phénomène mesurable, graduel, et antérieur à la reconnaissance institutionnelle du genre.

Partie III

Exploration : changements d'échelles

Chapitre 8

À la recherche de l'aventure

Objectifs

Ce chapitre prolonge l'enquête sur les genres romanesques en l'appliquant au roman d'aventures, un cas complémentaire du roman policier par ses frontières poreuses et sa définition disputée. L'objectif est double. À l'échelle du roman entier, il s'agit de retrouver les romans d'aventures dans le vaste corpus des Fictions Littéraires de Gallica, en combinant classification supervisée et correction par graphe de similarité, tirant ainsi les leçons méthodologiques du chapitre 5. À l'échelle du passage, il s'agit de détecter les scènes stéréotypiques qui constituent la matière concrète du genre, en opérationnalisant les deux pôles définitoires identifiés par Letourneux : le dépaysement (scènes d'exploration) et l'action violente (scènes de danger). En diffusant ces détecteurs sur l'ensemble de la production romanesque, nous testons l'hypothèse selon laquelle la spécificité du roman d'aventures ne réside pas dans la présence ponctuelle de ces scènes, car elles circulent largement entre les genres, mais dans leur persistance tout au long du récit. Ce mouvement circulaire, du corpus au passage et du passage au corpus, permet d'articuler deux questions solidaires : où sont les romans d'aventures dans les archives de la Bibliothèque nationale de France, et qu'est-ce qui fait qu'ils le sont ?

Sommaire

1 Introduction **191**
1.1 Du roman policier au roman d'aventures 191
1.2 Le roman d'aventures selon Letourneux 192
1.3 Des scénarios intertextuels aux scènes stéréotypiques 193
1.4 Questions de recherche 194
2 La scène comme unité d'analyse **195**
2.1 La notion de scène 195
2.2 Notre approche 196
3 Retrouver le roman d'aventures dans les fictions de Gallica **196**
3.1 Approche supervisée par SVM 197
3.2 Correction par approche non supervisée 201
4 Du corpus aux scènes : détecter l'aventure dans le texte **207**
4.1 Annotation 207

4.2 Diffusion par classification supervisée . . . 210
5 Analyse multiscalaire . . . **211**
5.1 Échelle du roman : lecture proche . . . 211
5.2 Échelle des sous-genres : lecture distante . . . 215
5.3 Échelle du corpus : diachronie . . . 218
6 Discussion . . . **219**
6.1 Complémentarité des approches . . . 219
6.2 Le genre entre regroupement et circulation . . . 220
6.3 Limites et perspectives . . . 220
Annexe . . . **221**

> Le Sage a créé, sans le vouloir, quelque chose de plus mince et de plus odieux que ses œuvres. Il a créé cette chose moderne, le roman d'aventures, — qui va des *Trois Mousquetaires* à Rocambole ; — cette chose qui n'est pas littéraire, qui file, s'interrompt et refile, au bas des journaux, sans autre raison que de toucher, comme un postillon, ses quelque sous à chaque relais.
>
> *Jules Barbey d'Aurevilly.* Romanciers d'hier et d'avant-hier. *Paris : A. Lemerre, 1904, p. 316-317*

1 Introduction

1.1 Du roman policier au roman d'aventures

Le chapitre 5 de cette thèse a permis de tester, sur un corpus de romans policiers, une méthode de classification générique fondée sur les représentations vectorielles des textes. Les résultats obtenus ont montré que les frontières du genre policier, loin d'être des lignes nettes séparant des territoires homogènes, se présentent plutôt comme des zones de transition où les textes entretiennent des degrés variables de proximité avec un noyau prototypique. Cette observation empirique rejoint les analyses théoriques de la partie I : le genre fonctionne moins comme une catégorie logique, que comme une « ressemblance de famille » formelle au sens wittgensteinien du terme.

Le présent chapitre propose de poursuivre cette enquête en l'appliquant à un second sous-genre romanesque : le roman d'aventures. Roman policier et roman d'aventures partagent en effet plusieurs caractéristiques qui en font des objets d'étude particulièrement pertinents pour une approche computationnelle des genres romanesques. D'abord, tous deux s'affirment comme genres sériels autonomes durant des périodes historiques proches (la fin du XIXe siècle pour le roman d'aventures, et le début du XXe siècle pour le roman policier), dans le contexte d'une industrialisation de la production littéraire et d'une massification du lectorat. Ensuite, tous deux relèvent de ce que Letourneux appelle les « littératures sérielles » [1], c'est-à-dire des productions qui assument explicitement leur inscription dans des conventions génériques partagées entre auteurs, éditeurs et lecteurs.

Cependant, si le roman policier a fait l'objet d'une attention soutenue dans cette thèse mais aussi plus largement dans le champ des études littéraires computationnelles, le roman d'aventures demeure un terrain moins exploré. Cette relative négligence tient sans doute, d'une part, à la difficulté de circonscrire un genre dont les frontières sont poreuses et dont la définition même fait débat. Mais elle s'explique aussi, d'autre part, par la moindre centralité du roman d'aventures dans la culture contemporaine : là où la fiction policière continue d'occuper une place structurante dans le paysage éditorial et médiatique actuel, le roman d'aventures apparaît comme un genre daté dans sa forme classique, ou bien devenu si protéiforme qu'il en perd sa spécificité. De plus, ses motifs ont migré vers les mondes imaginaires de la science-fiction et de la fantasy, ou encore

1. Letourneux, *Fictions à la chaîne*.

vers la littérature jeunesse, sans que l'étiquette « aventures » ne fédère plus ces productions. C'est précisément cette difficulté, un genre aux contours historiquement instables et aujourd'hui dispersé, qui en fait un cas d'étude intéressant pour notre propos.

Notre démarche procédera en deux temps, correspondant à deux échelles d'analyse complémentaires. Le premier temps opère à l'échelle du roman entier : il s'agit de retrouver les romans d'aventures dans le vaste corpus des *Fictions Littéraires de Gallica*[2], en combinant classification supervisée et correction par graphe de similarité. Le second temps opère à l'échelle du passage textuel : il s'agit de détecter, dans l'ensemble de la production romanesque, les scènes stéréotypiques qui constituent la matière du genre, et nous définissons les scénarios intertextuels de *danger* et d'*exploration*. Ce mouvement circulaire, du corpus au roman, du roman au passage, permettra d'articuler deux questions distinctes mais solidaires : où sont les romans d'aventures dans les archives de la Bibliothèque nationale de France, et qu'est-ce qui fait qu'ils le sont ?

1.2 Le roman d'aventures selon Letourneux

La thèse de Matthieu Letourneux, *Le Roman d'aventures, 1870-1930*[3], constitue une des références pour toute approche du genre dans le contexte français. Letourneux y propose une définition qui, tout en reconnaissant la fluidité des frontières génériques, identifie un certain nombre d'éléments convergents permettant de circonscrire un corpus cohérent.

Une première caractéristique définitoire est l'importance du dépaysement. Qu'il soit géographique, historique, social ou fantastique, le dépaysement constitue le cadre nécessaire à l'aventure. Comme le souligne Letourneux, « le dépaysement est moins une caractéristique première du genre qu'une conséquence de la primauté donnée à la mésaventure »[4]. En effet, pour que se multiplient les événements hors du commun qui mettent en péril le héros, il faut que le récit s'inscrive dans un univers où les règles du quotidien sont suspendues. Le dépaysement opère ainsi une « déréalisation »[5] de l'univers référentiel, rendant acceptable la logique particulière du roman d'aventures. Cette notion de dépaysement, que Letourneux emprunte à Victor Segalen[6], défini comme « Tout ce qui est 'en dehors' de l'ensemble de nos faits de conscience actuels, quotidiens »[7], présente l'avantage de ne pas réduire l'exotisme à sa seule dimension géographique.

La seconde caractéristique est la place centrale de l'action violente. Le roman d'aventures est le genre de la « mésaventure », c'est-à-dire de l'événement qui fait courir au héros un risque de mort ou au moins un péril physique. Cette thématique de la violence se décline « en barbarie, en agressivité, en pulsions, ou en images de la virilité, de la puissance ou du mal »[8]. Elle est organisée autour d'un personnage central qui subit une série d'agressions et en vient à bout par ses actions. C'est une véritable mise à l'épreuve du protagoniste, le temps d'épisodes narratifs courts qui vont

2. Corpus présenté au chapitre 4, sous-section 2.2
3. Matthieu Letourneux. *Le roman d'aventures : 1870-1930*. Limoges : Presses Universitaires de Limoges et du Limousin, 2010.
4. Ibid., p. 75.
5. Ibid., p. 132.
6. Victor Segalen. *Essai sur l'exotisme : une esthétique du divers*. Paris : Librairie Générale Française, 2009 [1978].
7. Victor Segalen, cité dans Letourneux, op. cit., p. 78.
8. Ibid., p. 409.

permettre la construction d'un suspens dont les mécanismes participent à construire la signature du genre.

Ces deux valeurs (dépaysement et action violente) interviennent selon l'analyse de Letourneux à tous les niveaux du récit : thématiquement, dans la caractérisation des personnages et du chronotope, stylistiquement, dans le recours à une écriture hyperbolique et nerveuse, structurellement, dans l'organisation épisodique du récit en une succession de crises et de résolutions. Il faut noter, même si nous ne pourrons développer ce point dans le cadre du présent chapitre, que ces deux pôles ne sont pas idéologiquement neutres. Le dépaysement du roman d'aventures est très largement un dépaysement colonial, et l'action violente qui s'y déploie met en scène, dans une proportion écrasante de la production, un héros blanc qui affronte les périls d'un monde « sauvage » et en sort vainqueur. Ce scénario fantasmatique, dont Edward Said [9] a montré qu'il participe de la construction occidentale de l'altérité, constitue une dimension idéologique du genre non négligeable. Nos méthodes computationnelles ne permettent pas totalement de saisir cette dimension, même si nous verrons que les coefficients de notre classifieur capte des termes comme « nègre » ou « blanche ».

Cette multi-dimensionnalité de la définition est précieuse pour notre propos : elle offre des prises à deux échelles d'opérationnalisation. À l'échelle du roman entier, le dépaysement et la violence laissent des empreintes lexicales détectables par les méthodes stylométriques. À l'échelle du passage, ils se cristallisent en scènes reconnaissables, des « scénarios intertextuels » au sens d'Eco, que nous chercherons à identifier automatiquement.

1.3 Des scénarios intertextuels aux scènes stéréotypiques

La notion de « scénario intertextuel », empruntée à Umberto Eco [10], désigne les schémas narratifs préfabriqués que le lecteur compétent mobilise pour interpréter un texte en le rapportant à d'autres textes du même type. Pour Eco, ce qui donne leur « ressemblance de famille » aux œuvres d'un même genre, ce sont les scénarios intertextuels qu'elles convoquent.

La notion d'Eco permet de penser la généricité comme un effet cumulatif produit par la récurrence de certaines situations ou configurations narratives. Un roman n'est pas « d'aventures » en vertu d'une essence qui lui serait inhérente, mais parce qu'il active, avec une fréquence et une intensité suffisantes, des scénarios que le lecteur reconnaît comme appartenant à l'encyclopédie du genre. Ces scénarios existent donc dans la mémoire culturelle du lecteur, formée par ses lectures antérieures et par les discours qui circulent autour du genre.

Letourneux, dans *Fictions à la chaîne*, souligne l'importance de ces mécanismes sériels qui opèrent à l'échelle du passage :

> Par-delà les éléments contextuels (support, paratexte, canal), le texte lui-même pourra mettre en branle des mécanismes sériels à des niveaux très différents. Stylistiquement, en recourant à une écriture stéréotypée, à des formules attendues, il s'enrichit des intertextes qu'il convoque. Ces effets de stéréotypie auront d'ailleurs souvent tendance

9. Edward W. Said. *L'orientalisme : l'Orient créé par l'Occident*. Trad. par Catherine Malamoud, Sylvestre Meininger et Claude Wauthier. Paris : Éditions du Seuil, 2005 [1978].
10. Eco, *Lector in fabula*, p. 101.

> à s'organiser en recourant aux idiolectes, thèmes, scénarios intertextuels, « formules » (ou *formulas* pour reprendre la notion popularisée par John G. Cawelti 16), et autres routines que l'on retrouve, dans les genres, d'une œuvre à l'autre [11].

La notion de *formulas* développée par Cawelti [12] mérite ici un éclaircissement. Pour le chercheur, les *formulas* sont des combinaisons stables de conventions narratives qui se reproduisent d'une œuvre à l'autre au sein d'un genre. Ces formules constituent des « routines narratologiques » qui assurent la cohérence du récit et garantissent aux lecteurs une certaine prévisibilité, indispensable à l'expérience du genre sériel. Eco permet de préciser le statut de ces formules en les situant dans une hiérarchie plus fine des schémas intertextuels [13]. Ce qu'il appelle les « scénarios maximaux » i.e. des fabulae préfabriquées prescrivant la succession correcte des ingrédients narratifs, correspond assez directement aux *formulas* de Cawelti. Mais Eco distingue en dessous de ce niveau des scénarios motifs (la « jeune fille persécutée », avec ses acteurs et ses séquences d'actions mais sans succession imposée) et des scénarios situationnels (Eco prend l'exemple du duel entre le shérif et le bandit, d'une tarte à la crème de la *slapstick comedy*), qui prescrivent des contraintes sur une portion d'histoire sans déterminer l'ensemble du récit. Cette hiérarchie est précieuse pour notre propos : elle permet de penser la généricité non comme une propriété monolithique du texte, mais comme un effet produit à plusieurs échelles, depuis les scènes reconnaissables qui constituent la matière concrète du récit jusqu'aux règles de succession qui en organisent l'enchaînement.

1.4 Questions de recherche

Ce chapitre poursuit un triple objectif. Le premier est de constituer un corpus de romans d'aventures au sein des *Fictions Littéraires de Gallica*, en combinant les leçons méthodologiques tirées du chapitre 5 avec une correction par approche non supervisée afin d'exploiter la structure de similarité entre les textes, et enfin un contrôle humain afin d'en interroger la validité.

Le second objectif est de mettre au jour ce que Tomachevski appelle la « dominante » du genre. Chez Tomachevski, les « traits du genre » sont « des procédés dominants, c'est-à-dire que tous les autres procédés nécessaires à la création de l'ensemble artistique leur sont soumis » [14]. La dominante est un principe structural de hiérarchisation, qui fait qu'un genre ne se définit pas par la simple présence de tel ou tel élément, mais par le fait qu'un procédé central subordonne et oriente les autres. Tomachevski ne précise toutefois pas ce qu'il entend exactement par le fait qu'un procédé « domine » les autres, et la notion reste, chez lui, qualitative et structurale plutôt que quantitative. L'opérationnalisation que nous en proposons est donc nécessairement réductive : nous reformulons la dominante comme persistance des scénarios intertextuels de danger et d'exploration tout au long du récit. Notre hypothèse est que cette persistance constitue un corrélat mesurable de la dominante au sens de Tomachevski : si le roman d'aventures se distingue des autres genres, ce n'est pas parce que de telles scènes y apparaissent (car elles

11. Letourneux, *Fictions à la chaîne*, p. 47.
12. Cawelti, *Adventure, mystery, and romance*.
13. Eco, op. cit., p. 101-104.
14. Tomachevski, « Théorie de la littérature », p. 308.

peuvent se rencontrer dans n'importe quel récit de fiction), mais parce qu'elles y reviennent avec une fréquence et une régularité suffisantes pour structurer l'ensemble du texte.

Le troisième objectif est de constater la porosité du genre en détectant ces scènes dans l'ensemble de la production romanesque. Ce projet prend appui sur la thèse formulée par Tadié dès la première page de son ouvrage : « l'aventure est l'essence de la fiction » [15]. Par cette formule, Tadié ne se contente pas d'un trait d'esprit : il soutient que l'aventure, définie comme « l'irruption du hasard, ou du destin, dans la vie quotidienne, où elle introduit un bouleversement qui rend la mort possible, probable, présente » [16], constitue un principe structurel à l'œuvre dans toute fiction. Le roman d'aventures, lui, est le genre qui fait de ce principe son objet premier et sa raison d'être. On retrouve ici, formulée de manière plus générale, la double polarité de Letourneux : le « bouleversement qui rend la mort possible » correspond au pôle de l'action violente, tandis que l'irruption de l'inconnu dans le quotidien rejoint le dépaysement. Nous devons donc nous attendre à retrouver nos scènes de danger et d'exploration dans d'autres sous-genres romanesques. La question n'est alors plus de savoir si ces scènes y sont présentes, mais dans quelle proportion elles y apparaissent par rapport au roman d'aventures.

2 La scène comme unité d'analyse

2.1 La notion de scène

La notion de scène occupe une place centrale en narratologie depuis les travaux fondateurs de Gérard Genette [17]. Dans la terminologie genettienne, la scène désigne un mode de régulation de la vitesse narrative où le temps du récit coïncide approximativement avec le temps de l'histoire : c'est le régime du dialogue, de l'action en temps réel, par opposition au sommaire (qui condense) ou à la pause (qui suspend). Mais cette définition, fondée sur le rapport entre temps diégétique et temps de la narration, pose un problème d'opérationnalisation. Comme le dit Underwood, « l'opposition binaire entre scène et sommaire est une convention critique qui n'est guère soutenue par des preuves solides » [18]. Les résultats d'Underwood n'invalident pas l'utilité descriptive des catégories de Genette, mais ils invitent à les considérer comme les pôles d'un continuum plutôt que comme deux régimes narratifs séparés par une frontière nette.

L'extraction automatique de la structure narrative constitue de fait l'un des défis majeurs des études littéraires computationnelles. Face à cette difficulté, la discipline a opté pour une définition de la scène qui est, de fait, la définition théâtrale : un même lieu, un même moment, un même ensemble de personnages engagés dans une même action, autrement dit, une unité cohérente définie par la stabilité de ses paramètres. Comme l'a montré Lojkine [19], cette définition est pertinente pour le roman dans la mesure où le roman moderne a absorbé le modèle théâtral au cours du XIXe siècle, faisant de la scène le moment où le récit échappe à la narration pour se donner comme espace et comme spectacle. C'est cette définition théâtrale que mobilisent les

15. Jean-Yves Tadié. *Le roman d'aventures*. Paris : Gallimard, 2013 [1982], p. 5.
16. Ibid., p. 5.
17. Gérard Genette. *Figures III*. Paris : Éditions du Seuil, 1972, p. 129, p. 187.
18. Underwood, « Why Literary Time is Measured in Minutes », p. 344.
19. Stéphane Lojkine. *La scène de roman : méthode d'analyse*. Paris : Armand Colin, 2002.

travaux récents en Allemagne. Zehe et al.[20] opérationnalisent ces quatre critères (temps, lieu, action, personnages) et proposent une segmentation automatique fondée sur la détection de leurs changements. À partir de ces unités minimales, Konle et al.[21] construisent deux graphes complémentaires : un graphe temporel qui lie les différentes scènes entre elles en fonction du temps narratif, et un graphe causal qui permet de tracer une chaîne de causalité entre les événements les plus importants pour l'intrigue.

Ces approches présentent l'avantage de capturer une information structurelle sur le récit, au-delà du simple contenu thématique. Cependant, elles requièrent une annotation préalable considérable et leur généralisation à de grands corpus reste problématique. Plus récemment, Zehe et al.[22] ont amélioré la procédure d'entraînement de ces modèles de segmentation, atteignant une performance de 0.68 sur des corpus allemands. Ce score, s'il marque un progrès sensible, illustre aussi la difficulté persistante de la tâche : la segmentation automatique en scènes reste, à ce jour, un problème ouvert, et les ressources disponibles demeurent en grande majorité germanophones.

2.2 Notre approche

C'est précisément parce que la segmentation automatique en scènes n'atteint pas encore une fiabilité suffisante que nous adoptons ici une stratégie différente. Notre approche ne vise pas à segmenter le récit en scènes narratologiquement délimitées, mais à classifier des passages selon leur appartenance à des types de scènes prédéfinis. Nous travaillons sur des fenêtres de taille fixe (512 mots), indépendamment du découpage narratif effectif. Ce choix, s'il introduit un bruit de segmentation (certaines fenêtres chevaucheront inévitablement deux scènes distinctes), présente l'avantage de ne pas dépendre d'une étape préalable de détection des frontières dont les performances actuelles compromettraient la fiabilité de l'analyse en aval.

3 Retrouver le roman d'aventures dans les fictions de Gallica

L'analyse des scènes stéréotypiques que nous proposerons dans la seconde partie de ce chapitre suppose de disposer au préalable d'un corpus de romans d'aventures suffisamment étendu et représentatif. Or, le corpus des *Fictions Littéraires de Gallica*[23], qui rassemble 12 ,176 romans numérisés, ne dispose pas d'annotations génériques systématiques. Les métadonnées de la Bibliothèque nationale de France, lorsqu'elles existent, sont lacunaires et inégalement fiables pour

20. Albin Zehe, Leonard Konle et al. « Detecting Scenes in Fiction : A new Segmentation Task ». *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics : Main Volume*. Online : Association for Computational Linguistics, 2021, p. 3167-3177. doi : 10.18653/v1/2021.eacl-main.276.

21. Leonard Konle et Fotis Jannidis. « Modeling Plots of Narrative Texts as Temporal Graphs ». *Proceedings of the Computational Humanities Research Conference (CHR 2022)*. CEUR Workshop Proceedings, 2022, p. 318-330 ; Leonard Konle, Agnes Hilger et Fotis Jannidis. « On Character Perception and Plot Structure of German Romance Novels ». *Proceedings of the Computational Humanities Research Conference (CHR 2023)*. CEUR Workshop Proceedings, 2023, p. 592-605.

22. Albin Zehe, Elisabeth Fischer et Andreas Hotho. « Assessing the State of the Art in Scene Segmentation ». *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics : Human Language Technologies (Volume 1 : Long Papers)*. Sous la dir. de Luis Chiruzzo, Alan Ritter et Lu Wang. Albuquerque, New Mexico : Association for Computational Linguistics, 2025, p. 9922-9941. doi : 10.18653/v1/2025.naacl-long.500.

23. Langlais, *Fictions littéraires de Gallica*.

les genres populaires. Il nous faut donc retrouver le roman d'aventures dans cette masse textuelle et constituer, à partir d'un signal faible, un corpus générique exploitable. Il ne s'agit pas d'une intuition entièrement nouvelle : sur Gallica, Langlais [24] a proposé dès 2019 une expérimentation visant à « reconstituer » des genres romanesques à partir du texte intégral, en attribuant des probabilités génériques à un sous-corpus d'environ 1 500 romans (1815–1850), précisément parce que les métadonnées de la BnF rendent ces catégories peu repérables.

Notre travail s'inscrit dans la continuité de cette recherche, mais s'en démarque sur plusieurs points. Nous opérons d'abord sur une collection plus vaste d'un facteur dix. Notre objectif n'est ensuite pas de cartographier des catégories globales, mais de récupérer un sous-genre spécifique de manière contrôlée. Enfin, nous ancrons le signal dans une liste historiquement située, dans la lignée d'Underwood et de sa « modélisation perspectiviste » présentée au chapitre 3.

Cette tâche de classification générique a déjà été abordée dans le chapitre 5 à propos du roman policier. Nous y avons montré qu'une approche purement supervisée produisait des résultats honorables mais imparfaits : le modèle tendait à sur-généraliser sur certains mots lexicaux de surface, tout en manquant des œuvres dont la signature s'écartait du prototype. Fort de ce constat, nous proposons ici une approche en deux temps : une classification supervisée suivie d'une correction par graphe de similarité. L'hypothèse sous-jacente est simple : un véritable roman d'aventures devrait ressembler à d'autres romans d'aventures. Un texte classé comme tel mais isolé dans l'espace des représentations est probablement un faux positif.

3.1 Approche supervisée par SVM

3.1.1 Données d'entraînement

Le corpus d'entraînement est constitué des 101 romans cités dans la thèse de Letourneux [25] et disponibles dans les *Fictions Littéraires de Gallica*. Ces textes sont issus de 36 auteurs, et couvrent la période 1870-1930 (certains textes dépassent un peu les bornes). Ils représentent un échantillon diversifié de la production du genre, des grands noms canoniques (Verne, Dumas, Sue, Féval, Gautier, Ponson du Terrail), et d'autres tombés dans l'obscurité (Boussenard, Ferry, Assolant, d'Ivoi, Aimard, Jacolliot) qui constituent de fait l'essentiel de la production. Un ensemble équivalent de 101 romans non-aventureux, tirés aléatoirement du même corpus, sert de classe négative.

Nous partons de la collection *Fictions Littéraires de Gallica* (19,240 romans numérisés) [26]. Comme nous l'avons expliqué au chapitre 4, nous appliquons des filtres de prétraitement afin d'améliorer la fiabilité textuelle et de réduire le bruit bibliographique avant la modélisation : nous conservons les textes dont la qualité OCR estimée dépasse 95%, excluons les volumes d'œuvres complètes et supprimons les rééditions. Après dédoublonnage (par ex. six éditions des *Travailleurs de la mer* de Hugo) et filtrage, le corpus de travail utilisé pour la classification et la construction du graphe contient 12 ,176 romans.

Par ailleurs, la liste de Letourneux est aussi robuste sur le plan méthodologique parce qu'elle

24. Idem, *Reconstituer les genres romanesque sur Gallica*.
25. Letourneux, *Le roman d'aventures*, Principaux auteurs du genre, p. 441.
26. Langlais, *Fictions littéraires de Gallica*.

est diverse et limite le biais d'idiolecte : elle couvre de nombreux auteurs et évite de sur-représenter une seule signature (au maximum cinq romans pour un auteur). Le signal supervisé a donc davantage de chances de capturer des régularités trans-auteurs alignées sur des conventions de genre.

L'objectif dans l'entraînement du modèle est autant d'apprendre ce qu'est un roman d'aventures que ce qu'il n'est pas. Or, Gallica couvre plusieurs siècles, et nous élargissons donc la classe négative afin de refléter l'amplitude temporelle de l'archive. Concrètement, nous ajoutons des négatifs temporels en échantillonnant jusqu'à cinq romans non-aventure par décennie en dehors de la fenêtre centrale de production du genre : en 1650-1870, puis en 1930-1950. Cette procédure étend le jeu de négatifs avec une prose non-aventure historiquement diversifiée, tout en gardant une règle d'échantillonnage transparente et reproductible.

3.1.2 Représentation et classification

Chaque roman est représenté par un vecteur de fréquences des mots les plus fréquents (MFW), selon la méthode présentée au chapitre 4. Le nombre de mots retenus a été fixé empiriquement. La figure 8.15 en annexe compare les performances du classifieur selon le nombre de MFW à une sélection aléatoire de mots, l'exactitude équilibrée (*balanced accuracy*) augmente régulièrement avec la taille du vocabulaire et atteint un optimum à 5 000 MFW (85.6%), avant de se stabiliser. La supériorité constante des MFW sur la sélection aléatoire confirme que les mots les plus fréquents portent un signal lexical pertinent pour la discrimination générique.

Afin de ne pas limiter l'analyse à des signaux fondés sur les seules fréquences lexicales, nous mobilisons également des représentations vectorielles au niveau du paragraphe, produites par un modèle d'embeddings spécialisé (fine-tuné) pour les textes littéraires français, également présenté au chapitre 4. Les romans excédant la fenêtre de contexte du modèle, chaque texte est encodé comme une séquence d'embeddings de passages, puis agrégé par moyenne afin d'obtenir une représentation unique de taille fixe par roman. Cette stratégie conserve un signal sémantique global tout en restant compatible avec des classifieurs standards et avec la construction de graphes de similarité à l'échelle du corpus.

Ces deux représentations sont mobilisées de manière complémentaire dans les deux étapes de la chaîne de traitement. Pour la classification supervisée, nous privilégions la représentation en sac-de-mots : elle est robuste en régime de faible supervision et, surtout, fournit des coefficients interprétables, permettant de rendre explicite le prototype de l'aventure. En revanche, pour l'étape de correction par graphe, nous construisons la structure de voisinage k-NN à partir des moyennes d'embeddings de passages. Ces dernières définissent une notion de proximité plus riche que le simple recouvrement lexical, mieux adaptée à la capture de ressemblances de famille graduelles entre sous-genres, ainsi qu'entre textes traduits ou stylistiquement atypiques.

3.1.3 Classification par SVM linéaire

Le classifieur utilisé est une machine à vecteurs de support (SVM)[27] à noyau linéaire, implémentée dans Scikit-learn[28]. Le noyau linéaire est ici préféré au noyau RBF utilisé pour la classification des scènes (section 4.2), car il permet d'inspecter directement les coefficients du modèle et donc d'interpréter les mots discriminants.

Représentation	Classe	Précision	Rappel	F1-score	Support
BoW (MFW)	Non-Aventure	0.94	0.91	0.92	219
	Aventure	0.81	0.87	0.84	101
Balanced accuracy (globale)			0.89	($n = 320$)	
Embeddings de paragraphes	Non-Aventure	0.95	0.89	0.92	219
	Aventure	0.80	0.91	0.85	101
Balanced accuracy (globale)			0.90	($n = 320$)	

TABLE 8.1 : Résultats de validation croisée sur le corpus Letourneux ($n = 320$) pour une base BoW (MFW) et pour des représentations par embeddings de paragraphes.

Appliquée à l'ensemble du corpus, le SVM prédit 1
,375 romans d'aventures (∼12% de la collection). Un premier indicateur de la robustesse du résultat se trouve dans la distribution des probabilités de classification. La figure 8.1 montre que le modèle est en général très sûr de ses prédictions. La grande majorité des textes classés comme « aventure » le sont avec une probabilité supérieure à 90%, et la tranche la plus représentée de la distribution se situe entre 95% et 100%. Ce comportement suggère que le signal stylistique du genre est suffisamment fort pour permettre une discrimination nette dans la plupart des cas. Les textes classés avec des probabilités intermédiaires (50–70%) constituent une zone d'incertitude qui méritera une attention particulière lors de la phase de correction.

Un second indicateur est la distribution temporelle des romans classés comme « aventure ». La figure 8.2 montre que les prédictions se concentrent massivement sur la période 1860–1910, avec un pic autour de la décennie 1875-1885 (¼ des textes). Ce profil temporel correspond à la périodisation proposée par Letourneux, ce qui constitue en soi une première validation externe de l'approche.

La figure 8.3 présente les mots dont les coefficients sont les plus élevés dans le modèle linéaire. Les coefficients positifs (associés à la classe « aventure ») révèlent un univers lexical cohérent avec la définition de Letourneux : on y trouve des marqueurs de l'altérité exotique et coloniale (*nègre*, *blanche*), du récit d'action physique (*appuya*, *couteau*), des verbes de parole signalant la prédominance du dialogue et du discours direct (*écria*), ainsi que des indicateurs d'un monde historiquement antérieur à la France contemporaine du genre : *maréchal*, *majesté*, *royale*, *lieutenant*, *coquin* évoquent un univers d'Ancien Régime ou de hiérarchie militaire qui fonctionne, au même titre que l'exotisme géographique, comme opérateur de dépaysement temporel. Ce vocabulaire dessine le profil d'un genre qui combine le dépaysement et la violence, conformément

27. Corinna CORTES et Vladimir VAPNIK. « Support-vector networks ». *Machine Learning* 1995, p. 273-297. DOI : 10.1007/BF00994018.
28. PEDREGOSA, VAROQUAUX et al., « Scikit-learn : Machine Learning in Python ».

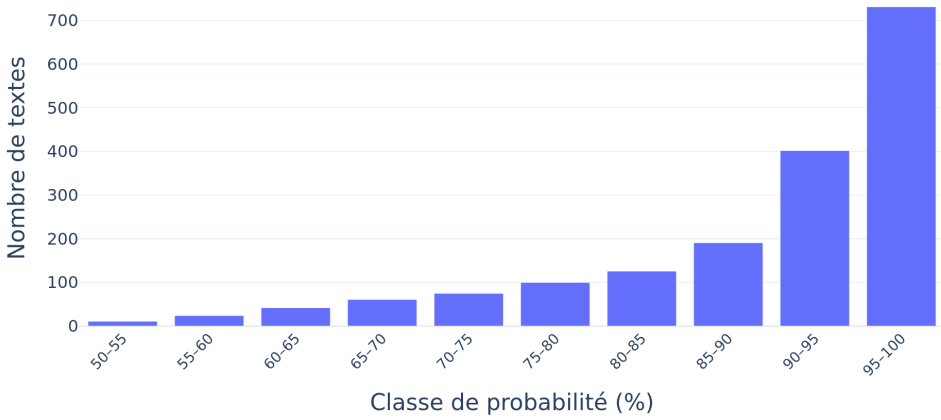


FIGURE 8.1 : Distribution des probabilités de classification « aventure » assignées par le SVM aux romans du corpus Gallica. Les ¾ des textes sont classés avec une probabilité très élevée (>90%), indiquant un signal stylistique fort.

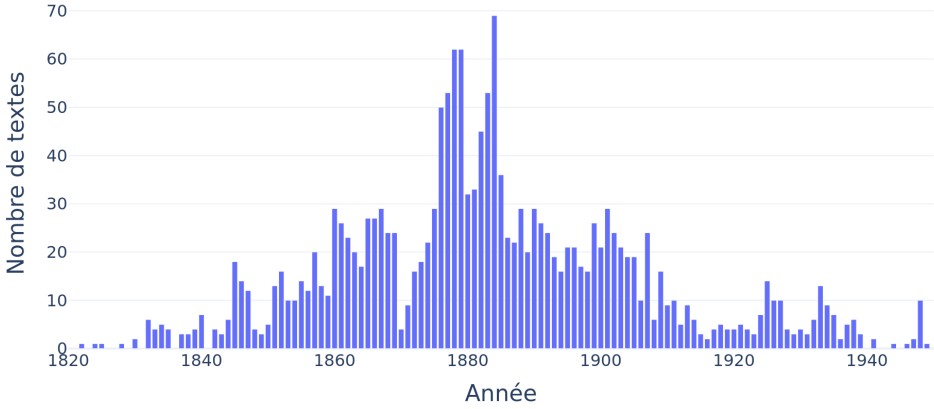


FIGURE 8.2 : Répartition temporelle des romans classés « aventure » par le SVM. La distribution se concentre sur la période 1860–1910, en accord avec la périodisation de Letourneux.

à la double polarité identifiée par Letourneux.

Les coefficients négatifs révèle la présence de termes apparemment « aventureux » comme *chevaliers* ou *clef* parmi les mots les plus anti-aventureux selon le modèle rappelle que le classifieur ne mesure pas l'aventure en soi, mais ce qui distingue le roman d'aventures tel que le définit Letourneux (1870–1930) du reste de la production romanesque. Le mot *chevaliers* renvoie au roman historique, qui partage avec le roman d'aventures le goût de l'action mais constitue, dans le corpus, un sous-genre distinct dont les conventions lexicales diffèrent. De même, *clef* relève davantage de l'univers domestique ou policier (la clef d'une enquête, ou comme accès à un espace clos) que du plein air aventureux.

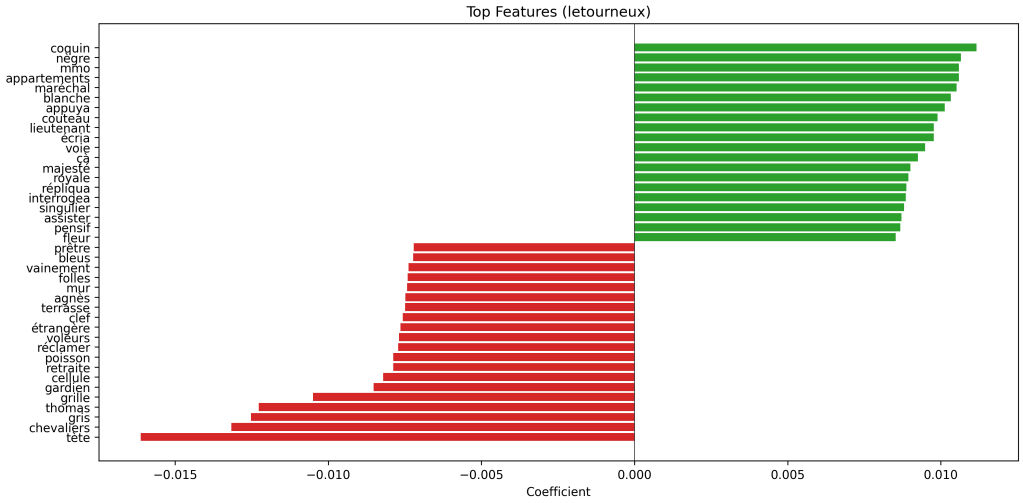


FIGURE 8.3 : Coefficients les plus élevés (en valeur absolue) du SVM linéaire. Les barres vertes (coefficients positifs) correspondent aux mots associés à la classe « aventure » ; les barres rouges (coefficients négatifs) aux mots associés à la classe « non-aventure ».

Au total, le SVM identifie 1 391 romans comme relevant du genre du roman d'aventures. Ce chiffre, qui représente environ 12% du corpus total, est plausible au regard de l'importance de la production sérielle dans la période concernée. Cependant, l'expérience acquise au chapitre 5 avec le roman policier nous incite à la prudence : ce premier étiquetage doit être affiné.

3.2 Correction par approche non supervisée

3.2.1 Principe

L'idée directrice de cette seconde étape est de mobiliser la structure de l'espace vectoriel pour corriger les erreurs du classifieur. Si le roman d'aventures constitue bien un genre, c'est-à-dire un ensemble de textes partageant des conventions reconnaissables, alors les romans qui en relèvent devraient former un regroupement, dans l'espace des représentations. Ils devraient être plus proches les uns des autres qu'ils ne le sont du reste de la production romanesque.

Nous construisons un graphe de k plus proches voisins (k-NN) sur l'ensemble du corpus, où chaque roman est un nœud et où une arête relie deux romans si l'un figure parmi les k plus proches voisins de l'autre dans l'espace vectoriel des embeddings. Nous examinons ensuite la position des romans étiquetés « aventure » par le SVM dans ce graphe : un roman d'aventures « authentique » devrait avoir la majorité de ses voisins également étiquetés « aventure », tandis qu'un faux positif sera isolé parmi des voisins non-aventureux.

Une notion clé ici est celle d'*homophilie*, empruntée à l'analyse des réseaux sociaux. Elle mesure la tendance des nœuds similaires à se connecter entre eux. L'homophilie d'un graphe étiqueté se comprend comme la proportion d'arêtes qui relient deux nœuds de même étiquette. Une homophilie de 0.5 indiquerait une distribution aléatoire des étiquettes. Une homophilie significativement supérieure à 0.5 témoignerait d'une structure de clustering réelle.

La figure 8.4 présente le graphe k-NN obtenu, où les nœuds orange représentent les romans

classés « aventure » par le SVM et les nœuds verts un échantillon aléatoire du reste du corpus. L'homophilie mesurée est de 0.754, ce qui confirme que les romans d'aventures forment bien un cluster distinct dans l'espace vectoriel. La séparation visuelle entre les deux couleurs est nette, même si des zones de mélange existent aux frontières.

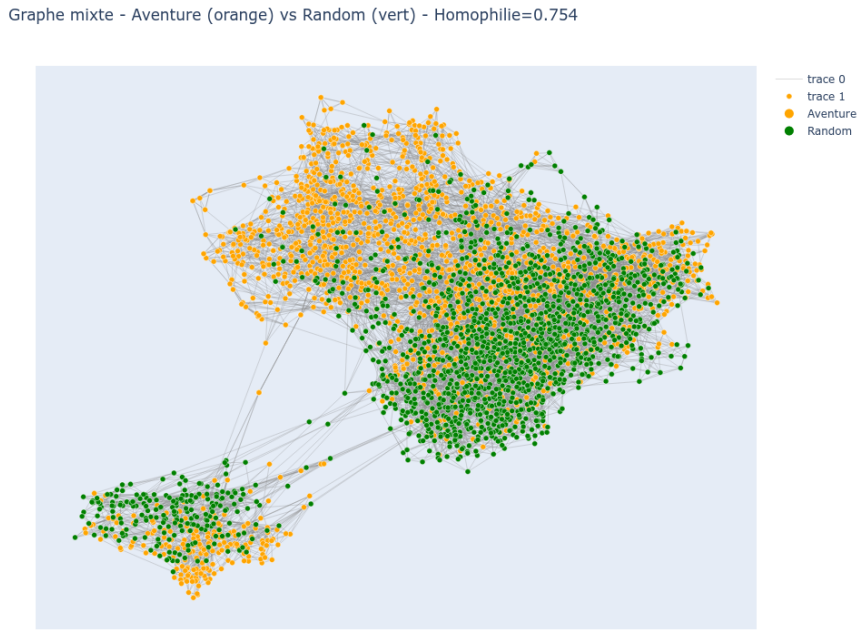


FIGURE 8.4 : Visualisation du graphe de similarité k-NN mixte : romans « aventure » étiquetés par le SVM (orange) et des romans « non-aventure » tirés au hasard (vert). Même si les *layouts* par forces peuvent produire des lobes secondaires, la forte séparation des étiquettes motive une correction fondée sur le voisinage.

Ce résultat est robuste au choix du paramètre k. La figure 8.16 en annexe montre que l'homophilie reste stable et bien supérieure à la baseline aléatoire (0.5) pour toutes les valeurs de k testées (de 3 à 20), passant de 0.76 à 0.73. La modularité du graphe, qui mesure la qualité de la partition en communautés, décroît logiquement à mesure que k augmente et que le graphe se densifie, mais demeure élevée (de 0.81 à 0.68). La convergence de ces deux métriques sur une large gamme de k garantit que la structure du regroupement observée n'est pas un artefact du paramétrage.

3.2.2 Protocole de correction

Le protocole de correction repose sur le nombre de voisins « aventure » de chaque roman dans le graphe k-NN :

Retrait des faux positifs (*outliers*) : Un roman étiqueté « aventure » par le SVM mais dont le voisinage est massivement « non-aventure », est traité comme un faux positif et supprimé. Concrètement, nous signalons un roman prédit « aventure » comme valeur aberrante lorsque au moins 80% de ses k plus proches voisins sont des textes « non-aventure ».

Ajout des faux négatifs (*infiltrés*) : Un roman non étiqueté « aventure » mais inséré dans un voisinage « aventure » est traité comme un faux négatif et ajouté. Concrètement, nous ajoutons un roman comme infiltré lorsque au moins 80% de ses k plus proches voisins sont étiquetés « aventure ».

Ce protocole identifie 113 faux positifs et 129 faux négatifs, soit un bilan net de +16 romans et un corpus corrigé de 1 391 textes.

3.2.3 Analyse qualitative des corrections

L'étape de correction produit des cas diagnostiquement parlants qui clarifient comment le modèle apprend. Comme l'étape en graphe évalue chaque prédiction relativement à son voisinage local, elle tend à faire émerger des erreurs structurelles : des textes qui peuvent paraître aventureux pris isolément mais qui n'occupent pas la région « aventure » de l'espace de similarité ; et, inversement, des textes que le classifieur manque bien qu'ils soient fortement insérés parmi des romans d'aventures. Par souci de transparence, les listes complètes des valeurs aberrantes retirées et des infiltrés ajoutés sont fournies en Annexe 7 (Tableaux 10.8 et 10.9).

Valeurs aberrantes retirées (faux positifs). Nous retirons 113 romans prédits « aventure » signalés comme valeurs aberrantes par notre règle de voisinage. Les retraits les mieux classés révèlent des motifs récurrents. Beaucoup sont clairement hors du roman d'aventure (par exemple des récits moraux et domestiques comme les *Contes moraux* de Genlis (1861), ou des fictions centrées sur la famille comme *La famille Gaudry* (Girardin, 1909)), qui peuvent néanmoins être attirées par des indices de surface ou des recouvrements locaux de vocabulaire. Nous observons aussi des cas limites où le titre contient « aventures » ou des motifs adjacents (e. g. *Histoire et aventures du baron…* (Bürger, 1840)), mais où les œuvres restent insérées dans des voisinages non-aventure et sont donc filtrées par le critère relationnel. Enfin, plusieurs items correspondent à des corpus narratifs plus anciens ou hétérogènes (e.g. *Cendrillon* ou *Le petit chaperon rouge* de Perrault), qui ne sont pas des romans au sens visé et se trouvent naturellement isolés du cluster aventure du XIXe siècle.

Infiltrés ajoutés (faux négatifs). Symétriquement, nous ajoutons 129 infiltrés à l'aide de la règle inverse. Ces ajouts récupèrent des œuvres canoniques et hautement conventionnelles que le SVM avait manquées, notamment *Le Chancellor* (1878) et *Famille sans nom* (1889) de Jules Verne, ainsi que des producteurs centraux du sous-genres dont la surface stylistique peut diverger du prototype appris, comme *Le Pirate* (1865) du capitaine Marryat et *Les chasseurs de girafes* (1869) de Mayne Reid. Ici, la densité de voisinage fonctionne comme une procuration de la centralité générique : l'étape de correction rétablit des textes qui occupent clairement la région aventure de l'espace de similarité même lorsque le classifieur lexical sous-généralise.

3.2.4 Bilan quantitatif

Le Tableau 8.2 résume la manière dont la correction modifie les propriétés du corpus. La similarité moyenne intra-genre augmente (+3.6%), la variance diminue fortement (−18.4%), et

l'agrégation des étiquettes dans le graphe s'améliore (+5.4% d'homophilie). En bref, la correction produit un corpus à la fois plus cohésif et mieux séparé du fond romanesque général.

Mesure	Avant	Après	Interprétation
Nombre de romans	1,375	1,391	Corpus enrichi
Similarité moyenne	0.789	0.825	+3.6% : Meilleure cohésion
Écart-type	0.098	0.080	−18.4% : plus homogène
Homophilie	0.754	0.7946	+5.4% : mieux séparé

TABLE 8.2 : Effet de la correction par graphe sur le corpus aventure.

3.2.5 Auteurs représentatifs du corpus

Les deux visualisations ci-dessous (figures 8.5 et 8.6) proposent une lecture complémentaire du corpus corrigé : d'un côté, la concentration de la production autour d'un petit nombre de signatures ; de l'autre, la dynamique temporelle de ces signatures, c'est-à-dire la manière dont certaines trajectoires éditoriales structurent la période d'essor du roman d'aventures.

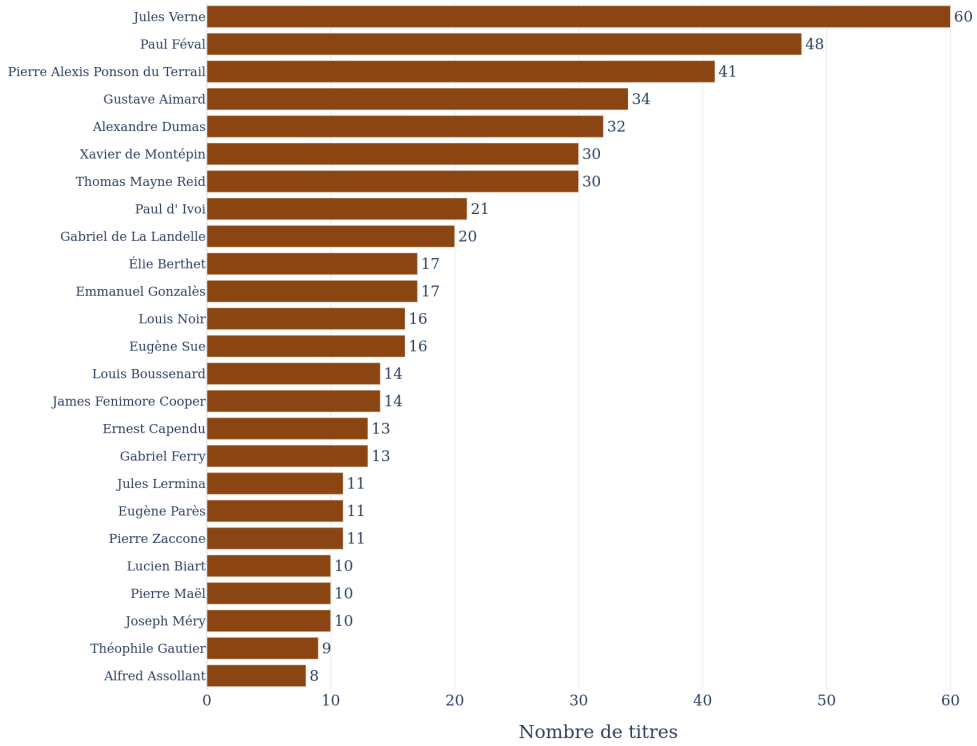


FIGURE 8.5 : Auteurs les plus représentés dans le corpus corrigé : nombre de titres par auteur (top 25).

La figure 8.5 met d'abord en évidence une forte asymétrie, avec quelques auteurs qui concentrent une part importante des titres, tandis que la majorité n'est représentée que par un petit nombre de romans. Jules Verne domine largement (avec 60 titres), suivi de Paul Féval

(48) et de Ponson du Terrail (41), puis de Gustave Aimard (34), Alexandre Dumas (32), Mayne Reid (30) et Xavier de Montépin (30). Cette hiérarchie n'a rien d'anecdotique : elle indique que le corpus n'est pas seulement un agrégat de textes « aventureux », mais qu'il se laisse aussi décrire comme un champ de production organisé autour de pôles auctoriaux stables. La présence importante de Montépin, davantage associé au drame judiciaire et au feuilleton sentimental qu'à l'aventure stricto sensu, confirme la porosité des frontières génériques : le roman d'aventures, en tant que genre éditorial, n'a jamais fonctionné comme une catégorie étanche, et les auteurs les plus prolifiques du feuilleton circulent librement entre registres.

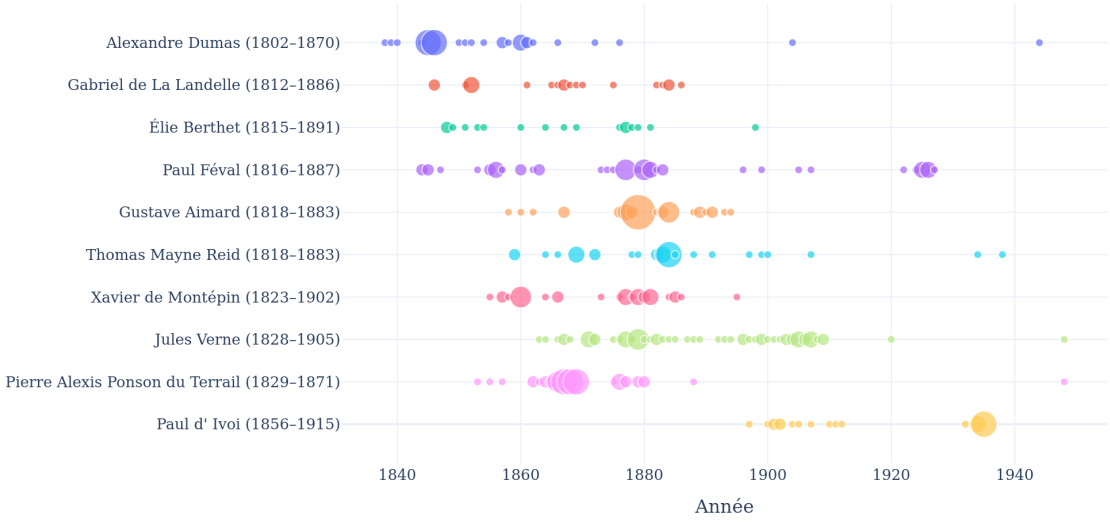


FIGURE 8.6 : Temporalité des auteurs les plus représentatifs : chaque point correspond à un titre du corpus, positionné par année de publication dans Gallica (la taille des points est proportionnelle au nombre de titres pour une même année). La dispersion temporelle tient en partie aux rééditions présentes dans les fonds numérisés.

La figure 8.7 met en évidence une distribution fortement asymétrique : quelques signatures dominent en volume (Dumas, Gonzalès, Ferry, etc.), tandis que la majorité des auteurs n'apparaissent que par un très petit nombre de titres. Près de sept auteurs sur dix ne sont représentés que par un seul titre (390 sur 569, soit 68,5 %), tout en couvrant à eux seuls plus d'un quart du corpus (27,6 %). Cette structure à queue longue rappelle que le genre repose d'abord sur une production de masse largement sortie de la mémoire littéraire : une littérature *hors d'usage* dont la numérisation conserve la trace sans nécessairement en réactiver la visibilité canonique. Autrement dit, l'image d'un genre structuré par quelques grandes figures ne doit pas masquer une réalité textuelle plus diffuse, portée par une multitude de signatures aujourd'hui peu reconnues.

Le corpus de romans d'aventures ainsi confectionné est mis à disposition en ligne, avec sa documentation descriptive et les fichiers nécessaires à sa réutilisation [29].

29. Voir le lien corpus raffiné.

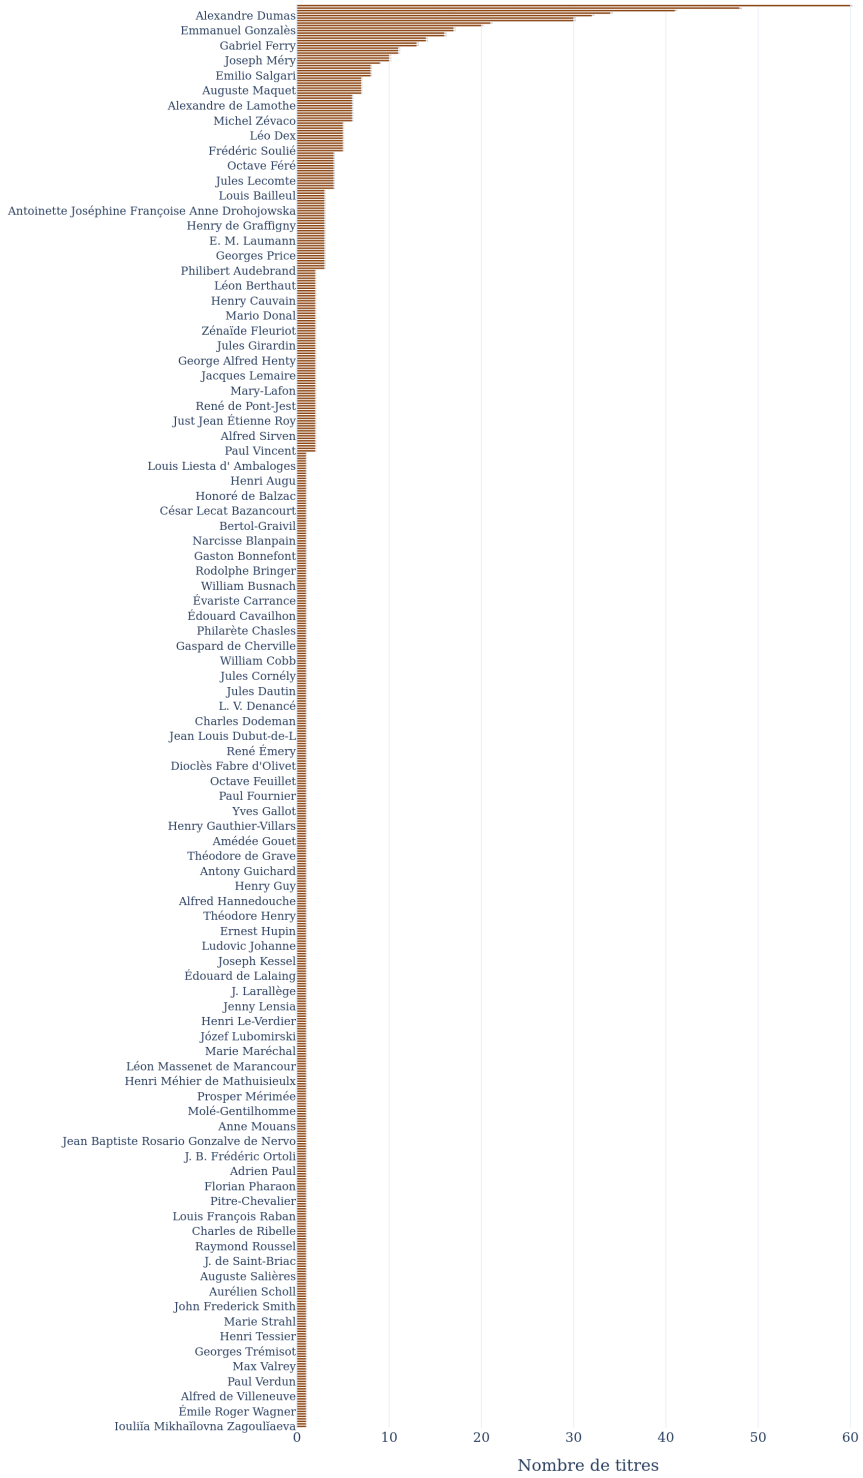


FIGURE 8.7 : Nombre de titres par auteur dans le corpus « aventures » de Gallica (barres triées par effectif). Pour des raisons de lisibilité, Plotly n'affiche qu'un sous-ensemble des étiquettes de l'axe des auteurs dans la version statique (PNG) ; toutes les barres correspondent néanmoins à l'ensemble des auteurs du corpus.

4 Du corpus aux scènes : détecter l'aventure dans le texte

Nous[30] disposons désormais d'un corpus de 1 391 romans d'aventures, constitué par la combinaison d'une classification supervisée et d'une correction par graphe de similarité. Ce corpus nous dit quels textes relèvent du genre. Mais il ne nous dit pas encore ce qui, dans le texte, fait le genre. Pour répondre à cette question, il faut changer d'échelle et passer du roman au passage.

L'enjeu de cette seconde partie est de détecter, à l'intérieur des textes, les scènes stéréotypiques qui constituent la matière concrète du roman d'aventures. L'idée de cette détection est de diffuser le modèle sur l'ensemble de la production romanesque, afin d'observer la circulation de ces scènes au-delà des frontières du genre.

4.1 Annotation

4.1.1 Exemples

Notre opérationnalisation de l'architextualité repose sur la définition de deux types de scènes stéréotypiques, directement dérivées de la définition du genre par Letourneux. Avant d'expliciter le protocole d'annotation, il convient de préciser concrètement ce que nos labels désignent dans les textes. Deux exemples, tirés respectivement de Jules Verne et d'Eugène Sue, permettent de saisir ce que chaque catégorie capte.

Exploration : l'océan souterrain dans *Voyage au centre de la Terre*. Considérons un passage central de *Voyage au centre de la Terre* (1864). Le professeur Lidenbrock et son neveu Axel, après une longue descente dans les entrailles du globe, débouchent sur un espace inattendu. Le texte bascule alors dans un registre contemplatif :

> D'abord je ne vis rien. Mes yeux déshabitués de la lumière se fermèrent brusquement. Lorsque je pus les rouvrir, je demeurai encore plus stupéfait qu'émerveillé. Une vaste nappe d'eau, le commencement d'un lac ou d'un océan, s'étendait au delà des limites de la vue. Le rivage, largement échancré, offrait aux dernières ondulations des vagues un sable fin, doré, parsemé de ces petits coquillages où vécurent les premiers êtres de la création. Les flots s'y brisaient avec ce murmure sonore particulier aux milieux clos et immenses. Une légère écume s'envolait au souffle d'un vent modéré, et quelques embruns m'arrivaient au visage. Sur cette grève légèrement inclinée, à cent toises environ de la lisière des vagues, venaient mourir les contreforts de rochers énormes qui montaient en s'évasant à une incommensurable hauteur. Quelques-uns, déchirant le rivage de leur arête aiguë, formaient des caps et des promontoires rongés par la dent du ressac. Plus loin, l'œil suivait leur masse nettement profilée sur les fonds brumeux de l'horizon. C'était un océan véritable, avec le contour capricieux des rivages terrestres, mais désert et d'un aspect effroyablement sauvage. Si mes

30. Cette section se fonde en partie sur un article publié en français : Jean Barré. « Détection automatique de l'architextualité dans le roman d'aventures (1870–1930). » *Humanistica 2024*. Association francophone des humanités numériques. Meknès, Maroc, 2024

> regards pouvaient se promener au loin sur cette mer, c'est qu'une lumière « spéciale » en éclairait les moindres détails. Non pas la lumière du soleil avec ses faisceaux éclatants et l'irradiation splendide de ses rayons, ni la lueur pâle et vague de l'astre des nuits, qui n'est qu'une réflexion sans chaleur. Non. Le pouvoir éclairant de cette lumière, sa diffusion tremblotante, sa blancheur claire et sèche, le peu d'élévation de sa température, son éclat supérieur en réalité à celui de la lune, accusaient évidemment une origine électrique. C'était comme une aurore boréale, un phénomène cosmique continu, qui remplissait cette caverne capable de contenir un océan [31].

Nous annotons ce genre de fragment comme *Exploration*. On y retrouve les marqueurs centraux de notre définition. Le passage s'ouvre sur une cécité provisoire (« je ne vis rien ») qui fonctionne comme un seuil perceptif : la vision, une fois recouvrée, produit un effet de révélation. L'affect du personnage est explicitement nommé (« stupéfait », « émerveillé ») et le paysage est construit comme un *spectacle* total, mobilisant plusieurs registres sensoriels : la vue (l'étendue de l'eau, les profils rocheux, la lumière), l'ouïe (le « murmure sonore » des flots), le toucher (les embruns au visage). L'accumulation de comparaisons avec le monde de la surface (« un océan véritable », « des rivages terrestres ») inscrit le lieu dans une logique de dépaysement radical, rappelons que l'intrigue se passe au centre de la terre. Enfin, la longue digression sur la lumière électrique relève d'un registre encyclopédique typique de Verne, où l'émerveillement se double d'une tentative de rationalisation scientifique. La scène d'exploration, ici, articule donc découverte sensorielle, affect d'émerveillement et discours savant, trois composantes que notre annotation cherche à capturer.

Danger : le combat naval dans *Kernok le pirate*. Le second exemple provient de *Kernok le pirate* (1830) d'Eugène Sue. Le corsaire Kernok, à bord de *L'Épervier*, engage un combat d'artillerie contre une corvette anglaise. Le passage se caractérise par une accélération brutale du rythme narratif :

> Car deux coups de canon en partirent presque au même instant, et les boulets hachèrent en quelques endroits le gréement de L'Épervier. La corvette ne riposta pas au boulet de Kernok, répara son avarie au plus vite, et laissa porter en plein sur le corsaire. Alors elle en était tellement près qu'on entendait la voix et le commandement des officiers anglais. – Enfants, à vos pièces, dit Kernok en se précipitant sur son banc de quart le porte-voix à la main ; à vos pièces, et, sacredieu ! ne faites pas feu avant le commandement. L'abordage !… l'abordage !… On se suspend au cordage, On s'élance des haubans. Maître Durand, il vient de se déclarer une voie d'eau dans la fosse aux lions. Maître Durand, ma tête, mon bras, tenez, voyez comme ça saigne ! Et le nom de maître Durand, le canonnier-chirurgien-charpentier du bord, retentissait depuis le pont jusqu'à la cale, dominant le bruit et le tumulte inséparables d'un combat aussi acharné que celui qui se livrait entre le brick et la corvette ; et, de fait, à chaque volée qu'il envoyait, L'Épervier tremblait et craquait dans sa membrure comme s'il eût été sur le point de s'entrouvrir [32].

31. Jules Verne. *Voyage au centre de la Terre*. Paris : Flammarion, 2014 [1864], p. 164–165.
32. Eugène Sue. *Kernok le pirate*. Paris : Gallimard, 1983 [1830], p. 85–86.

Les marqueurs de la scène de *Danger* sont d'un tout autre ordre que ceux de l'exploration. Le lexique martial et technique (« coups de canon », « boulets », « gréement », « membrure ») ancre le passage dans la matérialité violente du combat naval. Le rythme est fragmenté par la superposition des voix : les ordres de Kernok, les cris des blessés (« ma tête, mon bras, tenez, voyez comme ça saigne ! »). Le péril physique est à la fois collectif (le navire lui-même menace de se disloquer) et individuel, à travers les appels des blessés à maître Durand, ce personnage-pivot qui cumule à lui seul les fonctions de canonnier, chirurgien et charpentier, figure condensée de l'urgence totale.

Synthèse Ces deux exemples exemplifient la bipolarité du genre que nous voulons détecter. La scène d'exploration mobilise un registre descriptif et encyclopédique : accumulation de détails sensoriels, comparaisons savantes, posture contemplative du narrateur qui cherche à comprendre autant qu'à voir. La scène de danger mobilise un registre dramatique et polyphonique : fragmentation des voix, lexique de la destruction matérielle, accélération du tempo narratif. Dans les deux cas, le récit s'arrête sur un spectacle (un paysage souterrain ou un pont de navire sous le feu) mais l'affect qu'il produit est inverse : émerveillement d'un côté, effroi de l'autre. C'est cette alternance entre les deux pôles affectifs qui, selon notre hypothèse, constitue le rythme propre du roman d'aventures.

Notons enfin que ces deux passages proviennent d'auteurs et d'époques distincts (Verne en 1864, Sue en 1830) ce qui atteste d'une certaine stabilité des scénarios intertextuels à travers le temps. Si les marqueurs stylistiques diffèrent, la structure profonde des scènes, leur fonction narrative et leur régime affectif demeure reconnaissable. C'est précisément cette constance que notre annotation vise à capter, et que la phase de diffusion permettra de vérifier à grande échelle.

4.1.2 Annotation par modèle de langue

Nous avons utilisé une version compressée du modèle Mixtral-8x7B-Instruct-v0.1 [33] pour annoter nos scènes, dans un cadre d'apprentissage en *few-shot* (deux exemples fournis au modèle avant chaque annotation). Le choix de ce modèle se justifie par ses performances à l'état de l'art pour le français en avril 2024 et son caractère *open source*, qui garantit la reproductibilité de l'expérience.

Nous annotons des passages de 512 mots tirés aléatoirement dans le corpus. Une sélection manuelle des passages aurait introduit un biais de confirmation, en privilégiant les passages les plus « typiques » du genre. Le tirage aléatoire garantit que notre échantillon est représentatif de la distribution réelle de ces types de scènes dans le corpus.

Pour chaque passage de 512 mots, l'instruction suivante est donnée au modèle :

> La scène suivante doit être classée comme [EXPLORATION], [DANGER] ou [AUTRE].
> - [EXPLORATION] passage comportant la découverte d'un environnement nouveau, et des marqueurs d'écriture descriptive et encyclopédique : accumulation de toponymes, nomenclature savante, notations sensorielles détaillées, posture contemplative

33. Albert Q. Jiang, Alexandre Sablayrolles et al. *Mixtral of Experts*. 2024. arXiv : 2401.04088 [cs.LG].

du narrateur ou des protagonistes.
- [DANGER] passage caractérisé par une menace ou un péril pour les personnages, et par des marqueurs de tension narrative : phrases courtes, exclamations, accumulation de verbes d'action, discours direct fragmenté, interruptions.
- [AUTRE] pour les scènes ne correspondant ni à l'un ni à l'autre.
Sur la base du texte suivant, classez la scène suivante. La réponse ne doit comporter qu'un seul mot.

4.1.3 Analyse exploratoire des annotations

10 000 passages ont été annotés selon ce protocole. La distribution des labels est la suivante :

Label	Effectif	Pourcentage
Autre	8073	80.7%
Danger	1138	11.4%
Exploration	789	7.9%

TABLE 8.3 : Distribution des labels dans le corpus annoté.

La prédominance de la catégorie « Autre » (80%) est conforme à l'intuition que même dans un roman d'aventures, la majorité du texte est consacrée à des passages de transition, de dialogue, de réflexion ou d'exposition qui ne relèvent ni du danger ni de l'exploration au sens strict. Le ratio entre « Danger » (11%) et « Exploration » (8%) suggère que les scènes d'action violente sont légèrement plus fréquentes que les scènes de dépaysement contemplatif.

Une annotation manuelle sur 100 exemples permet d'évaluer la performance du modèle. Le kappa de Cohen (qui mesure l'accord inter-annotateurs en corrigeant l'effet du hasard) atteint 71%, soit un accord « substantiel » selon l'échelle de Landis et Koch [34]. Ce résultat nous a semblé suffisant pour mener à bien la phase de diffusion.

4.2 Diffusion par classification supervisée

L'étape de diffusion vise à généraliser les annotations sur un grand corpus de romans. Afin d'économiser le temps de calcul et d'inférencedes grands modèles de langue, nous avons entraîné un modèle statistique sur ces données synthétiques pour lui faire prédire sur le reste du corpus.

La représentation vectorielle des passages est obtenue par l'encodeur spécialisé de la thèse présenté au chapitre 4.

Pour la classification automatique, nous utilisons une machine à vecteurs de support (SVM) [35] avec un noyau RBF, implémentée dans Scikit-learn [36]. Le choix du SVM se justifie par ses bonnes performances sur les données textuelles et par la possibilité de récupérer les probabilités associées à chaque prédiction, ce qui est précieux pour l'analyse fine des résultats.

34. J. Richard LANDIS et Gary G. KOCH. « The Measurement of Observer Agreement for Categorical Data ». *Biometrics* 1977, p. 159-174.
35. CORTES et VAPNIK, op. cit.
36. PEDREGOSA, VAROQUAUX et al., op. cit.

	Précision	Rappel	F1
Danger	0.77	0.80	0.78
Exploration	0.72	0.74	0.73
Autre	0.71	0.65	0.68

TABLE 8.4 : Évaluation du modèle SVM en validation croisée (k=5).

Le modèle atteint une exactitude globale de 73%, bien supérieure à la baseline aléatoire de 33% (les classes étant équilibrées à 789 exemples chacune pour l'entraînement). Les performances sont légèrement meilleures pour la classe « Danger » (F1 = 0.78) que pour « Exploration » (F1 = 0.73), ce qui suggère que les marqueurs textuels du danger sont plus saillants et moins ambigus que ceux de l'exploration.

5 Analyse multiscalaire

Cette section propose une triple analyse de la diffusion du modèle entraîné, de la lecture proche à la lecture distante. L'objectif est de comprendre si notre opérationnalisation minimale de l'architextualité du roman d'aventures permet bien de détecter des scènes spécifiques au sous-genre, tout en constatant leur porosité dans l'ensemble de la fiction romanesque.

5.1 Échelle du roman : lecture proche

5.1.1 Vingt mille lieues sous les mers : un cas prototypique

Le premier exemple est celui d'un des romans d'aventures les plus célèbres de la sphère francophone : *Vingt mille lieues sous les mers* de Jules Verne (1869). La figure 8.8 présente la distribution des scènes d'« Exploration » au fil du récit.

Le résultat est saisissant : plus de 75% des passages du roman ont une probabilité supérieure à 0.5 d'être classés comme scènes d'exploration. Cette persistance du scénario intertextuel de l'exploration est caractéristique de l'œuvre vernienne, qui fait du voyage sous-marin le prétexte d'une encyclopédie des merveilles océaniques.

Examinons un passage caractéristique, classé avec une probabilité de 87% comme « Exploration » :

> J'observais que l'eau de la mer Rouge devenait de moins en moins salée, à mesure que nous approchions de Suez. **Le Nautilus pénétra dans le détroit de Jubal, qui conduit au golfe de Suez. J'aperçus distinctement une haute montagne, dominant entre les deux golfes le Ras-Mohammed. C'était le mont Oreb, ce Sinaï**, au sommet duquel Moïse vit Dieu face à face, et que l'esprit se figure incessamment couronné d'éclairs. À six heures, le Nautilus, tantôt flottant, tantôt immergé, passait au large de Tor, assise au fond d'une baie dont les eaux paraissaient teintées de rouge, observation déjà faite par le capitaine Nemo. Puis la nuit se fit, au milieu d'un lourd silence que rompaient parfois le cri du pélican et de quelques

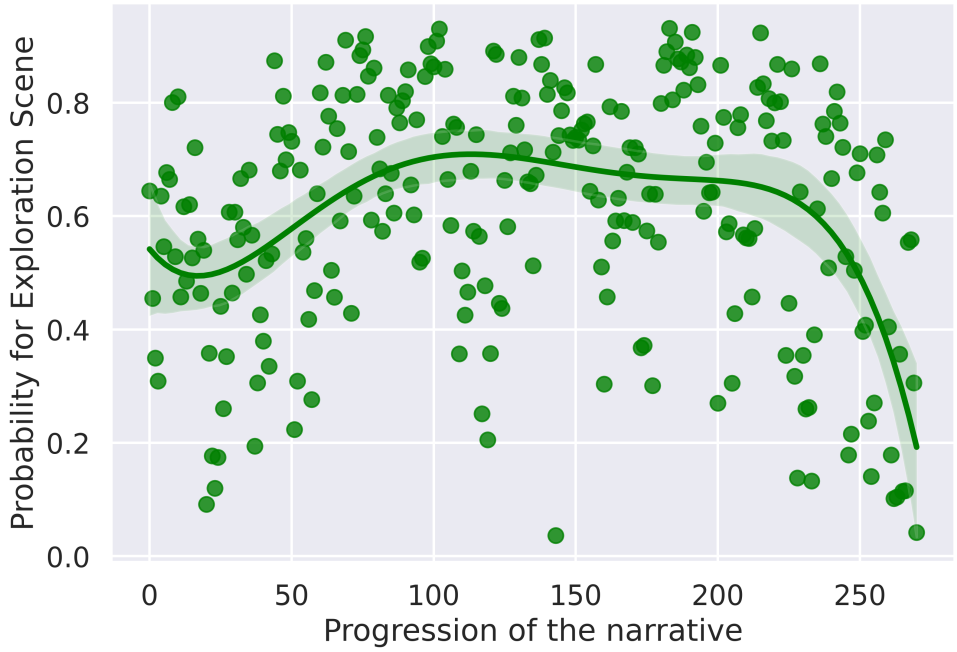


FIGURE 8.8 : Probabilité d'appartenance à la classe « Exploration » pour chaque passage de *Vingt mille lieues sous les mers*. L'abscisse représente la progression dans le récit, l'ordonnée la probabilité assignée par le modèle.

> oiseaux de nuit, le bruit du ressac irrité par les rocs ou le gémissement lointain d'un steamer battant les eaux du golfe de ses pales sonores[37].

Ce passage exhibe tous les marqueurs de la scène d'exploration telle que nous l'avons définie. L'accumulation toponymique (mer Rouge, Suez, détroit de Jubal, Ras-Mohammed, mont Oreb, Sinaï, Tor) produit un effet de dépaysement géographique. La nomenclature exotique (pélican, oiseaux de nuit) et les notations sensorielles (eaux teintées de rouge, lourd silence, cri, bruit, gémissement) construisent une atmosphère propre à l'exploration. Enfin, la référence culturelle (Moïse, les éclairs) inscrit le voyage dans une dimension mythique qui amplifie le dépaysement.

Qu'en est-il des scènes de danger ? La figure 8.9 montre que ces scènes sont beaucoup plus sporadiques, avec des pics localisés et une nette augmentation à la fin du récit.

La dernière scène du récit de Verne, l'épisode du Maelstrom, constitue le climax du récit et un exemple paradigmatique de scène de danger (p Danger = 83%) :

> **« Maelstrom ! Maelstrom ! » s'écriait-il. Le Maelstrom ! Un nom plus effrayant dans une situation plus effrayante pouvait-il retentir à notre oreille ?** […] Le Nautilus décrivait une spirale dont le rayon diminuait de plus en plus. Nous étions dans l'épouvante, dans l'horreur portée à son comble, la circulation suspendue, l'influence nerveuse annihilée, traversés de sueurs froides comme les sueurs de l'agonie ! Et quel bruit autour de notre frêle canot ! […] Le Nautilus se défendait comme un être humain. Ses muscles d'acier craquaient. Parfois il se dressait, et nous avec lui ! « Il faut tenir bon, dit Ned, et revisser les écrous ! » Il n'avait pas achevé de parler, qu'un

37. Jules VERNE. *Vingt mille lieues sous les mers*. Paris : 10/18, 2024 [1869], p. 324.

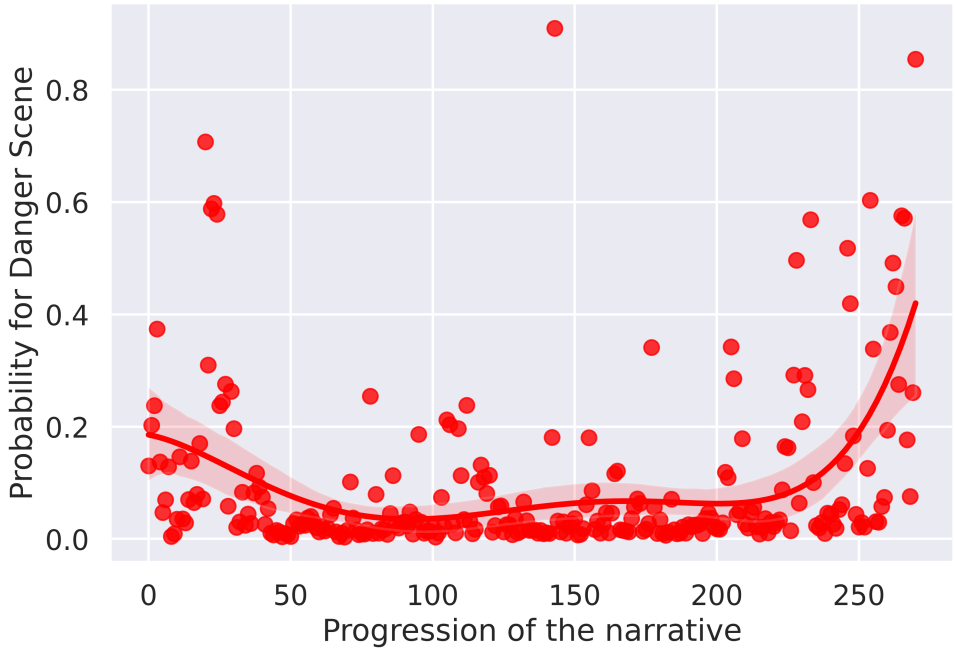


FIGURE 8.9 : Probabilité d'appartenance à la classe « Danger » pour chaque passage de *Vingt mille lieues sous les mers*.

> craquement se produisait. Les écrous manquaient, et le canot, arraché de son alvéole, était lancé comme la pierre d'une fronde au milieu du tourbillon. **Ma tête porta sur une membrure de fer, et, sous ce choc violent, je perdis connaissance.** [38]

Le lexique de la terreur (effrayant, épouvante, horreur, agonie), l'isotopie corporelle de la violence (sueurs froides, circulation suspendue, tête porta, choc violent), la dramatisation typographique (exclamations, répétitions) et la perte de conscience finale constituent autant de marqueurs caractéristiques de la scène de danger.

Vingt mille lieues sous les mers présente un déséquilibre entre les deux types de scènes. L'exploration y est omniprésente, quasiment continue. Le danger n'y survient que par moments, dans des pics localisés. Cela suggère une première hypothèse : la signature générique du roman d'aventures ne serait pas un ratio fixe entre exploration et danger, mais plutôt un *schéma d'enchaînement* où l'un des deux scénarios peut dominer, pourvu que l'autre intervienne de manière récurrente afin de garder cette persistance aventureuse.

5.1.2 L'Éducation sentimentale : un contre-exemple instructif

Pour valider notre approche, nous avons pris un contre-exemple au roman d'aventures : *L'Éducation sentimentale* de Gustave Flaubert (1869). Dans ce roman, plus de 90% des passages sont annotés comme « Autre ».

La figure 8.10 montre néanmoins trois moments où le modèle détecte des scènes de danger : le duel entre Frédéric Moreau et le vicomte Cisy, et deux épisodes dans le Paris révolutionnaire de 1848.

38. Ibid., p. 547–548.

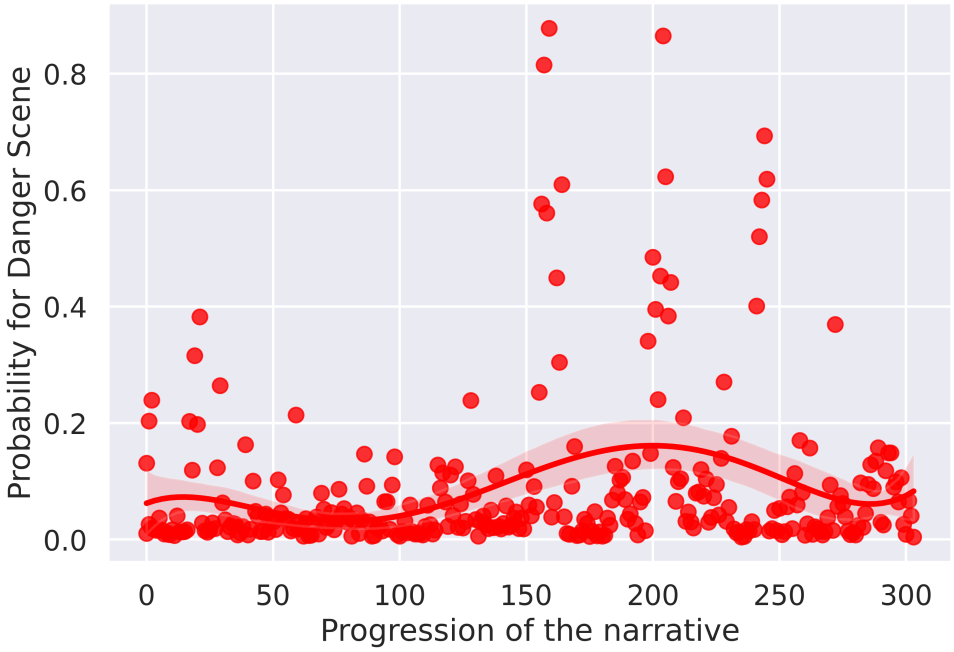


FIGURE 8.10 : Probabilité d'appartenance à la classe « Danger » dans *L'Éducation sentimentale*.

Examinons le passage du duel, classé à 88% comme « Danger » :

> Les adversaires étaient l'un devant l'autre, leurs témoins de chaque côté. **Il cria le signal : – Allons ! Cisy devint effroyablement pâle. Sa lame tremblait par le bout, comme une cravache. Sa tête se renversait, ses bras s'écartèrent, il tomba sur le dos, évanoui.** Joseph le releva ; et, tout en lui poussant sous les narines un flacon, il le secouait fortement. Le vicomte rouvrit les yeux, puis tout à coup, bondit comme un furieux sur son épée. Frédéric avait gardé la sienne ; et il l'attendait, l'œil fixe, la main haute. – Arrêtez, arrêtez ! cria une voix qui venait de la route, en même temps que le bruit d'un cheval au galop ; et la capote d'un cabriolet cassait les branches ! Un homme penché en dehors agitait un mouchoir, et criait toujours : « Arrêtez, arrêtez ! » [39]

Le modèle détecte correctement les marqueurs de la scène de danger : la tension dramatique (signal, lame tremblante), les manifestations corporelles de la peur (effroyablement pâle, tomba évanoui), le vocabulaire du combat (épée, bondit comme un furieux).

Mais le modèle ne détecte pas l'ironie flaubertienne. Le duel, loin d'être un affrontement héroïque, tourne au grotesque : Cisy, qui est vicomte, s'évanouit avant le premier assaut, puis « bondit comme un furieux » dans un sursaut dont le ridicule tient à l'écart entre la prétention aristocratique du geste et la médiocrité du personnage. Le danger, pourtant, n'est pas fictif, les deux jeunes gens ont légitimement peur, et leur inexpérience ne les protège pas de la blessure. Ce que Flaubert subvertit, ce n'est donc pas la matière de la scène, mais la stature que les personnages et le lecteur voudraient lui donner : la tentative de hausser une rivalité médiocre au

39. Gustave FLAUBERT. *L'Éducation sentimentale*. Sous la dir. de Pierre-Marc de BIASI. Paris : Librairie Générale Française, 2018, p. 349.

rang de l'affrontement romanesque échoue, et c'est cet échec même que met en scène l'ironie du récit.

Cette observation nous conduit à une distinction conceptuelle importante puisque notre modèle détecte ce que l'on pourrait appeler la surface thématique du genre : les éléments lexicaux, les configurations actantielles, les schémas narratifs qui constituent la « matière » du roman d'aventures. Mais il ne peut pas saisir la modalisation de cette matière : l'attitude énonciative de l'auteur vis-à-vis de ce qu'il raconte, le degré de sérieux ou d'ironie avec lequel les conventions génériques sont convoquées.

En termes bakhtiniens, on pourrait dire que notre modèle repère le contenu référentiel de l'énoncé, mais non son aspect expressif, c'est-à-dire « l'évaluation émotionnelle subjective du contenu référentiel de l'énoncé par le locuteur » [40]. Or, comme le rappelle Bakhtine, les mots en eux-mêmes « n'évaluent rien » et « peuvent servir aux évaluations les plus variées et les plus directement contradictoires » [41]. Autrement dit, un même matériau lexical du danger peut, selon le contexte énonciatif, recevoir une inflexion ironique comme chez Flaubert. Notre modèle détecte donc la disponibilité de certains scénarios intertextuels dans un texte, mais reste aveugle à leur modalisation. Cette limite n'invalide pas la méthode pour l'étude des littératures sérielles, dont les auteurs jouent le jeu des conventions plutôt qu'ils ne les subvertissent.

5.1.3 Synthèse : persistance comme marqueur du genre

La comparaison entre Verne et Flaubert suggère que la spécificité du roman d'aventures ne réside pas dans la présence ponctuelle de scènes de danger ou d'exploration, car de telles scènes peuvent apparaître dans n'importe quel roman, mais dans leur persistance latente tout au long du récit.

Dans *Vingt mille lieues sous les mers*, le scénario de l'exploration est quasi continu, formant une basse continue sur laquelle viennent se détacher les pics de danger. Dans *L'Éducation sentimentale*, les scènes de danger sont des « événements » isolés, sans continuité ni récurrence : elles ne constituent pas une dominante générique, mais des irruptions ponctuelles d'un registre étranger au roman.

5.2 Échelle des sous-genres : lecture distante

Dans la suite de l'analyse, les résultats sont diffusés sur une sélection de 40 000 passages du corpus *Chapitres* [42]. L'objectif est de constater, dans les autres sous-genres romanesques, la présence de passages d'« Exploration » ou de « Danger ».

Les étiquettes de sous-genres proviennent du même corpus, qui utilise la classification de chercheurs en littérature. Nous avons concentré notre analyse sur les dix sous-genres les plus représentés : roman d'aventures, roman sentimental, policier, littérature jeunesse, mémoires et autobiographies, fantastique, roman historique, roman de voyage, science-fiction et roman érotique.

40. Bakhtine, « The Problem of Speech Genres », p. 84.
41. Ibid., p. 85.
42. Leblond, *Corpus Chapitres*.

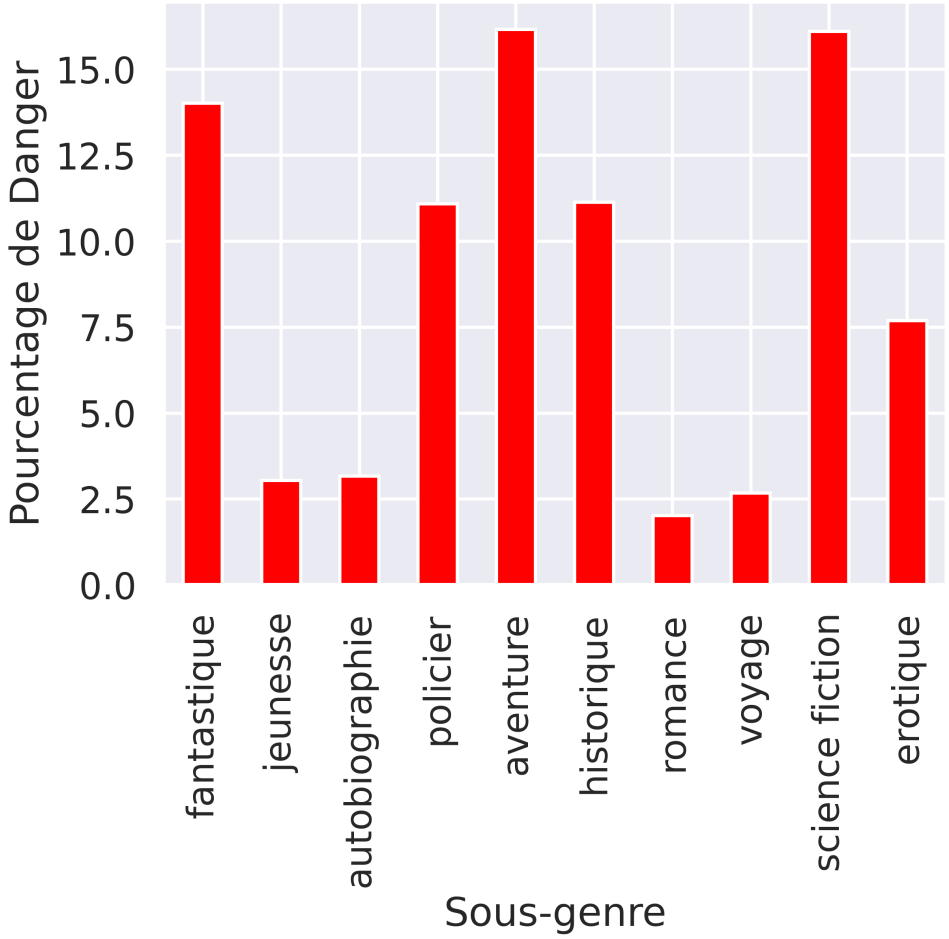


FIGURE 8.11 : Pourcentage de scènes de « Danger » par sous-genre.

La figure 8.11 montre le pourcentage de scènes de « Danger » dans chaque sous-genre. Le roman d'aventures est celui qui en contient le plus (16.2%), mais il est suivi de très près par la science-fiction (16.1%) et le fantastique (14%).

Cette proximité confirme ce que Letourneux appelle le caractère d'« hypergenre » du roman d'aventures [43] : ses traits définitoires (action violente, dépaysement) sont suffisamment généraux pour se retrouver dans des genres qui lui sont apparentés. La science-fiction et le fantastique partagent avec le roman d'aventures cette économie de la *mésaventure*, même si le cadre référentiel diffère. Le cas de la science-fiction est particulièrement éclairant : le *space opera*, qui se développe précisément au moment où la planète est entièrement quadrillée par l'exploration et l'entreprise coloniale, transpose dans l'espace interstellaire les structures mêmes du roman d'aventures géographiques. L'espace y tient le rôle de la mer, le vaisseau reste un vaisseau, la planète inconnue fonctionne comme la jungle ou le désert, et les extraterrestres occupent la place des peuplades exotiques. Loin d'une simple analogie, cette migration des motifs suggère que le roman d'aventures, une fois épuisé son terrain référentiel terrestre, a trouvé dans la science-fiction un prolongement qui en reconduit les scénarios fondamentaux sous un nouvel habillage intersidéral, ce qui pourrait

43. LETOURNEUX, op. cit., p. 176.

expliquer que nos détecteurs de scènes de danger y trouvent une fréquence presque identique.

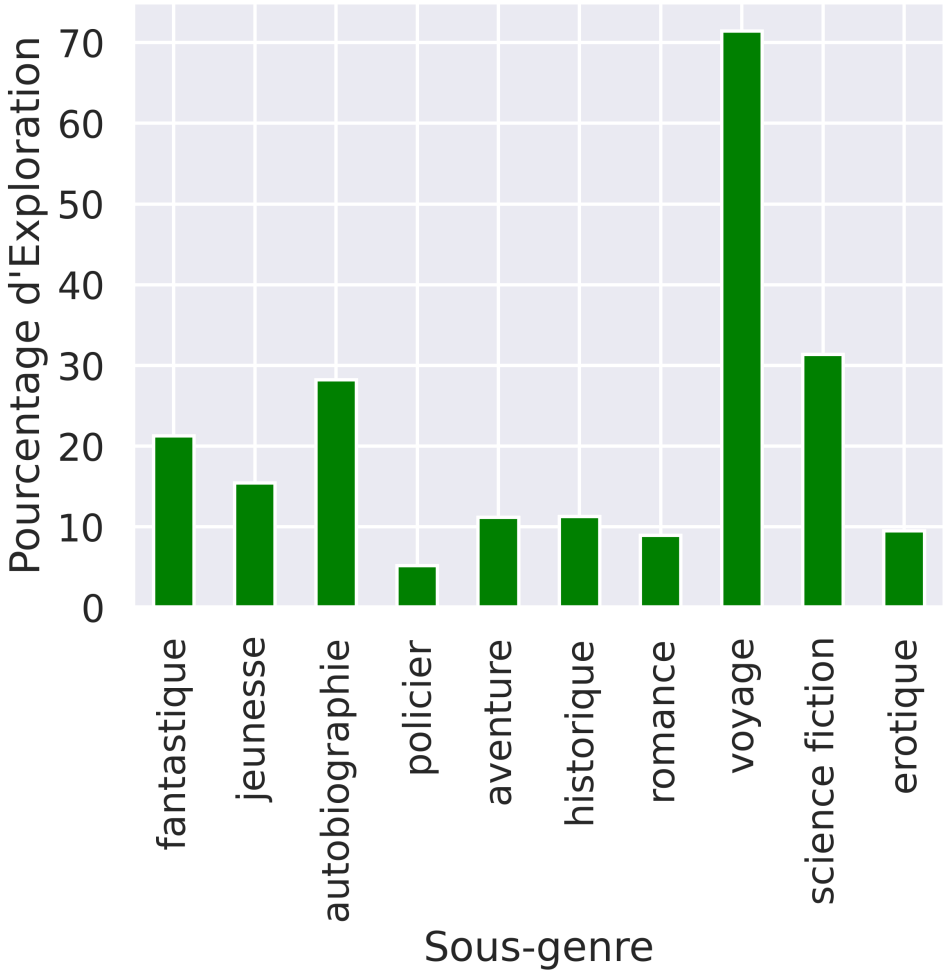


FIGURE 8.12 : Pourcentage de scènes d'« Exploration » par sous-genre.

La figure 8.12 présente des résultats plus contrastés pour les scènes d'« Exploration ». Le roman d'aventures n'en contient que 11.2%, tandis que le sous-genre des récits de voyage en compte plus de 70%.

Ce résultat confirme que notre définition de l'« Exploration » était sans doute trop large, privilégiant la description de paysages exotiques au détriment de l'agentivité des personnages. Le récit de voyage, qui fait de la description contemplative son mode principal, capture ainsi la majeure partie des scènes d'exploration, alors même qu'il ne partage pas avec le roman d'aventures l'économie de l'action violente.

Ensuite, ce résultat met en évidence la porosité des frontières génériques. Les scènes d'exploration ne sont pas spécifiques au roman d'aventures : elles circulent entre les genres, se retrouvant aussi bien dans l'autobiographie (28.2%) que dans la science-fiction (33.4%). L'architextualité, au sens de Genette, déborde le cadre du sous-genre pour embrasser des similarités thématiques transversales.

5.3 Échelle du corpus : diachronie

Enfin, la diffusion à grande échelle permet de discuter de la présence de ces scènes sur le temps long, au fil du corpus *Chapitres* (2960 romans écrits entre 1811 et 2020). La figure 8.13 présente la proportion des passages d'« Exploration » agrégés par année sur deux siècles de fiction. Ces derniers augmentent au cours du temps, passant de 10% des passages au début du XIXe siècle à près de 30% au début du XXIe siècle.

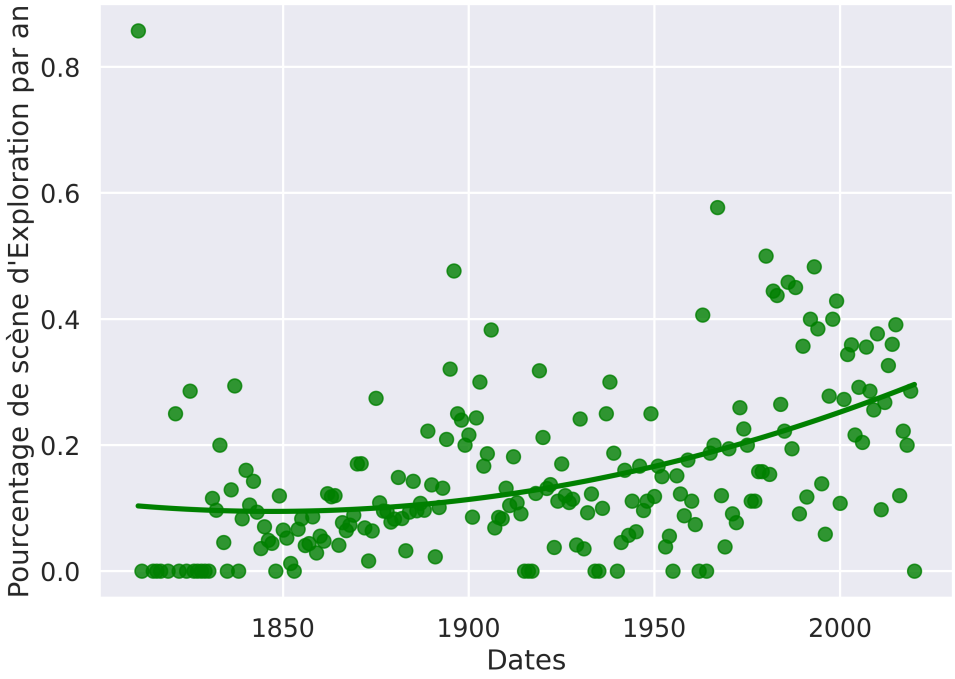


FIGURE 8.13 : Proportion de scènes d'« Exploration » dans l'ensemble du corpus, agrégée par année.

Cette tendance peut s'expliquer par plusieurs facteurs. Le premier est la répartition temporelle des sous-genres dans le corpus. Le genre du récit de voyage, principal moteur de ces passages d'« Exploration », se distribue autour des années 1900, ce qui correspond à une hausse visible sur les points de la courbe. L'affirmation de l'autobiographie et de la science-fiction dans la seconde moitié du XXe siècle pourrait également contribuer à cette augmentation, bien que ces deux sous-genres ne représentent qu'une partie minoritaire du corpus.

Le second facteur relève de l'histoire culturelle. Comme l'a montré Anne-Gaëlle Weber [44], le récit de voyage a connu un moment de mode à la fin du XVIIIe siècle, où il a influencé les critères même de définition de la littérature. L'augmentation que nous observons à la fin du XXe siècle pourrait être une réactualisation de ce phénomène, dans le contexte d'une mondialisation qui rend l'ailleurs à la fois plus accessible et plus désirable.

La figure 8.14 montre le comportement des scènes de « Danger » au fil du corpus. On observe une grande stabilité de la répartition de ces scènes, autour de 10% des passages tout au long de

44. Anne-Gaëlle WEBER. « Le récit de voyage et l'émergence de la littérature au tournant des xviiie et xixe siècles ». *Viatica* 2020. DOI : 10.52497/viatica1265.

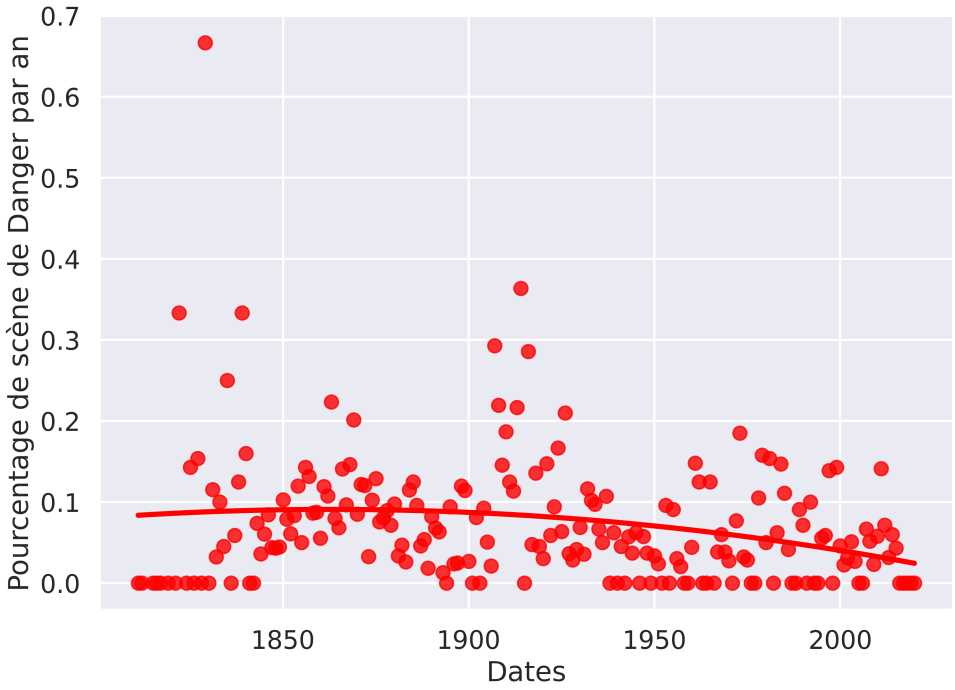


FIGURE 8.14 : Proportion de scènes de « Danger » dans l'ensemble du corpus, agrégée par année.

la période, avec une augmentation notable durant la Première Guerre mondiale. Cette stabilité suggère que la présence du danger dans la fiction romanesque est une constante structurelle, indépendante des évolutions génériques : le roman, quel que soit son sous-genre, a besoin du péril comme ressort dramatique.

6 Discussion

6.1 Complémentarité des approches

L'expérience de constitution du corpus met en évidence la complémentarité des approches supervisée et non supervisée pour la délimitation d'un genre littéraire. L'approche supervisée fournit une première approximation efficace, mais le SVM sur-généralise sur des mots lexicaux de surface : la présence de mots comme *aventure*, *voyage*, *nègre* ou *coquin* suffit à déclencher une classification positive, même lorsque le texte est une parodie, un guide pratique ou un roman d'avant-garde. Symétriquement, le SVM sous-performe sur certains auteurs ou sous-genres dont le profil stylistique s'écarte du prototype appris : des Verne tardifs, des *westerns* de Mayne Reid, des récits maritimes du capitaine Marryat.

L'approche non supervisée corrige ces erreurs en exploitant une information d'un autre ordre, celle de la structure de l'espace vectoriel. Un roman n'est plus évalué isolément, en fonction de ses mots intrinsèques, mais en fonction de son voisinage, de sa position dans le réseau des similarités textuelles. Cette logique relationnelle est précisément celle de la ressemblance de famille : un texte appartient à un genre parce qu'il partage avec d'autres textes du genre un nombre suffisant de similarité.

6.2 Le genre entre regroupement et circulation

Les deux échelles d'analyse produisent un résultat apparemment paradoxal qu'il convient de synthétiser avant d'en discuter les implications.

À l'échelle du corpus, la combinaison d'une classification supervisée et d'une correction par graphe k-NN a permis de constituer un ensemble de 1 391 romans d'aventures au sein des *Fictions Littéraires de Gallica*. La correction non supervisée a identifié 113 faux positifs et 129 faux négatifs, améliorant la cohérence intra-genre (+3.6% de similarité moyenne) et l'homogénéité du corpus (−18.4% d'écart-type). La distribution temporelle du corpus corrigé converge avec la périodisation de Letourneux, confirmant la validité historique de la délimitation obtenue. Le roman d'aventures forme donc bien un agrégat identifiable dans l'espace vectoriel : les textes qui en relèvent se ressemblent davantage entre eux que ne le font des romans pris au hasard.

À l'échelle du passage, cependant, les scènes constitutives du genre ne lui sont pas exclusives : elles circulent au-delà de ses frontières. Les scènes de danger et d'exploration se retrouvent dans la science-fiction, le fantastique ou le récit de voyage, témoignant de la porosité de l'architexte. Ce qui distingue le roman d'aventures des genres apparentés, ce n'est pas la présence de ces scènes, mais leur *persistance* tout au long du récit. Dans *Vingt mille lieues sous les mers*, le scénario de l'exploration forme une basse continue sur laquelle viennent se détacher les pics de danger. Dans *L'Éducation sentimentale*, les scènes de danger ne sont que des irruptions ponctuelles, sans continuité ni récurrence.

6.3 Limites et perspectives

Notre approche présente plusieurs limites, avec d'abord notre définition des scènes stéréotypiques qui reste somme toute minimale. Le roman d'aventures comporte bien d'autres scénarios intertextuels (la poursuite, le duel, la capture, l'évasion, …) que notre schéma d'annotation, limité à deux catégories, ne distingue pas. Rien dans la méthode n'empêcherait de les détecter : une extension du schéma d'annotation, avec un corpus d'exemples suffisant pour chaque nouveau label, permettrait d'affiner considérablement l'analyse et de tester si ces scénarios plus spécifiques se distribuent différemment selon les sous-genres.

Ensuite, comme nous l'avons vu avec le cas Flaubert et avec les parodies retirées lors de la correction du corpus, notre modèle détecte la matière du genre mais pas sa modalisation. Il ne peut pas distinguer un emploi sincère des conventions génériques d'un emploi ironique ou subversif. Cette limite est constitutive de toute approche fondée sur le lexique et les embeddings de paragraphes. Elle n'invalide cependant pas la méthode pour l'étude des littératures sérielles, dont les auteurs s'inscrivent pleinement dans ces conventions plutôt qu'ils ne les subvertissent.

Enfin, et c'est sans doute la limite la plus importante, nous n'avons pas testé formellement l'hypothèse de l'enchaînement des scènes comme signature du genre. Les graphiques de la section 5 montrent la distribution des scènes au fil du récit, et la comparaison entre Verne et Flaubert rend l'hypothèse de la persistance très plausible. Mais nous n'avons pas modélisé les transitions entre types de scènes. Or, c'est précisément dans ces transitions (danger suivi d'exploration, exploration interrompue par le danger) que pourrait résider la signature la plus fine du genre. Une analyse des

séquences de labels, par exemple au moyen de matrices de transition ou de modèles markoviens, permettrait de caractériser non seulement la proportion de chaque type de scène, mais le rythme de leur alternance. Cette perspective nous semble constituer le prolongement naturel du présent chapitre : si la persistance des scénarios intertextuels distingue le roman d'aventures des genres non-aventureux, c'est peut-être le pattern de succession qui le distinguerait des genres apparentés (la science-fiction, le fantastique, le récit de voyage) avec lesquels il partage les mêmes briques élémentaires.

Annexe

Considérations méthodologiques

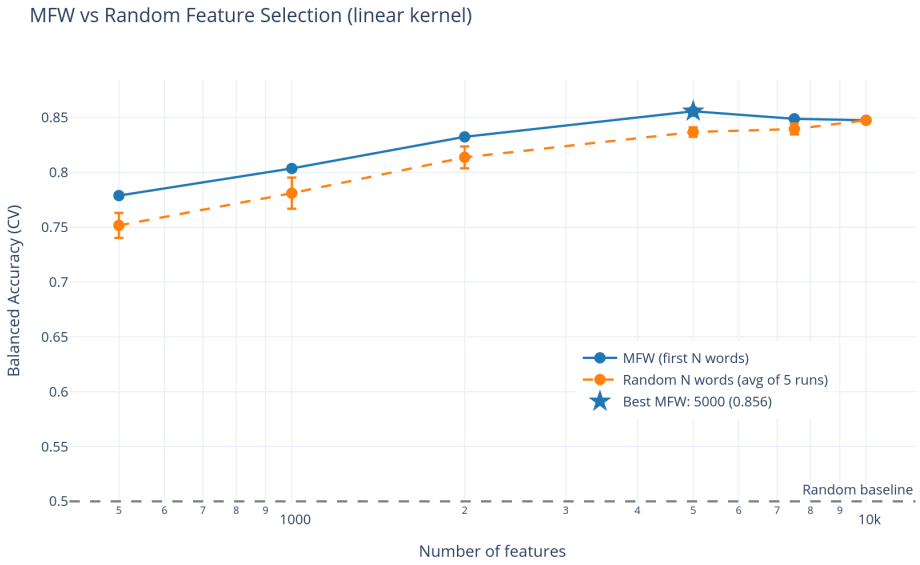


FIGURE 8.15 : Exactitude équilibrée (*balanced accuracy*) du SVM en fonction du nombre de mots (MFW ou sélection aléatoire). Les MFW surpassent systématiquement la sélection aléatoire. L'optimum est atteint à 5 000 MFW (85.6%).

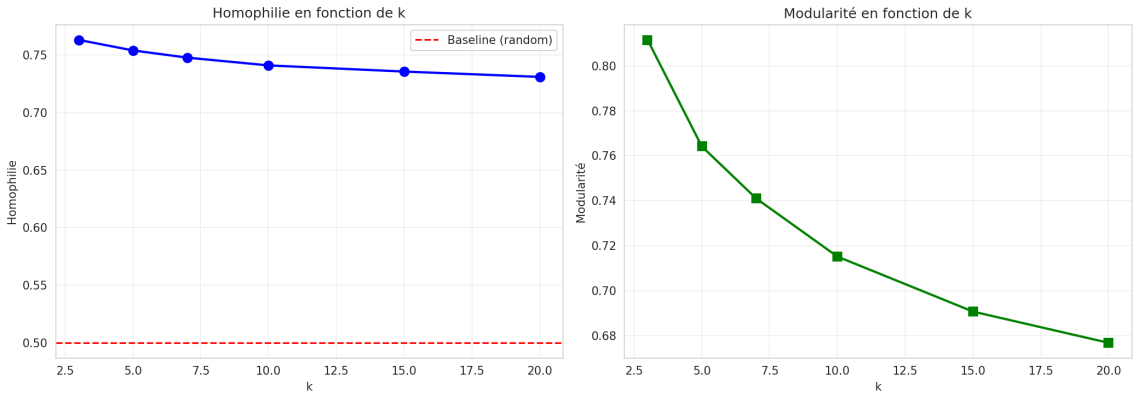


FIGURE 8.16 : Sensibilité des métriques du graphe au paramètre k. À gauche : l'homophilie reste stable et bien supérieure à la baseline aléatoire (0.5) pour toutes les valeurs de k testées. À droite : la modularité décroît à mesure que le graphe se densifie, mais demeure élevée, confirmant la robustesse de la structure de clustering.

Chapitre 9

Du feuilleton aux collections : la naissance de la littérature de genre

Objectifs

Ce chapitre s'intéresse à la relation entre reconnaissance contextuelle et normalisation formelle des genres littéraires. En comparant l'évolution du roman policier et du roman d'aventures avant et après leur cristallisation terminologique respective, nous testons l'hypothèse d'une contraction de la diversité narrative post-reconnaissance. Nous utilisons des représentations vectorielles de passages extraits de deux corpus de genre (830 romans policiers, 1 391 romans d'aventures) et de leurs témoins respectifs pour quantifier l'espace des possibles discursifs. Les résultats montrent une contraction significative de la diversité dans le roman policier post-1930, tandis que le roman d'aventures post-1920 présente une trajectoire différente. Ces résultats suggèrent que la reconnaissance contextuelle peut s'accompagner d'une normalisation formelle.

Sommaire

1 Introduction . . . **225**
1.1 De la dominante générique à la normalisation des genres . . . 225
1.2 La collection éditoriale comme dispositif normalisateur . . . 227
1.3 Deux régimes de codification . . . 228
1.4 Poids des contextes sur le texte . . . 230
1.5 Enjeux de recherche . . . 231
2 Méthode . . . **231**
2.1 Corpus . . . 231
2.2 Construction des modes discursifs . . . 232
2.3 Métriques . . . 237
2.4 Protection contre les artefacts d'échantillonnage . . . 238
2.5 Inférence statistique . . . 239
3 Résultats : le roman policier . . . **239**
3.1 Contraction de la diversité discursive . . . 239
3.2 Stabilité du centroïde . . . 240
3.3 Estimation en différences de différences . . . 241
3.4 Test de robustesse : l'effet Simenon . . . 241

3.5 Analyse qualitative : ce que le genre a perdu et gagné . . . 242
4 Résultats : le roman d'aventures . . . **246**
4.1 Évolution de la diversité discursive . . . 246
4.2 Dérive du centroïde : le genre se déplace . . . 247
4.3 Estimation en différences de différences . . . 247
4.4 Analyse qualitative : ce que le genre perd et ce qui lui survit . . . 248
5 Discussion . . . **250**
5.1 Deux logiques de normalisation . . . 250
5.2 La mort du feuilleton . . . 251
5.3 Limites . . . 252

> In fact, even the nineteenth-century novel was repetitive. Its fundamental patterns were always the same, and it was not so difficult, for a smart reader, to tell before the end of the story if Miss So-and-So was or was not the lost daughter of the duke of X. One can only say that the nineteenth-century feuilleton and contemporary mass media use different devices for making the expected appear unexpected.
>
> *Eco, « Innovation and Repetition », p. 13*

> Mais en réalité, le roman du XIXe siècle aussi était répétitif. Ses structures fondamentales restaient toujours les mêmes et il n'était guère difficile au lecteur averti de savoir avant la fin de l'histoire si mademoiselle Untel était ou non la fille disparue du Duc de X. Tout ce qu'on peut dire, c'est que le feuilleton du XIXe siècle et les mass media contemporains recourent à des procédés différents pour donner au prévu l'apparence de l'inattendu.
>
> *ibid., p. 13*

1 Introduction

1.1 De la dominante générique à la normalisation des genres

Le chapitre précédent a proposé une étude du roman d'aventures à travers la détection de scènes stéréotypiques. Les résultats ont montré que la signature du genre réside moins dans la présence ponctuelle de certains contenus que dans leur persistance tout au long du récit. Cette approche par les scénarios intertextuels a permis de constater à la fois la spécificité relative du roman d'aventures et la porosité de ses frontières avec les genres apparentés.

Le présent chapitre propose de changer de focale. Plutôt que de chercher ce qui caractérise un genre à un moment donné, nous nous interrogeons sur ce qui advient à un genre lorsqu'il se constitue en catégorie reconnue du champ littéraire. L'hypothèse centrale est que la reconnaissance institutionnelle d'un genre, c'est-à-dire l'avènement médiatique du terme et son inscription dans des collections éditoriales dédiées s'accompagne d'une normalisation de sa production, soit d'une réduction de l'espace des possibles discursifs au sein du genre. Une observation empirique simple en figure 9.1 est à l'origine de cette hypothèse. La figure présente l'évolution de la fréquence des expressions « roman policier » et « roman d'aventures » dans la presse française entre 1860 et 1940, telle que mesurée dans le corpus de presse française de la BNF, Gallica, utilisé par Gallicagram [1].

Le graphique montre pour les deux termes le même phénomène d'explosion médiatique, après la première guerre mondiale pour le « roman d'aventures », à la toute fin des années 20, et au début des années 30 pour le « roman policier ». Les deux courbes présentent cependant des trajectoires de gestation différentes : le « roman d'aventures » croît progressivement dès les années

1. Courson et Azoulay, « Gallicagram : un outil de lexicométrie pour la recherche ».

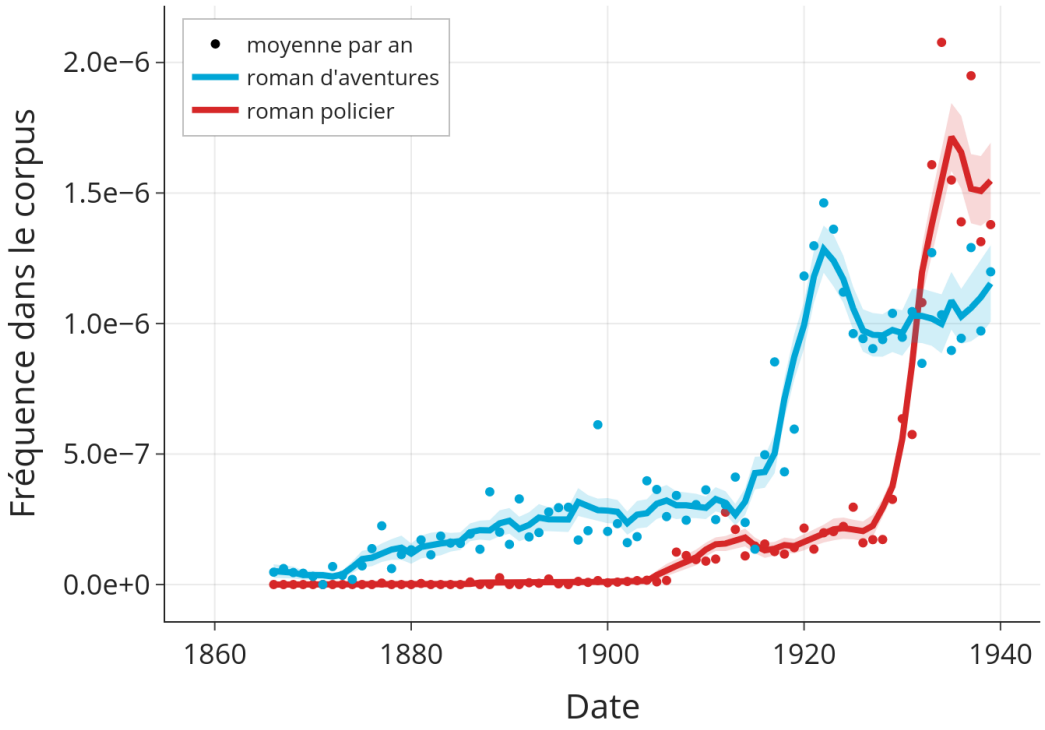


FIGURE 9.1 : Fréquence des expressions « roman policier » (rouge) et « roman d'aventures » (bleu) dans la presse française, 1860–1940. Source des points de données : Gallicagram.

1860 (60 ans de gestation), tandis que le « roman policier » demeure absent jusqu'en 1905 avant de connaître un décollage timide (25 ans de gestation). Il y a un croisement vers 1932, moment où le roman policier devient la catégorie générique dominante dans le discours médiatique. Cette différence de durée de gestation pourrait expliquer des différences dans la normalisation formelle que nous voulons étudier.

Ces trajectoires divergentes reflètent deux processus distincts de « cristallisation terminologique » [2]. Le roman d'aventures bénéficie d'une continuité sémantique : le mot « aventure » porte depuis le Moyen Âge [3] les caractéristiques du genre. La dénomination du genre est donc ancienne et bénéficie d'une construction par sédimentation progressive. L'explosion médiatique du genre est cependant assez compliquée à déterminer, et elle n'est en tout cas pas liée à un biais du corpus de journaux de Gallicagram, puisque leur répartition est plus importante avant la première guerre mondiale qu'après et que la production de journaux va mettre environ 5 ans à reprendre son niveau d'avant guerre.

Le cas du roman policier est en revanche différent. Avant les années 1920, le genre existe mais sous d'autres appellations. Dès 1929, Régis Messac dans sa thèse sur *Le Detective Novel et l'influence de la pensée scientifique* [4], recense cette dispersion terminologique : « roman judiciaire »,

2. LETOURNEUX, op. cit., p. 31.
3. Chrétien de Troyes parle « d'un conte d'avanture » dans le prologue d' *Érec et Énide*, son premier roman arthurien écrit vers 1160-1170
4. MESSAC, *Le "Detective Novel" et l'influence de la pensée scientifique*, p. 7, p. 395–396.

« roman criminel », « roman détective ». La rupture terminologique du roman policier est portée par des collections éditoriales clairement identifiées, au premier rang desquelles Le Masque (1927), et ses concurrentes, notamment *L'Empreinte* (1932) et *Police et Mystère* (1932), qui importent le *detective novel* anglo-saxon en France, avec la traduction entre autres de Conan Doyle, Agatha Christie, ou encore Valentin Williams. Le décollage brutal de la courbe à cette période n'est donc pas surprenant, malgré les débuts difficiles de la collection [5].

Dans les deux cas, la dénomination médiatique d'un genre est loin d'être anodine d'un point de vue des pratiques d'écriture dans le genre. Elle permet à tous les acteurs du champ littéraire (de l'auteur au lecteur, en passant par l'éditeur), d'arrêter des attentes spécifiques d'un architexte naissant.

> Sans tomber dans les excès du nominalisme, on doit convenir qu'un genre n'existe réellement qu'à partir du moment où il est associé à un terme qui le circonscrit dans l'ensemble du champ culturel. Certes, l'invention d'un terme définitoire – roman criminel, roman maritime…– n'est rien d'autre que le constat de quelque chose qui est déjà là, dans la mesure où, pour qu'on éprouve le besoin de créer une catégorie, il faut qu'on sente qu'il existe une série d'œuvres suffisamment proches pour imposer une telle création [6].

La reconnaissance terminologique décrite ci-dessus n'est pas un phénomène uniquement discursif. Letourneux soutient qu'elle constitue un tournant dans les conditions mêmes de la production générique.

> Cela signifie qu'il existe une rupture dans l'histoire d'un genre, qui tient au moment où il est nommé, isolé. Car si les auteurs s'inscrivent déjà dans une logique stéréotypique avant que le genre ne soit explicitement identifié, le fait de lui donner un nom tend à accélérer et à systématiser la logique de reformulation sérielle [7].

La question que pose ce chapitre est la suivante : cette reconnaissance médiatique a-t-elle des effets mesurables sur la production générique elle-même ? Si oui, peut-on détecter et quantifier la normalisation formelle qui accompagne la cristallisation d'un genre ?

1.2 La collection éditoriale comme dispositif normalisateur

Les discussions sur l'avènement terminologique de nos deux genres sont intimement liées à l'apparition d'un nouveau mode de publication au début du XXe siècle : les collections éditoriales. Dans *Fictions à la chaîne*, Letourneux analyse en détail la transformation qui s'opère lorsque l'édition populaire bascule du modèle du feuilleton vers celui de la collection. Ce passage a des conséquences directes sur la façon dont les genres sont produits et perçus :

> Avec le glissement, au début du XXe siècle, de l'édition populaire dans une logique de collection, les conventions génériques sont apparues plus évidentes, plus identifiables

5. Le lancement de la collection est hésitant : le premier titre, *La Mystérieuse affaire de Styles* d'Agatha Christie (tiré à 3000 exemplaires), « met du temps à s'écouler ». (Martinetti, *Le Masque*, p. 7–8)
6. Letourneux, op. cit., p. 25.
7. Ibid., p. 15.

> puisqu'elles devenaient un critère éditorial central. Les écrivains en sont venus à penser naturellement, dès l'origine, leurs romans suivant ces principes génériques. Ils les ont associés aux contraintes que faisait peser chacun des supports (petits romans, grands fascicules, volumes de collections de taille plus ou moins longue…) sur les architextes génériques [8].

Pour le roman d'aventures, cette naissance de la logique de collection se fait notamment par le biais de deux maisons concurrentes : la maison Ferenczi, qui structure au début des années 1920 une offre explicitement labellisée « Romans d'aventures » [9], et la maison Tallandier [10], qui relance en 1923 une « Bibliothèque des grandes aventures » [11]. Cette convergence de collections concurrentes mais similaires produit ce que Letourneux appelle un « effet de généricité qui s'impose aux auteurs et aux lecteurs comme une évidence » [12]. Ainsi, la collection ne se contente pas de refléter un genre préexistant, elle le produit matériellement, en standardisant à la fois les formats, les couvertures, les thèmes et les attentes.

Pour le roman policier, un même effet de structure éditoriale s'observe autour de l'importation du genre en France :

> Ainsi, il y a fort à parier que la façon qu'a la critique de définir le roman policier à travers les deux grands genres du *whodunit* à l'anglaise et du *hardboiled* à l'américaine tient à la domination du marché par deux grands éditeurs, les Éditions du Masque (spécialiste du roman à l'anglaise) et la collection « Série noire » de Gallimard (qui fera connaître en France la tradition des *pulps* à l'américaine). Les autres collections policières se sont généralement positionnées par rapport à ces deux principaux acteurs […], déterminant largement la façon qu'ont les lecteurs français de percevoir la polarisation du genre [13].

En d'autres termes, la collection est un dispositif qui produit activement la généricité, en sélectionnant les textes conformes, en rejetant les textes déviants, et en imposant aux auteurs un horizon d'attente contraignant. Le lecteur lui-même appréhende l'œuvre à travers la médiation de la collection : acheter un volume du Masque, c'est s'attendre à un certain type de roman policier.

1.3 Deux régimes de codification

La reconnaissance terminologique et la cristallisation éditoriale peuvent s'accompagner, ou non, d'une codification explicite des conventions génériques. Le cas du roman policier est

8. Idem, *Fictions à la chaîne*, p. 152.
9. Nicolas Stetenfeld. *Voyage au pays des collections de romans d'aventures : les éditions J. Ferenczi*. 2023. URL : https://www.bila.ink/voyage-au-pays-des-collections-de-romans-daventures-les-editions-j-ferenczi/ (visité le 27/02/2026).
10. Pour une histoire de la maison d'édition, voir Matthieu Letourneux et Jean-Yves Mollier. *La Librairie Tallandier : histoire d'une grande maison d'édition populaire, 1870-2000*. Paris : Nouveau monde éd, 2011
11. Nicolas Stetenfeld. *Voyage au pays des collections d'aventures : les éditions Jules Tallandier*. 2023. URL : https://www.bila.ink/voyage-au-pays-des-collections-daventures-les-editions-jules-tallandier/ (visité le 27/02/2026).
12. Letourneux, op. cit., p. 169.
13. Ibid., p. 168.

symptomatique. En 1928, S.S. Van Dine publie ses *Twenty Rules for Writing Detective Stories*[14], qui prescrivent et proscrivent avec une précision remarquable :

> Règle 3. Il ne doit y avoir aucune intrigue amoureuse. Introduire l'amour, c'est encombrer une expérience purement intellectuelle d'un sentiment hors de propos. L'affaire du moment consiste à traduire un criminel devant la justice, non à conduire un couple à l'autel nuptial.
>
> Règle 20. Un auteur de roman policier digne de ce nom n'a plus à recourir à certains artifices trop rebattus : l'indice du mégot de cigarette, la fausse séance spirite destinée à arracher un aveu, des empreintes digitales falsifiées, l'alibi au mannequin, le chien qui n'aboie pas, ou encore le jumeau comme coupable…

En 1929, Ronald Knox publie son *Detective Story Decalogue*[15], qui va dans le même sens. La fondation du Detection Club à Londres en 1930, institutionnalise ces règles au sein d'une communauté d'écrivains. Les *Twenty Rules for Writing Detective Stories* de Van Dine[16], déjà discutées au chapitre 5, ne sont pas seulement une prescription esthétique, elles codifient le jeu de variation au sein de l'architexte, en proscrivant les ficelles usées. En France, la concentration éditoriale autour du Masque traduit cette codification en politique éditoriale.

Le roman d'aventures offre le cas inverse : une reconnaissance sans codification. Letourneux montre que le roman d'aventures a pu être perçu comme un « hypergenre »[17], c'est-à-dire un ensemble flou recouvrant des productions très diverses (récits de voyage, westerns, romans d'espionnage, récits exotiques, cape et épée), mais souligne les limites de cette lecture :

> Malgré sa séduction, une telle position souffre du fait qu'elle tend à systématiser la relation du roman d'aventures à ce qui ne serait que des sous-catégories, alors même qu'à chaque fois, le roman d'aventures ne représente qu'une direction des genres auxquels il était lié.[18]

Le roman d'aventures, s'il traverse de nombreux genres, ne les contient pas : il n'en constitue qu'une direction possible, un pôle discursif parmi d'autres. Cette position transversale mais non englobante explique que le genre apparaisse comme « sémantiquement pauvre »[19] par rapport aux genres à définition thématique : là où le policier se cristallise autour du crime à résoudre, le roman d'aventures ne dispose pas d'un contenu sémantique aussi spécifique, se limitant au triomphe du héros après l'expérience d'une mort imminente. Cette pauvreté sémantique a une conséquence directe sur la normalisation : sans noyau thématique resserré, le genre n'a jamais produit de codification explicite. Il n'existe pas de « Twenty Rules for Writing Adventure Stories », pas de Club de l'aventure, pas de collection hégémonique qui imposerait à elle seule la définition du genre.

14. Van Dine, « Twenty Rules for Writing Detective Stories ».
15. Knox, « Introduction ».
16. Van Dine, op. cit.
17. Letourneux, op. cit., p. 56.
18. Idem, *Le roman d'aventures*, p. 177.
19. Ibid., p. 178.

1.4 Poids des contextes sur le texte

Au-delà des travaux de Letourneux, l'idée d'une normalisation des genres peut être étayée par plusieurs traditions complémentaires. Dans la théorie des fictions populaires, Cawelti [20] définit la formule comme la synthèse entre des archétypes narratifs universels (l'aventure, le mystère, la romance) et des conventions culturelles spécifiques (figures, décors, thèmes) propres à une époque et à un public. Le genre populaire repose ainsi sur des structures fortement prévisibles qui garantissent la satisfaction d'attentes conventionnelles : le lecteur attend à la fois la reconnaissance du familier et la surprise du nouveau. Ce modèle a une conséquence directe pour notre propos : si un genre est un système conventionnel de mise en scène de ces formules, alors la reconnaissance de ce système peut entraîner une réduction de l'espace des variations acceptables.

Eco [21] prolonge cette réflexion en déplaçant l'attention vers le mécanisme même du plaisir sériel : le lecteur de genre ne cherche pas la surprise mais la confirmation du familier, et son plaisir naît précisément de la répétition de schémas connus. Dans ce cadre, la répétition est un principe constitutif de la production sérielle. Si l'on accepte cette prémisse, il devient possible d'en tirer une conséquence qu'Eco ne formule pas explicitement : la reconnaissance d'un genre par le public et les éditeurs devrait logiquement renforcer cette tendance à la répétition, et donc favoriser un resserrement des formes autour des schémas les plus immédiatement reconnaissables.

À un autre niveau d'analyse, au cinéma et à la télévision, les théories de la généricité comme dispositif de coordination entre producteurs, médiateurs et publics décrivent les genres comme des catégories à la fois culturelles et industrielles, stabilisées par des conventions partagées et susceptibles d'entrer dans des phases de standardisation lorsque ces conventions se rigidifient. Bien que ces théories aient été principalement élaborées à partir du cinéma [22] et de la télévision [23], le modèle est directement transposable à l'édition sérielle du XIXe siècle, où collections, catalogues et publicités jouent un rôle analogue dans la stabilisation des catégories.

La sociologie du champ littéraire fournit un modèle proprement institutionnel de ce processus. Pour Bourdieu, le champ de production culturelle s'organise selon un principe de différenciation qui oppose deux pôles. D'un côté, l'économie de l'art pour l'art, orientée vers l'accumulation de capital symbolique. De l'autre,

> la logique « économique » des industries littéraires et artistiques qui, faisant du commerce des biens culturels un commerce comme les autres, confèrent la priorité à la diffusion, au succès immédiat et temporaire, mesuré par exemple au tirage, et se contentent de s'ajuster à la demande préexistante de la clientèle [...] et des *formes préétablies*. [24].

Ce cadre permet de formuler une hypothèse précise : si la reconnaissance d'un genre littéraire sériel le rattache plus fermement au pôle commercial du champ, elle devrait renforcer la pression vers des « *formes préétablies* » et réduire l'espace des variations formelles acceptables.

20. Cawelti, *Adventure, mystery, and romance*.
21. Eco, « Innovation and Repetition ».
22. Stephen Neale. *Genre and Hollywood*. London : Routledge, 2005.
23. Jason Mittell. *Genre and Television : From Cop Shows to Cartoons in American Culture*. London : Routledge, 2004.
24. Bourdieu, *Les Règles de l'art : Genèse et structure du champ littéraire*, p. 202–203.

L'histoire de l'édition confirme et prolonge ce constat sur un plan matériel. Jean-Yves Mollier montre que la librairie française est devenue, à partir de la fin du XIXe siècle, une « affaire financière et commerciale, ainsi qu'industrielle » [25], dont les logiques de rentabilité orientent directement la production des textes. Par leurs stratégies commerciales, les éditeurs contribuent à définir les contours de ce qui est publiable et, par conséquent, de ce qui s'écrit. Letourneux résume cela en soulignant que « les éditeurs orientant, par le choix des publications, les pratiques d'écriture. […] La standardisation des formes et des contenus est le trait principal de la culture de masse » [26]. La littérature sérielle peut dès lors être décrite comme un espace où la professionnalisation et la standardisation des dispositifs de production favorisent certaines régularités formelles au détriment d'autres. Ces traditions convergent vers une même intuition, celle d'un resserrement des formes d'un genre après sa reconnaissance, mais aucune ne l'a soumise à une vérification empirique à grande échelle sur des corpus textuels.

1.5 Enjeux de recherche

Les collections éditoriales du début du XXe siècle ont donc profondément reconfiguré la production sérielle, en imposant des conventions génériques de plus en plus explicites. Nous voulons dans ce chapitre faire le constat formel quantitatif de cette dynamique. Ce phénomène éditorial s'inscrit dans un mouvement plus large : la progressive reconnaissance, par les éditeurs, les écrivains et les lecteurs, de l'existence de genres distincts au sein de ce qui n'était encore, au XIXe siècle, que le vaste continuum du roman-feuilleton. La littérature de genre naît de cette sortie du feuilleton : le texte, publié désormais en monographie, s'accompagne d'un paratexte (illustrations en couverture, nom des collections, étiquettes génériques) qui oriente la lecture et contraint l'écriture.

Les dates de reconnaissance médiatique que nous avons identifiées, les années 1920 pour le roman d'aventures et les années 1930 pour le roman policier, cristallisent sans doute un mouvement formel de fond, lent et continu, dont elles ne sont que la manifestation terminologique à un temps t. La question que pose ce chapitre est de savoir si ce mouvement laisse une trace mesurable dans les textes eux-mêmes.

Il s'agit donc de mesurer l'évolution de la diversité formelle des genres sériels sur le temps long (1850–1948 pour le roman d'aventures, 1850–2000 pour le roman policier), en utilisant les représentations vectorielles des textes pour quantifier l'espace des possibles discursifs.

2 Méthode

2.1 Corpus

Nous travaillons sur les deux corpus constitués et introduits au chapitre 8 [27]. . Le corpus policier comprend 1 061 romans français publiés entre 1843 et 2000. Ce corpus est constitué par la jointure de deux sources : un corpus de référence de 307 romans étiqueté par des chercheurs

25. Mollier, *L' argent et les lettres*, p. 8.
26. Letourneux, *Fictions à la chaîne*, p. 95.
27. Voir le lien corpus raffiné.

spécialistes du XIXe siècle, issu du projet ANR *Chapitres*[28], et un corpus de 830 romans prédits par un classifieur entraîné sur les fréquences lexicales du genre, appliqué aux 12 176 textes numérisés de Gallica (BNF). Les textes communs aux deux sources ont été dédoublonnés. Découpé et vectorisé en passages, le corpus totalise environ 318 000 passages encodés. Il est cependant important de noter un déséquilibre structurel : le corpus *Chapitres*, seul disponible après 1950, est fortement dominé par Georges Simenon (80 romans sur environ 200 textes post-1930). Nous reviendrons sur ce point dans un test de robustesse (section 3.4).

Le corpus d'aventures comprend 1 391 romans français publiés entre 1817 et 1948, identifiés par le même type de classifieur lexical, entraîné à partir du corpus de référence de 101 romans d'aventures introduits dans la thèse de Letourneux. Le corpus totalise environ 467 000 passages encodés. Il convient de noter que ce corpus s'arrête en 1948, ce qui limite le nombre de fenêtres d'observation post-reconnaissance à 19 (contre 69 pour le policier).

Chaque corpus de genre est apparié à un corpus témoin constitué de romans non génériques extraits du corpus *Chapitres* (environ 3 000 romans français couvrant la période 1800-2020). Les corpus témoins sont construits par échantillonnage apparié en année : pour chaque année représentée dans le corpus de genre, un nombre proportionnel de romans est tiré aléatoirement parmi les textes du corpus *Chapitres* n'appartenant pas au genre étudié. Le corpus témoin du policier comprend 830 romans ; celui du roman d'aventures en comprend 1 391. Les corpus témoins suivent la même distribution temporelle que les corpus de genre, ce qui permet l'estimation en différences de différences présentée plus loin.

2.2 Construction des modes discursifs

L'unité d'analyse de ce chapitre est le « mode discursif », défini comme une famille de passages romanesques textuellement proches, identifiée par classification automatique. La construction de ces modes discursifs repose sur une pipeline en quatre étapes : segmentation des textes en passages, représentation vectorielle de chaque passage, réduction dimensionnelle, et regroupement non supervisé. Chacune de ces étapes implique des choix méthodologiques que nous détaillons ci-dessous.

Chacun des clusters produits par ces regroupements regroupe des passages dont les représentations vectorielles sont proches dans l'espace sémantique. Ces embeddings, produits par un modèle de langue, capturent certes le vocabulaire d'un passage mais aussi sa syntaxe, ses enchaînements et ses effets de registre. Dans la mesure où ces dimensions sont indissociables de la situation que le passage met en scène (un interrogatoire de police, une traversée maritime, un dialogue de salon), ces regroupements dessinent ce que nous appelons des modes discursifs : non pas des thèmes au sens d'un sujet abstrait, mais des configurations récurrentes où un vocabulaire, un type de scène et un registre d'énonciation convergent.

28. Leblond, *Corpus Chapitres*.

2.2.1 Segmentation en passages

Les romans du corpus sont découpés en passages de 512 tokens (environ 400 mots, soit environ deux pages de texte imprimé). Ce choix résulte d'un compromis. D'un côté, l'unité d'analyse ne peut pas être le roman entier : un roman policier peut contenir à la fois des scènes d'interrogatoire, des descriptions de paysages urbains et des digressions sentimentales, et c'est précisément la distribution de ces composantes que nous voulons mesurer. De l'autre, l'unité ne peut pas être la phrase ou le paragraphe, dont la granularité est trop fine pour capturer un registre discursif stable. Le passage de 512 tokens correspond à une unité intermédiaire, suffisamment longue pour qu'un registre s'installe (un interrogatoire, une scène d'action, une méditation morale), et suffisamment courte pour ne pas mélanger plusieurs registres. La taille de 512 tokens correspond en outre à la fenêtre contextuelle standard des modèles de représentation textuelle de type Transformer [29].

2.2.2 Représentation vectorielle

Nous utilisons ici le modèle développé dans le cadre de la thèse et présenté au chapitre 4. Chaque passage est encodé à l'aide du modèle et le résultat est un vecteur de 1 024 dimensions pour chaque passage. Les vecteurs sont normalisés (norme L2 unitaire), de sorte que la similarité cosinus entre deux passages corresponde à leur produit scalaire. À ce stade, chaque roman est représenté non pas par un seul point, mais par un nuage de points dans un espace à 1 024 dimensions, chaque point correspondant à un passage de 512 tokens.

2.2.3 Réduction dimensionnelle

Les représentations brutes à 1 024 dimensions sont réduites par analyse en composantes principales (ACP) à 50 dimensions. Cette réduction sert deux objectifs. Le premier est technique : le clustering par K-moyennes est sensible à ce que des chercheurs ont appelé « la malédiction de la haute dimensionnalité » [30], car ils remarquaient que les distances standards (euclidienne, cosine) perdaient leur pouvoir discriminant dans les espaces de très haute dimension. Le second est interprétatif : les composantes principales captent les axes de variation les plus importants du corpus, filtrant le bruit des dimensions résiduelles.

Le choix de 50 composantes est guidé par la courbe de variance expliquée cumulée (figure 9.2). Les 50 premières composantes capturent environ 81.2% de la variance totale. Au-delà, chaque composante supplémentaire n'apporte qu'un gain marginal. Ce seuil représente un compromis entre la perte d'information (les dimensions éliminées) et la stabilité du clustering (les dimensions conservées).

2.2.4 Classification : les K-moyennes

Une classification par K-moyennes est appliquée aux représentations réduites, avec $K = 50$ classes et 10 initialisations aléatoires. Chaque passage est ainsi assigné à l'un des 50 clusters, que

29. Vaswani, Shazeer et al., « Attention Is All You Need ».

30. Charu C. Aggarwal, Alexander Hinneburg et Daniel A. Keim. « On the Surprising Behavior of Distance Metrics in High Dimensional Space ». *Database Theory — ICDT 2001*. Sous la dir. de Jan Van den Bussche et Victor Vianu. Berlin, Heidelberg : Springer Berlin Heidelberg, 2001, p. 420-434.

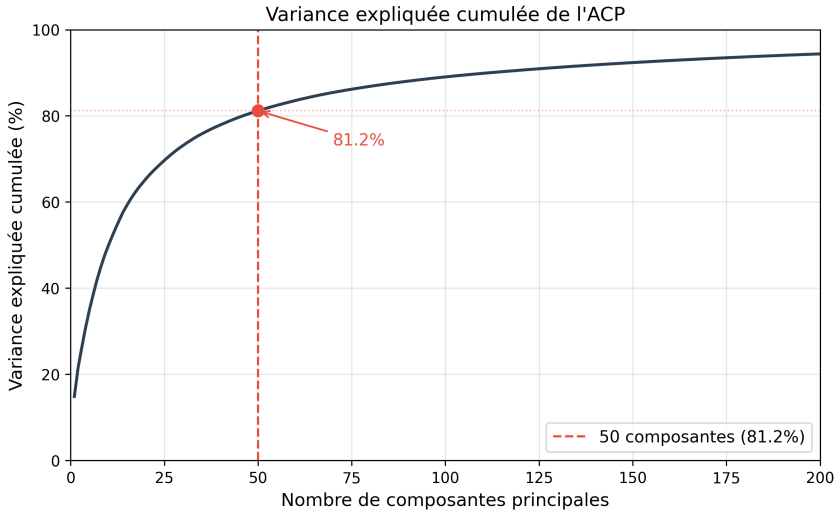


FIGURE 9.2 : Variance expliquée cumulée en fonction du nombre de composantes principales. La ligne pointillée indique le seuil retenu (50 composantes).

nous appelons « modes discursifs ».

Le choix de $K = 50$ résulte d'un compromis entre granularité et interprétabilité. Un K trop faible (par exemple 10) produit des clusters trop hétérogènes, mélangeant des registres distincts. Un K trop élevé (par exemple 200) produit des clusters trop fins, dont beaucoup ne correspondent pas à des registres discursifs identifiables et dont les effectifs sont trop faibles pour des analyses diachroniques robustes. Nous avons exploré plusieurs valeurs de K entre 20 et 100 en évaluant la cohérence qualitative des clusters résultants et le score de silhouette moyen[31]. La valeur $K = 50$ offre le meilleur compromis : des clusters suffisamment homogènes pour être interprétables, et suffisamment nombreux pour capturer la diversité des registres discursifs du corpus.

Il est important de souligner que le K-moyennes est un algorithme qui partitionne l'espace des passages en un nombre fixe de groupes, ici 50, en rassemblant chaque passage autour du centre le plus proche. Ce fonctionnement suppose implicitement que les groupes sont de forme régulière et de taille comparable, ce qui est une simplification. En pratique, les 50 clusters présentent des tailles très inégales (de 116 à 9,149 passages dans le corpus policier, de 5,794 à 26,665 dans le corpus d'aventures). Cette différence reflète le fait que certains types de passages occupent une part beaucoup plus grande de l'espace textuel que d'autres. Pour donner un exemple concret, un cluster regroupant des passages de dialogues entre personnages contient naturellement bien plus de passages qu'un cluster rassemblant des descriptions relevant de ce que l'on pourrait qualifier de *merveilleux scientifique*. Les métriques que nous utiliserons dans la suite sont précisément conçues pour prendre en compte cette inégalité de distribution entre clusters.

31. Peter J. ROUSSEEUW. « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis ». *Journal of Computational and Applied Mathematics* 1987, p. 53-65. DOI : https://doi.org/10.1016/0377-0427(87)90125-7.

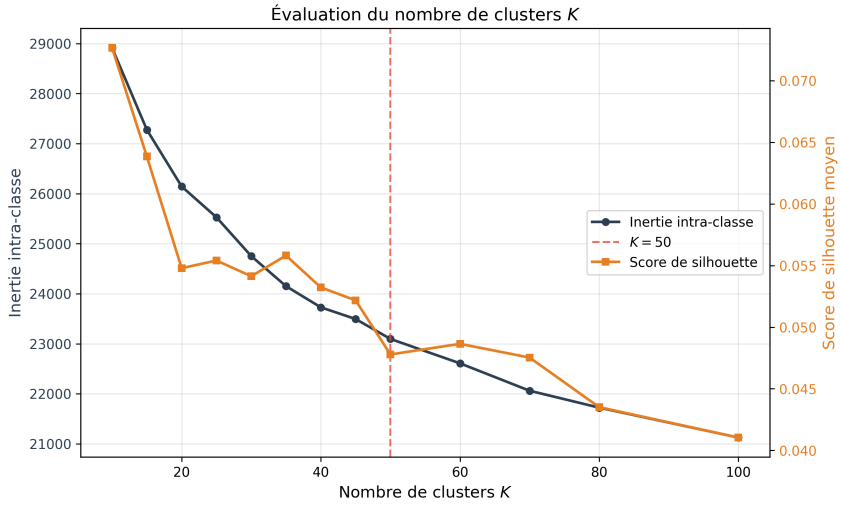


FIGURE 9.3 : Score de silhouette moyen en fonction du nombre de clusters K. La ligne pointillée indique la valeur retenue ($K = 50$).

2.2.5 Aperçu lexical des modes (TF-IDF) :

Le tableau 9.1 présente un aperçu lexical de quatre regroupements sélectionnés parmi les 50 clusters du corpus policier, choisis parce qu'ils illustrent la diversité des registres à l'intérieur du genre ainsi que les dynamiques de spécialisation analysées dans la section suivante. Pour chaque regroupement, les huit mots les plus distinctifs sont extraits par TF-IDF : chaque cluster est traité comme un document unique, et le score met en évidence les termes fréquents dans ce regroupement mais rares dans les autres. La liste complète des mots saillants pour l'ensemble des clusters figure en section 7.

TABLE 9.1 : Mots les plus distinctifs (TF-IDF) de quatre modes discursifs du corpus policier. n : nombre total de passages dans le cluster.

C	Mode	n	Mots saillants (TF-IDF)
1	Procédural urbain	8 152	*téléphone, inspecteurs, taxi, orfèvres, téléphoné, judiciaire, bistrot, brasserie, commissariat, autobus, policier, photos, métro, radio*
46	Scène judiciaire	2 881	*procureur, greffier, préfet, magistrats, audience, déposition, jury, jurés, accusés, huissier, parricide, substitut, débats, gendarme, judiciaire*
17	Néo-polar argotique	4 217	*flic, flics, merde, téléphone, boulot, photos, mec, métro, truc, commissariat, tueur, parking, mecs, fric, plastique, télé, autoroute*
23	Aristocratie d'Ancien Régime	811	*duc, duchesse, chevalier, monseigneur, sire, pyrénées, tsarine, majesté, palatin, chateau, procureur, altesse, parlement, gentilhomme, laquais*

Ces listes de mots fournissent un repérage rapide, l'interprétation des modes comme registres discursifs sera validée dans la section qualitative par un retour aux passages représentatifs en lecture proche.

Le cluster C1, le plus volumineux, constitue le cœur du genre policier tel qu'il se stabilise au

XXe siècle. Nous y trouvons le lexique du commissariat, du quai des Orfèvres, du téléphone et du taxi dessine un univers urbain et procédural reconnaissable. Ce mode concentre à lui seul plus de 8 000 passages, soit près de 10% du corpus échantillonné à l'étude, et recoupe les scènes d'enquête courante, de déplacement dans la ville, de communication entre inspecteurs.

Le cluster C46 capture les scènes du tribunal. Le lexique (« procureur, greffier, audience, jury, déposition ») correspond aux scènes d'instruction et de procès, un héritage du roman judiciaire du XIXe siècle qui persiste dans le genre policier mais avec un poids décroissant.

Le cluster C17 illustre le néo-polar des années 1970–1990, avec son lexique argotique (« flic, merde, mec, boulot, bagnole, fric ») et ses marqueurs contemporains (« métro, parking, autoroute, plastique »). Ce registre est absent du corpus avant 1960 et représente l'émergence d'un sous-genre qui se distingue discursivement du roman policier classique tout en restant dans le périmètre du genre.

Le cluster C23, à l'inverse, témoigne d'un registre antérieur à la constitution du genre. Il s'agit de celui de l'aristocratie d'Ancien Régime (« duc, duchesse, monseigneur, sire, altesse, gentilhomme »). Ce lexique, caractéristique des feuilletons judiciaires et des mélodrames du XIXe siècle, disparaît progressivement du roman policier après sa reconnaissance institutionnelle. Sa présence dans le corpus reflète l'hétérogénéité constitutive du genre avant sa normalisation. Les récits à énigme côtoyaient alors le roman historique, le roman de mœurs et le mélodrame social. La contraction de ce mode dans les fenêtres post-1927 est l'un des marqueurs les plus nets de la normalisation.

2.2.6 Les modes discursifs du roman d'aventures

Le tableau 9.2 présente quatre clusters du corpus d'aventures, choisis pour leur représentativité des grands sous-genres qui composent cette catégorie.

TABLE 9.2 : Mots les plus distinctifs (TF-IDF) de quatre modes discursifs du corpus d'aventures. n : nombre total de passages dans le cluster.

C	Mode	n	Mots saillants (TF-IDF)
3	Aventure maritime	2 330	*matelots, navires, corvette, brick, canot, frégate, chaloupe, pirates, corsaire, mât, amiral, vaisseaux, radeau, embarcation, pirate, cabine*
20	Merveilleux scientifique	2 077	*projectile, ingénieur, lunaire, bolide, pôle, kilomètres, ballon, disque, latitude, satellite, boulet, astronomes, température, oxygène, solaire, sélénites*
9	Exotisme colonial	2 998	*indiens, indien, indigènes, caravane, tribu, louveteau, serpents, loups, campement, éléphant, jungle, éléphants, cabane, tigres, girafes, caverne, fugitifs*
12	Cape-et-épée / cour royale	2 598	*sire, monseigneur, duchesse, altesse, cardinal, régent, maréchal, trône, gentilshommes, tulipe, monarque, coadjuteur, courtisans, connétable, louvre, dauphin*

Le cluster C3 incarne le roman maritime, l'un des sous-genres fondateurs du roman d'aventures : le lexique des « matelots », du « brick », de la « corvette » et des « pirates » renvoie aussi bien à la tradition des Voyages de Bougainville qu'aux romans de piraterie. Ce mode est massivement

présent dans le corpus avant 1900 et décline ensuite, à mesure que le roman d'aventures se déplace vers d'autres géographies.

Le cluster C20 correspond à ce que la critique française a appelé le « merveilleux scientifique ». Le lexique (« projectile, lunaire, ballon, satellite, boulet, latitude, oxygène, sélénites ») est celui des *Voyages extraordinaires* Verniens. L'aventure n'est plus seulement géographique, elle est technologique et scientifique. La catégorie a été forgée par Maurice Renard dans son manifeste de 1909, où il définit le roman merveilleux-scientifique comme présentant « l'aventure d'une science poussée jusqu'à la merveille ou d'une merveille envisagée scientifiquement » [32]. Comme l'a montré Pézard, les articles successifs de Renard constituent autant de « tentatives d'institutionnaliser le genre, c'est-à-dire de transformer une interprétation en catégorie critique admise et reconnue » [33]. Les textes de ce cluster constituent l'un des principaux vecteurs par lesquels le roman d'aventures engendre la science-fiction naissante, illustrant le processus de « centrifugation » [34] décrit par Letourneux : un sous-genre se détache du genre-mère pour acquérir son autonomie éditoriale. Verne n'est d'ailleurs pas seul dans ce cluster, qui récupère à la marge des passage de Boussenard et d'Ivoi, dans la veine des aventures scientifiques, ainsi que Rosny aîné, dans celle du merveilleux scientifique proprement dit. Ces auteurs alimentent un courant suffisamment dense pour que le sous-genre finisse par se constituer en catégorie distincte, avec ses propres circuits de diffusion.

Le cluster C9 capture le registre de l'exotisme colonial : « indiens, jungle, éléphants, campement, tribu, serpents, tigres ». C'est le roman d'aventures dans son acception la plus immédiatement reconnaissable, celui des expéditions en terre lointaine, du contact avec les peuples indigènes et de la faune sauvage. Ce mode est le plus stable du corpus : sa proportion reste relativement constante des années 1860 aux années 1930, ce qui suggère qu'il constitue un noyau permanent du genre plutôt qu'un registre marginal susceptible d'être éliminé par la normalisation.

Le cluster C12 est le mode du roman de cape et d'épée et de la cour royale : « sire, monseigneur, cardinal, régent, trône, courtisans ». Ce registre historique est l'un des plus volumineux du corpus (2 598 passages) et sa trajectoire temporelle est significative : il recule après 1920, à mesure que le roman de cape et d'épée se constitue comme genre autonome, distinct du roman d'aventures. Ici encore, la normalisation procède par perte : le genre-mère se contracte en cédant ses sous-genres à des collections et des étiquettes éditoriales spécifiques.

2.3 Métriques

Nous calculons deux métriques complémentaires sur des fenêtres temporelles de 5 ans, afin d'obtenir un résultat lissé dans le temps.

Nous proposons une métrique, celle du « nombre de modes effectifs » (K_{eff}), qui quantifie la diversité du genre à une époque donnée. Le K_{eff} s'obtient à partir de la distribution de fréquences $\mathbf{p}$ sur ces 50 clusters : l'entropie de Shannon $H = -\sum_k p_k \log p_k$ est convertie en nombre de modes effectifs par $K_{\text{eff}} = \exp(H)$. Un K_{eff} élevé (par exemple 25) indique que les romans du

32. Maurice Renard. « Du roman merveilleux-scientifique et de son action sur l'intelligence du progrès ». *ReS Futurae. Revue d'études sur la science-fiction* 2018. DOI : 10.4000/resf.1201, p. 3.

33. Emilie Pézard. « Défense et illustration d'un genre. Le merveilleux scientifique défini par Maurice Renard (1909-1928) ». *ReS Futurae. Revue d'études sur la science-fiction* 2018. DOI : 10.4000/resf.1383, p. 3.

34. Letourneux, op. cit., p. 232.

genre puisent dans un répertoire large et équilibré de modes. Un K_{eff} bas (par exemple 5) signale une concentration sur un petit nombre de modes dominants. Cette métrique est centrale dans le chapitre et mesure l'étendue de l'espace des possibles du genre, c'est-à-dire la diversité des configurations lexicales et discursives effectivement mobilisées par les textes.

La seconde métrique, qu =e nous appelons « dérive du centroïde », mesure la stabilité de l'identité du genre dans le temps. Pour chaque fenêtre temporelle de dix ans, nous calculons le centroïde du genre, c'est-à-dire le vecteur moyen de l'ensemble des passages appartenant aux romans du genre publiés durant cette décennie. La dérive est alors la distance cosinus entre les centroïdes de deux fenêtres successives. Une dérive faible signifie que le genre, quelle que soit l'étendue de sa diversité, reste centré sur le même noyau lexical d'une décennie à l'autre. Une dérive forte signale que le genre se transforme en profondeur, que son profil se déplace vers de nouveaux territoires.

2.4 Protection contre les artefacts d'échantillonnage

La mesure de la diversité discursive au sein d'un genre sur le temps long pose un problème méthodologique sérieux : la densité du corpus varie considérablement d'une décennie à l'autre. Le corpus d'aventures, par exemple, contient 150 romans pour les années 1880 mais seulement 5 pour les années 1940. Si l'on mesure naïvement la diversité dans chaque fenêtre temporelle, on risque de confondre la diversité du genre avec la taille de l'échantillon : une fenêtre contenant plus de romans a mécaniquement plus de chances d'exhiber une diversité élevée. Pour neutraliser ce biais, nous avons mis en place un pipeline de quatre niveaux de protection.

Le premier niveau est l'égalisation par premier quartile (Q1). Pour chaque année du corpus, le nombre de passages est plafonné au premier quartile de la distribution annuelle. Concrètement, les années ayant un volume de passages supérieur au Q1 voient leur contribution réduite par sous-échantillonnage aléatoire. Cette opération ramène le corpus policier de 318 000 à 61 000 passages (Q1 = 382 passages par an), et le corpus d'aventures de 467 000 à 61 000 passages (Q1 = 571 passages par an).

Le deuxième niveau est l'égalisation temporelle pour le regroupement. L'ACP et le K-moyennes ne sont pas ajustés sur le corpus brut, car cela donnerait un poids disproportionné aux décennies les plus représentées. Avant l'ajustement, les passages sont rééchantillonnés de sorte que chaque décennie fournisse un nombre égal de passages. Pour le corpus policier, l'équilibrage porte sur 21 décennies avec une cible de 5 382 passages par décennie, réduisant le corpus de 136 000 à 101 000 passages. Cette étape garantit que les 50 clusters reflètent la diversité de l'ensemble de la période et non la seule physionomie des décennies les plus denses.

Le troisième niveau est un sous-échantillonage par roman, appelé « raréfaction » [35], utilisé en écologie de la biodiversité et importé en sciences humaines et sociales computationnelles. Pour chaque fenêtre glissante de 5 ans, le pipeline ne tire pas directement un nombre fixe de passages, ce qui favoriserait les romans les plus longs. Il commence par échantillonner un nombre fixe de romans, puis tire un nombre fixe de passages parmi les romans retenus. Le nombre de romans par

35. Stuart H. Hurlbert. « The Nonconcept of Species Diversity : A Critique and Alternative Parameters ». *Ecology* 1971, p. 577-586. doi : 10.2307/1934145.

fenêtre est fixé au dixième percentile (p10) de la distribution du nombre de romans disponibles par fenêtre. Pour le corpus policier, ce seuil est de 8 romans par fenêtre (la distribution allant de 5 à 157) et pour le corpus d'aventures, il est de 16 romans par fenêtre. Les fenêtres ne disposant pas du minimum requis de romans sont exclues de l'analyse. Le nombre cible de passages par fenêtre est ensuite fixé à 74 pour le policier et 37 pour les aventures, en fonction de la capacité médiane des fenêtres raréfiées.

Dans le quatrième niveau nous vérifions que la métrique de diversité (K_{eff}) n'est plus corrélée à la densité de l'échantillon. Le coefficient de Spearman entre le nombre de romans effectivement échantillonnés par fenêtre et le K_{eff} mesuré doit être proche de zéro. Pour le corpus policier, cette corrélation est de $r = +0{,}014$ ($p = 0{,}86$), confirmant que la raréfaction a effectivement neutralisé le biais de densité. Pour le corpus d'aventures, la corrélation est de $r = +0{,}125$ ($p = 0{,}20$), également non significative. Sans raréfaction, ces corrélations étaient de $r = +0{,}483$ et $r = +0{,}556$ respectivement ($p < 0{,}001$), ce qui montre l'ampleur du biais que la procédure corrige.

Nous contrôlons également le biais de base, c'est-à-dire l'uniformité de la répartition des passages entre clusters indépendamment du signal temporel. L'entropie normalisée de la distribution des clusters est supérieure à 87% dans toutes les configurations, ce qui confirme que les 50 clusters sont utilisés de manière raisonnablement équilibrée.

2.5 Inférence statistique

Les intervalles de confiance sont estimés par *bootstrap*. Concrètement, nous générons 2 000 séries reconstituées en rééchantillonnant des blocs mobiles de 5 ans, puis nous recalculons l'indicateur sur chacune d'elles. Ce choix par blocs, plutôt qu'année par année, vise à conserver la dépendance locale des séries temporelles.

Ensuite, nous employons un estimateur en différences de différences (DiD) isole l'effet différentiel du genre en soustrayant à l'évolution observée dans le corpus de genre celle observée dans le corpus témoin. Concrètement, si le K_{eff} du policier passe de 14,7 à 6,3 et que celui du témoin passe de 18 à 14, le DiD est $(6{,}3 - 14{,}7) - (14 - 18) = -8{,}4 - (-4) = -4{,}4$. Si l'intervalle de confiance de cet estimateur n'inclut pas zéro, on en déduit que l'hypothèse d'absence d'effet différentiel n'est pas compatible avec les données au niveau retenu : autrement dit, l'évolution du genre ne se réduit pas à la tendance de fond observée dans le corpus témoin.

3 Résultats : le roman policier

3.1 Contraction de la diversité discursive

La figure 9.4 présente l'évolution du nombre de modes effectifs dans le corpus policier entre 1842 et 2013, comparée à celle du corpus témoin.

Le corpus policier présente une trajectoire en trois phases. De 1850 à 1890, la diversité atteint un plateau autour de 15 modes, son maximum historique. Ce plateau correspond à la période où coexistent sous une même étiquette rétrospective les feuilletons des enquêtes de Gaboriau, celles de Féval ou de Boisgobey. Le genre, à cette époque n'est pas encore clairement défini

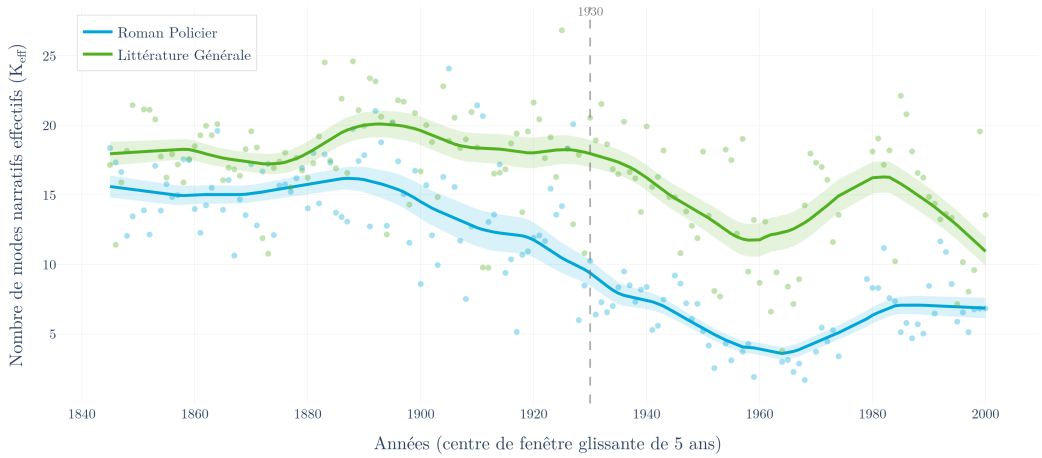


FIGURE 9.4 : Nombre de modes effectifs (K_{eff}), 1842-2013. Points : estimations par fenêtre de 5 ans (8 romans raréfiés par fenêtre). Ligne : lissage LOWESS. Ligne pointillée : seuil de 1930.

et doit s'extirper du roman feuilleton : il est perméable aux digressions morales, aux intrigues matrimoniales, au mélodrame, à la vie parisienne.

À partir de 1890, la diversité commence à décliner. Le mouvement s'accélère autour de 1930 : de 12 modes environ vers 1920, on tombe à 3 modes vers 1960. En moyenne, le K_{eff} pré-1930 est de 14,7 modes effectifs, contre 6,3 en post-1930, soit une réduction de 57% ($p < 0{,}0001$, test de permutation par blocs). Le roman policier post-reconnaissance se concentre sur un noyau étroit de configurations discursives.

Le corpus témoin présente également un déclin, mais avec un profil temporel différent. La diversité du témoin reste élevée et relativement stable jusqu'aux années 1900, puis décline progressivement jusqu'aux années 1930, avant une chute assez vertigineuse jusqu'aux années 60. Si les deux courbes partent sensiblement d'une même point, les deux présentent des caractéristiques communes dans la chute, mais le corpus policier a une baisse plus importante. L'estimateur en différences de différences (section 3.3) permet de quantifier cette divergence. Cette baisse généralisée est un témoin de la naissance de la littérature de genre en collection à cette période, et plus largement de la culture de masse en France.

3.2 Stabilité du centroïde

La figure 9.5 présente l'évolution de la dérive du centroïde.

La dérive du centroïde mesure le déplacement du genre par rapport à son centre de gravité discursif : plus elle augmente, plus les textes récents s'éloignent du noyau moyen qui caractérisait jusque-là le corpus. Or, dans le cas du roman policier, la normalisation observée après 1930 ne s'accompagne pas d'un déplacement net de ce centre. Autrement dit, le genre ne migre pas vers un nouveau territoire discursif. Il se contracte autour de son centre existant, en éliminant surtout des modes périphériques.

Les chiffres vont dans ce sens : la dérive du centroïde dans le roman policier passe en moyenne de 0,044 avant 1930 à 0,051 après 1930, soit une augmentation de 16%. Cette différence n'est

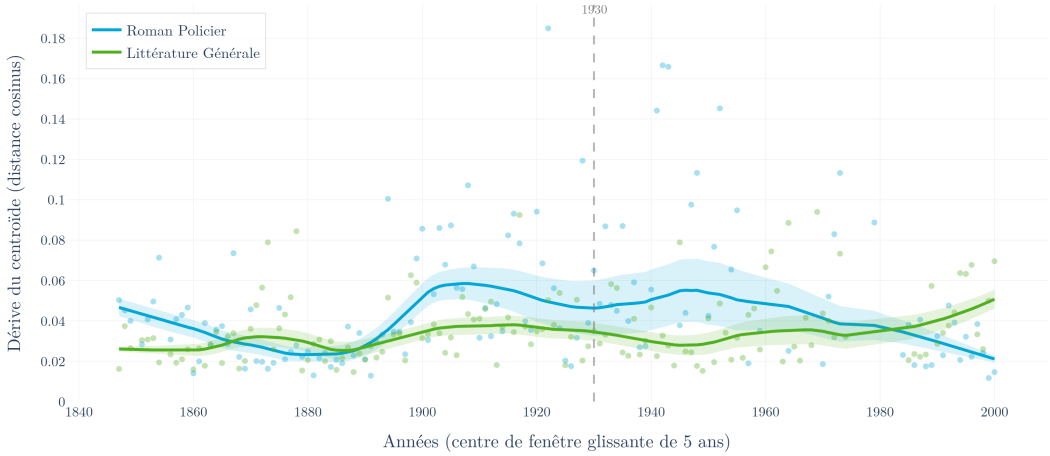


FIGURE 9.5 : Dérive du centroïde (distance cosinus entre prototypes de fenêtres successives), 1842-2013. Ligne pointillée : seuil de 1930.

cependant pas significative ($p = 0{,}42$). Le résultat est confirmé par l'estimateur DiD (section 3.3), qui ne détecte aucun effet spécifique au genre sur la dérive du centroïde.

3.3 Estimation en différences de différences

TABLE 9.3 : Estimation en différences de différences (DiD), corpus policier vs témoin (seuil : 1930)

Métrique	DiD	IC 95% (bas)	IC 95% (haut)	Significativité
Modes effectifs (K_{eff})	−4,62	−6,79	−2,70	Significatif
Dérive du centroïde	+0,002	−0,017	+0,024	NS

L'estimateur DiD pour les modes effectifs est de −4,62 (IC 95% : [−6,79; −2,70]). L'intervalle de confiance ne croise pas zéro, ce qui confirme que le roman policier a connu une contraction de diversité spécifique au genre, non réductible à la tendance observée dans la littérature française dans son ensemble. En d'autres termes, même en tenant compte du fait que le corpus témoin perd lui aussi de la diversité après 1930, le policier en perd significativement plus.

Le DiD pour la dérive du centroïde est en revanche non significatif (+0,002, IC [−0,017; +0,024]). La faible augmentation de la dérive dans le policier ne se distingue pas de l'évolution du témoin. Ce résultat signifie que le genre policier se normalise par contraction, en réduisant le nombre de registres utilisés.

3.4 Test de robustesse : l'effet Simenon

Le corpus policier post-1930 est fortement dominé par Georges Simenon (80 romans sur environ 150 textes post-1930 dans le corpus de référence). Pour départager l'hypothèse d'un effet-genre de celle d'un effet-auteur, nous avons relancé l'intégralité du pipeline en excluant les 80 romans de Simenon. Le corpus passe alors de 1 066 à 986 romans.

TABLE 9.4 : Comparaison des résultats avec et sans Simenon (seuil : 1930)

Configuration	K_{eff} pré	K_{eff} post	Variation	DiD (IC 95%)
Avec Simenon (1 066 romans)	14,68	6,32	−57%	−4,62 [−6,79 ; −2,70]
Sans Simenon (986 romans)	12,55	7,58	−40%	−2,97 [−5,62 ; −0,61]

La baisse de la diversité passe de −57% à −40%, une atténuation notable mais qui reste massive et statistiquement significative. Le DiD sans Simenon est de −2,97 (IC 95% : [−5,62; −0,61]) : l'intervalle de confiance ne croise pas zéro, confirmant que la contraction est un phénomène de genre. C'est donc bien toute la production policière française qui converge après 1930.

La dérive du centroïde reste non significative dans les deux configurations (+16% avec Simenon, $p = 0{,}42$; +15% sans Simenon, $p = 0{,}53$). Le DiD de la dérive est de +0,006 (IC [−0,019; +0,041]), non significatif. Ce résultat écarte l'hypothèse selon laquelle Simenon aurait fortement déplacé le centroïde du genre : avec ou sans lui, le policier se contracte sans se déplacer.

Simenon contribue donc à la contraction (le K_{eff} post-1930 passe de 6,32 à 7,58 sans lui, soit environ 1,3 mode effectif de différence), mais le phénomène de fond demeure.

3.5 Analyse qualitative : ce que le genre a perdu et gagné

Afin de caractériser la normalisation, nous avons analysé le contenu des 50 clusters, en identifiant les modes qui se sont développés et ceux qui ont disparu au seuil de 1930. Le tableau 9.5 présente les cinq clusters en plus forte expansion et les cinq en plus forte contraction, mesurés par la variation de proportion (Δ prop) entre les périodes pré et post-1930.

TABLE 9.5 : Modes discursifs en expansion et en contraction (corpus policier, seuil 1930)

Cluster	$n_{\text{pré}}$	n_{post}	Δ prop	Variation
En expansion				
C1	116	8 036	+0,285	+8 202%
C17	12	4 205	+0,151	+41 893%
C15	40	1 888	+0,067	+5 556%
C12	12	1 749	+0,062	+17 366%
C9	14	1 304	+0,046	+11 062%
En contraction				
C7	2 206	13	−0,066	−99,3%
C45	2 217	84	−0,063	−95,5%
C24	2 171	57	−0,063	−96,9%
C46	2 500	381	−0,061	−81,7%
C4	1 538	17	−0,045	−98,7%

La transformation qui se dessine est profonde et sa symétrie est instructive. Les cinq modes en contraction représentaient, avant 1930, plus de 10 600 passages, soit une part considérable de la production. Leur quasi-disparition révèle l'ampleur de la purification générique opérée par l'institutionnalisation. Pour caractériser cette transformation, nous commentons deux modes en

contraction et deux modes en expansion particulièrement parlants.

Ce que le genre a perdu. Le cluster C24 (2 171 passages pré-1930, 57 post-1930, −96,9%) capture le registre du feuilleton sentimental au sens le plus pur. Les passages représentatifs font apparaître un univers de secrets de famille, de passions avouées et de confrontations sentimentales où le crime n'est qu'un prétexte au déploiement du drame passionnel. Dans *Le Banquier de Bristol* (1840), de Lacroix, un romancier historique et feuilletoniste prolifique de la monarchie de Juillet, un banquier questionne insidieusement une femme sur un jeune homme qui l'accompagnait :

> Comment nommez-vous donc la personne qui vous accompagnait souvent ? Élisa, frappée au cœur, devint pâle comme la mort. — Rappelez-moi donc, je vous prie, son nom... continua le banquier. Oui... c'était un jeune homme, assez aimable même, à ce qu'on m'a dit... Comment diable : se nomme-t-il ?... En vérité, c'est déplorable, je n'ai plus de mémoire... — Je cherche, monsieur... balbutiat-elle d'une voix altérée.

La scène est construite sur le jeu des affects : la pâleur, le cœur frappé, la voix altérée, le balbutiement. L'intrigue avance non par la découverte d'un indice matériel, mais par la lecture des corps émotionnels. Dans *Une banqueroute frauduleuse* (1861), de Zaccone, feuilletoniste auteur de nombreux romans populaires et judiciaires, le même registre se déploie dans une scène de retrouvailles entre deux femmes, l'une déchue, l'autre compatissante : « Lucien a été sublime, répondit-elle ; son souvenir a été mon soutien dans les cruelles épreuves que j'ai eues à supporter, mais, j'étais indigne de son amour, et, vous le voyez, Emilie, je me suis fait justice. » L'aveu, le sacrifice, l'indignité revendiquée : c'est le vocabulaire du mélodrame moral, où chaque personnage porte sa faute comme un stigmate. Précisons que ces passages sont extraits automatiquement par l'algorithme comme étant les plus représentatifs de chaque cluster, c'est-à-dire les plus proches du centroïde. L'analyse littéraire que nous en proposons est donc rendue possible par le regroupement computationnel lui-même. Dans *Les Catacombes sous la Terreur* (1865), de Boulabert, feuilletoniste aujourd'hui oublié, la révélation d'un secret de famille (un titre de noblesse, cent mille francs de rente) provoque une scène de stupeur physique : « Martin ne répondit pas. Cela lui était impossible. » Le registre est celui du roman populaire du XIXe siècle, où l'identité des personnages se révèle par des coups de théâtre sentimentaux, et où la question centrale n'est pas « qui a commis le crime ? » mais « qui est véritablement qui ? ». Précisons toutefois que ce qui disparaît n'est pas tant la passion elle-même que son expression mélodramatique. La règle 3 de Van Dine (« Il ne doit y avoir aucun intérêt amoureux ») vise moins à supprimer tout affect qu'à en proscrire le déploiement spectaculaire. De fait, le roman policier postérieur ne manque pas de passion, mais elle s'exprime autrement, de manière plus sexuelle et cynique. Nos clusters captent donc non seulement une évolution propre au genre policier, mais aussi une transformation plus large des codes littéraires : l'expression mélodramatique des affects, encore possible en 1900, est devenue désuète en 1940, dans le roman policier comme dans le reste de la production romanesque. La normalisation du genre et l'évolution générale des conventions d'écriture convergent ici, et nos données ne permettent pas de démêler entièrement les deux facteurs.

Le cluster C7 (2 206 passages pré-1930, 13 post-1930, −99,3%) présente le versant physique de

ce même univers mélodramatique. Là où C24 est centré sur l'aveu et la confrontation verbale, C7 se concentre sur les manifestations corporelles de l'émotion poussées au paroxysme. Le passage le mieux classé, encore chez Lacroix (1840, *Le Banquier de Bristol*), déploie une scène où le corps entier de l'héroïne devient le théâtre de la souffrance :

> Elisa était au supplice, les idées les plus noires et les plus désespérantes se heurtaient dans sa tête ; son cœur était dévoré d'angoisses ; une sueur glacée mouillait ses tempes. Cependant elle s'efforçait de cacher toutes les tortures de son âme ; elle affectait une contenance calme et indifférente, mais ce qu'elle souffrait est impossible à rendre. Le malheureux qu'on déchire, et qui sent les tenailles ardentes mordre sa chair, n'éprouve pas de plus épouvantables tourmens.

La comparaison avec la torture physique (« les tenailles ardentes ») est caractéristique : dans ce registre, l'émotion est littéralement un supplice, le corps est le lieu d'un martyre. Chez Féval (*Les Mystères de Londres*, Tome II, 1843), la détresse prend la forme de la supplication filiale : une fille implore son père (« je suis forte, allez ! mon père ! ») avant de s'appuyer « la main sur son cœur qui défaillait ». Chez un anonyme de 1862 (*La femme du condamné*), la colère masculine se manifeste par un inventaire systématique du corps en crise : « Ses yeux semblaient lancer des éclairs, ses lèvres tremblaient et les veines de son cou étaient gonflées. » Ce registre du corps émotionnel, où chaque scène est l'occasion d'une crise physique, disparaît presque intégralement du roman policier post-1930. Sa quasi-extinction ($-99{,}3\%$, soit 13 passages sur 2 219 dans le corpus post-1930) est la contraction la plus radicale de tout le corpus.

Ces deux clusters relèvent d'un mode discursif où le récit progresse par la confrontation des affects, et non par l'accumulation des indices. La narration s'arrête pour déployer le spectacle d'un corps qui souffre, d'une âme qui se déchire. Le roman policier, en se normalisant, élimine cette psychologie passionnelle au profit d'une psychologie comportementale où le corps n'est plus un théâtre de la souffrance mais un réservoir d'indices.

Finalement, ce que le genre a perdu, c'est ce qui ne relève pas du roman policier à proprement parlé. Mais comme le corpus d'entraînement de Chapitre prenait assez largement les romans feuilletons avec une composante criminelle importante (Féval, Lermina, Gaboriau), le corpus inféré sur Gallica comporte les mêmes caractéristiques.

Ce que le genre a gagné. Le cluster C1 (116 passages pré-1930, 8 036 post-1930, $+8\,202\%$) domine massivement le corpus post-institutionnel : à lui seul, il représente près de 29% de l'ensemble des passages post-1930. C'est le mode de l'enquête procédurale quotidienne, telle que Simenon l'a codifiée avec Maigret. Les passages représentatifs se déroulent au quai des Orfèvres, dans des bureaux de commissariat, dans des voitures qui traversent Paris. Ici dans Dans *Maigret et les vieillards* (1960), les gestes du métier constituent la matière du récit :

> Il se leva, mécontent de lui, mécontent de tout et il alla se camper devant le jardin, frappant sa pipe sur son talon pour la vider, à l'indignation de Jaquette. […] La vieille fille, menue et raide sur sa chaise, écoutait avec effarement la voix du commissaire qui avait des vibrations qu'elle ne connaissait pas encore. Il est vrai que ce n'était

> pas à elle que Maigret s'adressait, mais à un personnage invisible à l'autre bout du fil. — Non, monsieur Cromières, je n'ai envoyé aucun communiqué à la presse et je n'ai invité ni journalistes ni photographes comme le font volontiers messieurs les ministres.

Là où C24 et C7 déployaient des scènes d'émotion pure (pâleur mortelle, sueur glacée, cœur défaillant), C1 énonce des faits de manière délibérée. Le commissaire frappe sa pipe, regagne sa voiture, passe un coup de téléphone. Les répliques sont brèves, professionnelles : « Rien de nouveau ? Une femme a téléphoné. Elle n'a pas dit de quoi il s'agissait ? Non. » Le détail physique n'est plus au service de l'effet dramatique mais de l'observation comportementale : on note une « tache de vin sur la joue gauche », un témoin qui « ne sortira plus ce matin ». Le corps n'est plus un théâtre de la passion ; il est un objet d'enquête. Même l'irritation du commissaire est contenue dans le geste professionnel : il est « mécontent de lui, mécontent de tout », mais cette humeur ne se traduit par aucun paroxysme. L'univers est celui de la routine policière, où le crime est un problème technique à résoudre dans les rouages d'une institution. Ce mode est quasiment inexistant avant 1930 (116 passages) et devient hégémonique après : c'est la conquête la plus massive de la normalisation.

Le cluster C17 (12 passages pré-1930, 4 205 post-1930, +41 893%) révèle un second pôle du genre normalisé, radicalement différent de l'univers Maigret. C'est le mode du néo-polar urbain, apparu dans les années 1970-1980 avec des auteurs comme Marc Villard, A.D.G. et Fred Vargas. Le registre est celui de la violence crue, du langage familier, de la rue. Chez Villard (*Rebelles de la nuit*, 1987), le récit progresse à coups d'argot et de faits bruts :

> — Sissi et Kader se sont fait sauter la paillasse à la grenade. — Tu es sûr qu'il s'agit de Sissi ? avait insisté Sonny Boy, qui connaissait l'existence de Samia. — J'ai vu ses cheveux. Approche-toi, tu verras. Sonny Boy qui avait son compte de bidoche malmenée pour la journée ne se rapprocha pas des cadavres.

Chez le même Villard (*La dame est une trainee*, 1989), l'interrogatoire n'est plus celui de Maigret, mesuré et empathique, mais une négociation brutale où l'on claque « sèchement l'arrière du crâne d'un revers de main » et où « tu signes des aveux et tu plonges pour un an à Fleury ». Chez Vargas (*Sans feu ni lieu*, 1997), le monde de l'enquête se teinte d'une étrangeté poétique : un personnage traverse « tranquillement le cimetière, sa bouteille de sancerre à la main », un poulet basquaise cuit pendant qu'un homme fait « des ronds dans la farine ». Ce mode partage avec C1 l'ancrage dans le monde de l'enquête et du milieu, mais il en inverse le ton : Maigret est mesuré, le néo-polar de Villard est brutal et cynique.

Ces deux pôles, malgré leurs différences de ton, participent d'une même évolution littéraire plus générale. Le passage d'une psychologie théâtrale et mélodramatique, héritée du roman populaire du XIXe siècle, à une écriture que l'on pourrait qualifier de *behaviouriste*, où seuls les comportements sont notés mais chargés d'un sens psychologique que le lecteur doit suppléer. Claude-Edmonde Magny a analysé cette technique chez les romanciers américains, montrant que le *behaviourisme* littéraire suppose qu'il y a « un parti pris de tenir pour seul réel, dans la vie psychologique d'un homme ou d'un animal, ce qu'en pourrait percevoir un observateur purement

extérieur, représenté à la limite par l'objectif d'un appareil photographique »[36]. Magny désigne Dashiell Hammett comme le maître du genre, dont le style ne consigne que ce qu'un observateur extérieur aurait pu voir ou entendre. Ce modèle narratif irrigue le roman policier français, d'abord indirectement chez Simenon, dont la sobriété procédurale relève d'une observation naturaliste proche du *behaviourisme*, puis explicitement dans le néo-polar, qui hérite du roman noir américain après 1945, comme l'a montré Anne Cadin[37] dans sa thèse de doctorat.

4 Résultats : le roman d'aventures

4.1 Évolution de la diversité discursive

La figure 9.6 présente l'évolution du nombre de modes effectifs dans le corpus d'aventures (1 391 romans, 1832-1939), comparée à celle du corpus témoin.

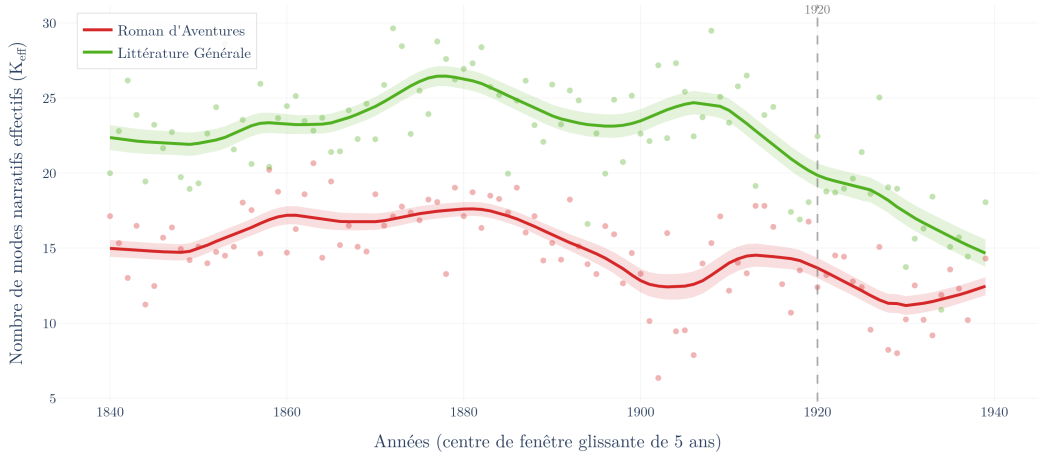


FIGURE 9.6 : Nombre de modes effectifs (K_{eff}), 1832-1939. Points : estimations par fenêtre de 5 ans (16 romans raréfiés par fenêtre). Ligne : lissage LOWESS. Ligne pointillée : seuil de 1920.

Au premier abord, le même constat s'offre à nous : il y a une baisse générale que ce soit dans le corpus témoin ou dans celui d'aventures. Cependant, la baisse est moins évidente, et la trajectoire du roman d'aventures diffère de celle du roman policier. Le K_{eff} moyen pré-1920 est de 15,3 modes effectifs, contre 11,8 en post-1920, soit une réduction de 23% ($p = 0{,}002$). La contraction est donc bien réelle, mais elle est trois fois plus faible que celle du policier (−23% contre −57%). Surtout, cette contraction ne résiste pas au contrôle par le corpus témoin : comme nous le verrons dans l'estimation DiD (section 4.3), le témoin décline lui aussi sur la même période, et la différence entre les deux trajectoires n'est pas significative.

Trois phases se dessinent néanmoins dans la trajectoire du genre. La première (1832-1880) est une phase de constitution : le K_{eff} croît progressivement d'environ 15 à 18 modes. La deuxième (1880-1905) correspond à une première baisse. La troisième (après un rebond dans les année 1910) est marquée par un déclin, mais l'interprétation de cette phase est limitée par le faible

36. Claude-Edmonde MAGNY. *L'âge du roman américain*. Paris : Éditions du Seuil, 1948, p. 50–51.
37. CADIN, « Le moment américain du roman français ».

nombre de fenêtres post-1920 : le corpus d'aventures s'arrêtant en 1940, seules 19 fenêtres sont disponibles pour la période post-reconnaissance, contre 87 pour la période pré-1920.

4.2 Dérive du centroïde : le genre se déplace

Le résultat le plus frappant pour le roman d'aventures concerne la dérive du centroïde. La figure 9.7 révèle une dynamique radicalement différente de celle du roman policier.

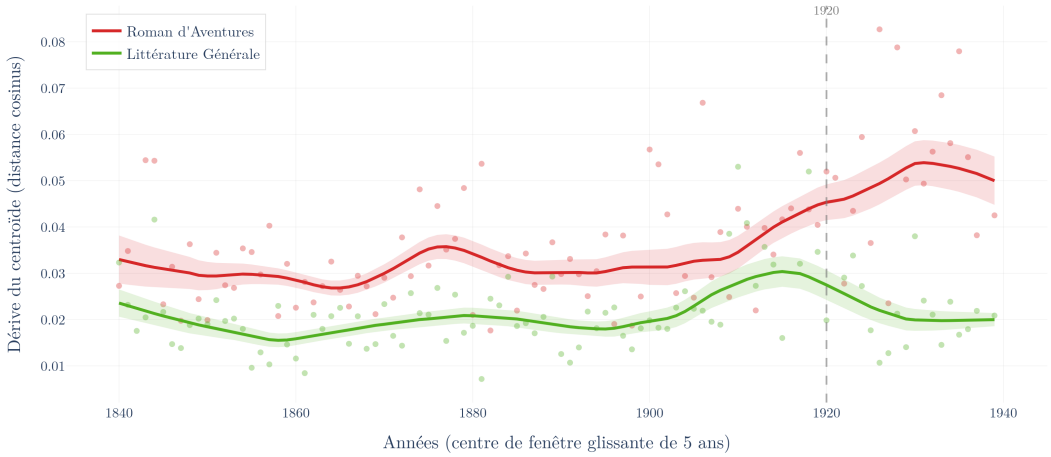


FIGURE 9.7 : Dérive du centroïde dans le corpus d'aventures et le témoin, 1832-1939. Ligne pointillée : seuil de 1920.

La dérive du centroïde passe en moyenne de 0,033 avant 1920 à 0,053 après 1920, soit une augmentation de 59% ($p < 0{,}001$). Ce résultat est l'inverse de ce que nous avons observé pour le policier, dont la dérive restait stable. Le roman d'aventures, après sa reconnaissance, ne se contracte pas autour d'un centre, il migre vers de nouveaux territoires discursifs.

4.3 Estimation en différences de différences

TABLE 9.6 : Estimation en différences de différences (DiD), corpus d'aventures vs témoin (seuil : 1920)

Métrique	DiD	IC 95% (bas)	IC 95% (haut)	Significativité
Modes effectifs (K_{eff})	+1,81	−1,18	+4,28	NS
Dérive du centroïde	+0,020	+0,008	+0,029	Significatif

L'estimation DiD (tableau 9.6) confirme la symétrie inversée entre les deux genres. Pour les modes effectifs, le DiD est de +1,81 (IC 95% : [−1,18; +4,28]), non significatif. Le corpus témoin décline lui aussi sur cette période, ce qui absorbe l'essentiel de la contraction observée dans le corpus d'aventures. La perte de diversité du roman d'aventures n'est donc pas un phénomène spécifique au genre : elle s'inscrit dans une tendance plus large de la littérature française de l'entre-deux-guerres.

Pour la dérive du centroïde, en revanche, le DiD est de +0,020 (IC 95% : [+0,008; +0,029]), hautement significatif. Le roman d'aventures se déplace significativement plus que le corpus témoin. Ce déplacement est propre au genre et ne s'explique pas par une tendance de fond.

La comparaison avec le policier est remarquable par sa symétrie. Le policier se contracte spécifiquement (DiD K_{eff} significatif) sans se déplacer (DiD dérive NS). L'aventures se déplace spécifiquement sans se contracter au-delà du corpus témoin. Les deux genres se normalisent, mais selon des mécanismes opposés, en contraction pour l'un, en déplacement pour l'autre.

4.4 Analyse qualitative : ce que le genre perd et ce qui lui survit

Au sein du genre, certains modes discursifs disparaissent de manière significative entre avant et après 1920. Le tableau 9.7 présente les cinq clusters en plus forte expansion et les cinq en plus forte contraction au seuil de 1920, mesurés par la variation de proportion.

TABLE 9.7 : Modes discursifs en expansion et en contraction (corpus d'aventures, seuil 1920)

Cluster	$n_{\text{pré}}$	n_{post}	Δ prop	Variation
En expansion				
C33	1 228	1 602	+0,124	+507%
C27	720	1 024	+0,081	+561%
C23	1 520	1 193	+0,080	+265%
C37	2 352	847	+0,032	+67%
C9	2 232	766	+0,026	+60%
En contraction				
C41	1 817	87	−0,028	−77,7%
C12	2 380	218	−0,027	−57,4%
C3	2 145	185	−0,026	−59,9%
C4	2 044	190	−0,023	−56,8%
C10	1 473	75	−0,022	−76,3%

La transformation est moins radicale que celle du policier, et elle suit une logique structurellement différente. Pour la caractériser, nous commentons deux modes en contraction et deux modes en expansion.

Ce que le genre a perdu. Le cluster C10 (1 473 passages pré-1920, 75 post-1920, −76,3%) capture le registre du mélodrame sentimental au sens le plus classique. Les passages représentatifs multiplient les scènes de confrontation passionnelle dans un cadre bourgeois ou aristocratique. Chez Emmanuel Gonzalès (1815-1887), feuilletoniste et président de la Société des gens de lettres, dans *L'Hôtesse du connétable* (1863), un personnage voit ses forces s'effondrer. La scène est décrite avec une précision clinique du corps défaillant :

> ses yeux étaient devenus caves et ternes ; des mèches blanches tachetaient sa chevelure ; son visage grimaçait sous des rides précoces et des plaques jaunâtres ; ses mains tremblaient et s'écartaient blêmes, amaigries, sur les bras du fauteuil. Il avait tout à coup vieilli de vingt ans.

Ce mode disparaît du roman d'aventures au même moment où il disparaît du roman policier (rappelons la quasi-extinction des clusters C7 et C24). La convergence avec le roman policier confirme que la perte du registre sentimental hérité du feuilleton est un phénomène de général, commun aux deux genres.

Le cluster C12 (2 380 passages pré-1920, 218 post-1920, −57,4%) capture un registre différent : l'intrigue de cour, le monde aristocratique, le roman historique au sens classique. Les passages représentatifs se déroulent dans les couloirs du pouvoir royal. Chez Dumas (*Les deux Diane* 1846), une princesse prise « entre les devoirs de deux affections » doit prévenir le roi d'un complot sans trahir ses proches ; chez Sue (*Latréaumont*, 1838), un roi sort de sa logette secrète d'où il a espionné des filles d'honneur et « se jeta sur son lit, pour se reposer de tant d'horribles agitations ». Ce registre est indissociable du roman historique de cape et d'épée tel qu'il existait au XIXe siècle, où l'aventure servait de prétexte au déploiement d'intrigues politiques et sentimentales dans un cadre aristocratique. Sa contraction reflète l'autonomisation du roman historique comme genre séparé, qui emporte avec lui son registre propre.

Ce que le genre a gagné. Le cluster C33 (1 228 passages pré-1920, 1 602 post-1920, +507%, Δ prop = +0,124) est le mode en plus forte expansion. Il capture le registre de la survie et du péril physique : prisonniers qui tentent de s'évader, sentinelles à organiser, corps rampant dans l'obscurité. Chez Moselli (*Les diamants de l'idole*, 1924), un ancien sergent prisonnier dans une grotte obscure réfléchit méthodiquement à sa fuite :

> Il songeait que la fermeture de la porte, fermeture qu'il avait eu le temps de remarquer lorsqu'on l'avait sorti et rentré, était assurée à l'aide d'un simple morceau de fer venu, Dieu savait d'où, et que ce morceau de fer était carré, autrement dit que les angles en étaient aigus. Il était situé, Dogueréau se lé rappelait parfaitement, à environ un mètre du sol. Et l'ancien sergent pensait précisément que, s'il réussissait à s'en approcher et à frotter contre lui les mailles du filet de phormiuga qui l'emprisonnait, il serait libre

Dans un autre passage du même auteur, un personnage « se laissa glisser dans la grotte, la traversa en trois pas, et se coula entre les buissons de roseaux », puis, « rampant à la façon d'un serpent », parcourt cinq fois la distance en ligne droite par prudence. Chez Sémant (*Faradel explorateur*, 1907), auteur et illustrateur de livres pour la jeunesse, l'organisation du service de sentinelles constitue la scène à elle seule. Le registre est celui de l'ingéniosité technique face au danger immédiat : le corps engagé dans un problème concret de survie, sans ornementation sentimentale ni cadre mondain.

Le cluster C27 (720 passages pré-1920, 1,024 post-1920) révèle un registre en expansion, celui du roman de cape et d'épée. Les trois passages les mieux classés proviennent tous des *Trois Mousquetaires* : d'Artagnan recevant une bague sertie de saphirs d'une femme « pleine de mystères », d'Artagnan traversant « la moitié de Paris tout courant ». Le registre est celui du rebondissement, de la course-poursuite dans un monde d'honneur et de panache. Ce résultat peut sembler contradictoire avec la contraction de C12, puisque Dumas est présent dans les deux clusters. Mais les deux modes captent des versants distincts de l'univers dumasien : C12 capte

les intrigues de cour (pouvoir royal, diplomatie secrète), C27 capte l'aventure proprement dite (duels, poursuites).

L'existence de ces deux pôles en expansion, le mode de la survie (C33) et le mode du panache (C27) ne convergent pas vers un genre unifié : ils divergent vers des territoires incompatibles, le premier préfigurant le thriller contemporain, le second perpétuant la tradition du roman de cape et d'épée. C'est cette divergence qui explique la forte dérive du centroïde : le roman d'aventures, après 1920, ne se contracte pas autour d'un prototype mais éclate vers des sous-genres qui n'ont plus en commun que l'étiquette générique. Là où le policier converge (C1 et C17 relèvent tous deux du paradigme de l'enquête), l'aventure diverge (C33 et C27 relèvent de paradigmes inconciliables). Dans le policier, un seul cluster (C1) absorbe 28% de la production post-1930 ; dans les aventures, les clusters en expansion croissent de manière plus équilibrée, sans qu'aucun ne domine.

5 Discussion

5.1 Deux logiques de normalisation

Nos résultats mettent en évidence deux logiques distinctes dans le phénomène de normalisation générique que nous avons pu mesurer.

Le roman policier se normalise par une réduction massive du nombre de modes effectifs (DiD $K_{\text{eff}} = -4{,}62$, significatif) associée à une stabilité du centroïde (DiD dérive non significatif). Le genre élimine ses registres hétérogènes et converge vers un noyau étroit de configurations discursives. Ce mécanisme est cohérent avec la concentration éditoriale de l'entre-deux-guerres, dont la collection du Masque est un des exemples typiques. Il ne faudrait pas en conclure que les auteurs ont sagement suivi les règles de Van Dine : celles-ci fonctionnent sans doute moins comme des prescriptions effectivement appliquées que comme le symptôme d'une normalisation déjà en cours, et la codification explicite venant ratifier des conventions que les pratiques éditoriales imposaient par d'autres voies, notamment par le formatage des collections et les attentes du lectorat. La contraction est un long processus qui s'achève dans les années 1960, avant un rebond formel qu'il faudrait valider sur de plus amples corpus. Ce processus n'est d'ailleurs pas propre au roman policier : dans sa théorie du polysystème, Even-Zohar [38] observe qu'aucun modèle littéraire innovant ne se perpétue sans subir ce qu'il nomme une secondarisation, c'est-à-dire une réduction progressive par laquelle les configurations hétérogènes s'homogénéisent et les schémas incompatibles sont éliminés. La contraction de -57% des modes effectifs que nous mesurons apparaît comme une manifestation empirique de ce mécanisme général.

Le roman d'aventures ne se normalise pas vraiment. Nous avons pu mesurer un déplacement significatif du centroïde (DiD dérive $= +0{,}020$, significatif) sans contraction spécifique du nombre de modes (DiD K_{eff} non significatif). Le genre ne converge pas vers un prototype unique puisque les modes en expansion pointent vers des registres distincts, survie, merveilleux scientifique, action violente, qui ne dessinent pas un genre unifié mais les germes de genres autonomes. Le cas du

38. Even-Zohar, « Polysystem Theory ».

merveilleux scientifique est particulièrement éclairant : la catégorie, forgée par Maurice Renard [39] et dont Pézard [40] a retracé la genèse critique, se détache du roman d'aventures pour acquérir ses propres circuits de diffusion, illustrant le processus de centrifugation décrit par Letourneux [41]. Ce mécanisme est cohérent avec l'absence de codification explicite et la position d'ensemble flou que Letourneux attribue au roman d'aventures [42]. En l'absence de noyau thématique resserré, la spécialisation éditoriale n'unifie pas le genre mais le redistribue.

La distinction entre ces deux logiques permet de préciser la notion de normalisation. Normaliser un genre, ce n'est pas nécessairement le rendre homogène. C'est le transformer de sorte que sa production cesse d'être indifférenciée par rapport au reste de la littérature. Cette transformation peut prendre la forme d'une convergence vers un prototype, comme dans le policier, ou d'une divergence vers des sous-genres spécialisés, comme dans l'aventure. Dans les deux cas, le genre quitte le terreau indifférencié du roman-feuilleton du XIXe siècle, mais il le quitte dans des directions opposées.

5.2 La mort du feuilleton

Les deux genres perdent, dans l'entre-deux-guerres, les mêmes registres sentimentaux, mélodramatiques et moralisateurs hérités du roman-feuilleton. Cette convergence des pertes reflète le phénomène de fond décrit dans notre état de l'art : la sortie progressive du feuilleton vers la monographie de genre, portée par les collections éditoriales spécialisées, impose une division du travail narratif qui élimine les registres hybrides. Le roman policier ne peut plus être un roman d'amour accessoirement criminel ; le roman d'aventures ne peut plus être un mélodrame familial accessoirement exotique.

Précisons toutefois que ce qui disparaît n'est pas tant la passion elle-même que son expression mélodramatique. Le roman policier postérieur ne manque pas d'affects, mais il les exprime autrement : plus sexuels que sentimentaux dans le roman noir américain, plus laconiques que déclamatoires chez Simenon, plus cyniques que tragiques dans le néo-polar. Claude-Edmonde Magny a analysé cette transformation chez les romanciers américains, montrant que le *behaviourisme* littéraire réduit la psychologie du personnage à une succession d'actes observables de l'extérieur [43]. Comme l'a montré Cadin [44], ce modèle narratif explose en France après la seconde guerre mondiale, avec l'arrivée du *hardboiled*. Nos clusters captent donc non seulement une évolution propre au genre policier, mais aussi une transformation plus large des codes littéraires : l'expression mélodramatique des affects, encore possible en 1900, est devenue désuète en 1940, dans le roman policier comme dans le reste de la production romanesque.

39. Renard, op. cit.
40. Pézard, op. cit.
41. Letourneux, op. cit., p. 232.
42. Idem, *Le roman d'aventures*.
43. Magny, op. cit., p. 50–51.
44. Cadin, op. cit.

5.3 Limites

Le corpus d'aventures s'arrête en 1948, ce qui ne laisse que 19 fenêtres d'observation post-1920 et limite la puissance statistique de nos estimations pour ce genre. Le corpus policier post-1945 repose exclusivement sur le corpus de référence annoté par des chercheurs spécialistes, environ 157 textes pour 65 ans, ce qui réduit la précision des estimations pour la période contemporaine. Le contrôle à 8 romans par fenêtre protège contre les biais de densité, mais ne compense pas un éventuel manque de représentativité.

Un point important concerne la composition du corpus policier. Celui-ci résulte de la jointure entre deux ensembles : un corpus de référence annoté manuellement par des chercheurs spécialistes du genre, et un corpus de romans étiquetés automatiquement comme policiers par un classifieur lexical entraîné sur le premier ensemble. Ce classifieur, décrit au chapitre précédent, atteint une précision de près de 90% sur l'ensemble de test, ce qui signifie qu'une fraction des textes qu'il sélectionne ne relèvent pas du genre policier au sens strict. Le risque de circularité est le suivant : le classifieur sélectionne des textes sur la base de traits lexicaux du crime et de la justice, puis nos métriques analysent l'évolution de ces mêmes textes. Toutefois, la circularité est limitée par le fait que le classifieur opère sur le vocabulaire de surface, tandis que les métriques de normalisation opèrent sur des embeddings contextuels qui captent des régularités bien plus larges que le seul lexique criminel. Ce que nous mesurons n'est donc pas la tautologie d'un lexique qui se reconnaît lui-même, mais l'évolution des configurations discursives globales de textes qui partagent un vocabulaire de départ. Il reste que le biais de sélection favorise les textes mobilisant un lexique du crime, y compris lorsque ces textes relèvent encore du roman-feuilleton et ne correspondent pas pleinement à ce qui deviendra le roman policier au sens codifié. Ce que nous décrivons n'est donc peut-être pas, au sens strict, la normalisation du genre policier, mais plus largement la professionnalisation progressive de la manière dont la fiction française traite le thème du crime. La contraction que nous mesurons correspond à l'alignement graduel d'un large ensemble de récits criminels sur un paradigme discursif de plus en plus spécialisé, dont la reconnaissance médiatique constitue simplement un accélérateur.

Conclusion

> Die Entschälung des Gegenstandes aus seiner Hülle, die Zertrümmerung der Aura, ist die Signatur einer Wahrnehmung, deren « Sinn für das Gleichartige in der Welt » so gewachsen ist, daß sie es mittels der Reproduktion auch dem Einmaligen abgewinnt. So bekundet sich im anschaulichen Bereich was sich im Bereich der Theorie als die zunehmende Bedeutung der Statistik bemerkbar macht.
>
> *Walter Benjamin. « Das Kunstwerk im Zeitalter seiner technischen Reproduzierbarkeit ».* Gesammelte Schriften. *Sous la dir. de Rolf Tiedemann et Hermann Schweppenhäuser. Frankfurt am Main : Suhrkamp, 1974 [1936], p. 464*
>
> L'extraction de l'objet hors de son enveloppe, la destruction de son aura, constitue la marque d'une perception dont « le sens pour ce qui est semblable dans le monde » s'est accru au point que, par la reproduction, elle annexe aussi l'unique. Ainsi se manifeste, dans la sphère de la contemplation, ce qui, dans celle de la théorie, apparaît d'une importance croissante, soit la statistique.
>
> *Walter Benjamin.* L'œuvre d'art à l'époque de sa reproductibilité technique. *Trad. par Lionel Duvoy. Paris : Éditions Allia, 2012 [1936], p. 16*

Cette thèse a proposé une étude quantitative de la littérature de genre, cet immense champ de la fiction romanesque qui s'étend du roman-feuilleton de la monarchie de Juillet aux collections spécialisées du XXe siècle, et qui a constitué lors des deux derniers siècles le mode dominant de production et de consommation de la fiction. L'introduction partait d'un constat selon lequel la plus grande partie de cette littérature a disparu de la mémoire de la discipline. La littérature *hors d'usage* de Cohen [45], l'*archive* massive que Moretti [46] oppose au *canon*, sont des témoins importants des pratiques culturelles de notre époque contemporaine. Les quelques dizaines de romans que l'histoire littéraire a retenues pour chaque genre ne suffisent pas à rendre compte des processus par lesquels les formes narratives se stabilisent, circulent et se transforment. Ces processus se jouent à l'échelle de milliers de textes, sur des décennies, et ils sont portés par des centaines de romans dont aucun, pris isolément, n'en constitue le moment décisif.

45. Cohen, *The sentimental education of the novel*, p. 20.
46. Moretti, « The Slaughterhouse of Literature ».

Cette thèse s'est donc appliquée à élargir la focale, maniant de larges corpus allant jusqu'aux 12 000 romans numérisés de Gallica dont la plupart sont sortis de toute mémoire littéraire. Des romans d'aventures publiés chez Ferenczi ou Tallandier que plus personne ne lit, des récits policiers parus dans des collections bon marché de l'entre-deux-guerres, des feuilletons judiciaires du Second Empire. Nous avons tenté de remettre en usage cette littérature de genre oubliée, non pas pour en revendiquer la valeur esthétique, mais pour observer ce qu'elle rend visible lorsqu'on la traite à grande échelle. Les méthodes que nous avons mobilisées (classification supervisée, représentations vectorielles, extraction d'information narrative, modélisation en réseau) ne sont pas, dans cette perspective, un supplément technique ajouté aux études littéraires. Elles opérationnalisent des phénomènes que la théorie avait identifiés mais que les moyens de la lecture proche ne permettaient pas de suivre, en les rendant observables à l'échelle où ils se déploient réellement.

À l'issue de notre parcours, il est difficile de proposer une lecture sensationnaliste de ce que les approches computationnelles peuvent apporter à l'étude de la littérature. Nous avons certes ouvert l'enquête à des corpus imposants de par leur taille, mais nos résultats n'ont pas mis à mal les théoriciens de la littérature de genre. Au contraire, la plupart des hypothèses sur lesquelles nous avons fondé nos travaux ont été vérifiées, appuyées, peut-être précisées par nos modèles, mais jamais renversées. Que dire alors de l'appel de Moretti, qui invitait à lire *moins* afin de mener une réelle histoire de la littérature ? Nous avons lu moins, et nous avons lu autrement, par le geste interprétatif de la statistique. Mais ce geste ne fait pas sens sans des liens profonds avec la théorie littéraire. Les méthodes computationnelles sont un mode d'approche des textes, pas un substitut à leur interprétation. Nous en avons autant appris sur nos propres pratiques de classification, sur les perspectives que nous projetons sur les textes, sur ce que la modélisation fait à nos objets et à nos concepts, que sur les textes eux-mêmes. Construire un classifieur de genres, c'est expliciter ce que l'on met dans une catégorie, et découvrir que les frontières que l'on croyait nettes ne le sont pas. Le cœur de la thèse réside en quelque sorte dans le constat que la définition de notions complexes se dérobe dès qu'on la formalise.

6 Apports

Un des résultats de notre thèse concerne la genèse du roman policier en tant que genre autonome. La thèse posait la question de savoir si l'avènement de catégories spécifiques (le « roman policier », le « roman d'aventures ») laissait des traces textuelles mesurables et des effets quantifiables sur la production. En décomposant le genre en trois dimensions formelles indépendantes, la persistance du thème criminel tout au long du récit, la centralité du personnage du détective dans le réseau des personnages, et une intrigue tirée vers la résolution, nous avons montré que ces traits se cristallisaient progressivement entre 1866 et 1930, c'est-à-dire bien avant la stabilisation médiatique et éditoriale du terme. Les éléments formels du roman policier préexistent à son affirmation contextuelle. Ce résultat n'invalide pas ce que les historiens du genre savaient déjà, mais il en fournit une caractérisation empirique et quantitative qui permet de départager deux modèles explicatifs de la cristallisation générique (génie fondateur ou

accumulation collective), en faveur du second.

Pour la théorie des genres, cela rend explicite un phénomène peu décrit jusque là. Si les traits formels du roman policier se cristallisent dans les textes avant que la catégorie ne se stabilise dans les discours médiatiques et dans les collections, alors le genre comme catégorie institutionnelle ne crée pas les régularités formelles. Il vient après coup nommer, et fixer quelque chose qui existait déjà à l'état diffus dans la production romanesque. Un roman policier n'est pas policier en vertu de propriétés intrinsèques. Il l'est parce qu'il s'inscrit dans une pratique culturelle, un ensemble de discours, de supports, d'attentes de lecture historiquement situées qui constituent le genre comme catégorie partagée. Nos modèles n'accèdent pas à cette dimension pragmatique. Ce qu'ils captent, c'est la trace que ces pratiques laissent dans les textes, les régularités lexicales, discursives, structurelles qui se sédimentent lorsqu'un genre se constitue comme horizon d'écriture et de lecture. Que cette trace soit mesurable et qu'elle dessine des structures cohérentes dans l'espace des textes ne signifie pas que le genre se réduit à des propriétés formelles. Cela signifie que les pratiques culturelles dont le genre est le nom finissent par s'incorporer dans la matière même des textes, et que cette incorporation est suffisamment régulière pour être captée par des modèles statistiques.

L'introduction annonçait que nous chercherions à observer « les empreintes formelles des conditions matérielles et institutionnelles de production » de la littérature de genre. Les travaux de Kalifa et Mollier sur la culture de masse, de Letourneux dans *fictions à la chaîne*, de Bourdieu sur la pression normative du champ littéraire décrivent des mécanismes par lesquels les contraintes éditoriales et sérielles façonnent les textes. Nos mesures ajoutent à ces analyses une trace quantitative de ces processus, avec notamment le chapitre 9 qui a montré un long processus de normalisation formelle. L'avènement des collections spécialisées de l'entre-deux-guerres, le Masque pour le policier, les collections de Ferenczi et Tallandier pour l'aventure, s'accompagne d'une contraction mesurable de l'espace des possibles discursifs. Le roman policier élimine ses registres périphériques et converge vers un noyau procédural. Le roman d'aventures se fragmente en sous-genres qui s'autonomisent et emportent chacun une partie de l'espace narratif initial. Les deux trajectoires partagent la perte d'une même substance, celle des registres sentimentaux et mélodramatiques hérités du roman-feuilleton. La collection ne se contente pas de regrouper des textes partageant des propriétés communes. Elle reconfigure activement l'espace de ce qui peut être écrit et lu comme relevant du genre, en rendant certaines formes et en écartant d'autres.

L'aller-retour entre lecture distante et lecture proche que l'on a opéré notamment dans l'analyse des cas limites a produit des interprétations qui nous ont permis d'éclairer les phénomènes à l'étude. En effet, dans ces cas-limites se dessinent la frontière entre ce que nos modèles peuvent et ne peuvent pas saisir. Les faux positifs du classifieur de genres, des parodies, des guides pratiques, des romans d'avant-garde classés « aventure » sur la foi de quelques mots de surface, ont précisé ce que le modèle captait et ce qu'il ne captait pas. Les faux négatifs du détecteur de détectives, un Maigret en vacances, un Juve présumé mort, ont rendu compte des conditions dans lesquelles l'archétype se dessine. Le duel de Flaubert, classé « danger » alors qu'il tourne au grotesque, a mis au jour une limite constitutive de l'approche. Ces cas représentent les endroits où la trace formelle cesse de coïncider avec la réalité contextuelle du genre. Le Maigret en vacances reste

un détective, tout lecteur le sait, mais formellement il échappe à la signature du genre parce que l'enquête est absente. Le duel de Flaubert est conforme au scénario de danger, mais il en subvertit la fonction. Les modèles détectent la matière des conventions, pas leur modalisation. Ils captent ce que les pratiques culturelles du genre ont sédimenté dans les textes, mais pas la manière dont un texte singulier se positionne par rapport à cette sédimentation, s'y conforme, la détourne ou la parodie.

La thèse a parcouru un large spectre de méthodes computationnelles, des plus anciennes aux plus récentes. Nous sommes partis des représentations les plus simples, le sac de mots et le calcul de fréquences relatives, pour aller vers la modélisation statistique supervisée (chapitre 5, chapitre 6, chapitre 8), la structuration non supervisée par graphes de similarité (chapitre 5, chapitre 8) ou par regroupement (chapitre 9), la détection automatique de thèmes (chapitre 7), l'utilisation de modèles de langue pour extraire des représentations de personnages (chapitre 6) ou de passages (chapitre 9), et enfin l'annotation de scènes par des grands modèles génératifs (chapitre 7, chapitre 8). Ce parcours n'avait pas pour ambition de dresser un catalogue, mais de montrer que chaque question littéraire appelle sa propre instrumentation. Aucune de ces méthodes, prise isolément, n'aurait produit de connaissance sur la littérature de genre. Le retour systématique aux cas-limites, en lecture proche, a permis de comprendre comment ces transformations computationnelles impactaient nos textes, nos genres et nos personnages. Par la même occasion, cela nous a permis, nous l'espèrons, de réellement apporter à la connaissance des manières dont nous produisons et consommons des objets culturels.

Plus généralement, cette approche en quelque sorte géométrique de la littérature, permise par les représentations vectorielles des textes, a rendu tangible un mode d'interrogation des textes que l'on doit aux structuralistes. L'idée fondamentale, celle que Kristeva formulait en parlant du texte comme absorption et transformation d'autres textes, est qu'un texte ne signifie pas par lui-même mais par les relations qu'il entretient avec d'autres textes. Les représentations vectorielles donnent à cette intuition une traduction concrète. Dans l'espace que dessinent nos modèles, les romans se rapprochent ou s'éloignent selon des régularités qui ne coïncident pas exactement avec les étiquettes que l'histoire littéraire leur attribue. Le roman policier forme un agrégat identifiable, mais ses frontières sont graduelles. Il existe des zones de transition entre le policier et le feuilleton judiciaire, entre le policier de détection et le roman noir. Le roman d'aventures forme lui un regroupement plus diffus, plus poreux, traversé par des sous-genres (le roman de cape et d'épée, le merveilleux scientifique, l'aventure coloniale) qui tirent le genre dans des directions divergentes. Cette géométrie n'est pas une propriété abstraite des modèles. Elle correspond à l'expérience de tout lecteur qui hésite à classer un Gaboriau entre le roman judiciaire et le feuilleton sentimental, ou un Verne entre le roman d'aventures et le merveilleux scientifique. La différence, c'est que le modèle permet de situer ces incertitudes dans un espace et de les comparer systématiquement.

7 Perspectives

En se limitant à la production francophone, cette thèse n'a pas pu observer les phénomènes de circulation transnationale qui sont pourtant constitutifs de l'histoire de la littérature de genre. Le roman policier français se constitue dans un dialogue permanent avec la tradition anglo-saxonne, Poe traduit par Baudelaire, le *whodunit* de Christie et Doyle importés par Le Masque, le *hardboiled* américain diffusé par la Série Noire. Mais comme le montre Letourneux à propos des échanges franco-italiens des Trente Glorieuses [47], la circulation transnationale des fictions criminelles ne se joue pas seulement au niveau des œuvres canoniques. Elle engage des séries culturelles entières, collections, formats, coproductions, portées par les mêmes logiques industrielles de sérialisation que celles dont nous avons mesuré les effets sur la normalisation des genres. Le roman d'aventures français s'exporte massivement vers d'autres langues, avec notamment Dumas, Sue et Verne qui font toujours partie des auteurs les plus traduits au monde. Une partie de ce que nous mesurons comme normalisation formelle reflète probablement des effets d'importation et de collaboration transnationale que notre dispositif monolingue ne peut pas saisir.

Eco, dans *Innovation et répétition* [48], formule un programme que la recherche n'a pas encore pleinement réalisé.

> Le problème est qu'il n'y a pas, d'un côté, une esthétique du « grand » art (originel et non sériel), et de l'autre une pure sociologie de la série. Il y aurait plutôt une esthétique des formes sérielles, qui exige une étude historique et anthropologique des manières dont, à différentes époques et en différents lieux, la dialectique entre répétition et innovation s'est trouvée illustrée.

Cette thèse a exploré plus d'un siècle de production sérielle, mais elle n'a pas exploré les lieux. Les processus de sédimentation, de circulation et de normalisation que nous avons observés dans la fiction française ne peuvent se comprendre pleinement que dans une perspective internationale. Le roman policier et le roman d'aventures ne sont pas des productions nationales en espace clos. Ce sont des genres qui circulent, se traduisent, s'importent et se remodèlent en traversant les frontières.

La dimension transnationale de ces dynamiques est attestée dès les origines. La vague des mystères urbains qui déferle sur l'Europe après le succès des *Mystères de Paris* de Sue (1842-1843) constitue l'un des premiers exemples documentés de diffusion sérielle d'un modèle générique à l'échelle du continent [49]. Ce phénomène de *mysterymania*, où un même patron narratif est importé, dans une atmosphère plongée dans les bas-fonds de la modernité, traduit et reconfiguré de ville en ville, préfigure les logiques de circulation qui structureront le roman policier tout au long du siècle suivant.

47. Matthieu Letourneux. « Une culture populaire européenne ? Circulation franco-italienne des fictions criminelles dans l'Europe des Trente Glorieuses ». *Contemporary French and Francophone Studies* 2025, p. 9-28. DOI : 10.1080/17409292.2025.2454158.

48. Eco, op. cit., p. 20.

49. Thérenty, « Mysterymania. Essor et limites de la globalisation culturelle au XIXe siècle » ; Letourneux, « Les "mystères urbains", expression d'une modernité énigmatique ».

Moretti [50] a proposé de penser la littérature du XIXe siècle comme un système structuré par des rapports de centre et de périphérie. Deux centres dominent l'espace littéraire européen, pour des raisons différentes. L'Angleterre par sa puissance économique et impériale, la France par le prestige intellectuel issu des Lumières et de la Révolution. Ces deux centres exportent des formes narratives, le roman réaliste, le feuilleton, le *detective novel*, le roman d'aventures, que les littératures périphériques importent, traduisent et reconfigurent selon leurs propres contextes.

Pour les genres qui nous occupent cette perspective nous semble décisive, et plusieurs questions en découlent : les transformations de la figure du détective que nous avons identifiés au chapitre 6 correspondent-ils à des phases partagées par les traditions anglaise, allemande, scandinave, ou bien sont-ils propres à la trajectoire française ? La fragmentation du roman d'aventures est-elle un phénomène proprement français, lié à l'absence de codification dans cette tradition nationale, ou bien une tendance qui traverse l'ensemble des littératures européennes au moment où le genre éclate en sous-genres spécialisés ? Plus fondamentalement, les formes se diffusent-elles effectivement des centres vers les périphéries, comme le postule Moretti, ou bien les périphéries produisent-elles des innovations formelles qui remontent vers les centres ?

Le prolongement naturel de ce travail serait de constituer des corpus comparables dans plusieurs langues européennes et d'y appliquer les mêmes méthodes. Les obstacles sont considérables, avec une numérisation inégale, des outils de traitement des langues de maturité variable et la nécessité d'une expertise littéraire dans chaque tradition nationale. Mais les avancées récentes en modélisation multilingue rendent cette perspective moins lointaine qu'elle ne l'était il y a dix ans. L'esthétique des formes sérielles qu'appelait Eco a trouvé, dans cette thèse, quelques instruments de mesure.

50. Franco Moretti. *Atlas of the European novel : 1800-1900*. London : Verso, 1998.

Liste des publications

Articles de revues

- *Hors d'usage : Curated French Fiction from Gallica, 1800–1950*
  Barré, J.
  Journal of Open Humanities Data, 12, 2026.
  DOI 10.5334/johd.597

- *Toward an Ontological Representation of Fictional Characters*
  Bourgois, A. ; **Barré, J.** ; Seminck, O. ; Poibeau, T.
  Journal of Computational Humanities Research (Cambridge University Press), 2026.
  DOI 10.1017/chr.2026.10025

- *BookNLP-fr, the French Versant of BookNLP. A Tailored Pipeline for 19th and 20th Century French Literature*
  Mélanie-Becquet, F. ; **Barré, J.** ; Seminck, O. ; Plancq, C. ; Naguib, M. ; Pastor, M. ; Poibeau, T.
  Journal of Computational Literary Studies, 3(1), 1–34, 2024.
  DOI 10.48694/jcls.3924

- *Operationalizing Canonicity : A Quantitative Study of French 19th and 20th Century Literature*
  Barré, J. ; Camps, J.-B. ; Poibeau, T.
  Journal of Cultural Analytics, 8(1), 2023.
  DOI 10.22148/001c.88113

Articles de conférences

- *In Search of Lost Adventure Novels : Supervised Genre Retrieval and Corpus Refinement in Gallica*
  Barré, J.
  Proceedings of the 6th International Conference on Natural Language Processing for the Digital Humanities (NLP4DH 2026), Association for Computational Linguistics, San Diego, USA, Jul. 2026, 255–263. 10.18653/v1/2026.nlp4dh-1.24

- *Birth of the Detective, Birth of a Genre*
  Barré, J.
  Digital Humanities 2026 (DH2026), Séoul, Corée du Sud, Jul. 2026. hal-05623518.

- *Modeling the Construction of a Literary Archetype : The Case of the Detective Figure in French Fiction*
  Barré, J. ; Seminck, O. ; Bourgois, A. ; Poibeau, T.
  Conference on Computational Humanities Research (CHR 2025), Esch-sur-Alzette, Luxembourg, Dec. 2025. DOI 10.63744/SMbYIWcHZj87 ; arXiv 2511.00627.

- *Patterns of Canon : A Multilingual Network Study*
  Brottrager, J. ; **Barré, J.** ; Bizzoni, Y. ; Feldkamp-Moreira, P.
  Conference on Computational Humanities Research (CHR 2025), Esch-sur-Alzette, Luxembourg, Dec. 2025. DOI 10.63744/Y0dv4ooACREY.

- *The Times Are a-Changin' : présent vs passé simple in French novels (1811–2020)*
  Gabay, S. ; **Barré, J.** ; Cafiero, F.
  Digital Humanities Benelux (DH Benelux 2025), Amsterdam, Pays-Bas, Jun. 2025. hal-04984105.

- *Latent Structures of Intertextuality in French Fiction*
  Barré, J.
  Conference on Computational Humanities Research (CHR 2024), Aarhus, Denmark, Dec. 2024. Proceedings ; arXiv 2410.17759.

- *Network Analysis, Plot Theory : Revisiting French Literature through Character Networks*
  Chen, N. ; Mélanie-Becquet, F. ; **Barré, J.** ; Poibeau, T.
  Digital Humanities 2024 (DH2024), Washington, D.C., Aug. 2024. abstract.

- *Détection automatique de l'architextualité dans le roman d'aventures*
  Barré, J.
  Humanistica 2024, Association francophone des humanités numériques, Meknès, Maroc, May 2024. hal-04559749.

- *Beyond Canonicity. Modeling Canon/Archive Literary Change in French Fiction*
  Barré, J. ; Poibeau, T.
  Conference on Computational Humanities Research (CHR 2023), Paris, France, Dec. 2023. Proceedings ; hal-04279087.

- *Gender Bias in French Literature*
  Vianne, L. ; Dupont, Y. ; **Barré, J.**
  Conference on Computational Humanities Research (CHR 2023), Paris, France, Dec. 2023. Proceedings.

- *Pour une détection automatique de l'espace personnage dans les romans*

  Barré, J. ; Cabrera-Ramirez, P. ; Mélanie-Becquet, F. ; Galleron, I.

  Humanistica 2023, Association francophone des humanités numériques, Genève, Suisse, Jun. 2023. hal-04105537.

- *Event Annotation for Literary Corpora Analysis*

  Grunspan, C. ; Mélanie-Becquet, F. ; **Barré, J.** ; Chardon, L. ; Galleron, I. ; Naguib, M. ; Plancq, C. ; Seminck, O. ; Poibeau, T.

  Digital Humanities 2022 (DH2022), Tokyo, Japon, Jul. 2022. hal-03738806.

Bibliographie

Généralités

Allen, Graham. *Intertextuality*. London, New York : Routledge, Taylor & Francis Group, 2022 (cf. p. 27).

Arendt, Hannah. « The Crisis in Culture : Its Social and Its Political Significance. Six Exercises in Political Thought ». *Between Past and Future*. Penguin Books, 1977 [1961], p. 197-226 (cf. p. 1).

— *La crise de la culture*. Paris : Gallimard, 2013 [1961] (cf. p. 1).

Aristote. *La poétique*. Trad. par Roselyne Dupont-Roc et Jean Lallot. Paris : Éditions du Seuil, 1980 [335 BCE] (cf. p. 31, 33, 134).

Artiaga, Loïc et Matthieu Letourneux. *Aux origines de la pop culture : le Fleuve noir et les Presses de la Cité au cœur du transmédia à la française, 1945-1990*. Paris : la Découverte, 2022 (cf. p. 101).

Assouline, Pierre. *Simenon : biographie*. Paris : Julliard, 1992 (cf. p. 101).

Bakhtine, Mikhaïl. « The Problem of Speech Genres ». *Speech Genres and Other Late Essays*. Sous la dir. de Caryl Emerson et Michael Holquist. Trad. par Vern W. McGee. Austin : University of Texas Press, 1986 [1952-1953], p. 60-102 (cf. p. 37, 38, 215).

Barbey d'Aurevilly, Jules. *Romanciers d'hier et d'avant-hier*. Paris : A. Lemerre, 1904 (cf. p. 191).

Baroni, Raphaël. *La tension narrative : suspense, curiosité et surprise*. Paris : Éditions du Seuil, 2007 (cf. p. 165).

Barthes, Roland. « Introduction à l'analyse structurale des récits ». *Communications* 1966, p. 1-27. doi : 10.3406/comm.1966.1113 (cf. p. 132, 135).

— *Texte (théorie du)*. 1974. url : https://www.universalis-edu.com/encyclopedie/theorie-du-texte/ (cf. p. 11).

— *S/Z*. Paris : Éditions du Seuil, 1996 [1970] (cf. p. 38, 135).

— « De l'œuvre au texte ». *Le bruissement de la langue*. Paris : Éditions Points, 2015 [1971] (cf. p. 12).

— « La mort de l'auteur ». *Le bruissement de la langue*. Paris : Éditions Points, 2015 [1968] (cf. p. 12).

Becker, Lucille F. *Georges Simenon*. Boston, Mass : Twayne, 1977 (cf. p. 154).

Béhar, Henri. *La littérature et son golem*. Paris : H. Champion, 1996 (cf. p. 18).

Benjamin, Walter. « Das Kunstwerk im Zeitalter seiner technischen Reproduzierbarkeit ». *Gesammelte Schriften*. Sous la dir. de Rolf Tiedemann et Hermann Schweppenhäuser. Frankfurt am Main : Suhrkamp, 1974 [1936] (cf. p. 253).

— *L'œuvre d'art à l'époque de sa reproductibilité technique*. Trad. par Lionel Duvoy. Paris : Éditions Allia, 2012 [1936] (cf. p. 253).

Blanckeman, Bruno. *Lire Patrick Modiano*. Paris : Armand Colin, 2014 (cf. p. 115).

Boisvert, Jayne R. « Introducing Fred Vargas : Commissioner Adamsberg, the Anti-flic as Interpreter of Signs ». *The French Review* 2012, p. 826-836. doi : 10.1353/tfr.2012.0228 (cf. p. 154).

Bonniot, Roger. *Émile Gaboriau ou La naissance du roman policier*. Paris : Vrin, 1985 (cf. p. 112, 165, 167).

Borges, Jorge Luis. *Borges, a reader : a selection from the writings of Jorge Luis Borges*. New York : Dutton, 1981 [1936] (cf. p. 164).

Bourdieu, Pierre. *Les Règles de l'art : Genèse et structure du champ littéraire*. Paris : Éditions du Seuil, 1992 (cf. p. 2, 4, 230).

Braudel, Fernand, éd. *La Méditerranée : l'espace et l'histoire*. Paris : Flammarion, 2001 [1949] (cf. p. 21).

Breiman, Leo. « Statistical Modeling : The Two Cultures ». *Statistical Science* 2001, p. 199-215 (cf. p. 60).

Brunetière, Ferdinand. *L'évolution des genres dans l'histoire de la littérature*. Paris : Hachette, 1914 (cf. p. 35).

Cadin, Anne. « Le moment américain du roman français : 1945-1950 ». Thèse de doct. Paris : Classiques Garnier, 2018 (cf. p. 117, 153, 246, 251).

Campbell, Lyle. *Historical linguistics : an introduction*. Edinburgh : Edinburgh University Press, 2013 (cf. p. 14).

Casanova, Pascale. *La république mondiale des lettres*. Paris : Éditions du Seuil, 2008 (cf. p. 2).

Cawelti, John G. *Adventure, mystery, and romance : formula stories as art and popular culture*. Chicago, Ill. : The Univ. of Chicago Press, 1997 [1976] (cf. p. 3, 134, 153, 171, 194, 230).

Chartier, Roger. « Textes, imprimés, lectures ». *Pour une sociologie de la lecture : lecture et lecteurs dans la France contemporaine*. Paris : Éditions du Cercle de la librairie, 1988 (cf. p. 170).

Cohen, Margaret. *The sentimental education of the novel*. Princeton : Princeton University press, 1999 (cf. p. 1, 253).

Colin, Jean-Paul. *Le roman policier français archaïque : un essai de lecture groupée*. Berne : Lang, 1984 (cf. p. 117, 171).

— *La belle époque du roman policier français. Aux origines d'un genre romanesque*. Paris : Delachaux et Niestlé, 1999. doi : 10.3917/deni.colin.1999.01 (cf. p. 171).

Compagnon, Antoine. *Théorie de la littérature : la notion de genre. Cours de M. Antoine Compagnon*. 2001 (cf. p. 33).

— *La seconde main ou Le travail de la citation*. Paris : Éditions Points, 2016 [1979] (cf. p. 12).

Compère, Daniel. « Le roman d'aventures policières au XIXe siècle ». *Poétiques du roman d'aventures*. Sous la dir. d'Alain-Michel Boyer et Daniel Couégnas. Nantes : Université de Nantes, 2004 (cf. p. 111).

Darwin, Charles. *L'origine des espèces au moyen de la sélection naturelle ou La préservation des races favorisées dans la lutte pour la vie*. Paris : Flammarion, 2008 [1859] (cf. p. 17).

Deleuze, Gilles et Félix Guattari. *Mille plateaux*. Paris : Éditions de Minuit, 2009 [1980] (cf. p. 14).

Dubois, Jacques. « Naissance du récit policier ». *Actes de la Recherche en Sciences Sociales* 1985, p. 47-55. doi : 10.3406/arss.1985.2287 (cf. p. 175).

— *Le roman policier ou La modernité*. Paris : Nathan, 1992 (cf. p. 165).

— *L'institution de la littérature*. Loverval : Éditions Labor, 2005 [1978] (cf. p. 169).

Dumasy, Lise. *La querelle du roman-feuilleton : littérature, presse et politique, un débat précurseur (1836-1848)*. Grenoble : ELLUG-Université Stendhal, 1999 (cf. p. 168).

Duncan, Dennis. « The Protean Ptyx : Nonsense, Non-Translation, and Word Magic in Mallarmé's 'Sonnet en yx' ». *Modernism and Non-Translation*. Oxford University PressOxford, 2019, 34-C3.P71. doi : 10.1093/oso/9780198821441.003.0003 (cf. p. 24).

Eco, Umberto. « Innovation and Repetition : Between Modern and Post-Modern Aesthetics ». *Daedalus* 1985, p. 161-184 (cf. p. 4, 225, 230, 257).

— *Lector in fabula*. Paris : Librairie Générale Française, 2018 [1979] (cf. p. 4, 193, 194).

Ellison, Murray S. « Edgar Allan Poe and Science : Unraveling the Plot of the Universe ». Master's thesis. Virginia Commonwealth University, 2015 (cf. p. 134).

Even-Zohar, Itamar. « Polysystem Theory ». *Poetics Today* 1990, p. 9-26. doi : 10.2307/1772666 (cf. p. 16, 250).

Flaubert, Gustave. *L'Éducation sentimentale*. Sous la dir. de Pierre-Marc de Biasi. Paris : Librairie Générale Française, 2018 (cf. p. 214).

Forster, Edward Morgan. *Aspects of the novel*. London : Penguin Books, 1988 [1927] (cf. p. 135).

Fort, Camille. « Détectives et décalogues : pour une éthique de l'enquête ? » *Études anglaises* 2003, p. 285-297. doi : 10.3917/etan.563.0285 (cf. p. 103).

Fortassier, Rose. *Le roman français du XIXe siècle*. Paris : Pr. Univ. de France, 1995 [1982] (cf. p. 164).

Fowler, Alastair. *Kinds of Literature - An Introduction to the Theory of Genres and Modes*. Oxford : Oxford University Press, 2002 [1982] (cf. p. 59).

Frow, John. *Genre*. London ; New York : Routledge, 2006 (cf. p. 41).

Gaboriau, Émile. *L'affaire Lerouge*. Paris : Éditions du Masque, 2013 [1866] (cf. p. 123, 124, 133).

Gagnon, Katerine. « Coup de théâtre angotien ». *Spirale* 2005, p. 48-49 (cf. p. 115).

Gasparov, Mikhail. « Boris Yarkho's works on literary theory ». *Studia Metrica et Poetica* 2017, p. 130-150. doi : 10.12697/smp.2016.3.2.05 (cf. p. 48).

Genette, Gérard. *Figures. I*. Paris : Éditions du Seuil, 1966 (cf. p. 15).

— *Figures III*. Paris : Éditions du Seuil, 1972 (cf. p. 195).

— *Palimpsestes : la littérature au second degré*. Paris : Éditions du Seuil, 1982 (cf. p. 5, 38, 39).

— « Introduction à l'architexte ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986, p. 110-148 (cf. p. 5, 15, 32, 33, 48).

— *Seuils*. Paris : Éditions du Seuil, 1987 (cf. p. 39).

— *Figures IV*. Paris : Éditions du Seuil, 1999 (cf. p. 38).

— *Métalepse. De la figure à la fiction*. Paris : Le Seuil, 2004 (cf. p. 38).

Gerson, Noel B. *The Vidocq dossier : the story of the world's first detective*. Boston : Houghton Mifflin, 1977 (cf. p. 134).

Goethe, Johann Wolfgang von. *Divan d'Orient et d'Occident*. Paris : les Belles lettres, 2012 (cf. p. 33).

Gonon, Laetitia. « Mythes et démystification dans le roman policier de Fred Vargas ». *Recherches & Travaux* 2010, p. 119-135. doi : 10.4000/recherchestravaux.434 (cf. p. 165).

Goscinny, René et Gotlib. *Les Dingodossiers*. Paris : Dargaud, 1967. 91 p. (cf. p. 132).

Greimas, Algirdas Julien. *Sémantique structurale : recherche de méthode*. Paris : Presses Universitaires de France, 2015 [1966] (cf. p. 135).

Hamon, Philippe. *Le personnel du roman : le système des personnages dans les Rougon-Macquart d'Emile Zola*. Genève : Droz, 1998 [1983] (cf. p. 135).

— *Du descriptif*. Hachette Éducation, 2014 (cf. p. 135).

Houppermans, Sjef. « Les Gommes : un roman policier poli et scié ». *Roman 20-50* 2010, p. 97-110. doi : 10.3917/r2050.hs6.0097 (cf. p. 128, 154).

Hurlbert, Stuart H. « The Nonconcept of Species Diversity : A Critique and Alternative Parameters ». *Ecology* 1971, p. 577-586. doi : 10.2307/1934145 (cf. p. 238).

Jakobson, Roman. *Questions de poétique*. Paris : Éditions du Seuil, 1973 (cf. p. 37).

Jannidis, Fotis. *Figur und Person : Beitrag zu einer historischen Narratologie*. De Gruyter, 2008. doi : 10.1515/9783110201697 (cf. p. 135).

— « Character ». *the living handbook of narratology*. Hamburg : Hamburg University, 2013 (cf. p. 135, 136).

Jauss, Hans Robert. « Littérature médiévale et théorie des genres ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986 [1970] (cf. p. 15, 41, 59, 162).

— *Pour une esthétique de la réception*. Paris : Gallimard, 2005 [1978] (cf. p. 41).

Jouve, Vincent. « Pour une analyse de l'effet personnages ». *Littérature* 1992, p. 103-111 (cf. p. 132, 135).

Kalifa, Dominique. *La culture de masse en France. 1 : 1860 - 1930*. Paris : Éditions La Découverte, 2001 (cf. p. 3, 28, 43).

— « Policier, détective, reporter : Trois figures de l'enquêteur dans la France de 1900 ». *Mil neuf cent* 2004, p. 15. doi : 10.3917/mnc.022.0015 (cf. p. 133).

— *Crime et culture au XIXe siècle*. Paris : Perrin, 2005 (cf. p. 110).

— *Les bas-fonds histoire d'un imaginaire*. Paris : Éditions du Seuil, 2013 (cf. p. 43, 110, 112).

Kincaid, Paul. « On the Origins of Genre ». *Extrapolation* 2003, p. 409-419. doi : 10.3828/extr.2003.44.4.04 (cf. p. 163).

Knox, Ronald. « Introduction ». *The Best Detective Stories of 1928–29*. Sous la dir. de Dorothy L. Sayers. London : Faber & Faber, 1929, p. 9-15 (cf. p. 103, 229).

Kristeva, Julia. « Le texte clos ». *Langages* 1968, p. 103-125. doi : 10.3406/lgge.1968.2356 (cf. p. 11).

— *Sèmèiotikè : recherches pour une sémanalyse*. Paris : Éditions Point, 2017 [1969] (cf. p. 5, 11).

Lacassin, Francis. *Mythologie du roman policier*. Paris : Christian Bourgois, 1993 [1974] (cf. p. 165).

Lamarck, Jean-Baptiste Pierre Antoine de Monet de. *Philosophie zoologique*. Paris : Éditions Flammarion, 1996 [1809] (cf. p. 17).

Lanson, Gustave. *Hommes et livres : études morales et littéraires*. Hachette livre-bnf, 1895 (cf. p. 1).

Lavergne, Elsa de. *La naissance du roman policier français : du Second Empire à la Première Guerre mondiale*. Paris : Classiques Garnier, 2009 (cf. p. 133, 148, 171-174, 183, 184, 186).

Leblanc, Maurice. *Les confidences d'Arsène Lupin*. Bibebook, 2013 [1913] (cf. p. 175).

Lee, Maurice S. « Edgar Allan Poe (1809–1849) ». *A Companion to Crime Fiction*. Sous la dir. de Charles J. Rzepka et Lee Horsley. Wiley, 2010, p. 369-380. doi : 10.1002/9781444317916.ch29 (cf. p. 166).

Leroux, Gaston. *Le mystère de la chambre jaune : Rouletabille*. Paris : Le Livre de Poche, 2001 [1907] (cf. p. 121, 122, 124).

Letourneux, Matthieu. « Les "mystères urbains", expression d'une modernité énigmatique ». *Alla ricerca delle radici popolari della cultura europea, Looking for the Roots of European Popular Culture*. Bologne, Italy, 2009 (cf. p. 42, 257).

— *Le roman d'aventures : 1870-1930*. Limoges : Presses Universitaires de Limoges et du Limousin, 2010 (cf. p. 192, 197, 216, 226, 227, 229, 251).

— « Le genre comme pratique historique ». *Belphégor* 2016. doi : 10.4000/belphegor.732 (cf. p. 40, 56, 60).

— *Fictions à la chaîne : littératures sérielles et culture médiatique*. Paris : Éditions du Seuil, 2017 (cf. p. 3, 16, 18, 103, 191, 194, 228, 229, 231, 237, 251).

— « Le genre comme fait de discours : pour une définition molle de la science-fiction ». *ReS Futurae* 2022. doi : 10.4000/resf.11405 (cf. p. 56).

— « Le genre comme pratique historique et médiatique (1860-1940) ». *Les Genres du roman au xixe siècle*. Classiques Garnier, 2022. doi : 10.48611/ISBN.978-2-406-12980-6.P.0339 (cf. p. 42-44).

— « Une culture populaire européenne ? Circulation franco-italienne des fictions criminelles dans l'Europe des Trente Glorieuses ». *Contemporary French and Francophone Studies* 2025, p. 9-28. doi : 10.1080/17409292.2025.2454158 (cf. p. 257).

Letourneux, Matthieu et Pierre-Carl Langlais. *Fictions Policières*. YouTube video. 2019 (cf. p. 55).

Letourneux, Matthieu et Jean-Yves Mollier. *La Librairie Tallandier : histoire d'une grande maison d'édition populaire, 1870-2000*. Paris : Nouveau monde éd, 2011 (cf. p. 228).

Levet, Natacha. *Le roman noir, une histoire française*. Paris : Presses Universitaires de France / Humensis, 2024 (cf. p. 154).

Lojkine, Stéphane. *La scène de roman : méthode d'analyse*. Paris : Armand Colin, 2002 (cf. p. 195).

Lvoff, Basil. « Distant Reading in Russian Formalism and Russian Formalism in Distant Reading ». *Russian Literature* 2021, p. 29-65. doi : 10.1016/j.ruslit.2021.07.003 (cf. p. 48).

Magny, Claude-Edmonde. *L'âge du roman américain*. Paris : Éditions du Seuil, 1948 (cf. p. 246, 251).

Maingueneau, Dominique. *Genèses du discours*. Bruxelles : Mardaga, 1989 (cf. p. 88).

Margolin, Uri. « Characterization in narrative : Some theoretical prolegomena ». *Neophilologus* 1983, p. 1-14. doi : 10.1007/BF01956983 (cf. p. 134, 135).

Martinetti, Anne. *Le Masque : histoire d'une collection*. Amiens : Encrage, 1997 (cf. p. 101, 227).

McKee, Robert. *Story : Substance, Structure, Style, and the Principles of Screenwriting*. New York : ReganBooks, 1997 (cf. p. 135).

Messac, Régis. *Le "Detective Novel" et l'influence de la pensée scientifique*. Genève : Slatkine Reprints, 1975 [1929] (cf. p. 101, 134, 164, 170, 226).

Mittell, Jason. *Genre and Television : From Cop Shows to Cartoons in American Culture*. London : Routledge, 2004 (cf. p. 230).

Moisan, Clément. « Les genres comme catégorie de l'histoire littéraire ». *L'Histoire littéraire aujourd'hui*. Sous la dir. d'Henri Béhar et Roger Fayolle. Paris : Armand Colin, 1990 (cf. p. 34).

Mollier, Jean-Yves. *L' argent et les lettres : histoire du capitalisme d'édition ; 1880 - 1920*. Paris : Fayard, 1988 (cf. p. 3, 231).

Monroe, Burt L., Michael P. Colaresi et Kevin M. Quinn. « Fightin' Words : Lexical Feature Selection and Evaluation for Identifying the Content of Political Conflict ». *Political Analysis* 2017, p. 372-403. doi : 10.1093/pan/mpn018 (cf. p. 141).

Montaigne, Michel de. *Les Essais*. Sous la dir. de P. Villey et V.-L. Saulnier. Online edition by P. Desan, University of Chicago, 1595 (cf. p. 11).

Moretti, Franco. « On Literary Evolution ». *Signs Taken for Wonders : Essays in the Sociology of Literary Forms*. London : Verso, 1997 [1983], p. 262-278 (cf. p. 17).

— *Atlas of the European novel : 1800-1900*. London : Verso, 1998 (cf. p. 258).

— « Conjectures on World Literature ». *New Left Review* 2000, p. 54-68 (cf. p. 2, 21).

— « The Slaughterhouse of Literature ». *Modern Language Quarterly* 2000, p. 207-228. doi : 10.1215/00267929-61-1-207 (cf. p. 2, 253).

— *Graphs, maps, trees : abstract models for a literary history*. London ; New York : Verso, 2005 (cf. p. 2, 18).

— *Distant reading*. London : Verso, 2013 (cf. p. 21).

Morin, Edgar. *La méthode. 1 : La nature de la nature*. Paris : Éditions du Seuil, 1977 (cf. p. 15).

Mukařovský, Jan. *Aesthetic Function, Norm and Value as Social Facts*. Trad. par Mark E. Suino. Ann Arbor, MI : University of Michigan Press, 1970 [1936], p. 102 (cf. p. 16).

Narcejac, Thomas. *Une machine à lire, le roman policier*. Paris : Denoël/Gonthier, 1975 (cf. p. 162).

Neale, Stephen. *Genre and Hollywood*. London : Routledge, 2005 (cf. p. 230).

Paige, Nicholas D. *Technologies of the Novel : Quantitative Data and the Evolution of Literary Systems*. Cambridge University Press, 2020. doi : 10.1017/9781108890861 (cf. p. 4).

Pennebaker, James W. *The secret life of pronouns : what our words say about us*. New York : Bloomsbury Press, 2011 (cf. p. 80, 105).

Pézard, Emilie. « Défense et illustration d'un genre. Le merveilleux scientifique défini par Maurice Renard (1909-1928) ». *ReS Futurae. Revue d'études sur la science-fiction* 2018. doi : 10.4000/resf.1383 (cf. p. 237, 251).

Pézard, Émilie et Valérie Stiénon. « Introduction ». *Les genres du roman au XIXe siècle*. Classiques Garnier, 2022. doi : 10.48611/ISBN.978-2-406-12980-6.P.0007 (cf. p. 40, 42).

Poe, Edgar Allan. *Histoires extraordinaires*. Trad. par Charles Baudelaire. Paris : Michel Lévy Frères, 1856 (cf. p. 164).

— *Eureka : la genèse d'un poëme ; Le corbeau ; Méthode de composition*. Trad. par Charles Baudelaire. Avec des annot. de Jacques Crépet. Paris : L. Conard, 1936 [1848] (cf. p. 165, 171).

Pollock, Griselda. *Differencing the canon : feminist desire and the writing of art's histories*. London ; New York : Routledge, 1999, p. 10 (cf. p. 2).

Propp, Vladimir Iakovlevitch. *Morphologie du conte*. Trad. par Marguerite Derrida, Tzvetan Todorov et Claude Kahn. Paris : Éditions Points, 2015 [1928] (cf. p. 135).

Queffélec, Lise. *Le roman-feuilleton français au XIXe siècle*. Paris : Presses Univ. de France, 1989 (cf. p. 170).

Renard, Maurice. « Du roman merveilleux-scientifique et de son action sur l'intelligence du progrès ». *ReS Futurae. Revue d'études sur la science-fiction* 2018. doi : 10.4000/resf.1201 (cf. p. 237, 251).

Rieder, John. « De l'avantage (ou non) de définir la science-fiction : théorie des genres, science-fiction et Histoire ». *ReS Futurae* 2013. doi : 10.4000/resf.489 (cf. p. 57, 163).

Riffaterre, Michael. « Intertextual Representation : On Mimesis as Interpretive Discourse ». *Critical Inquiry* 1984, p. 141-162. doi : 10.1086/448279 (cf. p. 12).

Riguet, Marine. « Le sacre d'une littérature palimpseste ? » *Des humanités numériques littéraires ?* Cerisy, France : Didier Alexandre, Marc Douguet et Milad Doueihi, 2017 (cf. p. 13, 14).

— « Pour une histoire naturelle de la littérature ». *La Littérature et la Vie*. Paris : Classiques Garnier, 2018, p. 33-49. doi : 10.15122/isbn.978-2-406-06743-6.p.0033 (cf. p. 35).

Rosch, Eleanor et Carolyn B Mervis. « Family resemblances : Studies in the internal structure of categories ». *Cognitive Psychology* 1975, p. 573-605. doi : 10.1016/0010-0285(75)90024-9 (cf. p. 59).

Ryan, Marie-Laure. *Possible worlds, artificial intelligence and narrative theory*. Bloomington, Ind. : Indiana Univ. Press, 1991 (cf. p. 135).

Said, Edward W. *L'orientalisme : l'Orient créé par l'Occident*. Trad. par Catherine Malamoud, Sylvestre Meininger et Claude Wauthier. Paris : Éditions du Seuil, 2005 [1978] (cf. p. 193).

Sainte-Beuve, Charles-Augustin. *De la littérature industrielle*. Paris : Éditions Allia, 2013 [1839] (cf. p. 3, 168).

Saussure, Ferdinand de. *Cours de linguistique générale*. Sous la dir. de Charles Bally, Albert Sechehaye et Albert Riedlinger. Paris : Payot, 1971 [1916] (cf. p. 13).

Schaeffer, Jean-Marie. « Du texte au genre ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986 (cf. p. 31, 32, 34, 35, 40).

— *Qu'est-ce qu'un genre littéraire ?* Paris : Éditions du Seuil, 1989 (cf. p. 15, 32, 36, 42).

Schlegel, August Wilhelm. *Vorlesungen über dramatische Kunst und Literatur (1809–1811) : Teilband 1 : Text*. Leiden, The Netherlands : Brill | Schöningh, 2018 [1809]. doi : 10.30965/9783657778546 (cf. p. 33).

Scholes, Robert. « Les modes de la fiction ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986 [1974] (cf. p. 162).

Segalen, Victor. *Essai sur l'exotisme : une esthétique du divers*. Paris : Librairie Générale Française, 2009 [1978] (cf. p. 192).

Simenon, Georges. « Le Romancier ». *Le Roman de l'Homme*. Lausanne : Éditions de l'Aire, 1980, p. 73-103 (cf. p. 116).

Sobchuk, Oleg. « Evolution of Modern Literature and Film ». *Oxford Handbook of Cultural Evolution*. Sous la dir. de Jamshid J. Tehrani, Jeremy Kendal et Rachel L. Kendal. Oxford University Press, 2023, p. 554-564. doi : 10.1093/oxfordhb/9780198869252.013.45 (cf. p. 16).

Souchier, Emmanuël. *Raymond Queneau*. Paris : Éditions du Seuil, 1991 (cf. p. 114).

Stetenfeld, Nicolas. *Voyage au pays des collections d'aventures : les éditions Jules Tallandier*. 2023. url : https://www.bila.ink/voyage-au-pays-des-collections-daventures-les-editions-jules-tallandier/ (visité le 27/02/2026) (cf. p. 228).

— *Voyage au pays des collections de romans d'aventures : les éditions J. Ferenczi*. 2023. url : https://www.bila.ink/voyage-au-pays-des-collections-de-romans-daventures-les-editions-j-ferenczi/ (visité le 27/02/2026) (cf. p. 228).

Sue, Eugène. *Kernok le pirate*. Paris : Gallimard, 1983 [1830] (cf. p. 208).

Tadié, Jean-Yves. *Le roman d'aventures*. Paris : Gallimard, 2013 [1982] (cf. p. 195).

Thérenty, Marie-Ève. « Pour une poétique historique du support ». *Romantisme* 2009, p. 109-115. doi : 10.3917/rom.143.0109 (cf. p. 170).

— « Mysterymania. Essor et limites de la globalisation culturelle au XIXe siècle ». *Romantisme* 2013, p. 53-64. doi : 10.3917/rom.160.0053 (cf. p. 43, 257).

Todorov, Tzvetan. « L'héritage méthodologique du formalisme ». *Poétique de la prose*. Paris : Éditions du Seuil, 1971 (cf. p. 48).

— *Introduction à la littérature fantastique*. Paris : Éditions du Seuil, 1976 (cf. p. 32).

— *Les Genres du discours*. Paris : Éditions du Seuil, 1978 (cf. p. 41).

— « Typologie du roman policier ». *Poétique de la prose*. Paris : Éditions du Seuil, 1980 [1966] (cf. p. 44, 102, 133, 162, 165).

— « L'origine des genres ». *La notion de littérature et autres essais*. Paris : Éditions du Seuil, 1987, p. 27-46 (cf. p. 41, 163).

Tomachevski, Boris. « Thématique ». *Théorie de la littérature : textes des formalistes russes*. Sous la dir. de Tzvetan Todorov. Paris : Éditions du Seuil, 2001 [1925] (cf. p. 37, 194).

Tynianov, Iouri. « De l'évolution littéraire ». *Théorie de la littérature : textes des formalistes russes*. Sous la dir. de Tzvetan Todorov. Paris : Éditions du Seuil, 2001 [1927] (cf. p. 13, 15, 37).

Van Dine, S. S. « Twenty Rules for Writing Detective Stories ». *American Magazine* 1928, p. 129-131 (cf. p. 103, 229).

Vareille, Jean-Claude. « Roman policier archaïque et aventure archaïque ». *L'Aventure dans la littérature populaire au xixe siècle*. Sous la dir. de Roger Bellet. Lyon : Presses universitaires de Lyon, 1985, p. 185-196. doi : 10.4000/books.pul.1232 (cf. p. 152).

— « Préhistoire du roman policier ». *Romantisme* 1986, p. 23-36. doi : 10.3406/roman.1986.4922 (cf. p. 125).

— *L'Homme masqué, le justicier et le détective*. Presses universitaires de Lyon, 1989 (cf. p. 163).

Verne, Jules. *Voyage au centre de la Terre*. Paris : Flammarion, 2014 [1864] (cf. p. 208).

— *Vingt mille lieues sous les mers*. Paris : 10/18, 2024 [1869] (cf. p. 212, 213).

Veyne, Paul. *Comment on écrit l'histoire*. Paris : Éditions du Seuil, 1989 (cf. p. 55).

Viëtor, Karl. « L'histoire des genres littéraires ». *Théorie des genres*. Sous la dir. de Gérard Genette et Tzvetan Todorov. Paris : Éditions du Seuil, 1986 (cf. p. 33, 39).

Weber, Anne-Gaëlle. « Le récit de voyage et l'émergence de la littérature au tournant des xviiie et xixe siècles ». *Viatica* 2020. doi : 10.52497/viatica1265 (cf. p. 218).

Wellek, René et Austin Warren. *Theory of literature*. New York, Harcourt, Brace & World, 1956 (cf. p. 16).

Willard Huntington Wright. « The Great Detective Stories ». *The Art of the Mystery Story*. New York : Grosset & Dunlap, 1947, p. 33-70 (cf. p. 134).

Wittgenstein, Ludwig. *Philosophical Investigations*. Trad. par G. E. M. Anscombe. Oxford : Basil Blackwell, 1958 [1953] (cf. p. 58).

— *Tractatus logico-philosophicus suivi de Investigations philosophiques*. Sous la dir. de Pierre Klossowski et Bertrand Russell. Paris : Gallimard, 1989 [1953] (cf. p. 58).

Yarkho, Boris I. « Speech Distribution in Five-Act Tragedies (A Question of Classicism and Romanticism) ». *Journal of Literary Theory* 2019, p. 13-76. doi : 10.1515/jlt-2019-0002 (cf. p. 48).

Méthodes et approches computationnelles

Aggarwal, Charu C., Alexander Hinneburg et Daniel A. Keim. « On the Surprising Behavior of Distance Metrics in High Dimensional Space ». *Database Theory — ICDT 2001*. Sous la dir. de Jan Van den Bussche et Victor Vianu. Berlin, Heidelberg : Springer Berlin Heidelberg, 2001, p. 420-434 (cf. p. 233).

Algee-Hewitt, Mark, Sarah Allison, Marissa Gemma, Ryan Heuser, Hannah Walser et Franco Moretti. « Canon/Archive. Large-scale Dynamics in the Literary Field ». *Pamphlets of the Stanford Literary Lab* 2016 (cf. p. 18, 21).

Algee-Hewitt, Mark, Erik Fredner et Hannah Walser. « The Novel as Data ». *The Cambridge Companion to the Novel*. Sous la dir. d'Eric Bulson. Cambridge University Press, 2018, p. 189-216. doi : 10.1017/9781316659694.013 (cf. p. 22).

Allen, Timothy, Charles Cooney et al. « Plundering Philosophers : Identifying Sources of the Encyclopédie ». *Journal of the Association for History and Computing* 2010 (cf. p. 27).

Allison, Sarah, Mark Algee-Hewitt, Ryan R. Heuser, Matthew Jockers, Franco Moretti et Michael Witmore. « Quantitative Formalism : an Experiment ». *Pamphlets of the Stanford Literary Lab* 2011 (cf. p. 22, 48).

Anthropic. *Claude Opus 4 & Claude Sonnet 4 System Card*. 2025 (cf. p. 98, 178).

Bamman, David. *BookNLP*. 2021 (cf. p. 136).

Bamman, David, Kent K. Chang, Li Lucy et Naitian Zhou. « On Classification with Large Language Models in Cultural Analytics ». *Proceedings of the Computational Humanities Research Conference*. Sous la dir. de Wouter Haverals, Marijn Koolen et Laure Thompson. 2024, p. 494-527 (cf. p. 74, 76).

Bamman, David, Olivia Lewke et Anya Mansoor. « An Annotated Dataset of Coreference in English Literature ». *Proceedings of the Twelfth Language Resources and Evaluation Conference*. Sous la dir. de Nicoletta Calzolari, Frédéric Béchet et al. Marseille, France : European Language Resources Association, 2020, p. 44-54 (cf. p. 69, 136).

Bamman, David, Sejal Popat et Sheng Shen. « An annotated dataset of literary entities ». *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1 (Long and Short Papers)*. Minneapolis, Minnesota : Association for Computational Linguistics, 2019, p. 2138-2144. doi : 10.18653/v1/N19-1220 (cf. p. 70).

Bamman, David, Ted Underwood et Noah A. Smith. « A Bayesian Mixed Effects Model of Literary Character ». *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*. Baltimore, Maryland : Association for Computational Linguistics, 2014, p. 370-379. doi : 10.3115/v1/P14-1035 (cf. p. 69, 136).

Barré, Jean. « Détection automatique de l'architextualité dans le roman d'aventures (1870–1930). » *Humanistica 2024*. Association francophone des humanités numériques. Meknès, Maroc, 2024 (cf. p. 207).

— « Latent Structures of Intertextuality in French Fiction ». *Proceedings of the Computational Humanities Research Conference 2024*. CHR 2024. Aarhus, 2024, p. 21-26 (cf. p. 79, 89).

— « Birth of the detective, birth of a genre ». *DH 2026 Book of Abstracts*. Séoul, South Korea, 2026.

— « Hors d'usage : Curated French Fiction from Gallica, 1800–1950 ». *Journal of Open Humanities Data* 2026. DOI : 10.5334/johd.597 (cf. p. 69).

— « In Search of Lost Adventure Novels : Supervised Genre Retrieval and Corpus Refinement in Gallica ». *Proceedings of the 6th International Conference on Natural Language Processing for the Digital Humanities*. Sous la dir. de Sil HAMILTON, Emily ÖHMAN et al. San Diego, USA : Association for Computational Linguistics, 2026, p. 255-263. DOI : 10.18653/v1/2026.nlp4dh-1.24.

BARRÉ, Jean, Pedro CABRERA RAMÍREZ, Frédérique MÉLANIE et Ioanna GALLERON. « Pour une détection automatique de l'espace personnage dans les romans ». *Humanistica 2023*. Genève, Suisse, 2023 (cf. p. 69, 137).

BARRÉ, Jean, Jean-Baptiste CAMPS et Thierry POIBEAU. « Operationalizing Canonicity : A Quantitative Study of French 19th and 20th Century Literature ». *Journal of Cultural Analytics* 2023. DOI : 10.22148/001c.88113 (cf. p. 21, 65, 91).

BARRÉ, Jean, Olga SEMINCK, Antoine BOURGOIS et Thierry POIBEAU. « Modeling the Construction of a Literary Archetype : The Case of the Detective Figure in French Literature ». *Computational Humanities Research 2025*. Sous la dir. de Taylor ARNOLD, Margherita FANTOLI et Ruben ROS. Anthology of Computers et the Humanities, 2025, p. 983-999. DOI : 10.63744/smbyiwchzj87 (cf. p. 132).

BARRON, Alexander T. J., Jenny HUANG, Rebecca L. SPANG et Simon DEDEO. « Individuals, institutions, and innovation in the debates of the French Revolution ». *Proceedings of the National Academy of Sciences* 2018, p. 4607-4612. DOI : 10.1073/pnas.1717729115 (cf. p. 17).

BEAUDOUIN, Valérie. « Retour aux origines de la statistique textuelle : Benzécri et l'école française d'analyse des données ». *JADT 2016*. Sous la dir. de Damon MAYAFFRE, Cédric POUDAT, Ludovic VANNI et al. Nice, France, 2016, p. 17-27 (cf. p. 20).

BENTZ, Christian, Dimitrios ALIKANIOTIS, Michael CYSOUW et Ramon FERRER-I-CANCHO. « The Entropy of Words—Learnability and Expressivity across More than 1000 Languages ». *Entropy* 2017, p. 275. DOI : 10.3390/e19060275 (cf. p. 17).

BENZÉCRI, Jean-Paul. *L'Analyse des données*. Paris Bruxelles Montréal : Dunod, 1973 (cf. p. 20).

BIBER, Douglas. *Variation across Speech and Writing*. Cambridge : Cambridge University Press, 1988 (cf. p. 51).

— « A Typology of English Texts ». *Linguistics* 1989, p. 3-43. DOI : 10.1515/ling.1989.27.1.3 (cf. p. 51).

BLEI, David M., Andrew Y. NG et Michael I. JORDAN. « Latent Dirichlet Allocation ». *Journal of Machine Learning Research* 2003, p. 993-1022 (cf. p. 80, 174).

BLONDEL, Vincent D, Jean-Loup GUILLAUME, Renaud LAMBIOTTE et Etienne LEFEBVRE. « Fast unfolding of communities in large networks ». *Journal of Statistical Mechanics : Theory and Experiment* 2008, P10008. DOI : 10.1088/1742-5468/2008/10/P10008 (cf. p. 94).

BOURGOIS, Antoine, Jean BARRÉ, Olga SEMINCK et Thierry POIBEAU. « Toward an Ontological Representation of Fictional Characters ». *Journal of Computational Humanities Research* 2026, p. 1-15. DOI : 10.1017/chr.2026.10025 (cf. p. 132).

BOURGOIS, Antoine et Thierry POIBEAU. *The Elephant in the Coreference Room : Resolving Coreference in Full-Length French Fiction Works*. 2025. arXiv : 2510.15594 [cs.CL] (cf. p. 70, 71, 137).

BROTTRAGER, Judith, Jean BARRÉ, Yuri BIZZONI et Pascale Feldkamp MOREIRA. « Patterns of Canon : A Multilingual Network Study ». *Computational Humanities Research 2025*. Sous la dir. de Taylor ARNOLD, Margherita FANTOLI et Ruben ROS. Anthology of Computers et the Humanities, 2025, p. 76-94. DOI : 10.63744/Y0dv4ooACREY.

BROTTRAGER, Judith, Annina STAHL, Arda ARSLAN, Ulrik BRANDES et Thomas WEITIN. « Modeling and Predicting Literary Reception. A Data-Rich Approach to Literary Historical Reception ». *Journal of Computational Literary Studies* 2022. DOI : 10.48694/jcls.95 (cf. p. 21).

BRUNET, Étienne. *Le vocabulaire de Proust*. Genéve : Slatkine, 1983 (cf. p. 20).

BÜCHLER, Marco, Gregory CRANE, Maria MORITZ et Alison BABEU. « Increasing Recall for Text Re-use in Historical Documents to Support Research in the Humanities ». *Lecture Notes in Computer Science*. Springer Berlin Heidelberg, 2012, p. 95-100. DOI : 10.1007/978-3-642-33290-6_11 (cf. p. 27).

BURROWS, J. « 'Delta' : a Measure of Stylistic Difference and a Guide to Likely Authorship ». *Literary and Linguistic Computing* 2002, p. 267-287. DOI : 10.1093/llc/17.3.267 (cf. p. 79).

— « All the Way Through : Testing for Authorship in Different Frequency Strata ». *Literary and Linguistic Computing* 2007. DOI : 10.1093/llc/fqi067 (cf. p. 53).

Calvo Tello, José. *The Novel in the Spanish Silver Age : A Digital Analysis of Genre Using Machine Learning*. Bielefeld University Press, 2021. doi : 10.1515/9783839459256 (cf. p. 52, 54, 55).

Camps, Jean-Baptiste et Julien Randon-Furling. « Lost Manuscripts and Extinct Texts : A Dynamic Model of Cultural Transmission ». *Proceedings of the Workshop on Computational Humanities Research (CHR 2022)*. CEUR Workshop Proceedings, 2022 (cf. p. 14).

Chen, Jianlv, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian et Zheng Liu. *BGE M3-Embedding : Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. 2024. arXiv : 2402.03216[cs] (cf. p. 82).

Chen, Newman, Frédérique Mélanie-Becquet, Jean Barré et Thierry Poibeau. « Network Analysis, Plot Theory : Revisiting French Literature through Character Networks ». *Digital Humanities (DH2024)*. ADHO. Washington DC, United States, 2024 (cf. p. 176).

— « Network Analysis, Plot Theory : Revisiting French Literature through Character Networks ». *Digital Humanities (DH2024)*. ADHO. Washington DC, United States, 2024.

Cortes, Corinna et Vladimir Vapnik. « Support-vector networks ». *Machine Learning* 1995, p. 273-297. doi : 10.1007/BF00994018 (cf. p. 199, 210).

Courson, Benoît de et Benjamin Azoulay. « Gallicagram : un outil de lexicométrie pour la recherche » 2021. doi : 10.31235/osf.io/84bf3 (cf. p. 166, 225).

Cranenburgh, Andreas van, Karina van Dalen-Oskam et Joris van Zundert. « Vector space explorations of literary language ». *Language Resources and Evaluation* 2019, p. 625-650. doi : 10.1007/s10579-018-09442-4 (cf. p. 82).

Cranenburgh, Andreas van, Laura Allen, Serge Sharoff et Karina van Dalen-Oskam. « Computational methods for the analysis of fiction genres ». *Multidisciplinary Views on Discourse Genre*. Routledge, 2024 (cf. p. 52).

DeDeo, Simon. *Information Theory for Intelligent People*. 2018 (cf. p. 17).

Delahaye, Jean-Paul et Nicolas Gauvrit. *Culturomics : le numérique et la culture*. Paris : Odile Jacob, 2013 (cf. p. 23).

Devlin, Jacob, Ming-Wei Chang, Kenton Lee et Kristina Toutanova. « BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding ». *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota : Association for Computational Linguistics, 2019, p. 4171-4186. doi : 10.18653/v1/N19-1423 (cf. p. 77).

Du, Keli, Julia Dudar, Cora Rok et Christof Schöch. « Zeta & Eta : An Exploration and Evaluation of Two Dispersion-based Measures of Distinctiveness ». *CEUR Workshop Proceedings*. 2021 (cf. p. 53).

Du, Keli, Julia Dudar et Christof Schöch. « Evaluation of measures of distinctiveness : Classification of literary texts on the basis of distinctive words » 2022. doi : 10.48694/JCLS.102 (cf. p. 53).

Eder, Maciej. « Boosting word frequencies in authorship attribution ». *Proceedings of the Computational Humanities Research Conference (CHR 2022)*. CEUR Workshop Proceedings, 2022, p. 387-397 (cf. p. 82).

Ehrmanntraut, Anton, Leonard Konle et Fotis Jannidis. « LLpro : A Literary Language Processing Pipeline for German Narrative Texts ». *Proceedings of the 19th Conference on Natural Language Processing (KONVENS 2023)*. Sous la dir. de Munir Georges, Aaricia Herygers, Annemarie Friedrich et Benjamin Roth. Ingolstadt, Germany : Association for Computational Linguistics, 2023, p. 28-39 (cf. p. 70, 136).

Elson, David, Nicholas Dames et Kathleen McKeown. « Extracting Social Networks from Literary Fiction ». *Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics*. Sous la dir. de Jan Hajič, Sandra Carberry, Stephen Clark et Joakim Nivre. Uppsala, Sweden : Association for Computational Linguistics, 2010, p. 138-147 (cf. p. 176).

Feldkamp, Pascale, Alie Lassche et al. « Canonical Status and Literary Influence : A Comparative Study of Danish Novels from the Modern Breakthrough (1870–1900) ». *Proceedings of the 4th international conference on natural language processing for digital humanities*. Sous la dir. de Mika Hämäläinen, Emily Öhman, So Miyagawa, Khalid Alnajjar et Yuri Bizzoni. Miami, USA : Association for Computational Linguistics, 2024, p. 140-155 (cf. p. 21).

Fruchterman, Thomas M. J. et Edward M. Reingold. « Graph drawing by force-directed placement ». *Software : Practice and Experience* 1991, p. 1129-1164. doi : 10.1002/spe.4380211102 (cf. p. 95).

Gabay, Simon, Jean Barré et Florian Cafiero. « The times are a-changin' : présent vs passé simple in French novels (1811-2024) ». *DH Benelux 2025*. Amsterdam, Netherlands, 2025.

Ganascia, Jean-Gabriel. « Détection automatique de phénomènes intertextuels ». *Genesis* 2020, p. 63-77. doi : 10.4000/genesis.5671 (cf. p. 27).

Ganascia, Jean-Gabriel, Pierre Glaudes et Andrea Del Lungo. *Automatic Detection of Reuses and Citations in Literary Texts*. 2014. doi : 10.48550/ARXIV.1404.2997 (cf. p. 27).

Gao, Tianyu, Xingcheng Yao et Danqi Chen. *SimCSE : Simple Contrastive Learning of Sentence Embeddings*. 2022. arXiv : 2104.08821 [cs.CL] (cf. p. 84).

Gius, Evelyn et Janina Jacke. « Are Computational Literary Studies Structuralist ? » *Journal of Cultural Analytics* 2022, p. 1289. doi : 10.22148/001c.46662 (cf. p. 7).

Grattafiori, Aaron, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey et Abhishek Kadian. *The Llama 3 Herd of Models*. 2024. arXiv : 2407.21783 [cs.AI] (cf. p. 178).

Grunspan, Claude, Frédérique Mélanie-Becquet et al. « Event annotation for literary corpora analysis ». *Digital Humanities 202,. Conference Abstracts,The University of Tokyo, Japan, 25-29 July 2022*. ADHO. Tokyo, Japan : DH2022 Local Organizing Committee, 2022, p. 471-472.

Guo, Daya, Dejian Yang, Haowei Zhang et Junxiao Song. « DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning ». *Nature* 2025, p. 633-638. doi : 10.1038/s41586-025-09422-z (cf. p. 178).

Hatzel, Hans Ole, Haimo Stiemer, Chris Biemann et Evelyn Gius. « Machine Learning in Computational Literary Studies ». *it – Information Technology* 2023, p. 200-217. doi : 10.1515/itit-2023-0041 (cf. p. 75, 76).

Henny-Krahmer, Ulrike. *Genre Analysis and Corpus Design : Nineteenth-Century Spanish-American Novels (1830–1910)*. IDE, 2023 (cf. p. 52, 54, 55).

Hettinger, Lena, Martin Becker, Isabella Reger, Fotis Jannidis et Andreas Hotho. « Genre Classification on German Novels ». *Proceedings of the 26th International Workshop on Database and Expert Systems Applications (DEXA)*. Valencia, Spain : IEEE, 2015, p. 249-253. doi : 10.1109/DEXA.2015.62 (cf. p. 75).

Hettinger, Lena, Fotis Jannidis, Isabella Reger et Andreas Hotho. « Classification of Literary Subgenres ». *DHd 2016 : Modellierung – Vernetzung – Visualisierung*. Leipzig, 2016 (cf. p. 52, 75).

Hughes, James M., Nicholas J. Foti, David C. Krakauer et Daniel N. Rockmore. « Quantitative patterns of stylistic influence in the evolution of literature ». *Proceedings of the National Academy of Sciences* 2012, p. 7682-7686. doi : 10.1073/pnas.1115407109 (cf. p. 90).

Jiang, Albert Q., Alexandre Sablayrolles et al. *Mixtral of Experts*. 2024. arXiv : 2401.04088 [cs.LG] (cf. p. 209).

Jockers, Matthew L. *Macroanalysis : Digital Methods and Literary History*. University of Illinois Press, 2013. doi : 10.5406/illinois/9780252037528.001.0001 (cf. p. 22, 23).

Ju, Meizhi, Makoto Miwa et Sophia Ananiadou. « A Neural Layered Model for Nested Named Entity Recognition ». *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1 (Long Papers)*. Association for Computational Linguistics, 2018, p. 1446-1459 (cf. p. 70).

Kelvin, Lord. « Electrical Units of Measurement ». *Popular Lectures and Addresses*. London : Macmillan, 1889, p. 73-136 (cf. p. 64).

Kessler, Brett, Geoffrey Nunberg et Hinrich Schuetze. *Automatic Detection of Text Genre*. 1997. doi : 10.48550/arXiv.cmp-lg/9707002 (cf. p. 51).

Konle, Leonard, Agnes Hilger et Fotis Jannidis. « On Character Perception and Plot Structure of German Romance Novels ». *Proceedings of the Computational Humanities Research Conference (CHR 2023)*. CEUR Workshop Proceedings, 2023, p. 592-605 (cf. p. 196).

Konle, Leonard et Fotis Jannidis. « Modeling Plots of Narrative Texts as Temporal Graphs ». *Proceedings of the Computational Humanities Research Conference (CHR 2022)*. CEUR Workshop Proceedings, 2022, p. 318-330 (cf. p. 196).

Krug, Markus, Fotis Jannidis, Isabella Reger, Lukas Weimer et Luisa Macharowsky. « Comparison of Methods for the Identification of Main Characters in German Novels ». *Digital Humanities (DH2016)*. ADHO. Kraków, Poland, 2016 (cf. p. 176).

Labatut, Vincent et Xavier Bost. « Extraction and Analysis of Fictional Character Networks : A Survey ». *ACM Computing Surveys* 2019. doi : 10.1145/3344548 (cf. p. 176).

Landis, J. Richard et Gary G. Koch. « The Measurement of Observer Agreement for Categorical Data ». *Biometrics* 1977, p. 159-174 (cf. p. 210).

Langlais, Pierre-Carl. *Reconstituer les genres romanesque sur Gallica : essai de classification automatisée de 1500 romans (1815-1850)*. Billet. 2019 (cf. p. 52, 67, 197).

— *Fictions littéraires de Gallica*. Version 1. 2021. doi : 10.5281/zenodo.4751204 (cf. p. 7, 20, 67, 196, 197).

Le, Quoc V. et Tomas Mikolov. *Distributed Representations of Sentences and Documents*. 2014. arXiv : 1405.4053 [cs.CL] (cf. p. 81).

Lebart, Ludovic et A. Salem. *Statistique textuelle*. Paris : Dunod, 1994 (cf. p. 20).

Leblond, Aude. *Corpus Chapitres*. Version v1.0.0. 2022. doi : 10.5281/zenodo.7446728 (cf. p. 7, 20, 65, 104, 108, 137, 173, 215, 232).

Legallois, Dominique, Thierry Charnois et Thierry Poibeau. « Repérer les clichés dans les romans sentimentaux grâce à la méthode des "motifs" ». *Lidil. Revue de linguistique et de didactique des langues* 2016, p. 95-117. doi : 10.4000/lidil.3950 (cf. p. 53).

Liddle, Dallas. « Could Fiction Have an Information History ? Statistical Probability and the Rise of the Novel ». *Journal of Cultural Analytics* 2019. doi : 10.22148/16.033 (cf. p. 18).

Long, Hoyt et Richard Jean So. « Literary Pattern Recognition : Modernism between Close Reading and Machine Learning ». *Critical Inquiry* 2016, p. 235-267. doi : 10.1086/684353 (cf. p. 26).

Lutoslawski, W. « Principes de stylométrie appliqués à la chronologie des œuvres de Platon ». *Revue des Études Grecques* 1898, p. 61-81. doi : 10.3406/reg.1898.5847 (cf. p. 79).

Manjavacas, Enrique, Folgert Karsdorp et Mike Kestemont. « A Statistical Foray into Contextual Aspects of Intertextuality ». *Proceedings of the Workshop on Computational Humanities Research (CHR 2020)*. CEUR Workshop Proceedings, 2020, p. 77-96 (cf. p. 27).

Martin, Louis, Benjamin Muller et al. « CamemBERT : a Tasty French Language Model ». *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Sous la dir. de Dan Jurafsky, Joyce Chai, Natalie Schluter et Joel Tetreault. Online : Association for Computational Linguistics, 2020, p. 7203-7219. doi : 10.18653/v1/2020.acl-main.645 (cf. p. 70, 72, 138).

McInnes, Leland, John Healy et James Melville. *UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction*. 2020. arXiv : 1802.03426 [stat.ML] (cf. p. 150).

Mélanie-Becquet, Frédérique, Jean Barré et al. « BookNLP-fr, the French Versant of BookNLP. A Tailored Pipeline for 19th and 20th Century French Literature ». *Journal of Computational Literary Studies* 2024, p. 1-34. doi : 10.48694/jcls.3924 (cf. p. 69, 70, 136, 137).

Michel, Jean-Baptiste, Yuan Kui Shen et al. « Quantitative Analysis of Culture Using Millions of Digitized Books ». *Science* 2011, p. 176-182. doi : 10.1126/science.1199644 (cf. p. 23).

MMTEB : Massive Multilingual Text Embedding Benchmark. 2025. arXiv : 2502.13595 [cs.CL] (cf. p. 82).

Moretti, Franco. « Style, Inc. Reflections on Seven Thousand Titles (British Novels, 1740–1850) ». *Critical Inquiry* 2009, p. 134-158. doi : 10.1086/606125 (cf. p. 25).

— « Operationalizing' : or, the function of measurement in modern literary theory ». *Pamphlets of the Stanford Literary Lab* 2013 (cf. p. 21, 22, 48).

— « Literature, Measured ». *Pamphlets of the Stanford Literary Lab* 2016 (cf. p. 22, 48).

Mu, Jiaqi et Pramod Viswanath. *All-but-the-Top : Simple and Effective Postprocessing for Word Representations*. 2018 (cf. p. 84).

Muennighoff, Niklas, Nouamane Tazi, Loïc Magne et Nils Reimers. *MTEB : Massive Text Embedding Benchmark*. 2022 (cf. p. 82).

Muller, Charles. *Principes et méthodes de statistique lexicale*. Paris : Hachette, 1977 (cf. p. 20).

Olsen, Mark. « Signs, Symbols and Discourses : A New Direction for Computer-Aided Literature Studies ». *Computers and the Humanities* 1993, p. 309-314 (cf. p. 20).

Page, Lawrence, Sergey Brin, Rajeev Motwani et Terry Winograd. *The PageRank Citation Ranking : Bringing Order to the Web*. Techreport. 1999 (cf. p. 176).

Pedregosa, F., G. Varoquaux et al. « Scikit-learn : Machine Learning in Python ». *Journal of Machine Learning Research* 2011, p. 2825-2830 (cf. p. 76, 139, 199, 210).

Pincemin, Bénédicte. « Sémantique interprétative et analyses automatiques de textes : que deviennent les sèmes ? » *Sémiotiques* 1999, p. 71-120 (cf. p. 20).

Piper, Andrew. « Fictionality ». *Journal of Cultural Analytics* 2016. doi : 10.22148/16.011 (cf. p. 25).

— « Think Small : On Literary Modeling ». *PMLA/Publications of the Modern Language Association of America* 2017, p. 651-658. DOI : 10.1632/pmla.2017.132.3.651 (cf. p. 25).

— *Enumerations : data and literary study*. Chicago ; London : The University of Chicago Press, 2018 (cf. p. 23).

REIMERS, Nils et Iryna GUREVYCH. « Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks ». *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Sous la dir. de Kentaro INUI, Jing JIANG, Vincent NG et Xiaojun WAN. Hong Kong, China : Association for Computational Linguistics, 2019, p. 3982-3992. DOI : 10.18653/v1/D19-1410 (cf. p. 83, 84).

RIBEIRO, Marco Tulio, Sameer SINGH et Carlos GUESTRIN. « "Why Should I Trust You ?" : Explaining the Predictions of Any Classifier ». *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. KDD '16 : The 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco California USA : ACM, 2016, p. 1135-1144. DOI : 10.1145/2939672.2939778 (cf. p. 26).

ROUSSEEUW, Peter J. « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis ». *Journal of Computational and Applied Mathematics* 1987, p. 53-65. DOI : https://doi.org/10.1016/0377-0427(87)90125-7 (cf. p. 234).

SAVAGE, Patrick E., Steven BROWN, Emi SAKAI et Thomas E. CURRIE. « Statistical universals reveal the structures and functions of human music ». *Proceedings of the National Academy of Sciences* 2015, p. 8987-8992. DOI : 10.1073/pnas.1414495112 (cf. p. 14).

SCHÖCH, Christof. « Zeta für die kontrastive Analyse literarischer Texte. Theorie, Implementierung, Fallstudie ». *Quantitative Ansätze in den Literatur- und Geisteswissenschaften. Systematische und historische Perspektiven*. Sous la dir. de Toni BERNHART, Sandra RICHTER, Marcus LEPPER, Marcus WILLAND et Andrea ALBRECHT. De Gruyter, 2018, p. 77-94. DOI : 10.1515/9783110523300-004 (cf. p. 53).

SEMINCK, Olga, Philippe GAMBETTE, Dominique LEGALLOIS et Thierry POIBEAU. « The Evolution of the Idiolect over the Lifetime : A Quantitative and Qualitative Study of French 19th Century Literature ». *Journal of Cultural Analytics* 2022. DOI : 10.22148/001c.37588 (cf. p. 18).

SINGH, Aaditya, Adam FRY, Adam PERELMAN, Adam TART et Adi GANESH. *OpenAI GPT-5 System Card*. 2025. arXiv : 2601.03267 [cs.CL] (cf. p. 98).

SO, Richard Jean. « "All Models Are Wrong" ». *PMLA/Publications of the Modern Language Association of America* 2017, p. 668-673. DOI : 10.1632/pmla.2017.132.3.668 (cf. p. 24).

SOBCHUK, Oleg. « Charting Artistic Evolution : An Essay in Theory ». PhD thesis. Tartu : University of Tartu, 2018 (cf. p. 164).

SOBCHUK, Oleg et Bret A. BEHEIM. « Does literature evolve one funeral at a time ? » *Proceedings of the Royal Society B : Biological Sciences* 2025, p. 20242033. DOI : 10.1098/rspb.2024.2033 (cf. p. 18, 81).

SOBCHUK, Oleg et Artjoms ŠEĻA. « Computational thematics : comparing algorithms for clustering the genres of literary fiction ». *Humanities and Social Sciences Communications* 2024, p. 1-12. DOI : 10.1057/s41599-024-02933-6 (cf. p. 54, 82).

TIMKEY, William et Marten van SCHIJNDEL. « All Bark and No Bite : Rogue Dimensions in Transformer Language Models Obscure Representational Quality ». *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Sous la dir. de Marie-Francine MOENS, Xuanjing HUANG, Lucia SPECIA et Scott Wen-tau YIH. Online et Punta Cana, Dominican Republic : Association for Computational Linguistics, 2021, p. 4527-4546. DOI : 10.18653/v1/2021.emnlp-main.372 (cf. p. 84).

TOMACHEVSKI, Boris. *O stikhe : stat'i*. Leningrad : Priboj, 1929 (cf. p. 48).

TRAAG, V. A., L. WALTMAN et N. J. van ECK. « From Louvain to Leiden : guaranteeing well-connected communities ». *Scientific Reports* 2019, p. 5233. DOI : 10.1038/s41598-019-41695-z (cf. p. 94).

UNDERWOOD, Ted. « The Life Cycles of Genres ». *Journal of Cultural Analytics* 2016. DOI : 10.22148/16.005 (cf. p. 49, 51, 52, 60, 107).

— « Why Literary Time is Measured in Minutes ». *ELH* 2018, p. 341-365. DOI : 10.1353/elh.2018.0013 (cf. p. 23, 195).

— *Distant horizons : digital evidence and literary change*. Chicago : The University of Chicago Press, 2019 (cf. p. 5, 6, 21, 25, 50, 52, 79, 104, 117).

— « Machine Learning and Human Perspective ». *PMLA* 2020, p. 92-109. DOI : 10.1632/pmla.2020.135.1.92 (cf. p. 118).

Underwood, Ted, Michael L. Black, Loretta Auvil et Boris Capitanu. « Mapping mutable genres in structurally complex volumes ». *2013 IEEE International Conference on Big Data*. 2013 IEEE International Conference on Big Data. Silicon Valley, CA, USA : IEEE, 2013, p. 95-103. doi : 10.1109/BigData.2013.6691676 (cf. p. 25).

Underwood, Ted, Kevin Kiley, Wenyi Shang et Stephen Vaisey. « Cohort Succession Explains Most Change in Literary Culture ». *Sociological Science* 2022, p. 184-205. doi : 10.15195/v9.a8 (cf. p. 18).

Underwood, Ted et Jordan Sellers. « The "Longue Durée" of Literary Prestige ». *Modern Language Quarterly* 2016, p. 321-344. doi : 10.1215/00267929-3570634 (cf. p. 21).

Vaswani, Ashish, Noam Shazeer et al. « Attention Is All You Need ». *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2017 (cf. p. 77, 233).

Wang, Bin, Angela Wang, Fenxiao Chen, Yuncheng Wang et C.-C. Jay Kuo. « Evaluating word embedding models : methods and experimental results ». *APSIPA Transactions on Signal and Information Processing* 2019. doi : 10.1017/ATSIP.2019.12 (cf. p. 84).

Xing, Yi. *Modelling Intertextuality with N-gram Embeddings*. 2025. arXiv : 2509.06637 [cs.CL] (cf. p. 27).

Yoder, Michael, Sopan Khosla et al. « FanfictionNLP : A Text Processing Pipeline for Fanfiction ». *Proceedings of the Third Workshop on Narrative Understanding*. Sous la dir. de Nader Akoury, Faeze Brahman, Snigdha Chaturvedi, Elizabeth Clark, Mohit Iyyer et Lara J. Martin. Virtual : Association for Computational Linguistics, 2021, p. 13-23. doi : 10.18653/v1/2021.nuse-1.2 (cf. p. 137).

Yu, B. « An evaluation of text classification methods for literary study ». *Literary and Linguistic Computing* 2008, p. 327-343. doi : 10.1093/llc/fqn015 (cf. p. 75).

Zehe, Albin, Elisabeth Fischer et Andreas Hotho. « Assessing the State of the Art in Scene Segmentation ». *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics : Human Language Technologies (Volume 1 : Long Papers)*. Sous la dir. de Luis Chiruzzo, Alan Ritter et Lu Wang. Albuquerque, New Mexico : Association for Computational Linguistics, 2025, p. 9922-9941. doi : 10.18653/v1/2025.naacl-long.500 (cf. p. 196).

Zehe, Albin, Leonard Konle et al. « Detecting Scenes in Fiction : A new Segmentation Task ». *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics : Main Volume*. Online : Association for Computational Linguistics, 2021, p. 3167-3177. doi : 10.18653/v1/2021.eacl-main.276 (cf. p. 196).

Ziems, Caleb, William Held, Omar Shaikh, Jiaao Chen, Zhehao Zhang et Diyi Yang. « Can Large Language Models Transform Computational Social Science ? » *Computational Linguistics* 2024, p. 237-291. doi : 10.1162/coli_a_00502 (cf. p. 76).

Zundert, Joris van, Andreas van Cranenburgh et Roel Smeets. « Putting Dutchcoref to the Test : Character Detection and Gender Dynamics in Contemporary Dutch Novels ». *Computational Humanities Research Conference*. CEUR Workshop Proceedings. 2023, p. 757-771 (cf. p. 70, 136).

Annexes

Annexes du Chapitre 8

Romans aberrants retirés

TABLE 10.8 : Romans aberrants retirés du corpus initial (règle : ≥80% de voisins non-aventure ; $n = 113$).

Year	Titre	Prop. non-av.	# vois. non-av.
1817	1817_Ménégault_A.-P.-F._Le-Robinson-du-faubourg-Saint-	1.000000	5
1874	1874_Des-Tilleu_A._La-princesse-aux-violettes	1.000000	5
1878	1878_Roy_Just-Jean-_Laurent-et-Jérôme-ou-Les-deux-	1.000000	5
1856	1856_About_Edmond_Les-mariages-de-Paris	1.000000	6
1878	1878_Maréchal_Marie_Le-mariage-de-Nancy	1.000000	5
1921	1921_Tellier_Jules_Les-deux-paradis-dAbd-Er-Rham	1.000000	5
1901	1901_Deschaumes_Edmond_Lauteur-mondain	1.000000	6
1824	1824_La-Ferté-M_Cesse-de_Léonce-et-Clémence,-ou-La-conf	1.000000	5
1825	1825_Paganel_Camille_Théodora,-ou-la-Famille-chréti	1.000000	7
1885	1885_Dussaud-Ro_Louise_La-promesse-dUrsule	1.000000	6
1937	1937_Silvestre_Charles_Le-vent-du-gouffre	1.000000	6
1834	1834_Kermel_Amédée_Une-âme-en-peine,-par-M.-Amédé	1.000000	8
1863	1863_Valrey_Max_Les-victimes-du-mariage	1.000000	5
1896	1896_Ségur_Sophie-de_Le-mauvais-génie	1.000000	5
1909	1909_Girardin_Jules_La-famille-Gaudry	1.000000	7
1876	1876_Bernardin-_Henri_Paul-et-Virginie	1.000000	5

Continue à la page suivante

Year	Titre	Prop. non-av.	# vois. non-av.
1802	1802_Castéra_Désirée-de_Armand-et-Angéla	1.000000	6
1849	1849_Filleul-de_Clara_Le-Dévouement-fraternel,-suivi	1.000000	5
1838	1838_David_Jules_Le-club-des-désoeuvrés	1.000000	5
1853	1853_Foudras_Théodore-d_Suzanne-dEstouteville	1.000000	7
1883	1883_Girardin_Jules_La-vocation-de-Paul-Violet	1.000000	5
1883	1883_Soave_Francesco_Les-bijoux-volés	1.000000	5
1833	1833_Touchard-L_Georges_Le-Bosquet-de-Romainville,-con	1.000000	6
1889	1889_Gaulard_G._Diane,-Prestaud,-Rustaud-et-Bo	1.000000	5
1803	1803_Dampmartin_Anne-Henri_Des-romans-,-par-A.-H.-Dampmar	1.000000	5
1879	1879_Cladel_Léon_Petits-cahiers	1.000000	5
1890	1890_Bertin_Marthe_Maltaverne	1.000000	5
1911	1911_Hyliane_Jacques_Lolotte-en-liberté	1.000000	5
1900	1900_Daudet_Alphonse_Premier-voyage,-premier-menson	1.000000	6
1890	1890_Perey_Lucien_La-Forêt-enchantée,-ou-Tranqui	1.000000	5
1904	1904_Taxil_Léo_Marchands-de-chair-humaine	1.000000	6
1901	1901_Mélandri_Achille_Un-bal-masqué	1.000000	5
1830	1830_Castillon_Frédéric-d_La-maîtresse-et-la-femme-marié	1.000000	8
1822	1822_none_none_Léonce-ou-Le-frère-de-la-doctr	1.000000	12
1927	1927_Fleuriot_Zénaïde_Monsieur-Nostradamus	1.000000	10
1884	1884_none_none_Jeannot.-Conte-inédit	1.000000	6
1869	1869_Dupin_O_Le-petit-Noël	1.000000	5
1860	1860_Lescure_Adolphe-de_Eux-et-elles	1.000000	5
1884	1884_Kock_Henry-de_Les-treize-nuits-de-Jane	0.916667	11
1886	1886_Genlis_Stéphanie-_Contes-moraux-de-Mme-de-Genlis	0.909091	10
1887	1887_Dubut-de-L_Jean-Louis_La-bonne-à-tout-faire	0.909091	10
1837	1837_Reybaud_Henriette-_Deux-à-deux	0.909091	10
1870	1870_Soulié_Frédéric_Le-Lion-amoureux.-La-Femme-du	0.904762	19
1908	1908_Germain_Henri_La-Belle-Louison	0.888889	8
1927	1927_Augé_Lucy_Lheure-du-crépuscule	0.888889	8
1882	1882_Monteil_Edgar_Rochefière	0.888889	8

Continue à la page suivante

Year	Titre	Prop. non-av.	# vois. non-av.
1866	1866_Gonzalès_Emmanuel_LHeure-du-berger,-par-Emmanue	0.888889	16
1875	1875_Hupin_Ernest_Au-temps-du-muguet	0.888889	8
1889	1889_Valtine_Marie-Alix_Belle-et-bonne	0.875000	7
1860	1860_LÉpinay_Marie-de_Clara-de-Noirmont	0.866667	13
1830	1830_Radcliffe_Ann_La-forêt,-ou-Labbaye-de-Saint	0.863636	19
1862	1862_Pommier_Armand_La-Dame-au-manteau-rouge,-hist	0.857143	6
1913	1913_Lesueur_Daniel_Au-tournant-des-jours-(Gilles-	0.857143	6
1867	1867_Vigne_Ange_Lémeraude-de-Berthe	0.857143	6
1887	1887_Du-Chateau_Pierre_Le-roman-de-Christian	0.857143	6
1869	1869_Stahl_P.-J._Hector-le-Fanfaron	0.857143	6
1865	1865_Assollant_Alfred_Une-Ville-de-garnison,-par-Alf	0.846154	11
1873	1873_Rouquette_Jules_La-route-fatale	0.833333	5
1882	1882_Gautier_Judith_Isoline	0.833333	5
1879	1879_Berthet_Élie_Paul-Duvert	0.833333	5
1897	1897_Barr_Maurice_Bluette-et-Coquelicot	0.833333	5
1862	1862_Bocage_Paul_Christian-de-Sauveterre	0.833333	5
1898	1898_Bilhaud_Paul_Histoire-du-bon-Cric-et-du-méc	0.833333	5
1878	1878_Chevalier_Henri-Émil_La-Fille-du-pirate,-légende-de	0.833333	5
1908	1908_Hauteville_Madame-d_Les-aventures-dune-poupée,-ou	0.833333	5
1903	1903_Dupuis_Eudoxie_Le-nain-à-la-citrouille	0.833333	5
1883	1883_Féval_Paul_La-fille-du-Juif-errant	0.833333	10
1832	1832_Saint-Maur_Charles-R._Gilbert,-chronique-de-lHôtel-	0.833333	5
1874	1874_Mirecourt_Eugène-de_Le-Fou-par-amour,-[La-clé-de-c	0.833333	5
1891	1891_Dubut-de-L_Jean-Louis_Colette-et-Renée	0.833333	5
1837	1837_Méry_Louis_Les-Boucles-doreilles,-souven	0.833333	5
1843	1843_Thomas_Frédéric_Un-coquin-doncle	0.833333	5
1877	1877_Roy_Just-Jean-_Le-moulin-de-laveugle-ou-Les-	0.833333	5
1881	1881_Stolz_Madame-de_Les-deux-reines	0.833333	10
1876	1876_Sue_Eugène_Les-Romans-parisiens.-Nouvelle	0.824561	47

Continue à la page suivante

Year	Titre	Prop. non-av.	# vois. non-av.
1858	1858_Ricard_Auguste_Le-Marchand-de-coco,-roman-de-	0.818182	9
1890	1890_About_Edmond_Nouvelles-et-souvenirs	0.818182	9
1885	1885_Ségalas_Anaïs_Récits-des-Antilles	0.800000	4
1879	1879_Gouraud_Julie_Les-enfants-de-la-ferme	0.800000	4
1868	1868_Perrault_Charles_Cendrillon	0.800000	4
1840	1840_Musset_Paul-de_Guise-et-Riom	0.800000	4
1877	1877_Carrance_Évariste_Les-aventures-du-Docteur-Van-d	0.800000	4
1890	1890_Irving_Washington_Le-souterrain-de-lAlhambra	0.800000	4
1914	1914_Gouvieux_Marc_Haut-les-ailes- !-carnet-de-rou	0.800000	4
1860	1860_Capendu_Ernest_Les-Mystificateurs	0.800000	4
1884	1884_Montifaud_Marc-de_Les-folles-journées	0.800000	4
1909	1909_Perrault_Charles_Le-petit-chaperon-rouge	0.800000	4
1924	1924_Cherbuliez_Victor_Le-comte-Kostia	0.800000	4
1882	1882_Gautier_Judith_Isoline-et-la-fleur-serpent	0.800000	8
1867	1867_Ponson-du-_Pierre-Ale_Les-fils-de-Judas	0.800000	4
1878	1878_Diard_Louise_La-batelière-de-Venise	0.800000	4
1885	1885_Améro_Constant_Le-tour-de-France-dun-petit-P	0.800000	4
1854	1854_Dumas_Alexandre_Ingénue.-[Blanche-de-Beaulieu.	0.800000	4
1857	1857_Aycard_Marie_Le-Diamant-de-famille,-par-Mar	0.800000	8
1886	1886_Largillièr_Paul_En-vacances-à-la-campagne	0.800000	4
1863	1863_Tardieu_Jules_Le-livre-des-enfants-qui-ne-sa	0.800000	4
1863	1863_Avenel_Paul_La-Nuit-porte-conseil	0.800000	4
1877	1877_none_none_Les-aides-de-père-et-de-mère	0.800000	4
1909	1909_none_none_Le-roman-du-Renard	0.800000	4
1833	1833_Perrault_Charles_Cendrillon,-ou-La-petite-panto	0.800000	4
1851	1851_Murger_Henry_Le-pays-latin	0.800000	4
1847	1847_Lacroix_Jules_Le-mauvais-ange	0.800000	4
1875	1875_Second_Albéric_Les-Demoiselles-du-Ronçay,-par	0.800000	4
1846	1846_Sue_Eugène_Deleytar	0.800000	4

Continue à la page suivante

Year	Titre	Prop. non-av.	# vois. non-av.
1864	1864_Méry_Joseph_Ursule	0.800000	4
1897	1897_Mouans_Anne_Frisonne-lengourdie,-par-A.-M	0.800000	4
1915	1915_Morphy_Michel_La-Dame-aux-violettes	0.800000	4
1879	1879_Fonvielle_Wilfrid-de_Néridah	0.800000	4
1892	1892_Le-Roux_Hugues_Les-gens-daujourdhui	0.800000	4
1915	1915_Germain_Henri_Rivalité-damour	0.800000	8
1868	1868_Grave_Théodore-d_Les-Duellistes.-Préface,-par-J	0.800000	4
1881	1881_Sue_Eugène_Les-misères-des-enfants-trouvé	0.800000	12

Romans infiltrés ajoutés

TABLE 10.9 : Romans infiltrés ajoutés au corpus initial (règle : ≥80% de voisins aventures).

Year	Titre (identifier)	Prop. av.	# vois. av.
1882	1882_Joliet_Charles_Le-crime-du-pont-de-Chatou	1.000000	5
1885	1885_Lalaing_Édouard-de_Souvenirs-dune-clef	1.000000	6
1899	1899_Brunet_Louis_Fille-de-France	1.000000	8
1887	1887_Lubomirski_Józef_Fonctionnaires-et-boyards	1.000000	6
1878	1878_Verne_Jules_Le-Chancellor	1.000000	5
1851	1851_Marmontel_Jean-Franç_Les-Incas,-ou-la-Destruction-d	1.000000	6
1880	1880_Rowcroft_Charles_Contes-des-colonies.-Le-Colon-	1.000000	7
1939	1939_Dorlys_Michel_Forêt-perfide-et-mer-douce	1.000000	7
1879	1879_Poe_Edgar-Alla_Nouvelles-américaines.-Traduct	1.000000	9
1884	1884_Aimard_Gustave_Lami-des-blancs	1.000000	5
1866	1866_La-Landell_Gabriel-de_[Le-Tableau-de-la-mer.-Moeurs-	1.000000	5
1878	1878_Friedel_Louis_Les-naufragés-au-Spitzberg,-ou	1.000000	5
1889	1889_Verne_Jules_Famille-sans-nom	1.000000	5
1869	1869_Reid_Thomas-May_Les-chasseurs-de-girafes	1.000000	12
1933	1933_Hellé_André_La-croisière-des-enfants	1.000000	7
1881	1881_Gozlan_Léon_Histoire-de-cent-trente-femmes	1.000000	6
1897	1897_Dujarric_Gaston_Le-roman-dun-capitaine-de-nav	1.000000	5
1895	1895_Zagoulĭaev_Iouliĭa-Mi_Les-Conteurs-russes-modernes,-	1.000000	5
1865	1865_Marryat_Capitaine_Le-Pirate,-par-le-capitaine-Ma	1.000000	18
1874	1874_Dubarry_Armand_LAlsace-Lorraine-en-Australie	1.000000	5
1885	1885_Lepage_Auguste_Le-roman-dun-héros	1.000000	7
1891	1891_Cahun_Léon_Hassan-le-janissaire	1.000000	5
1863	1863_Éthampes_Gabrielle-_Les-Orphelins-bretons,-épisode	1.000000	5
1892	1892_Demesse_Henri_La-petite-orpheline	1.000000	7

Continue à la page suivante

Year	Titre	Prop. av.	# vois. av.
1843	1843_Lacroix_Paul_Un-duel-sans-témoins,-histoire	1.000000	5
1884	1884_Nervo_Jean-Bapti_La-duchesse-de-Puerto-Real	1.000000	5
1831	1831_Thomas_Eugène_Jean-Cavalier,-ou-les-Camisard	1.000000	6
1822	1822_Gottis_Augustine_Jeanne-dArc,-ou-lHéroïne-fra	1.000000	5
1896	1896_Cooper_James-Feni_Le-cratère,-ou-Le-Robinson-amé	1.000000	7
1884	1884_Sirven_Alfred_Lenfant-dune-vierge	1.000000	7
1853	1853_Campe_Joachim-He_Le-Robinson-allemand,-traduit-	1.000000	5
1887	1887_Celières_Paul_Une-exilée	1.000000	5
1877	1877_Berthet_Élie_Le-braconnier	1.000000	5
1925	1925_Moselli_José_Les-Mystères-de-la-mer-de-Cora	1.000000	8
1874	1874_Gerstäcker_Friedrich_Les-voleurs-de-chevaux	1.000000	7
1904	1904_Verne_Jules_Un-drame-en-Livonie	1.000000	6
1852	1852_Gobineau_Arthur-de_Les-aventures-de-Nicolas-Belav	1.000000	6
1938	1938_Mille_Pierre_Féli-et-Mbala-léléphant.-Ill	1.000000	5
1854	1854_Maquet_Auguste_La-Chute-de-Satan,-par-Auguste	1.000000	5
1915	1915_Turrillot_Berthe_Patrie,-reine-des-fées...-proj	1.000000	5
1912	1912_Darville_Lucien_Sans-boussole	1.000000	5
1899	1899_Verne_Jules_LÉtoile-du-Sud	1.000000	10
1888	1888_Verne_Jules_Le-chemin-de-France	1.000000	5
1856	1856_Ferry_Gabriel_Le-Capitaine-Pallavidas,-par-G	1.000000	5
1886	1886_Gastyne_Jules-de_Labandonné	1.000000	6
1847	1847_Balzac_Honoré-de_La-dernière-incarnation-de-Vau	1.000000	5
1853	1853_Pavie_Théodore_Scènes-et-récits-des-pays-dou	0.928571	13
1894	1894_Hervilly_Ernest-d_En-bouteille-à-travers-lAtlan	0.916667	11
1868	1868_Ponson-du-_Pierre-Ale_Ponson-Du-Terrail.-Le-Dernier-	0.909091	10
1886	1886_Cooper_James-Feni_Lespion	0.888889	8
1872	1872_Héricault_Charles-d_Thermidor	0.875000	7

Continue à la page suivante

Year	Titre	Prop. av.	# vois. av.
1834	1834_Alexis_Willibald_Cabanis,-ou-La-guerre-de-sept-	0.875000	7
1879	1879_Verne_Jules_Michel-Strogoff	0.875000	7
1884	1884_Guéroult_Constant_Laffaire-de-la-rue-du-Temple	0.875000	7
1869	1869_Servan_Félix-de_Louis-XI-à-Amiens	0.863636	19
1873	1873_Vindex_Jacques_Le-Château-noir,-roman-histori	0.857143	6
1883	1883_Tourzo_Cte_Dans-les-Karpathes.-La-mort-de	0.857143	6
1880	1880_Richebourg_Émile_Le-fils	0.857143	6
1890	1890_Haggard_Henry-Ride_Découverte-des-mines-du-roi-Sa	0.857143	6
1902	1902_Talbot_Juliette_Périlleuse-aventure...	0.857143	6
1899	1899_Huet_Vincent_Les-cavernes-de-Hall-el-Houed	0.857143	6
1869	1869_Berthet_Élie_Le-démon-de-la-chasse	0.857143	6
1928	1928_Vincent_Paul_Le-fantôme-vert	0.857143	6
1907	1907_Méhier-de-_Henri_De-la-montagne-au-désert	0.846154	11
1930	1930_Derème_Tristan_Patachou,-petit-garçon	0.833333	5
1913	1913_Larallège_J._Lucien-Moulin	0.833333	5
1834	1834_Ménard_Ernest_Romans-historiques-bretons	0.833333	5
1935	1935_Ivoi_Paul-d_Le-radium-qui-tue	0.833333	5
1904	1904_Jacquin_Joseph_La-jeunesse-de-Cyrano-de-Berge	0.833333	5
1843	1843_Lespès_Léo_Les-mystères-du-grand-opéra	0.833333	5
1877	1877_Noir_Louis_La-femme-coupée-en-morceaux	0.833333	5
1857	1857_Dumas_Alexandre_La-comtesse-de-Charny	0.833333	5
1888	1888_Reid_Thomas-May_Bruin-ou-Les-chasseurs-dours	0.833333	5
1934	1934_Ivoi_Paul-d_Cigale-en-Chine	0.833333	5
1889	1889_Dargène_Jean_Le-feu-à-Formose	0.833333	5
1833	1833_Martin_Henri_Le-libelliste	0.833333	5
1861	1861_Dumas_Alexandre_Aventures-de-Lydéric	0.833333	5
1862	1862_Ponson-du-_Pierre-Ale_Les-spadassins-de-lOpéra	0.833333	5
1866	1866_Robert_Clémence_La-Fiancée-de-la-cour,-suite-d	0.833333	5
1913	1913_Gobineau_Arthur-de_Nouvelles-asiatiques	0.833333	10

Continue à la page suivante

Year	Titre	Prop. av.	# vois. av.
1899	1899_Verne_Jules_Le-testament-dun-excentrique	0.833333	5
1876	1876_Roy_Just-Jean-_Théodore-et-Louis-ou-Le-rempla	0.833333	5
1904	1904_Dumas_Alexandre_Les-quarante-cinq	0.833333	5
1900	1900_Loti_Pierre_Le-mariage-de-Loti	0.833333	5
1861	1861_Pont-Jest_René-de_Le-Fire-fly.-Souvenirs-des-Ind	0.833333	5
1909	1909_Kipling_Rudyard_Capitaines-courageux,-une-hist	0.833333	5
1872	1872_Kock_Henry-de_La-Grande-empoisonneuse,-par-H	0.818182	9
1853	1853_Méry_Joseph_La-Floride	0.818182	9
1862	1862_Desvosges_G._La-Jeunesse-de-Pierrette,-mémo	0.800000	4
1863	1863_Du-Gout-d_Joseph_Le-solitaire-de-la-Tour-dAvan	0.800000	8
1866	1866_Montépin_Xavier-de_Diane-et-Blanche,-troisième-pa	0.800000	4
1930	1930_Laeufer_Yvonne_Oeil-pour-oeil-(contes-arabes)	0.800000	4
1883	1883_Carpentier_Émilie_Les-Ignorances-de-Madeleine,-p	0.800000	4
1852	1852_Méry_Joseph_Trafalgar,-par-Méry	0.800000	4
1886	1886_Diguet_Charles_Mémoires-dun-lièvre	0.800000	4
1850	1850_Soulié_Frédéric_Le-Comte-de-Toulouse,-par-Fréd	0.800000	4
1892	1892_Assollant_Alfred_La-chasse-aux-lions	0.800000	4
1840	1840_Pitre-Chev_none_Jeanne-de-Montfort-(époque-gue	0.800000	4
1882	1882_Beugny-dH_Gabriel-de_La-vallée-maudite	0.800000	4
1878	1878_Bougy_Alfred-de_La-vengeance-du-bravo	0.800000	4
1893	1893_Cim_Albert_Spectacles-enfantins,-par-Albe	0.800000	4
1911	1911_Hue_Gustave-Fe_Les-chasseurs-du-roi	0.800000	4
1857	1857_Gautier_Théophile_Avatar,-par-Théophile-Gautier.	0.800000	4
1857	1857_Gozlan_Léon_Un-fou-couronné	0.800000	4
1881	1881_Martineau_Harriet_Contes-choisis-sur-léconomie-	0.800000	4

Continue à la page suivante

Year	Titre	Prop. av.	# vois. av.
1840	1840_Bürger_Gottfried-_Histoire-et-aventures-du-baron	0.800000	8
1868	1868_Laboulaye_Édouard_Le-Prince-Caniche,-par-Édouard	0.800000	4
1883	1883_Giron_Aimé_Les-cinq-sous-dIsaac-Laquedem	0.800000	4
1859	1859_Méry_Joseph_La-guerre-du-Nizam	0.800000	4
1901	1901_Ferry_Gabriel_Les-prouesses-de-Martin-Robert	0.800000	4
1881	1881_Verne_Jules_La-Jangada,-huit-cents-lieues-	0.800000	4
1884	1884_France_Jeanne_Le-Mystère-dun-vieux-château,	0.800000	4
1878	1878_Driou_Alfred_La-fille-du-sonneur	0.800000	4
1915	1915_Kipling_Rudyard_Simples-contes-des-collines	0.800000	4
1909	1909_Colonna-de_Raoul_Vengeances-corses	0.800000	4
1887	1887_Maria_Carla_Parsis-et-brahmine	0.800000	4
1830	1830_Aycard_Marie_Le-Sire-de-Moret,-page-du-roi-	0.800000	4
1879	1879_Wiseman_Nicholas_Fabiola,-ou-LÉglise-des-catac	0.800000	4
1925	1925_Groslier_George_La-route-du-plus-fort	0.800000	4
1887	1887_Flammarion_Camille_Lumen	0.800000	4
1879	1879_Henry_Théodore_La-duchesse-Hélène	0.800000	4
1845	1845_Guichard_Antony_Arthur-et-Laure-ou-Les-petits-	0.800000	4
1879	1879_Lemoine_none_La-guerre-pendant-les-vacances	0.800000	4
1925	1925_Féval_Paul_La-bague-de-chanvre	0.800000	4
1888	1888_Lermina_Jules_Jeanne-dArc	0.800000	4
1928	1928_Londres_Albert_Lhomme-qui-sévada	0.800000	4
1836	1836_Cayla_Jean-Mamer_Chroniques-du-midi	0.800000	4
1901	1901_Busnach_William_Le-crime-du-bois-de-Verrières,	0.800000	4
1895	1895_Émery_René_En-plein-amour	0.800000	4

Annexes du chapitre 9

Les tableaux ci-dessous présentent, pour chaque cluster produit par le *K-moyennes*, les mots les plus distinctifs selon le score *TF-IDF*. Chaque cluster est traité comme un document unique, obtenu par concaténation de l'ensemble de ses passages, et le score met en évidence les termes fréquents dans ce cluster mais rares dans les autres.

Ces profils lexicaux sont fournis à titre indicatif : ils visent à donner au lecteur un repère interprétatif rapide sur le contenu dominant de chaque cluster. L'interprétation proprement dite

s'est appuyée avant tout sur la lecture de trois ou quatre passages prototypiques par cluster ; les reproduire ici aurait toutefois considérablement alourdi l'annexe. Il faut en outre rappeler que ces mots ne correspondent pas à la représentation effectivement utilisée par l'algorithme, qui repose sur des embeddings contextuels capables de saisir des régularités sémantiques et syntaxiques plus riches que le seul lexique. Enfin, quelques clusters correspondent à des artefacts du corpus, avec des passages en langue étrangère intégrés aux romans, ou des segments de paratexte éditorial issus d'une mauvaise segmentation. Ils n'ont pas, en tant que tels, de signification littéraire.

Corpus policier

TABLE 10.10 : Profils lexicaux indicatifs des 50 modes discursifs du corpus policier. Pour chaque cluster, les mots les plus distinctifs (TF-IDF) sont présentés après filtrage des artefacts d'OCR, du paratexte éditorial et des tokens en langue étrangère. Ces profils lexicaux sont fournis à titre illustratif pour faciliter l'identification du contenu de chaque mode ; ils ne correspondent pas à la représentation vectorielle effectivement utilisée pour le clustering et le calcul des métriques. n : nombre de passages dans le cluster.

C	n	**Mots distinctifs (TF-IDF)**
0	681	*metiers, abbé, écrie, couac, gaudry, celte, coquin, mémoires*
1	8 152	*téléphone, inspecteurs, taxi, téléphoné, orfèvres, allô, téléphoner, immeuble*
2	125	*rames, barques, moteur, roseaux, yvoire, pêcheurs, morden, caravane*
3	380	*poubelles, johannes, renaissance*
4	1 555	*(cluster bruité : paratexte ou langue étrangère)*
5	1 314	*fantomes, moteur, ardentes, levert, aureus, théophraste, scie, balican*
6	433	*ben, ferrant, abbé, brigadier, magot, bouquetin, clergeon, maréchal*
7	2 219	*londres, laird, bristol, celte, élança, lord, commodore, intendant*
8	934	*merde, mec, boulot, flics, jarretelles, tronche, flic, motos*
9	1 318	*cigognes, téléphone, photo, photos, codex, ornithologue, décidai, film*
10	2 176	*détective, policier, lupin, arsène, téléphone, tressaillit, dollars, documents*
11	1 741	*hall, téléphone, fentolin, remarqua, mouchette, hamel, tressaillit, émerveillée*
12	1 761	*téléphone, flétan, photos, merde, otages, flics, portable, photo*
13	250	*baronne, elisabeth, roseraie, jones, tchéri, forestier, gouvernante, injurieux*

Suite page suivante

C	n	Mots distinctifs (TF-IDF)
14	659	*tribu, esquimaux, grotte, kanguroos, indiens, campement, esquimau, kogmollocks*
15	1 928	*reum, super, flics, merde, téléphone, mec, meuf, vachement*
16	1 416	*chah, avion, téléphone, aéroport, gorilles, turc, pétrolier, taxi*
17	4 217	*flic, flics, merde, téléphone, boulot, photos, mec, métro*
18	491	*(cluster bruité : paratexte ou langue étrangère)*
19	887	*orchestre, millionnaire, dot, dettes, industriel, tressaillit, résolut, empressement*
20	261	*(cluster bruité : paratexte ou langue étrangère)*
21	646	*mémoires, celte, tems, beautés, œuvre, amans, mysteres, enfans*
22	989	*chevalier, vicomte, duchesse, gentilhomme, baronne, duc, maurevert, gandins*
23	811	*duc, duchesse, chevalier, monseigneur, sire, pyrénées, tsarine, majesté*
24	2 228	*baronne, gandins, vicomte, duc, fiacre, procureur, celte, duchesse*
25	176	*sophie, dzi, youcef, appuie, cerf, agile, salaud, hurle*
26	535	*parking, photos, archives, corse, photo, cadres, exxyal, écran*
27	842	*vicomte, bondon, fiacre, orchestre, dot, rentes, champagne, baronne*
28	581	*patronne, allô, amants, garage, lupin, taxi, studio, téléphone*
29	446	*maitresse, mariee, léonce, sentimens, élise, clémence, vœux*
30	420	*carvajeros, sierra, senor, hacienda, zercaderos, peones, vautour, vaqueros*
31	929	*astrale, potion, gandins, celte, pouls, laboratoire, bossière, charpie*
32	1 042	*prussiens, major, allemands, hotel, régiment, donjon, niorres, russes*
33	104	*condottière, gote, glandes, faussaire, chardin, antonello, dépassant, chaotiques*
34	524	*mémoires, albe, colmant, fieschi, préfet, pulmonie, député, celte*
35	342	*charron, taxi, bébé, hibiscus, cinéma, vautour*
36	1 537	*étoit, avoit, celte, seroit, ame, delphine, convicts, baronne*
37	1 155	*téléphone, condottière, boulot, photos, métro, photo, cinéma, truc*
38	1 359	*veilleux, téléphone, camion, merde, bétaillère, photo, taxi, truc*

Suite page suivante

C	n	**Mots distinctifs (TF-IDF)**
39	649	*centurion, abbé, rome, tondeur, druides, matrone, consul, gaulois*
40	530	*léonce, sœurs, valentine, calèche, cle, sophie, mignonne, celte*
41	144	*poeme, méconnue, werther*
42	2 400	*détective, verrières, convicts, policier, procureur, téléphone, journaliste, préfet*
43	743	*fermier, chanvrier, aubergiste, abbé, résinier, bourres, tems, sanglier*
44	709	*matelot, matelots, commodore, chaloupe, marins, brick, cabine, passagers*
45	2 301	*fiacre, policier, caissier, procureur, celte, vicomte, gobette, chevalier*
46	2 881	*procureur, greffier, préfet, magistrats, audience, déposition, jury, policier*
47	295	*scarabée, kanguroos, gorille, marna, aria, kanguroo, sarvants, eyry*
48	2 079	*vicomte, duchesse, duc, baronne, chevalier, procureur, adrets, colporteur*
49	901	*aéronef, uncle, embarcation, barge, albatros, major, chaland, cabine*

Corpus d'aventures

TABLE 10.11 : Profils lexicaux indicatifs des 50 modes discursifs du corpus d'aventures. Pour chaque cluster, les mots les plus distinctifs (TF-IDF) sont présentés après filtrage des artefacts d'OCR, du paratexte éditorial et des tokens en langue étrangère. Ces profils lexicaux sont fournis à titre illustratif pour faciliter l'identification du contenu de chaque mode ; ils ne correspondent pas à la représentation vectorielle (embeddings) effectivement utilisée pour le clustering et le calcul des métriques. n : nombre de passages dans le cluster.

C	n	Mots distinctifs (TF-IDF)
0	1 726	*camisards, monseigneur, chrétiens, guerriers, ermite, chrétien, druides, moines*
1	533	*val, actrice, sentimens, pudeur, chaste, maitresse, lys, flattée*
2	473	*clarinetti, bourgmeister, roncier, hadgi, stavros, nina, claudin, bourricot*
3	2 330	*matelots, navires, corvette, brick, canot, frégate, chaloupe, pirates*
4	2 234	*brigadier, loups, aubergiste, pistolets, veneur, bandit, braconnier, gars*
5	1 099	*fiacre, client, million, dollars, pâtissier, vicomte, caissier, bretons*
6	709	*émir, arabes, mosquée, daoud, sultan, suleiman, bin, arabe*
7	1 781	*radeau, canot, rivage, nautilus, indien, indiens, matelots, schooner*
8	361	*anus, gange, marraine, fillettes, vacances, cousins, aanit, institutrice*
9	2 998	*indiens, indien, indigènes, caravane, tribu, louveteau, serpents, loups*
10	1 548	*précigny, vicomte, chapelain, étang, baronne, monseigneur, gandins, duchesse*
11	1 219	*(cluster bruité : paratexte ou langue étrangère)*
12	2 598	*sire, monseigneur, duchesse, altesse, cardinal, régent, maréchal, trône*
13	298	*maitresse, empereur, mariee, diligence, lyon, baronne, yug, hongroise*
14	349	*exposition, flic, trial, population, solferino, albe, commo*
15	193	*suzette, lolotte, tircis, claudin, grenadine, fred, danseuse, vote*
16	2 440	*guerriers, troupes, arabes, arabe, guerrier, sultan, brahmane, fakir*

Suite page suivante

C	n	Mots distinctifs (TF-IDF)
17	279	*biberons, ouais, chourineur, cloc, galette, ganabé, muscadins, financier*
18	948	*kaiserlicks, troupes, prussiens, caporal, empereur, allemands, tapin, baïonnette*
19	857	*batard, léonce, clémence, ouvrière, chanoinesse, curé, chapelain, commodore*
20	2 077	*projectile, ingénieur, lunaire, bolide, pôle, kilomètres, ballon, disque*
21	1 061	*poupée, œufs, patte, renard, éléphant, tortue, turbide*
22	48	*hindoues, poinsard, hindoue, torpilleur, vénus, promeneuse, bouddhisme, stuart*
23	2 713	*turcs, pacha, convicts, schwartz, empereur, banjo, aïdin, bandit*
24	161	*chanaan, document, pickpocket, tonga, dollars, runique, radium, frinc*
25	726	*vicomte, baronne, duchesse, pimodan, fiacre, olbreuse, hotel, vicomtesse*
26	149	*jazz, band, film, violoniste, opale, cigarette, bistrot, firme*
27	1 744	*cardinal, artagnan, mousquetaires, sire, monseigneur, éminence, gentilshommes, mousquetaire*
28	1 070	*baronne, tulipe, léonce, edward, maitresse, mariee, poëte, danseuse*
29	2 163	*monseigneur, sire, vicomte, prévôt, cardinal, messire, régent, artagnan*
30	974	*étoit, avoit, avois, étois, delphine, seroit, aurois, auroit*
31	122	*shu, cargo, broutavoine, fly, dindes, frits, mum, cabine*
32	149	*évada, bagne, chanaan, forçats, pirogue, venet, milreis, pernambouc*
33	2 830	*dayaks, négrito, ranch, indiens, convicts, trappeur, canot, ingénieur*
34	952	*russes, empereur, polonais, verstes, roubles, cosaques, moscovite, czar*
35	522	*détective, ladko, policier, radium, firme, avion, enquête, film*
36	2 196	*indiens, indien, armurier, guerriers, carabine, loups, peaux, campement*
37	3 199	*cabine, passagers, milles, embarcation, cap, canot, navires, matelots*
38	475	*abbé, curé, prélat, archevêque, évêque, monseigneur, pape, eglise*

Suite page suivante

C	n	Mots distinctifs (TF-IDF)
39	1 383	*batard, londres, tulipe, laird, chirurgien, cachot, souterrain, geôlier*
40	1 694	*matelot, matelots, canot, frégate, corvette, cabine, mât, brick*
41	1 904	*sire, troupes, monseigneur, chevaliers, connétable, pucelle, maréchal, gentilshommes*
42	121	*décagrammes, cochon, hectare, poissons, baghavat, manécanterie, lalouette, pilois*
43	713	*procureur, accusés, greffier, bristol, assassinat, arrestation, policier, gendarme*
44	1 316	*ello, commo, espagnols, monseigneur, senor, espagnole, gondole, dona*
45	582	*doctrine, chrétienne, emerance, maitresse, léonce, frere, mariee, sentimens*
46	2 384	*indiens, indien, hacienda, rio, pirogues, falcas, sierra, senor*
47	1 768	*empereur, troupes, comité, boy, scout, allemands, convention, artillerie*
48	159	*maitresse, mariee, élise, henriette, léonce, sentimens, stryga, chétardie*
49	652	*précigny, curé, étang, gars, manufacturier, bourg, perrine, fabrique*

RÉSUMÉ

Cette thèse propose une approche computationnelle de la littérature de genre dans la fiction de langue française, en articulant la théorie de l'intertextualité, la modélisation statistique et une analyse des textes à grande échelle. Elle prend appui sur la prémisse structuraliste selon laquelle les œuvres n'existent pas comme unités closes mais comme nœuds d'un réseau de relations, et soutient que les méthodes computationnelles en constituent une opérationnalisation directe. Elles rendent observables, sur de grands corpus, des régularités et des transformations qui échappent à la lecture individuelle.

La première partie construit ce cadre théorique et méthodologique, autour de la notion d'intertextualité, et de sa pertinence pour la notion de genre. Cette dernière y est définie comme une dimension à la fois interne et externe aux textes. Les études littéraires computationnelles se révèlent être une discipline privilégiée pour traiter les conséquences formelles des dispositifs contextuels spécifiques à la littérature de genre. Il s'agit également de mener une présentation critique des principales méthodes computationnelles employées.

La deuxième partie met ce cadre théorique à l'épreuve sur le roman policier (1866--2020). Elle identifie la signature textuelle du roman policier à partir d'une modélisation supervisée et contrôle la robustesse des résultats en examinant les cas limites. Elle analyse ensuite l'archétype du détective, figure clé du genre par la construction d'un *détecteur de détectives*. Cela permet de suivre la stabilité et les transformations de l'enquêteur au cours de l'histoire du genre. Enfin, l'étude de la *naissance* du roman policier montre une sédimentation progressive de trois caractéristiques formelles indépendantes avant la stabilisation médiatique du genre dans les années 1930 : la persistance du thème criminel, la centralité du détective dans le récit et la structure prototypique de l'intrigue, tirée du crime vers sa résolution.

La troisième partie change d'échelle et compare le roman policier au roman d'aventures en proposant de prédire leur présence au sein du corpus romanesque des archives de la Bibliothèque nationale de France. Il s'agit ensuite de détecter la signature du genre au niveau de ses scènes stéréotypiques, entre mésaventure et dépaysement. Elle teste enfin l'hypothèse d'une normalisation formelle accompagnant l'avènement des collections spécialisées dans l'entre-deux-guerres, et montre, en mesurant la diversité discursive de ces deux genres avant et après leur cristallisation éditoriale, que cette reconnaissance s'accompagne d'une contraction de l'espace des possibles discursifs.

MOTS CLÉS

littérature de genre, études littéraires computationnelles, romans d'aventures, romans policiers, traitement automatique des langues, lecture distante

ABSTRACT

This thesis proposes a computational approach to genre fiction in French-language literature, articulating intertextuality theory, statistical modelling, and large-scale text analysis. It builds on the structuralist premise that literary works do not exist as self-enclosed units but as nodes in a network of relations, and argues that computational methods constitute a direct operationalisation of this premise. They make it possible to observe, across large corpora, regularities and transformations that elude individual reading.

The first part constructs this theoretical and methodological framework around the notion of intertextuality and its relevance to the notion of genre. Genre is defined therein as a dimension that is both internal and external to texts. Computational literary studies prove to be a privileged discipline for addressing the formal consequences of the contextual apparatus specific to genre fiction. This part also offers a critical presentation of the main computational methods employed.

The second part puts this theoretical framework to the test on the detective novel (1866–2020). It identifies the textual signature of the detective novel through supervised modelling and checks the robustness of the results by examining borderline cases. It then analyses the archetype of the detective, a key figure of the genre, through the construction of a *detective detector*. This makes it possible to track the stability and transformations of the investigator over the history of the genre. Finally, the study of the *birth* of the detective novel reveals a gradual sedimentation of three independent formal characteristics prior to the media stabilisation of the genre in the 1930s : the persistence of the criminal theme, the centrality of the detective within the narrative, and the prototypical structure of the plot, drawn from the crime towards its resolution.

The third part shifts scale and compares the detective novel with the adventure novel by attempting to predict their presence within the novelistic corpus of the Bibliothèque nationale de France archives. It then seeks to detect the genre's signature at the level of its stereotypical scenes, between misadventure and estrangement. Finally, it tests the hypothesis of a formal normalisation accompanying the advent of specialised collections in the interwar period, and shows, by measuring the discursive diversity of these two genres before and after their editorial crystallisation, that this recognition is accompanied by a contraction of the space of discursive possibilities.

KEYWORDS

genre literature, computational literary studies, adventure novels, detective novels, natural language processing, distant reading